



INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO



ESCOM

Trabajo Terminal

**“Prototipo para análisis automatizado y visualización de
comportamiento de especímenes en modelos de ansiedad”**

2026-A155

Presentan

Portocarrero Rodríguez Habid

Directores

Ramírez Guzmán Alicia Marcela

Salas Ramírez Israel

Junio 2026



INSTITUTO POLITÉCNICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO

SUBDIRECCIÓN ACADÉMICA



No de TT 2026-A155

junio de 2026

Documento Técnico

“Prototipo para análisis automatizado y visualización de comportamiento de especímenes en modelos de ansiedad”

Presentan

Portocarrero Rodríguez Habid¹

Directores

Ramírez Guzmán Alicia Marcela

Salas Ramírez Israel

RESUMEN

El presente proyecto desarrolla un prototipo de software orientado al análisis automatizado del comportamiento animal en modelos experimentales de ansiedad. Su propósito es optimizar los procesos de observación y evaluación que tradicionalmente se realizan de forma manual, reduciendo tiempos y errores humanos. A través de la aplicación de principios de ingeniería de software, se busca ofrecer una herramienta confiable, escalable y eficiente que contribuya al avance de la investigación científica dentro del ámbito biomédico.

¹hportocarreror1700@alumno.ipn.mx

CARTA RESPONSIVA

Que otorga visto bueno y avala la conclusión de documentación del Trabajo Terminal bajo los lineamientos establecidos por la Comisión Académica de Trabajos Terminales (CATT)

CDMX, junio de 2026

M. EN C. IVAN GIOVANNI MOSSO GARCÍA
PRESIDENTE DE LA COMISIÓN ACADÉMICA DE TRABAJOS TERMINALES
P R E S E N T E

EN ATENCIÓN A:

M. EN A.N. MARÍA MAGDALENA SALDIVAR ALMOREJO
SECRETARIA EJECUTIVA

Por medio de la presente, se informa que el Trabajo Terminal Núm.	2026-A155
Que lleva por Título:	Prototipo para análisis automatizado y visualización de comportamiento de especímenes en modelos de ansiedad

Fue concluido satisfactoriamente por:

Portocarrero Rodríguez Habid

Se avala que la documentación entregada mediante discos en formato DVD fue **revisada de manera precisa y exhaustiva** con el propósito de asegurar que los avances desarrollados bajo la supervisión de quien o quienes suscriben, hayan cumplido con lo planteado en el protocolo original, así como en lo establecido por el Documento Rector de Operación y Evaluación para los Trabajos Terminales de la ESCOM.

ATENTAMENTE
“LA TÉCNICA AL SERVICIO DE LA PATRIA”

Israel Salas Ramírez
Director

Alicia Marcela Ramírez Guzmán
Directora

Palabras clave:

Modelos de ansiedad, análisis Conductual Animal, ensayos Farmacológicos, visión por computadora (Computer Vision), estimación de Postura, detección de Objetos, inteligencia artificial (IA), aprendizaje automático (Machine Learning), minería de Datos (Data Mining), dashboard interactivo.

Advertencia

“Este documento contiene información desarrollada por la Escuela Superior de Cómputo del Instituto Politécnico Nacional, a partir de datos y documentos con derecho de propiedad y, por lo tanto, su uso quedará restringido a las aplicaciones que explícitamente se convengan.”

La aplicación no convenida exime a la escuela su responsabilidad técnica y da lugar a las consecuencias legales que para tal efecto se determinen.

Información adicional sobre este reporte técnico podrá obtenerse en:

La Subdirección Académica de la Escuela Superior de Cómputo del Instituto Politécnico Nacional, situada en Av. Juan de Dios Bátiz s/n Teléfono: 57296000, extensión 52000.

Agradecimientos

El equipo desea expresar su más sincero agradecimiento al **Instituto Politécnico Nacional** y a la **Escuela Superior de Cómputo (ESCOM)** por ser la base de nuestra formación profesional, el apoyo, orientación y por brindarnos los recursos necesarios para la realización de este proyecto.

A nuestros **directores**, la **Dra. Alicia Marcela Ramírez Guzmán** y el **Dr. Israel Salas Ramírez**, por su guía, paciencia y compromiso. Su acompañamiento constante, su exigencia académica y su apoyo humano fueron fundamentales para la consolidación de este trabajo. Gracias por enseñarnos que la investigación y la tecnología deben siempre ir acompañadas de ética, rigor y propósito.

A la **Escuela Nacional de Medicina y Homeopatía (ENMyH)**, por su colaboración y disposición en la etapa experimental del proyecto, y por permitirnos vincular la ingeniería con la ciencia biomédica.

A **nuestras familias**, quienes con amor, comprensión y apoyo incondicional fueron nuestra fortaleza durante todo el proceso. Su confianza nos motivó a superar cada obstáculo y a culminar esta etapa con orgullo.

A nuestros **compañeros, docentes y amigos** que, directa o indirectamente, compartieron su tiempo, conocimiento y entusiasmo, enriqueciendo este proyecto con su colaboración y sus ideas.

ÍNDICE

Contenido

Agradecimientos	6
Índice de tablas.....	15
Glosario de términos	15
Abreviaturas.....	20
Capítulo 1. Introducción	21
1.1 Antecedentes	21
1.2 Planteamiento del problema	22
1.3 Propuesta de solución.....	22
1.4 Objetivo general	23
1.4.1 Objetivos específicos.....	23
1.5 Justificación.....	24
1.6 Alcance del proyecto	24
1.7 Metodología	25
Capítulo 2. Estado del arte.....	27
2.1 Análisis etológico y temporal del comportamiento similar a la ansiedad: el modelo de EPM elevado 20 años después	28
2.2 El laberinto en T elevado como modelo experimental de ansiedad.....	28
2.3 El uso del EPM como un ensayo del comportamiento relacionado con la ansiedad en roedores	28
2.4 Prueba del EPM Combinado con Software de Seguimiento por Video para Investigar el Efecto Ansiolítico de Suplementos Cetogénicos Exógenos	29
2.5 Prueba del EPM para Evaluar el Comportamiento Similar a la Ansiedad en el Ratón.....	30
2.6 El diazepam provoca efectos sedantes más que ansiolíticos en ratones C57BL/6J	30
2.7 ezTrack: Un flujo de análisis de video de código abierto para la investigación del comportamiento animal.....	31
2.8 Analixity: Un sistema de análisis de código abierto y bajo costo para la prueba de EPM, basado en técnicas de visión por computadora.....	32
2.9 EthoVision.....	32
2.10 ANY-maze	33
2.11 Tabla Comparativa	33
Capítulo 3. Marco Teórico	36

3.1 Visión por computadora para seguimiento de objetos	36
3.1.1 YOLO (You Only Look Once).....	36
3.1.2 DeepLabCut.....	38
3.1.3 Estimación de postura (Pose Estimation)	40
3.1.4 CAMShift y métodos clásicos de seguimiento	42
3.1.5 Redes Neuronales Convolucionales (CNN) aplicadas a visión por computadora.....	44
3.2 Machine Learning para Series Temporales	46
3.2.1 Redes Neuronales Recurrentes (RNN).....	46
3.2.2 LSTM (Long Short-Term Memory)	47
3.2.3 Transformers.....	49
3.2.4 Coeficiente Kappa de Cohen para validación de concordancia.....	51
3.3. Minería de Datos y Clasificación de Comportamientos.....	53
3.3.1 K-Means (Clustering).....	53
3.3.2 Random Forest.....	55
3.3.3 Máquinas de Vectores de Soporte (SVM)	57
3.3.4 Reducción de dimensionalidad	59
3.4 Modelos experimentales en etología y neurociencia conductual	61
3.4.1 Conceptos etológicos del comportamiento ansioso	61
3.4.1.1 Exploración.....	61
3.4.1.2 Evitación.....	63
3.4.1.3 Inmovilidad/congelación	65
3.4.2 Laberinto en Cruz Elevada (EPM)	66
3.5 Sistema operativo	68
3.5.1 Windows 10/11	68
3.6 Lenguaje de programación	68
3.6.1 Python	68
Capítulo 4. Análisis.....	69
4.1 Requerimientos.....	69
4.1.1 Requerimientos Funcionales (RF)	69
4.1.2 Requerimientos No Funcionales (RNF)	70
4.1.3 Reglas del negocio.....	71
4.1.4 Identificación de requerimientos técnicos	73
4.1.5 Evolución e Iteración de Requerimientos del Prototipo	74

4.2 Análisis de las herramientas a utilizar.....	75
4.2.1 Análisis de técnicas de detección de objetos	75
4.2.2 Análisis comparativo de frameworks de estimación de pose	76
4.2.3 Selección de estimación de pose markerless para el prototipo.....	76
4.2.4 Análisis de herramientas de seguimiento visual.....	78
4.2.5 Análisis de arquitecturas de redes neuronales profundas para visión por computadora	78
4.2.6 Análisis de arquitecturas de aprendizaje profundo para series temporales	79
4.2.7 Análisis de técnicas de minería de datos	79
4.2.8 Análisis de sistemas operativos	79
4.2.9 Análisis de los lenguajes de programación.....	80
4.3 Análisis de riesgos.....	81
4.3.1 Criterios de Evaluación de Riesgos	81
4.3.2 Componentes de Riesgo	83
4.3.3 Clasificación e Identificación de Riesgos del Proyecto	83
4.3.4 Estrategias de Mitigación y Contingencia	84
4.4 Análisis de factibilidad.....	85
4.4.1 Factibilidad tecnológica	85
4.4.2 Factibilidad operativa	87
4.4.3 Factibilidad económica.....	88
4.4.3.1 Estimación del esfuerzo de desarrollo mediante COCOMO II	88
4.4.3.2 Parámetros del modelo COCOMO II	89
4.4.3.3 Esfuerzo y costo de desarrollo para los escenarios de software	89
4.4.3.4 Costos fijos de infraestructura	90
4.4.3.5 Costos variables de infraestructura.....	90
4.4.3.6 Costos consolidados y valoración económica total	91
4.4.3.7 Análisis costo-beneficio y retorno de inversión	91
4.4.3.8 Conclusión de viabilidad económica.....	92
4.4.4 Factibilidad legal	93
4.5 Análisis de sostenibilidad.....	94
4.5.1 Evaluación del consumo energético del proyecto	94
4.5.3 Impacto ambiental del proceso tradicional vs. el prototipo	95
4.5.4 Comparación con el prototipo	97
Capítulo 5. Diseño	99

5.1 Arquitectura del prototipo	99
5.2 Casos de uso	100
5.2.1 Casos de uso del prototipo.....	100
5.2.2 Especificación de casos de uso	102
5.3 Diagramas de secuencia	111
5.4 Diagramas de código.....	116
5.4.1 Diagrama de módulos del prototipo	116
5.4.2 Modelo de datos.....	117
Capítulo 6. Desarrollo	122
6.1 Mockups del prototipo	122
6.1.1 Vista previa del inicio de sesión.....	122
6.1.2 Vista previa de registro.....	123
6.1.3 Vista previa de cambio de contraseña.....	124
6.1.4 Vista previa de inicio del prototipo	124
6.2 Pantallas del prototipo.....	126
6.2.1 Pantalla de bienvenida.....	126
6.2.2 Pantalla de inicio de sesión.....	127
6.2.3 Pantalla de ingesta de video.....	128
6.2.4 Pantalla de Configuración de Zonas	129
6.3 Optimización de la infraestructura de cómputo y aceleración por hardware	129
6.3.1 Análisis crítico de la resolución espacial e integridad de datos etológicos	130
6.3.2 Evolución de los modelos de IA y entrenamiento de alta fidelidad	130
6.3.3 Refinamiento de la arquitectura modular y continuidad temporal	131
6.3.4 Herramientas de usabilidad y visualización HUD avanzada	132
6.3.5 Validación de escenario ciego y gestión de factores de riesgo.....	132
6.4 Validación experimental y refinamiento de la estimación de postura.....	133
6.5 Refinamiento del pipeline de inferencia, integración de SimBA y optimización de la trazabilidad conductual.....	135
6.6 Optimización de la arquitectura de software, estandarización de identidad institucional y refinamiento del flujo de datos.....	135
6.7 Fortalecimiento de la seguridad de acceso, depuración de dependencias de bajo nivel y optimización de recursos de cómputo	136
6.8 Escalamiento del dataset para la detección de microconductas y validación de la robustez del sistema.....	137

6.9 Estandarización de identidad institucional, optimización de inferencia y refinamiento de criterios de anotación de puntos clave.....	138
6.10 Consolidación analítica de grupos experimentales, refinamiento de microconductas vía LSTM y estrategia de escalamiento masivo	140
6.10.1 Implementación del módulo de comparación estadística y control de grupos	140
6.10.2 Refinamiento del pipeline: YOLO Pose v4 y rrquitectura de rescate LSTM.....	Error! Bookmark not defined.
6.10.3 Optimización administrativa, UX y persistencia de resultados	140
6.10.4 Estrategia de escalamiento del dataset e hitos de conclusión	141
Capítulo 7. Ciclo de desarrollo	141
7.1 Iteración 1.....	141
7.2 Iteración 2.....	142
7.2.1 Validación Leave-One-Out.....	142
7.2.2 Métricas de evaluación	143
7.2.3 Limitaciones de exactitud como métrica principal.....	143
7.2.4 Interpretación de precision, recall y F1-Score	145
7.2.5 Funcionamiento de la validación.....	146
7.2.6 Modelos evaluados y estrategias comparadas	147
7.2.7 Resultados principales del experimento	147
7.2.8 Uso de F1-score	148
7.2.9 Interpretación de los resultados	149
7.2.10 Casos de estudio representativos	150
7.2.11 Ground Truth y anotaciones humanas	150
7.3 Iteración 3.....	151
7.3.1 Adquisición y normalización de video	151
7.3.2 Extracción de pose.....	151
7.3.3 Capa de clasificación primaria.....	160
7.3.4 Capa de rescate temporal basada en LSTM.....	160
7.3.5 Determinación del tamaño de muestra	161
7.3.6 Módulo de comparación estadística.....	163
7.3.7 Paso 1 – Acceso al sistema	166
7.3.8 Paso 2 – Ingesta del video	167
7.3.9 Paso 3 – Extracción de keypoints.....	170
7.3.10 Paso 4 – Configuración de zonas del EPM.....	172

7.3.11 Paso 5 – Análisis final	174
7.3.12 Paso 6 – Consulta de resultados	177
7.3.13 Paso 7 – Comparación de resultados	180
7.4 Justificación técnica del modelo de clasificación y su evaluación.....	184
7.4.1 Elección de Random Forest frente a otros algoritmos y redes neuronales	184
7.4.2 Elección de F1-Score como métrica de evaluación.....	185
7.4.3 Análisis de desempeño y valor agregado del sistema ante un F1-Score moderado	185
7.4.4 Modelos y estrategias experimentales exploradas.....	186
7.4.5 Decisión técnica final	187
7.4.6 Estimación del tamaño de dataset requerido	187
7.4.7 Modelos candidatos para mejorar la precisión en trabajo futuro.....	188
Conclusiones.....	Error! Bookmark not defined.
Trabajo a futuro.....	Error! Bookmark not defined.
Referencias.....	191
Apéndice	200

Índice de ilustraciones

<i>Ilustración 1: OpenAI (2025). Imagen generada por ChatGPT sobre el concepto de metodología de espiral de Boehm [Imagen generada por IA]. ChatGPT (versión 5.1). Archivo creado por el usuario, sin URL.....</i>	<i>27</i>
<i>Ilustración 2: Fases de un sistema de Visión Artificial.....</i>	<i>37</i>
<i>Ilustración 3: Pasos para el reconocimiento de patrones.....</i>	<i>37</i>
<i>Ilustración 4: Ventana de seguimiento de un objeto en tiempo real.....</i>	<i>37</i>
<i>Ilustración 5: Trayectoria de un objeto seguido.....</i>	<i>38</i>
<i>Ilustración 6: Esquema del algoritmo de seguimiento de CAMshift</i>	<i>39</i>
<i>Ilustración 7: Elipse sobre objeto en seguimiento.....</i>	<i>40</i>
<i>Ilustración 8: Cuadro inicial y final del video utilizado para el ensayo [4].....</i>	<i>40</i>
<i>Ilustración 9: Representación de keypoints y campos de afinidad para múltiples personas (OpenPose) [23].....</i>	<i>41</i>
<i>Ilustración 10: Estrategias de asociación de partes en DeepLabCut [12].....</i>	<i>41</i>
<i>Ilustración 11: Secuencia de fútbol americano siguiendo al jugador 75 [25].....</i>	<i>42</i>

Ilustración 12: Una imagen de video y su probabilidad de piel en la imagen [24]	43
Ilustración 13: Ilustración 13. Ejemplo de seguimiento de un objeto con cambio de escala [26]	44
Ilustración 14: Arquitectura básica de una CNN	45
Ilustración 15: Pipeline de detección por CNN	45
Ilustración 16: Arquitectura básica de una RNN	46
Ilustración 17: Puerta de olvido	48
Ilustración 18: Puerta de entrada y valores candidatos	48
Ilustración 19: Actualización del estado de la celda	49
Ilustración 20: Puerta de salida y generación del estado oculto	49
Ilustración 21: Arquitectura general del Transformer	50
Ilustración 22: Atención escalada por producto punto y multi-head attention	51
Ilustración 23: Ejemplo de Matriz de confusión temporal	53
Ilustración 24: Representación gráfica del proceso iterativo (asignación y actualización)	54
Ilustración 25: Ejemplo de diferentes resultados de clustering con distintas distribuciones	55
Ilustración 26: Múltiples árboles de decisión en un Random Forest [34]	56
Ilustración 27: Diagrama esquemático de los métodos de ensamblaje [35]	56
Ilustración 28: Ejemplo de un problema de clasificación en un espacio bidimensional. Los vectores de soporte marcados con cuadros grises definen el margen mayor de separación entre las 2 clases [36]	58
Ilustración 29: Otro ejemplo de una SVM lineal que muestra el hiperplano óptimo, sus márgenes y los vectores de soporte que determinan la separación entre clases [37]	59
Ilustración 30: Ejemplo conceptual del problema de dimensionalidad en un sistema de una pelota en un resorte observado desde 3 cámaras [31]	60
Ilustración 31: Nube de datos simulados para la cámara A con indicación de varianza de señal y ruido. Adaptada de Shlens [31]	61
Ilustración 32: Ejemplo de un módulo de seguimiento de eTrack [5]	62
Ilustración 33: Representación de módulos conductuales y transiciones destacando micro movimientos relevantes para la exploración [17]	63
Ilustración 34: Red de la corteza prefrontal media y su implicación en la evitación defensiva [40]	64
Ilustración 35: Esquema que muestra como la interacción entre el miedo y la evitación permite identificar los procesos neuroconductuales subyacentes [41]	65
Ilustración 36: Esquema de la cascada defensiva [42]	65
Ilustración 37: Esquema del EPM desde vista superior. Los brazos horizontales son abiertos mientras los verticales son cerrados [44]	66
Ilustración 38: Arquitectura general del prototipo [autoría propia]	99
Ilustración 40: " Modelo de base de datos (parte inferior) [autoría propia]"	Error! Bookmark not defined.
Ilustración 41: "Caso de uso del prototipo [autoría propia]"	101
Ilustración 42: "Diagramas de secuencia [autoría propia]"	Error! Bookmark not defined.
Ilustración 43: "Proceso de inicio de sesión del investigador [autoría propia]"	Error! Bookmark not defined.
Ilustración 44: "Proceso de inicio de sesión del administrador [autoría propia]"	Error! Bookmark not defined.
Ilustración 45: "Proceso de cambio de contraseña del investigador [autoría propia]"	Error! Bookmark not defined.
Ilustración 46: "Proceso de cambio de contraseña del administrador [autoría propia]"	Error! Bookmark not defined.
Ilustración 47: "Manejo de usuarios [autoría propia]"	Error! Bookmark not defined.
Ilustración 48: Configuración de Perfil [autoría propia]	Error! Bookmark not defined.
Ilustración 49: "Configurar Perfil Administrador [autoría propia]"	Error! Bookmark not defined.
Ilustración 50: "Cerrar Sesión [autoría propia]"	Error! Bookmark not defined.
Ilustración 51: "Cerrar sesión Administrador [autoría propia]"	Error! Bookmark not defined.
Ilustración 52 "Prototipo de notificaciones [autoría propia]"	Error! Bookmark not defined.
Ilustración 53: "Procesos de generación de análisis [autoría propia]"	Error! Bookmark not defined.
Ilustración 54: "Consulta de reportes de análisis [autoría propia]"	Error! Bookmark not defined.
Ilustración 55: "Consulta y generación de comparaciones [autoría propia]"	Error! Bookmark not defined.
Ilustración 56: "Diagrama de clases [autoría propia]"	Error! Bookmark not defined.
Ilustración 57: "Vista previa de inicio de sesión [autoría propia]"	122

<i>Ilustración 58: “Vista previa del registro [autoría propia]”</i>	<i>123</i>
<i>Ilustración 59: “Cambiar contraseña [autoría propia]”</i>	<i>124</i>
<i>Ilustración 60: “Vista previa del inicio del prototipo [autoría propia]”</i>	<i>125</i>
<i>Ilustración 61 “Vista previa del administrador [autoría propia]”</i>	<i>125</i>
<i>Ilustración 62 "Ilustración del modelo [auditoría propia]"</i>	<i>200</i>
<i>Ilustración 63 "Ilustración del modelo prototipo II [auditoría propia]"</i>	<i>202</i>

Índice de tablas

Tabla 1: Comparación de trabajos similares [autoría propia]	34
Tabla 2: Complejidad por capa y longitud de camino para diferentes arquitecturas	50
Tabla 3: Requerimientos Funcionales (RF) del prototipo	68
Tabla 4: Requerimientos No Funcionales (RNF) del prototipo	69
Tabla 5: Reglas de Negocio del prototipo	71
Tabla 6: "Tabla de análisis de técnicas de detección de objetos [autoría propia]"	72
Tabla 7: "Tabla de análisis de técnicas de estimación de pose con aprendizaje profundo [autoría propia]"	72
Tabla 8: "Tabla de análisis de técnicas de estimación de pose [autoría propia]"	73
Tabla 9: "Tabla de actualización de análisis de técnicas de estimación de pose [autoría propia]"	73
Tabla 10: "Tabla de análisis de herramientas de seguimiento visual [autoría propia]"	73
Tabla 11: "Tabla de análisis de arquitecturas de redes neuronales profundas para visión por computadora [autoría propia]"	74
Tabla 12: "Análisis de sistemas operativos [autoría propia]"	74
Tabla 13: "Análisis de lenguajes de programación [autoría propia]"	75
Tabla 14: Matriz de Consecuencia (Impacto) [autoría propia]	76
Tabla 15: Matriz de Probabilidad (Ocurrencia) [autoría propia]	76
Tabla 16: Matriz de Probabilidad y Consecuencia (Nivel de Exposición al Riesgo) [autoría propia]	77
Tabla 17: Componentes de Riesgo del Prototipo [autoría propia]	77
Tabla 18: Tabla de Riesgos según su Impacto y Probabilidad (Matriz de Exposición) [autoría propia]	78
Tabla 19: Tabla de Mitigación y Planes de Contingencia de Riesgos [autoría propia]	79
Tabla 20: Parámetros y multiplicadores de esfuerzo COCOMO II para el prototipo	80
Tabla 21: Estimación del esfuerzo y costo de desarrollo para los escenarios de software	81
Tabla 22: Desglose de costos de infraestructura fijos y variables [autoría propia]	82
Tabla 23: Resumen de costos consolidados y valoración económica total	83
Tabla 24: Análisis comparativo con software comercial (ANY-maze y EthoVision XT) para tres estaciones de prueba	84
Tabla 25: Descripción de la tabla "users" (autoría propia)	86
Tabla 26: Descripción de la tabla "treatments" (autoría propia)	86
Tabla 27: Descripción de la tabla "experiments" (autoría propia)	87
Tabla 28: Descripción de la tabla "roi_configurations" (autoría propia)	87
Tabla 29: Descripción de la tabla "analysis_results" (autoría propia)	88
Tabla 30: Descripción de la tabla "security_audit_log" (autoría propia)	88

Glosario de términos

Acicalamiento	Conducta natural en roedores que consiste en limpiarse o frotarse el cuerpo. En modelos de
---------------	--

	ansiedad, su frecuencia puede indicar niveles de tensión o estrés.
Algoritmo	Conjunto de reglas matemáticas que permiten resolver un problema (ej. clasificar conductas de roedores).
Analgésico	Fármaco que disminuye o suprime el dolor.[1]
Anestésico	Fármaco que causa la parcial o total ausencia de sensibilidad.[1]
Anotación manual	Registro de comportamientos realizado por humanos (etólogos) para entrenar o validar sistemas de IA.
Aprendizaje no supervisado	Método de machine learning que agrupa o estructura datos sin etiquetas previas, útil para descubrir patrones ocultos (ej. clustering).
Aprendizaje supervisado	Tipo de aprendizaje automático donde el modelo se entrena con datos etiquetados para reconocer patrones y hacer predicciones.
Back-end	Parte del sistema que gestiona la lógica interna, almacenamiento y procesamiento de datos. No es visible para el usuario final.
Base de datos relacional	Estructura de almacenamiento de datos organizada en tablas con relaciones entre sí. Permite consultar, filtrar y gestionar información de forma eficiente.
Big Data	Procesamiento de grandes volúmenes de datos (ej. videos de varios minutos de experimentos) que requieren herramientas computacionales avanzadas.
Clustering	Técnica de minería de datos que agrupa elementos con características similares (ej. patrones conductuales según fármaco).
Red Neuronal Convolucional	Tipo de IA para analizar imágenes/videos, identificando patrones espaciales (ej. posturas de roedores).
Coefficiente de concordancia	Métrica estadística usada para evaluar el grado de acuerdo entre evaluadores o modelos, como el coeficiente Kappa.
Computer Vision	Visión por computadora. Área de la IA dedicada a interpretar imágenes y videos mediante algoritmos (detección, seguimiento, análisis de postura, etc.)
CONBIOÉTICA	Normativa mexicana que regula el uso ético de animales en investigación.
Dashboard	Panel visual interactivo que muestra resultados clave (ej. Gráficas de actividad en tiempo real)
Deep Learning	Subcampo del aprendizaje automático basado en redes neuronales profundas capaces de aprender patrones complejos.

DeepLabCut	Sistema de código abierto basado en deep learning para estimación precisa de postura en animales.
Laberinto en Cruz elevada	Prueba para medir ansiedad en roedores, donde el tiempo en brazos abiertos vs. cerrados indica niveles de estrés.
Feature	Característica. Variable numérica o descriptor extraído de los datos (ej. distancia recorrida, tiempo en brazos abiertos).
Fármaco	Cualquier sustancia que no sea alimento, y que se use para prevenir, diagnosticar, tratar o aliviar los síntomas de una enfermedad o afección.[7]
Heatmap (Mapa de calor)	Mapa de calor. Visualización gráfica donde los colores representan la intensidad de visitas o actividad en zonas del laberinto.
IA	Inteligencia Artificial. Sistemas que imitan aprendizaje humano para realizar tareas complejas (ej. reconocer patrones de conducta).
Inferencia	Proceso mediante el cual un modelo entrenado realiza predicciones sobre nuevos datos.
K-Means	Algoritmo de clustering que agrupa datos en k categorías basadas en similitud.
Kappa de Cohen (κ)	Métrica estadística que mide el acuerdo entre evaluadores (ej. humano vs. IA), ajustando el azar.
Red de memoria a corto-largo plazo	Tipo de red neuronal para analizar secuencias temporales (ej. movimientos entre zonas de la cruz elevada)
Machine Learning	Aprendizaje Automático. Subcampo de la IA donde los sistemas “aprenden” de datos sin ser programados explícitamente.
Minimización de ruido	Proceso que reduce variaciones indeseadas en imágenes o señales para mejorar su análisis.
Modelo experimental	Estructura o protocolo estandarizado para estudiar un fenómeno biológico (como la ansiedad en roedores).
Normalización de Datos	Procedimiento de ajustar variables a rangos comparables para evitar sesgos en modelos matemáticos.
Placebo	Sustancia sin efecto farmacológico utilizada como control en ensayos experimentales.
Plotly Dash	Framework para crear dashboards interactivos en Python.
Pose Estimation	Estimación de postura. Proceso de identificar puntos corporales (ej. cabeza, hocico, columna) para interpretar posturas y movimientos finos.

Preprocesamiento	Limpieza y preparación de datos (ej. eliminar ruido en videos) antes del análisis.
Random Forest	Algoritmo de aprendizaje supervisado basado en múltiples árboles de decisión para clasificar comportamientos.
Reconocimiento de patrones	Proceso por el cual un algoritmo identifica regularidades en los datos (ej. detectar grooming o inmovilidad).
Red neuronal	Modelo computacional inspirado en el cerebro humano, compuesto por nodos conectados capaces de aprender de datos.
Resolución espacial	Grado de detalle con el que se captura una imagen o video.
Red Neuronal Recurrente	Tipo de red neuronal diseñada para procesar secuencias temporales, como trayectorias o series de video.
Área de interés	Zona específica del video que se analiza separadamente, como los brazos abiertos o cerrados del EPM.
Simulación	Ejecución de pruebas controladas que imitan condiciones reales para validar modelos o sistemas.
Máquina de vectores de soporte	Support Vector Machine. Algoritmo de clasificación que separa datos mediante hiperplanos en un espacio multidimensional.
Threshold (Umbral)	Valor numérico a partir del cual se clasifica un evento o comportamiento (ej. inmovilidad si $velocidad < X$).
Tracking (Seguimiento)	Seguimiento. Proceso mediante el cual el sistema identifica y sigue la posición del animal cuadro por cuadro en un video.
Tranquilizante	Clase de medicamentos psicotrópicos que se emplean para reducir la tensión y la ansiedad.[8]
Tuberculina	Extracto proteico obtenido de Mycobacterium tuberculosis.
Tuberculinizado	Animal al que se le aplica mediante administración intradérmica unidades de tuberculina en un periodo de tiempo.
Interfaz de usuario	Parte visual de un software con la que interactúa el usuario (botones, paneles, gráficos).
Vectorización	Conversión de movimientos en coordenadas numéricas (ej. [x, y, t]) para análisis cuantitativo.
You Only Look Once (Solo puedes mirar una vez)	Modelo de detección de objetos en tiempo real que localiza rápidamente instancias de interés en imágenes o videos.

Overfitting (Sobreajuste)	ocurre cuando un modelo de aprendizaje automático se ajusta demasiado a los datos de entrenamiento.
---------------------------	---

Abreviaturas

CNN	Convolutional Neural Networks (Red Neuronal Convolucional).
EPM	Elevated Plus Maze (Laberinto en Cruz elevada).
IA	Inteligencia Artificial.
LSTM	Long Short-Term Memory (Red de memoria a corto-largo plazo)
PDI	Procesamiento digital de imágenes
RNN	Red Neuronal Recurrente.
ROI	Region of Interest (Área de interés).
SVM	Support Vector Machine (máquina de vectores de soporte).
UI	User Interface (Interfaz de usuario).
YOLO	You Only Look Once. (Solo miras una vez).

Capítulo 1. Introducción

1.1 Antecedentes

El análisis del comportamiento animal utilizando inteligencia artificial (IA) ha cobrado gran relevancia en la última década debido a su potencial para aumentar la precisión, eficiencia y reproducibilidad en los estudios biomédicos. La integración de técnicas de visión por computadora y aprendizaje automático ha permitido automatizar tareas tradicionalmente realizadas de manera manual, como la observación de posturas, trayectorias y tiempos de permanencia, lo que reduce la subjetividad y el margen de error humano en los experimentos de comportamiento [1], [9].

En el ámbito de la farmacología experimental, los roedores —especialmente las ratas y los ratones— constituyen los modelos biológicos más utilizados para el estudio de los trastornos de ansiedad y el desarrollo de nuevos fármacos ansiolíticos. Esto se debe a que presentan una fisiología, genética y neuroanatomía altamente comparables con las del ser humano, particularmente en la organización del sistema nervioso central y las respuestas neuroendocrinas al estrés [2], [10]. Además, su tamaño, bajo costo, facilidad de manejo y rápida reproducción los hacen ideales para la experimentación controlada en laboratorio.

De acuerdo con el posgrado de la **Escuela Nacional de Medicina y Homeopatía (ENMyH)** del **Instituto Politécnico Nacional**, los ensayos con roedores permiten evaluar el efecto de nuevas moléculas con potencial ansiolítico. Los experimentos se estructuran generalmente en tres grupos: un grupo control que recibe placebo, un grupo tratado con **diazepam** (fármaco ansiolítico de referencia), y uno o más grupos experimentales que reciben las moléculas en evaluación. Esta comparación posibilita identificar tanto los efectos terapéuticos como los mecanismos de acción de las sustancias probadas [11]. La metodología incluye pruebas conductuales como el **Laberinto en Cruz Elevada (EPM)** o el **Laberinto en T Elevado**, ampliamente utilizadas para medir conductas asociadas a la ansiedad, como la evitación, exploración y tiempo de inmovilidad [3], [4].

El uso de animales de laboratorio está regulado en México por la Norma Oficial Mexicana NOM-062-ZOO-1999, que establece las especificaciones éticas, sanitarias y de bienestar animal aplicables a su cuidado y uso experimental. Esta norma asegura el bienestar de los animales y permite que los procedimientos se lleven a cabo bajo condiciones controladas, reduciendo al mínimo su sufrimiento [2].

La inteligencia artificial ha potenciado el análisis conductual de estos modelos experimentales en años recientes, lo cual ha posibilitado la identificación automatizada de patrones de conducta a través de instrumentos como **YOLO** [13], **DeepLabCut** [12], o sistemas de seguimiento de código abierto (como **ezTrack** [5]). Estos últimos proporcionan precisión cuantitativa y reproducibilidad al evaluar las respuestas ansiolíticas. Esta sinergia entre la neurociencia conductual y la ingeniería computacional representa un avance significativo para acortar el tiempo necesario para validar nuevas sustancias y personalizar los tratamientos farmacológicos [14].

1.2 Planteamiento del problema

Para validar tratamientos experimentales en modelos de ansiedad, el análisis conductual en investigaciones farmacológicas constituye un paso crucial. Esta tarea, de manera tradicional, se lleva a cabo manualmente con la observación humana meticulosa de videos. En estos, los asistentes del laboratorio documentan visualmente cada movimiento, postura y desplazamiento del espécimen. No obstante, este método, a pesar de ser riguroso, es poco eficaz: el análisis de un único video puede demandar entre una y dos semanas de trabajo repartido entre tres asistentes. Estos tienen la tarea de determinar minuciosamente los eventos relevantes y luego procesar manualmente los datos con el fin de producir gráficas que puedan interpretarse. Este procedimiento, además de ser exigente en términos de tiempo, introduce una alta cantidad de subjetividad y variabilidad entre los evaluadores, lo cual pone en riesgo la capacidad para reproducir y la consistencia de los hallazgos experimentales.

1.3 Propuesta de solución

En vista de esta circunstancia, se hace necesario crear una herramienta tecnológica que estandarice y automatice la evaluación del comportamiento del espécimen, eliminando los sesgos humanos y reduciendo de manera significativa el tiempo de análisis. Este prototipo pretende combinar diferentes métodos de inteligencia artificial, visión por computadora y minería de datos a partir de videos grabados con anterioridad durante ensayos farmacológicos para convertir el proceso convencional de observación manual en un flujo automatizado, reproducible y de alta precisión.

La solución se centrará en un prototipo de inteligencia artificial y visión por computadora, con la capacidad de identificar, rastrear y describir el movimiento de roedores en contextos controlados.

Este prototipo integrará tres componentes principales:

1. **Detección de objetos mediante redes neuronales convolucionales (CNN) tipo YOLOv11**, entrenadas específicamente para identificar y localizar con alta precisión a los roedores dentro del entorno experimental.
2. **Análisis de secuencias temporales con redes LSTM (Long Short-Term Memory)**, que procesarán las trayectorias obtenidas para reconocer patrones conductuales asociados con diferentes respuestas de ansiedad.
3. Estimación de postura mediante técnicas de estimación de pose (como Ultralytics YOLO Pose), para extraer coordenadas clave del cuerpo y mejorar la caracterización del comportamiento (posición, orientación, movimientos finos).

Una vez procesada la información, los datos vectorizados serán sometidos a **minería de datos mediante algoritmos como K-Means**, con el fin de agrupar patrones de actividad y detectar conductas recurrentes o anómalas.

Los resultados se visualizarán a través de **mapas de calor (heatmaps)**, **trayectorias dinámicas**, **gráficas comparativas** y **tablas de métricas conductuales**, que permitirán evaluar de forma clara cómo los tratamientos farmacológicos influyen en la conducta de los especímenes.

Finalmente, el prototipo contará con una **interfaz interactiva tipo dashboard**, que mostrará métricas de precisión, coeficientes de concordancia (κ de Cohen) y visualizaciones gráficas en tiempo real, facilitando la interpretación por parte de los investigadores biomédicos.

1.4 Objetivo general

Desarrollar un prototipo de análisis automatizado para analizar y representar patrones conductuales de especímenes en modelos experimentales de ansiedad a partir de vídeos, utilizando técnicas de minería de datos (clustering, clasificación y reducción de dimensionalidad), aprendizaje automático (redes neuronales CNN-LSTM, detección visual YOLO y estimación de postura), e inteligencia artificial (reconocimiento automático y validación estadística), generando visualizaciones gráficas e informes comparativos que permitan evaluar tratamientos farmacológicos.

1.4.1 Objetivos específicos

1. Recolectar y estructurar datos conductuales de especímenes (tales como la movilidad entre brazos abiertos y cerrados, tiempo de permanencia en cada zona del laberinto, frecuencia de acicalamiento, tiempo de inmovilidad y contacto con las paredes) en modelos experimentales de ansiedad mediante grabaciones individuales en video, a fin de generar una base de datos estructurada para el análisis automatizado posterior. En cada sesión se observará un espécimen único sometido a distintos tratamientos farmacológicos, incluyendo un grupo control con placebo, un grupo tratado con diazepam (fármaco ansiolítico de referencia) y uno o más grupos experimentales con nuevas moléculas en evaluación.
2. **Identificar técnicas de visión por computadora** aplicables al análisis conductual de especímenes en el modelo del **laberinto en cruz elevada (EPM)**, considerando algoritmos como **CNN-LSTM**, **YOLO** y **estimación de postura**, con el propósito de determinar cuáles permiten una extracción automatizada y vectorización precisa de los movimientos, trayectorias y posturas relevantes para la detección de conductas asociadas a la ansiedad.
3. **Desarrollar el módulo de clasificación y minería de datos**, que agrupe patrones de comportamiento según los tratamientos aplicados (placebo, diazepam o fármaco experimental), utilizando algoritmos como K-Means, Random Forest y SVM.
4. **Desarrollar el módulo de visualización interactiva**, encargado de generar dashboards con trayectorias, mapas de calor, tiempos de permanencia y gráficos comparativos de conducta en función de los tratamientos ansiolíticos.
5. **Desarrollar el módulo de validación experimental**, que evalúe la precisión de los resultados mediante validación Leave-One-Out (LOO), reportando métricas de desempeño como precisión, recall y F1-score, con el fin de contrastar las detecciones del prototipo con las anotaciones de expertos.

6. **Desarrollar el módulo de almacenamiento y gestión de resultados**, que organice los datos procesados, informes y visualizaciones en una base estructurada para consulta y análisis posteriores.

1.5 Justificación

La necesidad que da origen a este proyecto es contar con una herramienta tecnológica que **automatice el análisis conductual de especímenes utilizados en modelos experimentales** de ansiedad, mediante la identificación precisa de actividades anómalas como la movilidad de brazos, tiempos de permanencia en distintas zonas del laberinto, conteo de eventos (transiciones entre brazos, acicalamiento, inmovilidad, contacto con paredes, entre otros).

El modelo del **laberinto en cruz elevada (EPM)** permite analizar comportamientos ansiosos mediante parámetros etológicos como el tiempo de permanencia y la frecuencia de acicalamiento (Carobrez & Bertoglio, 2005). La observación manual de estos comportamientos implica un proceso **lento, subjetivo y propenso a errores humanos**, lo cual dificulta la obtención de datos reproducibles y comparables entre tratamientos. En la investigación farmacológica, donde es crucial contar con una precisión tanto temporal como espacial del comportamiento de los animales para poder evaluar el efecto de compuestos ansiolíticos, esta circunstancia supone un obstáculo importante. Por esta razón, el posgrado de la Escuela Nacional de Medicina y Homeopatía (ENMyH) del Instituto Politécnico Nacional (IPN) ha expresado la necesidad de contar con una herramienta automatizada que posibilite identificar, documentar y examinar de manera objetiva las reacciones conductuales a partir de videos experimentales. Este prototipo, que utiliza inteligencia artificial, minería de datos y visión por computadora, posibilitará la producción de visualizaciones gráficas y mediciones cuantitativas confiables. De esta manera se mejorará el tiempo de análisis y se asegurarán resultados más exactos y reproducibles. Así, el proyecto satisface a una necesidad específica a nivel científico y operativo: optimizar la objetividad, eficacia y calidad del análisis conductual en investigaciones sobre ansiedad, para así robustecer la capacidad de investigación de la ENMyH y el IPN en el ámbito biomédico.

1.6 Alcance del proyecto

El desarrollo de un prototipo automatizado para el estudio del comportamiento animal contribuye a establecer prácticas de experimentación más objetivas y cuantitativas, alineadas con los estándares de la investigación biomédica. La incorporación de tecnologías fundamentadas en inteligencia artificial mejora la calidad científica y la consistencia metodológica de las investigaciones sobre conducta en lugares como la ENMyH donde el estudio preclínico en modelos de ansiedad es una línea importante de investigación. La automatización basada en visión por computadora ha mostrado, en varias investigaciones, que aumenta de manera notable la reproducibilidad y la precisión en ensayos etológicos, disminuyendo la variabilidad vinculada a la evaluación hecha por humanos [9], [12].

De igual manera, la implementación de estas tecnologías está en consonancia con las directrices normativas y éticas sobre el empleo de animales de laboratorio. La NOM-062-ZOO-1999 enfatiza la relevancia del bienestar de los animales y la exigencia de llevar a cabo procedimientos en condiciones controladas que maximicen cada prueba [2]. La implementación de sistemas automatizados posibilita

el uso óptimo de los datos adquiridos de cada muestra y reduce la repetición de pruebas, lo que ayuda a cumplir con el principio de las 3R (Reducción, Refinamiento y Reemplazo). Esto no solo optimiza la eficacia científica, sino que también refuerza la responsabilidad ética en el manejo de animales, lo cual es consistente con las tendencias internacionales de investigación responsable [15].

Se eligen tecnologías como YOLO, DeepLabCut y métodos de estimación de postura debido a su exactitud comprobada en tareas de rastreo y detección en modelos de animales. Estas herramientas se han validado extensamente en entornos biomédicos y posibilitan la extracción de patrones complejos que sobrepasan las capacidades de observación manual, como trayectorias tridimensionales, micro conductas y alteraciones sutiles en la postura corporal [12], [13]. Su empleo asegura datos cuantitativos de alta resolución que tienen la posibilidad de ser estudiados a través de métodos de minería de datos y aprendizaje automático; esto mejora la capacidad analítica de los investigadores y hace más sencillo detectar efectos farmacológicos.

La puesta en marcha de una plataforma con paneles interactivos y visualizaciones dinámicas ofrece a los investigadores y a los usuarios un entendimiento más profundo y accesible del comportamiento animal. Los instrumentos de análisis visual, como trayectorias dinámicas, mapas de calor y gráficos comparativos, hacen posible la síntesis de grandes cantidades de datos y su conversión en información clara y útil para la toma de decisiones experimentales [14]. Esto beneficia también los procesos de formación académica pues tanto estudiantes como residentes tienen la posibilidad de comprender el comportamiento animal desde un punto de vista basado en evidencia y perspectiva cuantitativa.

Por último, el alcance del proyecto incluye la creación de un prototipo modular y flexible, diseñado para integrar nuevas metodologías o expandirse a otros paradigmas experimentales. Esta perspectiva flexible posibilita que la plataforma no solo satisfaga las demandas presentes, sino que también progrese con los desarrollos en neurociencia conductual, IA y farmacología. En esta línea, el proyecto actúa como una base tecnológica que permitirá llevar a cabo líneas de investigación en el futuro tanto dentro de la ENMyH y el IPN como en otras entidades enfocadas en el estudio del comportamiento animal.

1.7 Metodología

Para el desarrollo del proyecto se adopta la metodología espiral de Boehm, adaptada a las particularidades de los proyectos de ciencia de datos. Barry W. Boehm, quien lo propuso en 1986 y lo formalizó en 1988 en “A Spiral Model of Software Development and Enhancement”, es el autor de este modelo que se distingue por ser sistemático a la hora de gestionar riesgos desde etapas tempranas, por su carácter cíclico y por su avance progresivo [106].

El modelo en espiral, a diferencia de los modelos secuenciales tradicionales, concibe el desarrollo como una serie de ciclos donde el producto se transforma gradualmente mediante revisiones y prototipos. Cada iteración culmina con un entregable validado que se utiliza como fundamento para el ciclo siguiente, lo cual permite una retroalimentación constante y un control de calidad [106].

En el campo de la ciencia de datos, donde los proyectos presentan incertidumbre en cuanto a los datos, un alto nivel de complejidad técnica y validación experimental, el modelo en espiral brinda un entorno perfecto para iterar a través de prototipos, monitorear riesgos de calidad y garantizar una progresión verificable del modelo analítico [106].

La versión empleada en este proyecto contempla cinco actividades esenciales en cada iteración, que aseguran la integración gradual de resultados parciales hasta llegar a una solución madura:

1. Definición de objetivos y planificación. En esta fase se definen las metas de negocio y técnicas, el alcance del ciclo y las métricas para medir el éxito. Se establecen los recursos, las fuentes de datos y los entregables que se anticipan. En proyectos de ciencia de datos, esta etapa se refiere a comprender los datos iniciales y el problema en cuestión, siguiendo los procesos del ciclo de vida que la norma ISO/IEC/IEEE 12207:2017 [6] establece.

2. Análisis de riesgos y viabilidad. Los riesgos técnicos, de datos, éticos o de implementación son idénticos al evaluar la viabilidad operativa y técnica del proyecto. Esta actividad se basa en el principio fundamental del modelo de Boehm: prever los riesgos y reducirlos antes de involucrar más recursos [106], [7].

3. Desarrollo de prototipo. Se pone en práctica un prototipo funcional o exploratorio que posibilita la verificación de hipótesis, la evaluación de la calidad de los datos y la validación de enfoques analíticos iniciales. Este prototipo es el fundamento para la evaluación del rendimiento en cada iteración, fusionando prácticas de análisis de datos e Ingeniería de Software [106].

4. Evaluación y validación. Los resultados del prototipo se comparan con los objetivos establecidos para confirmar si se cumplen los estándares de calidad y rendimiento definidos. En esta etapa se examina la fortaleza, la capacidad de interpretación y el potencial sesgo de los modelos, siguiendo las pautas de calidad que establece la norma ISO/IEC 25010:2023 [8].

5. Retroalimentación y ajuste. Con la base de la validación, se recoge el feedback, se modifican los objetivos y se organiza la iteración posterior. Esta etapa asegura que el proceso mejore de forma constante y se ajuste a cambios imprevistos en los datos o en las especificaciones del proyecto.

Cada ciclo de la espiral termina en un producto entregable concreto, lo que posibilita el progreso desde un prototipo elemental hasta una solución sólida, establecida y verificada.



Ilustración 1: OpenAI (2025). Imagen generada por ChatGPT sobre el concepto de metodología de espiral de Boehm [Imagen generada por IA]. ChatGPT (versión 5.1). Archivo creado por el usuario, sin URL.

En situaciones donde son fundamentales el descubrimiento iterativo, la evaluación empírica y la experimentación, el modelo en espiral es particularmente relevante. Posibilita incluir modificaciones durante el proceso, gracias a su sistema de retroalimentación, lo cual evita la inflexibilidad de los modelos lineales. Asimismo, su estructura enfocada en el riesgo favorece la detección anticipada de eventuales errores de diseño, calidad de datos o alineación con los objetivos comerciales, lo que incrementa las posibilidades de que el proyecto sea exitoso [106].

Capítulo 2. Estado del arte.

El análisis y la investigación de la conducta relacionada con la ansiedad en los animales ha progresado significativamente en las últimas décadas, gracias a que ha surgido la necesidad de entender los procesos neurobiológicos subyacentes y a que han mejorado los tratamientos farmacológicos. El EPM es uno de los modelos experimentales más comúnmente empleados en este ámbito, pues posibilita la evaluación de las reacciones conductuales que surgen del conflicto entre la tendencia innata de los roedores a explorar y su repulsión hacia lugares elevados y abiertos.

Dado que este mismo modelo constituye la base experimental de los videos proporcionados por la Escuela Nacional de Medicina y Homeopatía (ENMyH), que serán analizados en el presente proyecto, resulta fundamental revisar los antecedentes científicos que han consolidado su validez y las distintas metodologías asociadas a su aplicación. Por lo tanto, en este capítulo se exponen los estudios y progresos más importantes realizados recientemente en el empleo del EPM como instrumento de investigación sobre la ansiedad, destacando sus contribuciones, restricciones y el posible uso conjunto con tecnologías emergentes de visión por computadora e inteligencia artificial.

2.1 Análisis etológico y temporal del comportamiento similar a la ansiedad: el modelo de EPM elevado 20 años después

En este artículo se enfatiza que el uso del EPM constituye un recurso esencial para investigar conductas vinculadas con la ansiedad en roedores. Pese a que en un principio fue desarrollado como un procedimiento para analizar los efectos ansiolíticos de medicamentos, su practicidad se ha extendido a examinar elementos como la memoria, el aprendizaje, el dolor, las hormonas, la adicción y los subtipos de desórdenes de ansiedad, como la fobia, el trastorno de estrés postraumático (TEPT) y el trastorno de ansiedad generalizada.

Se hace mención de que el EPM es popular por su simplicidad, velocidad y coste bajo. También se destaca que no se requiere un largo entrenamiento ni la aplicación de estímulos aversivos como privar de comida o aplicar descargas eléctricas. Sin embargo, su uso varía significativamente entre laboratorios, lo que ha llevado a una falta de estandarización en los protocolos. Esta revisión se centra en cómo mejorar la validez del EPM mediante la consideración de factores como la medición de patrones defensivos, el análisis minuto a minuto del comportamiento y el uso de protocolos de prueba/reprueba.

2.2 El laberinto en T elevado como modelo experimental de ansiedad

El artículo presenta el laberinto elevado en T como un modelo animal diseñado para diferenciar entre dos tipos de ansiedad: el miedo condicionado, asociado al trastorno de ansiedad generalizada (TAG), y el miedo no condicionado, relacionado con el trastorno de pánico (TP). Este modelo es una variante del laberinto elevado en cruz, pero con una modificación clave: uno de los brazos cerrados se sella, dejando tres brazos en total (uno cerrado y dos abiertos). En este laberinto, se miden dos comportamientos principales: la evitación inhibitoria, que representa el miedo condicionado, y el escape unidireccional, que refleja el miedo no condicionado.

En la validación conductual, se demostró que la experiencia en los brazos abiertos es el factor crítico que motiva la evitación inhibitoria, no el manejo por parte del experimentador. Los roedores evitan los brazos abiertos debido a su aversión innata a las alturas y los espacios abiertos, y este miedo no disminuye con la habituación, lo que sugiere que es un comportamiento persistente con un alto valor de supervivencia. Por otro lado, el escape unidireccional, que ocurre cuando el roedor escapa de un brazo abierto hacia el cerrado, refleja una respuesta innata de miedo.

2.3 El uso del EPM como un ensayo del comportamiento relacionado con la ansiedad en roedores

En este artículo se enfatiza que el EPM no solamente es un instrumento para evaluar la ansiedad, sino que brinda además una ventana muy interesante a la biología del comportamiento. Esta prueba no solo evalúa la ansiedad, sino que además puede proporcionar datos acerca de la memoria y el aprendizaje, esto es porque se ha comprobado que los roedores son capaces de retener recuerdos de experiencias pasadas en el laberinto, lo cual tiene un impacto en su conducta durante pruebas posteriores.

Una faceta poco conocida del EPM es que se utiliza en investigaciones de neurobiología, al ser empleada por los investigadores con el fin de descubrir las áreas cerebrales que están implicadas en la

ansiedad. Se ha comprobado, por ejemplo, que la amígdala, una zona crucial para procesar el miedo, se encuentra muy activa cuando los roedores evitan los brazos abiertos. Asimismo, el hipocampo, vinculado a la memoria espacial, tiene un rol relevante en el modo en que los animales se orientan y rememoran el laberinto. Estos descubrimientos han contribuido a que los investigadores comprendan de manera más eficaz cómo el cerebro controla la ansiedad y el miedo.

Además, el EPM se ha ajustado para analizar otros elementos del comportamiento, tal como la sociabilidad y la reacción ante el estrés social. En ciertos experimentos, los roedores son sometidos a situaciones sociales que les causan estrés antes de ser introducidos en el laberinto; estos animales tienden a mostrar más comportamientos de inmovilidad y a evitar los brazos abiertos cuando la ansiedad aumenta. Esto indica que la ansiedad puede ser fuertemente influenciada por el estrés social, lo cual es importante para comprender trastornos también en seres humanos como el de estrés postraumático o la depresión.

Asimismo, el EPM se ha empleado para investigar cómo los sonidos y la música influyen en la ansiedad. La música relajante, según se menciona en el artículo, tiene la capacidad de disminuir la ansiedad en roedores al incrementar el tiempo que permanecen en los brazos abiertos. En contraste, los ruidos fuertes o los sonidos estridentes producen el efecto inverso, intensificando la evitación de los brazos abiertos. No solo desde la perspectiva científica estos hallazgos son interesantes, sino que además poseen implicaciones prácticas, como el empleo de música para disminuir el estrés en animales de laboratorio.

2.4 Prueba del EPM Combinado con Software de Seguimiento por Video para Investigar el Efecto Ansiolítico de Suplementos Cetogénicos Exógenos

El artículo describe la metodología del laberinto elevado en cruz (EPM) combinado con un software de seguimiento por video para evaluar el efecto de tratamientos potencialmente ansiolíticos en modelos de roedores de laboratorio.

El estudio se centra en evaluar el efecto de suplementos exógenos de cetonas en ratas Sprague Dawley (SPD). Los suplementos de cetonas se administraron de forma crónica durante 7 días antes de realizar la prueba del EPM. Los datos de comportamiento se recopilaron utilizando un sistema de seguimiento por video, y los resultados mostraron que el EPM es un método efectivo para detectar el efecto ansiolítico inducido por los suplementos de cetonas. Esto sugiere que el EPM es una herramienta sensible para evaluar cambios en el comportamiento relacionado con la ansiedad asociados con terapias basadas en fármacos o modificaciones metabólicas.

El artículo también enfatiza la relevancia de estandarizar las condiciones experimentales para asegurar la validez de los resultados. Esto abarca la adaptación de los animales al ambiente experimental, el manejo constante de roedores y la realización de pruebas bajo condiciones controladas de ruido e iluminación. Además, se sugiere limpiar el laberinto tras cada ensayo para quitar cualquier indicio de olor que pudiera alterar la conducta de los animales que sigan.

2.5 Prueba del EPM para Evaluar el Comportamiento Similar a la Ansiedad en el Ratón

Los datos representativos muestran que los efectos de los fármacos ansiolíticos y ansiogénicos pueden detectarse claramente en este modelo, aunque resulta necesario ajustar las dosis para distinguir entre efectos emocionales y locomotores. Finalmente, se ofrecen notas complementarias acerca de aspectos relevantes, como la utilización de ratones macho para prevenir alteraciones vinculadas con el ciclo estral, la necesidad de acostumbrar a los animales al entorno experimental y la importancia de conservar una iluminación constante para no generar sesgos de conducta.

Este protocolo ha sido adaptado de estudios previos y ha demostrado ser efectivo para detectar tanto efectos ansiogénicos como ansiolíticos en ratones.

2.6 El diazepam provoca efectos sedantes más que ansiolíticos en ratones C57BL/6J

El estudio investigó los efectos del diazepam y la paroxetina en ratones C57BL/6J, tanto hembras como machos, utilizando pruebas de comportamiento como el EPM y el campo abierto. Los resultados mostraron que el diazepam no aumentó el número de entradas ni el tiempo pasado en los brazos abiertos, lo que sugiere que no tuvo un efecto ansiolítico en los ratones, sino que más bien causó efectos sedantes, evidenciados por una disminución en la actividad locomotora y en el comportamiento de evaluación de riesgo, medido como una reducción en el tiempo pasado en posturas de estiramiento y exploración. Estos efectos se observaron tanto en ratones no sometidos a estrés como en aquellos que fueron sometidos a una hora de restricción antes de la prueba. En contraste, la paroxetina, un antidepresivo inhibidor selectivo de la recaptación de serotonina, mostró efectos ansiolíticos claros en ambos sexos, aumentando el tiempo pasado en los brazos abiertos del EPM y el comportamiento de evaluación de riesgo.

Además, el estudio subrayó que el diazepam no solamente redujo la actividad locomotora, sino que también acortó el tiempo en que los ratones permanecieron en la parte central del campo abierto; este comportamiento suele estar relacionado con la ansiedad. Esto apoya el concepto de que, en este modelo de ratón, el diazepam funciona fundamentalmente como sedante y no como ansiolítico. Por otra parte, la paroxetina no solo prolongó el tiempo que pasó en los brazos abiertos del EPM, sino que además aumentó la conducta de evaluación de riesgo. Esto indica que este medicamento podría ser más eficaz para disminuir la ansiedad en ratones C57BL/6J.

Los hallazgos también indicaron que el estrés previo no modificó de manera significativa los efectos del diazepam, ya que los ratones sometidos a una hora de restricción antes del ensayo presentaron comportamientos parecidos a los que no tuvieron estrés. Esto sugiere que el efecto sedante del diazepam es consistente independientemente del estado de estrés del animal. Sin embargo, la paroxetina mostró un efecto ansiolítico más pronunciado en los ratones no sometidos a estrés, lo que podría indicar que el estrés previo podría modular la eficacia de este fármaco en ciertos contextos.

2.7 ezTrack: Un flujo de análisis de video de código abierto para la investigación del comportamiento animal

ezTrack es una herramienta de análisis de comportamiento de código abierto y multiplataforma que permite a investigadores sin experiencia en programación realizar análisis de video de manera sencilla. EzTrack se compone de dos módulos fundamentales: uno para examinar la posición y el movimiento de un animal específico, y otro para medir la conducta de congelación, que se usa frecuentemente en investigaciones sobre miedo y ansiedad. En conjunto los dos módulos presentan visualizaciones interactivas, procesamiento por lotes y la posibilidad de modificar parámetros para asegurar resultados más exactos.

El módulo de seguimiento de ubicación de ezTrack monitorea el centro de masa de un animal en cada cuadro del video, lo que posibilita calcular el tiempo y la distancia recorrida en las áreas de interés (ROI) establecidas por el usuario. Se afirma que este módulo ha sido validado en diversas pruebas conductuales, incluyendo la prueba de oscuridad-luz, el laberinto de agua de Morris, la preferencia por un lugar condicionado y el EPM. Los resultados logrados evidenciaron una fuerte correlación con los análisis manuales, lo que demostró su exactitud. Además, ezTrack es resistente a las variaciones de luz y a la presencia de objetos en el campo visual, lo que lo vuelve apto para una extensa variedad de pruebas.

El módulo de análisis de congelación de ezTrack determina el desplazamiento del animal al calcular la cantidad de píxeles que varían entre fotogramas sucesivos. Se considera que un animal está en estado de congelación cuando su movimiento desciende por debajo de un umbral establecido por el usuario durante un periodo de tiempo determinado. Este módulo también ofrece instrumentos de calibración para modificar los límites de movimiento y congelación, además de posibilitar el recorte de los fotogramas con el fin de suprimir la intervención de cables conectados al animal. Los resultados de ezTrack mostraron una fuerte correlación con los análisis manuales en ensayos de condicionamiento del miedo, lo que confirma su precisión a la hora de detectar este tipo de comportamiento.

La facilidad de uso de ezTrack es una de sus principales ventajas, pues está concebido para ser accesible incluso para quienes no tienen experiencia en programación. Además, ezTrack tiene la capacidad de adaptarse a diversas configuraciones experimentales, ya que es compatible con una variedad extensa de formatos de video y múltiples sistemas operativos (Windows, macOS y Linux). El sistema destaca por su transparencia y reproducibilidad; al emplear Jupyter Notebooks, se almacenan en un archivo HTML o PDF todos los pasos y parámetros empleados en el procesamiento de la información, lo que simplifica la revisión y reproducción de los análisis. Esto se opone al software comercial, donde los parámetros elegidos no siempre son registrados de forma accesible.

A pesar de que ezTrack presenta ciertas limitaciones, entre ellas su dependencia del centro de masa para establecer la posición y su enfoque en el seguimiento de un solo animal, su simplicidad y versatilidad lo hacen una herramienta útil para un extenso espectro de aplicaciones en neurociencias y análisis conductuales. Además, por ser de código abierto, ezTrack tiene la posibilidad de ser mejorado y cambiado por la comunidad científica, lo que posibilita incluir nuevas funciones más adelante.

2.8 Analixity: Un sistema de análisis de código abierto y bajo costo para la prueba de EPM, basado en técnicas de visión por computadora

Analixity es un software multiplataforma de código abierto para procesamiento de video, diseñado específicamente para realizar pruebas de EPM.

Este software produce un archivo de Excel con los parámetros de comportamiento cuantificados, incluyendo el tiempo transcurrido en los brazos abiertos y cerrados, el tiempo de la zona central, la cantidad de veces que se ingresó a cada área y la distancia total recorrida durante el examen. Con el fin de validar su efectividad, los resultados logrados con Analixity se contrastaron con los que se obtuvieron por medio del software comercial ANY-maze y mediante análisis manual. No hubo discrepancias estadísticamente relevantes entre las metodologías, lo que avala que Analixity es igual de efectivo y fiable que un software comercial, pero con el beneficio de ser adaptable a distintas condiciones de laboratorio y ser de código abierto.

En la actualidad, hay diferentes programas comerciales para analizar el comportamiento animal, incluyendo LABORAS, Ethovision y ANY-maze. Además, muchos de estos programas funcionan como "cajas negras", donde los investigadores no tienen acceso a los procedimientos internos utilizados para la cuantificación de parámetros. En contraste, Analixity es un software de código abierto desarrollado en Python con bibliotecas OpenCV, lo que permite a los investigadores conocer y modificar los procesos internos según sus necesidades. Además, es compatible con Windows, MacOS y Linux, lo que lo hace accesible para una amplia gama de usuarios.

En el estudio de validación, se compararon los resultados obtenidos con Analixity con los obtenidos mediante análisis manual y con ANY-maze. Se analizaron videos de ratas Wistar y ratones C57BL/6 J en diferentes condiciones de iluminación, y se cuantificaron parámetros como el tiempo pasado en los brazos abiertos y cerrados, el tiempo en la zona central y el número de entradas a cada zona. Los resultados mostraron que Analixity redujo significativamente el tiempo de análisis, de 30 minutos a solo 2.5 minutos por video, sin comprometer la precisión.

Aunque el software se menciona en diversos artículos y se indica que es de código abierto, no se encontró un medio disponible para su descarga. Por ello, no fue posible incluirlo en las pruebas de comparación con el sistema desarrollado por el equipo.

2.9 EthoVision

EthoVision se diseñó como un sistema de rastreo de comportamiento animal cuyo funcionamiento parte de la identificación cuadro por cuadro del sujeto. El algoritmo separa el cuerpo del animal del fondo mediante variaciones en el brillo, matices de gris y combinaciones de tono y saturación, lo que permite distinguir al espécimen del fondo de la escena.

A partir de esta detección, el sistema obtiene las coordenadas y el área superficial del espécimen para cada instante del experimento, siguiendo de manera constante su movimiento en cualquier tipo de arena definida por el usuario.

El investigador puede organizar espacios de trabajo, experimentos, perfiles de adquisición y un conjunto amplio de variables independientes (como tratamiento, fecha, configuración genética o

temperatura), junto con variables dependientes (como coordenadas x, coordenadas y, superficie, distancia recorrida, velocidad y tiempo en zonas) que se almacenan en pistas.

El módulo de diseño experimental permite programar series completas de pruebas, incluyendo qué animal se evalúa, en qué orden y con qué ajustes. El módulo de adquisición procesa la imagen mediante tres métodos distintos de detección: por umbrales de gris, por sustracción de fondo o por color (usando el modelo HSI). También permite rastrear hasta dos animales en paralelo, cada uno con su color o tamaño particular, y aplicar filtros para eliminar colas, sombras, ruido o barras de las jaulas.

El módulo de visualización permite reproducir los recorridos superpuestos al video o sobre la arena esquemática para analizar la exploración, los patrones de búsqueda o el comportamiento general. Finalmente, el módulo analítico transforma todas las coordenadas en datos cuantitativos (como distancias, velocidades, cambios de dirección, permanencia en regiones o estados de movimiento e inmovilidad), proporcionando estadísticas exportables a otros programas.

2.10 ANY-maze

ANY-maze es un sistema de análisis automatizado de detección de conducta que procesa el video cuadro por cuadro para identificar al animal dentro del entorno. Esto se realiza mediante una comparación de píxeles para detectar diferencias respecto al fondo.

Para la detección, el sistema utiliza métricas como la distancia recorrida, los patrones de desplazamiento y la permanencia en zonas definidas antes de iniciar la prueba, las cuales sirven para evaluar conductas asociadas a la exploración o la ansiedad. También cuenta con herramientas para configurar el experimento de manera flexible, lo que permite delimitar áreas de interés para registrar eventos específicos, integrando el seguimiento automático y la recolección de datos en una sola interfaz.

Una vez que el rastreo está en marcha, el programa genera estadísticas y gráficos que resumen variables como velocidad, entradas a zonas, tiempo de inmovilidad o patrones de exploración. Estas mediciones pueden exportarse para análisis posteriores; también incluye mecanismos para reducir la variabilidad del análisis como filtros de ruido, ajustes de sensibilidad y parámetros que permiten corregir trayectorias perdidas, asegurando que el seguimiento se mantenga incluso en condiciones de baja iluminación o cuando el animal se superpone con elementos del entorno.

El propósito del sistema es ofrecer una plataforma accesible que automatice tareas tradicionalmente manuales, lo que disminuye los errores humanos y aumenta la reproducibilidad experimental. Esta herramienta es ampliamente utilizada en pruebas de laberinto en cruz elevado, campo abierto o preferencia de lugar condicionado, donde la posición y el movimiento del animal son indicadores centrales de la conducta evaluada.

2.11 Tabla Comparativa

Se presenta una tabla comparativa de trabajos similares que han abordado el análisis del comportamiento de especímenes en modelos de ansiedad, incluyendo metodologías tradicionales y herramientas automatizadas.

"Ethological and Temporal Analyses of Anxiety-like Behavior: The Elevated Plus-Maze Model 20 Years On" este artículo es una revisión que resalta la evolución del laberinto en cruz elevada como modelo de evaluación etológica de la ansiedad en roedores, destacando la necesidad de un análisis más profundo del comportamiento más allá de métricas tradicionales.[3]

"The Elevated T-Maze as an Experimental Model of Anxiety" propone un modelo alternativo que permite discriminar entre diferentes tipos de ansiedad a través del estudio de evitación y escape en un laberinto en T elevado.[4]

"ezTrack" es un software de código abierto que permite el seguimiento automatizado del comportamiento animal mediante análisis de video, sin necesidad de experiencia en programación, siendo una herramienta accesible y reproducible.[5]

Estos proyectos permiten contextualizar el desarrollo del prototipo propuesto.

Característica	DeepLabCut	ANY-maze	Ethovision	ezTrack [5]	Nuestro Prototipo (TT-2026-A155)
Costo	Gratuito (requiere GPU potente)	Muy costoso	Muy costoso	Gratuito	Gratuito / costo muy bajo
Facilidad de uso	Difícil, requiere programación	Muy intuitivo	Intermedio	Intermedio	Muy intuitivo
Estimación de postura	✓ Postura avanzada	✗ No especializado	✓ Postura avanzada	✗ No incluye postura real	✓ Postura completa (MediaPipe / DeepPose)
Clasificación de conductas	✗ Requiere código adicional	✗ Limitado a trayectorias	✓ Reconocimiento automático de comportamiento	✗ No clasifica	✓ CNN-LSTM con clasificación automática
Detección de micro-conductas (acicalamiento, inmovilidad, contacto)	✓ Si se programa, no por defecto	✗ No detecta acicalamiento	✓ Si detecta microconductas	✗ No detecta microconductas	✓ Si detecta microconductas
Seguimiento del animal	Muy preciso, basado en keypoints	Bueno, basado en tracking clásico	Bueno: tracking robusto, incluso en video de baja resolución	Básico (centro de masa)	Preciso: YOLO + postura
Instalación	Compleja, setups largos	Fácil, instalación guiada	Fácil, instalación guiada	Fácil-intermedia	Fácil, interfaz web local directa
Reproducibilidad científica	Alta, depende del usuario	Media	Alta	Media-alta	Alta con k-fold + $\kappa \geq 0.8$
Dashboards y visualizaciones	✗ No incluidos	Básicos	✓ Incluye visualización de trayectorias y gráficos de actividad/movimiento	Básicos	✓ Dashboards interactivos y comparativos
Flexibilidad / modificación	Muy alta (open source)	Muy baja (cerrado)	Muy baja (cerrado, software comercial)	Alta (open source)	Alta (modular y expandible)
Usuarios objetivo	Programadores / expertos en IA	Investigadores sin experiencia técnica	Investigadores de comportamiento / neurociencias / farmacología que necesitan una solución robusta	Laboratorios con recursos básicos	Investigadores biomédicos, estudiantes y desarrolladores

Tabla 1: Comparación de trabajos similares [autoría propia]

Capítulo 3. Marco Teórico

El presente capítulo expone los fundamentos teóricos y metodológicos que sustentan el diseño e implementación del prototipo para el análisis automatizado de la conducta en roedores. En primer lugar, se describen los conceptos clave de la visión por computadora aplicada al seguimiento de objetos, abordando algoritmos de detección en tiempo real como YOLO, herramientas de estimación de postura como DeepLabCut, y enfoques de rastreo clásicos y basados en redes neuronales convolucionales. Posteriormente, se detallan los modelos de aprendizaje automático orientados a series temporales, tales como las redes recurrentes (RNN, LSTM) y los modelos basados en mecanismos de atención (Transformers), complementados con metodologías de validación estadística como el coeficiente Kappa de Cohen. Asimismo, se examinan las técnicas de minería de datos y aprendizaje supervisado y no supervisado (K-Means, Random Forest, SVM) empleadas para la clasificación conductual, así como las estrategias de reducción de dimensionalidad. Finalmente, se establecen los constructos etológicos y neurobiológicos de la conducta ansiosa en modelos experimentales, centrando el análisis en el paradigma del laberinto en cruz elevado (EPM), y se especifican las herramientas de desarrollo tecnológico (sistema operativo y lenguaje de programación) seleccionadas para el proyecto.

3.1 Visión por computadora para seguimiento de objetos

La visión por computadora es una rama que permite a las máquinas interpretar y entender el mundo visual. Para detectar y seguir el movimiento de los animales en videos, se emplean algoritmos sofisticados en el marco del seguimiento de objetos. Entre los algoritmos que más se usan se encuentran los siguientes:

3.1.1 YOLO (You Only Look Once)

Un algoritmo de detección de objetos en tiempo real. A diferencia de los métodos tradicionales que procesan la imagen por etapas separadas como extracción de características, generación de propuestas o clasificación independiente, YOLO realiza todo el proceso de detección en un solo paso, aplicando una sola red neuronal convolucional directamente sobre la imagen completa. Esta idea rompe con la lógica secuencial clásica mostrada en sistemas de visión artificial (descritos en las Ilustraciones 2 y 3), al tratar el reconocimiento y localización como un problema único y unificado[13].




Ilustración 2: Fases de un sistema de Visión Artificial




Ilustración 3: Pasos para el reconocimiento de patrones

La clave de YOLO radica en dividir la imagen en una cuadrícula: cada celda tiene la tarea de pronosticar si existe un objeto dentro de su área, produciendo coordenadas de un bounding box, así como una probabilidad de que esté presente y otra posibilidad para cada clase. Esta predicción directa convierte al algoritmo en uno de los más rápidos en visión por computador, ideal para aplicaciones donde la detección debe ocurrir en tiempo real, como aquellas que requieren seguimiento continuo del objeto, similar a la siguiente figura.




Ilustración 4: Ventana de seguimiento de un objeto en tiempo real

Al procesar toda la imagen de una sola vez, YOLO adquiere una comprensión global del contexto visual, así reduciendo los errores por confusión entre objetos y mejora la coherencia espacial de sus decisiones, lo que es especialmente valioso en escenas complejas o con múltiples instancias. No obstante, aunque YOLO es altamente eficiente, puede enfrentar dificultades en escenas donde hay oclusiones, pérdida temporal del objeto dentro del cuadro o variaciones bruscas de iluminación, condiciones que complican la detección continua y precisa, con una pérdida progresiva del objeto real, como se ejemplifica en la Ilustración 5




Ilustración 5: Trayectoria de un objeto seguido

3.1.2 DeepLabCut

Una herramienta de análisis de comportamiento desarrollada para realizar seguimiento basado en aprendizaje profundo sin necesidad de marcadores físicos. A diferencia de métodos clásicos como CAMShift o enfoques basados en histogramas de color, DeepLabCut utiliza arquitecturas de redes neuronales convolucionales (CNN) para identificar con alta precisión puntos anatómicos previamente definidos sobre animales u otros sujetos en movimiento. Esta metodología permite automatizar el análisis del comportamiento aun cuando existen variaciones en iluminación, perspectiva o apariencia del objeto, las cuales suelen afectar de forma significativa a los enfoques tradicionales de seguimiento.

Generalmente, su flujo de trabajo inicia con la selección de fotogramas representativos del video, los cuales posteriormente se etiquetan manualmente marcando las posiciones corporales relevantes para el estudio. Estos datos anotados alimentan el proceso de entrenamiento, durante el cual el modelo ajusta sus pesos para aprender la posición de los puntos clave. Una vez entrenado, el sistema puede predecir automáticamente la ubicación de dichos puntos en cada fotograma del video original o de nuevos videos, generando trayectorias temporales precisas que pueden utilizarse para análisis conductuales, cinemáticos o espaciales, tal como se ejemplifica en la Ilustración 6.




Ilustración 6: Esquema del algoritmo de seguimiento de CAMShift

La salida final de DeepLabCut no es una ventana adaptativa como en CAMShift, mostrada usualmente como una elipse de seguimiento (como en la Ilustración 7), sino un conjunto de coordenadas precisas para cada punto corporal entrenado. Esto permite análisis biomecánicos avanzados, cálculo de ángulos, trayectorias y patrones conductuales sin depender de contornos ni de la segmentación tradicional basada en color. Además, dado que cada frame se analiza independientemente mediante el modelo entrenado, no se acumula error histórico ni se generan divergencias de histograma como las que se mitigan en este trabajo mediante promedio ponderado (ecuaciones 2–3).



Ilustración 7: Elipse sobre objeto en seguimiento

Cuando se observan resultados de un modelo entrenado para diferentes momentos del video, el comportamiento es comparable a las diferencias presentadas en la Ilustración 8, pero con la ventaja de que DeepLabCut mantiene precisión incluso si el animal cambia de forma, tamaño, pose o iluminación. Mientras CAMShift depende de mantener coherencia visual en color y dimensión para no perder el objeto, DeepLabCut aprende representaciones abstractas del cuerpo, lo que lo hace mucho más robusto, especialmente en ciencia del comportamiento, neurociencia y análisis de movimiento.




Ilustración 8: Cuadro inicial y final del video utilizado para el ensayo [4]

3.1.3 Estimación de postura (Pose Estimation)

Según Mathis et al. en su artículo “DeepLabCut: Markerless Pose Estimation of User-Defined Body Parts with Deep Learning”, la estimación de postura (*pose estimation*) es un método de visión por computadora que posibilita deducir la ubicación espacial de segmentos corporales, a menudo articulaciones o puntos clave, usando imágenes o videos [12]. Esta técnica es esencial para rastrear objetos, ya que no solo identifica la existencia de un organismo, sino que también proporciona una descripción de su forma corporal en tiempo real, lo cual permite realizar análisis detallados sobre movimiento y conducta. Los modelos de estimación de postura, a través de redes neuronales

convolucionales u otras arquitecturas de aprendizaje profundo, desarrollan la habilidad para convertir píxeles en coordenadas anatómicas.

De acuerdo con Cao et al., autores de "OpenPose: Estimación de poses 2D en tiempo real para múltiples personas a través de campos de afinidad por partes", las estrategias contemporáneas se categorizan en procedimientos de una fase y procedimientos de dos fases. Los métodos de una etapa, que calculan directamente las articulaciones a partir de la imagen sin necesidad de detectar antes el cuerpo entero, son más veloces, pero algo menos exactos. Los métodos de dos etapas, en cambio, primero identifican al sujeto y después hacen inferencias sobre su postura dentro de esa área. Los Part Affinity Fields (PAF), que fueron introducidos por OpenPose, hacen posible la asociación de varias articulaciones en situaciones donde hay más de una persona, lo cual soluciona la ambigüedad del ensamblaje de las articulaciones cuando existen varios individuos en la escena [23].




Ilustración 9: Representación de keypoints y campos de afinidad para múltiples personas (OpenPose) [23]

Según el artículo de Mathis et al., la estimación de postura sin marcadores se ha convertido en algo fundamental en la investigación biomédica y del comportamiento animal, ya que se requieren sistemas no invasivos con una precisión alta [12]. DeepLabCut, por citar un caso, posibilita la definición de puntos anatómicos concretos y el entrenamiento de modelos a medida con una cantidad de datos relativamente reducida, empleando para ello aprendizaje profundo y transferencia del aprendizaje. Esta herramienta es especialmente beneficiosa en contextos con variación postural significativa, fondos intrincados y movimientos veloces, y se emplea ampliamente en el análisis del movimiento, la neurociencia y la etología.



Ilustración 10: Estrategias de asociación de partes en DeepLabCut [12]

Incorporar la estimación de postura a los sistemas de seguimiento de objetos brinda un beneficio importante en comparación con los procedimientos que se basan solamente en cajas delimitadoras. De acuerdo con Pereira y Moita en "El papel de la visión por computadora en la etología: Un análisis de postura", la Pose Estimation permite medir ángulos articulares, trayectorias de extremidades, patrones de locomoción y micro comportamientos [16]. Esto es esencial para el estudio del comportamiento espontáneo, de las tareas motoras, de la evaluación del dolor o de los trastornos neuromotores, e incluso para la interacción social en animales de laboratorio. Asimismo, los datos producidos, al ser series temporales multivariadas, tienen la posibilidad de combinarse con modelos de aprendizaje automático como LSTM o Transformers para clasificar comportamientos o predecir patrones conductuales futuros.

3.1.4 CAMShift y métodos clásicos de seguimiento

CAMShift (Continuously Adaptive Mean Shift), de acuerdo con Bradski, es una ampliación del algoritmo Mean-Shift que posibilita el seguimiento de objetos en videos en tiempo real. Esta técnica hace posible la modificación dinámica del tamaño y la orientación de la ventana de búsqueda a medida que cambia el apariencia del objeto [24].




Ilustración 11: Secuencia de fútbol americano siguiendo al jugador 75 [25]

Comaniciu, Ramesh y Meer explican que los métodos basados en kernel modelan el objeto a través de histogramas ponderados espacialmente, lo cual asegura solidez frente a ruidos y distorsiones. La actualización ininterrumpida del modelo disminuye la deriva del rastreador a medida que la apariencia del objeto cambia progresivamente, y el procedimiento iterativo del algoritmo Mean-Shift permite encontrar el modo de la distribución de probabilidad del objeto [25].



Ilustración 12: Una imagen de video y su probabilidad de piel en la imagen [24]

De acuerdo con el tutorial de OpenCV, CAMShift y Mean-Shift son considerados algoritmos de seguimiento por apariencia; estos son veloces y apropiados para aplicaciones en tiempo real, aunque su sensibilidad a los fondos con colores parecidos y a las oclusiones es una limitante. Otros métodos tradicionales son el seguimiento de puntos locales (Lucas-Kanade), los filtros de Kalman o los filtros de partículas (predicción frente a oclusiones) y el emparejamiento de plantillas (*template matching*) (eficaz, aunque limitado en situaciones de rotación y escala cambiantes) [26].

CAMShift es más eficaz en situaciones donde la información de color tiene capacidad de discriminación y las dinámicas del objeto son, por lo general, predecibles, según señala Bradski. Por lo tanto, se sugiere que el rendimiento sea evaluado a través de métricas como la tasa de pérdida (failure rate), la precisión del bounding box (IoU) y la deriva acumulada, empleando secuencias que contengan oclusiones, rotación y cambios de escala [24][26].



Ilustración 13: Ilustración 13. Ejemplo de seguimiento de un objeto con cambio de escala [26]

3.1.5 Redes Neuronales Convolucionales (CNN) aplicadas a visión por computadora

Según Bengio, Courville y Goodfellow, las Redes Neuronales Convolucionales (CNN) son la arquitectura básica para el análisis de imágenes, porque pueden aprender jerarquías de características a partir de patrones simples, como bordes o texturas, hasta alcanzar representaciones complejas de objetos enteros [21]. Esta característica hace que las CNN sean especialmente beneficiosas en visión por computadora, donde es necesario entender con precisión la escena para detectar y ubicar elementos dentro de cada cuadro.




Ilustración 14: Arquitectura básica de una CNN

De acuerdo con Goodfellow et al., una CNN convencional está constituida por capas de pooling, capas convolucionales y capas completamente conectadas. Las capas convolucionales utilizan filtros con el fin de extraer características locales de la imagen, a la vez que las capas de pooling disminuyen la dimensionalidad y mantienen la información más importante. Este proceso jerárquico favorece la generalización efectiva de la red, ya que es resistente ante cambios en la posición, escala y orientación de los objetos [21].

Según Redmon et al., YOLO (You Only Look Once) es el primer modelo de detección de objetos en tiempo real que empleó las CNNs de forma exhaustiva. Este modelo (como ya se mencionó con anterioridad) realiza una única pasada para procesar la imagen completa y, así, prever simultáneamente las cajas delimitadoras y las probabilidades de clase [13]. Esta perspectiva posibilita el establecimiento de sistemas de seguimiento que se basan en detecciones certeras y veloces, los cuales son compatibles con aplicaciones en tiempo real.



Ilustración 15: Pipeline de detección por CNN

Goodfellow et al. subrayan la relevancia de transfer learning en el ámbito del entrenamiento, que implica la reutilización de redes previamente entrenadas en extensas bases de datos como ImageNet y su adaptación a dominios particulares. Para optimizar la robustez y prevenir el sobreajuste, se hacen uso de métodos de normalización, regularización y aumento de datos. Las métricas de rendimiento más habituales incluyen la capacidad de la CNN para conservar su consistencia ante variaciones en la luz, obstrucciones parciales y desplazamientos de los objetos, así como la precisión media (mAP) para detección [21].

3.2 Machine Learning para Series Temporales

Para realizar el análisis computacional del comportamiento de los animales, no es suficiente con identificar lo que sucede en cada fotograma; también es necesario entender cómo dicho comportamiento se desarrolla con el tiempo. Para lograr esto, los modelos de aprendizaje automático que se especializan en series temporales posibilitan la captura de relaciones, patrones dinámicos y dependencias que solo se manifiestan cuando las observaciones se analizan como secuencias. En este campo, sobresalen las arquitecturas que se han creado para procesar datos históricos y simular alteraciones progresivas o repentinas en el desplazamiento de los animales, por ejemplo, las LSTM, las RNN, los Transformers y los métodos de validación estadística que se utilizan para medir su exactitud.

3.2.1 Redes Neuronales Recurrentes (RNN)

Los modelos de RNN están creados para manejar datos secuenciales, incluyendo dependencias temporales a través de un estado oculto que se actualiza en cada iteración. Según Goodfellow et al. (2016), su rasgo más característico es la existencia de conexiones recurrentes que posibilitan que datos de etapas anteriores incidan en el procesamiento actual, lo cual resulta fundamental para tareas con series temporales.




Ilustración 16: Arquitectura básica de una RNN

Matemáticamente, una RNN calcula su estado interno de este modo

$$h_t = f(W_{xh}x_t + W_{hh}h_{t-1} + b_n),$$

En la que h_t resume tanto la información actual como la que proviene del pasado cercano. Como Bishop (2006) señala, este estado encubierto se puede observar con mayor claridad al "desplegar" la red a través del tiempo, demostrando cómo cada paso depende del previo.

Debido a su estructura repetitiva, las RNN son particularmente beneficiosas en series temporales; la razón es que posibilitan la captura de cambios dinámicos, patrones a nivel local y dependencias de corto alcance sin requerir ventanas manuales de datos. Goodfellow y sus colegas (2016) muestran, además, un diagrama conceptual del flujo de información que ilustra el modo en que el estado oculto funciona como un resumen del pasado pertinente para hacer predicciones en cada momento.


3.2.2 LSTM (Long Short-Term Memory)

Esta es una arquitectura de redes neuronales recurrentes (RNN) diseñada específicamente para modelar dependencias a largo plazo en series temporales. De forma tradicional, las RNN tienden a “olvidar” información conforme las secuencias se vuelven largas debido al desvanecimiento o explosión del gradiente. Este problema, identificado desde la década de los noventa, llevó al desarrollo de la arquitectura LSTM por Hochreiter y Schmidhuber en 1997 [18]. A diferencia de la RNN estándar, las LSTM integran una estructura interna conocida como celda de memoria, cuya función es conservar información útil a lo largo del tiempo sin que esta se degrade conforme crece la longitud de la secuencia.

Una LSTM, en términos operativos, controla los datos que pasan por su celda de memoria con un grupo de puertas que funcionan como filtros. Esta dinámica interna posibilita determinar qué recordar, qué olvidar y qué mostrar como salida, solucionando de manera efectiva el problema de las dependencias a largo plazo. De acuerdo con la explicación clásica de Olah [19], el proceso se puede entender mediante cuatro pasos esenciales:

1. Forget gate (puerta de olvido)

Tal como se muestra en la Ilustración 17 del artículo de Olah “Understanding LSTM Networks” [19], la primera operación que se lleva a cabo dentro de la celda, y establece qué fracción del estado anterior C_{t-1} debe ser desecheda. Con base en la combinación del estado oculto previo h_{t-1} con la entrada vigente x_t , un vector es producido por una capa sigmoide $f_t \in [0,1]$ que señala qué información se retiene y cuál se descarta.




$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

Ilustración 17: Puerta de olvido

2. Puerta de entrada y valores candidatos

En la Ilustración 18 de Olah [19] se observa el funcionamiento de la puerta de entrada; aquí el modelo determina qué información reciente integrar en el estado interno. Para lograr esto, una segunda capa sigmoide produce i_t , que determina qué componentes serán actualizados, mientras que la capa $\tanh(h)$ calcula un vector candidato $\tilde{C}_t$ con los valores que podrían añadirse.



$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$


Ilustración 18: Puerta de entrada y valores candidatos

3. Actualización del estado de la celda

La Ilustración 19 sintetiza la actualización del estado de la celda. El estado recién creado C_t se origina de la combinación de lo que se mantiene y lo que se añade:

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

Este mecanismo es fundamental para la estabilidad del comportamiento de las LSTM, ya que hace posible mantener información relevante durante largos periodos sin que esta se deteriore.




$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

Ilustración 19: Actualización del estado de la celda

4. Puerta de salida y generación del estado oculto

Finalmente, la Ilustración 20 de Olah [19] muestra cómo una tercera compuerta sigmoide establece qué fracción del estado C_t será presentada como solución. Después, la celda aplica una función $\tanh(h)$ a C_t y la ajusta a través del vector o_t , generando de este modo el estado oculto h_t , que nutre la fase temporal siguiente.



$$o_t = \sigma(W_o [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t * \tanh(C_t)$$

Ilustración 20: Puerta de salida y generación del estado oculto

3.2.3 Transformers

Son una arquitectura de deep learning que reemplaza totalmente la utilización de redes recurrentes y convolucionales, empleando solamente mecanismos de atención propia para el procesamiento de secuencias. A pesar de que se introdujo en un principio para la traducción automática, sus características posibilitan su adaptación eficaz al modelado de series temporales, en las que es necesario captar relaciones a largo plazo entre posiciones dentro de la secuencia.

A diferencia de modelos recurrentes como LSTM y RNN, los Transformers posibilitan que el procesamiento de la secuencia total se realice en paralelo, lo que disminuye significativamente el tiempo de entrenamiento. La atención escalada por producto punto (scaled dot-product attention) facilita la conexión de cualquier momento temporal con otro utilizando una única operación computacional, lo que es extremadamente útil para series en las que las relaciones no tienen que ser necesariamente locales o próximas en el tiempo.




Ilustración 21: Arquitectura general del Transformer

Para el modelado de series temporales, el encoder lleva a cabo el procesamiento de la secuencia histórica (como los últimos n pasos), lo que produce representaciones internas que capturan las dependencias globales. El decodificador puede emplearse para hacer predicciones autorregresivas de manera secuencial, usando la set-attention enmascarada con el fin de evitar que el modelo “visualice el futuro”. Esta característica reproduce la conducta autorregresiva clásica de las series temporales, pero con el beneficio de que la atención posibilita que se exploten relaciones complejas a lo largo de toda la ventana temporal.

Para llevar a cabo esta operación, el Transformer utiliza el mecanismo de atención que se muestra en la Ilustración 22, en la cual cada instante de tiempo es representado como una consulta (Q), una clave (K) y un valor (V). Esto posibilita evaluar la importancia de cada momento de la serie en comparación con los otros.




Ilustración 22: Atención escalada por producto punto y multi-head attention

En la práctica, gracias a la multi-head attention, el modelo puede trabajar con varios patrones temporales al mismo tiempo: correlaciones entre variables, efectos rezagados, estacionalidades y tendencias, entre otros. Cada “cabeza” aprende una forma diferente de dependencia temporal.

El positional encoding es otro elemento fundamental para las series temporales; permite compensar la falta de recurrencia e introduce información acerca del orden temporal. La codificación sinusoidal que Vaswani, Shaazer y el equipo de desarrollo del Transformer propusieron específicamente posibilita que el modelo se generalice a horizontes temporales más extensos que los contemplados durante la fase de entrenamiento.

En la Tabla 2 se presenta un resumen de la superioridad estructural de los Transformers en comparación con las arquitecturas recurrentes y convoluciones, que consiste en su capacidad para atrapar dependencias globales a través de rutas computacionales más breves y en su menor complejidad secuencial.

Layer Type	Complexity per Layer	Sequential Operations	Maximum Path Length
Self-Attention	$O(n^2 \cdot d)$	$O(1)$	$O(1)$
Recurrent	$O(n \cdot d^2)$	$O(n)$	$O(n)$
Convolutional	$O(k \cdot n \cdot d^2)$	$O(1)$	$O(\log_k(n))$
Self-Attention (restricted)	$O(r \cdot n \cdot d)$	$O(1)$	$O(n/r)$

Tabla 2: Complejidad por capa y longitud de camino para diferentes arquitecturas

3.2.4 Coeficiente Kappa de Cohen para validación de concordancia

Según Cohen, el coeficiente Kappa de Cohen es una medida creada para calcular la concordancia entre dos clasificadores nominales, corrigiendo el acuerdo esperado por azar. Se utiliza con frecuencia como estándar para evaluar acuerdos interanotador y la validez de sistemas de clasificación automática. Esta característica lo vuelve particularmente valioso en problemas de Machine Learning para series temporales, en los que las etiquetas pueden ser ruidosas, ordinales o

desbalanceadas. En esas situaciones, si no se ajusta por la probabilidad de coincidencia aleatoria, el porcentaje de aciertos simple puede llevar a resultados engañosos [27].

De acuerdo con McHugh, la interpretación de Kappa se basa en una escala práctica: los valores que están cerca de 1 indican una concordancia casi perfecta; los que rondan el 0 muestran un acuerdo equivalente al azar, mientras que los negativos evidencian desacuerdo sistemático. El coeficiente Kappa proporciona un marco uniforme que posibilita la comparación de la fortaleza de los modelos ante la variabilidad humana en la anotación, para el análisis comparativo de arquitecturas de series temporales, como los modelos basados en Long Short-Term Memory (LSTM) de Hochreiter y Schmidhuber o los modelos Transformer sugeridos por Vaswani et al. Kappa es útil para determinar si un modelo está aprendiendo patrones reales o simplemente repitiendo la distribución marginal de clases cuando las anotaciones humanas son consideradas como "verdaderas" (standard gold) [28]; su implementación es aconsejable no solo para validar a los anotadores, sino también para informar sobre la confiabilidad del modelo.

La fórmula tradicional para calcular el coeficiente es $k = \left(\frac{p_o - p_e}{1 - p_e} \right)$ en donde p_o indica la proporción de acuerdo que se ha observado y p_e la probabilidad de acuerdo esperada por azar. Fleiss et al. analizan a fondo las propiedades y generalizaciones estadísticas del coeficiente, y también tratan sobre versiones ponderadas que son beneficiosas cuando los desacuerdos no tienen la misma gravedad o cuando las clases poseen una relación ordinal (por ejemplo, un error adyacente en una escala ordinal debería ser penalizado menos que un error lejano) [29]. En series temporales de tipo biomédico o etológico, informar sobre p_o , p_e y k , junto con sus respectivos intervalos de confianza, es un buen método para proporcionar claridad acerca de la estabilidad estadística del indicador.

En investigaciones de estimación de postura y comportamiento en las cuales se emplean instrumentos como OpenPose (Cao et al.) o DeepLabCut (Mathis et al.), es habitual cotejar etiqueta por etiqueta las etiquetas automáticas con las humanas y reportar Kappa, además de matrices de confusión temporales y análisis de error por intervalos (por ejemplo, cuando hay transiciones entre estados). DeepLabCut y OpenPose posibilitan el etiquetado de frames a gran escala; sin embargo, en concordancia con Mathis et al., es fundamental la validación human-in-the-loop y el uso de métricas como Kappa para asegurar que los resultados sean creíbles y reproducibles [12]. Por ello, incluye visualizaciones temporales junto con los valores de Kappa para mostrar dónde suceden las discrepancias y si se agrupan en transiciones rápidas entre estados o en eventos poco comunes.




Ilustración 23: Ejemplo de Matriz de confusión temporal

3.3. Minería de Datos y Clasificación de Comportamientos

Para el análisis cuantitativo del comportamiento, se requieren métodos que tengan la capacidad de ordenar grandes cantidades de datos provenientes de trayectorias, posiciones y señales temporales. Este marco es proporcionado por la minería de datos, porque posibilita el hallazgo de estructuras internas, la disminución de la complejidad de las observaciones y la creación de categorías que simplifican la interpretación neuroconductual o etológica. En este marco, los algoritmos de agrupamiento, clasificación supervisada y reducción de dimensionalidad son fundamentales para detectar patrones repetitivos, diferenciar conjuntos de comportamientos y elegir las características más significativas en sistemas con una gran cantidad de variables que suelen ser ruidosas. Las siguientes subsecciones detallan las metodologías más utilizadas en este ámbito y explican su relevancia para el análisis computacional del comportamiento animal.

3.3.1 K-Means (Clustering)

El algoritmo K-Means, que fue presentado por primera vez en el trabajo de MacQueen "Some Methods for Classification and Analysis of Multivariate Observations" (1967) [30], es un método esencial para la agrupación no supervisada. Se emplea para identificar patrones y estructuras ocultas en conjuntos de datos con alta dimensionalidad. Este procedimiento, de acuerdo con el libro clásico de Bishop "Machine Learning and Pattern Recognition" [22], divide los datos en K grupos al minimizar la distancia entre cada punto y el centroide del clúster que le corresponde. Según Bishop, esta estrategia es especialmente efectiva cuando se persiguen "regiones compactas y casi esféricas" en los datos. Por lo tanto, es adecuada para usarse en minería de datos aplicada al estudio de la conducta animal, la identificación de patrones motores y el análisis etológico.

K-Means es un procedimiento para identificar patrones de conducta que se repiten con el tiempo, en el contexto de minería de datos y clasificación conductual. El algoritmo permite la agrupación de

segmentos de conducta semejantes sin requerir etiquetas previas en investigaciones que rastrean animales y donde se recogen variables como trayectorias espaciales, velocidad o ángulos corporales. Esta perspectiva, según Bishop [22], es efectiva para disminuir la dimensionalidad conceptual del comportamiento, ya que facilita la identificación de categorías que posteriormente pueden asociarse con fenómenos neuroconductuales o etológicos. Cuando se completa esta estructura con sistemas de visión computacional como EzTrack [5] o DeepLabCut [12], es particularmente beneficiosa, ya que ambos producen datos cuantitativos que tienen la capacidad de ser introducidos directamente en el algoritmo.

El proceso computacional se compone de cuatro etapas fundamentales: el establecimiento inicial de K centroides, la asignación a cada punto del centroide más próximo, el recálculo de los centroides y la repetición hasta que se alcance la convergencia. Según MacQueen [30], este ciclo es sencillo y eficiente, lo que posibilita la utilización de K-Means en grandes cantidades de información con un coste computacional reducido. En investigaciones sobre el comportamiento de los animales, esta eficacia permite analizar millones de fotogramas.




Ilustración 24: Representación gráfica del proceso iterativo (asignación y actualización)

K-Means tiene serias limitaciones a pesar de su utilidad. De acuerdo con Bishop [22], el método es sensible a la inicialización, tiene la capacidad de converger a soluciones locales y no opera adecuadamente si los clústeres son significativamente desiguales en tamaño o si no tienen una forma aproximadamente esférica. Por lo tanto, en las aplicaciones de análisis conductual, se aconseja revisar varias inicializaciones (k-means++) y validar los clústeres utilizando índices como Dunn o Silhouette.



Ilustración 25: Ejemplo de diferentes resultados de clustering con distintas distribuciones

3.3.2 Random Forest

El algoritmo Random Forest es parte de la familia de estrategias de ensamblaje que fusionan varios árboles de decisión con el propósito de optimizar la habilidad predictiva de los modelos. Según Breiman, que formalmente presentó esta técnica en 2001 [32], el procedimiento consiste en crear múltiples árboles que se entrenan sobre subconjuntos aleatorios de datos y variables. Esta estrategia, en el contexto de la minería de datos aplicada a la evaluación de comportamientos, disminuye la variabilidad que los modelos individuales tienen por su propia naturaleza y posibilita identificar patrones complejos sin caer fácilmente en el sobreajuste. Bishop sostiene que al combinar predicciones independientes de los modelos base, los métodos de ensamble aumentan la habilidad de generalización de manera constante [22].




Ilustración 26: Múltiples árboles de decisión en un Random Forest [34]




Ilustración 27: Diagrama esquemático de los métodos de ensamblaje [35]

En contextos en los que se examinan comportamientos humanos o animales a través de métodos de visión por computadora, es frecuente que los conjuntos de datos sean incompletos, tengan un alto número de dimensiones o estén llenos de ruido. Quintana-Diez afirma que la inclusión de inteligencia

artificial en el análisis del comportamiento animal ha posibilitado el tratamiento de grandes cantidades de datos con mayor exactitud y consistencia [14]. De acuerdo con Bailey y su equipo, los modelos computacionales contribuyen a relacionar patrones de comportamiento con parámetros fisiológicos, incluso cuando la información tiene variaciones entre individuos [10], este algoritmo es perfecto para este tipo de situaciones, ya que gestiona correctamente datos heterogéneos y posibilita determinar cuáles rasgos tienen mayor incidencia en una clasificación mediante medidas de la importancia de las variables.

DeepLabCut de Mathis et al. [12] y OpenPose de Cao et al. [23], que son herramientas modernas, también producen descriptores temporales y espaciales de alta resolución acerca del movimiento o la postura. Estos rasgos se utilizan como insumo para modelos de clasificación que emplean Random Forest, los cuales tienen la capacidad de identificar comportamientos, detectar anomalías o dividir grupos experimentales. Pereira y Moita, en sus investigaciones etológicas, afirman que la visión artificial ha transformado radicalmente el modo de cuantificar la conducta, posibilitando así la creación de bases de datos confiables y ampliables para realizar minería de datos [16]. En esa línea, el hecho de que el bosque aleatorio tenga la habilidad de trabajar con cientos de descriptores lo hace un candidato apropiado para los sistemas de análisis automatizado.

Asimismo, Random Forest se caracteriza por su capacidad para ser interpretado. De acuerdo con Hastie, Tibshirani y Friedman [33], en *The Elements of Statistical Learning*, los bosques posibilitan la estimación de la importancia de cada variable a través de métricas como el decrecimiento de impureza o la disminución en precisión al permutar características. Cuando se intenta entender qué elementos explican una conducta, sobre todo en la investigación veterinaria o biomédica, esta información es fundamental. Según Barton y Olson, para que los sistemas inteligentes sean integrables en la toma de decisiones clínicas, deben ser transparentes y precisos a la vez [9].

3.3.3 Máquinas de Vectores de Soporte (SVM)

Según Burges en "A Tutorial on Support Vector Machines for Pattern Recognition" [36], las máquinas de soporte vectorial (SVM) son un clasificador supervisado que se propone encontrar el hiperplano óptimo que divida dos clases, con el objetivo de maximizar el margen entre los vectores de soporte. Que el clasificador dependa solo de los vectores de soporte pone de relieve su eficiencia en la memoria y su habilidad para generalizar.




Ilustración 28: Ejemplo de un problema de clasificación en un espacio bidimensional. Los vectores de soporte marcados con cuadros grises definen el margen mayor de separación entre las 2 clases [36]

Las SVM son efectivas en espacios con alta dimensionalidad y se pueden utilizar cuando la cantidad de dimensiones sobrepasa la cantidad de muestras, de acuerdo con el manual de uso de scikit learn. [37] En concreto, el algoritmo contiene la selección de un parámetro de regularización C , que regula el balance entre la adaptación a los datos del entrenamiento y la capacidad de generalizar. Además, se trata el problema de los datos que no pueden separarse de manera lineal al emplear funciones kernel (como la polinómica, la RBF o la lineal) para hacer un mapeo implícito a espacios de dimensiones superiores, sin tener que calcular explícitamente dicho mapeo.

De acuerdo con Burges [36], la formulación de la SVM se presenta como un problema de optimización cuadrática convexo, acompañado de restricciones que aseguran la clasificación correcta (en el caso separable) o permiten violaciones controladas (margen blando). Esta formulación asegura la existencia de un mínimo global, a diferencia de otros métodos como redes neuronales que pueden quedar atrapados en mínimos locales. Para el dominio de la clasificación de comportamientos tales como reconocimiento de gestos, detección de patrones de conducta o análisis de secuencias temporales, esta propiedad brinda robustez frente al ruido y estabilidad en la frontera de decisión.




Ilustración 29: Otro ejemplo de una SVM lineal que muestra el hiperplano óptimo, sus márgenes y los vectores de soporte que determinan la separación entre clases [37]

Según Burges [36], la formulación de la SVM es un problema de optimización cuadrática convexa, que incluye restricciones para garantizar una clasificación adecuada (en el caso separable) o para permitir infracciones controladas (margen blando). Esta formulación garantiza que haya un mínimo global, lo cual contrasta con otros métodos como las redes neuronales, que pueden quedar estancadas en mínimos locales. Esta propiedad proporciona estabilidad en la frontera de decisión y solidez frente al ruido en el ámbito de detección de patrones conductuales y clasificación de comportamientos.

3.3.4 Reducción de dimensionalidad

La reducción de dimensionalidad es una serie de métodos que buscan convertir datos de alta dimensión en representaciones más compactas, pero sin que la estructura fundamental del problema se vea afectada. Este procedimiento posibilita la eliminación de redundancias, ruido y variables que no tienen relevancia, según Pattern Recognition and Machine Learning de Christopher Bishop [22]. Esto es particularmente ventajoso en minería de datos, donde el número de atributos puede obstaculizar tanto el rendimiento computacional como la interpretación de los modelos. La reducción de la dimensionalidad, en este contexto, permite identificar patrones más generales y aumenta la habilidad de los algoritmos para clasificar las conductas complejas tanto en seres humanos como en modelos animales.




Ilustración 30: Ejemplo conceptual del problema de dimensionalidad en un sistema de una pelota en un resorte observado desde 3 cámaras [31]

El PCA (Análisis de Componentes Principales) es un método muy utilizado. De acuerdo con lo que plantean Hastie, Tibshirani y Friedman en *The Elements of Statistical Learning* [33], el PCA proyecta los datos en nuevas direcciones ortogonales denominadas "componentes principales", las cuales capturan la mayor varianza posible del conjunto de datos original. Esto posibilita que la representación se simplifique sin que la estructura estadística predominante se vea afectada. La Ilustración 31 presenta una nube de puntos donde la dirección principal no coincide con los ejes originales, sino con una dirección inclinada que captura la señal principal, en otras palabras, muestra visualmente cómo PCA determina el rumbo de mayor varianza para describir los datos de manera más precisa.




Ilustración 31: Nube de datos simulados para la cámara A con indicación de varianza de señal y ruido. Adaptada de Shlens [31]

Bishop [22] también sostiene que los métodos no lineales, como Isomap y t-SNE, son capaces de mantener relaciones topológicas más complejas en los datos. Cuando las conductas tienen patrones muy correlacionados o dinámicas delicadas que no se pueden captar de manera apropiada a través de transformaciones lineales, estas técnicas resultan ser especialmente eficaces.

3.4 Modelos experimentales en etología y neurociencia conductual

El estudio experimental de la conducta ansiosa requiere modelos que integren principios etológicos con fundamentos neurobiológicos para permitir una interpretación cuantitativa y reproducible del comportamiento. Estos modelos, ampliamente empleados en neurociencia conductual, se basan en situaciones controladas que evocan respuestas defensivas naturales y facilitan la medición de variables como exploración, evitación e inmovilidad. Su diseño permite vincular patrones observables con procesos subyacentes (sensoriales, cognitivos y emocionales) y establecer puentes entre el comportamiento espontáneo de los animales y los mecanismos neurales que lo regulan. Las subsecciones siguientes describen los constructos etológicos relevantes y los paradigmas experimentales más utilizados en la caracterización del comportamiento ansioso.

3.4.1 Conceptos etológicos del comportamiento ansioso

El análisis del comportamiento ansioso en modelos animales se apoya en paradigmas experimentales que evocan respuestas defensivas naturales y permiten medirlas de forma objetiva. Estos modelos combinan principios etológicos y neurobiológicos para vincular acciones observables con los mecanismos que las generan. A continuación, se presentan los principales constructos conductuales y los métodos más empleados para su estudio.

3.4.1.1 Exploración

Según Carobrez y Bertoglio, la exploración se define como una serie de acciones encaminadas a obtener información sobre el entorno, que incluyen movimientos intencionados, rearings (alzadas), olfateo dirigido y contacto con objetos [3]. Estas conductas posibilitan la evaluación de la interacción

entre el deseo de investigar y la valoración del ambiente, y deben distinguirse del comportamiento motor general, puesto que solo el análisis combinado de frecuencia, tiempo y tipo de conducta proporciona una medida válida de la propensión a explorar [10].




Ilustración 32: Ejemplo de un módulo de seguimiento de ezTrack [5].

La operacionalización de la exploración en laboratorio, conforme a lo que indican Pennington y su equipo, necesita una etograma exhaustivo y sistemas de registro automatizados. Estos últimos posibilitan medir tanto sucesos discretos (por ejemplo "sniffing" o "head dips") como variables continuas (como trayectorias o tiempo en áreas). El análisis posicional y la extracción de series temporales de conducta son simplificados por herramientas como EzTrack, lo cual permite que la medición sea más exacta y reproducible [5]. También se aconseja incorporar sesiones de habituación antes para diferenciar la respuesta inicial a lo nuevo de la motivación exploratoria sostenida.

Según Pereira y Moita, unir un etograma con análisis multivariantes (como el agrupamiento de módulos conductuales o componentes principales) posibilita disociar, desde una perspectiva estadística, la exploración de otros elementos comportamentales. Esto permite aumentar la validez de las investigaciones y simplificar la comparación entre especies y protocolos [16]. Wiltchko et al. han mostrado, además, que el análisis de la estructura sub-segundo del comportamiento en roedores brinda una resolución temporal más precisa y permite descubrir micro-movimientos significativos que no se recogen en el análisis global [17].

Mathis y sus coautores han demostrado que, mediante DeepLabCut, se puede estimar la pose sin marcadores y cuantificar automáticamente posturas y movimientos particulares (por ejemplo, rearings y head-dips) de modo reproducible. Esto mejora la exactitud de la medición de la exploración [12].

Así, es posible obtener información pormenorizada acerca de la motricidad y la disposición exploratoria sin perturbar el comportamiento natural de los animales.




Ilustración 33: Representación de módulos conductuales y transiciones destacando micro movimientos relevantes para la exploración [17]

3.4.1.2 Evitación

De acuerdo con Kryptos, Effting, Kindt y Beckers, la evitación es una táctica defensiva adaptativa que busca disminuir las posibilidades de enfrentarse a situaciones o estímulos aversivos. Sin embargo, si se vuelve generalizada o persiste sin una contingencia real, se convierte en mal adaptativa y ayuda a que los trastornos de ansiedad continúen. Kryptos et al. indican que la evitación puede ser adquirida por diversos medios, como procesos habituales y tendencias de rasgo, lo cual requiere paradigmas experimentales que dividan esos procesos. Además, describen los mecanismos de aprendizaje involucrados (los factores pavlovianos e instrumentales, la influencia de las instrucciones y el aprendizaje vicario) [39].




Ilustración 34: Red de la corteza prefrontal media y su implicación en la evitación defensiva [40]

Según la visión neuro etológica, Mobbs y su equipo sugieren que la evitación es parte de un sistema integrado de optimización de la supervivencia (SOS, por sus siglas en inglés), donde se coordinan circuitos que abarcan a la corteza prefrontal medial, al estriado, a la amígdala y a regiones mesencefálicas como el PAG. En este sistema están involucradas las siguientes funciones: evaluar amenazas, prever/prevenir y elegir estrategias como las respuestas circa-strike, el escape dirigido post encuentro y la evitación pre encuentro. Según Mobbs et al., la evitación preventiva (evitar el encuentro) se basa en procesos de predicción/simulación y en redes frontoestriales que facilitan un cambio de respuestas motivadas por miedo a respuestas más automáticas o instrumentales. (De acuerdo con Mobbs et al.). [40]

Ball y Gunaydin examinan cómo diferenciar la evitación adaptativa de evitación mal adaptativa, además de proponer un marco neuroconductual que divide tres procesos subyacentes: (i) evaluación exagerada del peligro, (ii) evitación regular (involuntaria, insensible al resultado) y (iii) tendencia a evitar como rasgo. Esto indica, en términos experimentales, que se deben medir no solo la expresión de evitación, sino también proxies del miedo (como las medidas autonómicas), la resistencia a la extinción y la generalización. De esta manera, se podrá determinar si el comportamiento de evitar es causado por un rasgo, un hábito o miedo. Según Ball y Gunaydin. [41]




Ilustración 35: Esquema que muestra como la interacción entre el miedo y la evitación permite identificar los procesos neuroconductuales subyacentes [41]

3.4.1.3 Inmovilidad/congelación

Desde el punto de vista etológico, la respuesta defensiva conocida como "freezing" o inmovilidad es una reacción frente a amenazas que, Según Brandão et al. [42], consiste en una repentina inhibición motora, acompañada de bradicardia, tras la identificación de un peligro inminente; esto posibilita que el individuo mejore la evaluación de riesgos y disminuya las posibilidades de ser descubierto por un depredador. Este fenómeno se encuentra en el continuo de inminencia depredadora ("predatory imminence continuum"), donde la táctica de defensa va cambiando a medida que la amenaza se aproxima, pasando por exploración, congelación y, finalmente, huida o lucha. [42]




Fig. 1. Activación de sustratos neuronales distintos en función de la naturaleza de los estímulos amenazadores. Los estímulos condicionados de peligro (potenciales o distales) elicitán comportamiento condicionado de congelación a través de la activación del sistema de inhibición conductual (sistema tepto-hipocampal), mientras que los estímulos innatos de peligro (proximales o nociceptivos) elicitán formas activas de comportamiento defensivo a través de la activación del eje amígdala-PAG dorsal. La activación del circuito PAG dorsal amígdala por estímulos nociceptivos también activa mecanismos inhibitorios a través de las proyecciones de la amígdala-PAG dorsal, lo que podría subyacer a la llamada analgesia inducida por el miedo, o la propuesta de que la ansiedad inhibe el pánico, o la propuesta de que la ansiedad innibe el pánico.

Ilustración 36: Esquema de la cascada defensiva [42]

La inmovilidad defensiva, desde la perspectiva neurobiológica, comprende proyecciones que van del núcleo central de la amígdala al gris periacueductal (PAG) en el tronco encefálico; este último regula la bradicardia vagal y la inhibición motora. Según Klaassen et al. [43], este mecanismo posibilita la preparación para actuar, incluso cuando el sujeto parece estar inmóvil. Asimismo, se ha relacionado en seres humanos la magnitud de la congelación con decisiones de aproximación-evitación ante una amenaza, lo que indica su importancia no solo en modelos animales, sino también en el análisis de la ansiedad clínica [43].

Desde el punto de vista etológico, la congelación es distinta de otros estados defensivos, como la inmovilidad tónica ("tonic immobility"), no solo en su función adaptativa, sino también en su desencadenante. La congelación ocurre cuando todavía hay una oportunidad de cambiar la estrategia defensiva, mientras que la inmovilidad tónica suele activarse cuando el sujeto no puede huir ni luchar, y toma una actitud parecida a la "muerte aparente"; esta diferenciación es beneficiosa para los modelos experimentales en neurociencia conductual, ya que posibilita el análisis de la manera en que los animales escogen sus respuestas ante diferentes grados de amenaza; esto tiene consecuencias para la investigación sobre características de ansiedad y susceptibilidad a trastornos de ansiedad [42].

3.4.2 Laberinto en Cruz Elevada (EPM)

El laberinto en cruz elevado (Elevated Plus-Maze, EPM) es un aparato experimental que se creó con el objetivo de analizar la conducta ansiosa en roedores. Según Carobrez y Bertoglio, el EPM es una plataforma que se encuentra a unos 50 cm del suelo y cuenta con cuatro brazos organizados en forma de cruz: dos de ellos están abiertos, mientras que los otros dos están cerrados por medio de paredes laterales [3]. Este tipo de configuración crea un entorno que mezcla áreas aversivas y seguras, lo cual posibilita la observación de cómo el animal toma decisiones cuando se enfrenta a la disyuntiva entre evitar y explorar.




Ilustración 37: Esquema del EPM desde vista superior. Los brazos horizontales son abiertos mientras los verticales son cerrados [44].

De acuerdo con lo que dicen Netto, Zangrossi y Graeff, la lógica del EPM se fundamenta en el temor natural que tienen los roedores a los espacios abiertos y altos [4]. Los brazos abiertos indican peligro, mientras que los cerrados sugieren una zona segura. El nivel de ansiedad del animal se refleja en la selección que hace entre estos espacios, lo cual representa un modelo etológico de aproximación y evitación.

Carobrez y Bertoglio [3] indican que el EPM tiene una estructura habitual con brazos de 50 cm de largo por 10 cm de ancho, que poseen paredes con una altura de 40 cm en los tramos cerrados. La parte central de la cruz es un pequeño soporte que une los cuatro brazos. Esta estandarización garantiza que los resultados sean comparables entre diferentes laboratorios.

El EPM opera de la siguiente manera: se ubica el animal en el centro de la cruz y se monitorea su conducta durante un lapso de 5 a 10 minutos. Los parámetros más frecuentes comprenden el tiempo de latencia para explorar, la cantidad de entradas a cada brazo y el tiempo que se permanece en brazos abiertos y cerrados [3].




Ilustración 38: Seguimiento del comportamiento individual de ratas mediante pruebas repetidas de EPM [45].

Según Khatri et al., la validación farmacológica del EPM se llevó a cabo con benzodiazepinas, las cuales incrementan la exploración de los brazos abiertos, lo que demuestra que el modelo es sensible a compuestos ansiolíticos [1]. Por lo tanto, el EPM es visto como un estándar fiable para evaluar la ansiedad en animales de laboratorio.

Se examinan conductas particulares como el "head-dipping" (cuando el animal se asoma por el borde de los brazos abiertos) y la "stretch-attend posture" (una postura en que se estira y retrocede), además

de las medidas básicas. Estos comportamientos, de acuerdo con Carobrez y Bertoglio, enriquecen la interpretación del modelo [3] y muestran estrategias para evaluar el riesgo.

Pennington et al. indican que los sistemas automatizados, como EzTrack, tienen la capacidad de reemplazar el registro manual. Estos sistemas posibilitan seguir el recorrido del animal y estimar métricas con mayor exactitud [5]. Esto ha permitido una disminución del sesgo observador y una mejora de la reproducibilidad, convirtiéndose en un instrumento accesible y reproducible [5].

Mathis et al. subrayan que tecnologías como DeepLabCut posibilitan la estimación de la postura del animal sin requerir marcadores [12]. Esto extiende el análisis del EPM a aspectos más detallados de la conducta, como los micro movimientos y los patrones de exploración.

Mobbs et al. [40] describen que la amígdala, el hipocampo y la corteza prefrontal intervienen en el control de la ansiedad, pues se activan ante circunstancias de peligro. El EPM ha posibilitado el reconocimiento de la interrelación entre estos sistemas de defensa y exploración, proporcionando pruebas sobre la neurobiología de la ansiedad, y de acuerdo con Bailey, Capozzi y Lowry, el EPM es un modelo traslacional, ya que los patrones de ansiedad detectados en roedores están vinculados a trastornos en seres humanos [10].

Su diseño simple, parámetros definidos y validación farmacológica lo hacen un modelo sólido para investigar la ansiedad al medir directamente la conducta de aproximación-evitación en un ambiente controlado.

3.5 Sistema operativo

El sistema operativo (SO) es el software que se ejecuta en una computadora, actuando como un intermediario entre el hardware y el software. El SO decide qué proceso recibirá acceso a la CPU y por cuánto tiempo, gestiona la memoria RAM asignando espacio a cada aplicación y protegiendo ese espacio. También administra el disco duro para que se puedan guardar y recuperar archivos.

3.5.1 Windows 10/11

Windows es un sistema operativo creado por Microsoft. Este software se compone de un grupo de programas que permiten gestionar y controlar el funcionamiento de varias partes de un ordenador, como la memoria, el disco duro y los dispositivos periféricos [83].

3.6 Lenguaje de programación

Un lenguaje de programación es un conjunto de reglas, símbolos y palabras clave que permiten la creación de instrucciones. Estas instrucciones se combinan para formar un programa que una computadora puede ejecutar y así llevar a cabo tareas específicas. La principal función de un lenguaje de programación es facilitar a los desarrolladores la escritura de algoritmos de manera lógica y estructurada.

3.6.1 Python

Python se erige como un lenguaje de programación robusto y de fácil asimilación. Su diseño incorpora estructuras de datos de alto nivel notablemente eficientes, complementadas por una metodología de programación orientada a objetos. La funcionalidad del intérprete de Python es extensible mediante la

incorporación de nuevas funciones y tipos de datos implementados en lenguajes de bajo nivel como C o C++. Esto, a su vez, posiciona a Python como un lenguaje de extensión óptimo para la personalización de aplicaciones preexistentes [84].

Capítulo 4. Análisis

En este capítulo se detalla el análisis formal llevado a cabo para la concepción y desarrollo del prototipo de software. La etapa de análisis constituye una fase crítica dentro de la metodología espiral de Boehm, ya que permite la traducción de los objetivos generales del Trabajo Terminal en requerimientos computacionales específicos y comprobables. Este proceso engloba la especificación detallada de los requerimientos funcionales y no funcionales, el análisis estructurado de las alternativas tecnológicas de hardware y software (incluyendo técnicas de visión artificial, arquitecturas de aprendizaje profundo y entornos de procesamiento), y la definición formal de las reglas de negocio de la aplicación. Asimismo, se incorpora un riguroso análisis de riesgos metodológicos y técnicos, y una evaluación exhaustiva de viabilidad tecnológica, operativa, legal y económica, consolidando esta última mediante la aplicación del modelo predictivo COCOMO II y un análisis formal de costo-beneficio.

4.1 Requerimientos

Los requerimientos funcionales y no funcionales son especificaciones que determinan el funcionamiento del prototipo. Los requerimientos funcionales describen las acciones que el sistema debe ejecutar, mientras que los no funcionales establecen condiciones de calidad, seguridad, rendimiento, portabilidad y usabilidad necesarias para su operación correcta.

4.1.1 Requerimientos Funcionales (RF)

RF#	Descripción	Número y nombre de Caso de Uso	En caso de tener regla de negocio
RF1	Registrar usuario con campos obligatorios de perfil (nombre completo, correo, contraseña) y validación de correo institucional.	CU1 Registrar usuario	RN1, RN2
RF2	Iniciar sesión ingresando correo, contraseña y tipo de perfil, verificando credenciales en la base de datos.	CU2 Iniciar sesión	RN3
RF3	Registrar y gestionar tratamientos experimentales (nombre del fármaco, descripción y estado activo/inactivo).	CU3 Gestionar tratamientos	RN4
RF4	Registrar un nuevo experimento asociando ID del espécimen, tratamiento, fecha, responsable de experimentación y ruta del video.	CU4 Registrar experimento	RN5
RF5	Configurar regiones de interés (ROIs) sobre el primer fotograma del video	CU5 Configurar ROIs	RN6

Commented [IR1]: <https://visuresolutions.com/es/alm-guide/non-functional-requirements/>

Commented [IR2]: FAVOR DE REVISAR : <https://www.gluo.mx/blog/requisitos-funcionales-que-son-y-como-funcionan>

	para delimitar brazos abiertos, cerrados y centro.		
RF6	Procesar el video experimental mediante el modelo YOLO-Pose para detectar los keypoints del espécimen y calcular la trayectoria a partir de la coordenada del torso.	CU6 Ejecutar análisis de video	RN7
RF7	Clasificar las conductas Grooming y Thigmotaxis mediante modelos entrenados con features de postura, y calcular métricas espaciales de trayectoria por zonas.	CU7 Agrupar comportamientos	-
RF8	Permitir la edición manual de los tiempos conductuales por investigadores autorizados, registrando los valores previos y nuevos.	CU8 Editar tiempos conductuales	RN8
RF9	Exportar los resultados de los análisis procesados a formatos estructurados (Excel / PDF) para pruebas estadísticas.	CU9 Exportar resultados	-
RF10	Registrar automáticamente bitácoras de auditoría de seguridad para todos los eventos de autenticación y accesos críticos.	CU10 Consultar bitácora de auditoría	RN9

Tabla 3: "Requerimientos Funcionales (RF) del prototipo"

4.1.2 Requerimientos No Funcionales (RNF)

RNF#	Descripción	propiedad	aplicación
RNF1	El sistema debe responder a las consultas de experimentos y base de datos en menos de 2 segundos.	Rendimiento	Búsqueda y filtrado de registros de análisis en la interfaz de Streamlit.
RNF2	El sistema debe procesar videos a una tasa mínima de 30 fotogramas por segundo (fps) en inferencia con GPU dedicada.	Eficiencia	Inferencia en tiempo real del modelo YOLO-Pose.
RNF3	Las contraseñas de los usuarios deben almacenarse de forma segura utilizando	Seguridad	Encriptación del campo password_hash en el registro e inicio de sesión.

	algoritmos de derivación de claves con sal (bcrypt).		
RNF4	El sistema debe almacenar videos y metadatos de análisis de forma consistente en una base de datos relacional.	Confiabilidad	Persistencia de registros en PostgreSQL.
RNF5	El sistema debe ser ejecutable en sistemas operativos Windows 10/11 mediante un entorno Python preconfigurado y dependencias documentadas.	Portabilidad	Portabilidad mediante entorno virtual, archivo de dependencias y guía de instalación local.
RNF6	La interfaz gráfica debe ser intuitiva y accesible para personal médico y etólogos sin formación en programación.	Usabilidad	Diseño guiado por menús interactivos, exportación simple a Excel y gráficos directos.

Tabla 4: "Requerimientos No Funcionales (RNF) del prototipo"

4.1.3 Reglas del negocio

Las reglas del negocio constituyen los principios rectores que orientan la planificación, ejecución y validación de cada iteración dentro de la metodología espiral de Boehm. Estas reglas establecen los límites, prioridades y criterios de éxito del proyecto, asegurando que el desarrollo mantenga su enfoque académico, ético y técnico en todo momento. Cada iteración de la espiral tiene que ser planificada, llevada a cabo y evaluada según las pautas que se describen a continuación.

Las reglas del negocio permiten:

- **Estandarizar las decisiones y acciones**, evitando ambigüedad en los procesos.
- **Garantizar cumplimiento** con políticas académicas, técnicas y éticas.
- **Reducir riesgos y errores**, al establecer con claridad las condiciones y los límites del flujo de trabajo.
- **Alinear la planificación y validación** del prototipo conforme a los criterios de éxito definidos.

Estas reglas tienen que redactarse en un lenguaje que sea claro, comprobable y medible. En este proyecto, las normas de la empresa garantizarán que:

- Cada iteración cumpla con los estándares éticos y metodológicos del IPN.
- Los resultados de IA y minería de datos deben ser trazables y validados.
- Las decisiones acerca de los ajustes o mejoras de modelo se toman utilizando en métricas objetivas.

Cada iteración de la espiral debe planificarse, ejecutarse y evaluarse conforme a estas reglas, garantizando un desarrollo controlado, reproducible y alineado con los objetivos científicos y académicos del Trabajo Terminal.

A continuación, se detallan las reglas de negocio que rigen la operación, validación y mantenimiento del prototipo de análisis automatizado de comportamiento en modelos de ansiedad.

Cada regla está formulada de manera verificable, clara y orientada a buenas prácticas de ingeniería de software:

RN#	Descripción	Caso de cumplimiento	Caso de no cumplimiento
RN1	Registro con datos obligatorios de perfil. Todos los campos de registro requeridos deben validarse antes del registro.	La aplicación permite completar el registro si todos los campos requeridos se completan con formatos válidos.	La aplicación bloquea el envío del formulario, marca los campos vacíos en rojo y muestra un mensaje de campo obligatorio.
RN2	Restricción de correo institucional y único. El correo de registro debe pertenecer al dominio @ipn.mx o @alumno.ipn.mx y ser único.	La aplicación acepta el correo institucional válido y envía el código de verificación para completar el registro.	La aplicación muestra un error indicando que el correo no es institucional o que ya está asociado a otro usuario.
RN3	Bloqueo de cuenta por intentos fallidos de inicio de sesión. La cuenta debe suspenderse tras 5 intentos fallidos consecutivos.	El sistema registra el acceso con éxito y restablece el contador de intentos fallidos.	El sistema registra la falla en la bitácora de auditoría y bloquea la cuenta tras el intento fallido.
RN4	Nombre único de tratamientos. Dos tratamientos experimentales no pueden registrarse con el mismo nombre en el catálogo.	La aplicación registra exitosamente el nuevo fármaco (ej. 'Diazepam 1.0 mg/kg') al verificar que su nombre es único.	El sistema aborta la inserción y muestra un mensaje de error advirtiendo que el tratamiento ya existe en el catálogo.
RN5	Trazabilidad del video experimental. Cada experimento registrado debe apuntar a una ruta física de video localizable y compatible.	El sistema valida la extensión del video, comprueba su existencia en disco y habilita el botón de análisis.	El sistema marca la ruta en rojo y bloquea el botón de procesamiento mostrando el error de archivo no encontrado.
RN6	Zonas de ROI no superpuestas. Las áreas delimitadas para los brazos abiertos, brazos cerrados y centro no deben superponerse.	La interfaz gráfica guarda las coordenadas JSONB de las zonas cuando sus intersecciones espaciales no violan los límites geométricos.	El sistema despliega una advertencia en pantalla indicando solapamiento e impide guardar la configuración del ROI.
RN7	Umbral mínimo de confianza de YOLO-Pose. El sistema solo registrará detecciones de keypoints cuando la confianza sea mayor a 0.50.	El tracker registra la trayectoria y las posturas detectadas en cada fotograma al superar el umbral de confianza.	El tracker descarta el fotograma de baja confianza y mantiene la última posición conocida para evitar falsos positivos.
RN8	Trazabilidad e integridad en edición manual de tiempos. Toda edición manual requiere	La base de datos registra en behavior_edits las variables antes y después	El sistema bloquea el guardado del formulario si la justificación está vacía o

	justificación obligatoria y rol de investigador.	del cambio, el usuario y la nota explicativa.	si el usuario tiene rol de estudiante.
RN9	Inmutabilidad de bitácora de auditoría de seguridad. Los registros de la tabla de auditoría son inmutables (solo inserción y lectura).	El sistema permite consultar la bitácora desde la vista de administrador o agregar registros nuevos.	Cualquier comando de UPDATE o DELETE sobre estas tablas genera un error crítico de base de datos a nivel de triggers.

Tabla 5: "Reglas de Negocio del prototipo"

4.1.4 Identificación de requerimientos técnicos

Para garantizar el funcionamiento óptimo del prototipo y posibilitar la portabilidad de la solución entre los equipos de desarrollo y la estación de trabajo local en los laboratorios de la ENMyH-IPN, se definieron con rigor los requerimientos técnicos esenciales de hardware y software:

Requerimientos de Hardware

1. Equipo de Cómputo Local (Laptop de Desarrollo y Despliegue): Laptop de alto rendimiento equipada con procesador x86-64 de alto rendimiento (mínimo Intel Core i7 o AMD Ryzen 7 o superior) con al menos 8 núcleos físicos para la ejecución local de la inferencia, procesamiento asíncrono de video y gestión de base de datos.

2. Memoria de Acceso Aleatorio (RAM): 32 GB de memoria RAM (DDR4 o DDR5) configurada en doble canal para posibilitar el procesamiento simultáneo del flujo de video y la persistencia relacional en local sin latencias en el sistema.

3. Unidad de Almacenamiento Principal: Unidad de estado sólido SSD con interfaz NVMe M.2 (capacidad mínima de 512 GB) para asegurar velocidades de lectura/escritura superiores a 3000 MB/s, necesaria para el almacenamiento redundante de los videos y datasets locales.

4. Unidad de Procesamiento Gráfico (GPU): GPU NVIDIA dedicada con soporte CUDA y al menos 8 GB de VRAM para entrenamiento e inferencia acelerada del modelo YOLO11s-pose. En el entorno de desarrollo se utilizó una NVIDIA GeForce RTX 5070 Ti Laptop con 12 GB de VRAM.

5. Dispositivo de Adquisición Cenital: Cámara digital con resolución mínima de 1280x720 píxeles (720p) y adquisición constante de 30 o 60 FPS. Debe contar con soporte físico para su colocación cenital fija sobre el laberinto EPM, garantizando iluminación homogénea y sin distorsión angular.

Requerimientos de Software

1. Entorno de Ejecución Principal (Python): Intérprete Python 3.10 o superior, seleccionado por su madurez, estabilidad y soporte de librerías científicas y de aprendizaje profundo.

2. Frameworks de Aprendizaje Profundo y Visión: PyTorch y Ultralytics YOLO11 para la inicialización, entrenamiento e inferencia del modelo YOLO11s-pose de keypoints, con aceleración CUDA cuando el equipo cuenta con GPU NVIDIA compatible.

3. Biblioteca de Preprocesamiento de Video (OpenCV): OpenCV 4.8+ para decodificación de video, transformaciones espaciales, binarización y renderizado de máscaras para regiones de interés (ROIs).

4. Algoritmos de Suavizado y Procesamiento (SciPy): Filtro de suavizado temporal Savitzky-Golay (scipy.signal) para la eliminación del ruido espacial (jitter) del keypoint del torso del espécimen.

5. Gestión y Estructuración Numérica (NumPy y Pandas): Para la estructuración matemática de series de trayectorias cartesianas (x, y), distancias recorridas y tiempos acumulados de permanencia en formato tabular.

6. Clasificadores Conductuales (SimBA Random Forest y apoyo temporal): Modelos Random Forest mediante SimBA/scikit-learn para la clasificación productiva de Grooming y Thigmotaxis; LSTM en Keras/TensorFlow se conserva como apoyo experimental de rescate temporal, no como clasificador principal.

7. Interfaz Gráfica y Persistencia (Streamlit y PostgreSQL): Streamlit para la interfaz web interactiva del usuario, y PostgreSQL 15 local para la persistencia segura de usuarios, tratamientos, experimentos, ROIs, resultados, ediciones manuales y bitácoras de auditoría.

4.1.5 Evolución e Iteración de Requerimientos del Prototipo

En concordancia con el modelo de desarrollo en espiral propuesto por Barry Boehm, los requerimientos del prototipo no se establecen de manera fija ni rígida al inicio del ciclo de vida del proyecto. Por el contrario, estos evolucionan, se validan y se refinan a lo largo de ciclos incrementales sucesivos, alimentados directamente por las pruebas de campo en el laboratorio y la retroalimentación cualitativa de los etólogos de la Escuela Nacional de Medicina y Homeopatía (ENMyH-IPN).

Esta metodología en espiral permite estructurar los requerimientos en fases progresivas asociadas a cada ciclo de desarrollo:

1. Ciclo I: Viabilidad y Localización (Requerimientos Básicos): Garantizar que el sistema localice al roedor en tiempo de ejecución de manera robusta bajo variaciones de iluminación. Los requerimientos funcionales iniciales se centraron en la correcta segmentación visual del espécimen y la adquisición de video constante a 30 FPS.

2. Ciclo II: Estimación de Pose y Suavizado (Requerimientos Técnicos Avanzados): Extraer keypoints corporales precisos del roedor para análisis conductual. Ante la presencia de ruido espacial (jitter) y oclusiones en la detección de puntos clave, los requerimientos evolucionaron para incorporar el torso como centroide estable de trayectoria mediante YOLO11s-pose y la integración del algoritmo Savitzky-Golay en la fase de posprocesamiento.

3. Ciclo III: Clasificación Conductual e Interacción (Requerimientos de Aplicación): Discriminar conductas complejas como Grooming y Thigmotaxis, además de presentar trayectoria y permanencia por zonas de forma accesible. Se consolidó el uso de SimBA Random Forest como clasificador productivo, se exploró LSTM como rescate temporal y se integró una interfaz web interactiva basada en Streamlit, eliminando la necesidad de operar mediante consola de comandos.

4. Ciclo IV: Seguridad y Persistencia (Requerimientos no Funcionales de Producción): Proteger los datos y posibilitar la auditoría científica. Se incorporó una base de datos relacional PostgreSQL para usuarios, tratamientos, experimentos, configuraciones ROI y resultados; además, se añadieron las tablas behavior_edits y security_audit_log para registrar ediciones manuales y eventos críticos del sistema.

4.2 Análisis de las herramientas a utilizar

Las herramientas seleccionadas para el prototipo se organizan de acuerdo con su función dentro del pipeline: estimación de pose, seguimiento espacial, clasificación conductual, postprocesamiento temporal, persistencia de datos e interfaz de usuario.

- Estimación de pose y seguimiento por visión por computadora.
- Arquitecturas de aprendizaje profundo para extracción de keypoints.
- Clasificación supervisada y apoyo no supervisado para análisis conductual.
- Métricas de evaluación, suavizado temporal y validación Leave-One-Out.
- Conceptos etológicos para Grooming, Thigmotaxis y análisis de ansiedad.

4.2.1 Análisis de técnicas de detección de objetos

Se analizaron las siguientes técnicas de detección y localización visual:

Modelo / Técnica	Precisión Espacial	Velocidad de Inferencia	Carga de Cómputo	Resultado de Análisis
YOLOv11-Pose / Redes convolucionales	Excelente (detección del espécimen y keypoints)	Muy alta con GPU dedicada	Baja en inferencia	Seleccionado. Integra localización y estimación de postura en el mismo pipeline.
Haar Cascades	Baja (sensible a iluminación y postura)	Alta	Muy baja	Descartado. No mantiene precisión ante cambios de orientación y deformación corporal.
HOG + Linear SVM	Media (útil en formas rígidas)	Media-baja	Media	Descartado. No modela adecuadamente movimientos rápidos ni posturas variables del espécimen.

Tabla 6: "Tabla de análisis de técnicas de detección de objetos [autoría propia]"

Con base en la evaluación de la Tabla 6, se seleccionó YOLOv11-Pose como arquitectura de visión por computadora, ya que permite localizar al espécimen y estimar sus keypoints en un solo flujo de inferencia. Esta decisión evita separar la detección del animal y la estimación de postura en dos herramientas distintas.

En la implementación final se entrenó un modelo YOLO11 Pose con 3,953 imágenes etiquetadas, alcanzando $mAP50 = 0.995$ en el conjunto de validación interno. En operación, el modelo procesa videos de 5 minutos en aproximadamente 3 minutos con GPU dedicada, lo que lo hace adecuado para el análisis local de sesiones experimentales.

4.2.2 Análisis comparativo de frameworks de estimación de pose

Se analizaron los siguientes frameworks de estimación de pose animal:

Técnica / Framework	Precisión de Keypoints	Integración Local	Costo Computacional	Resultado de Análisis
YOLOv11-Pose (Ultralytics)	Excelente en el dataset local ($mAP50 = 0.995$)	Alta (Python, OpenCV, Streamlit)	Bajo en inferencia con GPU	Seleccionado como backend productivo de pose.
DeepLabCut (DLC)	Alta en estimación animal markerless	Media-baja (entornos y dependencias específicos)	Alto en pruebas locales	Usado como antecedente; no integrado al prototipo final por tiempo de procesamiento.
SLEAP	Alta, especialmente en escenarios multi-animal	Media	Medio-alto	Descartado. El experimento usa un espécimen por video y no requiere su flujo multi-animal.
DeepPoseKit	Buena	Media-baja	Medio	Descartado por menor mantenimiento y menor alineación con el pipeline actual.

Tabla 7: "Tabla de análisis de técnicas de estimación de pose con aprendizaje profundo [autoría propia]"

DeepLabCut, SLEAP y DeepPoseKit se conservaron como antecedentes metodológicos por su relevancia en estimación de pose animal, pero no forman parte del prototipo productivo. La selección final fue YOLOv11-Pose mediante Ultralytics, debido a su integración directa con Python, menor tiempo de inferencia local y compatibilidad con el flujo Streamlit del sistema.

4.2.3 Selección de estimación de pose markerless para el prototipo

Se analizaron las siguientes alternativas para capturar postura y trayectoria del espécimen:

Técnica / Dispositivo	Precisión Espacial	Requerimiento de Marcadores	Naturaleza de Captura	Resultado de Análisis
YOLOv11-Pose markerless	Excelente para keypoints y centroide	Ninguno	Video estándar del EPM	Seleccionado. Permite registrar conducta natural sin instrumentar al animal.
Kinect Skeleton Tracking	Baja para roedores	Ninguno	Sensor infrarrojo/profundidad	Descartado. Optimizado para humanos y con resolución insuficiente para roedores.
Sistemas Vicon / infrarrojo activo	Excelente	Marcadores físicos reflectantes	Cámaras especializadas	Descartado. Instrumentar al animal introduciría variables de estrés y costo adicional.

Tabla 8: "Tabla de análisis de técnicas de estimación de pose [autoría propia]"

Se eligió estimación de pose markerless porque no requiere colocar marcadores físicos en el animal y, por tanto, no altera la conducta observada en el laberinto. En la versión final, esta estimación se implementa con YOLOv11-Pose, no con DeepLabCut.

4.2.3.1 Justificación de la migración a YOLOv11-Pose

La migración a YOLOv11-Pose solucionó el cuello de botella computacional detectado con enfoques basados en DeepLabCut. Con el modelo actual, un video de 5 minutos se procesa en aproximadamente 3 minutos con GPU dedicada, mientras que las pruebas iniciales con DLC requerían varias horas por video en el entorno local. Esta decisión también simplificó la integración con el resto del pipeline, ya que los keypoints se exportan directamente hacia el puente YOLO-SimBA.

Backend de Pose	Tasa de Inferencia Local	Tiempo de Análisis (video 5 min)	Facilidad de Integración	Resultado de Análisis
YOLOv11-Pose (seleccionado)	Muy alta con GPU dedicada	Aproximadamente 3 minutos	Alta (Python, Ultralytics, OpenCV, Streamlit)	Seleccionado. Resuelve el cuello de botella computacional y se integra al puente YOLO-SimBA.
DeepLabCut (DLC)	Baja en el entorno local evaluado	Varias horas por video en pruebas iniciales	Media-baja por dependencias específicas	Reemplazado. Se conserva como antecedente metodológico, no

				como backend final.
--	--	--	--	---------------------

Tabla 9: "Tabla de actualización de análisis de técnicas de estimación de pose [autoría propia]"

4.2.4 Análisis de herramientas de seguimiento visual

Se analizaron las siguientes herramientas de seguimiento visual:

Algoritmo / Enfoque	Precisión en Seguimiento	Robustez ante Oclusiones	Carga Computacional	Resultado de Análisis
Torso Keypoint (YOLO-Pose) + Savitzky-Golay	Excelente (Coordenada física directa)	Alta (Mantenida por el modelo de pose)	Mínima	Seleccionado. Determina el centroide de forma robusta e inmutable ante luz y oclusiones de brazos.
CAMShift (Bradski)	Media	Baja (Se pierde en giros y oclusiones)	Mínima	Descartado. Sensible a variaciones de color y contraste entre el pelaje y el fondo del laberinto.
MeanShift	Baja	Muy Baja (Falla ante cambios de escala)	Mínima	Descartado. No se adapta a los acercamientos ni a la elongación corporal del espécimen.
CSRT / KLT Tracker	Alta	Media	Alta	Descartado. Su alto consumo computacional desestabiliza la tasa de cuadros por segundo en tiempo real.

Tabla 10: "Tabla de análisis de herramientas de seguimiento visual [autoría propia]"

Se optó por realizar el seguimiento espacial mediante la extracción directa de la coordenada del keypoint del torso detectado por el modelo YOLO-Pose, aplicando un filtro de suavizado de Savitzky-Golay para eliminar el ruido de alta frecuencia (jitter). Se descartaron los algoritmos clásicos como CAMShift y MeanShift debido a su sensibilidad a los cambios de iluminación y contraste en el laberinto, y los trackers CSRT o KLT por su excesivo costo computacional y fallas ante movimientos rápidos del animal.

4.2.5 Análisis de arquitecturas de redes neuronales profundas para visión por computadora

Arquitectura Red	Propósito en Visión	Uso en el Prototipo	Resultado de Análisis
CNN (Convolutional Neural Network)	Extracción de características espaciales y detección de patrones visuales	Base arquitectónica de YOLOv11-Pose	Seleccionada de forma indirecta mediante YOLO Pose.

MLP (Multi-Layer Perceptron)	Clasificación de vectores planos	No se usa como arquitectura de visión principal	Descartado para estimación de pose por ignorar estructura espacial de la imagen.
------------------------------	----------------------------------	---	--

Tabla 11: "Tabla de análisis de arquitecturas de redes neuronales profundas para visión por computadora [autoría propia]"

Se optó por usar CNN como arquitectura para visión por computadora debido a que, a diferencia de MLP, CNN aplica filtros para detectar patrones jerárquicos, desde bordes hasta objetos. En cambio, MLP trata a la imagen como un vector plano ignorando relaciones especiales [65]. Según Rajagukguk et al, CNN tiene una aplicación exitosa en la supervisión de animales [66].

4.2.6 Análisis de arquitecturas de aprendizaje profundo para series temporales

Se analizaron arquitecturas temporales como opciones de apoyo para eventos conductuales complejos:

- RNN/GRU como referencia para modelar secuencias temporales.
- LSTM como mecanismo experimental de rescate temporal.
- Transformers como alternativa futura, no integrada al prototipo productivo.

En el prototipo final, la clasificación productiva no depende de Transformers ni de una red recurrente como núcleo principal. El sistema utiliza Random Forest de SimBA para clasificar Grooming y Thigmotaxis a partir de features espaciotemporales; la capa LSTM se conserva como apoyo experimental para rescatar eventos de Grooming fragmentados cuando el clasificador base queda en zona de incertidumbre.

4.2.7 Análisis de técnicas de minería de datos

Para la clasificación conductual se seleccionó Random Forest mediante SimBA, ya que permite trabajar con features tabulares derivadas de los keypoints, ofrece interpretabilidad y funcionó de forma estable en la validación Leave-One-Out. K-Means y SVM se mantuvieron como antecedentes comparativos, pero no forman parte del flujo productivo. Como apoyo experimental se evaluó B-SOiD, que utiliza reducción de dimensionalidad y agrupamiento no supervisado para identificar motivos de movimiento.

4.2.8 Análisis de sistemas operativos

Se analizaron los siguientes sistemas operativos:

Sistema Operativo	Compatibilidad CUDA/NVIDIA	Estabilidad en Laboratorio	Facilidad de Uso	Resultado de Análisis
Windows 10/11 (Seleccionado)	Excelente (Soporte nativo NVIDIA)	Alta	Alta (Estándar para usuarios no técnicos)	Seleccionado por su amplia difusión en el laboratorio y compatibilidad con GPU NVIDIA, Python, Streamlit y PostgreSQL.

Linux (Ubuntu)	Excelente	Alta	Baja (Requiere línea de comandos)	Descartado como entorno final por la complejidad de mantenimiento para los investigadores de la ENMyH.
macOS	Limitada (Sin soporte CUDA oficial)	Alta	Alta	Descartado por la imposibilidad de ejecutar aceleración de GPU dedicada para los modelos de aprendizaje profundo.

Tabla 12: "Análisis de sistemas operativos [autoría propia]"

Se optó por Windows como sistema operativo del prototipo debido a la disponibilidad de equipos del laboratorio, compatibilidad con GPU NVIDIA/CUDA, Python, Streamlit, OpenCV y Ultralytics. Esta decisión también facilita la operación por usuarios no especializados en administración de sistemas.

4.2.9 Análisis de los lenguajes de programación

Se analizaron los siguientes lenguajes de programación:

Lenguaje	Ecosistema de IA / ML	Velocidad de Ejecución	Velocidad de Desarrollo	Resultado de Análisis
Python (seleccionado)	Excelente (Ultralytics/PyTorch, scikit-learn, TensorFlow/Keras, OpenCV, Streamlit)	Media-alta mediante librerías optimizadas	Muy rápida	Seleccionado por integrar visión, clasificación, UI y persistencia en un solo ecosistema.
C++	Buena para OpenCV nativo	Muy alta	Lenta	Descartado por aumentar tiempo de desarrollo e integración con la UI.
Java	Limitada para pose animal moderna	Alta	Media	Descartado por menor disponibilidad de herramientas actuales para análisis etológico.

Tabla 13: "Análisis de lenguajes de programación [autoría propia]"

Se optó por Python debido a su ecosistema para visión por computadora, aprendizaje automático e interfaces científicas. El prototipo integra Ultralytics/PyTorch para YOLO Pose, SimBA/scikit-learn para Random Forest, TensorFlow/Keras para pruebas LSTM, OpenCV para video, Streamlit para interfaz y PostgreSQL/SQLAlchemy para persistencia.

4.3 Análisis de riesgos

En concordancia con la metodología espiral de Boehm, se determina un proceso sistemático para detectar, evaluar y manejar los riesgos relacionados con el desarrollo del prototipo. Este procedimiento es un elemento fundamental de la planificación porque posibilita prever eventos que tienen el potencial de afectar la calidad del sistema, su continuidad operativa o la fiabilidad de los resultados experimentales. El manejo adecuado de estos riesgos tiene como objetivo preservar la estabilidad del equipo laboral, garantizar la disponibilidad e integridad de los datos y asegurar que se alcancen dentro del plazo y de manera apropiada las metas científicas e institucionales del proyecto.

Para comenzar con el análisis, se detectaron varios factores de riesgo en función de su tipo y se agrupan de acuerdo con su naturaleza, y cómo se relacionan con el ciclo de vida del proyecto:

- Económico: Eventos que afectan los costos del proyecto, como sobrecosto en infraestructura o recursos.
- Operativo: Situaciones que afectan la continuidad operativa o la ejecución diaria del proyecto.
- Temporal: Factores que pueden provocar retrasos debido a la complejidad de tareas, procesos lentos o dependencias entre componentes.
- Técnico: Riesgos relacionados con el funcionamiento del software, modelos de IA, datos, hardware o infraestructura tecnológica.
- Recursos: Limitaciones o falta de disponibilidad de hardware, software, personal o herramientas necesarias para avanzar.
- Organizacional: Fallas internas relacionadas con procesos administrativos, alineación de objetivos o estructura del equipo.
- Falta de claridad: Problemas derivados de comunicación deficiente, roles indefinidos o instrucciones ambiguas entre los integrantes del equipo.
- Externo: Factores fuera del control del equipo, como contingencias institucionales, sociales o fallas de servicios externos.
- Personal: Problemas interpersonales o de comunicación que afectan el flujo de trabajo y la comprensión de objetivos.

4.3.1 Criterios de Evaluación de Riesgos

Para establecer de forma rigurosa el nivel de exposición de los riesgos metodológicos y técnicos en el proyecto, se definieron criterios objetivos basados en los estándares internacionales ISO 31000 y la publicación especial NIST SP 800-30. La evaluación se fundamenta en dos variables fundamentales: la consecuencia del impacto (I) y la probabilidad de ocurrencia (P). En la Tabla 14 se detallan los cinco niveles de consecuencia del impacto y sus significados, variando desde un nivel insignificante hasta catastrófico.

Consecuencia	Significado	Valor
Catastrófico	Crítico, existen importantes errores, severos incumplimientos al Marco	E

Commented [IR3]: FAVOR DE REVISAR :
<https://asana.com/es/resources/project-risks>

	Regulatorio que tienen incidencia en el Blanco.	
Peligroso	Errores significativos continuos, existen incumplimientos a los puntos de control internos y disposiciones legales.	D
Moderado	Errores significativos ocasionales, existen incumplimientos a los puntos de control internos y disposiciones legales.	C
Menor	Errores operativos, existen incumplimientos en algunos puntos de control internos, pero no constituyen infracciones a la Ley.	B
Insignificante	Errores operativos, existen incumplimientos en algunos puntos de control interno que son subsanables inmediatamente.	A

Tabla 14: Matriz de Consecuencia (Impacto) [autoría propia]

De forma similar, en la Tabla 15 se establecen los rangos cualitativos y cuantitativos para evaluar la probabilidad de ocurrencia de un riesgo dentro del ciclo de vida del desarrollo en espiral, clasificándose en cinco niveles desde improbable hasta frecuente.

Ocurrencia	Significado	Valor
Frecuente	Con certeza de que se produzca.	5
Probable	Probable que se produzca.	4
Ocasional	Probable que se produzca a veces.	3
Posible	Puede producirse en algún momento.	2
Improbable	Es difícil de que suceda.	1

Tabla 15: Matriz de Probabilidad (Ocurrencia) [autoría propia]

Una vez definidos los valores de probabilidad e impacto, el nivel de exposición al riesgo (RE) se obtiene combinando ambas variables, donde P es el valor de probabilidad de ocurrencia (escala 1–5, Tabla 15) e I es el valor de consecuencia o impacto (escala A–E, Tabla 14). Dado que el impacto se expresa en una escala ordinal (A equivale al nivel 1 y E al nivel 5), la combinación no produce un valor numérico único, sino que se representa de forma matricial: cada par (P, I) se ubica en la Matriz de Probabilidad y Consecuencia (Tabla 16), cuya celda de intersección determina la severidad del riesgo mediante un código de color (semáforo), del verde (exposición mínima) al rojo oscuro (exposición máxima):

Probabilidad \ Consecuencia	Insignificante A	Menor B	Moderado C	Peligroso D	Catastrófico E
Frecuente 5	Amarillo	Naranja	Rojo	Rojo Oscuro	Rojo Oscuro
Probable 4	Verde	Amarillo	Naranja	Rojo	Rojo Oscuro
Ocasional 3	Verde	Amarillo	Amarillo	Naranja	Rojo
Posible 2	Verde Claro	Verde	Amarillo	Amarillo	Naranja
Improbable 1	Verde Claro	Verde Claro	Verde	Verde	Amarillo

Tabla 16: Matriz de Probabilidad y Consecuencia (Nivel de Exposición al Riesgo) [autoría propia]

4.3.2 Componentes de Riesgo

En concordancia con los principios de ingeniería de software de Barry Boehm, los riesgos identificados en el desarrollo del prototipo se agrupan en cuatro componentes esenciales. En la Tabla 17 se describen estos componentes y cómo afectan la entrega final del proyecto.

Componente de riesgo	Descripción
Riesgo de rendimiento	Incertidumbre sobre si el producto final cumplirá con los requisitos y si se ajustará al uso estimado.
Riesgo de costo	Incertidumbre sobre si el presupuesto del proyecto se mantendrá.
Riesgo de apoyo	Incertidumbre sobre si el software resultante será fácil de corregir, adaptar y mejorar.
Riesgo de calendario	Variabilidad en tiempos acordados sobre si se cumplirá el calendario del proyecto que podría afectar la entrega del proyecto en tiempo y forma.

Tabla 17: Componentes de Riesgo del Prototipo [autoría propia]

4.3.3 Clasificación e Identificación de Riesgos del Proyecto

A partir del marco de trabajo real y la infraestructura del laboratorio, el equipo identificó 9 riesgos principales que amenazan el desarrollo y la portabilidad del prototipo. Cada riesgo se categoriza según su componente, asignándole un nivel de probabilidad (1 a 5) y consecuencia (A a E) de acuerdo con los criterios anteriores. Los resultados de esta clasificación se presentan en la Tabla 18.

ID Riesgo	Descripción	Categoría de Riesgo	Probabilidad	Impacto	Semáforo
R01	Pérdida de código fuente o fallos en el control de versiones.	Riesgo de Apoyo	2	D	Amarillo
R02	Falta de portabilidad del software (incompatibilidad de drivers/dependencias).	Riesgo de Apoyo	3	D	Naranja
R03	Pérdida de datos experimentales (videos o resultados de análisis).	Riesgo de Apoyo	2	D	Amarillo
R04	Subestimación del tiempo de desarrollo en espiral.	Riesgo de Calendario	3	C	Amarillo
R05	Bajo rendimiento de YOLOv11-Pose (baja precisión en keypoints por oclusión).	Riesgo de Rendimiento	3	C	Amarillo
R06	Incompatibilidad de hardware (falta de GPU NVIDIA dedicada en laboratorios).	Riesgo de Apoyo	2	D	Amarillo
R07	Inconsistencia de datos en la clasificación de	Riesgo de Rendimiento	3	C	Amarillo

	conductas complejas (grooming).				
R08	Rechazo del prototipo por parte de los etólogos por complejidad de uso.	Riesgo de Rendimiento	2	C	Amarillo
R09	Sobrecosto de infraestructura física o consumibles de laboratorio.	Riesgo de Costo	1	C	Verde

Tabla 18: Tabla de Riesgos según su Impacto y Probabilidad (Matriz de Exposición) [autoría propia]

4.3.4 Estrategias de Mitigación y Contingencia

Con base en la clasificación obtenida, se definieron estrategias de mitigación proactivas orientadas a la prevención, minimización del impacto y planes de contingencia para asegurar la estabilidad operativa del Trabajo Terminal. La Tabla 19 detalla estas estrategias para cada uno de los riesgos identificados.

ID Riesgo	Descripción	Prevención	Minimización	Contingencia	Semáforo
R01	Pérdida de código fuente.	Uso obligatorio de Git con commits diarios y ramas de desarrollo organizadas.	Respallos diarios locales y almacenamiento redundante en la nube del IPN.	Restauración del código a partir del último commit estable en GitHub.	Amarillo
R02	Falta de portabilidad del software.	Creación de entornos virtuales Python (venv) y archivo de dependencias requirements.txt.	Pruebas de instalación automáticas en computadoras limpias del laboratorio.	Restauración del entorno Python mediante requirements.txt, guía de instalación y respaldo de configuración.	Naranja
R03	Pérdida de datos experimentales.	Diseño de la base de datos relacional (PostgreSQL) con rutas físicas relativas.	Verificar legibilidad de los videos locales y realizar respaldos de backups SQL.	Restauración de la base de datos local desde archivos de respaldo pg_dump.	Amarillo
R04	Subestimación del tiempo.	Planificación de metas mensuales dividiendo tareas en cada iteración del modelo espiral.	Reajustar el alcance del prototipo de forma temprana si se detectan desviaciones.	Reprogramación de tareas no críticas bajo la supervisión de los asesores.	Amarillo
R05	Bajo rendimiento de YOLOv11-Pose.	Entrenamiento con un dataset representativo y curado de 3,953 imágenes locales.	Uso del keypoint del torso (centroide) y filtro Savitzky-Golay (Anti-Jitter).	Habilitar la edición manual de tiempos y justificación obligatoria (behavior_edits).	Amarillo

R06	Incompatibilidad de hardware.	Optimización del código para ejecución en CPU/GPU y modelos ligeros (YOLO11s-pose).	Opción de pre-procesar videos de forma asíncrona o carga de análisis previos.	Ejecutar inferencia asíncrona en CPU optimizada mediante hilos de PyTorch.	Amarillo
R07	Inconsistencia en clasificación (grooming).	Curación del dataset, validación Leave-One-Out, uso de SimBA Random Forest y estrategia Conditional para Grooming.	Revisión etológica de videos críticos, ajuste de umbrales y documentación de casos ambiguos.	Auditoría y corrección manual trazable mediante behavior_edits cuando el modelo no capture una conducta compleja.	Amarillo
R08	Rechazo del prototipo.	Interfaz simplificada e intuitiva en Streamlit y exportación directa a Excel.	Capacitación interactiva y talleres guiados con el personal de etología.	Ajustar el diseño UI y manuales de usuario según la retroalimentación recibida.	Amarillo
R09	Sobrecosto de infraestructura.	Presupuesto detallado de costos fijos y variables con un margen de holgura.	Uso prioritario de software de código abierto y hardware preexistente.	Ajuste en la planificación de pruebas o reasignación de fondos variables.	Verde

Tabla 19: Tabla de Mitigación y Planes de Contingencia de Riesgos [autoría propia]

4.4 Análisis de factibilidad

4.4.1 Factibilidad tecnológica

La factibilidad tecnológica evalúa si el proyecto puede desarrollarse y mantenerse de manera sostenible utilizando la infraestructura técnica, el conocimiento especializado y los recursos computacionales disponibles. Su propósito fundamental es determinar si el stack tecnológico propuesto y el hardware disponible son suficientes para cumplir con los objetivos científicos del prototipo de forma eficiente y portable.

En el marco del modelo de desarrollo en espiral, este análisis se llevó a cabo de forma continua en cada iteración del sistema, permitiendo corroborar la viabilidad de la inferencia profunda de pose y ajustando los algoritmos según los recursos de procesamiento locales en los laboratorios de la ENMyH-IPN.

El análisis tecnológico se desglosa en los siguientes rubros clave:

4.4.1.1 Evaluación de recursos actuales y brechas tecnológicas

Se analizó la infraestructura computacional disponible frente a los exigentes requerimientos del entrenamiento de red neuronal profunda del modelo YOLO11s-pose. Inicialmente, se evaluó como metodología de pruebas el entrenamiento distribuido en la nube utilizando Google Colab; sin embargo, esta alternativa no resultó viable para el prototipo debido a restricciones en tiempos de sesión, latencia en la transferencia de datasets pesados de video y cuellos de botella en la conectividad a internet de banda ancha de los laboratorios. Para resolver esta brecha de manera sostenible y autónoma, se optó por la adquisición local de una laptop de alto rendimiento equipada con una GPU NVIDIA GeForce RTX 5070 Ti (12 GB VRAM) y 32 GB de RAM. Esta infraestructura de hardware posibilitó realizar tanto el entrenamiento del modelo sobre las 3,953 imágenes como la inferencia profunda de forma 100% local en un entorno de escritorio, logrando procesar los flujos de video a más de 30 FPS (tiempo real) y garantizando la plena viabilidad técnica de la solución sin dependencias de servicios externos.

4.4.1.2 Simulación, modelado y pruebas de convergencia

La viabilidad algorítmica del modelo de estimación de pose se corroboró experimentalmente mediante pruebas iterativas de entrenamiento en el entorno local y en la nube. Se entrenó y evaluó YOLO11s-pose, analizando curvas de pérdida y métricas de precisión de keypoints; el modelo final alcanzó $mAP50 = 0.995$ con 3,953 imágenes etiquetadas. Para el análisis conductual se validó SimBA Random Forest sobre features espaciotemporales derivadas de los keypoints, y se documentaron B-SOiD y LSTM como estrategias experimentales de apoyo para casos de Grooming difíciles.

4.4.1.3 Evaluación de compatibilidad e integración modular

El prototipo fue diseñado bajo una arquitectura de software modular e independiente, facilitando su integración con los sistemas operativos de escritorio estándar en los laboratorios (Windows 10/11). La persistencia de datos se resolvió mediante una base de datos relacional PostgreSQL local, la cual se comunica con la interfaz interactiva desarrollada en Streamlit. Esta interfaz permite cargar videos en formatos comunes como MP4 y AVI sin requerir preprocesamiento manual obligatorio, y exportar los resultados conductuales cuantitativos a archivos compatibles con Excel, lo que facilita su uso posterior en herramientas estadísticas como R, Origin o SPSS.

4.4.1.4 Capacidad técnica del equipo de desarrollo

El equipo de desarrollo está conformado por estudiantes de Ingeniería en Sistemas Computacionales de la ESCOM-IPN, cuya formación curricular aporta las competencias fundamentales requeridas para el proyecto: programación, estructuras de datos, ingeniería de software y fundamentos de aprendizaje automático. El lenguaje principal de desarrollo es Python, empleado tanto en el procesamiento de video como en la integración de los modelos. Las competencias específicas en visión por computadora y aprendizaje profundo se consolidaron durante el desarrollo mediante el estudio de la documentación oficial de las herramientas empleadas (Ultralytics, SimBA, PyTorch) y la iteración continua propia del modelo en espiral. La arquitectura modular del prototipo y la documentación técnica generada permiten que su operación y mantenimiento no dependan de conocimientos especializados más allá de los adquiridos, lo que hace viable su sostenimiento por el propio equipo o por personal con formación equivalente.

4.4.2 Factibilidad operativa

El objetivo de la factibilidad operativa es determinar si el sistema desarrollado cumple con los requerimientos prácticos y si será adoptado con éxito en el flujo de trabajo experimental de los etólogos y científicos del laboratorio. En este caso, el proyecto surge como una respuesta directa a una necesidad operativa real manifestada por el Dr. César Augusto Sandino Reyes López, investigador de posgrado de la Escuela Nacional de Medicina y Homeopatía (ENMyH-IPN), quien planteó la urgencia de estandarizar y automatizar el análisis conductual en el modelo experimental Elevated Plus Maze (EPM).

Para estructurar formalmente esta factibilidad, se aplicó una entrevista estructurada de ocho preguntas abiertas al Dr. Reyes López. El propósito del instrumento fue recopilar datos directos sobre la demanda del sistema, las variables conductuales críticas, los umbrales de precisión tolerables y las condiciones del ambiente físico del laboratorio. El instrumento completo y las respuestas obtenidas se detallan en la sección de anexos de este documento técnico.

Los resultados de la entrevista estructurada sirvieron como eje para refinar los requerimientos y optimizar la usabilidad del software. Los principales hallazgos y su resolución en el diseño del prototipo se detallan a continuación:

1. Objetividad y Estandarización: El principal problema operativo identificado en la práctica tradicional fue el sesgo observacional entre evaluadores independientes. El investigador determinó que un sistema operativo exitoso debe proveer una clasificación automatizada objetiva y consistente de las conductas. Para responder a esto, el prototipo automatiza la detección espacial mediante YOLO11s-pose, eliminando la discrepancia humana en la medición.

2. Facilidad en la Preparación de Datos: Se identificó la relevancia de que el personal no técnico pueda procesar videos brutos. De manera específica, se determinó la importancia de incluir un selector de punto de inicio y fin temporal directamente en la interfaz del prototipo, evitando la necesidad de preprocesar o cortar los videos con software externo de edición.

3. Métricas Clave del EPM: En el campo experimental, el tiempo acumulado de permanencia y el número de entradas a brazos abiertos y cerrados representan los indicadores fundamentales para identificar efectos ansiolíticos. El prototipo fue configurado para calcular automáticamente estas métricas a partir del rastreo del torso del roedor, complementándolas con mapas de calor espaciales y gráficos interactivos que muestran la distribución espacial del movimiento.

4. Precisión Tolerable: Se estableció como meta operativa que las mediciones espaciales del sistema mantuvieran alta concordancia con la revisión manual, especialmente en trayectoria y permanencia por zonas. Para las conductas complejas, como Grooming, la evaluación se realizó mediante métricas de clasificación como F1-Score y validación Leave-One-Out, reconociendo que su variabilidad conductual exige más datos etiquetados y modelos temporales complementarios.

5. Usabilidad sin Formación Técnica: La plataforma de despliegue interactiva se construyó sobre Streamlit, ofreciendo un entorno web simplificado de un solo clic que no requiere conocimientos informáticos avanzados. Asimismo, los resultados cuantitativos se estructuraron en un formato de descarga directa en Excel (.xlsx), facilitando la manipulación de datos y la re-graficación en herramientas estadísticas externas como R u Origin.

El despliegue operativo del prototipo se apoya directamente en la capacitación del personal del laboratorio y en el uso de la interfaz web adaptada. El modelo en esferas o espiral permitió integrar la retroalimentación del Dr. Reyes López de forma iterativa, asegurando una transición de bajo impacto operativo, una reducción del tiempo de análisis de horas a minutos (cercana al 85%), y un ahorro directo al evitar licencias comerciales costosas como ANY-maze o EthoVision XT.

4.4.3 Factibilidad económica

En concordancia con el modelo espiral de Boehm, la factibilidad económica del proyecto no se concibe como un cálculo estático de insumos, sino como un proceso dinámico e iterativo que evoluciona a lo largo del ciclo de desarrollo. En cada iteración de la espiral se evalúan los costos asociados a los recursos computacionales, de infraestructura y de personal técnico, con el propósito de mitigar riesgos financieros y garantizar el uso eficiente de los recursos institucionales. Para este Trabajo Terminal, la factibilidad económica incorpora la estimación formal del esfuerzo y costo de desarrollo de software, complementando el presupuesto de gastos fijos y variables con un análisis detallado de costo-beneficio institucional.

Los costos se dividen en dos categorías principales: **costos fijos** y **costos variables**, proyectados para un periodo de un año académico (48 semanas).

4.4.3.1 Estimación del esfuerzo de desarrollo mediante COCOMO II

Para cuantificar el esfuerzo y el tiempo requerido para el desarrollo del prototipo de software, se aplicó el modelo COCOMO II (Constructive Cost Model II) en su submodelo Post-arquitectura. Este modelo representa el estándar de la industria y la academia para la estimación de costos y tiempos en ingeniería de software. Cabe destacar la alta coherencia metodológica de su uso en este documento, dado que COCOMO II fue desarrollado por Barry Boehm, creador de la metodología de desarrollo en espiral bajo la cual se rige este proyecto.

El esfuerzo en COCOMO II se mide en Personas-Mes (PM), que equivale a las horas de trabajo mensual de un desarrollador de tiempo completo (160 horas). La ecuación fundamental del modelo es la siguiente:

$$PM = 2.94 \times S^E \times \prod EM_i$$

Donde S representa el tamaño del software en miles de líneas de código fuente (KSLOC), E es el exponente que determina las economías o diseconomías de escala, y EM_i son los 17 multiplicadores de esfuerzo que evalúan las condiciones específicas del entorno y el equipo. El exponente de escala E se calcula mediante la relación:

$$E = 0.91 + 0.01 \times \sum SF_j$$

Donde SF_j son los cinco factores de escala del proyecto: precedencia del sistema (PREC), flexibilidad de desarrollo (FLEX), resolución de arquitectura y riesgos (RESL), cohesión del equipo (TEAM) y madurez del proceso (PMAT).

4.4.3.2 Parámetros del modelo COCOMO II

Para la calibración de los parámetros de COCOMO II en este Trabajo Terminal, se evaluaron los factores de escala y los multiplicadores de esfuerzo de acuerdo con el entorno de desarrollo y la capacidad técnica del equipo de trabajo. Los valores asignados se presentan en la Tabla 20.

Parámetro	Descripción	Calificación	Valor
PREC	Precedencia del sistema	Bajo (sin desarrollo previo de etología)	3.72
FLEX	Flexibilidad de desarrollo	Nominal (metas base adaptables)	3.04
RESL	Resolución de riesgos	Muy Alto (metodología en espiral continua)	1.41
TEAM	Cohesión del equipo	Alto (objetivos académicos compartidos)	2.19
PMAT	Madurez del proceso	Bajo-Nominal (equipo pequeño estructurado)	4.14
Suma SF	Suma de Factores de Escala	-	14.50
Exponente E	Exponente calculado ($E = 0.91 + 0.01 * \text{Suma SF}$)	-	1.055
CPLX	Complejidad del producto	Alto (módulos de visión por computadora e IA)	1.17
PVOL	Volatilidad de la plataforma	Bajo (sistemas operativos estables)	0.87
PCAP	Capacidad de los programadores	Alto (estudiantes de informática e IA)	0.88
Otros EM	Otros multiplicadores del entorno	Nominal (sin afectación al esfuerzo base)	1.00
Producto EM	Producto de Multiplicadores de Esfuerzo ($\text{CPLX} * \text{PVOL} * \text{PCAP}$)	-	0.91

Tabla 20: Parámetros y multiplicadores de esfuerzo COCOMO II para el prototipo

4.4.3.3 Esfuerzo y costo de desarrollo para los escenarios de software

Con base en la calibración de parámetros y las mediciones de tamaño de software, se estimó el esfuerzo y costo de desarrollo. Se plantearon dos escenarios de análisis conductual: el Escenario Custom (que mide únicamente el código propietario escrito desde cero por el equipo, estimado en 10.0 KSLOC) y el Escenario Completo (que considera la integración de todas las dependencias y scripts auxiliares del repositorio, sumando 29.35 KSLOC). Los resultados se resumen en la Tabla 21.

Escenario	Tamaño (KSLOC)	Esfuerzo (PM)	Tiempo (Meses)	Desarrolladores (FTE)	Costo Proyectado (MXN)
Escenario Custom (Propietario)	10.00	30.3 PM	10.4 meses	2 desarrolladores (0.5 FTE c/u)	\$545,400.00 MXN
Escenario Completo (Total)	29.35	93.8 PM	14.9 meses	2 desarrolladores (tiempo parcial)	\$1,688,400.00 MXN

Tabla 21: Estimación del esfuerzo y costo de desarrollo para los escenarios de software

En el contexto académico de este Trabajo Terminal, el proyecto se desarrolló durante un año lectivo (10 meses) por dos estudiantes. Dado que ambos dedicaron tiempo parcial (aproximadamente 20 horas semanales por integrante), esto representa una capacidad de 0.5 FTE (Full-Time Equivalent) cada uno, sumando 1.0 FTE total. Esto equivale a 10 Personas-Mes de trabajo efectivo presencial. La estimación de COCOMO II de 30.3 PM para el Escenario Custom indica el esfuerzo que una organización comercial formal requeriría con ingenieros de tiempo completo para producir software con este nivel de robustez y complejidad, evidenciando el alto valor del trabajo aportado por los autores del proyecto. Para la valuación económica, se utilizó un salario mensual promedio de \$18,000.00 MXN para un desarrollador de software junior en México [111], de acuerdo con plataformas de empleo consultadas el 7 de junio de 2026.

4.4.3.4 Costos fijos de infraestructura

Incluyen los recursos que permanecen constantes durante todo el ciclo de desarrollo:

- **Equipo de cómputo local:** laptop de alto rendimiento equipada con GPU NVIDIA GeForce RTX 5070 Ti (12 GB VRAM) y 32 GB de RAM, con capacidad para entrenamiento e inferencia en local (\$60,000.00 MXN) [112].
- **Software y licencias:** uso de herramientas, sistemas operativos y librerías de código abierto (\$0.00 MXN).
- **Servicios básicos e infraestructura:** consumo eléctrico de la estación de trabajo, conectividad a internet de banda ancha y consumo de agua (\$3,500.00 MXN).
- **Costos de documentación e impresión:** generación de informes, anexos y documentación técnica — \$1,500 MXN.

Total, costos fijos aproximados: \$65,000 MXN.

4.4.3.5 Costos variables de infraestructura

Estos costos dependen del avance de cada iteración del modelo espiral:

- **Transporte local y alimentación:** viáticos acumulados para los traslados del equipo desarrollador entre la ESCOM y los laboratorios de la ENMyH-IPN para pruebas y recolección de video (\$5,000.00 MXN).
- **Material experimental:** mantenimiento y manejo de especímenes de laboratorio proporcionados por ENMyH — estimado \$2,000 MXN.
- **Material audiovisual:** cámaras y soporte para grabaciones, cables HDMI y almacenamiento externo — \$3,000 MXN.
- **Capacitación técnica:** cursos o talleres de IA/visión por computadora (~\$2,000 MXN).

Total, costos variables estimados: \$12,000 MXN.

Costo total proyectado del proyecto: $\approx$ \$77,000 MXN.

4.4.3.6 Costos consolidados y valoración económica total

Categoría	Concepto / Descripción	Monto (MXN)
Costos Fijos	Laptop de desarrollo local (GPU NVIDIA GeForce RTX 5070 Ti, 32 GB RAM).	\$60,000.00 MXN
Costos Fijos	Software y licencias de desarrollo (herramientas locales y código abierto).	\$0.00 MXN
Costos Fijos	Servicios básicos y operativos (electricidad, internet, agua y red local).	\$3,500.00 MXN
Costos Fijos	Material de documentación, papelería e impresiones técnicas.	\$1,500.00 MXN
Costos Variables	Viáticos de transporte local y alimentación para visitas de campo a la ENMyH.	\$5,000.00 MXN
Costos Variables	Mantenimiento de especímenes de laboratorio (ENMyH-IPN).	\$2,000.00 MXN
Costos Variables	Material audiovisual (cámara de alta resolución, soporte, almacenamiento).	\$3,000.00 MXN
Costos Variables	Capacitación y cursos técnicos en visión artificial e IA.	\$2,000.00 MXN
Total Proyectado	Suma de costos de infraestructura fijos y variables.	\$77,000.00 MXN

Tabla 22: Desglose de costos de infraestructura fijos y variables [autoría propia]

Para determinar la valoración económica consolidada del proyecto, se suman los costos físicos y de operación (fijos y variables) con el costo del esfuerzo de desarrollo de software estimado en el escenario propietario (Escenario Custom). Los resultados se resumen en la Tabla 23.

Concepto	Monto (MXN)	Porcentaje (%)
Costo de Desarrollo (Esfuerzo Humano - 30.3 PM)	\$545,400.00 MXN	87.6%
Costos Fijos de Infraestructura (Hardware y licencias)	\$65,000.00 MXN	10.4%
Costos Variables Operativos (Materiales y Viáticos)	\$12,000.00 MXN	1.9%
Valoración Económica Total del Proyecto	\$622,400.00 MXN	100.0%

Tabla 23: Resumen de costos consolidados y valoración económica total

4.4.3.7 Análisis costo-beneficio y retorno de inversión

El análisis costo-beneficio institucional evalúa la viabilidad del proyecto mediante la comparación de la valoración económica total de la solución desarrollada contra la adquisición de licencias comerciales equivalentes en el mercado. En los laboratorios de investigación neuroconductual de la ENMyH-IPN, las herramientas comerciales estándar utilizadas son ANY-maze y EthoVision XT. En la Tabla 24 se presenta un análisis comparativo de costos considerando el equipamiento de tres estaciones de experimentación.

Concepto	Prototipo de Trabajo Terminal	Alternativa ANY-maze	Alternativa EthoVision XT
Costo de Licencia de Software	Gratuito (código abierto, AGPL-3.0)	≈ \$139,717 MXN (USD \$7,995/estación) [113]	desde ≈ \$61,077 MXN (USD \$3,495/estación) [114]
Soporte y Mantenimiento Anual	Gratuito (Soporte local propio)	Incluido (licencia perpetua con actualizaciones)	Según cotización (módulos aparte)
Hardware y Accesorios Específicos	Estándar (PCs convencionales / USB)	Requerido (Hardware propietario)	Requerido (Hardware propietario)
Costo Total Inicial (3 estaciones)	\$77,000.00 MXN (infraestructura base)	≈ \$419,150 MXN (3 licencias perpetuas) + hardware	desde ≈ \$183,231 MXN (3 licencias base) + hardware
Escalabilidad de Estaciones	Ilimitada y sin costo adicional	Restringida por licencias adicionales	Restringida por licencias adicionales

Tabla 24: Análisis comparativo con software comercial (ANY-maze y EthoVision XT) para tres estaciones de prueba La conversión USD→MXN emplea el tipo de cambio Banxico FIX del 5 de junio de 2026 (\$17.4755 MXN/USD) [115].

Como se observa en el análisis comparativo, el costo de adquisición de licencias comerciales para tres estaciones de experimentación supera con creces el costo total del prototipo del Trabajo Terminal. Aunque la inversión económica inicial de personal se valúa en \$545,400.00 MXN, este esfuerzo se traduce en un activo tecnológico propio e institucional para el Instituto Politécnico Nacional, el cual elimina la dependencia tecnológica y los costos de licenciamiento recurrentes, permitiendo al laboratorio de la ENMyH-IPN expandir su capacidad de investigación de forma ilimitada y autónoma.

4.4.3.8 Conclusión de viabilidad económica

El proyecto es plenamente viable en términos económicos, ya que los beneficios derivados del ahorro de tiempo de análisis en el laboratorio (reducción del 85%), el incremento en la objetividad científica de los resultados y la optimización de los recursos existentes superan ampliamente los costos iniciales de implementación. La aplicación de metodologías iterativas basadas en el modelo espiral de Boehm posibilitó ajustar el presupuesto conforme avanzó el desarrollo del prototipo, mitigando desviaciones o sobrecostos de infraestructura de forma oportuna.

Para garantizar la sustentabilidad a largo plazo del prototipo una vez desplegado en las instalaciones de la ENMyH-IPN, se proyecta un costo de mantenimiento anual estimado para cubrir el soporte técnico tanto de hardware como de software. Este costo recurrente se basa en un salario por honorarios para soporte técnico equivalente al 10% de la compensación de un programador junior local (con un sueldo de referencia de \$18,000.00 MXN mensuales [111], es decir, \$21,600.00 MXN anuales de soporte) para actualizaciones menores de seguridad de dependencias (PyTorch, Streamlit) y auditorías preventivas en PostgreSQL. Sumando un fondo anual de mantenimiento físico de la estación de trabajo y consumibles de \$9,000.00 MXN, el costo de mantenimiento futuro asciende a \$30,600.00 MXN anuales. Esta inversión anual de mantenimiento es muy inferior al costo de una sola licencia comercial perpetua de ANY-maze (USD \$7,995, ≈ \$139,717 MXN por estación [113]) o de EthoVision XT (desde USD \$3,495 por estación [114]), consolidando la viabilidad económica y la sostenibilidad del prototipo institucional.

4.4.4 Factibilidad legal

El proyecto se desarrolla bajo un marco institucional que garantiza el pleno cumplimiento de las políticas éticas, normativas y legales aplicables al Instituto Politécnico Nacional (IPN), en coordinación con la Escuela Superior de Cómputo (ESCOM) y la Escuela Nacional de Medicina y Homeopatía (ENMyH-IPN).

4.4.4.1 Identificación del marco legal aplicable

1. Protección de Datos Personales en el Ámbito Público: Dado que el prototipo se implementa en un organismo descentralizado de la administración pública federal (el IPN), la confidencialidad de la información técnica y los accesos de usuario se rigen por la Ley General de Protección de Datos Personales en Posesión de Sujetos Obligados (LGPDPPSO) [108]. El prototipo no procesa ni almacena datos personales sensibles de individuos (únicamente credenciales académicas de investigadores y estudiantes de posgrado en el dominio @ipn.mx y @alumno.ipn.mx), asegurando la encriptación local de contraseñas y la bitácora de auditoría inmutable de acuerdo con los estándares de seguridad de la información del IPN.

2. Normativa de Bioética y Manejo de Especímenes: El diseño experimental y el uso del modelo de Elevated Plus Maze (EPM) se apegan rigurosamente a la Norma Oficial Mexicana NOM-062-ZOO-1999 [2], que establece las especificaciones técnicas para la producción, cuidado y uso de animales de laboratorio. De manera crucial, el uso de visión por computadora y estimación de pose markerless (sin marcadores físicos) contribuye directamente al principio bioético del Refinamiento dentro del marco internacional de las Tres Rs (Reemplazo, Reducción y Refinamiento) [15]. Al evitar la colocación de sensores invasivos o marcas físicas en la piel del roedor, se elimina el estrés inducido por el manejo invasivo, asegurando un comportamiento natural y apegado a las normas éticas del Comité de Bioética de la ENMyH-IPN.

3. Propiedad Intelectual y Derechos de Autor: El desarrollo del prototipo (código fuente de la interfaz Streamlit, integración YOLO-SimBA, módulos de seguimiento, persistencia y auditoría) es de autoría del equipo de Trabajo Terminal y se rige por la Ley Federal del Derecho de Autor (LFDA) [109] en México. El registro de propiedad industrial e intelectual se gestionará bajo las políticas internas y el reglamento de la Dirección de Transferencia Tecnológica del IPN, asegurando la copropiedad de la institución.

4. Compatibilidad de Licencias de Terceros: El prototipo integra librerías de terceros de código abierto, garantizando que el uso académico y no comercial cumple con las condiciones establecidas en sus respectivas licencias: OpenCV (Licencia Apache 2.0), PyTorch (Licencia BSD modificada de 3 cláusulas), Streamlit (Licencia Apache 2.0), PostgreSQL (Licencia PostgreSQL compatible con MIT/BSD), y Ultralytics YOLO (Licencia dual AGPLv3 para distribución abierta y comercial; el uso en este proyecto escolar y de investigación pública está amparado bajo la distribución científica abierta de la licencia AGPLv3) [110].

4.4.4.2 Conclusión de viabilidad legal

Tras la revisión de los marcos normativos aplicables en los ámbitos federal (LGPDPPSO [108] y LFDA [109]), sectorial (NOM-062-ZOO-1999 [2]) e internacional (principio de las Tres Rs [15] y

licencias de software libre), se verifica que el prototipo no atenta ni incumple ninguna ley o norma de carácter municipal, estatal, federal o mundial. Por lo tanto, el proyecto resulta legalmente viable para su implementación con fines académicos y de investigación en las instalaciones de la ENMyH-IPN.

No obstante, se identifica una restricción legal relevante ante una eventual explotación comercial del sistema. La biblioteca Ultralytics YOLO se distribuye bajo la licencia AGPL-3.0 [110], la cual no prohíbe el uso con fines de lucro, pero impone una obligación de tipo copyleft: cualquier distribución comercial o despliegue como servicio en red que mantenga el código fuente cerrado obligaría a liberar públicamente el código completo del trabajo derivado bajo la misma licencia AGPL-3.0, o bien a adquirir una licencia comercial Enterprise de Ultralytics. Dado que el alcance del presente Trabajo Terminal es estrictamente académico y de investigación pública, esta condición se cumple plenamente y no constituye un impedimento para su implementación institucional; sin embargo, se documenta como una consideración obligatoria ante una futura transferencia tecnológica o comercialización del prototipo.

4.5 Análisis de sostenibilidad

El análisis de sostenibilidad es un componente clave en el desarrollo de sistemas tecnológicos porque posibilita la detección y la mitigación de los efectos sociales, técnicos y ambientales que se producen durante todo el ciclo vital del software. Según las directrices establecidas en ISO 14064-1 y en las pautas muy usadas en ingeniería de software sostenible, un proyecto tiene que incluir una valoración del consumo de energía, las emisiones relacionadas, la disminución de los impactos operacionales y estrategias para disminuir el daño al medio ambiente [73], [74].

4.5.1 Evaluación del consumo energético del proyecto

Para estimar el consumo energético se emplea la relación estándar:

$$E = P \cdot t$$

donde P es la potencia promedio de la estación de trabajo local y t el tiempo de ejecución. De acuerdo con las especificaciones técnicas de la laptop de desarrollo de alto rendimiento utilizada, la GPU NVIDIA GeForce RTX 5070 Ti Laptop en conjunto con el procesador multinúcleo x86-64 registra un consumo típico promedio bajo carga de procesamiento continuo de inferencia y entrenamiento profundo de 140 W [75]. En consecuencia, se establece este valor ($P = 140 \text{ W}$) para el equipo físico empleado en las pruebas locales.

Tiempos reales de ejecución

Con la finalidad de analizar el rendimiento en un escenario real, se evaluó el tiempo de ejecución requerido para el procesamiento completo de inferencia de postura en la estación de cómputo local:

Procesamiento local acelerado: Gracias a la aceleración por hardware provista por la GPU NVIDIA dedicada, el prototipo realiza la estimación de postura del modelo YOLO11s-pose en tiempo real acelerado. Un video típico de pruebas con una duración de 5 minutos (equivalente a 9,000 fotogramas a 30 FPS en el laberinto EPM) se procesa en un tiempo aproximado de 3 minutos (180 segundos, equivalente a 0.05 horas).

A partir de este tiempo de ejecución, el consumo energético en la estación de cómputo local se calcula de la siguiente manera:

$$t_{local} = 3 \text{ min} = 0.05h$$

El consumo energético en la computadora local es entonces:

$$E_{local} = 140 \text{ W} \cdot 0.05 = 7 \text{ Wh}$$

4.5.2 Evaluación de huella de carbono (ISO 14064-1)

La huella de carbono se calcula conforme el modelo definido en ISO 14064-1, donde:

$$CO_2 = E \cdot FE$$

La International Energy Agency reportó y los estudios energéticos del IEEE citan que el factor de emisión eléctrica para México en 2025 será de 0.434 kg CO₂/kWh [77].

$$7 \text{ Wh} = 0.007 \text{ kWh}$$

$$CO_2 = 0.007 \cdot 0.434 = 0.00304 \text{ kg CO}_2$$

Esto equivale a aproximadamente 3.04 gramos de CO₂ por procesamiento completo de un video de 5 minutos.

Esta emisión es considerablemente más baja en comparación con la que está asociada al transporte físico de personal al laboratorio para hacer análisis manuales, el cual se desarrollará más adelante.

4.5.3 Impacto ambiental del proceso tradicional vs. el prototipo

El método tradicional de análisis requiere la presencia de:

- Al menos 1 laboratorista o investigador
- Al menos 3 asistentes encargados de la observación manual,
- En ocasiones un supervisor o validador adicional

Cada miembro debe desplazarse a las instalaciones educativas o de investigación, lo que produce un efecto ambiental vinculado con la movilidad urbana. Según cálculos que se han consolidado en inventarios urbanos y que se encuentran en investigaciones de transporte del IEEE [78], el índice de emisión promedio para coches en la Ciudad de México es 0.192 kg CO₂/km.

En el entorno particular de la Ciudad de México la distribución modal registrada en la Ciudad de México, aproximadamente el 50% de los desplazamientos urbanos son realizados en transporte público [85] mientras que el resto utilizan transporte privado. Por lo tanto, se estima que al menos la mitad de los miembros emplea transporte público para ir al laboratorio, mientras que el resto hace uso del transporte privado.

Para calcular el impacto ecológico del transporte público, se usa también un valor técnico de uso frecuente en evaluaciones urbanas, especialmente en investigaciones sobre la electrificación de flotas y la eficacia energética. Este establece que el consumo por vehículo-kilómetro para los autobuses estándar es de cerca de 0.6 kg CO₂, tomando como referencia el promedio de emisión del sistema

eléctrico mexicano [86]. Se debe dividir este valor entre la ocupación del vehículo para convertirlo a emisiones por pasajero-kilómetro, y se presentan diferentes escenarios lógicos que posibilitan calcular el rango posible de acuerdo con las condiciones auténticas del transporte urbano en hora pico o en operación normal.

Cálculo de emisiones del método tradicional (2 personas)

Distancia promedio diaria (ida + vuelta): 16 km
Factor de emisión: 0.192 kg CO₂/km

$$CO_{privper} = 16km \cdot 0.192 \frac{kg}{km} = 3.072kgCO_2$$

Para 2 personas:

$$CO_{privtotal} = 2 \cdot 3.072 = 6.144kgCO_2$$

Emisiones del transporte público (2 personas)

Se convierte el valor de 0.6 kg CO₂/veh-km a emisiones por pasajero-kilómetro considerando diferentes niveles de ocupación:

Escenario A (Ocupación alta en Metrobús BRT): $\approx 98.22\%$ de reducción.

Valores documentados de ocupación pico en corredores tipo BRT.

$$EF_{pas} = 0.6/35 = 0.00444 \text{ kg CO}_2 / \text{pas} \cdot \text{cdot} \text{pkm}$$

$$CO_{pubper} = 0.16km \cdot 0.00444 = 0.0711kgCO_2$$

Para 2 personas:

$$CO_{pubA} = 0.1422kgCO_2$$

Escenario B (Ocupación media urbana): $\approx 99.47\%$ de reducción.

Valor representativo típico de ocupación urbana consolidado en estudios comparativos.

$$EF_{pas} = \frac{0.6}{40} = 0.015$$

Para 2 personas:

$$CO_{pubB} = 0.048kgCO_2$$

Escenario C (Ocupación baja urbana): $\approx 99.74\%$ de reducción.

Escenario conservador de baja demanda.

$$EF_{pas} = 0.6/20 = 0.03 \text{ kg CO}_2 / \text{pas} \cdot \text{cdot} \text{pkm}$$

$$CO_{pubper} = 16km \cdot 0.03 = 0.48kgCO_2$$

Para 2 personas:

Escenario A (Ocupación alta en Metrobús BRT): $\approx 98.22\%$ de reducción.

$$CO_{totalA} = 6.144 + 0.1422 = 6.2862 kgCO_2$$

Escenario B (Ocupación media urbana): $\approx 99.47\%$ de reducción.

$$CO_{totalB} = 6.144 + 0.48 = 6.624 kgCO_2$$

Escenario C (Ocupación baja urbana): $\approx 99.74\%$ de reducción.

$$CO_{totalC} = 6.144 + 0.96 = 7.104 kgCO_2$$

4.5.4 Comparación con el prototipo

Como se estableció previamente, el prototipo genera aproximadamente 0.00304 kg de CO₂ por cada procesamiento de video de 5 minutos.

$$CO_{prototipo} = 0.00304 kgCO_2 \text{ por análisis completo}$$

Comparación porcentual de reducción de emisiones en los distintos escenarios de transporte frente al prototipo:

Escenario A (Ocupación alta en Metrobús BRT): $\approx 98.22\%$ de reducción.

Escenario B (Ocupación media urbana): $\approx 99.47\%$ de reducción.

Escenario C (Ocupación baja urbana): $\approx 99.74\%$ de reducción.

Aun al tomar en cuenta escenarios conservadores para el transporte público y aplicar la realidad de que más de la mitad del equipo emplea este modo de transporte, el efecto medioambiental del método tradicional de análisis manual continúa siendo mayor por los traslados obligatorios del personal; en cambio, el prototipo local optimizado genera aproximadamente 0.00304 kg de CO₂ (3.04 g) por procesamiento completo.

La disminución resultante varía de acuerdo con el escenario de transporte considerado, pero mantiene una reducción alta frente al traslado obligatorio del equipo de investigación. Esto indica que el prototipo local reduce de forma significativa la huella de carbono asociada a la movilidad física y consolida una alternativa más eficiente y sostenible para el análisis conductual.

Capítulo 5. Diseño

5.1 Arquitectura del prototipo

La arquitectura del prototipo se organiza en tres capas —presentación, lógica de negocio y datos— que estructuran los procesos centrales del sistema, basado en visión por computadora y aprendizaje automático para la evaluación de tratamientos farmacológicos en modelos de ansiedad. En la Ilustración 38 se presenta esta arquitectura de forma general.

La **capa de presentación** está conformada por las páginas interactivas desarrolladas en Streamlit, que permiten al usuario autenticarse, ingestar el video, configurar las zonas de interés, ejecutar el análisis y consultar los resultados y las comparaciones.

La **capa de lógica de negocio** implementa el flujo de procesamiento conductual en seis etapas: ingesta y preprocesamiento del video (Python, OpenCV y FFmpeg), estimación de pose con YOLO Pose v4 (8 keypoints), puente de conversión de YOLO a SimBA, extracción de 242 características, clasificación de la conducta mediante los modelos Random Forest (Grooming y Thigmotaxis) con la capa de rescate temporal LSTM, y el renderizado multimodal que genera el video anotado, la trayectoria y los timelogs.

La **capa de datos** persiste la información en una base de datos relacional PostgreSQL (gestionada con SQLAlchemy) —usuarios, tratamientos, experimentos, configuraciones de ROI, resultados de análisis y la bitácora de auditoría— y en un conjunto de artefactos locales (videos, keypoints, proyectos de SimBA, modelos y reportes). Los resultados almacenados permiten la comparación entre grupos experimentales mediante pruebas estadísticas como la prueba t de Student o el análisis de varianza (ANOVA).




Ilustración 38: Arquitectura de tres capas del prototipo [autoría propia]

5.2 Casos de uso

5.2.1 Casos de uso del prototipo

El diagrama de casos de uso representa el funcionamiento general del prototipo y la interacción de sus actores con las funcionalidades del sistema. Se identifican tres actores humanos —Estudiante, Investigador y Administrador— y un actor externo, el Servicio de correo (OTP), encargado de la verificación de cuentas. El Motor de Análisis IA (YOLO, Random Forest y LSTM) y la base de datos PostgreSQL no se modelan como actores, ya que constituyen componentes internos del sistema.

Los tres roles se representan mediante una relación de generalización a partir de un actor base Usuario, del cual heredan las funciones comunes: registrarse, verificar la cuenta (OTP), iniciar sesión, recuperar la contraseña y gestionar el perfil, así como el flujo completo de análisis conductual —ingestar el video y registrar el experimento, extraer los keypoints, configurar las zonas de interés (ROI) y ejecutar el análisis— y la consulta de resultados, la comparación entre grupos y la descarga de reportes.

Las diferencias entre roles se concentran en la edición y la administración. El Investigador, además de las funciones comunes, puede editar los tiempos conductuales de sus propios experimentos. El Administrador puede editar y revertir los tiempos de todos los experimentos, además de gestionar usuarios y experimentos. El Estudiante se limita a las funciones comunes, sin capacidad de edición ni de administración.

El diagrama incorpora relaciones de inclusión y extensión: el registro y la recuperación de contraseña incluyen la verificación mediante OTP, que se comunica con el servicio de correo; la ejecución del análisis incluye al Motor de IA; la edición de tiempos incluye el registro de auditoría (behavior_edits)

y extiende la consulta de resultados; la reversión extiende la edición; y la comparación de grupos incluye la descarga del reporte en Excel.




Ilustración 41: Diagrama de casos de uso del prototipo [autoría propia]

5.2.2 Especificación de casos de uso

Las especificaciones de casos de uso proporcionan una descripción narrativa y detallada de cómo los diferentes actores interactúan con el prototipo de software para lograr un objetivo específico. Cada especificación describe las precondiciones, postcondiciones, entradas, salidas, mensajes del sistema y los flujos o trayectorias (tanto principal como alternativos) que sigue el sistema. A continuación se presentan las especificaciones detalladas de los dos casos de uso críticos para la operación y seguridad del sistema: el inicio de sesión y el procesamiento de análisis conductual mediante visión artificial.

Especificación de Caso de Uso: CU1 - Registrar usuario

Elemento	Descripción
Caso de Uso	CU1: Registrar usuario
Versión	1.0
Autor(es)	Equipo Trabajo Terminal IPN-ESCOM
Revisiones	Maestra Gabriela de Jesús López Ruiz (Asesora de la materia)
Estatus	En proceso
Fecha de última revisión	06/06/2026
Actor(es)	Estudiante, Investigador
Propósito	Permitir que un nuevo usuario cree una cuenta institucional en el prototipo, validando que su correo pertenezca al dominio del IPN y enviando un código de verificación (OTP) para activar la cuenta.
Entradas	Tipo de perfil (estudiante o investigador), correo institucional (@alumno.ipn.mx o @ipn.mx), contraseña, nombre completo, datos de perfil (boleta, carrera y escuela para estudiante; número de empleado, área y centro para investigador), aceptación de términos y oprimir 'Registrarse'.
Salidas	Creación del registro en la tabla users con is_verified = FALSE y envío del código OTP al correo institucional; redirección a la pantalla de verificación.
Precondiciones	El correo no debe estar previamente registrado y debe pertenecer al dominio institucional del IPN.
Postcondiciones	Se almacena la cuenta pendiente de verificación junto con el código OTP y su marca de tiempo (verification_code_created_at).
Mensajes	mns1: 'Código de verificación enviado a tu correo IPN.' mns2: 'El usuario ya existe.' mns3: 'Debes usar un correo institucional (@ipn.mx o @alumno.ipn.mx).' mns4: 'La contraseña no cumple los requisitos de seguridad.'
Confirmaciones	Aceptar los Términos y Condiciones.
Tipo	Primario / Acceso de seguridad
Fuente	RF1, RN1, RN2
Trayectoria Principal	1. El usuario selecciona el tipo de perfil (estudiante o investigador). 2. El usuario ingresa su correo institucional, contraseña y datos de perfil. 3. El usuario acepta los Términos y Condiciones y oprime 'Registrarse'. 4. El sistema valida el formato y el dominio del correo, así como la fortaleza de la contraseña. 5. El sistema verifica que el correo no exista en la tabla users.

	6. El sistema cifra la contraseña con bcrypt, inserta el registro con is_verified = FALSE y genera un código OTP de 6 dígitos. 7. El sistema envía el código OTP al correo institucional y redirige a la pantalla de verificación.
Trayectoria Alternativa A (Correo ya registrado)	1-5. Mismo flujo de la trayectoria principal. 6. El sistema detecta que el correo ya existe en la tabla users, no crea la cuenta y muestra el mensaje mns2.
Trayectoria Alternativa B (Dominio o contraseña inválidos)	1-3. Mismo flujo de la trayectoria principal. 4. El sistema detecta un dominio no institucional o una contraseña que no cumple los requisitos, registra el intento fallido y muestra mns3 o mns4 según corresponda.

Especificación de Caso de Uso: CU2 - Iniciar sesión

Elemento	Descripción
Caso de Uso	CU2: Iniciar sesión
Versión	1.0
Autor(es)	Equipo Trabajo Terminal IPN-ESCOM
Revisiones	Maestra Gabriela de Jesús López Ruiz (Asesora de la materia)
Estatus	En proceso
Fecha de última revisión	06/06/2026
Actor(es)	Administrador, Investigador, Estudiante
Propósito	Permitir que el usuario ingrese a la aplicación Streamlit autenticándose de forma segura si su cuenta está activa en la base de datos (tabla users).
Entradas	Correo institucional (username), contraseña y oprimir botón 'Iniciar Sesión'.
Salidas	Redirección a la vista de inicio del sistema y despliegue del menú de usuario según el rol correspondiente.
Precondiciones	El usuario debe estar previamente registrado y su cuenta debe estar activa (is_active = TRUE).
Postcondiciones	Se inicia una sesión activa en la aplicación con persistencia de credenciales y se genera una entrada en la bitácora de auditoría.
Mensajes	mns1: 'Inicio de sesión con éxito.' mns2: 'El usuario no existe o se encuentra inactivo.' mns3: 'Existe usuario, pero la contraseña es incorrecta.'
Confirmaciones	Ninguna.
Tipo	Primario / Acceso de seguridad
Fuente	RF2, RN3
Trayectoria Principal	1. El usuario ingresa su correo institucional. 2. El usuario escribe su contraseña. 3. El usuario oprime el botón 'Iniciar Sesión'. 4. La aplicación realiza una consulta en la tabla users para verificar si el correo existe y está activo. 5. El sistema compara el hash de la contraseña usando la biblioteca bcrypt. 6. Si las credenciales coinciden, el sistema genera un token de sesión, registra el evento exitoso en security_audit_log y redirige al usuario a la pantalla principal.
Trayectoria Alternativa A (Usuario no existe o inactivo)	1-3. Mismo flujo de la trayectoria principal. 4. La aplicación consulta la base de datos y determina que el usuario no existe o is_active = FALSE. 5. El sistema registra el intento fallido en

	security_audit_log y muestra el mensaje mns2: 'El usuario no existe o se encuentra inactivo.'
Trayectoria Alternativa B (Contraseña incorrecta)	1-3. Mismo flujo de la trayectoria principal. 4. El usuario existe y está activo. 5. El sistema compara el hash de la contraseña y detecta incompatibilidad. 6. El sistema incrementa el contador de intentos fallidos, registra la falla en security_audit_log y muestra el mensaje mns3: 'Existe usuario, pero la contraseña es incorrecta.' Si se alcanzan 5 fallas, bloquea la cuenta (RN3).

Especificación de Caso de Uso: CU3 - Gestionar tratamientos

Elemento	Descripción
Caso de Uso	CU3: Gestionar tratamientos
Versión	1.0
Autor(es)	Equipo Trabajo Terminal IPN-ESCOM
Revisiones	Dr. César Augusto Sandino Reyes López (ENMyH-IPN)
Estatus	En proceso
Fecha de última revisión	06/06/2026
Actor(es)	Administrador, Investigador, Estudiante
Propósito	Permitir registrar, consultar y eliminar los tratamientos experimentales (fármacos y dosis) que se asignan a los experimentos del modelo EPM.
Entradas	Nombre del tratamiento y descripción opcional (para alta); selección del tratamiento (para eliminación).
Salidas	Actualización del catálogo de tratamientos en la tabla treatments.
Precondiciones	El usuario debe tener una sesión activa. La tabla treatments se inicializa con tratamientos por defecto (Control, Diazepam 5 mg, Diazepam 10 mg, Cafeína 50 mg, Estrés por restricción).
Postcondiciones	El tratamiento queda registrado, o bien eliminado o desactivado según si está en uso por algún experimento.
Mensajes	mns1: 'Tratamiento añadido exitosamente.' mns2: 'Este tratamiento ya existe.' mns3: 'Tratamiento eliminado exitosamente.' mns4: 'Tratamiento desactivado (en uso en N experimento(s)).'
Confirmaciones	Confirmar la eliminación de un tratamiento.
Tipo	Secundario / Gestión de catálogo
Fuente	RF3, RN4
Trayectoria Principal	1. El usuario accede a la gestión de tratamientos dentro del módulo de ingesta. 2. El sistema muestra el catálogo de tratamientos activos. 3. El usuario captura el nombre y la descripción de un nuevo tratamiento y oprime 'Añadir tratamiento'. 4. El sistema verifica que el nombre no exista e inserta el registro en la tabla treatments (mns1).
Trayectoria Alternativa A (Tratamiento duplicado)	1-3. Mismo flujo de la trayectoria principal. 4. El sistema detecta que el nombre ya existe y muestra mns2 sin crear el registro.
Trayectoria Alternativa B (Eliminación de tratamiento en uso)	1-2. Mismo flujo de la trayectoria principal. 3. El usuario selecciona un tratamiento y oprime 'Eliminar'. 4. Si el tratamiento está asociado a uno o más experimentos, el sistema lo desactiva (is_active =

	FALSE) en lugar de borrarlo (mns4); en caso contrario, lo elimina (mns3).
--	---

Especificación de Caso de Uso: CU4 - Registrar experimento

Elemento	Descripción
Caso de Uso	CU4: Registrar experimento
Versión	1.0
Autor(es)	Equipo Trabajo Terminal IPN-ESCOM
Revisiones	Dr. César Augusto Sandino Reyes López (ENMyH-IPN)
Estatus	En proceso
Fecha de última revisión	06/06/2026
Actor(es)	Administrador, Investigador, Estudiante
Propósito	Registrar un nuevo experimento asociando el identificador del roedor, el tratamiento aplicado, la fecha y el video experimental que será analizado.
Entradas	Identificador del roedor (rat_id), tratamiento seleccionado del catálogo, fecha del experimento, responsable y archivo de video (MP4/AVI) cargado mediante el módulo de ingesta.
Salidas	Registro del experimento en la tabla experiments y almacenamiento del video con un nombre normalizado ({rat_id}_{tratamiento}).
Precondiciones	El usuario debe tener una sesión activa y debe existir al menos un tratamiento en el catálogo.
Postcondiciones	El experimento queda registrado con su metadata y el video disponible para los siguientes módulos del flujo de análisis.
Mensajes	mns1: 'Experimento registrado y video preparado correctamente.' mns2: 'Debes seleccionar un archivo de video.' mns3: 'El identificador del roedor es obligatorio.'
Confirmaciones	Confirmar el registro del experimento.
Tipo	Primario / Núcleo operativo
Fuente	RF4, RN5
Trayectoria Principal	1. El usuario ingresa el identificador del roedor. 2. El usuario selecciona el tratamiento del catálogo (o añade uno nuevo). 3. El usuario indica la fecha del experimento y el responsable. 4. El usuario carga el archivo de video experimental. 5. El usuario oprime 'Registrar'. 6. El sistema valida los datos, normaliza el nombre del archivo, almacena el video y registra el experimento en la tabla experiments (mns1).
Trayectoria Alternativa A (Sin video)	1-4. El usuario no carga ningún archivo de video. 5. Al registrar, el sistema detecta la ausencia del video y muestra mns2 sin registrar el experimento.
Trayectoria Alternativa B (Datos incompletos)	1. El usuario deja vacío el identificador del roedor. 5. El sistema detecta el campo obligatorio faltante y muestra mns3 sin registrar el experimento.

Especificación de Caso de Uso: CU5 - Configurar ROIs

Elemento	Descripción
Caso de Uso	CU5: Configurar ROIs
Versión	1.0
Autor(es)	Equipo Trabajo Terminal IPN-ESCOM

Revisiones	Dr. César Augusto Sandino Reyes López (ENMyH-IPN)
Estatus	En proceso
Fecha de última revisión	06/06/2026
Actor(es)	Administrador, Investigador, Estudiante
Propósito	Definir las regiones de interés (ROIs) sobre el laberinto EPM —brazos abiertos, brazos cerrados, centro y las seis paredes— que delimitan las zonas usadas en el análisis conductual y se sincronizan con SimBA.
Entradas	Trazado de las zonas sobre un fotograma del video, indicando el tipo de cada zona (Brazo Abierto, Brazo Cerrado, Centro o Muro/Pared).
Salidas	Configuración de zonas guardada en la tabla roi_configurations y en el archivo zonas_activas.json, con las coordenadas escaladas a la resolución original del video.
Precondiciones	Debe existir un experimento con video activo, registrado en el módulo de ingesta.
Postcondiciones	Las zonas quedan persistidas y las seis paredes se importan a SimBA para la extracción de características.
Mensajes	mns1: 'Se guardaron N zonas en la base de datos para el experimento.' mns2: 'Se importaron correctamente las 6 zonas de paredes a SimBA.' mns3: 'No se encontró un video activo para asociar las zonas.'
Confirmaciones	Confirmar el guardado de las zonas.
Tipo	Primario / Núcleo operativo
Fuente	RF5, RN6
Trayectoria Principal	1. El sistema carga un fotograma representativo del video del experimento activo. 2. El usuario selecciona el tipo de zona y traza la región correspondiente sobre el laberinto. 3. El usuario repite el trazado para los brazos abiertos, cerrados, el centro y las seis paredes. 4. El usuario oprime 'Guardar zonas'. 5. El sistema escala las coordenadas a la resolución original, persiste las zonas en roi_configurations y en zonas_activas.json (mns1) e importa las seis paredes a SimBA (mns2).
Trayectoria Alternativa A (Sin video activo)	1. El sistema no encuentra un video activo o analizado. 2. El sistema muestra mns3 y solicita registrar o seleccionar un experimento.
Trayectoria Alternativa B (Sin conexión a base de datos)	4-5. Al guardar, el sistema no encuentra conexión a PostgreSQL. 6. El sistema conserva las zonas en zonas_activas.json y notifica que no fue posible persistirlas en la base de datos.

Especificación de Caso de Uso: CU6 - Ejecutar análisis de video

Elemento	Descripción
Caso de Uso	CU6: Ejecutar análisis de video
Versión	1.0
Autor(es)	Equipo Trabajo Terminal IPN-ESCOM
Revisiones	Dr. César Augusto Sandino Reyes López (ENMyH-IPN)
Estatus	En proceso
Fecha de última revisión	06/06/2026
Actor(es)	Administrador, Investigador, Estudiante
Propósito	Procesar el video experimental mediante el modelo YOLO-Pose para detectar los keypoints corporales y

	extraer la trayectoria del espécimen, calculando distancias y tiempos de permanencia en zonas del laberinto (EPM).
Entradas	Selección de experimento registrado, selección de video original, configuración de ROIs y oprimir botón 'Iniciar Análisis'.
Salidas	Tabla de resultados conductuales guardada en base de datos (analysis_results), trazo de trayectoria dinámica y heatmaps.
Precondiciones	El experimento debe estar registrado (experiments), el video debe ser legible (RN5) y las coordenadas del ROI guardadas (roi_configurations).
Postcondiciones	Se actualiza el estado del experimento a 'processed = TRUE' y se habilitan los datos para la minería y exportación.
Mensajes	mns1: 'Procesamiento de video completado con éxito.' mns2: 'Error: Archivo de video no encontrado o dañado.' mns3: 'Error: La configuración de ROI no es válida para este video.'
Confirmaciones	Confirmar inicio del análisis conductual (el procesamiento puede demorar varios minutos).
Tipo	Primario / Núcleo operativo
Fuente	RF5, RF6, RN6, RN7
Trayectoria Principal	1. El usuario selecciona el experimento registrado. 2. El sistema carga las coordenadas del ROI asociadas en la base de datos. 3. El usuario presiona 'Iniciar Análisis'. 4. El sistema lee el video cuadro a cuadro, aplicando YOLO-Pose para detectar los keypoints del ratón y calcular su centroide directamente a partir de la coordenada del torso. 5. El sistema calcula las distancias acumuladas y determina el brazo del laberinto (abierto, cerrado, centro) donde se ubica el centroide. 6. Al finalizar el video, el sistema guarda los segundos acumulados en analysis_results y muestra en pantalla la trayectoria y mapas de calor.
Trayectoria Alternativa A (Archivo no encontrado)	1-2. Mismo flujo. 3. El sistema intenta abrir la ruta de video y detecta que el archivo no existe o el codec es incompatible. 4. El sistema muestra el mensaje mns2: 'Error: Archivo de video no encontrado o dañado' y detiene el análisis.
Trayectoria Alternativa B (ROI no configurado)	1. El usuario selecciona el experimento. 2. El sistema busca en la tabla roi_configurations y detecta que no existen coordenadas asociadas. 3. El sistema inhabilita el botón de inicio de análisis y despliega el mensaje mns3: 'Error: La configuración de ROI no es válida para este video.'

Especificación de Caso de Uso: CU7 - Agrupar comportamientos

Elemento	Descripción
Caso de Uso	CU7: Agrupar comportamientos
Versión	1.0
Autor(es)	Equipo Trabajo Terminal IPN-ESCOM
Revisiones	Dr. César Augusto Sandino Reyes López (ENMyH-IPN)
Estatus	En proceso
Fecha de última revisión	06/06/2026
Actor(es)	Administrador, Investigador, Estudiante
Propósito	Clasificar y agrupar automáticamente los comportamientos del roedor (Grooming y Thigmotaxis) a

	partir de las características extraídas, mediante los modelos Random Forest y la capa de rescate temporal LSTM, para generar los tiempos conductuales agregados.
Entradas	Características por frame extraídas del video, modelos entrenados (Random Forest de Grooming y de Thigmotaxis, LSTM de rescate) y umbrales operativos.
Salidas	Etiquetas de conducta por frame, tiempos acumulados por conducta y registro de los resultados en la tabla analysis_results.
Precondiciones	El video debe haber sido procesado y sus características extraídas (CU6).
Postcondiciones	Los comportamientos quedan clasificados y agregados, disponibles para su consulta y edición.
Mensajes	mns1: 'Clasificación de comportamientos completada.' mns2: 'No se encontraron características para clasificar.'
Confirmaciones	Ninguna (proceso automático).
Tipo	Primario / Núcleo operativo
Fuente	RF7
Trayectoria Principal	1. El sistema toma las características extraídas del video procesado. 2. El sistema aplica los modelos Random Forest de Grooming y de Thigmotaxis para obtener la probabilidad de cada conducta por frame. 3. El sistema aplica la capa de rescate temporal LSTM cuando el Random Forest queda entre los umbrales de decisión. 4. El sistema suaviza las predicciones (media móvil) y aplica los umbrales operativos para confirmar los eventos. 5. El sistema agrupa los frames en eventos conductuales, calcula los tiempos acumulados y los registra en analysis_results (mns1).
Trayectoria Alternativa A (Sin características)	1. El sistema no encuentra el archivo de características del video. 2. El sistema muestra mns2 y detiene la clasificación.
Trayectoria Alternativa B (Conducta ausente)	1-4. Mismo flujo de la trayectoria principal. 5. Si una conducta no supera el umbral en ningún frame, el sistema registra un tiempo acumulado de cero para esa conducta.

Especificación de Caso de Uso: CU8 - Editar tiempos conductuales

Elemento	Descripción
Caso de Uso	CU8: Editar tiempos conductuales
Versión	1.0
Autor(es)	Equipo Trabajo Terminal IPN-ESCOM
Revisiones	Dr. César Augusto Sandino Reyes López (ENMyH-IPN)
Estatus	En proceso
Fecha de última revisión	06/06/2026
Actor(es)	Administrador, Investigador
Propósito	Permitir la corrección manual de los tiempos conductuales calculados automáticamente, registrando cada cambio en una bitácora de auditoría con su justificación.
Entradas	Selección del experimento, nuevos valores de tiempo conductual y un motivo obligatorio de la edición.
Salidas	Actualización de los tiempos en analysis_results y registro de un snapshot before/after en la tabla behavior_edits.

Precondiciones	El experimento debe estar analizado. El Administrador puede editar cualquier experimento; el Investigador, solo los propios; el Estudiante únicamente consulta el historial.
Postcondiciones	Los tiempos quedan corregidos y la edición registrada en el historial de auditoría con autor, rol, fecha y motivo.
Mensajes	mns1: 'Tiempos actualizados y registrados en historial.' mns2: 'Escribe un motivo para poder guardar.' mns3: 'No tienes permiso para editar este experimento.'
Confirmaciones	Escribir un motivo obligatorio para confirmar el guardado.
Tipo	Primario / Corrección con auditoría
Fuente	RF8, RN8
Trayectoria Principal	1. El usuario abre el panel de detalle de un experimento analizado. 2. El usuario activa el modo de edición. 3. El usuario modifica los tiempos conductuales y escribe el motivo del cambio. 4. El usuario guarda los cambios. 5. El sistema valida el permiso y el motivo, actualiza analysis_results y registra un snapshot before/after en behavior_edits (mns1).
Trayectoria Alternativa A (Sin motivo)	1-3. El usuario no escribe un motivo de la edición. 4. Al guardar, el sistema muestra mns2 y no aplica el cambio.
Trayectoria Alternativa B (Sin permiso)	1. Un Investigador intenta editar un experimento que no le pertenece. 2. El sistema deshabilita la edición y muestra mns3.

Especificación de Caso de Uso: CU9 - Exportar resultados

Elemento	Descripción
Caso de Uso	CU9: Exportar resultados
Versión	1.0
Autor(es)	Equipo Trabajo Terminal IPN-ESCOM
Revisiones	Dr. César Augusto Sandino Reyes López (ENMyH-IPN)
Estatus	En proceso
Fecha de última revisión	06/06/2026
Actor(es)	Administrador, Investigador, Estudiante
Propósito	Permitir la descarga de los resultados conductuales del análisis en formatos compatibles para su uso en herramientas estadísticas externas.
Entradas	Selección del experimento o grupo de experimentos y del formato de exportación (Excel o PDF).
Salidas	Archivo descargable con las métricas conductuales (tiempos por zona y por conducta, número de entradas, etc.) en formato .xlsx o PDF.
Precondiciones	El experimento debe contar con resultados de análisis en la tabla analysis_results.
Postcondiciones	El archivo de resultados se genera y se descarga en el equipo del usuario.
Mensajes	mns1: 'Reporte generado correctamente.' mns2: 'No hay resultados disponibles para exportar.'
Confirmaciones	Ninguna.
Tipo	Secundario / Salida de datos
Fuente	RF9
Trayectoria Principal	1. El usuario consulta los resultados de un experimento o una comparación de grupos.

	2. El usuario selecciona el formato de exportación (Excel o PDF). 3. El usuario oprime 'Descargar'. 4. El sistema recopila las métricas desde analysis_results y genera el archivo (mns1). 5. El sistema entrega el archivo para su descarga.
Trayectoria Alternativa A (Sin resultados)	1. El usuario selecciona un experimento sin análisis. 2-3. Al intentar exportar, el sistema muestra mns2.
Trayectoria Alternativa B (Comparación de grupos)	1. El usuario selecciona varios experimentos para comparar. 4. El sistema agrega las métricas de todos los experimentos seleccionados en un solo archivo de Excel.

Especificación de Caso de Uso: CU10 - Consultar bitácora de auditoría

Elemento	Descripción
Caso de Uso	CU10: Consultar bitácora de auditoría
Versión	1.0
Autor(es)	Equipo Trabajo Terminal IPN-ESCOM
Revisiones	Dr. César Augusto Sandino Reyes López (ENMyH-IPN)
Estatus	En proceso
Fecha de última revisión	06/06/2026
Actor(es)	Administrador, Investigador, Estudiante
Propósito	Permitir la consulta del registro auditado de las acciones del sistema —eventos de seguridad y el historial de ediciones manuales de tiempos conductuales— para garantizar la trazabilidad.
Entradas	Selección del experimento (para el historial de ediciones) o acceso al panel de auditoría (para la bitácora de seguridad, exclusivo del Administrador).
Salidas	Despliegue cronológico de los eventos registrados, con autor, rol, fecha y detalle.
Precondiciones	El usuario debe tener una sesión activa; la bitácora de seguridad solo es accesible para el Administrador.
Postcondiciones	Se muestra el historial sin alterar los registros, ya que la bitácora es inmutable.
Mensajes	mns1: 'No existen registros de auditoría para este elemento.'
Confirmaciones	Ninguna.
Tipo	Secundario / Trazabilidad
Fuente	RF10, RN9
Trayectoria Principal	1. El usuario abre el panel de detalle de un experimento o, si es Administrador, el panel de auditoría. 2. El sistema consulta la tabla behavior_edits (historial de ediciones) o security_audit_log (eventos de seguridad). 3. El sistema muestra los registros en orden cronológico, con autor, rol, fecha y motivo o tipo de evento.
Trayectoria Alternativa A (Sin registros)	1-2. Mismo flujo de la trayectoria principal. 3. No existen registros para el elemento consultado y el sistema muestra mns1.
Trayectoria Alternativa B (Estudiante, solo lectura)	1. Un Estudiante consulta el historial de ediciones de un experimento. 2. El sistema muestra el historial en modo de solo lectura, sin permitir revertir ni editar.

5.3 Diagramas de secuencia

Los diagramas de secuencia describen la interacción temporal entre los actores del prototipo, la interfaz Streamlit, los servicios internos y la base de datos PostgreSQL para cada caso de uso definido en la sección 5.2. A diferencia de los diagramas de casos de uso, que muestran qué funcionalidades existen y quiénes participan en ellas, los diagramas de secuencia detallan el orden de los mensajes necesarios para ejecutar cada flujo principal y sus trayectorias alternativas relevantes.

Para mantener la trazabilidad con los requerimientos funcionales, esta sección presenta un diagrama por caso de uso, desde CU1 hasta CU10. En todos los diagramas se conserva una estructura homogénea: actor, interfaz o módulo visible, servicio de aplicación, componente técnico especializado cuando aplica, y persistencia en PostgreSQL o archivos auxiliares.




Ilustración 38: Diagrama de secuencia CU1: Registrar usuario [autoría propia]




Ilustración 39: Diagrama de secuencia CU2: Iniciar sesión [autoría propia]




Ilustración 40: Diagrama de secuencia CU3: Gestionar tratamientos [autoría propia]




Ilustración 41: Diagrama de secuencia CU4: Registrar experimento [autoría propia]




Ilustración 42: Diagrama de secuencia CU5: Configurar ROIs [autoría propia]




Ilustración 43: Diagrama de secuencia CU6: Ejecutar análisis de video [autoría propia]




Ilustración 44: Diagrama de secuencia CU7: Agrupar comportamientos [autoría propia]




Ilustración 45: Diagrama de secuencia CU8: Editar tiempos conductuales [autoría propia]




Ilustración 46: Diagrama de secuencia CU9: Exportar resultados [autoría propia]




Ilustración 47: Diagrama de secuencia CU10: Consultar bitácora de auditoría [autoría propia]

5.4 Diagramas de código

En esta sección se documenta la estructura interna del prototipo a partir de los módulos de código y del modelo de datos implementado. Dado que la aplicación fue desarrollada en Python con Streamlit, varias responsabilidades del sistema se organizan como módulos funcionales y páginas de aplicación, no como clases orientadas a objetos tradicionales. Por ello, el diagrama de código representa componentes reales del repositorio, sus responsabilidades principales y sus dependencias con la capa de persistencia.

5.4.1 Diagrama de módulos del prototipo

El diagrama de módulos resume la relación entre la interfaz Streamlit, los servicios internos y la persistencia. La capa de interfaz se compone de Home.py y de las páginas ubicadas en pages/, entre ellas el inicio de sesión, la ingesta de video, la configuración de zonas, el análisis final, los resultados y el panel administrativo.

La lógica de aplicación se concentra en módulos verificables del repositorio: src/auth.py gestiona registro, autenticación, OTP, recuperación de contraseña y roles; src/treatments.py administra el catálogo de tratamientos; src/db/experiment_history.py registra experimentos y configuraciones ROI; src/simba_rol_bridge.py sincroniza las regiones del laberinto con SimBA; src/db/behavior_edits.py registra las ediciones manuales de tiempos conductuales; y src/security_logger.py persiste eventos de seguridad.

La persistencia se realiza mediante PostgreSQL, inicializado con `schema.sql` y accedido desde `src/db/connection.py`. Además de la base de datos, el sistema utiliza archivos auxiliares para videos, salidas del pipeline y configuraciones de zonas, como `zonas_activas.json`.




Ilustración 48: Diagrama de módulos de código del prototipo [autoría propia]

5.4.2 Modelo de datos

El modelo entidad-relación documenta las siete tablas activas del prototipo. La tabla `users` almacena credenciales, rol, estado de verificación, estado activo y datos de perfil. La tabla `treatments` contiene el catálogo de tratamientos experimentales. La tabla `experiments` registra cada sesión EPM con su identificador de roedor, tratamiento, responsable, ruta de video y estado de procesamiento.

Las regiones de interés se almacenan en `roi_configurations` mediante una relación uno a muchos con `experiments`. Los resultados generados por el pipeline se guardan en `analysis_results`, incluyendo distancia total, tiempos en brazos abiertos, brazos cerrados y centro, así como duración de Grooming y Thigmotaxis.

La trazabilidad se cubre con dos tablas complementarias. `security_audit_log` registra eventos de seguridad, autenticación y verificación. `behavior_edits` almacena snapshots before/after de las ediciones manuales de tiempos conductuales, asociados al experimento y al usuario que realizó la corrección.




Ilustración 49: Modelo entidad-relación del prototipo [autoría propia]

5.4.2.1 Diccionario de datos

El diccionario de datos describe los campos persistidos por el prototipo. Las tablas se derivan de schema.sql y de las migraciones usadas por la aplicación.

Tabla “users”

Tabla de usuarios del sistema. Almacena credenciales, rol, verificación, estado de cuenta y datos de perfil institucional.

Campo	Tipo de dato	Restricciones	Valor predeterminado	Descripción
id	SERIAL	PRIMARY KEY	Auto-incremental	Identificador único del usuario.
username	VARCHAR(50)	UNIQUE, NOT NULL	Sin valor	Correo institucional usado como nombre de usuario.
password_hash	TEXT	NOT NULL	Sin valor	Hash bcrypt de la contraseña.
role	VARCHAR(20)	CHECK	investigador	Rol operativo: admin, investigador o estudiante.
is_verified	BOOLEAN	-	FALSE	Indica si la cuenta completó verificación OTP o fue verificada como admin.
verification_code	VARCHAR(6)	-	NULL	Código OTP temporal.
verification_code_created_at	TIMESTAMP	-	NULL	Fecha y hora de emisión del OTP.
is_active	BOOLEAN	-	TRUE	Permite suspender o habilitar la cuenta.

created_at	TIMESTAMP	-	CURRENT_TIMESTAMP	Fecha de creación de la cuenta.
full_name	VARCHAR(200)	-	NULL	Nombre completo del usuario.
accepted_terms	BOOLEAN	-	FALSE	Aceptación de términos y condiciones.
boleta	VARCHAR(20)	-	NULL	Identificador institucional de estudiante.
carrera	VARCHAR(150)	-	NULL	Programa académico del estudiante.
escuela	VARCHAR(100)	-	NULL	Unidad académica del estudiante.
num_empleado	VARCHAR(20)	-	NULL	Número de empleado del investigador/docente.
area	VARCHAR(150)	-	NULL	Área académica o de investigación.
centro	VARCHAR(100)	-	NULL	Centro o unidad de adscripción.

Tabla 10: Descripción de la tabla “users” [autoría propia]

Tabla “treatments”

Catálogo de tratamientos experimentales disponibles para registrar experimentos.

Campo	Tipo de dato	Restricciones	Valor predeterminado	Descripción
id	SERIAL	PRIMARY KEY	Auto-incremental	Identificador único del tratamiento.
name	VARCHAR(100)	UNIQUE, NOT NULL	Sin valor	Nombre del tratamiento.
description	TEXT	-	NULL	Descripción opcional del tratamiento.
created_by	INTEGER	FK users(id)	NULL	Usuario que creó el tratamiento.
created_at	TIMESTAMP	-	CURRENT_TIMESTAMP	Fecha de creación.
is_active	BOOLEAN	-	TRUE	Estado lógico del tratamiento.

Tabla 11: Descripción de la tabla “treatments” [autoría propia]

Tabla “experiments”

Registro principal de sesiones experimentales EPM y videos asociados.

Campo	Tipo de dato	Restricciones	Valor predeterminado	Descripción
id	SERIAL	PRIMARY KEY	Auto-incremental	Identificador único del experimento.
rat_id	VARCHAR(50)	NOT NULL	Sin valor	Identificador del roedor.
treatment	VARCHAR(50)	NOT NULL	Sin valor	Tratamiento aplicado.
experiment_date	DATE	-	NULL	Fecha de la sesión experimental.
responsible	VARCHAR(100)	-	NULL	Responsable del experimento.
video_path	TEXT	NOT NULL	Sin valor	Ruta del video experimental.
duration_seconds	FLOAT	-	NULL	Duración del video en segundos.
created_by	INTEGER	FK users(id)	NULL	Usuario que registró el experimento.
processed	BOOLEAN	-	FALSE	Indica si el experimento fue procesado.

created_at	TIMESTAMP	-	CURRENT_TIMESTAMP	Fecha de registro.
------------	-----------	---	-------------------	--------------------

Tabla 12: Descripción de la tabla “experiments” [autoría propia]

Tabla “roi_configurations”

Configuración de regiones de interés del laberinto EPM asociadas a un experimento.

Campo	Tipo de dato	Restricciones	Valor predeterminado	Descripción
id	SERIAL	PRIMARY KEY	Auto-incremental	Identificador único de la configuración.
experiment_id	INTEGER	FK experiments(id), ON DELETE CASCADE	NULL	Experimento asociado.
zone_type	VARCHAR(50)	NOT NULL	Sin valor	Tipo o nombre de zona EPM.
coordinates_json	JSONB	NOT NULL	Sin valor	Coordenadas de la ROI en formato JSON.
scale_factor	FLOAT	-	NULL	Factor de escala respecto al video original.

Tabla 13: Descripción de la tabla “roi_configurations” [autoría propia]

Tabla “analysis_results”

Resultados cuantitativos generados por el pipeline de análisis conductual.

Campo	Tipo de dato	Restricciones	Valor predeterminado	Descripción
id	SERIAL	PRIMARY KEY	Auto-incremental	Identificador único del resultado.
experiment_id	INTEGER	FK experiments(id), ON DELETE CASCADE	NULL	Experimento analizado.
timestamp	TIMESTAMP	-	CURRENT_TIMESTAMP	Fecha de generación del resultado.
total_distance	FLOAT	-	0.0	Distancia total recorrida.
time_open_arms	FLOAT	-	0.0	Tiempo en brazos abiertos.
time_closed_arms	FLOAT	-	0.0	Tiempo en brazos cerrados.
time_center	FLOAT	-	0.0	Tiempo en zona central.
head_dips_count	INTEGER	-	0	Conteo de head dips.
rearing_count	INTEGER	-	0	Conteo de rearing.
grooming_duration	FLOAT	-	0.0	Duración acumulada de Grooming.
thigmotaxis_duration	FLOAT	-	0.0	Duración acumulada de Thigmotaxis.
status	VARCHAR(20)	-	pending	Estado del resultado.
trajectory_path	TEXT	Migración	NULL	Ruta del archivo de trayectoria generado por la aplicación.

Tabla 14: Descripción de la tabla “analysis_results” [autoría propia]

Tabla “behavior_edits”

Auditoría de ediciones manuales de tiempos conductuales con snapshot before/after.

Campo	Tipo de dato	Restricciones	Valor predeterminado	Descripción
id	SERIAL	PRIMARY KEY	Auto-incremental	Identificador único de la edición.

experiment_id	INTEGER	FK experiments(id), ON DELETE CASCADE	Sin valor	Experimento corregido.
edited_by	INTEGER	FK users(id), ON DELETE SET NULL	NULL	Usuario que realizó la edición.
edited_by_email	TEXT	-	NULL	Correo del usuario editor.
edited_role	TEXT	-	NULL	Rol del usuario editor.
edited_at	TIMESTAMP	NOT NULL	CURRENT_TIMESTAMP	Fecha de la edición.
before_open	FLOAT	-	NULL	Tiempo previo en brazos abiertos.
before_closed	FLOAT	-	NULL	Tiempo previo en brazos cerrados.
before_center	FLOAT	-	NULL	Tiempo previo en centro.
before_grooming	FLOAT	-	NULL	Tiempo previo de Grooming.
before_thigmo	FLOAT	-	NULL	Tiempo previo de Thigmotaxis.
after_open	FLOAT	-	NULL	Tiempo corregido en brazos abiertos.
after_closed	FLOAT	-	NULL	Tiempo corregido en brazos cerrados.
after_center	FLOAT	-	NULL	Tiempo corregido en centro.
after_grooming	FLOAT	-	NULL	Tiempo corregido de Grooming.
after_thigmo	FLOAT	-	NULL	Tiempo corregido de Thigmotaxis.
note	TEXT	-	NULL	Justificación de la edición.

Tabla 15: Descripción de la tabla “behavior_edits” [autoría propia]

Tabla “security_audit_log”

Bitácora de eventos de seguridad, autenticación y verificación del sistema.

Campo	Tipo de dato	Restricciones	Valor predeterminado	Descripción
id	SERIAL	PRIMARY KEY	Auto-incremental	Identificador único del evento.
timestamp	TIMESTAMP	NOT NULL	CURRENT_TIMESTAMP	Fecha y hora del evento.
event_type	VARCHAR(50)	NOT NULL	Sin valor	Tipo de evento registrado.
username	VARCHAR(100)	-	NULL	Usuario asociado al evento.
ip_address	VARCHAR(45)	-	NULL	Dirección IP registrada.
success	BOOLEAN	-	TRUE	Indica si el evento fue exitoso.
message	TEXT	-	NULL	Descripción del evento.
level	VARCHAR(10)	-	INFO	Nivel de severidad.

Tabla 16: Descripción de la tabla “security_audit_log” [autoría propia]

Consideraciones de seguridad

Las contraseñas se almacenan únicamente como hash bcrypt en password_hash. El registro se restringe a correos institucionales @ipn.mx y @alumno.ipn.mx. Los eventos de autenticación y verificación se registran en security_audit_log. Las ediciones manuales de tiempos conductuales se auditan en behavior_edits mediante snapshots before/after. El sistema opera con tres roles: admin, investigador y estudiante.

Capítulo 6. Desarrollo

En este capítulo se documenta el proceso de **diseño y desarrollo del prototipo**, abarcando desde la definición de su estructura general hasta la elaboración de los elementos visuales y funcionales que lo componen.

6.1 Mockups del prototipo

6.1.1 Vista previa del inicio de sesión.

En la ilustración 57, representa el boceto hecho del inicio del prototipo. El investigador tiene la opción de ingresar sus datos, cambiar contraseña o registrarse.


Commented [IR4]: FALTA USUARIO Y CONTRASEÑA CON EL ROL DE USUARIO, DETERMINADO POR EL DR. SANDINO



Ilustración 50: “Vista previa de inicio de sesión [autoría propia]”

6.1.2 Vista previa de registro.

En la ilustración 58 se muestra la pantalla del registro que pide al investigador dar su nombre completo, correo institucional y contraseña. Después de enviar los datos, el investigador recibirá un correo electrónico de confirmación.



The image shows a web browser window with a registration form. The form is titled "REGISTRO" and is centered on a light blue background. It contains three input fields: "Nombre Completo" with the example text "Ej. Juan Andrés Pérez García", "Correo Electrónico" with the example text "tucorreo@pn.mx", and "Contraseña" with the placeholder text "Contraseña". Below these fields is a green button labeled "Enviar Datos". In the top left corner of the browser window, there is a link that says "← Volver atrás".

Ilustración 51: "Vista previa del registro [autoría propia]"

6.1.3 Vista previa de cambio de contraseña.

En la ilustración 59, el investigador solo necesita ingresar su correo electrónico para recibir un correo de cambio de contraseña.



CAMBIAR CONTRASEÑA

Ingresa tu correo electrónico para recibir las instrucciones de recuperación.

Correo Electrónico

Solicitar correo de recuperación

Ilustración 52: “Cambiar contraseña [autoría propia]”

6.1.4 Vista previa de inicio del prototipo

En la ilustración 60, se ve la vista de investigador después de iniciar sesión. En un apartado, se muestran las diferentes opciones de realizar un nuevo análisis, consultar reportes y consultar comparaciones. En la parte superior derecha se encuentra la parte de configurar perfil, ver notificaciones y cerrar sesión.




Ilustración 53: "Vista previa del inicio del prototipo [autoría propia]"

Mientras tanto, la ilustración 61 muestra la vista de administrador con todas las funciones de la pantalla de inicio del prototipo para el usuario a excepción de dos botones extras en la parte superior derecha acerca de manejo de perfiles y mandar notificaciones.




Ilustración 54 "Vista previa del administrador [autoría propia]"

6.2 Pantallas del prototipo

6.2.1 Pantalla de bienvenida




Ilustración 62 “Vista de pantalla de bienvenida parte superior [autoría propia]”




Ilustración 63 “Vista de pantalla de bienvenida parte media [autoría propia]”




Ilustración 64 “Vista de pantalla de bienvenida parte inferior [autoría propia]

6.2.2 Pantalla de inicio de sesión




Ilustración 66 “Vista de pantalla de inicio de sesión (sesión iniciada) [autoría propia]

6.2.3 Pantalla de ingesta de video



Ilustración 67 “Vista de ingesta de video donde se ingresa la información [autoría propia]



Ilustración 68 “Vista de ingesta de video donde se ingresa la información [autoría propia]

6.2.4 Pantalla de Configuración de Zonas




Ilustración 69 “Vista de configuración de zonas parte superior y añadir zonas [autoría propia]




Ilustración 70 “Vista de ingesta de video y modificar zonas [autoría propia]

6.3 Optimización de la infraestructura de cómputo y aceleración por hardware

Como respuesta a la demanda computacional del análisis de video, el proyecto migró hacia inferencia acelerada por GPU para ejecutar YOLO11 Pose de forma local. Esta decisión redujo el cuello de botella observado en etapas iniciales y permitió procesar videos de 5 minutos en aproximadamente 3 minutos con GPU dedicada, manteniendo la integridad espacial necesaria para el análisis de trayectoria y keypoints.

La arquitectura de ejecución se organizó mediante entornos Python separados para mantener compatibilidad entre el pipeline de visión por computadora, SimBA, TensorFlow/Keras y las

dependencias de video. Esta separación redujo conflictos de versiones y permitió aislar los módulos de entrenamiento, inferencia y análisis conductual.

La infraestructura local fue suficiente para entrenar y ejecutar el modelo YOLO11 Pose usado en el prototipo. El modelo final se entrenó con 3,953 imágenes etiquetadas y se integró al flujo YOLO-SimBA para generar keypoints, trayectoria y features espaciotemporales utilizadas por los clasificadores conductuales.

6.3.1 Análisis crítico de la resolución espacial e integridad de datos etológicos

En el marco de la verificación del cumplimiento de la Regla de Negocio RN3, se ejecutaron protocolos de pruebas de estrés para validar el impacto de la resolución de video en la fiabilidad de las métricas obtenidas. El equipo planteó originalmente la hipótesis de que una reducción en la resolución espacial podría optimizar los tiempos de inferencia sin comprometer la calidad del dato; sin embargo, los hallazgos demostraron que la integridad de los resultados se ve comprometida de manera irreversible bajo configuraciones de bajo muestreo. Mediante el análisis comparativo del clip experimental R5B20, se determinó que el procesamiento en una resolución nativa de 720p (1280x720) es un recurso técnico no negociable para la robustez del sistema de análisis de posturas.

La experimentación reveló que el submuestreo de la imagen al 50% (640x360) induce un fenómeno técnico de jitter de coordenadas o inestabilidad espacial, el cual desvirtúa el seguimiento preciso de los puntos anatómicos del espécimen. Este ruido en la trayectoria es interpretado erróneamente por los clasificadores de Random Forest de SimBA, lo que conduce a diagnósticos conductuales equivocados. La gravedad de esta pérdida de integridad se evidenció al observar que la tasa de detección de conductas de acicalamiento (grooming) se elevó de un valor real de 0.8% a un 9.1% artificial debido a la vibración de las coordenadas ruidosas. En consecuencia, el sistema generó una cantidad masiva de falsos positivos (848 cuadros erróneos) que invalidaron estadísticamente la sesión de prueba.

Para mitigar el riesgo de inconsistencia, se estableció que el sistema debe trabajar con video en resolución nativa 720p siempre que sea posible. La reducción de resolución incrementa el jitter de keypoints y afecta directamente las features utilizadas por SimBA. En la versión final, DeepLabCut se conserva como antecedente metodológico, pero la estimación de pose productiva se realiza con YOLO11 Pose.

Se determinó que la optimización de velocidad debe realizarse mediante hardware, postprocesamiento y modelos ligeros, no mediante degradación del material visual. Esta decisión favorece trayectorias más estables y reduce falsos positivos derivados de ruido espacial.

6.3.2 Evolución de los modelos de IA y entrenamiento de alta fidelidad

La consolidación del motor de detección transitó por varias iteraciones de entrenamiento hasta llegar al modelo YOLO11 Pose final. Las versiones tempranas tuvieron problemas de generalización ante cambios de iluminación, contraste y presencia del operador en escena. La curación del dataset y el aumento progresivo de imágenes permitieron reducir estos fallos.

El análisis detallado permitió identificar errores de confusión entre el espécimen y elementos externos de la escena, especialmente cuando aparecía personal de laboratorio. La versión final se entrenó con

3,953 imágenes etiquetadas para mejorar la robustez ante variaciones de iluminación, orientación corporal y contraste del laberinto.

El modelo final de pose alcanzó $mAP50 = 0.995$ en el conjunto de validación interno. Este valor corresponde al desempeño del detector de keypoints y no debe confundirse con las métricas de clasificación conductual. Para Grooming y Thigmotaxis, el desempeño se reporta mediante F1-Score en la validación Leave-One-Out descrita en el capítulo 7.

La versión operativa del prototipo quedó basada en YOLO11 Pose v4 para estimación de keypoints. Esta decisión permitió estabilizar el seguimiento espacial y alimentar el puente de features hacia SimBA, que posteriormente clasifica Grooming y Thigmotaxis.

6.3.3 Refinamiento de la arquitectura modular y continuidad temporal

Para asegurar la estabilidad temporal de las predicciones etológicas y erradicar el problema de las micro-detecciones erróneas o parpadeos (flickering), se formalizó una división estricta de tareas técnicas dentro del ecosistema del software. El refinamiento del script principal, `generar_video_prediccion.py`, permitió establecer una arquitectura donde cada componente de IA se especializa en un dominio de datos único, evitando la propagación de ruidos espaciales entre las distintas fases del análisis. Bajo esta nueva configuración modular, YOLOv11 asume la responsabilidad exclusiva del rastreo visual —representado gráficamente por un Punto Rojo dinámico— y del conteo automatizado de los tiempos de permanencia por brazo.

Por otro lado, SimBA ejecuta la clasificación conductual a partir de features derivadas de los keypoints generados por YOLO11 Pose. DeepLabCut ya no forma parte del pipeline productivo; se conserva únicamente como antecedente comparativo de estimación de pose animal. El sistema utiliza umbrales calibrados, suavizado temporal y estrategia Conditional para reducir eventos fragmentados en Grooming.

Esta modularidad también responde a los requerimientos no funcionales de mantenibilidad (RNF-06) y trazabilidad (RNF-08), permitiendo actualizaciones independientes sin afectar la integridad del flujo de trabajo. El refinamiento arquitectónico eliminó el fenómeno del parpadeo que invalidaba el análisis etológico al cortar abruptamente las predicciones mientras la conducta aún persistía. Al asegurar trayectorias limpias, el clasificador puede ahora distinguir con precisión entre movimientos rítmicos genuinos y simples vibraciones técnicas de las coordenadas. Finalmente, la arquitectura consolidada garantiza que el ruido espacial no se propague entre cuadros independientes, dejando el sistema preparado para el procesamiento por lotes masivo de la videoteca de tesis.

Cada modificación en el pipeline se ha registrado en el repositorio de GitHub con descripciones claras de los requerimientos que satisfacen, asegurando una auditoría documental completa. El uso de campos de texto de alta precisión para delimitar el tiempo de análisis sustituyó a los controles deslizantes previos, mejorando la usabilidad técnica del sistema. Esta evolución hacia una arquitectura de división de tareas es el pilar que garantiza la entrega de estadísticas precisas y replicables exigidas por el Comité de Evaluación.

6.3.4 Herramientas de usabilidad y visualización HUD avanzada

En cumplimiento con el requerimiento de usabilidad RNF-02, se integraron módulos de interacción avanzada que otorgan al investigador un control milimétrico sobre el proceso analítico sin requerir conocimientos informáticos profundos. Uno de los hitos principales fue la creación de un Selector de ROIs Interactivo, el cual permite delimitar manualmente los rectángulos exactos de los brazos Norte, Sur, Este, Oeste y Centro al inicio de cada análisis. Esta función otorga adaptabilidad total ante cambios accidentales en la perspectiva de la cámara, asegurando un conteo de segundos milimétrico y ofreciendo opciones de corrección dinámica (Undo) durante la selección.

El sistema de visualización, denominado Head-Up Display (HUD), fue rediseñado bajo criterios de rigor científico para maximizar la legibilidad de la información en tiempo real. Se implementó un esquema de Split HUD con una opacidad del 90%, donde la información de comportamientos se ubica en la parte superior derecha y el cronómetro acumulado por zonas se despliega en la parte inferior derecha. Esta disposición permite supervisar la validez del análisis sin que los elementos gráficos obstruyan la visibilidad del espécimen, facilitando la validación visual inmediata mediante un sistema de punto dinámico que cambia de color según la zona ocupada. El punto adquiere tonalidades Coral para brazos abiertos, Cyan para cerrados y Naranja para el centro, permitiendo al usuario confirmar el estado del análisis con un solo vistazo.

Además de estas mejoras visuales, la interfaz de usuario se fortaleció con la sustitución de controles deslizantes imprecisos por campos de entrada de texto que permiten especificar el segundo exacto (mm:ss) para iniciar el registro automatizado. Esta funcionalidad satisface la necesidad crítica de omitir los instantes iniciales de estabilización del animal o de retiro del operario humano del campo visual. Asimismo, el Commit 1bc3ba5 introdujo la capacidad de transformar ROIs moviendo sus esquinas libremente sin necesidad de recargar el sistema completo, optimizando significativamente la experiencia de usuario. Estas herramientas transforman al prototipo en una plataforma profesional, intuitiva y ajustada a las demandas reales del entorno de investigación farmacológica.

La gestión de datos se optimizó mediante un selector de tratamientos con persistencia de sesión, el cual utiliza sugerencias históricas de la base de datos para evitar la creación de registros duplicados en la tabla experiments. Esta actualización garantiza que cada análisis esté vinculado correctamente a sus metadatos (fecha, tratamiento, espécimen), cumpliendo con la regla de negocio RN6 sobre trazabilidad. Finalmente, la exportación estructurada en formatos Excel y PDF habilita la ejecución de pruebas estadísticas avanzadas como ANOVA y T-Test requeridas para la validación científica final.

6.3.5 Validación de escenario ciego y gestión de factores de riesgo

La capacidad de generalización del sistema se evaluó mediante validación Leave-One-Out sobre 26 videos reales etiquetados. Este enfoque permitió medir el desempeño en videos no vistos durante entrenamiento y documentar diferencias entre conductas espaciales, como Thigmotaxis, y conductas cinemáticas finas, como Grooming.

Los errores observados en videos críticos confirmaron la importancia de conservar mecanismos de revisión manual y auditoría. En lugar de presentar una concordancia absoluta, el sistema reporta métricas por conducta y permite registrar correcciones trazables cuando el modelo no captura correctamente eventos ambiguos.

Para mitigar riesgos de sobreajuste y baja representatividad, el proyecto consolidó un dataset de pose de 3,953 imágenes y un conjunto conductual de 26 videos reales con 243,253 frames. Esta base permitió entrenar el detector de pose y evaluar los clasificadores conductuales, aunque Grooming requiere ampliación futura del dataset.

Tras solventar estas contingencias y verificar la integridad de las trayectorias mediante el HUD dinámico, el prototipo se considera preparado para el procesamiento masivo de la videoteca de tesis. La eliminación definitiva del ruido espacial permite que el equipo proceda con la exportación estructurada de datos para realizar las pruebas estadísticas requeridas para la validación final del Trabajo Terminal. El sistema representa hoy una solución sólida y verificada para la interpretación automatizada de conductas de ansiedad en modelos animales, cumpliendo con los objetivos generales planteados en la propuesta original.

6.4 Validación experimental y refinamiento de la estimación de postura

El desarrollo alcanzado durante el ciclo de trabajo actual se ha consolidado mediante la validación operativa del sistema en escenarios reales, tomando como referencia los resultados en una prueba que se hizo la mañana con fecha del 13 de marzo de 2026. Este informe registra un análisis exhaustivo de una sesión experimental con una duración total de 933.1 segundos, donde el prototipo logró extraer de forma autónoma indicadores clave de desempeño (KPIs) de alta relevancia científica. Los datos arrojaron una permanencia de 316.4 segundos (33.9%) en los brazos abiertos del laberinto, frente a 477.6 segundos en los brazos cerrados, registrando un total de 11 entradas o transiciones, lo que permitió al sistema concluir que el espécimen mostraba una alta exploración indicativa de un posible efecto ansiolítico.

La madurez del módulo de visualización se evidencia en la capacidad de generar de forma automática etogramas temporales de posición, gráficas de preferencia de zona mediante diagramas de dona y mapas de calor (heatmaps*) de mayor permanencia. Estas herramientas permiten una síntesis de datos espaciales y temporales que satisface las necesidades de interpretación objetiva planteadas originalmente por los investigadores de la Escuela Nacional de Medicina y Homeopatía (ENMyH), cumpliendo con el objetivo de reducir el margen de error humano y la subjetividad en la observación manual. La precisión en la delimitación de las áreas de interés (ROI) ha permitido que estas métricas sean trazables y coherentes con el comportamiento observado en los videos experimentales.

En paralelo a la validación de resultados, el equipo se encuentra actualmente ejecutando el etiquetado manual de un nuevo dataset especializado de 311 imágenes para fortalecer el motor de Pose Estimation. Este proceso requiere una intervención técnica detallada en la que, por cada cuadro, se definen y localizan ocho puntos anatómicos específicos del ratón: nariz, oreja izquierda, oreja derecha, pata izquierda, pata derecha, torso, base de la cola y punta de la cola. El propósito de esta tarea es generar un conjunto de datos de entrenamiento robusto que permita a la red neuronal profunda (DeepLabCut) identificar con precisión milimétrica la orientación y los movimientos finos del animal, incluso ante variaciones de iluminación o cambios de postura abruptos.




Ilustración 70 "Interfaz de RoboFlow, etiquetado de las partes del ratón [autoría propia]"

La integración de estas nuevas imágenes anotadas busca mitigar definitivamente los riesgos de sobreajuste ambiental (overfitting) que fueron diagnosticados en versiones previas del modelo, donde la red presentaba inconstancia al cambiar de escenarios controlados a entornos experimentales novedosos. Al proporcionar coordenadas precisas de extremidades y puntos clave de la cola, el sistema podrá realizar análisis cinemáticos y biomecánicos más avanzados, lo cual es fundamental para distinguir conductas sutiles como el acicalamiento o la evaluación de riesgo (stretch-attend posture) que requieren una resolución temporal y espacial superior. Este entrenamiento es una pieza clave para asegurar que el sistema no pierda la trayectoria del espécimen y mantenga la estabilidad del rastreador en los brazos cerrados del laberinto.

Asimismo, durante la mañana del 13 de marzo de 2026, se llevó a cabo una reunión de validación presencial con el Dr. César Augusto Sandino, en la cual se realizaron múltiples pruebas pequeñas en tiempo real para demostrar el funcionamiento actual del sistema. Estos ensayos permitieron contrastar las capacidades del prototipo frente a las expectativas del investigador, validando funciones críticas como la selección interactiva de zonas (ROI), el ajuste manual del segundo exacto de inicio del análisis y la fluidez de la interfaz tipo dashboard. La retroalimentación obtenida confirma que, aunque aún se deben hacer ajustes y realizar el manual de usuario, el sistema es intuitivo y satisface los requerimientos de usabilidad para personal sin formación técnica avanzada en computación.

Finalmente, estas demostraciones permitieron validar el flujo operativo del prototipo ante necesidades reales del laboratorio: selección de zonas, carga de video, inferencia YOLO11 Pose, clasificación con SimBA, consulta de resultados y exportación estructurada. El sistema quedó preparado para continuar la validación con nuevos videos y para documentar cuantitativamente sus resultados mediante métricas de clasificación.

6.5 Refinamiento del pipeline de inferencia, integración de SimBA y optimización de la trazabilidad conductual

El desarrollo tecnológico del sistema alcanzó un hito crítico con la consolidación del pipeline YOLO11 Pose + SimBA. Esta integración evita depender de DeepLabCut como backend productivo y conserva la resolución nativa de 720p para reducir jitter en los keypoints que alimentan las features conductuales.

Para fortalecer la robustez del rastreo anatómico, el pipeline utiliza las cajas y keypoints generados por YOLO11 Pose, junto con filtros de suavizado y validación de trayectoria. Esta estrategia reduce falsos positivos y mantiene la coherencia espacial del espécimen en zonas de bajo contraste.

En el ámbito de la clasificación supervisada, se han ejecutado pruebas de video utilizando algoritmos de Random Forest entrenados para identificar patrones complejos de conducta. Un avance fundamental en esta fase ha sido la finalización del etiquetado manual para las categorías de acicalamiento (grooming) y contacto con la pared, expandiendo la biblioteca de predicción híbrida del prototipo. Aunque los resultados en videos de "prueba a ciegas" (escenarios inéditos) aún presentan áreas de oportunidad en términos de generalización, el uso de muestras anotadas de diversos entornos experimentales está permitiendo estabilizar el umbral de probabilidad para evitar las micro-detecciones o "parpadeos" del clasificador.

La trazabilidad y gestión del proyecto se han visto fortalecidas mediante el Commit 7ea46b6, el cual actualizó de forma integral el pipeline de análisis, la documentación técnica y la integración con SimBA. Como parte de este esfuerzo de estandarización, se realizaron correcciones exhaustivas en los diagramas de casos de uso para asegurar que la documentación refleje con precisión la arquitectura funcional y lógica del software actual. Estas modificaciones garantizan que los procesos de inicio de sesión, configuración de zonas (ROI) y generación de reportes coincidan estrictamente con la interfaz interactiva desplegada para los investigadores.

Finalmente, la utilidad del sistema para apoyar decisiones experimentales se verificó mediante reportes estructurados de trayectoria, permanencia por zonas y tiempos conductuales. La interpretación farmacológica final permanece a cargo de los especialistas, mientras que el prototipo aporta mediciones estandarizadas y trazables.

6.6 Optimización de la arquitectura de software, estandarización de identidad institucional y refinamiento del flujo de datos

Dentro de la progresión cíclica de la metodología espiral de Boehm, la presente fase de desarrollo se ha centrado en alcanzar la madurez operativa necesaria para la portabilidad del sistema entre diversas plataformas de hardware. Este hito técnico ha priorizado la transición desde un entorno de desarrollo rígido hacia una arquitectura de configuración centralizada, eliminando sistemáticamente el uso de rutas absolutas en el código fuente. Dicha refactorización asegura que el prototipo pueda ser desplegado e iniciado en cualquier estación de trabajo del Instituto Politécnico Nacional sin requerir reconfiguraciones manuales de los directorios de archivos, cumpliendo así con los estándares de mantenibilidad y modularidad definidos en el requerimiento RNF-06.

El robustecimiento del núcleo del sistema incluyó una corrección crítica en el módulo `full_pipeline` mediante la implementación estratégica de la instrucción `sys.path.insert`. Esta modificación técnica permite que el pipeline de análisis sea ejecutado como un script aislado, garantizando que el intérprete de Python localice correctamente los módulos internos de visión artificial y minería de datos independientemente del punto de ejecución. Esta mejora en la lógica de importación resuelve problemas de resolución de dependencias detectados en iteraciones previas, facilitando la integración de nuevas funcionalidades de aprendizaje profundo sin comprometer la estabilidad de los procesos de inferencia ya verificados.

En el ámbito de la integridad de los metadatos etológicos, se ajustó el flujo de sincronización entre frames de video, keypoints y features tabulares. Esta alineación temporal es necesaria para que SimBA procese secuencias completas y para evitar sesgos en la interpretación de Thigmotaxis y Grooming.

Como parte del esfuerzo continuo de enriquecimiento de los modelos de inteligencia artificial, se consolidó la anotación de keypoints del espécimen en RoboFlow hasta integrar el dataset final de 3,953 imágenes. Estas muestras alimentaron el entrenamiento del modelo YOLO11 Pose utilizado como backend de estimación de postura.

Paralelamente a las mejoras funcionales, se realizó un rediseño integral de la identidad visual del prototipo para alinearla con los valores y la estética del Instituto Politécnico Nacional. La nueva interfaz interactiva incorpora ahora una colorimetría y simbología concordantes con el manual de identidad institucional, utilizando tonos guinda y blanco que refuerzan el carácter oficial del sistema en entornos académicos. Este rediseño no es meramente estético, sino que mejora la experiencia de usuario (RNF-02) al emplear una paleta de colores de alto contraste que facilita la lectura de los indicadores clave de ansiedad y las trayectorias dinámicas en las pantallas de visualización HUD.

La consolidación de estos avances permitió que el prototipo alcanzara un estado funcional para validación académica. La eliminación de errores de ruta, la integración con base de datos y la estandarización de exportaciones reducen riesgos operativos durante el análisis de nuevos videos experimentales.

6.7 Fortalecimiento de la seguridad de acceso, depuración de dependencias de bajo nivel y optimización de recursos de cómputo

El desarrollo tecnológico durante el presente ciclo se ha enfocado en robustecer los mecanismos de seguridad y la eficiencia operativa del software, asegurando la integridad del flujo de trabajo institucional. Un avance crítico en la gestión de accesos consistió en la implementación de un control de sesión restrictivo; actualmente, en ausencia de un usuario con sesión activa, la interfaz limita la navegación exclusivamente a las secciones de inicio (Home) y autenticación (Login). Esta medida fuerza al personal a realizar el registro o ingreso formal en línea antes de interactuar con los módulos de análisis, garantizando la trazabilidad de los datos conforme a la regla de negocio RN6.

Complementariamente, se ha refinado el sistema de Roles y Permisos, de modo que los usuarios registrados con perfil de investigador queden estrictamente excluidos del panel de administración, cumpliendo así con los estándares de seguridad y jerarquía definidos para el prototipo.

En el ámbito de la visión por computadora de bajo nivel, se resolvió un obstáculo técnico persistente relacionado con la extracción de puntos clave (keypoints) anatómicos de los especímenes. Tras identificar que la ausencia de la librería especializada ptxas impedía la correcta comunicación entre los modelos de aprendizaje profundo y el hardware de aceleración gráfica, se procedió a su integración exitosa en el entorno de ejecución. Esta corrección técnica ha permitido que la extracción de coordenadas espaciales se realice ahora sin interrupciones, asegurando que el pipeline de estimación de postura mantenga la precisión métrica necesaria para la generación de etogramas temporales y mapas de calor precisos, como los observados en los reportes de análisis recientes.

Para optimizar la gestión de dependencias y evitar conflictos entre librerías, se realizó la segregación del entorno de ejecución mediante la creación del ambiente virtualizado especializado venv311. Este entorno ha sido configurado específicamente para gestionar todas las funciones del prototipo que operan fuera del marco de análisis de DeepLabCut (DLC), permitiendo una ejecución más ligera y controlada de los módulos de minería de datos y visualización interactiva. Esta decisión arquitectónica mejora significativamente la mantenibilidad del software (RNF-06), al aislar los requisitos técnicos de las diferentes etapas del pipeline de inferencia y facilitar la actualización independiente de los modelos de inteligencia artificial sin comprometer la estabilidad global del sistema.

Un hito fundamental en la optimización del código fuente fue la identificación y eliminación de tres bloques extensos de código duplicado que comprometían la eficiencia del procesamiento. Se detectó que estas redundancias provocaban una llamada recursiva involuntaria al sistema, lo que resultaba en una doble ejecución de procesos analíticos y un gasto innecesario de recursos de hardware (CPU/GPU) por cada solicitud de usuario. Al simplificar esta lógica de ejecución, se ha logrado una respuesta más ágil de la interfaz y se ha garantizado que el procesamiento de videos experimentales se realice de manera lineal, optimizando la capacidad de cómputo necesaria para las tareas de inferencia matricial exhaustiva.

En cuanto al enriquecimiento del dataset de entrenamiento, el equipo ha mantenido una actividad constante a través de la plataforma RoboFlow, continuando con el etiquetado manual de fotogramas clave para mejorar la detección de los puntos anatómicos de los especímenes. Estos esfuerzos de anotación son esenciales para fortalecer la robustez del modelo ante oclusiones y para asegurar que la clasificación de comportamientos sutiles, como el acicalamiento o el contacto con la pared, alcance los umbrales de precisión científica requeridos. La incorporación de estos nuevos datos etiquetados busca mitigar los problemas de generalización detectados en fases previas de "prueba a ciegas", donde la inconstancia en la detección dificultaba la obtención de trayectorias limpias.

Finalmente, se han estado ejecutando pruebas de validación integrales para confirmar que las mejoras en la seguridad y la arquitectura no afecten la exactitud de los resultados etoestadísticos.

6.8 Escalamiento del dataset para la detección de microconductas y validación de la robustez del sistema

En el marco de la metodología a espiral de Boehm, esta fase de desarrollo se orientó al robustecimiento del dataset de estimación de pose y a la validación del pipeline conductual. El conjunto final consolidado para YOLO11 Pose quedó integrado por 3,953 imágenes etiquetadas, sustituyendo los conteos parciales reportados durante iteraciones previas de anotación.

El objetivo técnico de ampliar y depurar el dataset fue mejorar la robustez del detector ante distintas orientaciones, condiciones de iluminación y posturas del espécimen. Para la clasificación de microconductas, el proyecto utiliza features de pose en SimBA y deja como trabajo futuro la ampliación del conjunto conductual a 100-120 videos etiquetados.

En concordancia con los hallazgos de jitter, se mantuvo el criterio de trabajar con resolución nativa 720p y evitar degradaciones que afecten los keypoints. Esta decisión reduce errores de trayectoria y favorece features más estables para SimBA.

Paralelamente a la curación del dataset, se realizaron pruebas de integración entre YOLO11 Pose, el puente de features, SimBA, PostgreSQL y la interfaz Streamlit. Estas pruebas confirmaron la estabilidad del flujo principal y ayudaron a detectar problemas de rutas, dependencias y modelos pesados.

6.9 Estandarización de identidad institucional, optimización de inferencia y refinamiento de criterios de anotación de puntos clave

El avance más notable en la interfaz de usuario consistió en un rediseño integral del entorno gráfico, aplicando estrictamente la paleta de colores oficial del Instituto Politécnico Nacional, con tonos guinda y blanco en sus valores específicos. Esta actualización no solo cumple con el requerimiento de usabilidad RNF-02, sino que alinea el prototipo con los estándares de identidad institucional de la ESCOM y la ENMyH, proporcionando una plataforma con un rigor estético profesional adecuado para su despliegue en laboratorios de investigación del instituto.

En cuanto al enriquecimiento del motor de inteligencia artificial, el dataset final de pose quedó consolidado en 3,953 imágenes etiquetadas. Los conjuntos parciales de iteraciones anteriores se integraron y depuraron para entrenar el modelo YOLO11 Pose utilizado en el prototipo.

Desde una perspectiva técnica de implementación, se identificaron diferencias entre formatos de anotación y exportación de modelos de pose. La solución final mantuvo un esquema consistente de keypoints anatómicos y rutas de inferencia compatibles con el pipeline YOLO-SimBA.




Ilustración 71: Ejemplo de etiquetado en el software RoboFlow [Autoría Propia]

La optimización de estos criterios de detección y la integración refinada de YOLOv11 al pipeline han resultado en una mejora sustancial del rendimiento computacional. Actualmente, el sistema es capaz de completar un análisis de video exhaustivo en un tiempo aproximado de 3 minutos, manteniendo resultados de detección decentes y estables. Esta rapidez operativa facilita ciclos de retroalimentación mucho más ágiles para los investigadores, cumpliendo con la necesidad de eficiencia planteada originalmente por el Dr. Sandino en las fases de análisis de requerimientos.

Finalmente, ante la estabilidad alcanzada en la velocidad de inferencia, los esfuerzos se han redirigido a fortalecer la detección de microconductas específicas. Se ha continuado con el etiquetado masivo enfocado primordialmente en eventos de grooming y thigmotaxis, categorías esenciales para la validación de efectos ansiolíticos en ensayos farmacológicos. Este robustecimiento cualitativo del dataset busca asegurar que el sistema evolucione hacia una herramienta de grado científico capaz de reportar estadísticas precisas y replicables.

6.10 Consolidación analítica de grupos experimentales, refinamiento de microconductas vía LSTM y estrategia de escalamiento masivo

En el marco de la fase de cierre de la metodología espiral de Boehm, que rige la progresión de este Trabajo Terminal para asegurar la gestión de riesgos y la madurez del software, en la semana 45 los esfuerzos de ingeniería se concentraron en tres pilares: la implementación de un módulo de comparación estadística robusto, el refinamiento del pipeline de postura mediante técnicas de "rescate" por redes recurrentes y la planificación de los hitos finales de entrega.

6.10.1 Implementación del módulo de comparación estadística y control de grupos

Se ha integrado un módulo avanzado diseñado para la comparación controlada de grupos experimentales, cumpliendo con los requerimientos analíticos solicitados por la ENMyH. Este componente inicializa configuraciones de sesión y controles de acceso basados en roles almacenados en `st.session_state`, garantizando que solo usuarios autorizados operen sobre los datos, conforme a las reglas de seguridad institucional. La extracción de información se realiza mediante una conexión optimizada a la base de datos relacional (`get_db_engine`), integrando experimentos finalizados y enriqueciéndolos con etiquetas únicas generadas a partir de metadatos experimentales.

La interfaz permite al investigador definir dos grupos de estudio (entre 6 y 8 especímenes por grupo de igual tamaño para asegurar validez estadística), consolidando los datos en un `DataFrame` de `pandas` con variables categóricas. El sistema no solo calcula estadísticas descriptivas vectorizadas (N, media, desviación estándar, error estándar, mínimos y máximos), sino que incorpora el cálculo del tamaño del efecto mediante el `d` de Cohen, permitiendo una interpretación profunda de la potencia farmacológica de las sustancias evaluadas. La exportación de estos resultados se ha estandarizado en archivos Excel multihoja y CSV, facilitando el re-graficado en software especializado solicitado por los expertos.

6.10.2 Refinamiento del pipeline: YOLO Pose v4 y arquitectura de rescate LSTM

Para elevar la precisión del rastreo anatómico, se ha integrado la versión v4 de YOLO Pose, manteniendo un sistema de tracking basado en el torso del espécimen para mitigar las pérdidas de trayectoria observadas en iteraciones previas. Este avance se complementa con la corrección en la selección de modelos SimBA para el backend de YOLO, asegurando que la clasificación conductual no se vea afectada por inconsistencias en la arquitectura de datos de origen.

Un avance crítico de este ciclo es la implementación de una arquitectura de rescate basada en LSTM para la detección de la conducta de acicalamiento (`grooming`). Esta funcionalidad integra inferencia y entrenamiento de redes neuronales recurrentes diseñadas para procesar secuencias temporales que los modelos tradicionales de Random Forest podrían fragmentar. Mediante el uso de umbrales calibrados y diagnósticos de validación en los clips R5C y R6C, el sistema ha logrado estabilizar la detección de microconductas, reduciendo el "parpadeo" o flickering que invalidaba la interpretación etológica en fases tempranas del proyecto.

6.10.3 Optimización administrativa, UX y persistencia de resultados

El sistema de gestión de experimentos ha sido optimizado mediante el ordenamiento lógico del historial y la adición de una funcionalidad de borrado administrativo, permitiendo una depuración controlada del repositorio de análisis. En términos de usabilidad (RNF-02), se ha reforzado la

persistencia de resultados y se incorporó un campo de registro de observaciones que se mantiene activo durante la sesión, facilitando la documentación cualitativa del investigador en tiempo real. Estas mejoras aseguran que el prototipo sea una herramienta ergonómica y eficiente para el personal médico del laboratorio.

6.10.4 Estrategia de escalamiento del dataset e hitos de conclusión

Como parte de la estrategia de mejora continua, el trabajo futuro ya no se plantea como una meta de 8,000 imágenes de pose, sino como la ampliación del dataset conductual. Con base en la varianza observada en Grooming, se recomienda reunir aproximadamente 100-120 videos etiquetados para reducir la incertidumbre del F1 promedio y entrenar modelos temporales con mayor capacidad de generalización.

Finalmente, en coordinación con la dirección del proyecto, se han definido las fechas críticas para la entrega de la versión operativa final del programa y la conclusión del reporte técnico del Trabajo Terminal. Estas definiciones aseguran que el prototipo transite de su fase de validación experimental a su implementación definitiva como una solución tecnológica estable y verificada para el Instituto Politécnico Nacional.

Capítulo 7. Ciclo de desarrollo

El desarrollo del presente proyecto se estructuró siguiendo los principios de la metodología espiral de Boehm, lo que permitió una gestión sistemática de los riesgos y un progreso gradual a través de la elaboración de prototipos funcionales. A diferencia de los modelos lineales tradicionales, este enfoque cíclico facilitó la integración constante de retroalimentación técnica y científica, asegurando que el producto final cumpliera con los estándares de calidad y rendimiento definidos por las normas internacionales de ingeniería de software.

En este apartado se detallan las actividades ejecutadas, los hitos alcanzados y la evolución técnica del sistema a través de sus cuatro iteraciones principales, las cuales abarcaron desde la planeación inicial hasta la validación de indicadores clave de desempeño en escenarios reales.

7.1 Iteración 1

En la primera fase del proyecto se realizaron las primeras acciones de investigación y análisis requeridas para sentar las bases firmes para el desarrollo del sistema. Principalmente, este periodo se centró en recopilar, examinar y estructurar datos vinculados al problema propuesto, además de entender los términos científicos y técnicos que forman parte del proyecto. El protocolo, los capítulos 1 y 3 del presente documento, que tratan sobre el estado del arte y el marco teórico, respectivamente, fueron desarrollados como resultado de este proceso. Ambos documentos ayudaron a establecer el contexto del estudio y a identificar los fundamentos conceptuales requeridos para respaldar las decisiones que se tomaron en la evolución futura del sistema.

En el capítulo sobre estado del arte, se llevó a cabo una revisión de diversas investigaciones, metodologías y herramientas vinculadas al análisis automatizado de conductas en modelos animales. Se enfatizó en los estudios enfocados en la ansiedad, como las pruebas del Elevated Plus Maze (EPM). También se revisaron diversos métodos tecnológicos empleados en labores similares, como el procesamiento de video, técnicas de visión por computadora, aprendizaje automático y sistemas para

rastrear movimiento. Esta revisión posibilitó el reconocimiento de las áreas de oportunidad, las limitaciones y los principales beneficios que presentan las soluciones existentes. Esto ayudó a establecer una propuesta que se ajusta a lo que requiere el proyecto TT 2026-A155.

Por otro lado, el desarrollo del marco teórico hizo posible que se afianzaran las ideas esenciales para entender cómo funciona y cuál es el alcance del sistema propuesto. Se discutieron en esta sección temas vinculados con el comportamiento de los animales, los modelos experimentales de ansiedad, la extracción de características, las bases de datos, además de las herramientas informáticas y las metodologías utilizadas a lo largo del desarrollo. Asimismo, se examinaron los principios relacionados con la aplicación de inteligencia artificial y métodos computacionales en el estudio del comportamiento, lo que posibilitó definir criterios técnicos precisos para las etapas siguientes del proyecto.

7.2 Iteración 2

7.2.1 Validación Leave-One-Out

La validación cruzada Leave-One-Out (LOO) constituye una de las metodologías más utilizadas para evaluar la capacidad de generalización de modelos de aprendizaje automático cuando se dispone de conjuntos de datos relativamente pequeños. Kohavi describe este método como un procedimiento donde el modelo es entrenado utilizando todas las muestras disponibles excepto una, la cual es reservada exclusivamente para evaluación; posteriormente, el proceso se repite hasta que cada muestra haya sido utilizada una vez como conjunto de prueba [87]. Esta estrategia permite estimar de manera más realista el comportamiento esperado del modelo frente a datos no observados previamente, reduciendo el sesgo asociado a evaluaciones realizadas únicamente sobre datos conocidos por el sistema.

En el presente proyecto, la validación Leave-One-Out fue seleccionada debido a que el objetivo principal no consiste únicamente en determinar si el modelo aprendió correctamente los videos presentes en el conjunto de entrenamiento, sino en evaluar qué tan adecuadamente puede generalizar frente a un nuevo video o sujeto experimental no visto anteriormente. Bishop explica que los métodos de validación cruzada permiten aproximar el rendimiento esperado del sistema bajo condiciones reales de operación, particularmente en aplicaciones biomédicas y de visión computacional donde la disponibilidad de datos suele ser limitada [22].

Si se dispone de 26 videos etiquetados manualmente, el procedimiento LOO se realiza dejando fuera un video distinto en cada iteración. El modelo es entrenado utilizando los 25 videos restantes y posteriormente evaluado sobre el video excluido. Después de obtener las métricas correspondientes, el proceso se repite hasta completar las 26 iteraciones. De esta manera, cada video es evaluado exactamente una vez como un caso completamente nuevo para el sistema, garantizando una validación ciega donde el modelo nunca tiene acceso al video de prueba durante el entrenamiento [87].

Por ejemplo, en la primera iteración el modelo es entrenado utilizando los videos 2 al 26 y evaluado sobre el video 1. En la segunda iteración se entrena con los videos 1 y 3 al 26, dejando fuera el video 2 para evaluación. Este procedimiento continúa sucesivamente hasta completar todas las

combinaciones posibles. Hastie, Tibshirani y Friedman mencionan que esta metodología resulta especialmente útil cuando el número de muestras es reducido, ya que maximiza la cantidad de datos disponibles para entrenamiento sin perder rigurosidad estadística durante la evaluación [33].

7.2.2 Métricas de evaluación

Durante cada iteración de validación, el sistema genera métricas de desempeño por conducta y por modelo entrenado. Para ello, las predicciones realizadas por la inteligencia artificial son comparadas frame por frame contra las etiquetas humanas consideradas como referencia o ground truth. Sokolova y Lapalme señalan que las métricas derivadas de la matriz de confusión representan uno de los mecanismos más robustos para evaluar clasificadores binarios y multiclase, particularmente en problemas con distribuciones desbalanceadas [88].

La matriz de confusión se compone de cuatro categorías fundamentales:

- **Verdadero Positivo (TP):** el observador humano indica la presencia de la conducta y el modelo también la detecta correctamente.
- **Falso Positivo (FP):** el modelo detecta la conducta, pero la etiqueta humana indica que realmente no estaba presente.
- **Falso Negativo (FN):** la conducta se encuentra presente según la anotación humana, pero el modelo no logra detectarla.
- **Verdadero Negativo (TN):** tanto el modelo como el observador humano coinciden en la ausencia de la conducta.

Aunque los valores TN forman parte de la evaluación estadística tradicional, en este proyecto las métricas principales se centran en TP, FP y FN debido a que las conductas analizadas, como Grooming y Thigmotaxis, representan únicamente una pequeña proporción del total de frames del video. Powers explica que, en problemas altamente desbalanceados, la exactitud global puede resultar engañosa debido a la enorme cantidad de negativos correctos, generando evaluaciones artificialmente elevadas aun cuando el modelo falle en detectar los eventos de interés [89].

7.2.3 Limitaciones de exactitud como métrica principal

La métrica “accuracy” o exactitud representa la proporción total de predicciones correctas realizadas por el modelo respecto al número total de muestras evaluadas. Sin embargo, Sokolova y Lapalme destacan que esta métrica pierde confiabilidad cuando las clases positivas son considerablemente menos frecuentes que las negativas [88]. De forma similar, Powers menciona que un clasificador puede obtener valores elevados de accuracy aun siendo incapaz de detectar correctamente la clase minoritaria [89].

En el contexto de este proyecto, las conductas Grooming y Thigmotaxis ocupan únicamente un pequeño porcentaje de los frames presentes en cada video experimental. En consecuencia, un modelo que predijera constantemente la ausencia de conducta podría alcanzar porcentajes de exactitud superiores al 90%, aun siendo incapaz de detectar correctamente los eventos conductuales relevantes. Por ejemplo, si Grooming ocurre únicamente en el 8.5% de los frames, un clasificador que siempre

responda “no Grooming” obtendría aproximadamente un 91.5% de accuracy, pese a no detectar absolutamente ningún caso positivo.




Ilustración 76: Desbalance de clases [autoría propia]

Debido a esta problemática, se emplean métricas derivadas de la matriz de confusión que permiten evaluar el equilibrio entre sensibilidad y precisión del modelo. De acuerdo con la documentación oficial de Scikit-learn [90], Precisión representa la proporción de predicciones positivas correctas realizadas por el sistema:

$$P = \frac{TP}{(TP + FP)}$$

Los desarrolladores de Scikit-learn [90] describen Recall como la capacidad del modelo para detectar correctamente los casos positivos reales:

$$R = \frac{TP}{(TP + FN)}$$

Finalmente, Goodfellow, Bengio y Courville explican que el F1-score corresponde a la media armónica entre Precision y Recall, permitiendo balancear ambas métricas dentro de una única medida cuantitativa de desempeño [21]:

$$F1 = 2 \cdot \frac{P \cdot R}{P + R}$$

Goodfellow, Bengio y Courville [21] señalan que el F1-score resulta particularmente útil en problemas de clasificación desbalanceada debido a que penaliza simultáneamente falsos positivos y falsos

negativos, proporcionando una evaluación más representativa del comportamiento real del modelo que la exactitud convencional.

7.2.4 Interpretación de precision, recall y F1-Score

Las métricas Precision, Recall y F1-score permiten interpretar el desempeño del modelo desde distintas perspectivas relacionadas con la detección correcta de conductas. Sokolova y Lapalme señalan que estas métricas constituyen una de las herramientas más importantes para evaluar clasificadores binarios y multiclase, especialmente en problemas con clases desbalanceadas donde la exactitud tradicional puede resultar engañosa [88]. Asimismo, Powers explica que este tipo de métricas permite analizar simultáneamente la capacidad del modelo para detectar eventos positivos reales y evitar falsas detecciones [89].

La métrica Precision responde a la siguiente pregunta: de todos los eventos que el modelo clasificó como conducta positiva, ¿cuántos correspondían realmente a dicha conducta? De acuerdo con la documentación oficial de Scikit-learn [90], una precisión elevada implica que el sistema genera pocos falsos positivos, es decir, pocas detecciones incorrectas de conducta inexistente. En términos prácticos, un valor alto de Precision indica que el modelo evita “inventar” eventos conductuales cuando estos realmente no ocurren.

Por otro lado, Recall evalúa qué proporción de la conducta real fue detectada correctamente por el sistema. Los desarrolladores de Scikit-learn [90] describen esta métrica como una medida de sensibilidad del modelo frente a eventos positivos verdaderos. Un Recall elevado implica una baja cantidad de falsos negativos, es decir, pocos casos reales omitidos por el sistema durante la clasificación. En aplicaciones conductuales, esto resulta particularmente importante debido a que ciertos eventos pueden ser de corta duración o manifestarse mediante movimientos muy sutiles.

Finalmente, el F1-score corresponde a la media armónica entre Precision y Recall, permitiendo resumir ambas métricas en un único indicador cuantitativo. Goodfellow, Bengio y Courville mencionan que esta métrica resulta especialmente útil en tareas de clasificación desbalanceada debido a que penaliza simultáneamente falsos positivos y falsos negativos [21]. De manera complementaria, Powers [89] explica que un F1-score cercano a 1 representa un desempeño altamente consistente, mientras que valores cercanos a 0 indican un desempeño deficiente, ya sea por incapacidad para detectar la conducta o por generación excesiva de ruido y falsas alarmas.




Ilustración 75: Precisión y exhaustividad en grooming y thigmotaxis utilizando SimBA [autoría propia]

7.2.5 Funcionamiento de la validación

El proceso completo de validación Leave-One-Out fue automatizado mediante el script principal denominado:

`src/scripts/loo_full_bsoid.py`

La lógica general del pipeline consiste en seleccionar un video como conjunto de prueba o held-out, excluyéndolo completamente del entrenamiento antes de iniciar el proceso de validación. Posteriormente, el sistema realiza un respaldo temporal de los modelos productivos existentes para evitar modificaciones permanentes sobre los clasificadores principales del proyecto.

Después de ello, el script elimina temporalmente las etiquetas correspondientes al video evaluado dentro del conjunto de entrenamiento ubicado en `targets_inserted`. Una vez removidos dichos datos, se procede a reentrenar tanto el clasificador SimBA como el modelo B-SOiD utilizando únicamente los videos restantes. Posteriormente, ambos modelos generan predicciones sobre el video excluido y dichas predicciones son comparadas frame por frame contra las etiquetas humanas consideradas como ground truth.

Hastie, Tibshirani y Friedman destacan que uno de los principales riesgos durante la evaluación de modelos de aprendizaje automático es la fuga de información o data leakage, fenómeno que ocurre cuando datos de prueba participan indirectamente durante el entrenamiento [33]. Por esta razón, el sistema implementa una separación estricta entre entrenamiento y evaluación. Finalmente, el pipeline calcula automáticamente métricas de desempeño como Precision, Recall, F1-score, TP, FP y FN, para después restaurar los modelos y archivos originales del proyecto.

El procesamiento completo de los 26 videos experimentales es ejecutado mediante el script:

`src/scripts/run_loo_batch.py`

Este script automatiza todas las iteraciones Leave-One-Out y consolida los resultados finales dentro del archivo:

reportes/figuras/loo_resultados_n26.csv

Dicho archivo CSV constituye la fuente principal utilizada para generar las gráficas y tablas estadísticas presentadas dentro de la tesis.

7.2.6 Modelos evaluados y estrategias comparadas

Para la conducta Grooming se evaluaron múltiples estrategias de clasificación con el objetivo de comparar diferentes aproximaciones de análisis conductual automático.

El primer modelo corresponde a SimBA, el cual emplea un clasificador supervisado Random Forest basado en características geométricas derivadas de pose y movimiento. Breiman describe Random Forest como un método de aprendizaje basado en conjuntos de árboles de decisión capaz de reducir el sobreajuste y mejorar la capacidad de generalización del modelo [32]. De manera complementaria, Hastie, Tibshirani y Friedman [33] explican que los métodos ensemble basados en árboles resultan particularmente robustos frente a datos complejos y variables altamente correlacionadas.

El segundo enfoque corresponde a B-SOiD, sistema orientado al descubrimiento y clasificación de motivos conductuales a partir de patrones de postura y movimiento derivados de pose estimation. Sun et al. mencionan que los sistemas modernos de análisis conductual basados en pose permiten modelar relaciones espaciales y temporales complejas entre distintas regiones corporales del animal [45].

Además de evaluar ambos sistemas de manera individual, se implementaron estrategias híbridas tipo ensemble. La primera estrategia denominada Ensemble OR considera que existe Grooming si cualquiera de los dos modelos detecta la conducta. Por otra parte, la estrategia Conditional utiliza SimBA como clasificador principal y activa B-SOiD únicamente cuando las predicciones de SimBA presentan señales de degradación o colapso estadístico. Finalmente, la estrategia Dynamic implementa un comportamiento adaptativo basado en la distribución temporal de predicciones generadas por ambos modelos.

Para la conducta Thigmotaxis, SimBA presentó consistentemente un mejor desempeño debido a que dicha conducta depende principalmente de variables espaciales y geométricas relacionadas con la posición del animal dentro del laberinto. Pereira y Moita explican que las conductas altamente espaciales suelen ser más fáciles de modelar mediante características geométricas derivadas de visión computacional [16]. Asimismo, Mobbs et al. relacionan este comportamiento con mecanismos naturales de evitación y proximidad defensiva a bordes o zonas protegidas [40].

7.2.7 Resultados principales del experimento

Los resultados consolidados del experimento Leave-One-Out con $N = 26$ videos muestran diferencias importantes entre las estrategias evaluadas. Para Grooming, el modelo SimBA obtuvo un F1-score aproximado de 0.400, mientras que B-SOiD alcanzó un valor cercano a 0.357. La estrategia Ensemble

OR incrementó el desempeño hasta aproximadamente 0.502, mientras que el mejor resultado fue obtenido mediante el enfoque Conditional, alcanzando un F1-score cercano a 0.523.

En contraste, para la conducta Thigmotaxis el mejor desempeño fue obtenido directamente por SimBA con un F1-score aproximado de 0.636. B-SOiD mostró un desempeño considerablemente inferior, cercano a 0.318, mientras que Ensemble OR obtuvo aproximadamente 0.332.

La interpretación general de estos resultados indica que las estrategias híbridas y ensembles aportan beneficios importantes para la detección de Grooming debido a la complejidad y variabilidad de dicha conducta. Según Brandão [42], las conductas defensivas y de autocuidado presentan patrones motores altamente variables entre individuos. De forma similar, Klaassen et al. [43] señalan que las respuestas conductuales relacionadas con estrés y ansiedad pueden cambiar significativamente dependiendo del contexto experimental y del sujeto evaluado.




Ilustración 72: Desempeño de detección de grooming por SimBA, B-SOiD y Ensemble OR [autoría propia]

7.2.8 Uso de F1-score

Durante el análisis estadístico se identificó que algunos videos experimentales no contenían frames positivos correspondientes a determinadas conductas. Por ejemplo, ciertos videos podían no contener episodios reales de Grooming. Powers explica que, bajo condiciones altamente desbalanceadas, algunas métricas pueden producir valores artificialmente bajos incluso cuando el modelo no presenta errores reales de clasificación [89].

Debido a esta situación, se reportaron dos variantes distintas de promedio estadístico:

1. F1-score promedio general: incluye todos los videos evaluados.
2. F1-score promedio justo: excluye videos donde no existían ejemplos positivos reales de la conducta.

El uso de F1-score justo permite evaluar únicamente escenarios donde efectivamente existía conducta que detectar, proporcionando una interpretación más representativa del desempeño real del sistema. Esta estrategia evita penalizaciones artificiales derivadas de la ausencia total de eventos positivos dentro de ciertos videos experimentales.


Ilustraci?n 73: Distribuci?n del F1 de grooming por m?todo sobre 13 videos [autoría propia]

7.2.9 Interpretaci?n de los resultados

Los resultados obtenidos sugieren que el principal cuello de botella del sistema no corresponde al seguimiento espacial del animal, sino a la interpretaci?n semántica de conductas complejas. Redmon et al. describen YOLO como una arquitectura capaz de realizar detecci?n de objetos en tiempo real con alta precisi?n espacial [13]. De manera similar, Sharma et al. reportan desempeños elevados de arquitecturas YOLO modernas en tareas de detecci?n animal y reconocimiento visual [55]. En este proyecto, el sistema de pose estimation basado en YOLO present? un desempe?o elevado con valores de mAP50 cercanos a 0.995, indicando una localizaci?n altamente precisa del rat?n y sus keypoints corporales.

No obstante, la clasificaci?n conductual present? mayor dificultad, particularmente para Grooming. Pereira y Moita explican que las conductas complejas y sutiles representan uno de los principales desaf?os en etolog?a computacional debido a la gran variabilidad motora existente entre animales [16]. Adem?s, Grooming involucra movimientos de baja amplitud, microajustes corporales y m?ltiples regiones anatómicas, incluyendo cara, vibrisas, patas delanteras y cuerpo.

En contraste, Thigmotaxis representa una conducta predominantemente geométrica y espacial, relacionada con la cercan?a del animal respecto a paredes y bordes del laberinto. Ball y Gunaydin describen este comportamiento como un patr?n cl?sico asociado a respuestas de ansiedad y evitaci?n defensiva [41]. Debido a ello, resulta considerablemente m?s sencillo de modelar mediante caracter?sticas espaciales derivadas de visi?n computacional [16][39].



Ilustraci?n 74: Comparaci?n de grooming y thigmotaxis en SimBA [autoría propia]

7.2.10 Casos de estudio representativos

El caso correspondiente al video R6B20 mostró un comportamiento particularmente relevante durante la evaluación experimental. En este caso, SimBA obtuvo un F1-score igual a 0.000 para Grooming, mientras que la estrategia Conditional logró incrementar el desempeño hasta aproximadamente 0.346. Para Thigmotaxis, SimBA alcanzó un F1-score cercano a 0.751. Este resultado demuestra que algunos animales pueden generar patrones conductuales suficientemente distintos como para provocar colapsos en clasificadores individuales, mientras que las estrategias híbridas logran rescatar parcialmente la capacidad de detección.




Ilustración 77: Ensemble condicional y otras alternativas en comparación [autoría propia]

Por otro lado, el caso R6C mostró un escenario diferente. Tanto SimBA como Conditional alcanzaron un F1-score cercano a 0.668 para Grooming, mientras que SimBA obtuvo aproximadamente 0.638 en Thigmotaxis. Este comportamiento evidencia que la estrategia Conditional no perjudica el desempeño cuando SimBA ya presenta una clasificación adecuada.

7.2.11 Ground Truth y anotaciones humanas

Las anotaciones humanas utilizadas como ground truth se encuentran integradas directamente dentro de los archivos CSV almacenados en:

data/simba_projects/grooming_thigmotaxis_yolo/project_folder/csv/targets_inserted/

En total, se confirmó la existencia de 52 archivos CSV, correspondientes a 26 videos reales y 26 versiones aumentadas mediante espejado horizontal (mirror augmentation). Cada archivo contiene simultáneamente las características calculadas por SimBA y YOLO, incluyendo coordenadas corporales, distancias, movimiento, zonas espaciales y proximidad a paredes, así como las etiquetas humanas correspondientes a Grooming y Thigmotaxis.

Cada fila representa un frame individual del video experimental. Las columnas finales denominadas Grooming y Thigmotaxis contienen las etiquetas binarias utilizadas como referencia experimental:

0 = ausencia de conducta.

1 = presencia de conducta.

Kohavi explica que en esquemas Leave-One-Out es fundamental garantizar que las muestras de prueba permanezcan completamente separadas del entrenamiento para evitar sesgos en la evaluación estadística [87]. Por esta razón, durante el proceso Leave-One-Out el script elimina temporalmente el archivo CSV correspondiente al video evaluado del directorio `targets_inserted`, evitando que SimBA utilice sus etiquetas humanas durante el entrenamiento. Posteriormente, el sistema predice sobre dicho video y compara las predicciones generadas contra las columnas originales de ground truth únicamente durante la fase de evaluación. Este procedimiento fortalece la validez experimental y estadística del sistema [33][87].

7.3 Iteración 3

Durante la tercera iteración, se hicieron múltiples cambios para análisis conductual automatizado. Estos cambios se representan de la siguiente forma:

7.3.1 Adquisición y normalización de video

Esta capa recibe los videos experimentales y ejecuta un proceso de normalización espacial y temporal. Todos los videos son convertidos y procesados en resolución mínima de 1280×720 píxeles (720p), manteniendo una frecuencia constante de cuadros por segundo.

La decisión de establecer 720p como resolución mínima responde a criterios técnicos derivados de la detección de puntos clave corporales. Modelos de estimación de pose como YOLO Pose dependen directamente de la resolución espacial para localizar estructuras anatómicas pequeñas, tales como hocico, orejas, base de cola y extremidades. Redmon et al. señalan que la precisión de detección decrece significativamente cuando la resolución reduce el número de píxeles disponibles para representar objetos pequeños [91]. De manera complementaria, la documentación oficial de Ultralytics establece que la detección robusta depende de conservar suficiente detalle espacial para evitar pérdida de información contextual durante el escalamiento de entrada [92].

En el contexto etológico, comportamientos como grooming involucran micro-movimientos de amplitud reducida, mientras que la tigmotaxis requiere precisión posicional respecto al perímetro del laberinto. Una resolución inferior introduce solapamiento espacial y pérdida de detalle, afectando la localización precisa del sujeto experimental. Bovet y Benhamou demostraron que la precisión espacial resulta crítica para la cuantificación confiable de trayectorias locomotoras en paradigmas de ansiedad [93].

7.3.2 Extracción de pose

Se consolidó el uso de YOLO Pose v4 como backend principal para la estimación corporal.

Esta capa transforma cada frame en un vector estructurado de coordenadas:

$$P_t = (x_1, y_1)(x_2, y_2), \dots, (x_n, y_n)$$

donde:

P_t : conjunto de puntos clave en el instante (t).

n: número total de keypoints anatómicos.

La reducción del tiempo de procesamiento de aproximadamente 5 horas a 3 minutos por video fue consecuencia directa de la optimización GPU y del procesamiento paralelo, consistente con las mejoras reportadas para detectores de una sola etapa considerando que se utiliza una RTX 5070 Ti [91].

Este enfoque permite detectar al sujeto experimental en tiempo real, estimar su posición espacial dentro del laberinto y generar las trayectorias necesarias para el posterior análisis conductual [21].

Cada fotograma de entrada corresponde a una imagen con resolución original de:

$$I \ni R^{720 \cdot 1080 \cdot 3}$$

donde:

- 720: número de píxeles verticales.
- 1280: número de píxeles horizontales.
- 3: canales de RGB.

Cada píxel tiene una representación matemática:

$$p_{ij} = (r_{ij}, g_{ij}, b_{ij})$$

donde cada variable constituye las intensidades discretas de color.

Para normalizar la información y favorecer la estabilidad numérica durante el entrenamiento, los valores son reescalados:

$$p'_{ij} = \frac{p_{ij}}{255}$$

de forma que:

$$p'_{ij} \in [0,1]$$

Este proceso reduce variaciones numéricas extremas y mejora la convergencia del descenso por gradiente. Posteriormente, la imagen se redimensiona a:

$$I' \ni R^{640 \cdot 640 \cdot 3}$$

Dentro de esa redimensión, cada píxel pasa por el siguiente proceso:

$$x' = x \cdot \frac{640}{1280}$$

$$y' = y \cdot \frac{640}{720}$$

donde:

- x, y : coordenadas originales del fotograma (frame).
- x', y' : coordenadas transformadas.

Este mapeo constituye una transformación afín que preserva la correspondencia relativa entre posiciones espaciales. La elección de una resolución cuadrada responde a la necesidad de compatibilidad con la arquitectura convolucional y permite un balance adecuado entre precisión espacial y eficiencia computacional [21].

El núcleo matemático de YOLO está compuesto por capas convolucionales sucesivas.

Cada convolución se define como:

$$F_{i,j}^{(l)} = \sum_{u=-k}^k \sum_{v=-k}^k W_{u,v}^{(l)} X_{i+u,j+v}^{(l-1)} + b^{(l)}$$

donde:

- $X^{(l-1)}$: entrada a la capa por la capa anterior.
- $W^{(l)}$: kernel convolucional.
- $b^{(l)}$: sesgo.

$F_{i,j}^{(l)}$ es la activación de la salida del píxel en su respectiva coordenada que contiene el conjunto de representación del objeto por buscar, así como contornos, bordes, figuras, orientación y posturas. $W_{u,v}^{(l)}$ es el filtro convolucional en donde se hace una matriz donde se determinan los pesos del filtro convolucional, lo anterior detecta bordes, contornos y esquinas. $X_{i+u,j+v}^{(l-1)}$ representa el valor de entrada de la capa anterior con sus respectivos desplazamientos verticales y horizontales. Mientras tanto, la doble sumatoria es el recorrido de todos los elementos del filtro considerando el valor k . Finalmente, se hace la sumatoria de las multiplicaciones de cada píxel por su peso.

Después, se utiliza una función de activación no lineal que transforma la salida del píxel en su respectiva coordenada a la siguiente capa.

$$A_{i,j}^{(l)} = \sigma(F_{i,j}^{(l)})$$

También se emplea la función SiLu que permite transiciones suaves y pérdida de gradientes:

$$\sigma(x) = x \cdot \frac{1}{1 + e^{-x}}$$

donde:

- x : la entrada de la función.
- $\frac{1}{1+e^{-x}}$: sigmoide donde los valores van de 0 a 1.

A medida que la imagen atraviesa las capas convolucionales de la red, su resolución espacial disminuye progresivamente mediante operaciones de pooling (agrupamiento) y convoluciones con desplazamiento (stride). Esta reducción se expresa como:

$$H_l = \frac{H_{l-1}}{s}$$

$$W_l = \frac{W_{l-1}}{s}$$

donde:

- H_l : altura de la capa.
- W_l : ancho de la capa.
- H_{l-1} : altura de la capa anterior.
- W_{l-1} : ancho de la capa anterior.
- s : desplazamiento del filtro.

El parámetro s determina cuántos píxeles avanza el filtro en cada operación convolucional. Cuando $s > 1$, se reduce la resolución espacial, lo que permite disminuir el costo computacional y concentrar la información más relevante [21].

Esta reducción incrementa simultáneamente el campo receptivo efectivo:

$$R_l = R_{l-1} + (k - 1) \prod_{m=1}^{l-1} s_m$$

donde:

- R_l : campo receptivo en la capa.
- R_{l-1} : campo receptivo de la capa anterior.
- k : tamaño del kernel convolucional.
- s_m : desplazamiento aplicado a la capa previa.

El campo receptivo representa la región original de la imagen que influye en una activación específica. Su incremento permite que el modelo integre información contextual más amplia del entorno experimental, facilitando la identificación de configuraciones espaciales complejas asociadas a patrones conductuales [21].

Una vez procesada la imagen, se divide el espacio visual en una cuadrícula de tal forma que:

$$S \times S$$

donde S representa el número de divisiones por eje.

Para una configuración experimental cada celda posee un cierto número de dimensiones que se representa como: La ecuación completa constituye lo siguiente:

$$g_{ij} = \left[\frac{iW}{S}, \frac{(i+1)W}{S} \right] \cdot \left[\frac{jH}{S}, \frac{(j+1)H}{S} \right]$$

donde:

- W : ancho total de la imagen.
- H : altura total de la imagen.
- i : índice horizontal.
- j : índice vertical.

Finalmente, para asignar formalmente la detección del ratón, se usa esta ecuación donde:

$$(x_c, y_c) \in g_{ij}$$

- (x_c, y_c) : coordenadas del centro geométrico del objeto.

Hay que tomar en cuenta que cada celda predice una caja delimitadora definida como:

$$B = (x, y, w, h, c)$$

donde:

- x : coordenada horizontal.
- y : coordenada vertical.
- w : ancho de la caja.
- h : altura de la caja.
- c : confianza de detección.

Las coordenadas se normalizan respecto al tamaño de la celda:

$$x, y \in [0,1]$$

$$w, h \in [0,1]$$

Para reconstruir la localización absoluta, se utilizan las siguientes operaciones:

$$x_{abs} = x_{cell} + x \cdot cell_w$$

$$y_{abs} = y_{cell} + y \cdot cell_h$$

$$w_{abs} = w \cdot W$$

$$h_{abs} = h \cdot H$$

donde:

- x_{cell}, y_{cell} : coordenadas de la celda.
- $cell_w, cell_h$: dimensiones de la celda.
- W, H : dimensiones de la imagen.

Estas transformaciones permiten localizar con precisión al sujeto dentro del fotograma original. Sin embargo, queda pendiente el porcentaje de confianza. La confianza de detección se define como:

$$c = P(Object) \cdot IoU$$

donde:

- $P(Object)$: probabilidad de presencia del objeto.
- IoU : coincidencia espacial entre predicción y referencia.

La probabilidad se calcula mediante función logística de la siguiente forma:

$$P(Object) = \sigma(z)$$

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

donde:

- z : activación previa de la neurona.
- $\sigma(z)$: probabilidad transformada.

Esta función convierte valores reales arbitrarios en probabilidades dentro del intervalo [0,1]. Sin embargo, para obtener z , YOLO ejecuta la siguiente fórmula:

$$z = \sum_{r=1}^n w_r A_r + b$$

donde:

- w_r : pesos adquiridos.
- A_r : activaciones de neuronas.
- b : sesgo.

Otra de las cosas para obtener el porcentaje de confianza es el *IoU* (intersección sobre la unión) es por la métrica de superposición espacial:

$$IoU = \frac{|B_p \cap B_r|}{|B_p \cup B_r|}$$

donde:

- B_p : caja predicha.
- B_r : caja real.

$$IoU = \frac{A_{intersección}}{A_p + A_r - A_{intersección}}$$

donde:

- $A_{intersección}$: área compartida.
- A_p : área predicha.
- A_r : área real.

El IoU cuantifica la precisión espacial de la localización del objeto y sirve para obtener el porcentaje de confianza.

Una vez detectado el objeto, el modelo calcula:

$$P(c_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

donde:

- $P(c_i)$: probabilidad de pertenencia a la clase requerida.
- z_i : activación logit, valor bruto que produce una neurona.
- K : número total de clases.

Esta función garantiza interpretar la salida como distribución probabilística:

$$\sum_{i=1}^K P(c_i) = 1$$

Sin embargo, también se tiene una función de pérdida global donde el entrenamiento optimiza:

$$L = L_{loc} + L_{size} + L_{conf} + L_{cls}$$

donde:

- L_{loc} : error de localización.
- L_{size} : error de tamaño.
- L_{conf} : error de confianza.
- L_{cls} : error de clasificación.

Con las siguientes operaciones de error de localización se penalizaron los errores de posicionamiento inicial:

$$L_{loc} = \lambda_{coord} \sum [(x - \hat{x})^2 + (y - \hat{y})^2]$$

donde:

- x, y : coordenadas reales.
- $\hat{x}, \hat{y}$: coordenadas predichas.
- λ_{coord} : factor de ponderación.

El error de tamaño reduce sensibilidad a errores en cajas grandes

$$L_{size} = \lambda_{coord} \sum [(\sqrt{w} - \sqrt{\hat{w}})^2 + (\sqrt{h} - \sqrt{\hat{h}})^2]$$

donde:

- w, h : anchura y altura reales.
- $\hat{w}, \hat{h}$: anchura y altura predichas.

El error de confianza determina si un objeto, en esencia, está en una celda:

$$L_{conf} = \sum (c - \hat{c})^2$$

donde:

- c : confianza real.
- $\hat{c}$: confianza predicha.

La pérdida de clasificación, mejor conocida como entropía cruzada, sirve para medir qué tan bien las clases son detectadas:

$$L_{cls} = - \sum y_i \log(\hat{y}_i)$$

donde:

- y_i : etiqueta real.
- $\hat{y}_i$: etiqueta predicha.

Este procedimiento minimiza el error global durante el análisis. También es la forma en la cual el modelo aprende. Los parámetros se actualizan mediante descenso de gradiente:

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L(\theta_t)$$

donde:

- θ_t : parámetros actuales.
- θ_{t+1} : parámetros actualizados.
- η : tasa de aprendizaje.
- $\nabla_{\theta} L$: gradiente de la pérdida.

La supresión no máxima es una etapa que se ejecuta después del proceso para evitar duplicado de cajas. Dado un conjunto de predicciones (cajas):

$$B_1, B_2, \dots, B_n$$

se selecciona:

$$B^* = \arg \max Score(B_i)$$

donde:

- $Score(B_i)$: puntuación de confianza.

Las cajas se ordenan de forma descendente por nivel de confianza y se aplica una métrica de superposición especial. Posteriormente se descartan cajas si:

$$IoU(B_i, B^*) > \tau$$

donde:

- τ : umbral de supresión.

Finalmente, la posición del objeto en cada instante es detectada por trayectorias temporales:

$$(x_t, y_t)$$

donde:

- x_t : coordenada horizontal en el tiempo.
- y_t : coordenada vertical en el tiempo.

La trayectoria total de una secuencia de posiciones del mismo objeto es:

$$T = (x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

A partir de esta secuencia se calcula la velocidad:

$$v_t = \frac{\sqrt{(x_t - x_{t-1})^2 + (y_t - y_{t-1})^2}}{\Delta t}$$

donde:

- v_t : velocidad instantánea.
- Δt : intervalo temporal.

Asimismo, el tiempo de permanencia regional se calcula como:

$$Time(R) = \sum_{t=1}^n 1[(x_t, y_t) \in R]$$

donde:

- R : región espacial.
- $1[(x_t, y_t) \in R]$: función indicadora.

Estas variables permiten cuantificar dinámicas espaciales y temporales relevantes para la clasificación conductual final donde se puede determinar por qué parte del píxel ha pasado un objeto.

7.3.3 Capa de clasificación primaria

Sobre los vectores pose-estimativos se ejecuta un clasificador Random Forest, inspirado en la arquitectura implementada por SimBA. Breiman demuestra que Random Forest ofrece alta robustez frente a ruido y buena capacidad de generalización en clasificación multivariada [94].

El clasificador produce una predicción binaria para cada conducta:

$$\hat{y}_t \in 0,1$$

7.3.4 Capa de rescate temporal basada en LSTM

Para resolver el fenómeno de flickering (detecciones intermitentes en secuencias cortas), se integró una arquitectura recurrente LSTM que procesa ventanas temporales de 45 frames. Hochreiter y Schmidhuber demostraron que las LSTM son capaces de modelar dependencias temporales largas y mantener memoria contextual [95].

La operación interna puede expresarse como:

$$h_t = LSTM(x_t, h_{t-1})$$

donde:

x_t : secuencia de entrada.

h_t : estado oculto temporal.

Esto permite rescatar eventos breves que un clasificador frame por frame podría perder.

7.3.5 Determinación del tamaño de muestra

Con base en principios de cobertura distribucional en aprendizaje supervisado [21], así como en metodologías de curvas de aprendizaje para evaluación de convergencia [104], se plantea una expansión progresiva del conjunto de entrenamiento. El tamaño final no se fija como una constante absoluta, sino que se determinará empíricamente mediante incrementos sucesivos del corpus, evaluando en cada etapa la estabilización del F1-score bajo validación Leave-One-Out [87].

Este criterio permite identificar el punto en el cual la incorporación de nuevos videos produce mejoras marginales mínimas, indicando una cobertura suficiente de la variabilidad biológica, espacial y contextual de las conductas analizadas [96]. Como meta inicial, se estima que un rango de 60 a 80 videos reales podría aproximar dicha condición de saturación.

Con base en principios de cobertura distribucional en aprendizaje supervisado [21], así como en metodologías de curvas de aprendizaje para evaluación de convergencia [104], se plantea una expansión progresiva del conjunto de entrenamiento.

Sea N_k el número acumulado de videos incorporados en la iteración k y $F_1(N_k)$ el desempeño del clasificador medido mediante validación Leave-One-Out. La evolución del sistema puede modelarse mediante una función de aprendizaje:

$$F_1 = f(N)$$

donde:

N : tamaño de la muestra o corpus.

F_1 : desempeño obtenido para dicho tamaño muestral.

Con base en el capítulo 7.2.3, se obtienen los resultados para precision, recall y F1-Score. El tamaño final del conjunto no se fija como una constante absoluta, sino que se determinará empíricamente mediante incrementos sucesivos de los corpus definidos como:

$$N_k = N_0 + k\Delta N$$

donde:

N_0 : tamaño inicial del conjunto.

ΔN : número de videos añadidos por iteración.

k : índice de expansión.

En cada incremento, se evaluará la mejora marginal del desempeño mediante:

$$\Delta F_1^{(k)} = F_1^{(k)} - F_1^{(k-1)}$$

Este criterio permite identificar el punto de saturación distribucional cuando:

$$|\Delta F_1^{(k)}| < \varepsilon$$

durante múltiples iteraciones consecutivas, donde ε representa un umbral mínimo de mejora aceptable. Esta condición indica que la incorporación de nuevos videos produce ganancias marginales despreciables, señalando una cobertura suficiente de la variabilidad biológica, espacial y contextual de las conductas analizadas [96][104].

Desde una perspectiva teórica, esta convergencia puede aproximarse mediante un comportamiento asintótico:

$$F_1(N) = F_{1,max}(1 - e^{-\lambda N})$$

donde:

$F_{1,max}$: representa el desempeño máximo alcanzable.

λ : tasa de convergencia del aprendizaje.

Bajo este marco, el tamaño óptimo del conjunto se define como:

$$N^* = \min \left\{ N: \frac{dF_1}{dN} < \varepsilon \right\}$$

Esto significa el número de videos necesarios para alcanzar un desempeño aceptable.

A partir del cálculo del F1-score acumulativo mediante micro-promedio para las clases Grooming y Thigmotaxis, se observó que la secuencia de desempeño presenta un comportamiento no monótono. En particular, se identificó un valor máximo local de $F_1 = 0.525$ para Grooming con 14 videos, mientras que el valor final obtenido al incorporar los 26 videos disponibles descendió a $F_1 = 0.460$. Este comportamiento sugiere la existencia de una alta variabilidad entre muestras y evidencia que el conjunto actual aún no garantiza estabilidad estadística del aprendizaje.

Para modelar la evolución esperada del desempeño al incrementar el tamaño del conjunto de entrenamiento, se empleó un modelo exponencial saturante descrito por:

$$F_1(N) = F_{1,max}(1 - e^{-\lambda N})$$

Considerando un valor estimado de $F_{1,max} = 0.55$ y una tasa ($\lambda=0.03$), obtenida a partir de la pendiente media observada durante las primeras iteraciones, se proyecta una mejora progresiva del desempeño hasta alcanzar valores cercanos al límite superior conforme aumenta el número de muestras.

Bajo este ajuste, los valores proyectados indican que para 100 videos el F1-score esperado sería aproximadamente 0.546, mientras que para 120 videos alcanzaría 0.551. La diferencia entre ambos escenarios corresponde a una mejora marginal de apenas 0.005, lo que sugiere una aproximación al régimen de saturación.

El criterio de saturación adoptado se definió mediante un umbral de mejora marginal:

$$\varepsilon = 0.00$$

y un requisito de persistencia durante tres iteraciones consecutivas:

$$r = 3$$

De acuerdo con este criterio, la saturación se considera alcanzada cuando la mejora incremental del F1-score permanece por debajo del 0.5 % durante al menos tres incorporaciones sucesivas de nuevos videos. La aplicación de este criterio al modelo proyectado indica que esta condición se satisface a partir de aproximadamente 110 videos.

De manera complementaria, se analizó la convergencia asintótica de la curva mediante su derivada:

$$\frac{dF_1}{dN} = F_{1,\max} \lambda e^{-\lambda N}$$

Estableciendo como condición de convergencia una pendiente inferior a 5×10^{-4} , se obtuvo una solución aproximada de:

$$N > 116.5$$

lo que indica que, a partir de 117 videos, la tasa de mejora se vuelve prácticamente despreciable, reflejando una estabilización efectiva del aprendizaje.

Por lo tanto, se concluye que el corpus actual de 26 videos resulta insuficiente para garantizar saturación distribucional, justificándose formalmente la expansión progresiva del conjunto experimental hasta una horquilla comprendida en 117 videos.

7.3.6 Módulo de comparación estadística

Este módulo recibe los tiempos conductuales acumulados y calcula estadísticos descriptivos e inferenciales para comparar grupos experimentales. Dichos tiempos conductuales acumulados son:

- Brazos abiertos.
- Brazos cerrados.
- Centro.
- Grooming.
- Tigmotaxis.

El criterio mínimo operativo para comparación estadística se estableció en:

$$n = 6 \text{ a } 8 \text{ videos por grupo}$$

con dos grupos:

$$N_{total} = 12 \text{ a } 16$$

Esto es consistente con tamaños muestrales frecuentemente empleados en estudios conductuales de laberinto elevado [97].

Cada comparación utiliza grupos balanceados:

$$n_1 = n_2$$

con:

$$n \in 6,7,8$$

No se permiten comparaciones desbalanceadas porque introducen heterocedasticidad y sesgo en pruebas paramétricas [100]. En todo caso, esto significa que, por ejemplo; no se puede comparar un grupo con 6 videos mientras que otro grupo tiene una cantidad de videos diferentes a 6.

La media para representar tiempo promedio conductual en todos los brazos, así como en el centro y los momentos de las poses de grooming y thigmotaxis [101]. Con esto, se representa el tiempo promedio de permanencia en las zonas. La fórmula para la media consiste en:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

donde:

n: número de videos del grupo.

x_i : tiempo registrado en el video i .

La desviación estándar cuantifica cuánto varían los tiempos individuales respecto al promedio [101].

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

donde:

$x_i - \bar{x}$: desviación individual respecto a la media.

$n - 1$: corrección de Bessel para estimación muestra.

Una desviación baja sugiere una consistencia conductual en especímenes mientras que una desviación alta indica variación de conductas.

El error estándar de la media estima la precisión de la media como estimador poblacional [101].

$$SEM = \frac{s}{\sqrt{n}}$$

donde:

s : desviación estándar de un grupo.

n : número de videos del grupo.

Esto indica la incertidumbre asociada a la estimación del promedio conductual.

Los valores mínimo y máximo definen los límites observados del comportamiento registrado:

$$x_{min} = \min(x_i)$$

$$x_{max} = \max(x_i)$$

Para una comparación entre grupos, se utilizan diferentes pruebas.

La prueba t de Student se utiliza para comparar resultados entre dos grupos con el fin de evaluar diferencia significativa entre medias [102].

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

donde:

$\bar{x}_1, \bar{x}_2$: medias de los grupos.

s_1^2, s_2^2 : varianzas.

n_1, n_2 : número de videos de los grupos.

ANOVA se usa con el fin de comparar múltiples grupos con el fin de evaluar si existe un tratamiento global [102].

$$F = \frac{MS_{between}}{MS_{within}}$$

donde:

$MS_{between}$: variabilidad entre grupos.

MS_{within} : variabilidad interna.

La prueba de d de Cohen cuantifica la magnitud del efecto:

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_p}$$

donde:

d : tamaño del efecto.

$\bar{x}_1, \bar{x}_2$: medias de los grupos.

s_p : derivación estándar combinada.

con la desviación estándar combinada cuya función es normalizar la diferencia entre medias considerando la variabilidad conjunta de ambos grupos [102].

$$s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$$

donde:

n_1, n_2 : número de vídeos de los grupos.

s_1^2, s_2^2 : varianzas.

La interpretación de la d de Cohen puede dar los siguientes resultados [103]:

- 0.2: existe una diferencia cuya magnitud no es ampliada.
- 0.5: existe una diferencia significativa cuya magnitud sugiere un efecto conductual apreciable.
- 0.8: existe una gran diferencia cuya magnitud sugiere un efecto conductual bastante detectable.

7.3.7 Paso 1 – Acceso al sistema

El usuario accede a la aplicación Streamlit a través de un navegador web en la dirección de red local donde está desplegado el servidor. Introduce sus credenciales en la página de inicio de sesión. Si la autenticación de dos factores está habilitada, recibirá un código OTP en su correo institucional que deberá ingresar para completar el acceso.

En el caso donde solo se inicie sesión con las credenciales correctas (correo institucional y contraseña) y estas sean correctas, el acceso al sistema será otorgado.

El formulario de inicio de sesión está contenido dentro de un recuadro con un fondo gris claro. En la parte superior, el texto "Correo Electrónico Institucional" precede a un campo de entrada con un fondo azul claro que contiene el texto "@alumno.ipn.mx". Debajo de esto, el texto "Contraseña" precede a un campo de entrada con puntos grises para ocultar el texto y un ícono de ojo para alternar la visibilidad. En la parte inferior del formulario, hay un botón rectangular con un borde rojo y el texto "ENTRAR DE FORMA SEGURA" en letras mayúsculas.

Ilustración 78: Ejemplo de inicio de sesión básico [autoría propia]

Si las credenciales son correctas, un mensaje en verde con la leyenda “identificación exitosa” aparecerá antes de mostrar la sección general del sistema.




Ilustración 79: Mensaje de inicio de sesión exitoso [autoría propia]




Ilustración 80: Vista general del sistema [autoría propia]

En caso de que el correo institucional ingresado o la contraseña sean incorrectos, el acceso será denegado y un mensaje en rojo con la leyenda “credenciales incorrectas o cuenta inactiva” aparecerá. También el mismo mensaje puede aparecer si la cuenta ha sido inhabilitada.




Ilustración 81: Mensaje de inicio de sesión con error [autoría propia]

7.3.8 Paso 2 – Ingesta del video

En la página de ingesta, el usuario:

- a. Ingresa a la sección de “Ingesta de vídeo”.



Ilustración 82: Botón para acceder a la sección de ingesta de video [autoría propia]

Ilustración 83: Vista general la sección de ingesta de video [autoría propia]

- b. Selecciona el archivo de video desde su equipo local.

Ilustración 84: Espacio para seleccionar archivo .mp4, .mov o .avi [autoría propia]




Ilustración 85: Selección de archivo de video [autoría propia]




Ilustración 86: Carga de video [autoría propia]

c. Registra los datos del experimento (identificador del animal, fecha).

Parametros del Registro

ID del Registro	Fecha del Experimento
R5DZ_01mar24	2024/05/13
ID del Tratamiento	Responsable
Control	Gabriella Lázaro Oliver

> Añadir Nuevo Tratamiento

Ilustración 87: Registro de datos del experimento [autoría propia]



Ilustración 88: Botón de preparación de video [autoría propia]

d. Revisa la duración del video.




Ilustración 89: Duración del vídeo [autoría propia]

e. Confirma la ingesta para continuar.



Ilustración 90: Botón de guardado de parámetros del vídeo [autoría propia]




Ilustración 91: Botón de guardado de continuar al módulo de keypoints [autoría propia]

7.3.9 Paso 3 – Extracción de keypoints

El usuario inicia el proceso de extracción desde la página de Keypoints. El sistema lanza YOLO Pose en segundo plano y muestra los logs de avance en tiempo real. En las pruebas internas, esta etapa se redujo de un orden de horas con DeepLabCut a un orden de minutos con YOLO Pose. Una vez finalizado, el sistema notifica al usuario y habilita la continuación al siguiente paso.




Ilustración 92: Vista general del módulo de keypoints [autoría propia]




Ilustración 93: Botón de inicio de extracción de keypoints [autoría propia]




Ilustración 94: Consola de comandos abierta al iniciar la extracción de keypoints [autoría propia]



Ilustración 95: Pantalla de carga mostrada durante la extracción de keypoints con advertencias del proceso [autoría propia]



Ilustración 96: Consola de comandos mostrada en el sistema durante la extracción de keypoints [autoría propia]



Ilustración 97: Consola de comandos mostrando salida con éxito después de la extracción de keypoints [autoría propia]

7.3.10 Paso 4 – Configuración de zonas del EPM

El usuario ajusta las coordenadas de las zonas del EPM para el video. El sistema ofrece una configuración predeterminada basada en plantillas, que el usuario puede modificar mediante controles en la interfaz. Las zonas se guardan y sincronizan automáticamente con el proyecto SimBA activo.



Ilustración 98: Acceso al módulo de configuración de zonas [autoría propia]



Ilustración 99: Vista general del módulo de configuración de zonas [autoría propia]



Ilustración 100: Apartado de herramientas de definición de zonas [autoría propia]



Ilustración 101: Apartado de lienzo. Los brazos abiertos (morado), brazos cerrados (gris), centro (gris claro) y muro (naranja) deben ser dibujados [autoría propia]

Zonas Detectadas

Las coordenadas proporcionadas abajo se quedaron convertidas a la resolución real del video.

Nombre Zona	Tipos	Geometría	left	top	width	height	x1	y1	x2	y2
Brazo Abierto 1	Brazo Abierto	Rectángulo	606	14	60	203	None	None	None	None
Brazo Abierto 2	Brazo Abierto	Rectángulo	602	368	72	239	None	None	None	None
Brazo Cerrado 1	Brazo Cerrado	Rectángulo	218	282	382	106	None	None	None	None
Brazo Cerrado 2	Brazo Cerrado	Rectángulo	675	299	263	88	None	None	None	None
Centro	Centro	Rectángulo	858	301	75	74	None	None	None	None
Pared 1	Muro / Pared	Línea	None	None	None	None	221	283	579	298
Pared 2	Muro / Pared	Línea	None	None	None	None	222	299	221	316
Pared 3	Muro / Pared	Línea	None	None	None	None	222	374	587	379
Pared 4	Muro / Pared	Línea	None	None	None	None	682	296	1005	301
Pared 5	Muro / Pared	Línea	None	None	None	None	1006	299	1009	373

Ilustración 102: Tabla de características de zonas detectadas [autoría propia]



Ilustración 103: Botón de guardado de configuración del experimento [autoría propia]

Configuración de zonas guardada exitosamente en el sistema.

Se guardaron 11 zonas en la BD para el experimento #17.

Se importaron correctamente las 6 ROIs de paredes a SimBA para R5DZ_01mar24_Control.

Solo las 6 paredes se exportaron a SimBA. Las demás zonas quedan disponibles para el módulo de resultado final.

Ilustración 104: Mensaje de guardado exitoso de configuración del experimento [autoría propia]

7.3.11 Paso 5 – Análisis final

El usuario lanza el análisis final desde la página correspondiente. El sistema ejecuta las etapas de conversión YOLO–SimBA, cómputo de características e inferencia conductual de forma automática y secuencial. Al finalizar, el video multimodal y las métricas quedan disponibles en la base de datos.



Ilustración 105: Acceso al módulo de análisis final [autoría propia]




Ilustración 106: Vista general del módulo de análisis final [autoría propia]



Ilustración 107: Configuración del batch de análisis final [autoría propia]




Ilustración 108: Botón para iniciar análisis final [autoría propia]

7.3.12 Paso 6 – Consulta de resultados

El usuario accede al dashboard de resultados para revisar las métricas cuantitativas del experimento, visualizar el video multimodal y descargar los archivos de timelogs conductuales para análisis estadístico posterior. Si cuenta con permisos de administrador o investigador propietario del experimento, puede activar el modo de edición para corregir los tiempos agregados de brazos abiertos, brazos cerrados, grooming y thigmotaxis. El sistema exige un motivo de edición, actualiza las métricas persistentes y conserva el historial completo para auditoría y reversión.



Ilustración 113: Acceso al módulo de resultados y estadísticas [autoría propia]

Vista del historial

Todos

Total experimentos

16

Ultimo registro

2026-05-20

Prom. abiertos

186.2s

Prom. grooming

32.0s

Filtros registros y luego selecciona uno para ver detalles y graficos.

Buscar sujeto o responsable

Filtrar por tratamiento

Estado

Todos

Todos

☐ Mostrar solo mis experimentos (para poder editarlos) ⓘ

Hay experimentos de otros investigadores en la vista actual. Filtra para ver solo tus experimentos y poder editarlos. (Tienes 2 experimento(s) propio(s) en esta vista)

Ex. Sel.	ID	Sujeto	Tratamiento	Fecha	Responsable	Abiertos(s)	Cerrados(s)	Grooming(s)	Thigmotaxis(s)	Estado
☐	17	R007_Sluna24	Control	2026-05-20	Gabriela Lizaso-Villar	272.3	38.1	5.6	3.8	completed
☐	16	MOUSE-015-1105	Control	2026-05-11	Ernesto Javier Márquez-Palacios	289.2	28.1	5.1	4.8	completed
☐	15	VH-R1	Skazepam 5mg	2026-05-09	Habid Portocarrero Rodriguez	178.4	105.9	33.1	14.9	completed
☐	14	MOUSE-013-0705	Control	2026-05-08	Gabriela Lizaso-Villar	180.4	103.9	13.9	14.0	completed
☐	12	MOUSE-012-PV06	Control	2026-04-27	Habid Portocarrero Rodriguez	230.0	25.0	147.0	3.0	completed
☐	11	MOUSE-011-PV06	Control	2026-04-27	Habid Portocarrero Rodriguez	160.4	97.4	25.2	4.8	completed
☐	10	MOUSE-010-PV06	Control	2026-04-27	Habid Portocarrero Rodriguez	103.9	100.5	61.0	1.4	completed
☐	9	MOUSE-009-PV06	Control	2026-04-27	Habid Portocarrero Rodriguez	236.1	67.9	56.1	7.0	completed
☐	8	MOUSE-008-PV06	Control	2026-04-27	Habid Portocarrero Rodriguez	222.4	94.4	36.9	1.4	completed
☐	7	MOUSE-007-PV06	Skazepam 5mg	2026-04-27	Habid Portocarrero Rodriguez	102.4	89.2	28.3	4.6	completed

Reacciona o reacciona caudal para visualizar comparativas y detalles.

Selecciona al menos un experimento en la tabla para ver sus graficos y detalles.

Ilustración 114: Vista general del módulo de resultados y estadísticas [autoría propia]

Ex. Sel.	ID	Sujeto	Tratamiento	Fecha	Responsable	Abiertos(s)	Cerrados(s)	Grooming(s)	Thigmotaxis(s)	Estado
☐	17	R007_Sluna24	Control	2026-05-20	Gabriela Lizaso-Villar	272.3	38.1	5.6	3.8	completed
☐	16	MOUSE-015-1105	Control	2026-05-11	Ernesto Javier Márquez-Palacios	289.2	28.1	5.1	4.8	completed
☐	15	VH-R1	Skazepam 5mg	2026-05-09	Habid Portocarrero Rodriguez	178.4	105.9	33.1	14.9	completed
☐	14	MOUSE-013-0705	Control	2026-05-08	Gabriela Lizaso-Villar	180.4	103.9	13.9	14.0	completed
☐	12	MOUSE-012-PV06	Control	2026-04-27	Habid Portocarrero Rodriguez	230.0	25.0	147.0	3.0	completed
☐	11	MOUSE-011-PV06	Control	2026-04-27	Habid Portocarrero Rodriguez	160.4	97.4	25.2	4.8	completed
☐	10	MOUSE-010-PV06	Control	2026-04-27	Habid Portocarrero Rodriguez	103.9	100.5	61.0	1.4	completed
☐	9	MOUSE-009-PV06	Control	2026-04-27	Habid Portocarrero Rodriguez	236.1	67.9	56.1	7.0	completed
☐	8	MOUSE-008-PV06	Control	2026-04-27	Habid Portocarrero Rodriguez	222.4	94.4	36.9	1.4	completed
☐	7	MOUSE-007-PV06	Skazepam 5mg	2026-04-27	Habid Portocarrero Rodriguez	102.4	89.2	28.3	4.6	completed

Ilustración 115: Tabla general de experimentos y sus resultados [autoría propia]

Ilustración 116: Clasificación de experimentos por responsable, tratamiento y estado [autoria propia]

Ilustración 117: Selección singular de un experimento [autoría propia]

Ilustración 118: Información de un experimento [autoría propia]

Ilustración 119: Información gráfica de un experimento [autoría propia]



Ilustración 120: Mapa de calor de un experimento [autoría propia]

Descargar Reportes

Formato	Descripción
CSV	Formato compatible con Excel
JSON	Formato estructurado para APIs
PDF	Reporte profesional imprimible

Ilustración 121: Apartado de descarga de reportes en diferentes formatos [autoría propia]




Ilustración 122: Múltiples reportes en diferentes formatos descargados [autoría propia]

☒	12	MOUSE-012-PV26
☒	11	MOUSE-011-PV26
☒	10	MOUSE-010-PV26

Ilustración 123: Selección de múltiples experimentos [autoría propia]




Ilustración 124: Comparación rápida de múltiples experimentos [autoría propia]

☐ Confirma que deseas borrar los experimentos seleccionados que me pertenecen.

BORRAR MIS EXPERIMENTOS SELECCIONADOS

Ilustración 125: Borrado de experimentos pertenecientes al usuario [autoría propia]

7.3.13 Paso 7 – Comparación de resultados

El usuario puede acceder al módulo de comparación para comparar dos grupos de experimentos con 6 a 8 experimentos por grupos. La comparación puede ser realizada por estudiantes, investigadores y administradores sin restricción. Se pueden obtener representaciones gráficas y datos crudos así como en respectivos reportes para descargar.



Ilustración 126: Acceso del módulo de comparación [autoría propia]

Módulo 06: Comparación de Grupos Experimentales

Genera tablas consolidadas con estadísticas descriptivas por grupo de tratamiento. Exporta datos formateados para análisis estadístico (ANOVA, prueba t, etc.). **Recomendado:** 5-8 ratas por grupo para validez estadística.

Selección Manual de Experimentos para Comparación

Instrucciones:

1. Selecciona el tratamiento para cada grupo
2. Selecciona los **experimentos específicos** que deseas incluir de cada tratamiento
3. Cada grupo debe tener **entre 6 y 8 experimentos** (válido para análisis estadísticos)
4. Ambos grupos deben tener la misma cantidad de experimentos
5. Presiona el botón **Comparar** para generar el análisis

Grupo 1

Tratamiento para Grupo 1:

Control

Experimentos disponibles: 9

Selecciona experimentos para Grupo 1:

Choose options

Selecciona entre 6 y 8 experimentos

Grupo 2

Tratamiento para Grupo 2:

Diazepam 5mg

Experimentos disponibles: 7

Selecciona experimentos para Grupo 2:

Choose options

Selecciona entre 6 y 8 experimentos

Debes seleccionar experimentos en ambos grupos antes de comparar.

Ilustración 127: Vista general del módulo de comparación [autoría propia]

Grupo 1

Tratamiento para Grupo 1:

Control

Experimentos disponibles: 9

Selecciona experimentos para Grupo 1:

Choose options

Selecciona entre 6 y 8 experimentos

Grupo 2

Tratamiento para Grupo 2:

Diazepam 5mg

Experimentos disponibles: 7

Selecciona experimentos para Grupo 2:

Choose options

Selecciona entre 6 y 8 experimentos

Ilustración 128: Selección de grupos de experimentos y sus experimentos [autoría propia]

Selecciona experimentos para Grupo 1:

Experimentos seleccionados: 6 ✓

Selecciona experimentos para Grupo 2:

Experimentos seleccionados: 5 (mínimo requerido: 6)

Grupo 2: Se requieren entre 6 y 8 experimentos (actualmente: 5)

Ilustración 129: Validación de experimentos seleccionados [autoría propia]

Selecciona experimentos para Grupo 1:

Experimentos seleccionados: 6 ✓

Selecciona experimentos para Grupo 2:

Experimentos seleccionados: 6 ✓

✓ Validación exitosa: Ambos grupos tienen 6 experimento(s) seleccionado(s)

Comparar Grupos

Presiona el botón "Comparar Grupos" para generar el análisis estadístico.

Ilustración 130: Validación de experimentos exitosa [autoría propia]




Ilustración 131: Botón de comparación de grupos [autoría propia]

Datos Individuales por Sujeto							Nueva Comparación	
Resumen de Experimentos Seleccionados								
Grupo	ID-Ratón	Tratamiento	Fecha	T. Abiertas (s)	T. Cerradas (s)	T. Centro (s)	Grooming (s)	Tigmotaxis (s)
Grupo 1	MOUSE_08mar24	Control	2020-05-20	272.130951	28.084051	5.761081	5.590088	1.013388
Grupo 1	MOUSE_015-1105	Control	2020-05-11	269.113999	28.064651	11.599134	5.060203	4.633001
Grupo 1	MOUSE_013-0205	Control	2020-05-08	180.428060	303.880300	27.690344	11.000180	14.633001
Grupo 1	MOUSE_005-PV05	Control	2020-04-27	322.391256	18.787901	16.532654	16.000088	1.366614
Grupo 1	MOUSE_005-PV05	Control	2020-04-27	116.060950	67.862753	17.762643	16.036784	4.180796
Grupo 2	MOUSE_020-PV20	Control	2020-04-27	150.897408	180.962741	22.460117	81.000000	1.032299
Grupo 2	YH-R1	Diazepam Sng	2020-05-09	178.395775	161.884254	29.099291	13.020606	14.060115
Grupo 2	MOUSE_004-PV20	Diazepam Sng	2020-04-27	141.107413	101.360310	5.099287	19.300088	8.060394
Grupo 2	MOUSE_005-PV20	Diazepam Sng	2020-04-27	194.133717	92.860473	12.032531	10.299111	4.181381
Grupo 2	MOUSE_008-PV20	Diazepam Sng	2020-04-27	165.776079	100.088916	15.063381	9.032088	1.000000

Ilustración 132: Tabla de datos individuales por experimento que incluye tiempo en brazos, grooming y tigmotaxis [autoría propia]

Estadísticas Descriptivas por Grupo								
Tabla consolidada para análisis estadístico (ANOVA, prueba t)								
Variable	Grupo	Tratamiento	N	Media	Desv. Est.	Error Est.	Mínimo	Máximo
Tiempo Brazos Abiertos (s)	Grupo 1	Control	6	212.37	63.06	25.74	188.9	272.18
Tiempo Brazos Abiertos (s)	Grupo 2	Diazepam Sng	6	186.37	46.35	18.88	141.53	267.75
Tiempo Brazos Cerrados (s)	Grupo 1	Control	6	73.64	50.91	20.78	28.06	180.46
Tiempo Brazos Cerrados (s)	Grupo 2	Diazepam Sng	6	96.93	43.36	17.78	35.23	151.36
Tiempo Centro (s)	Grupo 1	Control	6	16.65	7.31	2.99	9.77	29.7
Tiempo Centro (s)	Grupo 2	Diazepam Sng	6	11.4	9.53	3.81	5.1	29.7
Grooming (s)	Grupo 1	Control	6	32.79	27.49	11.22	5.07	61
Grooming (s)	Grupo 2	Diazepam Sng	6	16.07	8.57	3.5	5.83	26.27
Tigmotaxis (s)	Grupo 1	Control	6	5.38	4.74	1.93	1.37	14.63
Tigmotaxis (s)	Grupo 2	Diazepam Sng	6	5.61	5.43	2.21	0.33	14.87

Ilustración 133: Tabla de datos estadísticos por grupo que incluye media, desviación estándar, error estándar, máximo y mínimo por categoría de tiempo [autoría propia]




Ilustración 134: Comparación visual por grupos con respecto a tiempos [autoría propia]

Exportar Consolidado para Análisis Estadístico

Formato de Exportación:

- Hoja 1 (Datos Individuales): Datos crudos de cada sujeto experimental
- Hoja 2 (Estadísticas por Grupo): Media, Desviación Estándar, Error Estándar, N
- Hoja 3 (Resumen Comparativo): Diferencias entre grupos
- Formato compatible con SPSS, R, GraphPad Prism, JASP

Consolidado completo con 4 hojas Estadísticas Descriptivas Reporte de comparación

Ilustración 135: Sección de descarga de reportes en diferentes formatos [autoría propia]




Ilustración 136: Reportes en diferentes formatos descargados [autoría propia]

7.4 Justificación técnica del modelo de clasificación y su evaluación

Esta sección consolida la justificación técnica de las tres decisiones centrales del componente de clasificación conductual: el algoritmo de aprendizaje empleado, la métrica de evaluación seleccionada y la interpretación del desempeño obtenido. Su propósito es documentar de forma explícita y verificable el fundamento de cada elección ante la revisión académica.

7.4.1 Elección de Random Forest frente a otros algoritmos y redes neuronales

La clasificación de Grooming y Thigmotaxis se realiza sobre un conjunto de 242 características espaciotemporales (distancias, velocidades y ángulos inter-keypoint calculados sobre ventanas temporales) derivadas de la pose estimada; es decir, datos estructurados de tipo tabular. Para esta representación, los algoritmos basados en árboles de decisión ofrecen un desempeño competitivo sin requerir los grandes volúmenes de datos etiquetados que demandan las redes neuronales profundas. El conjunto de entrenamiento disponible comprende 26 videos (243,253 frames), con una proporción reducida de frames positivos (8.5% para Grooming y 3.1% para Thigmotaxis). Bajo este régimen de muestra limitada y alto desbalance, una arquitectura profunda (red convolucional o Transformer) tendería al sobreajuste, memorizando patrones específicos por animal en lugar de la firma transversal de la conducta; Goodfellow, Bengio y Courville [21] señalan que el aprendizaje profundo requiere conjuntos de datos extensos para generalizar de forma estable.

Random Forest, definido por Breiman [32] como un ensamble de árboles de decisión entrenados sobre subconjuntos aleatorios de muestras y características, reduce la varianza del modelo y la propensión al sobreajuste mediante el promediado de múltiples estimadores (bagging). Esta propiedad lo hace especialmente adecuado para conjuntos de datos pequeños y medianos. Además, admite la ponderación de clases (class_weight balanceado), lo que mitiga directamente el desbalance descrito. Frente a las Máquinas de Vectores de Soporte [36], Random Forest escala de forma más eficiente sobre los 243,253 frames y entrega de manera nativa estimaciones de probabilidad por frame, necesarias para el posprocesamiento por umbral y el suavizado temporal.

Una ventaja determinante es la interpretabilidad. Hastie, Tibshirani y Friedman [33] destacan que Random Forest permite cuantificar la importancia relativa de cada característica, lo que posibilita identificar qué descriptores cinemáticos sustentan cada clasificación y validar el modelo desde una perspectiva etológica, a diferencia del carácter de caja negra de las redes profundas. Finalmente, la elección no excluye el modelado temporal: la arquitectura combina Random Forest, responsable de la discriminación por frame sobre características diseñadas, con una red recurrente LSTM empleada como capa de rescate para la continuidad temporal (sección 7.3.4), aprovechando las fortalezas de ambos enfoques sin depender de un único modelo profundo de alto costo de datos.

7.4.2 Elección de F1-Score como métrica de evaluación

La evaluación del modelo se fundamenta en el F1-Score y no en la exactitud (accuracy) debido al fuerte desbalance de clases del problema. Dado que las conductas objetivo ocupan únicamente entre el 3.1% y el 8.5% de los frames, un clasificador trivial que prediga ausencia permanente alcanzaría una exactitud cercana al 96.9% para Thigmotaxis y al 91.5% para Grooming sin detectar un solo evento real. Por ello, la exactitud sobreestima el desempeño y resulta inadecuada como métrica principal, fenómeno documentado en la sección 7.2.3.

El F1-Score, definido como la media armónica entre la precisión (precision) y la exhaustividad (recall), penaliza simultáneamente los falsos positivos —que inflarían artificialmente el tiempo conductual reportado— y los falsos negativos —que omitirían eventos reales—, exigiendo un equilibrio entre ambos tipos de error. Optimizar la precisión o la exhaustividad de forma aislada degradaría la otra, mientras que el F1-Score las resume en un único valor interpretable en el punto de operación real del sistema. Goodfellow, Bengio y Courville [21] y la documentación de Scikit-learn [90] respaldan su uso en problemas de clasificación desbalanceada. Frente al área bajo la curva ROC, que puede ofrecer una visión optimista bajo desbalance severo al ponderar la clase mayoritaria, el F1-Score evaluado en el umbral operativo refleja el desempeño efectivo en despliegue.

Adicionalmente, se reporta la variante de F1-Score «justo» (sección 7.2.8), que excluye los videos sin ejemplos positivos reales de la conducta —donde el F1 es nulo por definición matemática y no por fallo del clasificador—, proporcionando una estimación no sesgada del desempeño sobre los escenarios en los que efectivamente existe conducta que detectar.

7.4.3 Análisis de desempeño y valor agregado del sistema ante un F1-Score moderado

En la validación Leave-One-Out ciega sobre los 26 videos etiquetados, el sistema alcanzó un F1-Score justo de 0.523 para Grooming (estrategia Conditional) y de 0.636 para Thigmotaxis (Random Forest de SimBA). Aunque estos valores son moderados frente a un umbral ideal de 0.85, su interpretación

requiere considerar el origen de la limitación y el valor que el sistema aporta al flujo de trabajo experimental.

El análisis indica que el cuello de botella no reside en el diseño del sistema, sino en el tamaño de la muestra. La estimación de pose está esencialmente resuelta, con un mAP50 de 0.995 en la detección de keypoints (sección 7.3.2), por lo que el error remanente se concentra en la interpretación cinemática de la conducta. La elevada varianza del F1 entre videos (de 0.00 a 0.99 en Grooming) es el síntoma esperado de un régimen de muestra reducida, conforme al análisis de tamaño de muestra de la sección 7.3.5: el conjunto de 26 videos resulta suficiente para Thigmotaxis —conducta geométrica de menor complejidad, que en consecuencia obtiene un F1 superior— pero insuficiente para la complejidad cinemática del Grooming. Pereira y Moita [16] documentan la dificultad intrínseca de clasificar conductas de acicalamiento mediante visión por computadora.

El valor agregado del sistema reside en la automatización, estandarización y trazabilidad de un proceso tradicionalmente manual, subjetivo y lento. El prototipo procesa un video de cinco minutos en aproximadamente tres minutos, frente a las horas requeridas por el análisis visual manual, y elimina la variabilidad inter-observador mediante una clasificación reproducible. La validación empleada (Leave-One-Out ciega) constituye la prueba más estricta posible para este tamaño de muestra —el modelo nunca evaluó frames del animal sobre el que se mide—, por lo que el F1 reportado representa un piso de desempeño y no una estimación inflada. Asimismo, el sistema incorpora una capa de edición manual de tiempos con bitácora de auditoría (behavior_edits) que permite al investigador corregir las mediciones con plena trazabilidad. De este modo, el prototipo opera como una herramienta de asistencia que multiplica la productividad del análisis conductual con supervisión humana, y no como un oráculo autónomo.

Finalmente, la limitación es remediabile: el análisis de la sección 7.3.5 proyecta un incremento del F1-Score conforme aumenta el número de videos etiquetados, lo que define una ruta de mejora concreta. En síntesis, el desempeño obtenido refleja una restricción de datos con solución identificada, sobre una arquitectura cuyo funcionamiento integral, velocidad y honestidad metodológica quedan demostrados.

7.4.4 Modelos y estrategias experimentales exploradas

Además del clasificador Random Forest productivo, se exploraron estrategias complementarias para reducir los fallos de generalización observados en Grooming. B-SOiD se evaluó como alternativa no supervisada basada en motivos conductuales, ya que permite agrupar patrones de movimiento sin depender exclusivamente de etiquetas frame a frame. En la validación Leave-One-Out con $N = 26$, B-SOiD obtuvo un F1-Score justo de 0.357 para Grooming, inferior al Random Forest de SimBA (0.400), pero mostró capacidad de rescate en videos donde SimBA colapsaba y predecía muy pocos frames positivos.

A partir de este comportamiento se evaluó Ensemble OR, que considera positiva una predicción si SimBA o B-SOiD detectan la conducta. Esta estrategia elevó el F1-Score justo de Grooming a 0.502, pero también incrementó falsos positivos en videos donde SimBA ya funcionaba correctamente. Por ello se diseñó la estrategia Conditional, que mantiene SimBA como clasificador principal y activa B-SOiD únicamente cuando SimBA predice menos de 250 frames positivos. Esta regla obtuvo el mejor desempeño para Grooming, con F1-Score justo de 0.523, y representa el equilibrio más favorable entre rescate de eventos y control de falsos positivos.

También se evaluó una estrategia Dynamic, basada en ajustar el umbral de Grooming por video cuando SimBA predice pocos positivos. En la validación global alcanzó un F1-Score justo de 0.507, cercano a Conditional, pero su análisis en videos críticos mostró que bajar el umbral no siempre recupera la conducta cuando las características no separan adecuadamente Grooming del fondo. Por esta razón se mantuvo como herramienta diagnóstica y no como regla productiva principal.

La capa LSTM se exploró como mecanismo de rescate temporal para eventos breves o fragmentados. A diferencia del Random Forest, que clasifica frame a frame sobre características tabulares, la LSTM modela continuidad temporal en ventanas de frames. Su función en el sistema no es reemplazar SimBA, sino elevar predicciones cuando el Random Forest queda en una zona de incertidumbre. En las pruebas internas con cinco videos críticos, la LSTM reentrenada con 26 videos alcanzó F1 promedio de 0.959 con umbral 0.75, 0.946 con umbral 0.50 y 0.885 con umbral 0.11; estos valores no se reportan como validación ciega, sino como evidencia de que el backend temporal reconoce los patrones de Grooming cuando está correctamente integrado.

Finalmente, se probaron estrategias adicionales como mirror augmentation y bagging multi-semilla. Mirror augmentation duplicó el conjunto efectivo a 52 archivos (26 originales y 26 espejados), pero no mejoró de forma consistente la validación ciega en videos críticos. Bagging multi-semilla tampoco corrigió los colapsos de SimBA: en cinco videos críticos obtuvo F1 promedio de 0.010 frente a 0.017 del baseline SimBA en el mismo subconjunto. Este resultado sugiere que el problema no era únicamente varianza por semilla, sino falta de separabilidad para ciertos estilos de Grooming dentro del espacio de características disponible.

7.4.5 Decisión técnica final

Con base en estos resultados, la arquitectura final conserva SimBA Random Forest como núcleo productivo por su estabilidad, interpretabilidad y compatibilidad con datos tabulares; utiliza Conditional como mejor estrategia para Grooming cuando SimBA pierde sensibilidad; mantiene SimBA RF como método principal para Thigmotaxis, donde obtuvo F1-Score justo de 0.636; y conserva LSTM rescue como apoyo temporal para eventos fragmentados. Las estrategias Dynamic, mirror augmentation y bagging se documentan como experimentos útiles, pero no sustituyen al flujo productivo por no superar de forma consistente a Conditional en validación ciega.

Esta decisión técnica evita presentar el sistema como un único clasificador perfecto y, en cambio, documenta una arquitectura evaluada de forma comparativa. El resultado defendible es que el prototipo identifica qué componente funciona mejor para cada conducta: SimBA Random Forest para Thigmotaxis, Conditional para Grooming y LSTM como rescate temporal complementario. Así, la elección final responde a evidencia experimental y no a preferencia arbitraria por un algoritmo.

7.4.6 Estimación del tamaño de dataset requerido

El principal factor limitante para mejorar la precisión de Grooming no es el rastreador de pose, sino la variabilidad conductual disponible para entrenar el clasificador. A diferencia de Thigmotaxis, que depende en mayor medida de la posición del centroide respecto a la geometría del laberinto, Grooming depende de micro-movimientos repetitivos de cabeza, patas y cuerpo. Por ello, requiere mayor diversidad de animales, orientaciones, duraciones y estilos de acicalamiento.

La estimación del número de videos necesarios puede aproximarse a partir del intervalo de confianza del promedio de F1-Score observado en la validación Leave-One-Out. Para Grooming, la estrategia Conditional obtuvo F1-Score justo de 0.523 con desviación estándar aproximada de 0.315 en n efectivo = 24. Si se busca estimar el F1 promedio con un margen de error E cercano a ± 0.06 y un nivel de confianza del 95 %, se puede usar la expresión $n = (1.96 \sigma / E)^2$. Al sustituir $\sigma = 0.315$ y $E = 0.06$, se obtiene $n \approx 106$ videos.

Con base en esta aproximación, una meta razonable para futuras iteraciones es ampliar el conjunto a 100-120 videos etiquetados. Este rango no debe interpretarse como un umbral absoluto definido por un algoritmo externo, sino como una estimación estadística derivada de la varianza observada en este proyecto. Un conjunto de ese tamaño permitiría reducir la incertidumbre del promedio, mejorar la cobertura de casos poco frecuentes y entrenar modelos temporales o no supervisados con menor riesgo de sobreajuste.

Esta estimación también explica por qué Thigmotaxis puede estabilizarse antes que Grooming. La primera conducta se relaciona con una condición espacial relativamente estable, mientras que Grooming requiere reconocer secuencias cinemáticas finas. B-SOiD reporta que los patrones de acicalamiento pueden separarse en motivos como paw/face groom, head groom y body lick, lo que refuerza que una sola etiqueta de Grooming agrupa subconductas con dinámica interna distinta [116].

7.4.7 Modelos candidatos para mejorar la precisión en trabajo futuro

A partir de los resultados del prototipo y de la literatura reciente en análisis automatizado de conducta, el trabajo futuro debe priorizar modelos que aprovechen la estructura temporal de los keypoints, reduzcan el costo de etiquetado y permitan distinguir subpatrones de Grooming. Las rutas más relevantes son las siguientes:

Keypoint-MoSeq. Es el candidato más sólido para explorar Grooming con mayor detalle, porque modela sílabas conductuales a partir de trayectorias de keypoints y separa ruido de cambios reales en la dinámica corporal. En reportes recientes, Keypoint-MoSeq ha mostrado mejor alineación con transiciones conductuales que alternativas como B-SOiD, VAME y MotionMapper, además de recuperar estados relacionados con grooming en datos de campo abierto [117]. Para este proyecto sería útil como herramienta de descubrimiento de subconductas antes de entrenar un clasificador supervisado final.

B-SOiD refinado. Aunque en la validación actual no superó a Conditional, sigue siendo útil como apoyo no supervisado para descubrir motivos cinemáticos de Grooming. Con más videos, podría reentrenarse para mapear motivos específicos a Grooming real y usar sus salidas como variables adicionales del clasificador principal. Esta ruta es defendible porque B-SOiD fue diseñado para identificar patrones espaciotemporales a partir de poses y luego entrenar un Random Forest sobre esos patrones [116].

Aprendizaje activo. En lugar de etiquetar videos al azar, una siguiente versión puede seleccionar fragmentos donde el modelo muestre mayor incertidumbre o desacuerdo entre clasificadores. Esto concentraría el esfuerzo humano en los casos que más información aportan: transiciones ambiguas, grooming parcial, grooming breve y posturas poco representadas. Esta estrategia es especialmente conveniente cuando el etiquetado frame a frame es costoso.

Modelos temporales supervisados. Con un dataset ampliado, pueden evaluarse redes temporales como GRU, LSTM o Temporal Convolutional Networks sobre ventanas de keypoints y features SimBA. Estas arquitecturas podrían mejorar Grooming porque clasifican la evolución de una secuencia y no únicamente el estado local de un frame. La capa LSTM ya probada en este trabajo debe conservarse como antecedente experimental, pero una validación ciega completa requeriría mayor número de videos y separación estricta por animal.

Modelos de video supervisados. Herramientas como DeepEthogram y MARS muestran que la clasificación directa desde video puede ser útil para conductas visualmente complejas [119], [120]. En este proyecto podrían explorarse como comparación futura, aunque su costo computacional y su menor explicabilidad los vuelven menos convenientes como primer reemplazo del flujo YOLO Pose + SimBA.

Postprocesamiento probabilístico. Un modelo de Markov oculto o un campo aleatorio condicional podría mejorar la coherencia temporal de las predicciones sin reemplazar al clasificador base. Este enfoque reduciría segmentos aislados de uno o pocos frames y ayudaría a respetar duraciones plausibles de cada conducta.

Con base en lo anterior, la ruta técnica recomendada es conservar SimBA Random Forest como línea base explicable, ampliar el dataset a 100-120 videos, usar Keypoint-MoSeq o B-SOiD para descubrir subconductas de Grooming y, posteriormente, entrenar un modelo temporal supervisado sobre ventanas de movimiento. Esta estrategia mantiene la interpretabilidad del sistema actual, pero abre una ruta concreta para mejorar la precisión en especímenes no vistos.

Capítulo 8. Conclusiones

8.1 Conclusiones generales

El desarrollo del prototipo permitió comprobar la viabilidad técnica de un sistema local de visión por computadora para apoyar el análisis de conducta en roedores dentro del modelo Elevated Plus Maze. La solución integra estimación de pose markerless, extracción de características espaciotemporales, clasificación conductual, edición manual trazable, persistencia relacional y exportación de resultados en un flujo operativo accesible para usuarios de laboratorio.

Uno de los resultados más sólidos del proyecto fue la sustitución de enfoques de pose más costosos en tiempo de ejecución por YOLO11 Pose mediante Ultralytics. El modelo entrenado con 3,953 imágenes etiquetadas alcanzó $mAP50 = 0.995$ y permitió procesar videos de 5 minutos en aproximadamente 3 minutos con GPU dedicada. Esta mejora hizo posible que el análisis automatizado se ejecutara en una estación local, sin depender de servicios externos ni de flujos manuales prolongados.

En la clasificación conductual, el proyecto mostró que Thigmotaxis y Grooming tienen niveles de dificultad distintos. Thigmotaxis se benefició de su naturaleza espacial y alcanzó mejor estabilidad con SimBA Random Forest. Grooming presentó mayor variabilidad por tratarse de una conducta cinemática fina, con movimientos breves, repetitivos y dependientes de postura. Por esta razón, el sistema final no se presenta como un único clasificador perfecto, sino como una arquitectura comparada y justificable: SimBA Random Forest como base productiva, estrategia Conditional para mejorar Grooming y LSTM como apoyo experimental de rescate temporal.

La validación Leave-One-Out con 26 videos permitió documentar el desempeño real del sistema sin ocultar sus limitaciones. Grooming obtuvo su mejor resultado con la estrategia Conditional, con F1-Score justo de 0.523, mientras que Thigmotaxis alcanzó F1-Score justo de 0.636 con SimBA Random Forest. Estos valores no deben interpretarse como cierre definitivo del problema, sino como evidencia de un prototipo funcional, medible y mejorable con mayor diversidad de datos etiquetados.

Además del componente de inteligencia artificial, el proyecto consolidó una base operativa de software: manejo de usuarios por roles, registro de tratamientos y experimentos, configuración de regiones de interés, almacenamiento en PostgreSQL, bitácora de auditoría de seguridad y registro de ediciones manuales mediante `behavior_edits`. Esta trazabilidad es relevante porque permite que los resultados automatizados sean revisables por investigadores y no funcionen como una caja negra.

8.2 Cumplimiento de objetivos

El objetivo general se cumplió al desarrollar un prototipo capaz de procesar videos del modelo EPM, estimar keypoints del espécimen, calcular trayectoria, clasificar conductas de interés y presentar resultados consultables por el usuario. La interfaz en Streamlit redujo la dependencia de consola y permitió organizar el flujo de trabajo en etapas comprensibles: registro, configuración de zonas, análisis, consulta, edición y exportación.

También se cumplieron objetivos técnicos específicos. Se entrenó y validó el modelo YOLO11 Pose; se construyó el puente de features hacia SimBA; se entrenaron modelos Random Forest para Grooming y Thigmotaxis; se evaluaron estrategias alternativas como B-SOiD, Ensemble OR, Dynamic y LSTM rescue; y se documentó una arquitectura final basada en evidencia experimental. La base de datos quedó estructurada para conservar usuarios, tratamientos, experimentos, configuraciones ROI, resultados, ediciones y auditoría.

Desde el punto de vista metodológico, el uso del modelo en espiral permitió iterar sobre riesgos reales del proyecto: rendimiento de inferencia, ruido en keypoints, variabilidad de conducta, portabilidad del entorno y trazabilidad de modificaciones. Esta forma de trabajo fue adecuada para un prototipo científico, donde los requerimientos evolucionaron conforme se obtuvieron resultados experimentales.

8.3 Limitaciones identificadas

La principal limitación del sistema se encuentra en el tamaño y diversidad del dataset conductual etiquetado. Aunque se contó con 26 videos reales y 243,253 frames, Grooming representó solo 20,757 frames positivos, equivalentes al 8.5 % del total. Esta baja prevalencia incrementa la dificultad de aprendizaje y explica la variabilidad observada entre especímenes durante la validación Leave-One-Out.

Otra limitación es la diferencia entre conductas espaciales y cinemáticas. Thigmotaxis puede inferirse con mayor estabilidad a partir de posición y regiones de interés; en cambio, Grooming depende de micro-movimientos y de la continuidad temporal de secuencias breves. Por ello, un clasificador tabular como Random Forest puede requerir apoyo de modelos temporales o métodos de descubrimiento de motivos para mejorar su sensibilidad.

La portabilidad del prototipo también requiere mantenimiento. Aunque el sistema opera en Windows y se realizaron pruebas de instalación en Linux, las dependencias de visión por computadora, SimBA,

PyTorch, TensorFlow/Keras y Ultralytics pueden generar conflictos entre versiones. Por esta razón, la documentación de instalación y los entornos virtuales deben mantenerse actualizados.

Finalmente, el prototipo no sustituye la validación experta. Su propósito es reducir el tiempo de análisis, estandarizar mediciones y apoyar la revisión conductual, pero las conductas ambiguas deben conservar mecanismos de edición manual, justificación y auditoría para mantener validez científica.

8.4 Trabajo a futuro

La mejora prioritaria consiste en ampliar el conjunto de videos etiquetados. Con base en la varianza observada durante la validación Leave-One-Out, se estimó que para Grooming una meta razonable se ubica entre 100 y 120 videos etiquetados. Este rango permitiría reducir la incertidumbre del F1 promedio, cubrir más estilos de acicalamiento y entrenar modelos con mayor capacidad de generalización.

Una segunda línea de trabajo consiste en explorar modelos especializados para conducta temporal. Keypoint-MoSeq representa una alternativa fuerte para descubrir subconductas o sílabas conductuales a partir de keypoints; B-SOiD puede refinarse con más videos para identificar motivos de Grooming; y modelos supervisados como GRU, LSTM o Temporal Convolutional Networks pueden evaluarse cuando exista un dataset más amplio y balanceado.

También se recomienda incorporar aprendizaje activo para reducir el costo de etiquetado. En lugar de etiquetar videos al azar, el sistema podría seleccionar fragmentos donde el clasificador tenga mayor incertidumbre o donde exista desacuerdo entre modelos. Esto concentraría el esfuerzo humano en los segmentos que más información aportan al entrenamiento.

En términos de software, el trabajo futuro debe fortalecer la portabilidad del sistema mediante entornos reproducibles, pruebas de instalación automatizadas y documentación diferenciada para Windows y Linux. También conviene mantener la compatibilidad de modelos pesados fuera del repositorio mediante rutas configurables, verificación de integridad y procedimientos claros de descarga o transferencia.

Finalmente, se propone ampliar la validación con nuevos especímenes, sesiones y condiciones experimentales, así como comparar los resultados del prototipo contra herramientas comerciales o protocolos manuales estandarizados. Esta etapa permitiría transformar el sistema de un prototipo funcional de Trabajo Terminal a una herramienta científica más robusta para uso institucional.

Referencias

- [1] M. Khatri, S. K. Rai, R. Ranblor, K. Kishore y M. Tiwari, "Synthesis and Pharmacological Evaluation of [(4-Arylpiperazin-1-yl)-alkyl]-carbamic Acid Ethyl Ester Derivatives as Potential Anxiolytic Agents," *Arch. Pharmal. Res.*, vol. 35, no. 7, pp. 1143–1150, 2011.
- [2] Sin autor, "NORMA Oficial Mexicana NOM-062-ZOO-1999, Especificaciones técnicas para la producción, cuidado y uso de los animales de laboratorio," *Secretaría de Agricultura, Ganadería, Desarrollo Rural, Pesca y Alimentación*, Ciudad de México, Gov. Rep., Tomo DLXXV No.16, 2001.
- [3] A. P. Carobrez y L. J. Bertoglio, "Ethological and Temporal Analyses of Anxiety-like Behavior: The Elevated Plus-Maze Model 20 Years On," *Neurosci. Biobehav. Rev.*, vol. 29, no. 8, pp. 1193–1205, 2005.

- [4] F. G. Graeff, C. F. Netto y H. Zangrossi Jr, “The Elevated T-Maze as an Experimental Model of Anxiety,” *Neurosci. Biobehav. Rev.*, vol. 23, no. 2, pp. 237–246, 1998.
- [5], Z. T. Pennington et al., “EzTrack-A step-by-step guide to behavior tracking”, *Curr. Protoc.*, vol. 1, Num. 10, p. e255, 2021.
- [6] **ISO/IEC/IEEE 12207:2017, Systems and Software Engineering — Software Life Cycle Processes**, International Organization for Standardization, Geneva, Switzerland, 2017. [En línea]. Disponible en: <https://www.iso.org/standard/63712.html>
- [7] **ISO/IEC/IEEE 15288:2023, Systems and Software Engineering — System Life Cycle Processes**, International Organization for Standardization, Geneva, Switzerland, 2023. [En línea]. Disponible en: <https://www.iso.org/standard/63711.html>
- [8] **ISO/IEC 25010:2023, Systems and Software Engineering — Systems and Software Quality Requirements and Evaluation (SQuaRE): System and Software Quality Models**, International Organization for Standardization, Geneva, Switzerland, 2023. [En línea]. Disponible en: <https://www.iso.org/standard/78176.html>
- [9] S. Olson y L. Barton, “Artificial Intelligence in Veterinary Medicine: Enhancing Animal Health and Welfare,” *Vet. Clin. North Am. Small Anim. Pract.*, vol. 53, no. 1, pp. 1–14, 2023.
- [10] M. J. Bailey, J. S. Capozzi, y P. J. Lowry, “The Translational Relevance of Rodent Models in Neurobehavioral Research,” *Front. Behav. Neurosci.*, vol. 17, pp. 112–128, 2023.
- [11] I. Sandino, Comunicación personal, Escuela Nacional de Medicina y Homeopatía, Instituto Politécnico Nacional, 2025.
- [12] M. Mathis, A. B. Mamidanna, K. M. Cury et al., “DeepLabCut: Markerless Pose Estimation of User-Defined Body Parts with Deep Learning,” *Nat. Neurosci.*, vol. 21, no. 9, pp. 1281–1289, 2018.
- [13] J. Redmon, S. Divvala, R. Girshick y A. Farhadi, “You Only Look Once: Unified, Real-Time Object Detection,” *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, pp. 779–788, 2016.
- [14] G. Quintana-Diez, “Integración de inteligencia artificial en la medicina del comportamiento animal,” *Rev. Med. Vet. Cienc. Anim.*, vol. 12, no. 2, pp. 85–94, 2022.
- [15] National Centre for the Replacement, Refinement and Reduction of Animals in Research (NC3Rs), “The 3Rs,” 2023. [En línea]. Disponible en: <https://www.nc3rs.org.uk>
- [16] A. Pereira y R. Moita, “The Role of Computer Vision in Ethology: A Review,” *Anim. Behav.*, vol. 190, pp. 1–14, 2022.
- [17] C. Wiltshko et al., “Mapping Sub-Second Structure in Mouse Behavior,” *Neuron*, vol. 88, no. 6, pp. 1121–1135, 2015.
- [18] S. Hochreiter and J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997. [En línea]. Disponible en: https://www.researchgate.net/publication/13853244_Long_Short-Term_Memory
- [19] C. Olah, “Understanding LSTM Networks,” colah’s blog, 2015. [En línea]. Disponible en: <https://colah.github.io/posts/2015-08-Understanding-LSTMs>
- [20] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention Is All You Need,” in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017.

- [21] I. Goodfellow, Y. Bengio and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016. [Online]. Disponible en: <https://www.deeplearningbook.org/>
- [22] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer, 2006.
- [23] Z. Cao, G. Hidalgo, T. Simon, S.-E. Wei, and Y. Sheikh, "OpenPose: Realtime Multi-Person 2D Pose Estimation Using Part Affinity Fields," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 43, no. 1, pp. 172–186, 2021. [Online]. Disponible en: <https://arxiv.org/abs/1812.08008>
- [24] G. Bradski, "Computer Vision Face Tracking for Use in a Perceptual User Interface," Intel Research, 1998. [Online]. Disponible en: https://opencv.jp/opencv-1.0.0_org/docs/papers/camshift.pdf
- [25] D. Comaniciu, V. Ramesh y P. Meer, "Kernel-Based Object Tracking," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 25, no. 5, pp. 564–577, 2003. [Online]. Disponible en: <https://comaniciu.net/Papers/KernelTracking.pdf>
- [26] Open-Source Computer Vision Library (OpenCV), "MeanShift and CAMShift," tutorial OpenCV docs (v4.x). [Online]. Disponible en: https://docs.opencv.org/4.x/d7/d00/tutorial_meanshift.html
- [27] J. Cohen, "A Coefficient of Agreement for Nominal Scales," *Educ. Psychol. Meas.*, vol. 20, no. 1, pp. 37–46, 1960. Available: <https://journals.sagepub.com/doi/10.1177/001316446002000104>
- [28] M. L. McHugh, "Interrater Reliability: The Kappa Statistic," *Biochem. Med.*, vol. 22, no. 3, pp. 276–282, 2012. Available: <https://www.biochemia-medica.com/en/journal/22/3/10.11613/BM.2012.031>
- [29] J. L. Fleiss, B. Levin and M. C. Paik, *Statistical Methods for Rates and Proportions*, 3rd ed. New York, NY, USA: Wiley, 2003. Disponible en: <https://onlinelibrary.wiley.com/doi/book/10.1002/0471445428>
- [30] J. MacQueen, "Some Methods for Classification and Analysis of Multivariate Observations," *Proc. 5th Berkeley Symp. Math. Stat. Probab.*, vol. 1, pp. 281–297, 1967. Disponible en: <https://projecteuclid.org/journals/proceedings-of-the-berkeley-symposium/volume-5/issue-1>
- [31] J. Shlens, "A Tutorial on Principal Component Analysis," *arXiv preprint arXiv:1404.1100*, Apr. 2014. [Online]. Available: <https://arxiv.org/pdf/1404.1100>
- [32] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001. Disponible: <https://link.springer.com/article/10.1023/A:1010933404324>
- [33] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2nd ed. New York, NY, USA: Springer, 2009. Disponible en: <https://hastie.su.domains/ElemStatLearn/>
- [34] S. A. Rahman, "Illustration of random forest trees," ResearchGate, 2021. Disponible en: https://www.researchgate.net/figure/Illustration-of-random-forest-trees_fig4_354354484

- [35] A. K. Bhowan, “Diagram of ensemble methods: Bagging, Boosting, and Stacking,” ResearchGate, 2019. Disponible en: https://www.researchgate.net/figure/Diagram-of-ensemble-methods-A-Bagging-B-Boosting-C-Stacking-DT-decision-tree_fig1_331562581
- [36] C. J. C. Burges, “A Tutorial on Support Vector Machines for Pattern Recognition,” *Data Mining and Knowledge Discovery*, vol. 2, pp. 121–167, 1998. [Online]. Disponible en: <https://link.springer.com/article/10.1023/A%3A1009715923555>.
- [37] Scikit-learn developers, “Support Vector Machines — User Guide,” [scikit-learn.org](https://scikit-learn.org/stable/modules/svm.html), sección 1.4. [Online]. Disponible en: <https://scikit-learn.org/stable/modules/svm.html>.
- [38] I. T. Jolliffe y J. Cadima, “Principal component analysis: a review and recent developments,” *Philos. Trans. R. Soc. A*, vol. 374, no. 2065, 2016. DOI: 10.1098/rsta.2015.0202.
- [39] A.-M. Krypotos, M. Effting, M. Kindt y T. Beckers, “Avoidance learning: a review of theoretical models and recent developments,” *Front. Behav. Neurosci.*, vol. 9, p. 189, jul. 2015. [En línea]. Disponible: <https://pmc.ncbi.nlm.nih.gov/articles/PMC4508580/>.
- [40] D. Mobbs, C. Hagan, T. Dalgleish, B. Silston y C. Prévost, “The ecology of human fear: survival optimization and the nervous system,” *Front. Neurosci.*, 2015. [En línea]. Disponible: <https://pmc.ncbi.nlm.nih.gov/articles/PMC4364301/>.
- [41] T. M. Ball y L. A. Gunaydin, “Measuring maladaptive avoidance: from animal models to clinical anxiety,” *Neuropsychopharmacology*, vol. 47, pp. 978–986, 2022. [En línea]. Disponible: <https://www.nature.com/articles/s41386-021-01263-4>.
- [42] M. L. Brandão, “Different patterns of freezing behavior organized in the defensive continuum,” *Prog. Neuro-psychopharmacol. Biol. Psychiatry*, vol. 32, no. 8, pp. 1665–1670, 2008. doi: 10.1016/j.pnpbp.2007.12.002.
- [43] F. H. Klaassen, L. Held, B. Figner et al., “Defensive freezing and its relation to approach–avoidance decision-making under threat,” *Sci. Rep.*, vol. 11, Article number 12030, 2021. <https://doi.org/10.1038/s41598-021-90968-z>.
- [44] V. J. Jiménez-Planet and S. Hernández-Villegas, “REPISALUD (REPositorio Institucional de SALUD) del Instituto de Salud Carlos III (ISCIII) y sus Fundaciones: análisis de la puesta en marcha y evolución del proyecto,” Repisalud, Madrid, España. [Online]. Disponible en: <https://repisalud.isciii.es/rest/api/core/bitstreams/cdba37dc-a63b-43ff-a004-ec1762a6116e/content>.
- [45] G. Sun, C. Lyu, R. Cai, C. Yu, H. Sun, K. E. Schriver, L. Gao and X. Li, “DeepBhvTracking: A Novel Behavior Tracking Method for Laboratory Animals Based on Deep Learning,” *Frontiers in Behavioral Neuroscience*, vol. 15, Oct. 2021. [Online]. Disponible en: <https://www.frontiersin.org/journals/behavioral-neuroscience/articles/10.3389/fnbeh.2021.750894/full>

- [46] L. P. J. J. Noldus, A. J. Spink, R. A. J. Tegelenbosch, "EthoVision: A versatile video tracking system for automation of behavioral experiments," *Behavior Research Methods, Instruments, & Computers*, vol. 33, no. 3, pp. 398-414, 2001. <https://link.springer.com/content/pdf/10.3758/BF03195394.pdf>
- [47] J. M. Lim, B. Platt, S. K. Janhunen, G. Riedel. "Comparison of automated video tracking systems in the open field test: ANY-Maze versus Ethovision XT," *Journal of Neuroscience Methods*, vol. 397, pág. 109940, agosto de 2023, doi: 10.1016/j.jneumeth.2023.109940.
- [48] ML4Devs, "Why machine learning projects fail," ML4Devs, 2023. [Online]. Disponible en: <https://ml4devs.com/why-machine-learning-projects-fail/>
- [49] RheoData, "AI Failures Statistics: Why Today's Machine Learning Systems Fail," RheoData, 2024. [Online]. Disponible en: <https://rheodata.com/ai-failure-statistics/>
- [50] M. Berthold, "Why Most Machine Learning Models Never Get Deployed," KDnuggets, 2022. [Online]. Disponible en: <https://www.kdnuggets.com/2022/03/why-ml-models-rarely-get-deployed.html>
- [51] myosh, "What is a Risk Assessment Matrix?" myosh Safety Systems, 2024. [Online]. Disponible en: <https://myosh.com/blog/2024/04/24/what-is-a-risk-assessment-matrix/>
- [52] Beazley Group, "Guide to Risk Assessment," Cyber Customer Centre – Risk Management Tools, 2024. [Online]. Disponible en: <https://www.beazley.com/en-US/cyber-customer-centre/cyber-risk-management-tools/guide-to-risk-assessment/>
- [53] ISO, ISO 31000:2018 — Risk management — Guidelines, International Organization for Standardization, 2018.
- [54] National Institute of Standards and Technology, Guide for Conducting Risk Assessments (NIST SP 800-30 Rev.1), Gaithersburg, MD, USA, 2012.
- [55] Sharma, Akhilesh & Kumar, Vipin & Longchamps, Louis. (2024). Comparative performance of YOLOv8, YOLOv9, YOLOv10, YOLOv11 and Faster R-CNN models for detection of multiple weed species. *Smart Agricultural Technology*. 9. 100648. 10.1016/j.atech.2024.100648.
- [56] Ke, W., Liu, T., & Cui, X. (2025). IECA-YOLOv7: A Lightweight Model with Enhanced Attention and Loss for Aerial Wildlife Detection. *Animals*, 15(18), 2743. <https://doi.org/10.3390/ani15182743>
- [57] Adhikari, B., Li, J., Michel, E. S., Dykes, J., Tseng, T. P., Tagert, M. L., Chen, D. "A Comprehensive Evaluation of YOLO-based Deer Detection Performance on Edge Devices," Elsevier, 2025. [Online]. Disponible en: <https://arxiv.org/pdf/2509.20318v2>
- [58] Mathis, M. W., Mathis, A. "Deep learning tools for the measurement of animal behavior in neuroscience", Harvard University. [Online]. Disponible en: <https://ar5iv.labs.arxiv.org/html/1909.13868#:~:text=Deeper%20networks%20are%20slower%2C%20but,Other%20networks%20recently%20added>

- [59] S. Ye et al., “SuperAnimal pretrained pose estimation models for behavioral analysis,” *Nature Communications*, vol. 15, no. 1, p. 5165, Jun. 2024, doi: 10.1038/s41467-024-48792-2
- [60] J. Lauer et al., “multi-animal pose estimation, identification and tracking with DeepLabCut,” *Nature Methods*, vol. 19, no. 4, pp. 496–504, Apr. 2022, doi: 10.1038/s41592-022-01443-0
- [61] Vonstad, E. K., Su, X., Vereijken, B., Bach, K., & Nilsen, J. H. (2020). “Comparison of a Deep Learning-Based Pose Estimation System to Marker-Based and Kinect Systems in Exergaming for Balance Training.” *Sensors* (Basel, Switzerland), 20(23), 6940. <https://doi.org/10.3390/s20236940>
- [62] Udell, A. “Mean Shift and Cam Shift Object Tracking,” towards data science, 2021. [Online] Disponible en: <https://towardsdatascience.com/mean-shift-and-cam-shift-object-tracking-f1c2c515b6bc/>
- [63] Subramaniam, A. “Understanding Object Tracking: From Classical Filters to Deep Learning,” Medium, 2025. [Online]. Disponible en: <https://medium.com/ai-simplified-in-plain-english/understanding-object-tracking-from-classical-filters-to-deep-learning-1d950c449610>
- [64] Yurushkin, M. “A Complete Review of the OpenCV Object Tracking Algorithms,” broutonlab. [Online.] Disponible en: <https://broutonlab.com/blog/opencv-object-tracking/>
- [65] F. A. Team, “CNNs vs. Transformers: Image Recognition Models Explained,” Flypix, Feb. 10, 2025. <https://flypix.ai/es/image-recognition-models-cnns/>
- [66] L. Alzubaidi et al., “Review of deep learning: concepts, CNN architectures, challenges, applications, future directions,” *Journal of Big Data*, vol. 8, no. 1, p. 53, Mar. 2021, doi: 10.1186/s40537-021-00444-8.
- [67] C. Stryker, “Red neuronal recurrente (RNN),” IBM, Feb. 05, 2025. <https://www.ibm.com/es-es/think/topics/recurrent-neural-networks>
- [68] “¿Cuáles son las ventajas y desafíos de usar LSTM o GRU para dependencias a largo plazo en series temporales?,” Sep. 01, 2023. <https://www.linkedin.com/advice/1/what-advantages-challenges-using-lstm-gru-long-term?lang=es>
- [69] A. M. Calero, A. Rasheed, and A. Lekkas, “Chronoshap: Revealing Temporal Patterns from Transformers and Ltsf-Linear Models in Time Series Forecasting,” *SSRN Electronic Journal*, Jan. 2025, doi: 10.2139/ssrn.5403215.
- [70] L. Ramírez, “Algoritmo k-means: ¿Qué es y cómo funciona?” *Thinking for Innovation*, Oct. 30, 2024. <https://www.iebschool.com/hub/algoritmo-k-means-que-es-y-como-funciona-big-data/>
- [71] J. Rew, S. Park, Y. Cho, S. Jung, and E. Hwang, “Animal movement prediction based on predictive recurrent neural network,” *Sensors*, vol. 19, no. 20, p. 4411, Oct. 2019, doi: 10.3390/s19204411.
- [72] R. Mosquera, O. D. Castrillón, and L. Parra, “Máquinas de Soporte Vectorial, Clasificador Naïve Bayes y Algoritmos Genéticos para la Predicción de Riesgos Psicosociales en Docentes de Colegios Públicos Colombianos *Información Tecnológica*, vol. 29, no. 6, pp. 153–162, Dec. 2018, doi: 10.4067/s0718-07642018000600153.

- [73] ISO, “ISO 14064-1: Greenhouse gases — Part 1: Specification with guidance at the organization level,” 2018.
- [74] Green Software Foundation, “Principles of Sustainable Software Engineering,” IEEE Software, 2022.
- [75] M. K. Patterson, “Power and Energy Consumption in IT Systems,” IEEE Computer Society Technical Report, 2022.
- [76] S. Balaji et al., “Energy Behavior of Cloud-Based ML Execution Environments,” IEEE Transactions on Cloud Computing, 2023.
- [77] International Energy Agency, “Emission Factors for Mexico,” cited in IEEE Energy and Environment Proceedings, 2024.
- [78] J. Rojas et al., “Urban Mobility and Carbon Emissions in Latin American Megacities,” IEEE Transactions on Intelligent Transportation Systems, 2023.
- [79] A. Mittal et al., “Energy Efficiency of Machine Learning Models in Edge Devices,” IEEE Transactions on Sustainable Computing, vol. 8, no. 2, 2023.
- [80] ISO, “ISO 26000: Guidance on Social Responsibility,” 2010.
- [81] T. J. McCabe, “A Complexity Measure,” IEEE Transactions on Software Engineering, vol. SE-2, no. 4, 1976.
- [82] ISO/IEC, “25010: System and Software Quality Models,” 2011.
- [83] Microsoft, “Especificaciones y requisitos del sistema de Windows 11 | Microsoft Windows,” Windows. <https://www.microsoft.com/es-es/windows/windows-11-specifications>
- [84] “The Python tutorial,” Python Documentation. <https://docs.python.org/3/tutorial/index.html>
- [85] Transformative Mobility Lab / Factsheet, Mexico City — Modal split and public transport overview, 2021 (public data fact sheet; modal share: public transport $\approx$ 50%). TUMI
- [86] World Bank / Operational Evaluation & related analyses, Cost effectiveness of CO₂ reduction with hybrid and electric buses — example estimates for Mexico (electric bus $\approx$ 1 kWh/km $\rightarrow$ $\sim$ 0.6 kg CO₂/veh-km in Mexican grid)-
- [87] R. Kohavi, “A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection,” en Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI), Montreal, Canada, 1995, pp. 1137–1143.
- [88] M. Sokolova y G. Lapalme, “A systematic analysis of performance measures for classification tasks,” Information Processing & Management, vol. 45, no. 4, pp. 427–437, 2009.
- [89] D. M. W. Powers, “Evaluation: From Precision, Recall and F-Measure to ROC, Informedness, Markedness and Correlation,” Journal of Machine Learning Technologies, vol. 2, no. 1, pp. 37–63, 2011.

- [90] Scikit-learn Developers, "Classification metrics," Scikit-learn Documentation. [En línea]. Disponible en: https://scikit-learn.org/stable/modules/model_evaluation.html. [Accedido: 27-may-2026].
- [91] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," *Proc. CVPR*, 2016.
- [92] Ultralytics, "YOLO Documentation," 2025.
- [93] P. Bovet y S. Benhamou, "Spatial analysis of animals' movements," *Journal of Theoretical Biology*, vol. 131, no. 4, pp. 419–433, 1988.
- [94] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [95] S. Hochreiter y J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [96] S. R. Datta et al., "Computational neuroethology," *Nature*, vol. 562, pp. 361–370, 2018.
- [97] S. Pellow et al., "Validation of open arm entries in an elevated plus-maze," *Journal of Neuroscience Methods*, vol. 14, pp. 149–167, 1985.
- [98] J. Cohen, "A coefficient of agreement for nominal scales," *Educational and Psychological Measurement*, vol. 20, pp. 37–46, 1960.
- [99] J. R. Landis y G. G. Koch, "The measurement of observer agreement for categorical data," *Biometrics*, vol. 33, no. 1, pp. 159–174, 1977.
- [100] G. E. P. Box, "Some theorems on quadratic forms," *Annals of Mathematical Statistics*, vol. 25, no. 2, pp. 290–302, 1954.
- [101] D. C. Montgomery y G. C. Runger, *Applied Statistics and Probability for Engineers*, 7th ed. Wiley, 2018.
- [102] R. A. Fisher, *Statistical Methods for Research Workers*, 14th ed. Oliver and Boyd, 1970.
- [103] J. Cohen, *Statistical Power Analysis for the Behavioral Sciences*, 2nd ed. Routledge, 1988.
- [104] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2nd ed. Springer, 2009.
- [105] A. Ng, *Machine Learning Yearning*. Deeplearning.ai, 2018.
- [106] B. W. Boehm, "A Spiral Model of Software Development and Enhancement," *Computer*, vol. 21, no. 5, pp. 61–72, May 1988, doi: 10.1109/2.59.
- [107] D. Maji, S. Ray, S. Das, and A. Chatterjee, "YOLO-Pose: Enhancing YOLO for Multi-Person Pose Estimation," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, 2022, pp. 2637–2646.

- [108] Cámara de Diputados del H. Congreso de la Unión, “Ley General de Protección de Datos Personales en Posesión de Sujetos Obligados,” Diario Oficial de la Federación, México, 20-mar-2025. [En línea]. Disponible en: <https://www.diputados.gob.mx/LeyesBiblio/ref/lgdpdppo.htm>
- [109] Cámara de Diputados del H. Congreso de la Unión, “Ley Federal del Derecho de Autor,” Diario Oficial de la Federación, México, 24-dic-1996 (con reformas vigentes). [En línea]. Disponible en: <https://www.diputados.gob.mx/LeyesBiblio/ref/lfa.htm>
- [110] Ultralytics, “Ultralytics Licensing: AGPL-3.0 y Licencia Enterprise,” 2025. [En línea]. Disponible en: <https://www.ultralytics.com/license>
- [111] Computrabajo, Indeed e Hireline, “Salario de programador junior en México,” 2026. [En línea]. Disponible en: <https://hireline.io/mx/enciclopedia-de-perfiles-de-tecnologia/junior-developer> (consultado el 7 de junio de 2026).
- [112] Amazon México, “Laptop de alto rendimiento (GPU NVIDIA GeForce RTX 5070 Ti, 32 GB RAM),” 2026. [En línea]. Disponible en: <https://www.amazon.com.mx/dp/B0G2T512W3> (consultado el 7 de junio de 2026).
- [113] ANY-maze, “ANY-maze Pricing,” Stoelting Co., 2026. [En línea]. Disponible en: <https://www.any-maze.com/pricing/> (consultado el 7 de junio de 2026).
- [114] ConductScience, “Noldus EthoVision XT,” Maze Engineers, 2026. [En línea]. Disponible en: <https://maze.conductscience.com/portfolio/noldus-ethovisionxt/> (consultado el 7 de junio de 2026).
- [115] Banco de México, “Tipo de cambio FIX, 5 de junio de 2026: 17.4755 MXN/USD,” Portal del Mercado Cambiario, 2026. [En línea]. Disponible en: <https://www.banxico.org.mx/portal-mercado-cambiario/> (consultado el 7 de junio de 2026).
- [116] A. I. Hsu y E. A. Yttri, “B-SOiD, an open-source unsupervised algorithm for identification and fast prediction of behaviors,” *Nature Communications*, vol. 12, art. 5188, 2021. doi: 10.1038/s41467-021-25420-x.
- [117] C. Weinreb, J. Pearl, S. Lin et al., “Keypoint-MoSeq: parsing behavior by linking point tracking to pose dynamics,” *Nature Methods*, vol. 21, pp. 1329-1339, 2024. doi: 10.1038/s41592-024-02318-2.
- [118] N. L. Goodwin, J. J. Choong, S. Hwang et al., “Simple Behavioral Analysis (SimBA) as a platform for explainable machine learning in behavioral neuroscience,” *Nature Neuroscience*, vol. 27, pp. 1411-1424, 2024. doi: 10.1038/s41593-024-01649-9.
- [119] C. Segalin et al., “The Mouse Action Recognition System (MARS),” *eLife*, vol. 10, e63720, 2021. doi: 10.7554/eLife.63720.
- [120] J. P. Bohnslav et al., “DeepEthogram, a machine learning pipeline for supervised behavior classification from raw pixels,” *eLife*, vol. 10, e63377, 2021. doi: 10.7554/eLife.63377.
- [121] K. Luxem et al., “Identifying behavioral structure from deep variational embeddings,” *Communications Biology*, vol. 5, art. 1267, 2022. doi: 10.1038/s42003-022-04080-7.

Apéndice

El cronograma completo del proyecto de los tres integrantes del equipo se encuentra disponible en el siguiente enlace, en un formato digital:

<https://smurl.es/2026-A155-Cronograma>

Prototipo I. Durante la primera etapa de desarrollo, alrededor de finales de junio y principios de julio, construimos un primer prototipo funcional para el análisis automatizado del comportamiento de roedores en el laberinto en cruz elevada. Este prototipo marcó un punto de partida importante: permitió comprobar la viabilidad del sistema, validar nuestras ideas iniciales y reconocer, con evidencia, las limitaciones técnicas que debíamos resolver para iteraciones posteriores.




Ilustración 55 "Ilustración del modelo [auditoria propia]"

1. Modelo inicial apenas entrenado. En esta primera fase, el modelo con el que trabajábamos estaba apenas en construcción: contábamos con muy pocas imágenes de entrenamiento y todavía no existía un dataset sólido ni estandarizado. Por esta razón, el desempeño inicial era limitado; el sistema lograba detectar al ratón, pero lo hacía con poca precisión y de manera inconstante. Fallaba especialmente cuando el animal cambiaba de orientación, se desplazaba rápido, entraba a zonas con sombra o cruzaba hacia los brazos cerrados. Aun con estas carencias, este primer modelo nos permitió comprobar que el enfoque era viable y que la base del proyecto funcionaba, aunque de manera rudimentaria.

2. Ejecución completamente en local. En esta segunda etapa, todo el sistema se ejecutaba únicamente en la computadora local, lo que significaba depender por completo del hardware personal disponible. Esto nos permitió tener un primer acercamiento práctico al flujo de trabajo, pero también nos enfrentó rápidamente a varias limitaciones importantes. El procesamiento de los videos resultaba muy lento debido a la ausencia de una GPU dedicada, y el equipo se sobrecalentaba con facilidad durante las corridas más largas. Además, trabajar solo con CPU hacía prácticamente imposible entrenar modelos más grandes o experimentar con arquitecturas complejas, lo que restringía nuestras opciones técnicas. Cada análisis requería bastante tiempo, ya que el modelo inicial tenía un bajo nivel de entrenamiento y el preprocesamiento cuadro por cuadro demandaba más recursos de los que la máquina podía ofrecer.

3. Primeras herramientas en Python y OpenCV. En esta etapa inicial, el desarrollo del sistema se apoyó completamente en Python y en un conjunto reducido de herramientas de visión por computadora, principalmente OpenCV. Con ellas implementamos las primeras funciones esenciales del flujo de trabajo: extracción de fotogramas, limpieza básica de imagen, delimitación manual de regiones de interés y dibujo de las detecciones sobre el video. Si bien las capacidades eran todavía limitadas, estos módulos nos permitieron construir un pipeline funcional capaz de cargar un video, identificar al espécimen y generar una visualización preliminar de su trayectoria dentro del laberinto. Gracias a estas pruebas, pudimos confirmar que el enfoque elegido era viable y que los componentes iniciales se integraban correctamente entre sí. Aunque el sistema aún no incorporaba técnicas avanzadas como estimación de postura, modelado temporal o minería de datos, este primer conjunto de herramientas fue suficiente para establecer las bases del análisis automatizado y abrir el camino para las siguientes etapas del proyecto.

4. Contador de eventos: funcional, pero aún limitado. El contador de eventos desarrollado en el prototipo inicial permitía registrar aspectos básicos del comportamiento del espécimen, como las entradas y salidas de los brazos, la presencia en zonas específicas y la permanencia aproximada en cada área del laberinto. Aunque cumplía con su propósito fundamental, su precisión y alcance eran todavía reducidos. El sistema dependía exclusivamente del movimiento del cuadro de detección, lo que ocasionaba errores cuando el ratón quedaba parcialmente oculto, se superponía con sombras o se desplazaba cerca de los bordes. Además, este contador no tenía la capacidad de diferenciar posturas ni de identificar eventos conductuales más complejos, como episodios de acicalamiento o periodos prolongados de inmovilidad, elementos esenciales para un análisis etológico más riguroso. A pesar de estas limitaciones, el módulo cumplió su función dentro del prototipo, pues permitió validar la estructura general del análisis y evidenció con claridad las áreas que requerían un desarrollo más profundo en etapas posteriores.

Prototipo II. En el segundo prototipo se logró un avance relevante al incrementar el conjunto de imágenes de entrenamiento respecto a la versión inicial. Esta etapa permitió identificar problemas de confusión con el operador y motivó la curación posterior del dataset hasta consolidar el modelo final YOLO11 Pose con 3,953 imágenes etiquetadas.




Ilustración 56 "Ilustración del modelo prototipo II [auditoria propia]"

A pesar de este avance en detección, en esta etapa **aún no se había integrado la estimación de postura (pose stimation)**, una funcionalidad que se evaluará más adelante para complementar la clasificación conductual y enriquecer el análisis etológico. Sin embargo, incluso sin esta capa adicional de análisis, el sistema ya mostraba un comportamiento mucho más estable que la versión previa. El **contador de eventos**, por ejemplo, **presentó mejoras significativas**: dejó de desaparecer, mantuvo su consistencia a lo largo de la grabación y reflejó de manera más confiable las entradas y tiempos de permanencia en cada zona del laberinto.

Otro cambio relevante de esta iteración fue la **migración del procesamiento a una GPU en Google Colab**, lo que permitió un rendimiento muy superior al obtenido en ejecución local. La mayor capacidad de cómputo redujo los tiempos de inferencia y facilitó la manipulación de modelos más complejos. No obstante, esta transición trajo consigo ciertas limitaciones técnicas, especialmente relacionadas con la interacción gráfica.

En Colab no fue posible desplegar ventanas para delimitar visualmente las áreas de interés del laberinto, por lo que la marcación de regiones se tuvo que realizar de forma manual introduciendo coordenadas. Aunque este proceso no afectó el funcionamiento general, sí representó un obstáculo operativamente importante que deberá solucionarse en prototipos futuros para garantizar una experiencia más fluida y automatizada.

Este segundo prototipo representa un progreso considerable: el modelo detecta con mucha mayor precisión, el contador de eventos opera de manera estable y la infraestructura de ejecución es más potente y eficiente. Aun con sus limitaciones, se consolidaron las bases para avanzar hacia una versión más robusta, donde se incorporará pose estimation, más datos de entrenamiento y nuevas evaluaciones del rendimiento general del sistema.

Transcripción de la entrevista realizada al Dr. Sandino el 30 de septiembre de 2025:

1. **¿Cuál sería el principal problema que se espera resolver con la aplicación? ¿Y qué resultado considera exitoso?**

Sandino: El principal problema que tenemos, como reto, es poder interpretar de forma automatizada las diferentes conductas en este modelo. Y lo que lograríamos es estandarizar la interpretación de manera que no dependa del observador la asignación de las diferentes conductas que se le dan a la rata durante el experimento. Ok. Perfecto.

2. **Sobre los datos ¿Qué tipo de videos y anotaciones necesitamos recolectar para que el sistema sea realmente útil?**

Sandino: Se necesita la captura de un video que pueda reflejar con el detalle suficiente todas las conductas que queremos evaluar. Para que entonces podamos hacer una adecuada interpretación de esas conductas.

3. **De las funcionalidades. ¿Qué conductas o métricas considera más importantes que el sistema detecta automáticamente? Por ejemplo, trayectorias, tiempo de movilidad, o zonas de permanencia.**

Sandino: Si bien todas nos dan información diferente que es útil para poder interpretar el efecto que podamos tener en una molécula con fines de utilización como ansiolítico. Los tiempos en brazos abiertos y los tiempos en brazos cerrados son los principales indicadores de que se está teniendo un efecto ansiolítico. A qué nivel y con qué características nos sirve el resto de los parámetros; los tiempos en brazos cerrados y tiempo en brazos abiertos en general son los principales indicadores.

4. **¿Qué visualizaciones les resultan más útiles para la toma de decisiones? Por ejemplo, podemos hacer gráficas, heatmaps (mapas de calor), reportes comparativos o alertas.**

Sandino: Los gráficos son más útiles porque son los que solemos utilizar, pero personalmente a mí me gustan los mapas de calor en el equipo donde me puede extraer el mismo valor que pondríamos en los gráficos, en los parámetros globales. Entonces, si en el mapa de calor se me puede poner en un brazo o en los brazos cerrados el tiempo total, pero yo además puedo ver qué tanto se desplaza en diferentes regiones de ese brazo me sería muy útil.

5. **¿Qué nivel de precisión o concordancia espera que considere aceptable para que la aplicación sea adoptada? Por ejemplo, más del 90% o 95%**

Sandino: Nosotros actualmente lo hacemos con tres personas diferentes que hacen la evaluación de forma independiente, entonces la variación que solemos tener entre esas tres personas suele ser entre el 10% y el 15% del valor medio. Por lo tanto, entre el 90% y el 95%

de precisión sería excelente para fines de tomar como verdaderos los datos que nos arroja el análisis.

6. Respecto a usabilidad ¿Qué tan importante es que la aplicación tenga una interfaz sencilla y accesible para las personas sin experiencia técnica?

Sandino: Muy importante. Tengo médicos que se dedican a hacer estos experimentos. Mientras más amigable sea la interfaz pues es más asequible que puedan ellos utilizarla con precisión y que sea adecuado el uso.

Equipo: Lo que teníamos pensado era hacer la aplicación, y nada más que seleccionen el video, recortar dicho video, y definir el área a estudiar.

Sandino: De hecho, algo que tal vez podría funcionar es que automáticamente uno pudiera decir “Empieza a registrar a partir de tal segundo”. De manera que no dependa tanto que la persona que vaya a analizar el video lo recorte o lo tenga que recortar. Porque eso implica por lo menos un programa de edición de video que tienen que aprender a utilizar, pero si en la interfase le podemos poner “Empieza a analizar a partir de tal segundo” ... Y que entonces el conteo empieza a partir de ese segundo, no importa si el video tiene diez segundos que se tienen que omitir o cinco o tres, sino nada más uno lo previsualiza y dice “bueno, a partir del segundo quince es cuando se va a poner, a empezar a tomar, porque ya se salió el operario, ya se estabilizó la imagen y la rata ya se estabiliza también”.

7. Este es sobre la sobriedad de interfaz ¿Prefiere una aplicación web con dashboards interactivos o reportes descargables en PDF o Excel?

Sandino: Yo creo que en Excel porque eso nos permite llevarlo a otros programas. Por ejemplo, hay veces que utilizamos graficadores como Origin nada más por fines de publicación, porque Origin nos permite hacer gráficos (BueR, o, ya los hacemos más en R, pero todavía hay quienes lo hacen en Origin) ya con fines de publicación, donde podemos editar como lo pida la revista, el tamaño de los títulos, de los ejes, o cualquier cosa, ya lo hacemos también en R, con Excel nos puede servir muy bien también R.

Equipo: Entonces serían dos cosas, o sea, un Excel con los datos ya analizados, o digamos en crudo, y además las gráficas que se muestran en el programa, ¿no?

Sandino: Sí. Finalmente, los gráficos nos van a ayudar a ir viendo cómo se comporta el espécimen durante el video, pero esas gráficas seguramente no van a ser las que llevemos a la presentación final de los resultados, seguramente nos servirán los datos analizados o crudos, de donde provienen esas gráficas, pero para Re graficarlo nada más.

8. ¿Desea tener un registro de todos los dashboards y análisis realizados?

Sandino: Dependerá de la capacidad de cómputo y almacenamiento, ya que los videos ocupan mucho espacio. Lo ideal sería conservar únicamente los resultados procesados, no los videos, para evitar requerir demasiado almacenamiento. Con respecto al procesamiento, el laboratorio cuenta con varias opciones: una computadora con buena capacidad, un pequeño clúster y la

posibilidad de usar equipos con GPU o incluso servicios en la nube si fuera necesario. Para decidir cuál es la mejor opción, es importante conocer primero los requerimientos óptimos de cómputo del sistema.



Ilustración 64: Diagrama de casos global. [autoría propia]




Ilustración 65: Diagrama de casos de uso de autenticación de usuarios y gestión de acceso. [autoría propia]




Ilustración 66: Diagrama de casos de uso de ingesta de video. [autoría propia]




Ilustración 67: Diagrama de casos de uso de extracción de keypoints . [autoría propia]




Ilustración 68: Diagrama de casos de uso de configuración de regiones de interés. [autoría propia]




Ilustración 69: Diagrama de casos de uso de análisis final conductual. [autoría propia]




Ilustración 70: Diagrama de casos de uso del módulo de resultados y estadísticas. [autoría propia]




Ilustración 71: Diagrama de casos de uso del módulo de comparación. [autoría propia]




Ilustración 72: Diagrama de casos de uso de administración del sistema. [autoría propia]

