



INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO



ESCOM

Trabajo Terminal

**“Prototipo para análisis automatizado y visualización de
comportamiento de especímenes en modelos de ansiedad”**

2026-A155

Presentan

Portocarrero Rodríguez Habid

Directores

Ramírez Guzmán Alicia Marcela

Salas Ramírez Israel

Junio 2026



INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO
SUBDIRECCIÓN ACADÉMICA



No de TT 2026-A155

junio de 2026

Documento Técnico

**“Prototipo para análisis automatizado y visualización de
comportamiento de especímenes en modelos de ansiedad”**

Presentan

Portocarrero Rodríguez Habid¹

Directores

Ramírez Guzmán Alicia Marcela

Salas Ramírez Israel

RESUMEN

El presente proyecto desarrolla un prototipo de software orientado al análisis automatizado del comportamiento animal en modelos experimentales de ansiedad. Su propósito es optimizar los procesos de observación y evaluación que tradicionalmente se realizan de forma manual, reduciendo tiempos y errores humanos. A través de la aplicación de principios de ingeniería de software, se busca ofrecer una herramienta confiable, escalable y eficiente que contribuya al avance de la investigación científica dentro del ámbito biomédico.

¹hportocarreror1700@alumno.ipn.mx

CARTA RESPONSIVA

Que otorga visto bueno y avala la conclusión de documentación del Trabajo Terminal bajo los lineamientos establecidos por la Comisión Académica de Trabajos Terminales (CATT)

CDMX, junio de 2026

M. EN C. IVAN GIOVANNI MOSSO GARCÍA
PRESIDENTE DE LA COMISIÓN ACADÉMICA DE TRABAJOS TERMINALES
P R E S E N T E

EN ATENCIÓN A:

M. EN A.N. MARÍA MAGDALENA SALDIVAR ALMOREJO
SECRETARIA EJECUTIVA

Por medio de la presente, se informa que el Trabajo Terminal Núm.	2026-A155
Que lleva por Título:	Prototipo para análisis automatizado y visualización de comportamiento de especímenes en modelos de ansiedad

Fue concluido satisfactoriamente por:

Portocarrero Rodríguez Habid

Se avala que la documentación entregada mediante discos en formato DVD fue **revisada de manera precisa y exhaustiva** con el propósito de asegurar que los avances desarrollados bajo la supervisión de quien o quienes suscriben, hayan cumplido con lo planteado en el protocolo original, así como en lo establecido por el Documento Rector de Operación y Evaluación para los Trabajos Terminales de la ESCOM.

ATENTAMENTE
“LA TÉCNICA AL SERVICIO DE LA PATRIA”

Israel Salas Ramírez
Director

Alicia Marcela Ramírez Guzmán
Directora

Palabras clave:

Modelos de ansiedad, análisis Conductual Animal, ensayos Farmacológicos, visión por computadora (Computer Vision), estimación de Postura, detección de Objetos, inteligencia artificial (IA), aprendizaje automático (Machine Learning), minería de Datos (Data Mining), dashboard interactivo.

Advertencia

“Este documento contiene información desarrollada por la Escuela Superior de Cómputo del Instituto Politécnico Nacional, a partir de datos y documentos con derecho de propiedad y, por lo tanto, su uso quedará restringido a las aplicaciones que explícitamente se convengan.”

La aplicación no convenida exime a la escuela su responsabilidad técnica y da lugar a las consecuencias legales que para tal efecto se determinen.

Información adicional sobre este reporte técnico podrá obtenerse en:

La Subdirección Académica de la Escuela Superior de Cómputo del Instituto Politécnico Nacional, situada en Av. Juan de Dios Bátiz s/n Teléfono: 57296000, extensión 52000.

Agradecimientos

El equipo desea expresar su más sincero agradecimiento al **Instituto Politécnico Nacional** y a la **Escuela Superior de Cómputo (ESCOM)** por ser la base de nuestra formación profesional, el apoyo, orientación y por brindarnos los recursos necesarios para la realización de este proyecto.

A nuestros **directores**, la **Dra. Alicia Marcela Ramírez Guzmán** y el **Dr. Israel Salas Ramírez**, por su guía, paciencia y compromiso. Su acompañamiento constante, su exigencia académica y su apoyo humano fueron fundamentales para la consolidación de este trabajo. Gracias por enseñarnos que la investigación y la tecnología deben siempre ir acompañadas de ética, rigor y propósito.

A la **Escuela Nacional de Medicina y Homeopatía (ENMyH)**, por su colaboración y disposición en la etapa experimental del proyecto, y por permitirnos vincular la ingeniería con la ciencia biomédica.

A **nuestras familias**, quienes con amor, comprensión y apoyo incondicional fueron nuestra fortaleza durante todo el proceso. Su confianza nos motivó a superar cada obstáculo y a culminar esta etapa con orgullo.

A nuestros **compañeros, docentes y amigos** que, directa o indirectamente, compartieron su tiempo, conocimiento y entusiasmo, enriqueciendo este proyecto con su colaboración y sus ideas.

ÍNDICE

Contenido

Agradecimientos	6
INDICE DE TABLAS	15
Glosario de términos	15
Abreviaturas	20
Capítulo 1. Introducción	21
1.1 Antecedentes	21
1.2 Planteamiento del problema	22
1.3 Propuesta de solución	22
1.4 Objetivo general	23
1.4.1 Objetivos específicos.....	23
1.5 Justificación	24
1.6 Alcance del proyecto	24
1.7 Metodología	25
Capítulo 2. Estado del arte.....	27
2.1 Análisis etológico y temporal del comportamiento similar a la ansiedad: el modelo de EPM elevado 20 años después	28
2.2 El laberinto en T elevado como modelo experimental de ansiedad	28
2.3 El uso del EPM como un ensayo del comportamiento relacionado con la ansiedad en roedores.....	28
2.4 Prueba del EPM Combinado con Software de Seguimiento por Video para Investigar el Efecto Ansiolítico de Suplementos Cetogénicos Exógenos	29
2.5 Prueba del EPM para Evaluar el Comportamiento Similar a la Ansiedad en el Ratón	30
2.6 El diazepam provoca efectos sedantes más que ansiolíticos en ratones C57BL/6J.....	30
2.7 ezTrack: Un flujo de análisis de video de código abierto para la investigación del comportamiento animal	31
2.8 Analixity: Un sistema de análisis de código abierto y bajo costo para la prueba de EPM, basado en técnicas de visión por computadora	32
2.9 EthoVision.....	32
2.10 ANY-maze	33

2.11 Tabla Comparativa	33
Capítulo 3. Marco Teórico	36
3.1 Visión por computadora para seguimiento de objetos	36
3.1.1 YOLO (You Only Look Once)	36
3.1.2 DeepLabCut.....	38
3.1.3 Estimación de postura (Pose Estimation)	40
3.1.4 CAMShift y métodos clásicos de seguimiento.....	42
3.1.5 Redes Neuronales Convolucionales (CNN) aplicadas a visión por computadora ...	44
3.2 Machine Learning para Series Temporales	46
3.2.1 Redes Neuronales Recurrentes (RNN)	46
3.2.2 LSTM (Long Short-Term Memory)	47
3.2.3 Transformers.....	49
3.2.4 Coeficiente Kappa de Cohen para validación de concordancia	51
3.3. Minería de Datos y Clasificación de Comportamientos	53
3.3.1 K-Means (Clustering)	53
3.3.2 Random Forest.....	55
3.3.3 Máquinas de Vectores de Soporte (SVM)	57
3.3.4 Reducción de dimensionalidad	59
3.4 Modelos experimentales en etología y neurociencia conductual.....	61
3.4.1 Conceptos etológicos del comportamiento ansioso	61
3.4.1.1 Exploración	61
3.4.1.2 Evitación	63
3.4.1.3 Inmovilidad/congelación	65
3.4.2 Laberinto en Cruz Elevada (EPM)	66
3.5 Sistema operativo.....	68
3.5.1 Windows 10/11	68
3.6 Lenguaje de programación	68
3.6.1 Python	69
Capítulo 4. Análisis	69
4.1 Requerimientos.....	69
4.1.1 Requerimientos Funcionales (RF)	70
4.1.2 Requerimientos No Funcionales (RNF).....	71

4.1.3 Reglas del negocio.....	71
4.2 Análisis de las herramientas a utilizar	73
4.2.1 Análisis de técnicas de detección de objetos.....	74
4.2.2 Análisis de técnicas de estimación de pose con aprendizaje profundo	74
4.2.3 Análisis de técnicas de estimación de pose.....	74
4.2.4 Análisis de herramientas de seguimiento visual.....	75
4.2.5 Análisis de arquitecturas de redes neuronales profundas para visión por computadora	76
4.2.6 Análisis de arquitecturas de aprendizaje profundo para series temporales	76
4.2.7 Análisis de técnicas de minería de datos	76
4.2.8 Análisis de sistemas operativos.....	76
4.2.9 Análisis de los lenguajes de programación	77
4.3 Análisis de riesgos	77
4.3.6 Identificación de requerimientos técnicos.....	82
4.3.7 Requerimientos del prototipo	83
4.4 Análisis de factibilidad	83
4.4.1 Factibilidad tecnológica.....	83
4.4.1.1 Evaluación de recursos actuales y brechas tecnológicas	83
4.4.1.2 Simulación, modelado y pruebas.....	83
4.4.1.3 Evaluación de compatibilidad e integración.....	83
4.4.2 Factibilidad operativa	84
4.4.3 Factibilidad económica.....	85
4.4.3.1 Costos fijos	85
4.4.3.2 Costos variables	86
4.4.3.3 Costos totales estimados del desarrollo del proyecto	87
4.4.3.4 Conclusión de viabilidad económica.....	87
4.4.4 Factibilidad legal	87
4.4.4.1 Identificación del marco legal aplicable	87
4.5 Análisis de sostenibilidad.....	88
4.5.1 Evaluación del consumo energético del proyecto	88
4.5.3 Impacto ambiental del proceso tradicional vs. el prototipo.....	90
3.5.4 Comparación con el prototipo	91

Capítulo 5. Diseño.....	93
5.1 Arquitectura del prototipo	93
5.2 Modelo de bases de datos.....	93
5.2.1 Diccionario de datos	97
5.3 Casos de uso	103
5.3.1 Casos de uso del prototipo.....	103
5.3.2 Diagramas de secuencia.....	106
5.3.3 Diagrama de clases	120
Capítulo 6. Desarrollo	123
6.1 Mockups del prototipo	123
6.1.1 Vista previa del inicio de sesión.	123
6.1.2 Vista previa de registro.....	124
6.1.3 Vista previa de cambio de contraseña.....	125
6.1.4 Vista previa de inicio del prototipo	125
6.2 Pantallas del prototipo.....	127
6.2.1 Pantalla de bienvenida.....	127
6.2.2 Pantalla de inicio de sesión	128
6.2.3 Pantalla de ingesta de video	129
6.2.4 Pantalla de Configuración de Zonas.....	130
6.3 Optimización de la infraestructura de cómputo y aceleración por hardware	130
6.3.1 Análisis crítico de la resolución espacial e integridad de datos etológicos	131
6.3.2 Evolución de los modelos de IA y entrenamiento de alta fidelidad.....	132
6.3.3 Refinamiento de la arquitectura modular y continuidad temporal	133
6.3.4 Herramientas de usabilidad y visualización HUD avanzada	134
6.3.5 Validación de escenario ciego y gestión de factores de riesgo.....	134
6.4 Validación experimental y refinamiento de la estimación de postura.....	135
6.5 Refinamiento del pipeline de inferencia, integración de SimBA y optimización de la trazabilidad conductual	137
6.6 Optimización de la arquitectura de software, estandarización de identidad institucional y refinamiento del flujo de datos.....	138
6.7 Fortalecimiento de la seguridad de acceso, depuración de dependencias de bajo nivel y optimización de recursos de cómputo.....	139

6.8 Escalamiento del dataset para la detección de microconductas y validación de la robustez del sistema	140
6.9 Estandarización de identidad institucional, optimización de inferencia y refinamiento de criterios de anotación de puntos clave	141
6.10 Consolidación analítica de grupos experimentales, refinamiento de microconductas vía LSTM y estrategia de escalamiento masivo	143
6.10.1 Implementación del módulo de comparación estadística y control de grupos ...	143
6.10.2 Refinamiento del pipeline: YOLO Pose v4 y rrquitectura de rescate LSTM	143
6.10.3 Optimización administrativa, UX y persistencia de resultados	144
6.10.4 Estrategia de escalamiento del dataset e hitos de conclusión.....	144
Capítulo 7. Ciclo de desarrollo	144
7.1 Iteración 1	144
7.2 Iteración 2.....	145
7.2.1 Validación Leave-One-Out	145
7.2.2 Métricas de evaluación	146
7.2.3 Limitaciones de exactitud como métrica principal	146
7.2.4 Interpretación de precision, recall y F1-Score	148
7.2.5 Funcionamiento de la validación	149
7.2.6 Modelos evaluados y estrategias comparadas.....	150
7.2.7 Resultados principales del experimento.....	150
7.2.8 Uso de F1-score	151
7.2.9 Interpretación de los resultados	152
7.2.10 Casos de estudio representativos	153
7.2.11 Ground Truth y anotaciones humanas	154
7.3 Iteración 3.....	155
7.3.1 Adquisición y normalización de video.....	155
7.3.2 Extracción de pose	155
7.3.3 Capa de clasificación primaria	164
7.3.4 Capa de rescate temporal basada en LSTM	164
7.3.5 Determinación del tamaño de muestra	164
7.3.6 Módulo de comparación estadística	167
7.3.7 Paso 1 – Acceso al sistema.....	169

7.3.8 Paso 2 – Ingesta del video.....	171
7.3.9 Paso 3 – Extracción de keypoints	174
7.3.10 Paso 4 – Configuración de zonas del EPM	176
7.3.11 Paso 5 – Análisis final	179
7.3.12 Paso 6 – Consulta de resultados	181
7.3.13 Paso 7 – Comparación de resultados	185
7.4 Iteración 4.....	Error! Bookmark not defined.
Conclusiones	Error! Bookmark not defined.
Trabajo a futuro.....	Error! Bookmark not defined.
Referencias	215
Apéndice	223

<i>Ilustración 1: OpenAI (2025). Imagen generada por ChatGPT sobre el concepto de metodología de espiral de Boehm [Imagen generada por IA]. ChatGPT (versión 5.1). Archivo creado por el usuario, sin URL.</i>	<i>27</i>
<i>Ilustración 2: Fases de un sistema de Visión Artificial.....</i>	<i>36</i>
<i>Ilustración 3: Pasos para el reconocimiento de patrones</i>	<i>36</i>
<i>Ilustración 4: Ventana de seguimiento de un objeto en tiempo real.....</i>	<i>37</i>
<i>Ilustración 5: Trayectoria de un objeto seguido</i>	<i>37</i>
<i>Ilustración 6: Esquema del algoritmo de seguimiento de CAMshift.....</i>	<i>39</i>
<i>Ilustración 7: Elipse sobre objeto en seguimiento</i>	<i>40</i>
<i>Ilustración 8: Cuadro inicial y final del video utilizado para el ensayo [4].....</i>	<i>40</i>
<i>Ilustración 9: Representación de keypoints y campos de afinidad para múltiples personas (OpenPose) [23].....</i>	<i>41</i>
<i>Ilustración 10: Estrategias de asociación de partes en DeepLabCut [12]</i>	<i>41</i>
<i>Ilustración 11: Secuencia de fútbol americano siguiendo al jugador 75 [25].....</i>	<i>42</i>
<i>Ilustración 12: Una imagen de video y su probabilidad de piel en la imagen [24]</i>	<i>43</i>
<i>Ilustración 13: Ilustración 13. Ejemplo de seguimiento de un objeto con cambio de escala [26]</i>	<i>44</i>
<i>Ilustración 14: Arquitectura básica de una CNN.....</i>	<i>45</i>
<i>Ilustración 15: Pipeline de detección por CNN.....</i>	<i>45</i>
<i>Ilustración 16: Arquitectura básica de una RNN</i>	<i>46</i>
<i>Ilustración 17: Puerta de olvido.....</i>	<i>48</i>

<i>Ilustración 18: Puerta de entrada y valores candidatos</i>	48
<i>Ilustración 19: Actualización del estado de la celda</i>	48
<i>Ilustración 20: Puerta de salida y generación del estado oculto</i>	49
<i>Ilustración 21: Arquitectura general del Transformer</i>	50
<i>Ilustración 22: Atención escalada por producto punto y multi-head attention</i>	51
<i>Ilustración 23: Ejemplo de Matriz de confusión temporal</i>	53
<i>Ilustración 24: Representación gráfica del proceso iterativo (asignación y actualización)</i>	54
<i>Ilustración 25: Ejemplo de diferentes resultados de clustering con distintas distribuciones</i>	55
<i>Ilustración 26: Múltiples árboles de decisión en un Random Forest [34]</i>	56
<i>Ilustración 27: Diagrama esquemático de los métodos de ensamblaje [35]</i>	56
<i>Ilustración 28: Ejemplo de un problema de clasificación en un espacio bidimensional. Los vectores de soporte marcados con cuadros grises definen el margen mayor de separación entre las 2 clases [36]</i>	58
<i>Ilustración 29: Otro ejemplo de una SVM lineal que muestra el hiperplano óptimo, sus márgenes y los vectores de soporte que determinan la separación entre clases [37]</i>	59
<i>Ilustración 30: Ejemplo conceptual del problema de dimensionalidad en un sistema de una pelota en un resorte observado desde 3 cámaras [31]</i>	60
<i>Ilustración 31: Nube de datos simulados para la cámara A con indicación de varianza de señal y ruido. Adaptada de Shlens [31]</i>	61
<i>Ilustración 32: Ejemplo de un módulo de seguimiento de ezTrack [5].</i>	62
<i>Ilustración 33: Representación de módulos conductuales y transiciones destacando micro movimientos relevantes para la exploración [17]</i>	63
<i>Ilustración 34: Red de la corteza prefrontal media y su implicación en la evitación defensiva [40]</i>	64
<i>Ilustración 35: Esquema que muestra como la interacción entre el miedo y la evitación permite identificar los procesos neuroconductuales subyacentes [41]</i>	65
<i>Ilustración 36: Esquema de la cascada defensiva [42]</i>	65
<i>Ilustración 37: Esquema del EPM desde vista superior. Los brazos horizontales son abiertos mientras los verticales son cerrados [44].</i>	66
<i>Ilustración 38: Arquitectura general del prototipo [autoría propia]</i>	93
<i>Ilustración 40: "Modelo de base de datos (parte inferior) [autoría propia]"</i>	97
<i>Ilustración 41: "Caso de uso del prototipo [autoría propia]"</i>	104
<i>Ilustración 42: "Diagramas de secuencia [autoría propia]"</i>	106
<i>Ilustración 43: "Proceso de inicio de sesión del investigador [autoría propia]"</i>	107
<i>Ilustración 44: "Proceso de inicio de sesión del administrador [autoría propia]"</i>	108
<i>Ilustración 45: "Proceso de cambio de contraseña del investigador [autoría propia]"</i>	109
<i>Ilustración 46: "Proceso de cambio de contraseña del administrador [autoría propia]"</i>	110
<i>Ilustración 47: "Manejo de usuarios [autoría propia]"</i>	111
<i>Ilustración 48: Configuración de Perfil [autoría propia]</i>	112
<i>Ilustración 49: "Configurar Perfil Administrador [autoría propia]"</i>	113
<i>Ilustración 50: "Cerrar Sesión [autoría propia]"</i>	114
<i>Ilustración 51: "Cerrar sesión Administrador [autoría propia]"</i>	114
<i>Ilustración 52 "Prototipo de notificaciones [autoría propia]"</i>	116
<i>Ilustración 53: "Procesos de generación de análisis [autoría propia]"</i>	118
<i>Ilustración 54: "Consulta de reportes de análisis [autoría propia]"</i>	119
<i>Ilustración 55: "Consulta y generación de comparaciones [autoría propia]"</i>	120
<i>Ilustración 56: "Diagrama de clases [autoría propia]"</i>	122
<i>Ilustración 57: "Vista previa de inicio de sesión [autoría propia]"</i>	123
<i>Ilustración 58: "Vista previa del registro [autoría propia]"</i>	124
<i>Ilustración 59: "Cambiar contraseña [autoría propia]"</i>	125
<i>Ilustración 60: "Vista previa del inicio del prototipo [autoría propia]"</i>	126

<i>Ilustración 61 “Vista previa del administrador [autoría propia]”</i>	126
<i>Ilustración 62 "Ilustración del modelo [auditoría propia]"</i>	223
<i>Ilustración 63 "Ilustración del modelo prototipo II [auditoría propia]"</i>	225

INDICE DE TABLAS

Tabla 1: Comparación de trabajos similares [autoría propia]	35
Tabla 2: Complejidad por capa y longitud de camino para diferentes arquitecturas	51
Tabla 3: "Requerimientos Funcionales (RF)"	70
Tabla 4: "Requerimientos No Funcionales (RNF)"	71
Tabla 5: "Reglas de Negocio"	73
Tabla 6: "Tabla de análisis de técnicas de detección de objetos [autoría propia]"	74
Tabla 7: "Tabla de análisis de técnicas de estimación de pose con aprendizaje profundo [autoría propia]"	74
Tabla 8: "Tabla de análisis de técnicas de estimación de pose [autoría propia]"	75
Tabla 9: "Tabla de actualización de análisis de técnicas de estimación de pose [autoría propia]"	75
Tabla 9: "Tabla de análisis de herramientas de seguimiento visual [autoría propia]"	75
Tabla 10: "Tabla de análisis de arquitecturas de redes neuronales profundas para visión por computadora [autoría propia]"	76
Tabla 11: " Análisis de sistemas operativos [autoría propia]"	76
Tabla 12: " Análisis de lenguajes de programación [autoría propia]"	77
Tabla 13: Costos totales estimados del desarrollo del proyecto	87

Glosario de términos

Acicalamiento	Conducta natural en roedores que consiste en limpiarse o frotarse el cuerpo. En modelos de
---------------	--

	ansiedad, su frecuencia puede indicar niveles de tensión o estrés.
Algoritmo	Conjunto de reglas matemáticas que permiten resolver un problema (ej. clasificar conductas de roedores).
Analgésico	Fármaco que disminuye o suprime el dolor.[1]
Anestésico	Fármaco que causa la parcial o total ausencia de sensibilidad.[1]
Anotación manual	Registro de comportamientos realizado por humanos (etólogos) para entrenar o validar sistemas de IA.
Aprendizaje no supervisado	Método de machine learning que agrupa o estructura datos sin etiquetas previas, útil para descubrir patrones ocultos (ej. clustering).
Aprendizaje supervisado	Tipo de aprendizaje automático donde el modelo se entrena con datos etiquetados para reconocer patrones y hacer predicciones.
Back-end	Parte del sistema que gestiona la lógica interna, almacenamiento y procesamiento de datos. No es visible para el usuario final.
Base de datos relacional	Estructura de almacenamiento de datos organizada en tablas con relaciones entre sí. Permite consultar, filtrar y gestionar información de forma eficiente.
Big Data	Procesamiento de grandes volúmenes de datos (ej. videos de varios minutos de experimentos) que requieren herramientas computacionales avanzadas.
Clustering	Técnica de minería de datos que agrupa elementos con características similares (ej. patrones conductuales según fármaco).
Red Neuronal Convolucional	Tipo de IA para analizar imágenes/videos, identificando patrones espaciales (ej. posturas de roedores).
Coefficiente de concordancia	Métrica estadística usada para evaluar el grado de acuerdo entre evaluadores o modelos, como el coeficiente Kappa.
Computer Vision	Visión por computadora. Área de la IA dedicada a interpretar imágenes y videos mediante algoritmos (detección, seguimiento, análisis de postura, etc.)
CONBIOÉTICA	Normativa mexicana que regula el uso ético de animales en investigación.
Dashboard	Panel visual interactivo que muestra resultados clave (ej. Gráficas de actividad en tiempo real)
Deep Learning	Subcampo del aprendizaje automático basado en redes neuronales profundas capaces de aprender patrones complejos.

DeepLabCut	Sistema de código abierto basado en deep learning para estimación precisa de postura en animales.
Laberinto en Cruz elevada	Prueba para medir ansiedad en roedores, donde el tiempo en brazos abiertos vs. cerrados indica niveles de estrés.
Feature	Característica. Variable numérica o descriptor extraído de los datos (ej. distancia recorrida, tiempo en brazos abiertos).
Fármaco	Cualquier sustancia que no sea alimento, y que se use para prevenir, diagnosticar, tratar o aliviar los síntomas de una enfermedad o afección.[7]
Heatmap (Mapa de calor)	Mapa de calor. Visualización gráfica donde los colores representan la intensidad de visitas o actividad en zonas del laberinto.
IA	Inteligencia Artificial. Sistemas que imitan aprendizaje humano para realizar tareas complejas (ej. reconocer patrones de conducta).
Inferencia	Proceso mediante el cual un modelo entrenado realiza predicciones sobre nuevos datos.
K-Means	Algoritmo de clustering que agrupa datos en k categorías basadas en similitud.
Kappa de Cohen (κ)	Métrica estadística que mide el acuerdo entre evaluadores (ej. humano vs. IA), ajustando el azar.
Red de memoria a corto-largo plazo	Tipo de red neuronal para analizar secuencias temporales (ej. movimientos entre zonas de la cruz elevada)
Machine Learning	Aprendizaje Automático. Subcampo de la IA donde los sistemas “aprenden” de datos sin ser programados explícitamente.
Minimización de ruido	Proceso que reduce variaciones indeseadas en imágenes o señales para mejorar su análisis.
Modelo experimental	Estructura o protocolo estandarizado para estudiar un fenómeno biológico (como la ansiedad en roedores).
Normalización de Datos	Procedimiento de ajustar variables a rangos comparables para evitar sesgos en modelos matemáticos.
Placebo	Sustancia sin efecto farmacológico utilizada como control en ensayos experimentales.
Plotly Dash	Framework para crear dashboards interactivos en Python.
Pose Estimation	Estimación de postura. Proceso de identificar puntos corporales (ej. cabeza, hocico, columna) para interpretar posturas y movimientos finos.

Preprocesamiento	Limpieza y preparación de datos (ej. eliminar ruido en videos) antes del análisis.
Random Forest	Algoritmo de aprendizaje supervisado basado en múltiples árboles de decisión para clasificar comportamientos.
Reconocimiento de patrones	Proceso por el cual un algoritmo identifica regularidades en los datos (ej. detectar grooming o inmovilidad).
Red neuronal	Modelo computacional inspirado en el cerebro humano, compuesto por nodos conectados capaces de aprender de datos.
Resolución espacial	Grado de detalle con el que se captura una imagen o video.
Red Neuronal Recurrente	Tipo de red neuronal diseñada para procesar secuencias temporales, como trayectorias o series de video.
Área de interés	Zona específica del video que se analiza separadamente, como los brazos abiertos o cerrados del EPM.
Simulación	Ejecución de pruebas controladas que imitan condiciones reales para validar modelos o sistemas.
Máquina de vectores de soporte	Support Vector Machine. Algoritmo de clasificación que separa datos mediante hiperplanos en un espacio multidimensional.
Threshold (Umbral)	Valor numérico a partir del cual se clasifica un evento o comportamiento (ej. inmovilidad si velocidad < X).
Tracking (Seguimiento)	Seguimiento. Proceso mediante el cual el sistema identifica y sigue la posición del animal cuadro por cuadro en un video.
Tranquilizante	Clase de medicamentos psicotrópicos que se emplean para reducir la tensión y la ansiedad.[8]
Tuberculina	Extracto proteico obtenido de Mycobacterium tuberculosis.
Tuberculinizado	Animal al que se le aplica mediante administración intradérmica unidades de tuberculina en un periodo de tiempo.
Interfaz de usuario	Parte visual de un software con la que interactúa el usuario (botones, paneles, gráficos).
Vectorización	Conversión de movimientos en coordenadas numéricas (ej. [x, y, t]) para análisis cuantitativo.
You Only Look Once (Solo puedes mirar una vez)	Modelo de detección de objetos en tiempo real que localiza rápidamente instancias de interés en imágenes o videos.

Overfitting (Sobreajuste)	ocurre cuando un modelo de aprendizaje automático se ajusta demasiado a los datos de entrenamiento.
---------------------------	---

Abreviaturas

CNN	Convolutional Neural Networks (Red Neuronal Convolutacional).
EPM	Elevated Plus Maze (Laberinto en Cruz elevada).
IA	Inteligencia Artificial.
LSTM	Long Short-Term Memory (Red de memoria a corto-largo plazo)
PDI	Procesamiento digital de imágenes
RNN	Red Neuronal Recurrente.
ROI	Region of Interest (Área de interés).
SVM	Support Vector Machine (máquina de vectores de soporte).
UI	User Interface (Interfaz de usuario).
YOLO	You Only Look Once. (Solo miras una vez).

Capítulo 1. Introducción

1.1 Antecedentes

El análisis del comportamiento animal utilizando inteligencia artificial (IA) ha cobrado gran relevancia en la última década debido a su potencial para aumentar la precisión, eficiencia y reproducibilidad en los estudios biomédicos. La integración de técnicas de visión por computadora y aprendizaje automático ha permitido automatizar tareas tradicionalmente realizadas de manera manual, como la observación de posturas, trayectorias y tiempos de permanencia, lo que reduce la subjetividad y el margen de error humano en los experimentos de comportamiento [1], [9].

En el ámbito de la farmacología experimental, los roedores —especialmente las ratas y los ratones— constituyen los modelos biológicos más utilizados para el estudio de los trastornos de ansiedad y el desarrollo de nuevos fármacos ansiolíticos. Esto se debe a que presentan una fisiología, genética y neuroanatomía altamente comparables con las del ser humano, particularmente en la organización del sistema nervioso central y las respuestas neuroendocrinas al estrés [2], [10]. Además, su tamaño, bajo costo, facilidad de manejo y rápida reproducción los hacen ideales para la experimentación controlada en laboratorio.

De acuerdo con el posgrado de la **Escuela Nacional de Medicina y Homeopatía (ENMyH)** del **Instituto Politécnico Nacional**, los ensayos con roedores permiten evaluar el efecto de nuevas moléculas con potencial ansiolítico. Los experimentos se estructuran generalmente en tres grupos: un grupo control que recibe placebo, un grupo tratado con **diazepam** (fármaco ansiolítico de referencia), y uno o más grupos experimentales que reciben las moléculas en evaluación. Esta comparación posibilita identificar tanto los efectos terapéuticos como los mecanismos de acción de las sustancias probadas [11]. La metodología incluye pruebas conductuales como el **Laberinto en Cruz Elevada (EPM)** o el **Laberinto en T Elevado**, ampliamente utilizadas para medir conductas asociadas a la ansiedad, como la evitación, exploración y tiempo de inmovilidad [3], [4].

El uso de animales de laboratorio está regulado en México por la **Norma Oficial Mexicana NOM-062-ZOO-1999**, que establece las especificaciones éticas, sanitarias y de bienestar animal aplicables a su cuidado y uso experimental. Esta norma asegura el bienestar de los especímenes y permite que los procedimientos se lleven a cabo bajo condiciones controladas, reduciendo al mínimo el sufrimiento de los especímenes.[5].

La inteligencia artificial ha potenciado el análisis conductual de estos modelos experimentales en años recientes, lo cual ha posibilitado la identificación automatizada de patrones de conducta a través de instrumentos como **YOLO** [13], **DeepLabCut** [12], o sistemas de seguimiento de código abierto (como **ezTrack** [5]). Estos últimos proporcionan precisión cuantitativa y reproducibilidad al evaluar las respuestas ansiolíticas. Esta sinergia entre la neurociencia conductual y la ingeniería computacional representa un avance significativo para acortar el tiempo necesario para validar nuevas sustancias y personalizar los tratamientos farmacológicos [14].

1.2 Planteamiento del problema

Para validar tratamientos experimentales en modelos de ansiedad, el análisis conductual en investigaciones farmacológicas constituye un paso crucial. Esta tarea, de manera tradicional, se lleva a cabo manualmente con la observación humana meticulosa de videos. En estos, los asistentes del laboratorio documentan visualmente cada movimiento, postura y desplazamiento del espécimen. No obstante, este método, a pesar de ser riguroso, es poco eficaz: el análisis de un único video puede demandar entre una y dos semanas de trabajo repartido entre tres asistentes. Estos tienen la tarea de determinar minuciosamente los eventos relevantes y luego procesar manualmente los datos con el fin de producir gráficas que puedan interpretarse. Este procedimiento, además de ser exigente en términos de tiempo, introduce una alta cantidad de subjetividad y variabilidad entre los evaluadores, lo cual pone en riesgo la capacidad para reproducir y la consistencia de los hallazgos experimentales.

1.3 Propuesta de solución

En vista de esta circunstancia, se hace necesario crear una herramienta tecnológica que estandarice y automatice la evaluación del comportamiento de nuestro espécimen, eliminando los sesgos humanos y acortando de manera significativa el tiempo de análisis. Este prototipo pretende combinar diferentes métodos de inteligencia artificial, visión por computadora y minería de datos a partir de videos grabados con anterioridad durante ensayos farmacológicos para convertir el proceso convencional de observación manual en un flujo automatizado, reproducible y de alta precisión.

La solución se centrará en un prototipo de inteligencia artificial y visión por computadora, con la capacidad de identificar, rastrear y describir el movimiento de roedores en contextos controlados.

Este prototipo integrará tres componentes principales:

1. **Detección de objetos mediante redes neuronales convolucionales (CNN) tipo YOLOv11**, entrenadas específicamente para identificar y localizar con alta precisión a los roedores dentro del entorno experimental.
2. **Análisis de secuencias temporales con redes LSTM (Long Short-Term Memory)**, que procesarán las trayectorias obtenidas para reconocer patrones conductuales asociados con diferentes respuestas de ansiedad.
3. **Estimación de postura mediante técnicas de pose estimation (MediaPipe o DeepLabCut)**, para extraer coordenadas clave del cuerpo y mejorar la caracterización del comportamiento (posición, orientación, movimientos finos).

Una vez procesada la información, los datos vectorizados serán sometidos a **minería de datos mediante algoritmos como K-Means**, con el fin de agrupar patrones de actividad y detectar conductas recurrentes o anómalas.

Los resultados se visualizarán a través de **mapas de calor (heatmaps)**, **trayectorias dinámicas**, **gráficas comparativas** y **tablas de métricas conductuales**, que permitirán evaluar de forma clara cómo los tratamientos farmacológicos influyen en la conducta de los especímenes.

Finalmente, el prototipo contará con una **interfaz interactiva tipo dashboard**, que mostrará métricas de precisión, coeficientes de concordancia (κ de Cohen) y visualizaciones gráficas en tiempo real, facilitando la interpretación por parte de los investigadores biomédicos.

1.4 Objetivo general

Desarrollar un prototipo de análisis automatizado para analizar y representar patrones conductuales de especímenes en modelos experimentales de ansiedad a partir de vídeos, utilizando técnicas de minería de datos (clustering, clasificación y reducción de dimensionalidad), aprendizaje automático (redes neuronales CNN-LSTM, detección visual YOLO y estimación de postura), e inteligencia artificial (reconocimiento automático y validación estadística), generando visualizaciones gráficas e informes comparativos que permitan evaluar tratamientos farmacológicos.

1.4.1 Objetivos específicos

1. **Recolectar y estructurar datos conductuales de especímenes**, tales como la **movilidad entre brazos abiertos y cerrados, tiempo de permanencia en cada zona del laberinto, frecuencia de acicalamiento, tiempo de inmovilidad y contacto con las paredes**, a fin de generar una base de datos estructurada para el análisis automatizado posterior. Utilizados en modelos experimentales de ansiedad, mediante grabaciones individuales en video. En cada sesión se observará un espécimen único sometido a distintos tratamientos farmacológicos, incluyendo **un grupo control con placebo, un grupo tratado con diazepam** (fármaco ansiolítico de referencia) y **uno o más grupos experimentales con nuevas moléculas en evaluación**.
2. **Identificar técnicas de visión por computadora** aplicables al análisis conductual de especímenes en el modelo del **laberinto en cruz elevada (EPM)**, considerando algoritmos como **CNN-LSTM, YOLO y estimación de postura**, con el propósito de determinar cuáles permiten una extracción automatizada y vectorización precisa de los movimientos, trayectorias y posturas relevantes para la detección de conductas asociadas a la ansiedad.
3. **Desarrollar el módulo de clasificación y minería de datos**, que agrupe patrones de comportamiento según los tratamientos aplicados (placebo, diazepam o fármaco experimental), utilizando algoritmos como K-Means, Random Forest y SVM.
4. **Desarrollar el módulo de visualización interactiva**, encargado de generar dashboards con trayectorias, mapas de calor, tiempos de permanencia y gráficos comparativos de conducta en función de los tratamientos ansiolíticos.
5. **Desarrollar el módulo de validación experimental**, que evalúe la precisión de los resultados mediante validación Leave-One-Out (LOO), reportando métricas de desempeño como precisión, recall y F1-score, con el fin de contrastar las detecciones del prototipo con las anotaciones de expertos.

6. **Desarrollar el módulo de almacenamiento y gestión de resultados**, que organice los datos procesados, informes y visualizaciones en una base estructurada para consulta y análisis posteriores.

1.5 Justificación

La necesidad que da origen a este proyecto es contar con una herramienta tecnológica que **automatice el análisis conductual de especímenes utilizados en modelos experimentales** de ansiedad, mediante la identificación precisa de actividades anómalas como la movilidad de brazos, tiempos de permanencia en distintas zonas del laberinto, conteo de eventos (transiciones entre brazos, acicalamiento, inmovilidad, contacto con paredes, entre otros).

El modelo del **laberinto en cruz elevada (EPM)** permite analizar comportamientos ansiosos mediante parámetros etológicos como el tiempo de permanencia y la frecuencia de acicalamiento (Carobrez & Bertoglio, 2005). La observación manual de estos comportamientos implica un proceso **lento, subjetivo y propenso a errores humanos**, lo cual dificulta la obtención de datos reproducibles y comparables entre tratamientos. En la investigación farmacológica, donde es crucial contar con una precisión tanto temporal como espacial del comportamiento de los animales para poder evaluar el efecto de compuestos ansiolíticos, esta circunstancia supone un obstáculo importante. Por esta razón, el posgrado de la Escuela Nacional de Medicina y Homeopatía (ENMyH) del Instituto Politécnico Nacional (IPN) ha expresado la necesidad de contar con una herramienta automatizada que posibilite identificar, documentar y examinar de manera objetiva las reacciones conductuales a partir de videos experimentales. Este prototipo, que utiliza inteligencia artificial, minería de datos y visión por computadora, posibilitará la producción de visualizaciones gráficas y mediciones cuantitativas confiables. De esta manera se mejorará el tiempo de análisis y se asegurarán resultados más exactos y reproducibles. Así, el proyecto satisface a una necesidad específica a nivel científico y operativo: optimizar la objetividad, eficacia y calidad del análisis conductual en investigaciones sobre ansiedad, para así robustecer la capacidad de investigación de la ENMyH y el IPN en el ámbito biomédico.

1.6 Alcance del proyecto

Es importante crear un prototipo automatizado para estudiar el comportamiento animal, ya que esto ayuda a establecer prácticas de experimentación más objetivas y cuantitativas, y que estén en líneas con los estándares de la investigación biomédica. La incorporación de tecnologías fundamentadas en inteligencia artificial mejora la calidad científica y la consistencia metodológica de las investigaciones sobre conducta en lugares como la ENMyH donde el estudio preclínico en modelos de ansiedad es una línea importante de investigación. La automatización basada en visión por computadora ha mostrado, en varias investigaciones, que aumenta de manera notable la reproducibilidad y la precisión en ensayos etológicos, disminuyendo la variabilidad vinculada a la evaluación hecha por humanos [9], [12].

De igual manera, la implementación de estas tecnologías está en consonancia con las directrices normativas y éticas sobre el empleo de animales de laboratorio. La NOM-062-ZOO-1999 enfatiza la relevancia del bienestar de los animales y la exigencia de llevar a cabo procedimientos en condiciones controladas que maximicen cada prueba [2]. La implementación de sistemas automatizados posibilita

el uso óptimo de los datos adquiridos de cada muestra y reduce la repetición de pruebas, lo que ayuda a cumplir con el principio de las 3R (Reducción, Refinamiento y Reemplazo). Esto no solo optimiza la eficacia científica, sino que también refuerza la responsabilidad ética en el manejo de animales, lo cual es consistente con las tendencias internacionales de investigación responsable [5].

Se eligen tecnologías como YOLO, DeepLabCut y métodos de estimación de postura debido a su exactitud comprobada en tareas de rastreo y detección en modelos de animales. Estas herramientas se han validado extensamente en entornos biomédicos y posibilitan la extracción de patrones complejos que sobrepasan las capacidades de observación manual, como trayectorias tridimensionales, micro conductas y alteraciones sutiles en la postura corporal [12], [13]. Su empleo asegura datos cuantitativos de alta resolución que tienen la posibilidad de ser estudiados a través de métodos de minería de datos y aprendizaje automático; esto mejora la capacidad analítica de los investigadores y hace más sencillo detectar efectos farmacológicos.

La puesta en marcha de una plataforma con paneles interactivos y visualizaciones dinámicas ofrece a los investigadores y a los usuarios un entendimiento más profundo y accesible del comportamiento animal. Los instrumentos de análisis visual, como trayectorias dinámicas, mapas de calor y gráficos comparativos, hacen posible la síntesis de grandes cantidades de datos y su conversión en información clara y útil para la toma de decisiones experimentales [14]. Esto beneficia también los procesos de formación académica pues tanto estudiantes como residentes tienen la posibilidad de comprender el comportamiento animal desde un punto de vista basado en evidencia y perspectiva cuantitativa.

Por último, el alcance del proyecto incluye la creación de un prototipo modular y flexible, diseñado para integrar nuevas metodologías o expandirse a otros paradigmas experimentales. Esta perspectiva flexible posibilita que la plataforma no solo satisfaga las demandas presentes, sino que también progrese con los desarrollos en neurociencia conductual, IA y farmacología. En esta línea, el proyecto actúa como una base tecnológica que permitirá llevar a cabo líneas de investigación en el futuro tanto dentro de la ENMyH y el IPN como en otras entidades enfocadas en el estudio del comportamiento animal.

1.7 Metodología

Para el desarrollo del proyecto se adopta la metodología espiral de Boehm, adaptada a las particularidades de los proyectos de ciencia de datos. Barry W. Boehm, quien lo propuso en 1986 y lo formalizó en 1988 en “A Spiral Model of Software Development and Enhancement”, es el autor de este modelo que se distingue por ser sistemático a la hora de gestionar riesgos desde etapas tempranas, por su carácter cíclico y por su avance progresivo [15].

El modelo en espiral, a diferencia de los modelos secuenciales tradicionales, concibe el desarrollo como una serie de ciclos donde el producto se transforma gradualmente mediante revisiones y prototipos. Cada iteración culmina con un entregable validado que se utiliza como fundamento para el ciclo siguiente, lo cual permite una retroalimentación constante y un control de calidad [16], [17].

En el campo de la ciencia de datos, donde los proyectos presentan incertidumbre en cuanto a los datos, un alto nivel de complejidad técnica y validación experimental, el modelo en espiral brinda un entorno perfecto para iterar a través de prototipos, monitorear riesgos de calidad y garantizar una progresión verificable del modelo analítico [16], [18].

La versión empleada en este proyecto contempla cinco actividades esenciales en cada iteración, que aseguran la integración gradual de resultados parciales hasta llegar a una solución madura:

1. Definición de objetivos y planificación. En esta fase se definen las metas de negocio y técnicas, el alcance del ciclo y las métricas para medir el éxito. Se establecen los recursos, las fuentes de datos y los entregables que se anticipan. En proyectos de ciencia de datos, esta etapa se refiere a comprender los datos iniciales y el problema en cuestión, siguiendo los procesos del ciclo de vida que la norma ISO/IEC/IEEE 12207:2017 [6] establece.

2. Análisis de riesgos y viabilidad. Los riesgos técnicos, de datos, éticos o de implementación son idénticos al evaluar la viabilidad operativa y técnica del proyecto. Esta actividad se basa en el principio fundamental del modelo de Boehm: prever los riesgos y reducirlos antes de involucrar más recursos [15], [7].

3. Desarrollo de prototipo. Se pone en práctica un prototipo funcional o exploratorio que posibilita la verificación de hipótesis, la evaluación de la calidad de los datos y la validación de enfoques analíticos iniciales. Este prototipo es el fundamento para la evaluación del rendimiento en cada iteración, fusionando prácticas de análisis de datos e Ingeniería de Software [16], [18].

4. Evaluación y validación. Los resultados del prototipo se comparan con los objetivos establecidos para confirmar si se cumplen los estándares de calidad y rendimiento definidos. En esta etapa se examina la fortaleza, la capacidad de interpretación y el potencial sesgo de los modelos, siguiendo las pautas de calidad que establece la norma ISO/IEC 25010:2023 [8].

5. Retroalimentación y ajuste. Con la base de la validación, se recoge el feedback, se modifican los objetivos y se organiza la iteración posterior. Esta etapa asegura que el proceso mejore de forma constante y se ajuste a cambios imprevistos en los datos o en las especificaciones del proyecto.

Cada ciclo de la espiral termina en un producto entregable concreto, lo que posibilita el progreso desde un prototipo elemental hasta una solución sólida, establecida y verificada.



Ilustración 1: OpenAI (2025). Imagen generada por ChatGPT sobre el concepto de metodología de espiral de Boehm [Imagen generada por IA]. ChatGPT (versión 5.1). Archivo creado por el usuario, sin URL.

En situaciones donde son fundamentales el descubrimiento iterativo, la evaluación empírica y la experimentación, el modelo en espiral es particularmente relevante. Posibilita incluir modificaciones durante el proceso, gracias a su sistema de retroalimentación, lo cual evita la inflexibilidad de los modelos lineales. Asimismo, su estructura enfocada en el riesgo favorece la detección anticipada de eventuales errores de diseño, calidad de datos o alineación con los objetivos comerciales, lo que incrementa las posibilidades de que el proyecto sea exitoso [16], [17].

Capítulo 2. Estado del arte.

El análisis y la investigación de la conducta relacionada con la ansiedad en los animales ha progresado significativamente en las últimas décadas, gracias a que ha surgido la necesidad de entender los procesos neurobiológicos subyacentes y a que han mejorado los tratamientos farmacológicos. El EPM es uno de los modelos experimentales más comúnmente empleados en este ámbito, pues posibilita la evaluación de las reacciones conductuales que surgen del conflicto entre la tendencia innata de los roedores a explorar y su repulsión hacia lugares elevados y abiertos.

Dado que este mismo modelo constituye la base experimental de los videos proporcionados por la Escuela Nacional de Medicina y Homeopatía (ENMyH), que serán analizados en el presente proyecto, resulta fundamental revisar los antecedentes científicos que han consolidado su validez y las distintas metodologías asociadas a su aplicación. Por lo tanto, en este capítulo se exponen los estudios y progresos más importantes realizados recientemente en el empleo del EPM como instrumento de investigación sobre la ansiedad, destacando sus contribuciones, restricciones y el posible uso conjunto con tecnologías emergentes de visión por computadora e inteligencia artificial.

2.1 Análisis etológico y temporal del comportamiento similar a la ansiedad: el modelo de EPM elevado 20 años después

En este artículo se enfatiza que el uso del EPM constituye un recurso esencial para investigar conductas vinculadas con la ansiedad en roedores. Pese a que en un principio fue desarrollado como un procedimiento para analizar los efectos ansiolíticos de medicamentos, su practicidad se ha extendido a examinar elementos como la memoria, el aprendizaje, el dolor, las hormonas, la adicción y los subtipos de desórdenes de ansiedad, como la fobia, el trastorno de estrés postraumático (TEPT) y el trastorno de ansiedad generalizada.

Se hace mención de que el EPM es popular por su simplicidad, velocidad y coste bajo. También se destaca que no se requiere un largo entrenamiento ni la aplicación de estímulos aversivos como privar de comida o aplicar descargas eléctricas. Sin embargo, su uso varía significativamente entre laboratorios, lo que ha llevado a una falta de estandarización en los protocolos. Esta revisión se centra en cómo mejorar la validez del EPM mediante la consideración de factores como la medición de patrones defensivos, el análisis minuto a minuto del comportamiento y el uso de protocolos de prueba/reprueba.

2.2 El laberinto en T elevado como modelo experimental de ansiedad

El artículo presenta el laberinto elevado en T como un modelo animal diseñado para diferenciar entre dos tipos de ansiedad: el miedo condicionado, asociado al trastorno de ansiedad generalizada (TAG), y el miedo no condicionado, relacionado con el trastorno de pánico (TP). Este modelo es una variante del laberinto elevado en cruz, pero con una modificación clave: uno de los brazos cerrados se sella, dejando tres brazos quedando de tal forma, uno cerrado y dos abiertos. En este laberinto, se miden dos comportamientos principales: la evitación inhibitoria, que representa el miedo condicionado, y el escape unidireccional, que refleja el miedo no condicionado.

En la validación conductual, se demostró que la experiencia en los brazos abiertos es el factor crítico que motiva la evitación inhibitoria, no el manejo por parte del experimentador. Los roedores evitan los brazos abiertos debido a su aversión innata a las alturas y los espacios abiertos, y este miedo no disminuye con la habituación, lo que sugiere que es un comportamiento persistente con un alto valor de supervivencia. Por otro lado, el escape unidireccional, que ocurre cuando el roedor escapa de un brazo abierto hacia el cerrado, refleja una respuesta innata de miedo.

2.3 El uso del EPM como un ensayo del comportamiento relacionado con la ansiedad en roedores

En este artículo se enfatiza que el EPM no solamente es un instrumento para evaluar la ansiedad, sino que brinda además una ventana muy interesante a la biología del comportamiento. Esta prueba no solo evalúa la ansiedad, sino que además puede proporcionar datos acerca de la memoria y el aprendizaje, esto es porque se ha comprobado que los roedores son capaces de retener recuerdos de experiencias pasadas en el laberinto, lo cual tiene un impacto en su conducta durante pruebas posteriores.

Una faceta poco conocida del EPM es que se utiliza en investigaciones de neurobiología, al ser empleada por los investigadores con el fin de descubrir las áreas cerebrales que están implicadas en la

ansiedad. Se ha comprobado, por ejemplo, que la amígdala, una zona crucial para procesar el miedo, se encuentra muy activa cuando los roedores evitan los brazos abiertos. Asimismo, el hipocampo, vinculado a la memoria espacial, tiene un rol relevante en el modo en que los animales se orientan y rememoran el laberinto. Estos descubrimientos han contribuido a que los investigadores comprendan de manera más eficaz cómo el cerebro controla la ansiedad y el miedo.

Además, el EPM se ha ajustado para analizar otros elementos del comportamiento, tal como la sociabilidad y la reacción ante el estrés social. En ciertos experimentos, los roedores son sometidos a situaciones sociales que les causan estrés antes de ser introducidos en el laberinto, estos animales tienden a mostrar más comportamientos de inmovilidad y a evitar los brazos abiertos cuando la ansiedad aumenta. Esto indica que la ansiedad puede ser fuertemente influenciada por el estrés social, lo cual es importante para comprender trastornos también en seres humanos como el de estrés postraumático o la depresión.

Un dato interesante es que el EPM se ha empleado además para investigar como los sonidos y la música afectan la ansiedad. La música relajante, según se menciona en el artículo, tiene la capacidad de disminuir la ansiedad en roedores al incrementar el tiempo que permanecen en los brazos abiertos. En contraste, los ruidos fuertes o los sonidos estridentes producen el efecto inverso, intensificando la evitación de los brazos abiertos. No solo desde la perspectiva científica estos hallazgos son interesantes, sino que además poseen implicaciones prácticas, como el empleo de música para disminuir el estrés en animales de laboratorio.

2.4 Prueba del EPM Combinado con Software de Seguimiento por Video para Investigar el Efecto Ansiolítico de Suplementos Cetogénicos Exógenos

El artículo describe la metodología del laberinto elevado en cruz (EPM) combinado con un software de seguimiento por video para evaluar el efecto de tratamientos potencialmente ansiolíticos en modelos de roedores de laboratorio.

El estudio se centra en evaluar el efecto de suplementos exógenos de cetonas en ratas Sprague Dawley (SPD). Los suplementos de cetonas se administraron de forma crónica durante 7 días antes de realizar la prueba del EPM. Los datos de comportamiento se recopilaban utilizando un sistema de seguimiento por video, y los resultados mostraron que el EPM es un método efectivo para detectar el efecto ansiolítico inducido por los suplementos de cetonas. Esto sugiere que el EPM es una herramienta sensible para evaluar cambios en el comportamiento relacionado con la ansiedad asociados con terapias basadas en fármacos o modificaciones metabólicas.

La relevancia de estandarizar las condiciones experimentales para asegurar la validez de los resultados también es enfatizada en este artículo. Esto abarca la adaptación de los animales al ambiente experimental, el manejo constante de roedores y la realización de pruebas bajo condiciones controladas de ruido e iluminación. Además, se sugiere limpiar el laberinto tras cada ensayo para quitar cualquier indicio de olor que pudiera alterar la conducta de los animales que sigan.

2.5 Prueba del EPM para Evaluar el Comportamiento Similar a la Ansiedad en el Ratón

Los datos representativos muestran que los efectos de los fármacos ansiolíticos y ansiogénicos pueden detectarse claramente en este modelo, aunque es importante ajustar las dosis para distinguir entre efectos emocionales y locomotores. Finalmente, se ofrecen notas complementarias acerca de aspectos relevantes, como la utilización de ratones macho para prevenir alteraciones vinculadas con el ciclo estral, lo necesario que es acostumbrar a los animales al entorno experimental y la relevancia de conservar una iluminación constante para no generar sesgos de conducta.

Este protocolo ha sido adaptado de estudios previos y ha demostrado ser efectivo para detectar tanto efectos ansiogénicos como ansiolíticos en ratones.

2.6 El diazepam provoca efectos sedantes más que ansiolíticos en ratones C57BL/6J

El estudio investigó los efectos del diazepam y la paroxetina en ratones C57BL/6J, tanto hembras como machos, utilizando pruebas de comportamiento como el EPM y el campo abierto. Los resultados mostraron que el diazepam no aumentó el número de entradas ni el tiempo pasado en los brazos abiertos, lo que sugiere que no tuvo un efecto ansiolítico en los ratones, sino que más bien causó efectos sedantes, evidenciados por una disminución en la actividad locomotora y en el comportamiento de evaluación de riesgo, medido como una reducción en el tiempo pasado en posturas de estiramiento y exploración. Estos efectos se observaron tanto en ratones no sometidos a estrés como en aquellos que fueron sometidos a una hora de restricción antes de la prueba. En contraste, la paroxetina, un antidepresivo inhibidor selectivo de la recaptación de serotonina, mostró efectos ansiolíticos claros en ambos sexos, aumentando el tiempo pasado en los brazos abiertos del EPM y el comportamiento de evaluación de riesgo.

Además, el estudio subrayó que el diazepam no solamente redujo la actividad locomotora, sino que también acortó el tiempo en que los ratones permanecieron en la parte central del campo abierto; este comportamiento suele estar relacionado con la ansiedad. Esto apoya el concepto de que, en este modelo de ratón, el diazepam funciona fundamentalmente como sedante y no como ansiolítico. Por otra parte, la paroxetina no solo prolongó el tiempo que pasó en los brazos abiertos del EPM, sino que además aumentó la conducta de evaluación de riesgo. Esto indica que este medicamento podría ser más eficaz para disminuir la ansiedad en ratones C57BL/6J.

Los hallazgos también indicaron que el estrés previo no modificó de manera significativa los efectos del diazepam, porque los ratones que fueron sometidos a una hora de limitación antes del ensayo presentaron comportamientos parecidos a los que no tuvieron estrés. Esto sugiere que el efecto sedante del diazepam es consistente independientemente del estado de estrés del animal. Sin embargo, la paroxetina mostró un efecto ansiolítico más pronunciado en los ratones no sometidos a estrés, lo que podría indicar que el estrés previo podría modular la eficacia de este fármaco en ciertos contextos.

2.7 ezTrack: Un flujo de análisis de video de código abierto para la investigación del comportamiento animal

ezTrack es una herramienta de análisis de comportamiento de código abierto y multiplataforma que permite a investigadores sin experiencia en programación realizar análisis de video de manera sencilla. EzTrack se compone de dos módulos fundamentales: uno para examinar la posición y el movimiento de un animal específico, y otro para medir la conducta de congelación, que se usa frecuentemente en investigaciones sobre miedo y ansiedad. En conjunto los dos módulos presentan visualizaciones interactivas, procesamiento por lotes y la posibilidad de modificar parámetros para asegurar resultados más exactos.

El módulo de seguimiento de ubicación de ezTrack monitorea el centro de masa de un animal en cada cuadro del video, lo que posibilita calcular el tiempo y la distancia recorrida en las áreas de interés (ROI) establecidas por el usuario. Se dice que este módulo ha sido validado en diversas pruebas conductuales, incluyendo la prueba de oscuridad-luz, el laberinto de agua de Morris, la preferencia por un lugar condicionado, y finalmente el EPM. Los resultados logrados evidenciaron una fuerte correlación con los análisis manuales, lo que demostró su exactitud. Además, ezTrack es resistente a las variaciones de luz y a la presencia de objetos en el campo visual, lo que lo vuelve apto para una extensa variedad de pruebas.

El módulo de análisis de congelación de ezTrack determina el desplazamiento del animal al calcular la cantidad de píxeles que varían entre fotogramas sucesivos. Se considera que un animal está en estado de congelación cuando su movimiento desciende por debajo de un umbral establecido por el usuario durante un periodo de tiempo determinado. Este módulo también ofrece instrumentos de calibración para modificar los límites de movimiento y congelación, además de posibilitar el recorte de los fotogramas con el fin de suprimir la intervención de cables conectados al animal. Los resultados de ezTrack mostraron una fuerte correlación con los análisis manuales en ensayos de condicionamiento del miedo, lo que confirma su precisión a la hora de detectar este tipo de comportamiento.

La sencillez para utilizar ezTrack es una de sus principales ventajas, pues está concebido para ser accesible incluso para quienes no tienen experiencia en programación. Además, ezTrack tiene la capacidad de adaptarse a diversas configuraciones experimentales, ya que es compatible con una variedad extensa de formatos de video y múltiples sistemas operativos (Windows, macOS y Linux). Es relevante también subrayar la transparencia y la reproducibilidad de ezTrack. Ya que se hace uso de Jupyter Notebook, se almacenan en un archivo HTML o PDF todos los pasos y parámetros que se emplearon para procesar la información, lo que simplifica la revisión y reproducción de los análisis. Esto se opone al software comercial, donde los parámetros elegidos no siempre son registrados de forma accesible.

A pesar de que ezTrack presenta ciertas limitaciones, entre ellas su dependencia del centro de masa para establecer la posición y su enfoque en el seguimiento de un solo animal, su simplicidad y versatilidad lo hacen una herramienta útil para un extenso espectro de aplicaciones en neurociencias y análisis conductuales. Además, por ser de código abierto, ezTrack tiene la posibilidad de ser mejorado y cambiado por la comunidad científica, lo que posibilita incluir nuevas funciones más adelante.

2.8 Analixity: Un sistema de análisis de código abierto y bajo costo para la prueba de EPM, basado en técnicas de visión por computadora

Analixity es un software en un sistema multiplataforma de código abierto para procesamiento de video, diseñado específicamente para realizar pruebas de EPM.

Este software produce un archivo de Excel con los parámetros de comportamiento cuantificados, incluyendo el tiempo transcurrido en los brazos abiertos y cerrados, el tiempo de la zona central, la cantidad de veces que se ingresó a cada área y la distancia total recorrida durante el examen. Con el fin de validar su efectividad, los resultados logrados con Analixity se contrastaron con los que se lograron por medio del software comercial ANY-maze y mediante análisis manual. No hubo discrepancias estadísticamente relevantes entre las metodologías, lo que avala que Analixity es igual de efectivo y fiable que un software comercial, pero con el beneficio de ser adaptable a distintas condiciones de laboratorio y ser de código abierto.

En la actualidad, hay diferentes programas comerciales para analizar el comportamiento animal, incluyendo LABORAS, Ethovision y ANY-maze. Además, muchos de estos programas funcionan como "cajas negras", donde los investigadores no tienen acceso a los procedimientos internos utilizados para la cuantificación de parámetros. En contraste, Analixity es un software de código abierto desarrollado en Python con bibliotecas OpenCV, lo que permite a los investigadores conocer y modificar los procesos internos según sus necesidades. Además, es compatible con Windows, MacOS y Linux, lo que lo hace accesible para una amplia gama de usuarios.

En el estudio de validación, se compararon los resultados obtenidos con Analixity con los obtenidos mediante análisis manual y con ANY-maze. Se analizaron videos de ratas Wistar y ratones C57BL/6 J en diferentes condiciones de iluminación, y se cuantificaron parámetros como el tiempo pasado en los brazos abiertos y cerrados, el tiempo en la zona central y el número de entradas a cada zona. Los resultados mostraron que Analixity redujo significativamente el tiempo de análisis, de 30 minutos a solo 2.5 minutos por video, sin comprometer la precisión.

Aunque el software se menciona en diversos artículos y se indica que es de código abierto, no se encontró un medio disponible para su descarga. Por ello, no fue posible incluirlo en las pruebas de comparación con el sistema desarrollado por el equipo

2.9 EthoVision

Iniciado como un sistema de rastreo de comportamiento animal cuyo funcionamiento parte de la identificación cuadro por cuadro de los objetos que aparecen en la escena separando siempre el cuerpo del animal del fondo mediante variaciones en brillo, matices de gris y combinaciones de tono y saturación lo que permite que el algoritmo distinga entre animales y el fondo del frame.

A partir de esta detección obtiene coordenadas área superficial para cada instante del experimento siguiendo de manera constante el movimiento en cualquier tipo de arena definida por el usuario.

El investigador puede organizar espacios de trabajo experimentos perfiles de adquisición y un conjunto amplio de variables independientes como tratamiento fecha configuración genética o temperatura junto

con variables dependientes como coordenadas x, coordenadas y, superficie, distancia recorrida, velocidad y tiempo en zonas que se almacenan en pistas.

El módulo de diseño experimental permite programar series completas de pruebas incluyendo qué animal se evalúa, en qué orden y con qué ajustes el módulo de adquisición procesa la imagen con tres métodos distintos de detección por umbrales de gris por sustracción del fondo o por color usando el modelo HSI. También puede rastrear hasta dos animales en paralelo cada uno con su color o tamaño particular y aplicar filtros para eliminar colas, sombras, ruido o barras de jaulas

El módulo de visualización permite reproducir los recorridos superpuestos al video o sobre la arena esquemática para analizar la exploración patrones de búsqueda o comportamiento. Finalmente, el módulo analítico transforma todas las coordenadas en datos cuantitativos como distancias, velocidades, cambios de dirección, permanencia en regiones o estados como movimiento e inmovilidad proporcionando estadísticas exportables a otros programas.

2.10 ANY-maze

ANY-Maze es un sistema de análisis automatizado de detección de conducta que funciona tomando un vídeo del experimento y procesándolo frame por frame para identificar al animal dentro del entorno por medio de un análisis de imagen por imagen con cada píxel siendo comparado para detectar diferencias con otras imágenes.

Para lograr la detección de movimiento, también utiliza métricas como la distancia recorrida, los patrones de movimiento y la permanencia en zonas, que se definen antes de iniciar la prueba y, que sirven para evaluar conductas como exploración o ansiedad. También cuenta con herramientas para configurar el experimento de manera flexible permitiendo delimitar áreas de interés para registrar eventos específicos ofreciendo un sistema que integra el seguimiento automático y la recolección de datos en una sola interfaz.

Una vez que el rastreo está en marcha, el programa genera estadísticas y gráficos que resumen variables como velocidad, entradas a zonas, tiempo de inmovilidad o patrones de exploración. Estas mediciones pueden exportarse para análisis posteriores; también incluye mecanismos para reducir la variabilidad del análisis como filtros de ruido, ajustes de sensibilidad y parámetros que permiten corregir trayectorias perdidas asegurando que el seguimiento se mantenga incluso en condiciones de baja iluminación o cuando el animal se superpone con elementos del entorno

El propósito del sistema es ofrecer una plataforma fácil de usar que automatice tareas que normalmente se harían manualmente lo que disminuye errores humanos y aumenta la reproducibilidad del experimento siendo una herramienta utilizada ampliamente en pruebas como laberintos elevados, laberintos en cruz, campo abierto o tareas de preferencia de lugar donde la posición y el movimiento del animal son indicadores centrales de la conducta evaluada.

2.11 Tabla Comparativa

Se presenta una tabla comparativa de trabajos similares que han abordado el análisis del comportamiento de especímenes en modelos de ansiedad, incluyendo metodologías tradicionales y herramientas automatizadas.

"Ethological and Temporal Analyses of Anxiety-like Behavior: The Elevated Plus-Maze Model 20 Years On" este artículo es una revisión que resalta la evolución del laberinto en cruz elevada como modelo de evaluación etológica de la ansiedad en roedores, destacando la necesidad de un análisis más profundo del comportamiento más allá de métricas tradicionales.[3]

"The Elevated T-Maze as an Experimental Model of Anxiety" propone un modelo alternativo que permite discriminar entre diferentes tipos de ansiedad a través del estudio de evitación y escape en un laberinto en T elevado.[4]

"ezTrack" es un software de código abierto que permite el seguimiento automatizado del comportamiento animal mediante análisis de video, sin necesidad de experiencia en programación, siendo una herramienta accesible y reproducible.[5]

Estos proyectos permiten contextualizar el desarrollo de nuestra propuesta.

Característica	DeepLabCut	ANY-maze	Ethovision	ezTrack [5]	Nuestro Prototipo (TT-2026-A155)
Costo	Gratuito (requiere GPU potente)	Muy costoso	Muy costoso	Gratuito	Gratuito / costo muy bajo
Facilidad de uso	Difícil, requiere programación	Muy intuitivo	Intermedio	Intermedio	Muy intuitivo
Estimación de postura	✓ Postura avanzada	✗ No especializado	✓ Postura avanzada	✗ No incluye postura real	✓ Postura completa (MediaPipe / DeepPose)
Clasificación de conductas	✗ Requiere código adicional	✗ Limitado a trayectorias	✓ Reconocimiento automático de comportamiento	✗ No clasifica	✓ CNN-LSTM con clasificación automática
Detección de micro-conductas (acicalamiento, inmovilidad, contacto)	✓ Si se programa, no por defecto	✗ No detecta acicalamiento	✓ Si detecta microconductas	✗ No detecta microconductas	✓ Sí detecta microconductas
Seguimiento del animal	Muy preciso, basado en keypoints	Bueno, basado en tracking clásico	Bueno: tracking robusto, incluso en video de baja resolución	Básico (centro de masa)	Preciso: YOLO + postura
Instalación	Compleja, setups largos	Fácil, instalación guiada	Fácil, instalación guiada	Fácil-intermedia	Fácil, interfaz web local directa
Reproducibilidad científica	Alta, depende del usuario	Media	Alta	Media-alta	Alta con k-fold + $\kappa \geq 0.8$
Dashboards y visualizaciones	✗ No incluidos	Básicos	✓ Incluye visualización de trayectorias y gráficos de actividad/movimiento	Básicos	✓ Dashboards interactivos y comparativos
Flexibilidad / modificación	Muy alta (open source)	Muy baja (cerrado)	Muy baja (cerrado, software comercial)	Alta (open source)	Alta (modular y expandible)
Usuarios objetivo	Programadores / expertos en IA	Investigadores sin experiencia técnica	Investigadores de comportamiento / neurociencias / farmacología que necesitan una solución robusta	Laboratorios con recursos básicos	Investigadores biomédicos, estudiantes y desarrolladores

Tabla 1: Comparación de trabajos similares [autoría propia]

Capítulo 3. Marco Teórico

3.1 Visión por computadora para seguimiento de objetos

La visión por computadora es una rama que permite a las máquinas para interpretar y entender el mundo visual. Para detectar y seguir el movimiento de los animales en videos, se emplean algoritmos sofisticados en el marco del seguimiento de objetos. Entre los algoritmos que más se usan se encuentran los siguientes:

3.1.1 YOLO (You Only Look Once)

Un algoritmo de detección de objetos en tiempo real. A diferencia de los métodos tradicionales que procesan la imagen por etapas separadas como extracción de características, generación de propuestas o clasificación independiente, YOLO realiza todo el proceso de detección en un solo paso, aplicando una sola red neuronal convolucional directamente sobre la imagen completa. Esta idea rompe con la lógica secuencial clásica mostrada en sistemas de visión artificial (descritos en las Ilustraciones 2 y 3), al tratar el reconocimiento y localización como un problema único y unificado[3].




Ilustración 2: Fases de un sistema de Visión Artificial




Ilustración 3: Pasos para el reconocimiento de patrones

La clave de YOLO radica en dividir la imagen en una cuadrícula: cada celda tiene la tarea de pronosticar si existe un objeto dentro de su área, produciendo coordenadas de un bounding box, así como una probabilidad de que esté presente y otra posibilidad para cada clase. Esta predicción directa convierte al algoritmo en uno de los más rápidos en visión por computador, ideal para aplicaciones donde la detección debe ocurrir en tiempo real, como aquellas que requieren seguimiento continuo del objeto, similar a la siguiente figura.




Ilustración 4: Ventana de seguimiento de un objeto en tiempo real

Al procesar toda la imagen de una sola vez, YOLO adquiere una comprensión global del contexto visual, así reduciendo los errores por confusión entre objetos y mejora la coherencia espacial de sus decisiones, lo que es especialmente valioso en escenas complejas o con múltiples instancias. No obstante, aunque YOLO es altamente eficiente, puede enfrentar dificultades en escenas donde hay oclusiones, pérdida temporal del objeto dentro del cuadro o variaciones bruscas de iluminación, condiciones que complican la detección continua y precisa, con una pérdida progresiva del objeto real, como se ejemplifica en la Ilustración 5




Ilustración 5: Trayectoria de un objeto seguido

3.1.2 DeepLabCut

Una herramienta de análisis de comportamiento desarrollada para realizar seguimiento basado en aprendizaje profundo sin necesidad de marcadores físicos. A diferencia de métodos clásicos como CAMShift o enfoques basados en histogramas de color, DeepLabCut utiliza arquitecturas de redes neuronales convolucionales (CNN) para identificar con alta precisión puntos anatómicos previamente definidos sobre animales u otros sujetos en movimiento. Esta metodología permite automatizar el análisis del comportamiento aun cuando existen variaciones en iluminación, perspectiva o apariencia del objeto, las cuales suelen afectar de forma significativa a los enfoques tradicionales de seguimiento.

Generalmente, su flujo de trabajo inicia con la selección de fotogramas representativos del video, los cuales posteriormente se etiquetan manualmente marcando las posiciones corporales relevantes para el estudio. Estos datos anotados alimentan el proceso de entrenamiento, durante el cual el modelo ajusta sus pesos para aprender la posición de los puntos clave. Una vez entrenado, el sistema puede predecir automáticamente la ubicación de dichos puntos en cada fotograma del video original o de nuevos videos, generando trayectorias temporales precisas que pueden utilizarse para análisis conductuales, cinemáticos o espaciales, tal como se ejemplifica en la Ilustración 6.




Ilustración 6: Esquema del algoritmo de seguimiento de CAMShift

La salida final de DeepLabCut no es una ventana adaptativa como en CAMShift, mostrada usualmente como una elipse de seguimiento (como en la Ilustración 7), sino un conjunto de coordenadas precisas para cada punto corporal entrenado. Esto permite análisis biomecánicos avanzados, cálculo de ángulos, trayectorias y patrones conductuales sin depender de contornos ni de la segmentación tradicional basada en color. Además, dado que cada frame se analiza independientemente mediante el modelo entrenado, no se acumula error histórico ni se generan divergencias de histograma como las que tu documento soluciona mediante promedio ponderado (ecuaciones 2–3).



Ilustración 7: Elipse sobre objeto en seguimiento

Cuando se observan resultados de un modelo entrenado para diferentes momentos del video, el comportamiento es comparable a las diferencias presentadas en la Ilustración 8, pero con la ventaja de que DeepLabCut mantiene precisión incluso si el animal cambia de forma, tamaño, pose o iluminación. Mientras CAMShift depende de mantener coherencia visual en color y dimensión para no perder el objeto, DeepLabCut aprende representaciones abstractas del cuerpo, lo que lo hace mucho más robusto, especialmente en ciencia del comportamiento, neurociencia y análisis de movimiento.




Ilustración 8: Cuadro inicial y final del video utilizado para el ensayo [4]

3.1.3 Estimación de postura (Pose Estimation)

Según Mathis et al. en su artículo “DeepLabCut: "Markerless Pose Estimation of User-Defined Body Parts with Deep Learning": el Pose Estimation es un método de visión por computadora que posibilita deducir la ubicación espacial de segmentos corporales, a menudo articulaciones o puntos clave, usando imágenes o videos [12]. Esta técnica es esencial para rastrear objetos, ya que no solo identifica la existencia de un organismo, sino que también proporciona una descripción de su forma corporal en tiempo real, lo cual permite realizar análisis detallados sobre movimiento y conducta. Los modelos de estimación de postura, a través de redes neuronales convolucionales u otras

arquitecturas de aprendizaje profundo, desarrollan la habilidad para convertir píxeles en coordenadas anatómicas.

De acuerdo con Cao et al., los escritores de "OpenPose: Estimación de poses 2D en tiempo real para múltiples personas a través de campos de afinidad por partes", las estrategias contemporáneas se categorizan en procedimientos de una fase y procedimientos de dos fases. Los métodos de una etapa, que calculan directamente las articulaciones a partir de la imagen sin necesidad de detectar antes el cuerpo entero, son más veloces, pero algo menos exactos. Los métodos de dos etapas, en cambio, primero identifican al sujeto y después hacen inferencias sobre su postura dentro de esa área. Los Part Affinity Fields (PAF), que fueron introducidos por OpenPose, hacen posible la asociación de varias articulaciones en situaciones donde hay más de una persona, lo cual soluciona la ambigüedad del ensamblaje de las articulaciones cuando existen varios individuos en la escena [23].




Ilustración 9: Representación de keypoints y campos de afinidad para múltiples personas (OpenPose) [23]

Según el artículo de Mathis et al., la estimación de postura sin marcadores se ha convertido en algo fundamental en la investigación biomédica y del comportamiento animal, ya que se requieren sistemas no invasivos con una precisión alta [12]. DeepLabCut, por citar un caso, posibilita la definición de puntos anatómicos concretos y el entrenamiento de modelos a medida con una cantidad de datos relativamente reducida, empleando para ello aprendizaje profundo y transferencia del aprendizaje. Esta herramienta es especialmente beneficiosa en contextos con variación postural significativa, fondos intrincados y movimientos veloces, y se emplea mucho en el análisis del movimiento, la neurociencia y la etología.




Ilustración 10: Estrategias de asociación de partes en DeepLabCut [12]

Incorporar la estimación de postura a los sistemas de seguimiento de objetos brinda un beneficio importante en comparación con los procedimientos que se basan solamente en cajas delimitadoras. De acuerdo con Pereira y Moita en "El papel de la visión por computadora en la etología: Un análisis de postura", la Pose Estimation permite medir ángulos articulares, trayectorias de extremidades, patrones de locomoción y micro comportamientos [16]. Esto es esencial para el estudio del comportamiento espontáneo, de las tareas motoras, de la evaluación del dolor o de los trastornos neuromotores, e incluso para la interacción social en animales de laboratorio. Asimismo, los datos producidos, al ser series temporales multivariadas, tienen la posibilidad de combinarse con modelos de aprendizaje automático como LSTM o Transformers para clasificar comportamientos o anticipar patrones en el futuro.

3.1.4 CAMShift y métodos clásicos de seguimiento

CAMShift (Continuously Adaptive Mean Shift), de acuerdo con Bradski, es una ampliación del algoritmo Mean-Shift que posibilita el seguimiento de objetos en videos en tiempo real. Esta técnica hace posible la modificación dinámica del tamaño y la orientación de la ventana de búsqueda a medida que cambia el aspecto del objeto [24].




Ilustración 11: Secuencia de fútbol americano siguiendo al jugador 75 [25]

Comaniciu, Ramesh y Meer explican que los métodos en función del kernel modelan el objeto a través de histogramas que son ponderados de manera espacial, lo cual asegura solidez frente a ruidos y distorsiones. La actualización ininterrumpida del modelo disminuye la deriva del rastreador a medida que la apariencia del objeto cambia progresivamente, y el procedimiento iterativo del algoritmo Mean-Shift permite encontrar el modo de la distribución de probabilidad del objeto [25].



Ilustración 12: Una imagen de video y su probabilidad de piel en la imagen [24]

De acuerdo con el tutorial de OpenCV, CAMShift y Mean-Shift son considerados algoritmos de seguimiento por apariencia; estos son veloces y apropiados para aplicaciones en tiempo real, aunque su sensibilidad a los fondos con colores parecidos y a las oclusiones es una limitante. Otros métodos tradicionales son el seguimiento de puntos locales (Lucas-Kanade), los filtros de Kalman o los filtros de partículas (predicción frente a oclusiones) y el template matching (eficaz, aunque limitado en situaciones de rotación y escala cambiantes) [26].

CAMShift es más eficaz en situaciones donde la información de color tiene capacidad de discriminación y las dinámicas del objeto son, por lo general, predecibles, según señala Bradski. Por lo tanto, se sugiere que el rendimiento sea evaluado a través de métricas como la tasa de pérdida (failure rate), la precisión del bounding box (IoU) y la deriva acumulada, empleando secuencias que contengan oclusiones, rotación y cambios de escala [24][26].



Ilustración 13: Ilustración 13. Ejemplo de seguimiento de un objeto con cambio de escala [26]

3.1.5 Redes Neuronales Convolucionales (CNN) aplicadas a visión por computadora

Según Bengio, Courville y Goodfellow, las Redes Neuronales Convolucionales (CNN) son la arquitectura básica para el análisis de imágenes, porque pueden aprender jerarquías de propiedades a partir de patrones sencillos, como texturas o bordes, hasta alcanzar representaciones complejas de objetos enteros [21]. Esta característica hace que las CNN sean especialmente beneficiosas en visión por computadora, donde es necesario entender con precisión la escena para detectar y ubicar elementos dentro de cada cuadro.




Ilustración 14: Arquitectura básica de una CNN

De acuerdo con Goodfellow et al., una CNN convencional está constituida por capas de pooling, capas convolucionales y capas completamente conectadas. Las capas convolucionales utilizan filtros con el fin de obtener propiedades locales de la imagen, a la vez que las capas de pooling disminuyen la dimensionalidad y mantienen la información más importante. Este proceso jerárquico favorece la generalización efectiva de la red, ya que es resistente ante cambios en la posición, escala y orientación de los objetos [21].

Según Redmon et al., YOLO (You Only Look Once) es el primer modelo de detección de objetos en tiempo real que empleó las CNNs de forma exhaustiva. Este modelo (como ya se mencionó con anterioridad) realiza una única pasada para procesar la imagen completa y, así, prever simultáneamente las cajas delimitadoras y las probabilidades de clase [13]. Esta perspectiva posibilita el establecimiento de sistemas de seguimiento que se basan en detecciones certeras y veloces, los cuales son compatibles con aplicaciones en tiempo real.



Ilustración 15: Pipeline de detección por CNN

Goodfellow et al. subrayan la relevancia de transfer learning en el ámbito del entrenamiento, que implica la reutilización de redes previamente entrenadas en extensas bases de datos como ImageNet y su adaptación a dominios particulares. Para optimizar la robustez y prevenir el sobreajuste, se hacen uso de métodos de normalización, regularización y aumento de datos. Las métricas de rendimiento más habituales incluyen la capacidad de la CNN para conservar su consistencia ante variaciones en la luz, obstrucciones parciales y desplazamientos de los objetos, así como la precisión media (mAP) para detección [21].

3.2 Machine Learning para Series Temporales

Para realizar el análisis computacional del comportamiento de los animales, no es suficiente con identificar lo que sucede en cada fotograma; también es necesario entender cómo dicho comportamiento se desarrolla con el tiempo. Para lograr esto, los modelos de aprendizaje automático que se especializan en series temporales posibilitan la captura de relaciones, patrones dinámicos y dependencias que solo se manifiestan cuando las observaciones se analizan como secuencias. En este campo, sobresalen las arquitecturas que se han creado para procesar datos históricos y simular alteraciones progresivas o repentinas en el desplazamiento de los animales, por ejemplo, las LSTM, las RNN, los Transformers y los métodos de validación estadística que se utilizan para medir su exactitud.

3.2.1 Redes Neuronales Recurrentes (RNN)

Los modelos de RNN están creados para manejar datos secuenciales, incluyendo dependencias temporales a través de un estado oculto que se actualiza en cada iteración. Según Goodfellow et al. (2016), su rasgo más característico es la existencia de conexiones recurrentes que posibilitan que datos de etapas anteriores incidan en el procesamiento actual, lo cual resulta fundamental para tareas con series temporales.




Ilustración 16: Arquitectura básica de una RNN

Matemáticamente, una RNN calcula su estado interno de este modo

$$h_t = f(W_{xh}x_t + W_{hh}h_{t-1} + b_n),$$

En la que h_t resume tanto la información actual como la que proviene del pasado cercano. Como Bishop (2006) señala, este estado encubierto se puede observar con mayor claridad al "desplegar" la red a través del tiempo, demostrando cómo cada paso depende del previo.

Debido a su estructura repetitiva, las RNN son particularmente beneficiosas en series temporales; la razón es que posibilitan la captura de cambios dinámicos, patrones a nivel local y dependencias de corto alcance sin requerir ventanas manuales de datos. Goodfellow y sus colegas (2016) muestran, además, un diagrama conceptual del flujo de información que ilustra el modo en que el estado oculto funciona como un resumen del pasado pertinente para hacer predicciones en cada momento.


3.2.2 LSTM (Long Short-Term Memory)

Esta es una arquitectura de redes neuronales recurrentes (RNN) diseñada específicamente para modelar dependencias a largo plazo en series temporales. De forma tradicional, las RNN tienen a “olvidar” información conforme las secuencias se vuelven largas debido al desvanecimiento o explosión del gradiente. Este problema, identificado desde la década de los noventa, llevó al desarrollo de la arquitectura LSTM por Hochreiter y Schmidhuber en 1997 [18]. A diferencia de la RNN estándar, las LSTM integran una estructura interna conocida como celda de memoria, cuya función es conservar información útil a lo largo del tiempo sin que esta se degrade conforme crece la longitud de la secuencia.

Una LSTM, en términos operativos, controla los datos que pasan por su celda de memoria con un grupo de puertas que funcionan como filtros. Esta dinámica interna posibilita determinar qué recordar, qué olvidar y qué mostrar como salida, solucionando de manera efectiva el problema de las dependencias a largo plazo. De acuerdo con la explicación clásica de Olah [19], el proceso se puede entender mediante cuatro pasos esenciales:

1. Forget gate (puerta de olvido)

Tal como se muestra en la Ilustración 9 del artículo de Ola “Understanding LSTM Networks” [19], la primera operación que se lleva a cabo dentro de la celda, y establece qué fracción del estado anterior C_{t-1} debe ser desechado. Basado en la combinación del estado oculto previo h_{t-1} con la entrada vigente x_t , un vector es producido por una capa sigmoide $f_t \in [0,1]$ que señala qué información se retiene y cuál se descarta.




$$f_t = \sigma (W_f \cdot [h_{t-1}, x_t] + b_f)$$

Ilustración 17: Puerta de olvido

2. Puerta de entrada y valores candidatos

En la Ilustración 10 de Olah [19] se observa el funcionamiento de la puerta de entrada, Aquí el modelo determina qué información reciente integrar en el estado interno. Para lograr esto, una segunda capa sigmoide produce i_t , que determina qué componentes serán actualizados, mientras que la capa $\tanh(h)$ calcula un vector candidato $\tilde{C}_t$ con los valores que podrían añadirse.



$$i_t = \sigma (W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$


Ilustración 18: Puerta de entrada y valores candidatos

3. Actualización del estado de la celda

La Ilustración 11 sintetiza la actualización del estado de la celda. El estado recién creado C_t se origina de la combinación de lo que se mantiene y lo que se añade:

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

Este mecanismo es fundamental para la estabilidad del comportamiento de las LSTM, ya que hace posible mantener información relevante durante largos periodos sin que esta se deteriore.



$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

Ilustración 19: Actualización del estado de la celda

4. Puerta de salida y generación del estado oculto

Finalmente, la Ilustración 12 de Olah [19] muestra como una tercera compuerta sigmoide establece qué fracción del estado C_t será presentada como solución. Después la celda aplica una función $\tanh(h)$ a C_t y la ajusta a través del vector o_t , generando de este modo el estado oculto h_t , que nutre la fase temporal siguiente.




Ilustración 20: Puerta de salida y generación del estado oculto

3.2.3 Transformers

Son una arquitectura de deep learning que reemplaza totalmente la utilización de redes recurrentes y convolucionales, empleando solamente mecanismos de atención propia para el procesamiento de secuencias. A pesar de que se introdujo en un principio para la traducción automática, sus características posibilitan su adaptación eficaz al modelado de series temporales, en las que es necesario captar relaciones a largo plazo entre posiciones dentro de la secuencia.

A diferencia de modelos recurrentes como LSTM y RNN, los Transformers posibilitan que el procesamiento de la secuencia total se realice en paralelo, lo que disminuye significativamente el tiempo de entrenamiento. La atención escalada por producto punto (scaled dot-product attention) facilita la conexión de cualquier momento temporal con otro utilizando una única operación computacional, lo que es extremadamente útil para series en las que las relaciones no tienen que ser necesariamente locales o próximas en el tiempo.




Ilustración 21: Arquitectura general del Transformer

Para el modelado de series temporales, el encoder lleva a cabo el procesamiento de la secuencia histórica (como los últimos n pasos), lo que produce representaciones internas que capturan las dependencias globales. El decodificador puede emplearse para hacer predicciones autorregresivas de manera secuencial, usando la set-attention enmascarada con el fin de evitar que el modelo “visualice el futuro”. Esta característica reproduce la conducta autorregresiva clásica de las series temporales, pero con el beneficio de que la atención posibilita que se exploten relaciones complejas a lo largo de toda la ventana temporal.

Para llevar a cabo esta operación, el Transformer utiliza el mecanismo de atención que se muestra en la Ilustración 14, en la cual cada instante de tiempo es representado como una consulta (Q), una clave (K) y un valor (V). Esto posibilita evaluar la importancia de cada momento de la serie en comparación con los otros.




Ilustración 22: Atención escalada por producto punto y multi-head attention

En la práctica, gracias a la multi-head attention, el modelo puede trabajar con varios patrones temporales al mismo tiempo: correlaciones entre variables, efectos rezagados, estacionalidades y tendencias, entre otros. Cada “cabeza” aprende una forma diferente de dependencia temporal.

El positional encoding es otro elemento fundamental para las series temporales; permite compensar la falta de recurrencia e introduce información acerca del orden temporal. La codificación sinusoidal que Vaswani, Shaazer y el equipo de desarrollo del Transformer propusieron específicamente posibilita que el modelo se generalice a horizontes temporales más extensos que los contemplados durante la fase de entrenamiento.

En la Tabla 2 se presenta un resumen de la superioridad estructural de los Transformers en comparación con las arquitecturas recurrentes y convoluciones, que consiste en su capacidad para atrapar dependencias globales a través de rutas computacionales más breves y en su menor complejidad secuencial.

Layer Type	Complexity per Layer	Sequential Operations	Maximum Path Length
Self-Attention	$O(n^2 \cdot d)$	$O(1)$	$O(1)$
Recurrent	$O(n \cdot d^2)$	$O(n)$	$O(n)$
Convolutional	$O(k \cdot n \cdot d^2)$	$O(1)$	$O(\log_k(n))$
Self-Attention (restricted)	$O(r \cdot n \cdot d)$	$O(1)$	$O(n/r)$

Tabla 2: Complejidad por capa y longitud de camino para diferentes arquitecturas

3.2.4 Coeficiente Kappa de Cohen para validación de concordancia

Según Cohen, el coeficiente Kappa de Cohen es una medida creada para calcular la concordancia entre dos clasificadores nominales, corrigiendo el acuerdo esperado por azar. Se utiliza con frecuencia como estándar para evaluar acuerdos interanotador y la validez de sistemas de clasificación automática. Esta característica lo vuelve particularmente valioso en problemas de Machine Learning para series temporales, en los que las etiquetas pueden ser ruidosas, ordinales o

desbalanceadas. En esas situaciones, si no se ajusta por la probabilidad de coincidencia aleatoria, el porcentaje de aciertos simple puede llevar a resultados engañosos [27].

De acuerdo con McHugh, la interpretación de Kappa se basa en una escala práctica: los valores que están cerca de 1 indican una concordancia casi perfecta; los que rondan el 0 muestran un acuerdo equivalente al azar, mientras que los negativos evidencian desacuerdo sistemático. El coeficiente Kappa proporciona un marco uniforme que posibilita la comparación de la fortaleza de los modelos ante la variabilidad humana en la anotación, para el análisis comparativo de arquitecturas de series temporales, como los modelos basados en Long Short-Term Memory (LSTM) de Hochreiter y Schmidhuber o los modelos Transformer sugeridos por Vaswani et al. Kappa es útil para determinar si un modelo está aprendiendo patrones reales o simplemente repitiendo la distribución marginal de clases cuando las anotaciones humanas son consideradas como "verdaderas" (standard gold) [28]; su implementación es aconsejable no solo para validar a los anotadores, sino también para informar sobre la confiabilidad del modelo.

La fórmula tradicional para calcular el coeficiente es $k = \left(\frac{p_o - p_e}{1 - p_e} \right)$ en donde p_o indica

la proporción y acuerdo que se ha observado y p_e la probabilidad de acuerdo esperada por azar. Fleiss et al. analizan a fondo las propiedades y generalizaciones estadísticas del coeficiente, y también tratan sobre versiones ponderadas que son beneficiosas cuando los desacuerdos no tienen la misma gravedad o cuando las clases poseen una relación ordinal (por ejemplo, un error adyacente en una escala ordinal debería ser penalizado menos que un error lejano) [29]. En series temporales de tipo biomédico o etológico, es necesario informar sobre p_o , p_e y k junto con intervalos de confianza es un buen método para proporcionar claridad acerca de la estabilidad estadística del indicador.

En investigaciones de estimación de postura y comportamiento en las cuales se emplean instrumentos como OpenPose (Cao et al.) o DeepLabCut (Mathis et al.), es habitual cotejar etiqueta por etiqueta las etiquetas automáticas con las humanas y reportar Kappa, además de matrices de confusión temporales y análisis de error por intervalos (por ejemplo, cuando hay transiciones entre estados). DeepLabCut y OpenPose posibilitan el etiquetado de frames a gran escala; sin embargo, en concordancia con Mathis et al., es fundamental la validación human-in-the-loop y el uso de métricas como Kappa para asegurar que los resultados sean creíbles y reproducibles [12]. Por ello, incluye visualizaciones temporales junto con los valores de Kappa para mostrar dónde suceden las discrepancias y si se agrupan en transiciones rápidas entre estados o en eventos poco comunes.




Ilustración 23: Ejemplo de Matriz de confusión temporal

3.3. Minería de Datos y Clasificación de Comportamientos

Para el análisis cuantitativo del comportamiento, se requieren métodos que tengan la capacidad de ordenar grandes cantidades de datos provenientes de trayectorias, posiciones y señales temporales. Este marco es proporcionado por la minería de datos, porque posibilita el hallazgo de estructuras internas, la disminución de la complejidad de las observaciones y la creación de categorías que simplifican la interpretación neuroconductual o etológica. En este marco, los algoritmos de agrupamiento, clasificación supervisada y reducción de dimensionalidad son fundamentales para detectar patrones repetitivos, diferenciar conjuntos de comportamientos y elegir las características más significativas en sistemas con una gran cantidad de variables que suelen ser ruidosas. Las siguientes subsecciones detallan las metodologías más utilizadas en este ámbito y explican su relevancia para el análisis computacional del comportamiento animal.

3.3.1 K-Means (Clustering)

El algoritmo K-Means, que fue presentado por primera vez en el trabajo de MacQueen "Some Methods for Classification and Analysis of Multivariate Observations" (1967) [30], es un método esencial para la agrupación no supervisada. Se emplea para identificar patrones y estructuras ocultas en conjuntos de datos con alta dimensionalidad. Este procedimiento, de acuerdo con el libro clásico de Bishop "Machine Learning and Pattern Recognition" [22], divide los datos en K grupos al minimizar la distancia entre cada punto y el centroide del clúster que le corresponde. Según Bishop, esta estrategia es especialmente efectiva cuando se persiguen "regiones compactas y casi esféricas" en los datos. Por lo tanto, es adecuada para usarse en minería de datos aplicada al estudio de la conducta animal, la identificación de patrones motores y el análisis etológico.

K-Means es un procedimiento para identificar patrones de conducta que se repiten con el tiempo, en el contexto de minería de datos y clasificación conductual. El algoritmo permite la agrupación de

segmentos de conducta semejantes sin requerir etiquetas previas en investigaciones que rastrean animales y donde se recogen variables como trayectorias espaciales, velocidad o ángulos corporales. Esta perspectiva, según Bishop [22], es efectiva para disminuir la dimensionalidad conceptual del comportamiento, ya que facilita la identificación de categorías que posteriormente pueden asociarse con fenómenos neuroconductuales o etológicos. Cuando se completa esta estructura con sistemas de visión computacional como EzTrack [5] o DeepLabCut [12], es particularmente beneficiosa, ya que ambos producen datos cuantitativos que tienen la capacidad de ser introducidos directamente en el algoritmo.

El proceso computacional se compone de cuatro etapas fundamentales: el establecimiento inicial de K centroides, la asignación a cada punto del centroe más próximo, el recálculo de los centroides y la repetición hasta que se alcance la convergencia. Según MacQueen [30], este ciclo es sencillo y eficiente, lo que posibilita la utilización de K-Means en grandes cantidades de información con un coste computacional reducido. En investigaciones sobre el comportamiento de los animales, esta eficacia permite analizar millones de fotogramas.




Ilustración 24: Representación gráfica del proceso iterativo (asignación y actualización)

K-Means tiene serias limitaciones a pesar de su utilidad. De acuerdo con Bishop [22], el método es sensible a la inicialización, tiene la capacidad de converger a soluciones locales y no opera adecuadamente si los clústeres son significativamente desiguales en tamaño o si no tienen una forma aproximadamente esférica. Por lo tanto, en las aplicaciones de análisis conductual, se aconseja que se revisen varias inicializaciones (k-means++) y que se valide a los clusters utilizando índices como Dunn o Silhouette.




Ilustración 25: Ejemplo de diferentes resultados de clustering con distintas distribuciones

3.3.2 Random Forest

El algoritmo Random Forest es parte de la familia de estrategias de ensamblaje que fusionan varios árboles de decisión con el propósito de optimizar la habilidad predictiva de los modelos. Según Breiman, que formalmente presentó esta técnica en 2001 [32], el procedimiento consiste en crear múltiples árboles que se entrenan sobre subconjuntos aleatorios de datos y variables. Esta estrategia, en el contexto de la minería de datos aplicada a la evaluación de comportamientos, disminuye la variabilidad que los modelos individuales tienen por su propia naturaleza y posibilita identificar patrones complejos sin caer fácilmente en el sobreajuste. Bishop sostiene que al combinar predicciones independientes de los modelos base, los métodos de ensamble aumentan la habilidad de generalización de manera constante [22].




Ilustración 26: Múltiples árboles de decisión en un Random Forest [34]




Ilustración 27: Diagrama esquemático de los métodos de ensamblaje [35]

En contextos en los que se examinan comportamientos humanos o animales a través de métodos de visión por computadora, es frecuente que los conjuntos de datos sean incompletos, tengan un alto número de dimensiones o estén llenos de ruido. Quintana-Diez afirma que la inclusión de inteligencia

artificial en el análisis del comportamiento animal ha posibilitado el tratamiento de grandes cantidades de datos con mayor exactitud y consistencia [14]. De acuerdo con Bailey y su equipo, los modelos computacionales contribuyen a relacionar patrones de comportamiento con parámetros fisiológicos, incluso cuando la información tiene variaciones entre individuos [10], este algoritmo es perfecto para este tipo de situaciones, ya que gestiona correctamente datos heterogéneos y posibilita determinar cuáles rasgos tienen mayor incidencia en una clasificación mediante medidas de la importancia de las variables.

DeepLabCut de Mathis et al. [12] y OpenPose de Cao et al. [23], que son herramientas modernas, también producen descriptores temporales y espaciales de alta resolución acerca del movimiento o la postura. Estos rasgos se utilizan como insumo para modelos de clasificación que emplean Random Forest, los cuales tienen la capacidad de identificar comportamientos, detectar anomalías o dividir grupos experimentales. Pereira y Moita, en sus investigaciones etológicas, afirman que la visión artificial ha transformado radicalmente el modo de cuantificar la conducta, posibilitando así la creación de bases de datos confiables y ampliables para realizar minería de datos [16]. En esa línea, el hecho de que el bosque aleatorio tenga la habilidad de trabajar con cientos de descriptores lo hace un candidato apropiado para los sistemas de análisis automatizado.

Asimismo, Random Forest se caracteriza por su capacidad para ser interpretado. De acuerdo con Hastie, Tibshirani y Friedman [33], en *The Elements of Statistical Learning*, los bosques posibilitan la estimación de la importancia de cada variable a través de métricas como el decrecimiento de impureza o la disminución en precisión al permutar características. Cuando se intenta entender qué elementos explican una conducta, sobre todo en la investigación veterinaria o biomédica, esta información es fundamental. Según Barton y Olson, para que los sistemas inteligentes sean integrables en la toma de decisiones clínicas, deben ser transparentes y precisos a la vez [9].

3.3.3 Máquinas de Vectores de Soporte (SVM)

Según Burges en "A Tutorial on Support Vector Machines for Pattern Recognition" [36], las máquinas de soporte vectorial (SVM) son un clasificador supervisado que se propone encontrar el hiperplano óptimo que divida dos clases, con el objetivo de maximizar el margen entre los vectores de soporte. Que el clasificador dependa solo de los vectores de soporte pone de relieve su eficiencia en la memoria y su habilidad para generalizar.




Ilustración 28: Ejemplo de un problema de clasificación en un espacio bidimensional. Los vectores de soporte marcados con cuadros grises definen el margen mayor de separación entre las 2 clases [36]

Las SVM son efectivas en espacios con alta dimensionalidad y se pueden utilizar cuando la cantidad de dimensiones sobrepasa la cantidad de muestras, de acuerdo con el manual de uso de scikit learn. [37] En concreto, el algoritmo contiene la selección de un parámetro de regularización C , que regula el balance entre la adaptación a los datos del entrenamiento y la capacidad de generalizar. Además, se trata el problema de los datos que no pueden separarse de manera no lineal al emplear funciones kernel (como la polinómica, la RBF o la lineal) para hacer un mapeo implícito a espacios de dimensiones superiores, sin tener que calcular explícitamente dicho mapeo.

De acuerdo con Burges [36], la formulación de la SVM se presenta como un problema de optimización cuadrática convexo, acompañado de restricciones que aseguran la clasificación correcta (en el caso separable) o permiten violaciones controladas (margen blando). Esta formulación asegura la existencia de un mínimo global, a diferencia de otros métodos como redes neuronales que pueden quedar atrapados en mínimos locales. Para el dominio de la clasificación de comportamientos tales como reconocimiento de gestos, detección de patrones de conducta o análisis de secuencias temporales, esta propiedad brinda robustez frente al ruido y estabilidad en la frontera de decisión.




Ilustración 29: Otro ejemplo de una SVM lineal que muestra el hiperplano óptimo, sus márgenes y los vectores de soporte que determinan la separación entre clases [37]

Según Burges [36], la formulación de la SVM es un problema de optimización cuadrática convexa, que incluye restricciones para garantizar una clasificación adecuada (en el caso separable) o para permitir infracciones controladas (margen blando). Esta formulación garantiza que haya un mínimo global, lo cual contrasta con otros métodos como las redes neuronales, que pueden quedar estancadas en mínimos locales. Esta propiedad proporciona estabilidad en la frontera de decisión y solidez frente al ruido en el ámbito de detección de patrones conductuales y clasificación de comportamientos.

3.3.4 Reducción de dimensionalidad

La reducción de dimensionalidad es una serie de métodos que buscan convertir datos de alta dimensión en representaciones más compactas, pero sin que la estructura fundamental del problema se vea afectada. Este procedimiento posibilita la eliminación de redundancias, ruido y variables que no tienen relevancia, según *Pattern Recognition and Machine Learning* de Christopher Bishop [22]. Esto es particularmente ventajoso en minería de datos, donde el número de atributos puede obstaculizar tanto el rendimiento computacional como la interpretación de los modelos. La reducción de la dimensionalidad, en este contexto, permite identificar patrones más generales y aumenta la habilidad de los algoritmos para clasificar las conductas complejas tanto en individuos como en animales.




Ilustración 30: Ejemplo conceptual del problema de dimensionalidad en un sistema de una pelota en un resorte observado desde 3 cámaras [31]

El PCA (Análisis de Componentes Principales) es un método muy utilizado. De acuerdo con lo que plantean Hastie, Tibshirani y Friedman en *The Elements of Statistical Learning* [33], el PCA proyecta los datos en nuevas direcciones ortogonales denominadas "componentes principales", las cuales capturan la mayor varianza posible del conjunto de datos original. Esto posibilita que la representación se simplifique sin que la estructura estadística predominante se vea afectada. La Ilustración 31 presenta una nube de puntos donde la dirección principal no coincide con los ejes originales, sino con una dirección inclinada que captura la señal principal, en otras palabras, muestra visualmente cómo PCA determina el rumbo de mayor varianza para describir los datos de manera más precisa.




Ilustración 31: Nube de datos simulados para la cámara A con indicación de varianza de señal y ruido. Adaptada de Shlens [31]

Bishop [22] también sostiene que los métodos no lineales, como Isomap y t-SNE, son capaces de mantener relaciones topológicas más complejas en los datos. Cuando las conductas tienen patrones muy correlacionados o dinámicas delicadas que no se pueden captar de manera apropiada a través de transformaciones lineales, estas técnicas resultan ser especialmente eficaces.

3.4 Modelos experimentales en etología y neurociencia conductual

El estudio experimental de la conducta ansiosa requiere modelos que integren principios etológicos con fundamentos neurobiológicos para permitir una interpretación cuantitativa y reproducible del comportamiento. Estos modelos, ampliamente empleados en neurociencia conductual, se basan en situaciones controladas que evocan respuestas defensivas naturales y facilitan la medición de variables como exploración, evitación e inmovilidad. Su diseño permite vincular patrones observables con procesos subyacentes (sensoriales, cognitivos y emocionales) y establecer puentes entre el comportamiento espontáneo de los animales y los mecanismos neurales que lo regulan. Las subsecciones siguientes describen los constructos etológicos relevantes y los paradigmas experimentales más utilizados en la caracterización del comportamiento ansioso.

3.4.1 Conceptos etológicos del comportamiento ansioso

El análisis del comportamiento ansioso en modelos animales se apoya en paradigmas experimentales que evocan respuestas defensivas naturales y permiten medirlas de forma objetiva. Estos modelos combinan principios etológicos y neurobiológicos para vincular acciones observables con los mecanismos que las generan. A continuación, se presentan los principales constructos conductuales y los métodos más empleados para su estudio.

3.4.1.1 Exploración

Según Carobrez y Bertoglio, la exploración se define como una serie de acciones encaminadas a obtener información sobre el entorno, que incluyen movimientos intencionados, rearings (alzadas),

olfateo dirigido y contacto con objetos [3]. Estas conductas posibilitan la evaluación de la interacción entre el deseo de investigar y la valoración del ambiente, y deben distinguirse del comportamiento motor general, puesto que solo el análisis combinado de frecuencia, tiempo y tipo de conducta proporciona una medida válida de la propensión a explorar [10].




Ilustración 32: Ejemplo de un módulo de seguimiento de ezTrack [5].

La operacionalización de la exploración en laboratorio, conforme a lo que indican Pennington y su equipo, necesita una etograma exhaustivo y sistemas de registro automatizados. Estos últimos posibilitan medir tanto sucesos discretos (por ejemplo "sniffing" o "head dips") como variables continuas (como trayectorias o tiempo en áreas). El análisis posicional y la extracción de series temporales de conducta son simplificados por herramientas como EzTrack, lo cual permite que la medición sea más exacta y reproducible [5]. También se aconseja incorporar sesiones de habituación antes para diferenciar la respuesta inicial a lo nuevo de la motivación exploratoria sostenida.

Según Pereira y Moita, unir una etograma con análisis multivariantes (como el agrupamiento de módulos conductuales o componentes principales) posibilita disociar, desde una perspectiva estadística, la exploración de otros elementos comportamentales. Esto permite aumentar la validez de las investigaciones y simplificar la comparación entre especies y protocolos [16]. Wiltshko et al. han mostrado, además, que el análisis de la estructura sub-segundo del comportamiento en roedores brinda una resolución temporal más precisa y permite descubrir micro-movimientos significativos que no se recogen en el análisis global [17].

Mathis y sus coautores han demostrado que, mediante DeepLabCut, se puede estimar la pose sin marcadores y cuantificar automáticamente posturas y movimientos particulares (por ejemplo, rearings

y head-dips) de modo reproducible. Esto mejora la exactitud de la medición de la exploración [12]. Así, es posible obtener información pormenorizada acerca de la motricidad y la disposición exploratoria sin perturbar el comportamiento natural de los animales.




Ilustración 33: Representación de módulos conductuales y transiciones destacando micro movimientos relevantes para la exploración [17]

3.4.1.2 Evitación

De acuerdo con Krypotos, Effting, Kindt y Beckers, la evitación es una táctica defensiva adaptativa que busca disminuir las posibilidades de enfrentarse a situaciones o estímulos aversivos. Sin embargo, si se vuelve generalizada o persiste sin una contingencia real, se convierte en mal adaptativa y ayuda a que los trastornos de ansiedad continúen. Krypotos et al. indican que la evitación puede ser adquirida por diversos medios, como procesos habituales y tendencias de rasgo, lo cual requiere paradigmas experimentales que dividan esos procesos. Además, describen los mecanismos de aprendizaje involucrados (los factores pavlovianos e instrumentales, la influencia de las instrucciones y el aprendizaje vicario). (Según Krypotos et al.). [39]




Ilustración 34: Red de la corteza prefrontal media y su implicación en la evitación defensiva [40]

Según la visión neuro etológica, Mobbs y su equipo sugieren que la evitación es parte de un sistema integrado de optimización de la supervivencia (SOS, por sus siglas en inglés), donde se coordinan circuitos que abarcan a la corteza prefrontal medial, al estriado, a la amígdala y a regiones mesencefálicas como el PAG. En este sistema están involucradas las siguientes funciones: evaluar amenazas, prever/prevenir y elegir estrategias como las respuestas circa-strike, el escape dirigido post encuentro y la evitación pre encuentro. Según Mobbs et al., la evitación preventiva (evitar el encuentro) se basa en procesos de predicción/simulación y en redes frontoestriales que facilitan un cambio de respuestas motivadas por miedo a respuestas más automáticas o instrumentales. (De acuerdo con Mobbs et al.). [40]

Ball y Gunaydin examinan cómo diferenciar la evitación adaptativa de evitación mal adaptativa, además de proponer un marco neuroconductual que divide tres procesos subyacentes: (i) evaluación exagerada del peligro, (ii) evitación regular (involuntaria, insensible al resultado) y (iii) tendencia a evitar como rasgo. Esto indica, en términos experimentales, que se deben medir no solo la expresión de evitación, sino también proxies del miedo (como las medidas autonómicas), la resistencia a la extinción y la generalización. De esta manera, se podrá determinar si el comportamiento de evitar es causado por un rasgo, un hábito o miedo. Según Ball y Gunaydin. [41]




Ilustración 35: Esquema que muestra como la interacción entre el miedo y la evitación permite identificar los procesos neuroconductuales subyacentes [41]

3.4.1.3 Inmovilidad/congelación

Desde el punto de vista etológico, la respuesta defensiva conocida como "freezing" o inmovilidad es una reacción frente a amenazas que, Según Brandão et al. [42], consiste en una repentina inhibición motora, acompañada de bradicardia, tras la identificación de un peligro inminente; esto posibilita que el individuo mejore la evaluación de riesgos y disminuya las posibilidades de ser descubierto por un depredador. Este fenómeno se encuentra en el continuo de inminencia depredadora ("predatory imminence continuum"), donde la táctica de defensa va cambiando a medida que la amenaza se aproxima, pasando por exploración, congelación y, finalmente, huida o lucha. [42]




Fig. 1. Activación de sustratos neuronales distintos en función de la naturaleza de los estímulos amenazadores. Los estímulos condicionados de peligro (potenciales o distales) elicitán comportamiento condicionado de congelación a través de la activación del sistema de inhibición conductual (sistema tepto-hipocampal), mientras que los estímulos innatos de peligro (proximales o nociceptivos) elicitán formas activas de comportamiento defensivo a través de la activación del eje amígdala-PAG dorsal. La activación del circuito PAG dorsal amígdala por estímulos nociceptivos también activa mecanismos inhibitorios a través de las proyecciones de la amígdala-PAG ventral, lo que podría subyacer a la llamada analgesia inducida por el miedo, o la propuesta de que la ansiedad inhibe el pánico, o la propuesta de que la ansiedad inhibe el pánico.

Ilustración 36: Esquema de la cascada defensiva [42]

La inmovilidad defensiva, desde la perspectiva neurobiológica, comprende proyecciones que van del núcleo central de la amígdala al gris periacueductal (PAG) en el tronco encefálico; este último regula la bradicardia vagal y la inhibición motora. Según Klaassen et al. [43], este mecanismo posibilita la preparación para actuar, incluso cuando el sujeto parece estar inmóvil. Asimismo, se ha relacionado en seres humanos la magnitud de la congelación con decisiones de aproximación-evitación ante una amenaza, lo que indica su importancia no solo en modelos animales, sino también en el análisis de la ansiedad clínica [43].

Desde el punto de vista etológico, la congelación es distinta de otros estados defensivos, como la inmovilidad tónica (“tonic immobility”), no solo en su función adaptativa, sino también en su desencadenante. La congelación ocurre cuando todavía hay una oportunidad de cambiar la estrategia defensiva, mientras que la inmovilidad tónica suele activarse cuando el sujeto no puede huir ni luchar, y toma una actitud parecida a la “muerte aparente”, esta diferenciación es beneficiosa para los modelos experimentales en neurociencia conductual, ya que posibilita el análisis de la manera en que los animales escogen sus respuestas ante diferentes grados de amenaza; esto tiene consecuencias para la investigación sobre características de ansiedad y susceptibilidad a trastornos de ansiedad [42].

3.4.2 Laberinto en Cruz Elevada (EPM)

El laberinto en cruz elevado (Elevated Plus-Maze, EPM) es un aparato experimental que se creó con el objetivo de analizar la conducta ansiosa en roedores. Según Carobrez y Bertoglio, el EPM es una plataforma que se encuentra a unos 50 cm del suelo y cuenta con cuatro brazos organizados en forma de cruz: dos de ellos están abiertos, mientras que los otros dos están cerrados por medio de paredes laterales [3]. Este tipo de configuración crea un entorno que mezcla áreas aversivas y seguras, lo cual posibilita la observación de cómo el animal toma decisiones cuando se enfrenta a la disyuntiva entre evitar y explorar.




Ilustración 37: Esquema del EPM desde vista superior. Los brazos horizontales son abiertos mientras los verticales son cerrados [44].

De acuerdo con lo que dicen Netto, Zangrossi y Graeff, la lógica del EPM se fundamenta en el temor natural que tienen los roedores a los espacios abiertos y altos [4]. Los brazos abiertos indican peligro, mientras que los cerrados sugieren una zona segura. El nivel de ansiedad del animal se refleja en la selección que hace entre estos espacios, lo cual representa un modelo etológico de aproximación y evitación.

Carobrez y Bertoglio [3] indican que el EPM tiene una estructura habitual con brazos de 50 cm de largo por 10 cm de ancho, que poseen paredes con una altura de 40 cm en los tramos cerrados. La parte central de la cruz es un pequeño soporte que une los cuatro brazos. Esta estandarización garantiza que los resultados sean comparables entre diferentes laboratorios.

El EPM opera de la siguiente manera: se ubica el animal en el centro de la cruz y se monitorea su conducta durante un lapso de 5 a 10 minutos. Los parámetros más frecuentes comprenden el tiempo de latencia para explorar, la cantidad de entradas a cada brazo y el tiempo que se permanece en brazos abiertos y cerrados [3].




Ilustración 38. Seguimiento del comportamiento individual de ratas mediante pruebas repetidas de EPM [45].

Según Khatri et al., la validación farmacológica del EPM se llevó a cabo con benzodiacepinas, las cuales incrementan la exploración de los brazos abiertos, lo que demuestra que el modelo es sensible a compuestos ansiolíticos [1]. Por lo tanto, el EPM es visto como un estándar fiable para evaluar la ansiedad en animales de laboratorio.

Se examinan conductas particulares como el "head-dipping" (cuando alguien se asoma por el borde de los brazos abiertos) y la "stretch-attend posture" (una postura en que se estira y retrocede), además de

las medidas básicas. Estos comportamientos, de acuerdo con Carobrez y Bertoglio, enriquecen la interpretación del modelo [3] y muestran estrategias para evaluar el riesgo.

Pennington et al. indican que los sistemas automatizados, como EzTrack, tienen la capacidad de reemplazar el registro manual. Estos sistemas posibilitan seguir el recorrido del animal y estimar métricas con mayor exactitud [5]. Esto ha permitido una disminución del sesgo observador y una mejora de la reproducibilidad, convirtiéndose en un instrumento accesible y reproducible [5].

Mathis et al. subrayan que tecnologías como DeepLabCut posibilitan la estimación de la postura del animal sin requerir marcadores [12]. Esto extiende el análisis del EPM a aspectos más detallados de la conducta, como los micro movimientos y los patrones de exploración.

Mobbs et al. [40] describen que la amígdala, el hipocampo y la corteza prefrontal intervienen en el control de la ansiedad, pues se activan ante circunstancias de peligro. El EPM ha posibilitado el reconocimiento de la interrelación entre estos sistemas de defensa y exploración, proporcionando pruebas sobre la neurobiología de la ansiedad, y de acuerdo con Bailey, Capozzi y Lowry, el EPM es un modelo traslacional, ya que los patrones de ansiedad detectados en roedores están vinculados a trastornos en seres humanos [10].

Su diseño simple, parámetros definidos y validación farmacológica lo hacen un modelo sólido para investigar la ansiedad al medir directamente la conducta de aproximación-evitación en un ambiente controlado.

3.5 Sistema operativo

El sistema operativo (SO) es el software que se ejecuta en una computadora, actuando como un intermediario entre el hardware y el software. El SO decide qué proceso recibirá acceso a la CPU y por cuánto tiempo, gestiona la memoria RAM asignando espacio a cada aplicación y protegiendo ese espacio. También administra el disco duro para que se puedan guardar y recuperar archivos.

3.5.1 Windows 10/11

Windows es un sistema operativo creado por Microsoft. Este software se compone de un grupo de programas que permiten gestionar y controlar el funcionamiento de varias partes de un ordenador, como la memoria, el disco duro y los dispositivos periféricos [83].

3.6 Lenguaje de programación

Un lenguaje de programación es un conjunto de reglas, símbolos y palabras clave que permiten la creación de instrucciones. Estas instrucciones se combinan para formar un programa que una computadora puede ejecutar y así llevar a cabo tareas específicas. La principal función de un lenguaje de programación es facilitar a los desarrolladores la escritura de algoritmos de manera lógica y estructurada.

3.6.1 Python

Python se erige como un lenguaje de programación robusto y de fácil asimilación. Su diseño incorpora estructuras de datos de alto nivel notablemente eficientes, complementadas por una metodología de programación orientada a objetos. La funcionalidad del intérprete de Python es extensible mediante la incorporación de nuevas funciones y tipos de datos implementados en lenguajes de bajo nivel como C o C++. Esto, a su vez, posiciona a Python como un lenguaje de extensión óptimo para la personalización de aplicaciones preexistentes [84].

Capítulo 4. Análisis

En este capítulo se ejemplificará el análisis que se realizó para desarrollar este prototipo. Este análisis engloba una serie de requerimientos, herramientas, técnicas, así como las especificaciones mínimas que se requieren para ejecutar el prototipo de manera segura.

4.1 Requerimientos

Los requerimientos funcionales y no funcionales son una serie de especificaciones que determinan el funcionamiento del prototipo. La necesidad de los requerimientos funcionales es esencial para el funcionamiento del prototipo; mientras que los no funcionales a pesar de ser importantes, no son esenciales para el prototipo, pero si para su correcto funcionamiento.

4.1.1 Requerimientos Funcionales (RF)

RF#	Descripción	Número y nombre de Caso de Uso	En caso de tener regla de negocio
RF-01	El sistema debe permitir cargar videos experimentales en formato MP4 y almacenar los metadatos asociados (fecha, tratamiento, espécimen y prueba).	Cargar video	RN2, RN3
RF-02	El sistema debe extraer y limpiar frames de los videos utilizando OpenCV y FFmpeg para generar secuencias listas para análisis.	Lanzamiento Pipeline YOLO Pose o DLC	
RF-03	El sistema debe detectar automáticamente la posición del espécimen mediante YOLO y realizar seguimiento utilizando estimación de postura con MediaPipe.	Lanzamiento Pipeline YOLO Pose o DLC	RN4
RF-04	El sistema debe reconocer patrones de comportamiento utilizando modelos CNN-LSTM entrenados con anotaciones expertas.	Rescate Temporal LSTM para Grooming	RN4
RF-05	El sistema debe mostrar trayectorias, mapas de calor y métricas de desempeño mediante un dashboard interactivo.	Visualización de detalle individual	
RF-06	El sistema debe incluir autenticación y gestión de roles (administrador e investigador) para controlar el acceso a los datos.	Verificación por OTP	RN1
RF-07	El sistema debe generar reportes en formato PDF que incluyan métricas, gráficas y análisis comparativos de tratamientos.	Exportación a CSV/JSON/PDF	
RF-08	El sistema debe generar archivos XLSX con tablas estructuradas que contengan métricas conductuales.	Exportación a CSV/JSON/PDF	

Tabla 3: "Requerimientos Funcionales (RF) del prototipo"

4.1.2 Requerimientos No Funcionales (RNF)

ID	Categoría	Requerimiento No Funcional	Descripción Detallada
RNF-01	Rendimiento y eficiencia	Tiempo máximo de procesamiento por video menor a 5 horas en GPU Colab.	El prototipo deberá ejecutar las fases de extracción, detección y clasificación en menos de 5 horas por video, optimizando el uso de GPU y memoria. Los procesos deberán paralelizarse cuando sea posible para evitar cuellos de botella.
RNF-02	Usabilidad y experiencia de usuario	Interfaz web intuitiva, accesible y coherente.	La interfaz deberá ser clara, visual y fácil de operar incluso para usuarios sin experiencia en programación. Se emplearán dashboards interactivos con colores contrastantes, menús descriptivos y mensajes de error interpretables.
RNF-03	Fiabilidad y disponibilidad	Continuidad del servicio y manejo de fallos.	El prototipo deberá garantizar la integridad de los datos y permitir la reanudación automática de procesos interrumpidos. Cualquier error crítico deberá registrarse en logs y notificarse al usuario sin pérdida de información.
RNF-04	Escalabilidad y capacidad de expansión	Capacidad para escalar horizontal o verticalmente.	La arquitectura deberá permitir añadir más recursos (CPU/GPU) o instancias en la nube sin necesidad de modificar el código fuente, posibilitando el procesamiento de mayores volúmenes de video y datos en futuras iteraciones.
RNF-05	Seguridad y confidencialidad	Protección de credenciales y datos experimentales.	Todas las comunicaciones deberán realizarse bajo protocolo HTTPS, con autenticación por token y cifrado SHA-256 para contraseñas.
RNF-06	Mantenibilidad y modularidad	Código modular, documentado y versionado.	El código fuente debe organizarse en módulos independientes (procesamiento, modelado, visualización), con documentación en cada función y control de versiones mediante Git y GitHub Issues para facilitar actualizaciones futuras.
RNF-07	Portabilidad y compatibilidad	Ejecución multiplataforma.	El prototipo deberá ejecutarse correctamente en sistemas operativos como Windows 10 o superior, utilizando dependencias fácilmente instalables mediante entornos virtuales (Conda o pip).
RNF-08	Trazabilidad y control de versiones	Registro y seguimiento de todos los cambios.	Cada modificación en el código, dataset o modelo entrenado deberá asociarse a una versión del repositorio en GitHub. Los commits deberán incluir descripciones claras y referencias a los requerimientos que satisfacen.

Tabla 4: "Requerimientos No Funcionales (RNF)"

4.1.3 Reglas del negocio

Las reglas del negocio constituyen los **principios rectores** que orientan la planificación, ejecución y validación de cada iteración dentro de la **metodología espiral de Boehm**. Estas reglas establecen los límites, prioridades y criterios de éxito del proyecto, asegurando que el desarrollo mantenga su enfoque académico, ético y técnico en todo momento. Cada iteración de la espiral tiene que ser planificada, llevada a cabo y evaluada según las pautas que se describen a continuación.

Las reglas del negocio permiten:

- **Estandarizar las decisiones y acciones**, evitando ambigüedad en los procesos.

- **Garantizar cumplimiento** con políticas académicas, técnicas y éticas.
- **Reducir riesgos y errores**, al establecer con claridad las condiciones y los límites del flujo de trabajo.
- **Alinear la planificación y validación** del prototipo conforme a los criterios de éxito definidos.

Estas reglas tienen que redactarse en un lenguaje que sea claro, comprobable y medible. En este proyecto, las normas de la empresa garantizarán que:

- Cada iteración cumpla con los estándares éticos y metodológicos del IPN.
- Los resultados de IA y minería de datos deben ser trazables y validados.
- Las decisiones acerca de los ajustes o mejoras de modelo se toman utilizando en métricas objetivas.

Cada iteración de la espiral debe planificarse, ejecutarse y evaluarse conforme a estas reglas, garantizando un desarrollo controlado, reproducible y alineado con los objetivos científicos y académicos del Trabajo Terminal.

A continuación, se detallan las reglas de negocio que rigen la operación, validación y mantenimiento del prototipo de análisis automatizado de comportamiento en modelos de ansiedad.

Cada regla está formulada de manera verificable, clara y orientada a buenas prácticas de ingeniería de software:

RN#	Descripción	Caso de cumplimiento	Caso de no cumplimiento
RN1	Todo usuario debe autenticarse mediante credenciales válidas, con contraseña. Solo personal autorizado puede acceder a datos experimentales.	El usuario ingresa con credenciales correctas y el prototipo muestra únicamente las funciones permitidas.	Se impide el acceso y se muestra mensaje: "Credenciales inválidas o usuario no autorizado".
RN2	Todo archivo cargado (videos, datos) debe cumplir validaciones automáticas de integridad: formato, tamaño, duración y consistencia con tratamiento.	El archivo pasa todas las validaciones y se registra correctamente.	La carga es rechazada con el mensaje: "El archivo no cumple las validaciones".
RN3	Los videos deberán tener resolución mínima de 720p para garantizar confiabilidad en detección de posturas.	El video es $\geq 720p$ y el prototipo permite el análisis.	El prototipo bloquea el análisis y muestra: "Resolución insuficiente (mínimo 720p)".
RN4	El modelo CNN-LSTM clasificará comportamiento en: activo, inmóvil, exploratorio, ansioso. Se guarda probabilidad, fecha e ID del video.	Si la probabilidad ≥ 0.6 , se registra la clasificación correspondiente.	Si la probabilidad < 0.6 , el segmento se marca como "indeterminado".
RN5	Cada resultado debe tener trazabilidad: video fuente, modelo, usuario, fecha y parámetros.	El prototipo genera automáticamente el registro completo de trazabilidad.	No se permite guardar el resultado y se muestra: "Información de trazabilidad incompleta".
RN6	Toda modificación del modelo o reglas deberá registrarse bajo control de versiones (GitHub) con commits identificados.	El cambio se registra en el repositorio con etiqueta de versión (vX.X).	El cambio no se acepta si no se documenta con commit y descripción.
RN7	Todo cambio en métricas, reglas o umbrales deberá documentarse, justificarse y aprobarse; el prototipo actualizará umbrales vía interfaz administrativa.	Se registra el cambio, se aprueba y se notifica al responsable técnico.	No se aplican cambios y se muestra: "Modificación no autorizada".
RN8	Cada regla deberá tener al menos un caso de prueba unitario registrado.	La prueba se ejecuta, pasa correctamente y queda documentada.	No se permite cerrar iteración sin caso de prueba correspondiente.
RN9	Todas las reglas deben cumplir estándares ISO/IEC 25010 y 12207: calidad, mantenibilidad y fiabilidad.	Auditoría de iteración $\geq 80\%$ de cumplimiento.	La auditoría exige correcciones antes de aprobar la iteración.
RN10	Todas las reglas deben estar en el SRS y reflejarse en los diagramas UML. Se mantendrá bitácora de decisiones.	La documentación está actualizada, con UML y bitácora completa.	No se aprueba avance si falta sincronización documental.
RN11	El prototipo debe cumplir ética y confidencialidad según NOM-062-ZOO-1999 e IPN. Ningún dato puede compartirse sin autorización.	Los datos se mantienen internos y accesibles solo a personal autorizado.	El prototipo bloquea cualquier acceso o exportación no autorizada.
RN12	Toda terminología (especimen, iteración, métrica, etc.) debe estar definida en un diccionario de negocio único.	Los documentos y el prototipo utilizan la misma terminología.	El sistema exige definir el término antes de continuar.

Tabla 5: "Reglas de Negocio"

4.2 Análisis de las herramientas a utilizar

Las herramientas por utilizar en este prototipo se dividen de la siguiente manera:

- Técnicas de visión por computadora.
- Arquitectura de aprendizaje profundo (Deep Learning).
- Algoritmos de clasificación (Clustering).
- Herramientas estadísticas.
- Conceptos etológicos para análisis de ansiedad.

4.2.1 Análisis de técnicas de detección de objetos

Se analizaron las siguientes técnicas de detección de objetos:

Herramienta	Tiempo real	Maneja múltiples objetos	Precisión	Fácil de entrenar	Ligero
YOLO	✓	✓	✓	✓	✓
Faster R-CNN	X	✓	✓	X	X
SSD	✓	✓	X	✓	✓
Retina Net	X	✓	✓	X	X
EfficientDet	X	✓	✓	X	✓

Tabla 6: "Tabla de análisis de técnicas de detección de objetos [autoría propia]"

Se optó por utilizar YOLO (You Only Look Once) sobre otras herramientas debido a que su tiempo de inferencia fue menor que varias implementaciones de Faster R-CNN con solo un tiempo de 13.5 milisegundos [55]. También suele ser más preciso que Retina Net y EfficientDet por márgenes de más de 40% [56]. Por otra parte, Adhikari et al sostienen que YOLO equilibra mejores factores como la precisión, velocidad, robustez y facilidad de uso [57].

4.2.2 Análisis de técnicas de estimación de pose con aprendizaje profundo

Se analizaron las siguientes técnicas de estimación de pose con aprendizaje profundo:

Herramienta	Precisión	No requiere marcadores	Adaptable	Facilita extracción de características	Requiere de alto cómputo
DeepLabCut	✓	✓	✓	✓	✓
DeepPoseKit	✓	✓	✓	✓	✓
LEAP	✓	✓	X	✓	X
OpenPose (adaptado a animales)	X	✓	X	✓	✓
SLEAP	✓	✓	✓	✓	✓

Tabla 7: "Tabla de análisis de técnicas de estimación de pose con aprendizaje profundo [autoría propia]"

A pesar de que DLC (DeepLabCut), DPK (DeepPoseKit) y SLEAP poseen características similares entre sí. DLC ofrece una mejor precisión a diferencia de DPK y SLEAP, dicha precisión de DLC puede ser comparada con la precisión humana. DLC es más robusto que LEAP y SLEAP para manejar oclusiones [58]. DLC puede ser entrenado para ser preciso con datasets pequeños de 100 a 200 imágenes, en comparación con otras herramientas que utilizan mayores cantidades de datos y no alcanzan una precisión como la de DLC [59].

4.2.3 Análisis de técnicas de estimación de pose

Se analizaron las siguientes técnicas de estimación de pose:

Herramienta	Seguimiento de puntos	Adaptable	Robustez	Tiempo real	Escalable
Pose Estimation	✓	✓	✓	✓	✓
Kinect Skeleton	✓	X	X	✓	✓
Marker-based Vicon	✓	X	✓	✓	X
OpenPose	✓	✓	X	X	✓
SLEAP	✓	✓	✓	✓	✓

Tabla 8: "Tabla de análisis de técnicas de estimación de pose [autoría propia]"

Según Lauer et al, Pose Estimation basada en DLC suele ser precisa sin necesidad de un marcador además de que es adaptable a varias especies de animales [60]. Mientras tanto, Kinect Skeleton y Vicon requieren de marcadores y es limitado en entornos naturales [61].

4.2.3.1 Actualización de análisis de técnicas de estimación de pose

El sistema migró de DLC a YOLO debido a que YOLO-Pose aplica un método sin mapas de calor, con entrenamiento extremo a extremo y optimización directa a través de la similitud entre puntos clave de objetos, según Deprabiya et al

Herramienta	Detección directa	Facilidad de entrenamiento	Robustez	Escalabilidad	Adapatabilidad
Pose Estimation (DLC)	X	X	✓	X	✓
YOLO	✓	✓	✓	✓	✓

Tabla 9: "Tabla de actualización de análisis de técnicas de estimación de pose [autoría propia]"

4.2.4 Análisis de herramientas de seguimiento visual

Se analizaron las siguientes herramientas de seguimiento visual:

Herramienta	Tiempo real	Ligero	Sensible a cambios	Robusto	Manejo de movimiento rápido
CamShift	✓	✓	✓	X	X
MeanShift	✓	✓	X	X	X
Optical Flow	✓	✓	X	X	✓
KLT Tracker	✓	✓	X	X	✓
CSRT Tracker	✓	X	✓	✓	✓

Tabla 10: "Tabla de análisis de herramientas de seguimiento visual [autoría propia]"

Se eligió CAMShift gracias a su simplicidad y eficiencia. CAMShift es basado en color y es útil en entornos controlados [62]. En cambio, MeanShift se pierde fácilmente con cambios de escala [63]. CAMShift no requiere una carga significativa de recursos computacionales a diferencia de CSRT y KLT que, no solo requieren más recursos, sino que también no funciona bien con oclusiones [64].

4.2.5 Análisis de arquitecturas de redes neuronales profundas para visión por computadora

Herramienta	Datos espaciales	Extracción de características visuales	Eficiencia en parámetros	Manejo de secuencias	Procesamiento en paralelo	Requerimientos computacionales
CNN	✓	✓	✓	✓	✓	✓
MLP	X	X	X	X	✓	✓
RNN	X	X	X	✓	X	✓
LSTM	X	X	X	✓	X	X
Transformers	✓	✓	X	✓	✓	X

Tabla 11: "Tabla de análisis de arquitecturas de redes neuronales profundas para visión por computadora [autoría propia]"

Se optó por usar CNN como arquitectura para visión por computadora debido a que, a diferencia de MLP, CNN aplica filtros para detectar patrones jerárquicos, desde bordes hasta objetos. En cambio, MLP trata a la imagen como un vector plano ignorando relaciones especiales [65]. Según Rajagukguk et al, CNN tiene una aplicación exitosa en la supervisión de animales [66].

4.2.6 Análisis de arquitecturas de aprendizaje profundo para series temporales

De forma conjunta, se optó por utilizar las siguientes arquitecturas:

- RNN (Red Neuronal Recurrente).
- LSTM (Long Short-Term Memory).
- Transformers.

Según Cole, RNN incorpora cada nueva secuencia y la salida depende de las secuencias ingresadas con anterioridad, además de que maneja entradas y salidas de longitud variable [67]. Por otra parte, las LSTM retienen información por largos períodos de tiempos capturando tendencias de largo plazo [68]. Mientras tanto, los Transformers suelen examinar las secuencias de entrada simultáneamente en vez de paso a paso [69].

4.2.7 Análisis de técnicas de minería de datos

Se optó por utilizar K-Means ya que reduce la complejidad de una imagen ya que se puede utilizar como herramienta de apoyo para segmentar poblaciones [70]. Por otra parte, Random Forest ayuda a clasificar el comportamiento animal a partir de datos de postura o movimiento, según Rew et al [71]. Las Máquinas de Soporte Vectorial (SVM) son una opción robusta para clasificar comportamientos de animales cuando se cuentan con datos de etiquetado para el entrenamiento, según Mosquera et al [72].

4.2.8 Análisis de sistemas operativos

Se analizaron los siguientes sistemas operativos:

Sistema operativo	Compatibilidad	Soporte para herramientas de Deep Learning	Facilidad de uso	Soporte técnico comercial
Windows	✓	✓	✓	✓
Linux	X	X	X	X
macOS	✓	X	✓	✓

Tabla 12: "Análisis de sistemas operativos [autoría propia]"

Se optó por usar Windows como sistema operativo del prototipo debido a su compatibilidad con herramientas de Deep Learning además de que hay soporte técnico comercial que evita incompatibilidades entre herramientas.

4.2.9 Análisis de los lenguajes de programación

Se analizaron los siguientes lenguajes de programación:

Lenguaje de programación	Facilidad de aprendizaje	Velocidad de desarrollo	Rendimiento	Soporte técnico
Python	✓	✓	✓	✓
Java	X	X	X	X
C++	X	X	✓	✓

Tabla 13: " Análisis de lenguajes de programación [autoría propia]"

Se optó por utilizar el lenguaje de programación Python debido a su velocidad de desarrollo y rendimiento en tareas de Machine Learning.

4.3 Análisis de riesgos

En concordancia con la metodología espiral de Boehm, se determina un proceso sistemático para detectar, evaluar y manejar los riesgos relacionados con el desarrollo del prototipo. Este procedimiento es un elemento fundamental de la planificación porque posibilita prever eventos que tienen el potencial de afectar la calidad del sistema, su continuidad operativa o la fiabilidad de los resultados experimentales. El manejo adecuado de estos riesgos tiene como objetivo preservar la estabilidad del equipo laboral, garantizar la disponibilidad e integridad de los datos y asegurar que se alcancen dentro del plazo y de manera apropiada las metas científicas e institucionales del proyecto.

Para comenzar con el análisis, se detectaron varios factores de riesgo en función de su tipo y se agrupan de acuerdo con su naturaleza, y cómo se relacionan con el ciclo de vida del proyecto:

- Económico: Eventos que afectan los costos del proyecto, como sobre costo en infraestructura o recursos.
- Operativo: Situaciones que afectan la continuidad operativa o la ejecución diaria del proyecto.
- Temporal: Factores que pueden provocar retrasos debido a la complejidad de tareas, procesos lentos o dependencias entre componentes.
- Técnico: Riesgos relacionados con el funcionamiento del software, modelos de IA, datos, hardware o infraestructura tecnológica.
- Recursos: Limitaciones o falta de disponibilidad de hardware, software, personal o herramientas necesarias para avanzar.
- Organizacional: Fallas internas relacionadas con procesos administrativos, alineación de objetivos o estructura del equipo.

- Falta de claridad: Problemas derivados de comunicación deficiente, roles indefinidos o instrucciones ambiguas entre los integrantes del equipo.
- Externo: Factores fuera del control del equipo, como contingencias institucionales, sociales o fallas de servicios externos.
- Personal: Problemas interpersonales o de comunicación que afectan el flujo de trabajo y la comprensión de objetivos.

Para clasificar cada riesgo el equipo definió criterios y rangos porcentuales en una tabla auxiliar llamada “Tabla de Evaluación de Impacto”, en donde se establece el nivel de severidad que tendría un riesgo si este llegara a presentarse, expresado mediante valores porcentuales asociados a afectación menor, compromiso de entregables o impacto crítico para el proyecto

Nivel	Valor Numérico (%)	Descripción del impacto
Bajo	<30%	Afectación menor sin alterar entregables
Medio	30-65%	Compromete entregables, calidad o datos
Alto	66-85%	Impacto crítico que detiene o invalida el proyecto

Tabla 6. Tabla de Evaluación de Impacto [autoría propia]

Tras establecer los grados de impacto, se calculó el riesgo total vinculado a cada evento usando la siguiente fórmula:

$$RE \text{ (Riesgo)} = P \text{ (Probabilidad)} \times I \text{ (Impacto)}$$

Esta expresión se refiere al modelo que la literatura acepta en gran medida para medir el nivel de riesgo. En esta, RE significa exposición total al riesgo, P es la probabilidad de ocurrencia expresada como porcentaje e I es la severidad del impacto también en porcentaje.

La fórmula se fundamenta en la definición oficial de riesgo de la norma internacional ISO 31000, que lo describe como la combinación entre la probabilidad de un evento y sus consecuencias [53]. Asimismo, coincide con la definición presentada por el National Institute of Standards and Technology (NIST) específicamente en la “NIST Special Publication 800-30”, una guía de 95 páginas para la evaluación de riesgos, en la cual el riesgo se define como el producto de la probabilidad de que un evento ocurra y el impacto que genera dentro del sistema evaluado [54]. Dada la publicación de Beazley Group [52], esta misma relación matemática se utiliza en guías aplicadas para el análisis de

riesgo, las cuales son empleadas en el sector de la ciberseguridad y tecnológico, por lo que su aplicación es completamente coherente con proyectos relacionados con ingeniería y software.

Finalmente, se presenta la Tabla de Clasificación de Riesgos, que permite identificar y categorizar cada riesgo según su nivel de impacto real, facilitando la evaluación objetiva de su severidad y la priorización de las medidas de mitigación correspondientes

Nivel	Rango de Probabilidad (%)	Rango de Probabilidad (%)
Bajo	<20%	Afectación mínima
Moderado	20-50%	Retraso o reproceso moderado
Alto	51-80%	Compromete entregables o datos
Extremo	>80%	Con impacto crítico al proyecto

Tabla 7. Tabla de Clasificación de Riesgos [autoría propia]

A partir de esta metodología, se elaboró la Matriz de Riesgos del Proyecto, que muestra los riesgos generales detectados, su categoría, probabilidad de ocurrencia, gravedad del impacto, nivel alcanzado según el tipo y las acciones de mitigación pertinentes que están en línea con los principios de gestión de Boehm. Esta matriz posibilita que se concentren recursos en los lugares que más lo necesitan, que se prioricen esfuerzos y, además, que haya una vigilancia constante sobre aquellos factores críticos que podrían afectar el éxito del prototipo.

ID	Riesgo	Descripción	Categoría	Probabilidad de ocurrencia (P%)	Severidad del impacto (I%)	Nivel (según P)	Gestión del riesgo
R01	Costes elevados	Incremento en el gasto de infraestructura en la nube o licencias para almacenamiento y entrenamiento.	Económico / Operativo	40%	50%	20% (Moderado)	Aprovechar servicios gratuitos o educativos de Google Cloud; programar sesiones de entrenamiento fuera de picos de carga.
R02	Factor tiempo	Retrasos por complejidad técnica o dependencia entre iteraciones (entrenamiento, validación, dashboard).	Temporal / Técnico	80% [48]	80%	64% (Alto)	Dividir entregables en sprints semanales, aplicar seguimiento ágil y establecer márgenes de contingencia.
R03	Escasez de recursos	Limitación de hardware (GPU, RAM) o falta temporal de integrantes para pruebas o validación.	Recursos	50%	80%	40% (Moderado)	Distribuir tareas, usar recursos compartidos (Colab, VM ESCOM), implementar cronograma de disponibilidad.
R04	Cambios operativos	Actualización o incompatibilidad de librerías (TensorFlow, MediaPipe) o errores por versiones distintas.	Operativo / Técnico	15%	50%	7.5% (Bajo)	Documentar dependencias, fijar versiones en requirements.txt, revisar entorno antes de cada iteración.
R05	Falta de claridad	Malentendidos en la comunicación del equipo o con los directores que afecten decisiones técnicas o prioridades.	Organizacional	15%	50%	7.5% (Bajo)	Reuniones de seguimiento semanales, bitácora compartida de decisiones y acuerdos, control de documentación en GitHub.

R06	Pérdida de código	Eliminación accidental o corrupción del repositorio	Técnico	5%	90%	4.5% (Bajo)	Implementar control de versiones y realizar respaldos periódicos en repositorios y almacenamiento en la nube.
R07	Falla de librería	Errores o incompatibilidades en dependencias	Técnico	10%	85%	8.5% (Bajo)	Reinstalar la librería afectada y verificar su compatibilidad con el entorno de desarrollo.
R08	Falla de hardware	Fallo de GPU, disco o equipo durante el desarrollo	Técnico	10%	90%	9% (Bajo)	Mantener respaldos actualizados en repositorios y nube, así como documentar cualquier cambio en el entorno de trabajo.
R09	Sesgo en los datos	Dataset no representativo o con distribución desigual	Técnico	75% [49]	80%	60% (Alto)	Realizar auditorías manuales o automáticas para detectar y corregir sesgos en el dataset.
R10	Baja calidad de datos	Datos incompletos, ruidosos o mal etiquetados	Técnico	85% [50]	80%	68% (Alto)	Implementar validaciones automáticas y procedimientos de preprocesamiento para estandarizar los datos.
R11	Sobreajuste	Modelo memoriza patrones y falla al generalizar	Técnico	30%	80%	24% (Moderado)	Aplicar técnicas de regularización y validación cruzada de manera iterativa.
R12	Problemas de escalabilidad	Falta de capacidad para procesar más datos o usuarios	Técnico	10%	80%	8% (Bajo)	Ajustar los requisitos del prototipo y utilizar infraestructura con mayor capacidad cuando sea necesario.
R13	Falta de habilidades	Dominio insuficiente de herramientas o frameworks	Falta de claridad	20%	50%	10% (Bajo)	Fomentar la capacitación continua mediante cursos y documentación técnica.
R14	Conflictos de rol	Funciones poco claras o tareas mal asignadas	Falta de claridad	30%	50%	15% (Bajo)	Definir claramente los roles y estructurar el flujo de trabajo del equipo.
R15	Falta de alineación	Diferencias en prioridades u objetivos	Organizacional	45%	50%	22.5% (Bajo)	Emplear herramientas de gestión colaborativa y reuniones periódicas de seguimiento.

R16	Expectativas excesivas	Estimaciones o promesas no realistas	Organizacional	25%	50%	12.5% (Bajo)	Establecer reportes de progreso semanales y revisar los compromisos adquiridos.
R17	Factores externos	Huelgas, recortes, cierres o eventos sociales	Externo / Temporal	25%	20%	5% (Bajo)	Esperar la resolución del conflicto y reprogramar las actividades afectadas.
R18	Cambios en requerimientos	Modificaciones al alcance del prototipo	Organizacional / Técnico	55%	70%	38.5% (Moderado)	Definir el alcance desde la primera iteración; registrar cambios mediante control de versiones y aprobación por los directores.
R19	Precisión insuficiente	Modelo ML no alcanza $\kappa < 0.80$	Técnico	30%	80%	24% (Moderado)	Ajustar hiperparámetros, ampliar dataset validado y aplicar técnicas de regularización y validación cruzada.
R20	Sobrecosto nube	Uso excesivo de GPU, VMs o almacenamiento	Económico / Operativo	40%	50%	20% (Moderado)	Monitorear consumo mensual; aprovechar créditos educativos y optimizar entrenamientos en sesiones programadas.
R21	Retraso por dependencias	Desfase entre módulos que impide avanzar	Temporal / Organizacional	80%	80%	64% (Alto)	Planificar con márgenes de contingencia; dividir iteraciones en tareas cortas con seguimiento semanal.
R22	Falta temporal de recursos	Escasez de hardware o personal disponible	Operativo / Recursos	50%	60%	30% (Moderado)	Compartir recursos mediante entornos colaborativos (Colab, servidores ESCOM) y redistribuir cargas de trabajo.
R23	Incompatibilidad de librerías	Cambios imprevistos en TensorFlow/MediaPipe	Técnico	45%	50%	22.5% (Moderado)	Documentar versiones en requirements.txt; validar compatibilidad antes de actualizar y mantener respaldo de entorno virtual.
R24	Confusión comunicativa	Malentendidos internos sobre objetivos	Organizacional / Personal	65%	50%	32.5% (Moderado)	Establecer reuniones semanales, bitácora compartida y control de tareas mediante GitHub Projects o Asana.

Tabla 8. Matriz de Riesgos [autoría propia]

4.3.6 Identificación de requerimientos técnicos

Se han definido los recursos esenciales necesarios para el funcionamiento óptimo del prototipo, tanto en hardware como en software, considerando la naturaleza del procesamiento de datos audiovisuales y el entrenamiento de modelos de aprendizaje profundo.

- **Hardware:**

- Cámaras de alta resolución y alta tasa de fotogramas por segundo (fps).
- *(Opcional)* Equipos o sensores específicos según los requerimientos del experimento, en caso de necesitar mediciones complementarias fuera del análisis visual.
- Servidores o GPUs potentes para el entrenamiento del modelo de IA (por ejemplo, NVIDIA RTX 3090 o equivalentes)

- **Software:**

- Librerías de visión por computadora como **OpenCV** y **DeepLabCut**.

- Frameworks de aprendizaje automático como **TensorFlow** y **PyTorch**.
- Entornos y lenguajes de análisis de datos como **Python**, **R** y **MATLAB**.

4.3.7 Requerimientos del prototipo

Los requerimientos del prototipo no se definen de manera rígida al inicio, sino que se **refinan progresivamente en cada iteración**, conforme se obtienen nuevos resultados de validación y retroalimentación de los usuarios expertos de la **Escuela Nacional de Medicina y Homeopatía (ENMyH)**.

El prototipo propuesto —un prototipo para el análisis automatizado de comportamiento en modelos de ansiedad— integra procesos de **visión por computadora, aprendizaje profundo, minería de datos y visualización interactiva**, por lo que sus requerimientos se dividen en **funcionales (RF)** y **no funcionales (RNF)**.

4.4 Análisis de factibilidad

4.4.1 Factibilidad tecnológica

La factibilidad tecnológica consiste en evaluar si el proyecto puede desarrollarse con la infraestructura técnica, el conocimiento especializado y los recursos disponibles. Su propósito es determinar si las tecnologías actuales, los equipos y el personal capacitado son suficientes para implementar el prototipo de manera eficiente y sostenible.

En el marco del modelo espiral de Boehm, este análisis se realiza de manera **iterativa**, verificando en cada ciclo la capacidad técnica del prototipo para cumplir con los objetivos planteados y ajustando los recursos conforme a las necesidades de desarrollo, entrenamiento y validación del prototipo.

El proceso de evaluación tecnológica del presente proyecto considera los siguientes aspectos:

4.4.1.1 Evaluación de recursos actuales y brechas tecnológicas

Se analizó la infraestructura disponible y las capacidades técnicas actuales, identificando posibles **brechas tecnológicas** entre los requerimientos del proyecto y los recursos existentes. Este análisis posibilita prever requerimientos de inversión, compra de partes o formación técnica extra para asegurar la compatibilidad y el desempeño del prototipo.

4.4.1.2 Simulación, modelado y pruebas

Se van a utilizar herramientas de simulación y experimentales para anticipar el comportamiento del prototipo y mejorar el desempeño de los modelos. Estas simulaciones posibilitan la validación de la eficiencia de los algoritmos y la capacidad del hardware antes de su implementación definitiva, lo que disminuye los costos y los riesgos técnicos.

4.4.1.3 Evaluación de compatibilidad e integración

El prototipo tiene una arquitectura modular que simplifica la incorporación con otros entornos laborales y programas científicos. Se toman en cuenta los elementos como la adecuación a sistemas ya existentes, el cumplimiento de las regulaciones técnicas y las limitaciones físicas y temporales del ambiente donde se desplegará el prototipo.

4.4.2 Factibilidad operativa

El objetivo de la factibilidad operativa del proyecto es establecer si el sistema propuesto tiene la capacidad de ser empleado adecuadamente en el ámbito académico y experimental para el que se pidió. En este caso, el proyecto no se origina como una iniciativa independiente, sino como una reacción directa a un requerimiento expuesto por el mismo solicitante: el Dr. César Augusto Sandino Reyes López, investigador del posgrado de la Escuela Nacional de Medicina y Homeopatía (ENMyH), quien propuso la necesidad de automatizar la interpretación de comportamientos en el modelo del EPM.

Para respaldar esta viabilidad, se utilizó un instrumento formal de recolección de datos dirigido al Dr. Sandino, investigador del posgrado de la Escuela Nacional de Medicina y Homeopatía (ENMyH). La aplicación se realizó a través de una entrevista estructurada que contenía ocho preguntas abiertas. El propósito de esta creación fue obtener datos reales sobre la demanda del sistema, los indicadores más relevantes, la factibilidad técnica del prototipo y las condiciones reales de operación en el laboratorio. El instrumento se utilizó en una reunión programada con el investigador en persona. El instrumento completo estará incluido en la sección de anexos.

Los datos obtenidos posibilitaron el análisis minucioso e individual de cada pregunta, funcionando como eje para perfeccionar requisitos y verificar las aptitudes operativas del sistema. Los cambios en la interfaz, la organización de los datos, las funciones automáticas de análisis y el modo en que se deben mostrar los resultados al usuario final fueron guiados por la información recabada.

El problema principal detectado en la entrevista fue que había que estandarizar la evaluación para que esta no dependiera del observador humano, y así poder interpretar las conductas de forma automatizada. El Dr. Sandino sostiene que el resultado exitoso es aquel en el que el sistema asigna las conductas de manera objetiva y consistente, disminuyendo así la variación común entre los evaluadores.

En relación con los datos necesarios, se determinó que los videos deben grabar las conductas de interés con un nivel de detalle suficiente para facilitar su identificación precisa. El sistema tiene que ser capaz de entender estos materiales sin requerir que el usuario los preprocese de manera compleja. En realidad, se destacó la relevancia de que la interfaz haga posible elegir el punto preciso en el que comienza el análisis, para no obligar al personal a manejar programas externos de edición para cortar los videos.

En el campo funcional, los periodos de tiempo en brazos abiertos y cerrados se indicaron como los indicadores primordiales para identificar efectos ansiolíticos. Estas dos categorías son el eje interpretativo del modelo, a pesar de que otras variables como la movilidad, las trayectorias o las áreas de permanencia ofrecen información importante. Asimismo, se destacó la conveniencia de observar los resultados en gráficos comunes y mapas de calor precisos que exhiban no solamente los valores globales, sino también la manera en que se distribuye el movimiento en el espacio.

Se concluyó que, en términos de precisión, el sistema tiene que obtener un nivel de concordancia entre el 90% y el 95% con respecto al análisis llevado a cabo por humanos, porque este rango es equivalente a la variación común entre tres observadores independientes en el laboratorio. Este aspecto fue crucial para determinar el umbral mínimo necesario para implementar el sistema como un instrumento de operación fiable.

El Dr. Sandino también subrayó que es fundamental que la plataforma sea accesible a los usuarios sin formación técnica, en especial a los investigadores y médicos que llevan a cabo los experimentos.

Si la interfaz es simple, con opciones claras y sin requerir conocimientos informáticos avanzados, se incrementará notablemente el uso del sistema. Se determinó que, en lo que concierne al formato de exportación de los resultados, la información tiene que ser descargable en Excel. Esto se debe a que el formato Excel posibilita la elaboración y re-graficado de los resultados en softwares especializados como R u Origin, dependiendo de las exigencias de publicación.

La sugerencia es mantener solamente los resultados procesados, no los videos originales, porque estos últimos ocupan mucho espacio de almacenamiento y registro histórico. El laboratorio tiene una variedad de opciones de computación, que van desde estaciones de trabajo hasta clústeres pequeños y sistemas con GPU. Por tanto, la elección definitiva estará determinada por las necesidades óptimas del sistema.

La viabilidad operativa general del prototipo, más allá de estos elementos particulares, se basa en contar con personal calificado, infraestructura tecnológica apropiada y una colaboración eficaz entre los desarrolladores y los investigadores participantes. La aplicación del modelo espiral de Boehm posibilitó incorporar en cada iteración una retroalimentación directa, modificando los requisitos a medida que el desarrollo progresaba.

El prototipo ofrecerá ventajas operativas concretas: disminución de errores humanos, reducción del tiempo de análisis de varias horas a minutos (dentro de un margen cercano al 85%), incremento en la reproducibilidad científica y ahorro financiero indirecto. La habilidad del prototipo para expandirse a otros modelos o especies, además de evitar licencias comerciales caras como EthoVision XT o ANY-maze, hace que su aceptación operativa sea aún mayor.

4.4.3 Factibilidad económica

En concordancia con el modelo **espiral de Boehm**, la **factibilidad económica** del proyecto no se concibe como un cálculo estático, sino como un **proceso iterativo** que evoluciona a lo largo de los ciclos de desarrollo. En cada iteración de la espiral se evalúan los costos asociados a recursos computacionales, humanos y tecnológicos, con el fin de identificar riesgos financieros y optimizar el uso de los recursos disponibles.

Los costos se dividen en dos categorías principales: **costos fijos** y **costos variables**, proyectados para un periodo de un año académico (48 semanas).

4.4.3.1 Costos fijos

Incluyen los recursos que permanecen constantes durante todo el ciclo de desarrollo:

- **Equipos de cómputo:** laptops o estaciones con GPU NVIDIA (mínimo RTX 3060) para el entrenamiento de modelos (~\$35,000 MXN por equipo).
- **Software y licencias:** herramientas de desarrollo (Google Colab Pro, o entornos de nube con GPU dedicadas) — costo anual estimado \$5,000 MXN.
- **Gastos administrativos y de infraestructura:** conexión a internet, electricidad y mantenimiento de red — \$3,500 MXN.
- **Costos de documentación e impresión:** generación de informes, anexos y documentación técnica — \$1,500 MXN.

Total, costos fijos aproximados: \$45,000 MXN.

4.4.3.2 Costos variables

Estos costos dependen del avance de cada iteración del modelo espiral:

- **Servicios en la nube:** ejecución de experimentos y almacenamiento de datasets en Google Cloud o Kaggle (~\$1,000 MXN por iteración; total \$5,000 MXN).
- **Material experimental:** mantenimiento y manejo de especímenes de laboratorio proporcionados por ENMyH — estimado \$2,000 MXN.
- **Material audiovisual:** cámaras y soporte para grabaciones, cables HDMI y almacenamiento externo — \$3,000 MXN.
- **Capacitación técnica:** cursos o talleres de IA/visión por computadora (~\$2,000 MXN).

Total, costos variables estimados: \$12,000 MXN.

Costo total proyectado del proyecto: $\approx$ \$57,000 MXN.

4.4.3.3 Costos totales estimados del desarrollo del proyecto

Categoría	Concepto	Costo estimado (MXN)	Descripción
Costos fijos	Equipos de cómputo con GPU (RTX 3060 o superior)	\$35,000	Estación de trabajo para entrenamiento de modelos CNN-LSTM y YOLO.
	Licencias y entornos de desarrollo (Colab Pro, VS Code, GitHub, GCP)	\$5,000	Accesos premium y servicios de nube.
	Gastos administrativos (electricidad, internet, mantenimiento)	\$3,500	Operación durante el periodo de desarrollo.
	Documentación, reportes e impresión	\$1,500	Material de apoyo y entregables físicos.
Costos variables	Servicios en la nube y almacenamiento de datasets	\$5,000	Ejecución y respaldo de modelos durante las iteraciones.
	Material experimental y mantenimiento de especímenes	\$2,000	Uso en colaboración con la ENMyH.
	Cámaras y materiales audiovisuales	\$3,000	Grabación y vectorización de video.
	Capacitación técnica especializada	\$2,000	Cursos o talleres de IA y visión por computadora.
Total	—	\$57,000	Inversión total proyectada para 48 semanas.

Tabla 14: Costos totales estimados del desarrollo del proyecto

4.4.3.4 Conclusión de viabilidad económica

El proyecto es **económicamente viable**, ya que los beneficios derivados del ahorro de tiempo, la precisión en los resultados y la optimización de los recursos superan ampliamente los costos de implementación.

El uso de **metodologías iterativas basadas en el modelo espiral** permite ajustar los recursos económicos conforme avanza el desarrollo y **minimizando riesgos financieros**.

4.4.4 Factibilidad legal

El proyecto “Prototipo para análisis automatizado y visualización de comportamiento de especímenes en modelos de ansiedad” se desarrolla en un entorno académico e institucional bajo los lineamientos del Instituto Politécnico Nacional (IPN), en colaboración con la Escuela Nacional de Medicina y Homeopatía (ENMyH) y la Escuela Superior de Cómputo (ESCOM), garantizando que todas las actividades estén sujetas a las políticas éticas y normativas vigentes del Instituto.

4.4.4.1 Identificación del marco legal aplicable

1. Protección de datos personales

El prototipo no procesa información personal de individuos, sino datos derivados de observaciones experimentales con especímenes animales.

No obstante, se cumplen los principios establecidos en la Ley Federal de Protección de Datos Personales en Posesión de los Particulares (LFPDPPP), asegurando la confidencialidad de cualquier información técnica o académica generada por los investigadores y colaboradores.

2. Normativa sobre el uso de animales de laboratorio

El manejo experimental de los especímenes se apega a la Norma Oficial Mexicana NOM-062-ZOO-1999, que regula la producción, cuidado y uso de animales de laboratorio.

Esta norma establece especificaciones éticas y sanitarias que deben seguirse en todos los procedimientos experimentales, las cuales son observadas por la ENMyH-IPN.

3. Propiedad intelectual y licencias de software

Todo el desarrollo del código, documentación y modelos de IA es de autoría del equipo desarrollador y se encuentra protegido por la Ley Federal del Derecho de Autor (LFDA).

El proyecto utiliza herramientas y librerías de código abierto bajo licencias compatibles (MIT, Apache 2.0 y GPL v3), lo cual no infringe derechos de terceros y permite la libre distribución y modificación del software con fines académicos.

4. Cumplimiento institucional y uso educativo

El prototipo se enmarca en las políticas de investigación del IPN y cumple con los Lineamientos de Propiedad Intelectual y Transferencia de Conocimiento (2023) del Instituto.

Además, su uso está destinado exclusivamente a fines científicos, educativos y de investigación, sin propósito comercial directo.

4.5 Análisis de sostenibilidad

El análisis de sostenibilidad es un componente clave en el desarrollo de sistemas tecnológicos porque posibilita la detección y la mitigación de los efectos sociales, técnicos y ambientales que se producen durante todo el ciclo vital del software. Según las directrices establecidas en ISO 14064-1 y en las pautas muy usadas en ingeniería de software sostenible, un proyecto tiene que incluir una valoración del consumo de energía, las emisiones relacionadas, la disminución de los impactos operacionales y estrategias para disminuir el daño al medio ambiente [73], [74].

4.5.1 Evaluación del consumo energético del proyecto

Para estimar el consumo energético se emplea la relación estándar:

$$E = P \cdot t$$

donde P es la potencia promedio del equipo empleado y t el tiempo de ejecución. Patterson indica que los servidores ligeros y las estaciones de trabajo empleados para cargas intensivas de cómputo tienen un consumo típico que oscila entre 40 y 70 W [75]. En consecuencia, se establece un valor intermedio de 50 W para el ordenador personal empleado en las pruebas.

Tiempos reales de ejecución

Los datos siguientes fueron recolectados a lo largo de la experimentación del proyecto:

Computadora A: Procesados 5 minutos de video (aproximadamente 7200 fotogramas) en un tiempo de alrededor de 35 minutos.

Computadora B: Procesamiento de 3000 fotogramas en un lapso de alrededor de 49 minutos.

Para mantener consistencia, se toma el tiempo promedio observado para la ejecución completa del video:

$$t_{local} = 42 \text{ min} = 0.7h$$

El consumo energético en la computadora local es entonces:

$$E_{local} = 50W \cdot 0.7 = 35Wh$$

Consumo energético en Google Colab

Google Colab utiliza la infraestructura compartida de los centros de datos. Según una investigación reciente del IEEE, los nodos de computación virtualizados que se utilizan para cargas de trabajo moderadas tienen un consumo medio de entre 100 y 150 W, tomando en cuenta el segmento del servidor atribuido a un notebook virtualizado [76]. Se adopta el valor conservador de 100 W.

Si la mitad del procesamiento se delega a Colab:

$$t_{colab} = 0.7h$$

$$E_{colab} = 100W \cdot 0.7h = 70Wh$$

Consumo total del análisis

$$E_{total} = E_{local} + E_{colab} = 35Wh + 70Wh = 105Wh$$

4.5.2 Evaluación de huella de carbono (ISO 14064-1)

La huella de carbono se calcula conforme el modelo definido en ISO 14064-1, donde:

$$CO_2 = E \cdot FE$$

La International Energy Agency reportó y los estudios energéticos del IEEE citan que el factor de emisión eléctrica para México en 2025 será de 0.434 kg CO₂/kWh [77].

$$105Wh = 0.105kWh$$

$$CO_2 = 0.105 \cdot 0.434 = 0.04557kgCO_2$$

Esto equivale a aproximadamente a 45 gramos de CO₂ por procesamiento completo de un video de 5 minutos.

Esta emisión es considerablemente más baja en comparación con la que está asociada al transporte físico de personal al laboratorio para hacer análisis manuales, el cual se desarrollará más adelante.

4.5.3 Impacto ambiental del proceso tradicional vs. el prototipo

El método tradicional de análisis requiere la presencia de:

- Al menos 1 laboratorista o investigador
- Al menos 3 asistentes encargados de la observación manual,
- En ocasiones un supervisor o validador adicional

Cada miembro debe desplazarse a las instalaciones educativas o de investigación, lo que produce un efecto ambiental vinculado con la movilidad urbana. Según cálculos que se han consolidado en inventarios urbanos y que se encuentran en investigaciones de transporte del IEEE [78], el índice de emisión promedio para coches en la Ciudad de México es 0.192 kg CO₂/km.

En el entorno particular de la Ciudad de México la distribución modal registrada en la Ciudad de México, aproximadamente el 50% de los desplazamientos urbanos son realizados en transporte público [85] mientras que el resto utilizan transporte privado. Por lo tanto, se estima que al menos la mitad de los miembros emplea transporte público para ir al laboratorio, mientras que el resto hace uso del transporte privado.

Para calcular el impacto ecológico del transporte público, se usa también un valor técnico de uso frecuente en evaluaciones urbanas, especialmente en investigaciones sobre la electrificación de flotas y la eficacia energética. Este establece que el consumo por vehículo-kilómetro para los autobuses estándar es de cerca de 0.6 kg CO₂, tomando como referencia el promedio de emisión del sistema eléctrico mexicano [86]. Se debe dividir este valor entre la ocupación del vehículo para convertirlo a emisiones por pasajero-kilómetro, y se presentan diferentes escenarios lógicos que posibilitan calcular el rango posible de acuerdo con las condiciones auténticas del transporte urbano en hora pico o en operación normal.

Cálculo de emisiones del método tradicional (2 personas)

Distancia promedio diaria (ida + vuelta): 16 km
Factor de emisión: 0.192 kg CO₂/km

$$CO_{privper} = 16km \cdot 0.192 \frac{kg}{km} = 3.072kgCO_2$$

Para 2 personas:

$$CO_{privtotal} = 2 \cdot 3.072 = 6.144kgCO_2$$

Emisiones del transporte público (2 personas)

Se convierte el valor de 0.6 kg CO₂/veh-km a emisiones por pasajero-kilómetro considerando diferentes niveles de ocupación:

Escenario A: Ocupación alta (135 pasajeros, BRT/Metrobús en hora pico)

Valores documentados de ocupación pico en corredores tipo BRT.

$$EF_{pas} = 0.6/35 = 0.00444 \text{ kg CO}_2 / pas \cdot km$$

$$CO_{pubper} = 0.16km \cdot 0.00444 = 0.0711kgCO_2$$

Para 2 personas:

$$CO_{pubA} = 0.1422kgCO_2$$

Escenario B: Ocupación media (40 pasajeros)

Valor representativo típico de ocupación urbana consolidado en estudios comparativos.

$$EF_{pas} = \frac{0.6}{40} = 0.015$$

Para 2 personas:

$$CO_{pubB} = 0.048kgCO_2$$

Escenario C: Ocupación baja (20 pasajeros)

Escenario conservador de baja demanda.

$$EF_{pas} = 0.6/20 = 0.03 \text{ kg } CO_2 / pas \cdot km$$

$$CO_{pubper} = 16km \cdot 0.03 = 0.48kgCO_2$$

Para 2 personas:

Escenario A:

$$CO_{totalA} = 6.144 + 0.1422 = 6.2862kgCO_2$$

Escenario B:

$$CO_{totalB} = 6.144 + 0.48 = 6.624kgCO_2$$

Escenario C:

$$CO_{totalC} = 6.144 + 0.96 = 7.104kgCO_2$$

3.5.4 Comparación con el prototipo

Como se estableció previamente, el prototipo genera.

$$CO_{prototipo} = 0.04557kgCO_2 \text{ por análisis completo}$$

Comparación porcentual:

Escenario A $\approx 99.33\%$

Escenario B: $\approx 99.31\%$

Escenario C: $\approx 99.35\%$

Aun al tomar en cuenta escenarios conservadores para el transporte público y aplicar la realidad de que más de la mitad del equipo emplea este modo de transporte, el efecto medioambiental del método

tradicional continúa siendo de 6.2 a 7.1 kg CO₂ por jornada; en cambio, el prototipo solamente genera 0.0379 kg CO₂ por procesamiento completo.

La disminución resultante varía entre el 99.33% y el 99.35%, lo que indica que el prototipo erradica casi por completo la huella vinculada al traslado del personal, convirtiéndose así en una opción significativamente más responsable con el medio ambiente, eficiente y sostenible.

Capítulo 5. Diseño

5.1 Arquitectura del prototipo

La arquitectura del prototipo refleja los procesos más importantes del desarrollo este prototipo, el cual realizara mediante minería de datos, IA y machine learning para la evaluación de tratamientos farmacológicos en modelos de ansiedad. Además, contará con un sistema de inicio de sesión, vectorización de video y validación del comportamiento de los especímenes en pruebas específicas. En la ilustración 38, se puede observar la arquitectura del prototipo de forma general para entender visualmente el funcionamiento de esta. La arquitectura describe los diferentes módulos dentro del prototipo por el cual pasa un archivo audiovisual (vídeo) siendo preprocesado antes de que se obtengan datos que son útiles para los módulos de modelado de conductas y análisis estadístico. El módulo de visualización presenta los datos al usuario y estos son guardados posteriormente para una comparación usando tesis o ANOVA en este.




Ilustración 38: Arquitectura general del prototipo [autoría propia]

5.2 Modelo de bases de datos

El diagrama entidad-relación representa la estructura de la base de datos del prototipo. La entidad Usuario (users) almacena la información de autenticación y perfil de los usuarios del sistema, incluyendo atributos como id, username, password_hash, role, is_verified, is_active y created_at. Además, dependiendo del rol del usuario (admin, investigador o estudiante), se incluyen atributos específicos como boleta, carrera, num_empleado o area. Los usuarios pueden registrar experimentos y crear tratamientos experimentales.

La entidad Tratamiento (treatments) contiene los atributos id, name, description, created_by, is_active y created_at, y define los diferentes tratamientos aplicados durante los experimentos. Cada tratamiento puede ser creado por un usuario mediante una relación uno a muchos entre users y treatments.

La entidad Experimento (experiments) representa cada sesión experimental realizada sobre un modelo animal y contiene atributos como id, rat_id, treatment, experiment_date, responsible, video_path, duration_seconds, processed y created_at. Cada experimento es registrado por un usuario y puede estar asociado a múltiples configuraciones de regiones de interés.


La entidad Configuración ROI (roi_configurations) almacena las regiones de interés utilizadas en el análisis del laberinto EPM, incluyendo atributos como id, experiment_id, zone_type, coordinates_json y scale_factor. Cada experimento puede tener múltiples configuraciones ROI correspondientes a zonas como Brazo Abierto, Brazo Cerrado y Centro.

La entidad Resultados de Análisis (analysis_results) almacena las métricas obtenidas mediante el análisis automatizado por inteligencia artificial. Entre sus atributos se encuentran id, experiment_id, total_distance, time_open_arms, time_closed_arms, time_center, head_dips_count, rearing_count, grooming_duration, thigmotaxis_duration, status y timestamp. Cada experimento genera un único conjunto de resultados de análisis, estableciendo una relación uno a uno entre experiments y analysis_results.

Finalmente, la entidad Registro de Auditoría (security_audit_log) almacena eventos relacionados con autenticación, verificación y seguridad del sistema. Sus atributos incluyen id, timestamp, event_type, username, ip_address, success, message y level, permitiendo mantener trazabilidad y control de eventos críticos dentro de la plataforma.



Ilustración 39: "Modelo de base de datos (parte superior) [autoría propia]"



5.2.1 Diccionario de datos

En este apartado se presenta el diccionario de datos correspondiente a la base de datos del sistema, utilizado para la organización y gestión de la información empleada por el prototipo desarrollado. Su propósito es establecer de manera estructurada los elementos necesarios para el almacenamiento y administración de los datos dentro de la plataforma.

Tabla “users”

Tabla de gestión de usuarios del sistema. Almacena credenciales, perfiles y datos de autenticación. Soporta dos tipos de perfil: Estudiante (@alumno.ipn.mx) e Investigador (@ipn.mx).

Campo	Tipo de dato	Restricciones	Valor predeterminado	Descripción	Notas
id	SERIAL	PRIMARY KEY	Auto-incremental	Identificador único de usuario	
username	VARCHAR(50)	UNIQUE NOT NULL	Ninguno	Email del usuario	Debes ser email válido del IPN
password_hash	TEXT	NOT NULL	Ninguno	Contraseña hashada con bcrypt	Nunca se almacena en texto plano
role	VARCHAR(20)	CHECK(IN)	investigador	Rol del usuario	Valores: admin, investigador, estudiante
is_verified	BOOLEAN	NOT NULL	FALSE	Indica si el email fue verificado	TRUE = verificado por OTP o admin
verification_code	VARCHAR(6)	NULLABLE	NULL	Código OTP de 6 dígitos	Expira en 5 minutos desde emisión
verification_code_created_at	TIMESTAMP	NULLABLE	NULL	Timestamp de emisión del OTP	Se usa para validar expiración

is_active	BOOLEAN	NOT NULL	TRUE	Indica si la cuenta está activa	FALSE = cuenta suspendida
full_name	VARCHAR(200)	NULLABLE	NULL	Nombre completo del usuario	Puede ser preferido o real
accepted_terms	BOOLEAN	NULLABLE	FALSE	Aceptación de términos y condiciones	
boleta	VARCHAR(20)	NULLABLE	NULL	Número de boleta (estudiante)	Solo para rol estudiante
carrera	VARCHAR(150)	NULLABLE	NULL	Nombre de carrera (estudiante)	Solo para rol estudiante
escuela	VARCHAR(100)	NULLABLE	NULL	Escuela o institución (estudiante)	Solo para rol estudiante
num_empleado	VARCHAR(20)	NULLABLE	NULL	Número de empleado (investigador)	Solo para rol investigador
area	VARCHAR(150)	NULLABLE	NULL	Área de investigación	Solo para rol investigador
centro	VARCHAR(100)	NULLABLE	NULL	Centro de investigación	Solo para rol investigador
created_at	TIMESTAMP	NOT NULL	CURRENT_TIMESTAMP	Fecha y hora de registro	

Tabla 14: Descripción de la tabla “users” (autoría propia)

Tabla “treatments”

Tabla de catálogo de tratamientos experimentales. Define los tipos de tratamientos que se pueden aplicar en los experimentos del modelo EPM.

Campo	Tipo de Dato	Restricciones	Valor Predeterminado	Descripción	Notas
id	SERIAL	PRIMARY KEY	Auto-incremental	Identificador único del tratamiento	
name	VARCHAR(100)	UNIQUE NOT NULL	Ninguno	Nombre del tratamiento	Ej: Placebo, Fármaco A, Control
description	TEXT	NULLABLE	NULL	Descripción detallada del tratamiento	Puede incluir dosis, tipo, propiedades
created_by	INTEGER	FOREIGN KEY	NULL	Usuario que creó el tratamiento	FK → users(id)
is_active	BOOLEAN	NOT NULL	TRUE	Indica si el tratamiento está activo	FALSE = archivado
created_at	TIMESTAMP	NOT NULL	CURRENT_TIMESTAMP	Fecha de creación del tratamiento	

Tabla 15: Descripción de la tabla “treatments” (autoría propia)

Tabla “experiments”

Tabla principal de registro de experimentos. Almacena la metadata de cada sesión de video experimental en el modelo EPM (Elevated Plus Maze).

Campo	Tipo de Dato	Restricciones	Valor Predeterminado	Descripción	Notas
id	SERIAL	PRIMARY KEY	Auto-incremental	Identificador único del experimento	
rat_id	VARCHAR(50)	NOT NULL	Ninguno	ID/Nombre del roedor/sujeto	Ej: R001, Rata-123
treatment	VARCHAR(50)	NOT NULL	Ninguno	Tipo de tratamiento o aplicado	Referencia a treatments.name
experiment_date	DATE	NULLABLE	NULL	Fecha del experimento	

responsible	VARCHAR(100)	NULLABLE	NULL	Nombre del investigador responsable	
video_path	TEXT	NOT NULL	Ninguno	Ruta del archivo de video	Ruta relativa o absoluta al video
duration_seconds	FLOAT	NULLABLE	NULL	Duración del video en segundos	Calculado automáticamente
created_by	INTEGER	FOREIGN KEY	NULL	Usuario que registró el experimento	FK → users(id)
processed	BOOLEAN	NOT NULL	NULL		TRUE = análisis completado
created_at	TIMESTAMP	NOT NULL	CURRENT_TIMESTAMP	Fecha de registro en la BD	

Tabla 16: Descripción de la tabla “experiments” (autoría propia)

Tabla “roi_configurations”

Tabla de configuración de regiones de interés (ROIs). Define los rectángulos/zonas del laberinto EPM (Brazos Abiertos, Cerrados, Centro) que se utilizan para análisis de comportamiento.

Campo	Tipo de Dato	Restricciones	Valor Predeterminado	Descripción	Notas
id	SERIAL	PRIMARY KEY	Auto-incremental	Identificador único de configuración	
experiment_id	INTEGER	FOREIGN KEY + CASCADE	Ninguno	Experimento asociado	FK → experiments(id), ON DELETE CASCADE
zone_type	VARCHAR(50)	NOT NULL	Ninguno	Tipo de zona en el EPM	Valores: Brazo Abierto, Brazo Cerrado, Centro

coordinates_json	JSONB	NOT NULL	Ninguno	Coordenadas en formato JSON	{x, y, w, h} - píxeles
scale_factor	FLOAT	NULLABLE	NULL	Factor de escala para conversión	Píxeles a cm/m

Tabla 17: Descripción de la tabla "roi_configurations" (autoría propia)

Tabla "analysis_results"

Tabla de resultados de análisis IA. Almacena todas las métricas comportamentales extraídas del análisis automático: distancia, tiempos por zona, conductas exploratorias, y métricas de ansiedad.

Campo	Tipo de Dato	Restricciones	Valor Predeterminado	Descripción	Notas
id	SERIAL	PRIMARY KEY	Auto-incremental	Identificador único de resultado	
experiment_id	INTEGER	FOREIGN KEY + CASCADE	Ninguno	Experimento analizado	FK → experiments(id), ON DELETE CASCADE
total_distance	FLOAT	NULLABLE	0.0	Distancia total recorrida (cm/m)	Calculado desde trayectoria
time_open_arms	FLOAT	NULLABLE	0.0	Tiempo en brazos abiertos (seg)	Métrica ansiedad (↓ ansiedad)
time_closed_arms	FLOAT	NULLABLE	0.0	Tiempo en brazos cerrados (seg)	Métrica ansiedad (↑ ansiedad)
time_center	FLOAT	NULLABLE	0.0	Tiempo en zona central (seg)	Comportamiento transitorio
head_dips-count	INTEGER	NULLABLE	0	Número de "head dips"	Conducta exploratoria riesgo
rearing_count	INTEGER	NULLABLE	0	Número de "rearing" (alzadas)	Conducta exploratoria vertical
grooming-duration	FLOAT	NULLABLE	0.0	Duración de	Conducta repetitiva estrés

				acicalamiento (seg)	
thigmotaxis_duration	FLOAT	NULLABLE	0.0	Duración adherencia a paredes (seg)	Métrica ansiedad (↑ ansiedad)
status	VARCHAR(20)	NOT NULL	pending	Estado del análisis	pending, processing, completed, error
timestamp	TIMESTAMP	NOT NULL	CURRENT_TIMESTAMP	Fecha de análisis	

Tabla 18: Descripción de la tabla “analysis_results” (autoría propia)

Tabla “security_audit_log”

Tabla de auditoría de seguridad. Registro completo de todos los eventos de autenticación, verificación y acceso para auditoría y cumplimiento normativo.

Campo	Tipo de Dato	Restricciones	Valor Predeterminado	Descripción	Notas
id	SERIAL	PRIMARY KEY	Auto-incremental	Identificador único del evento	
timestamp	TIMESTAMP	NOT NULL	CURRENT_TIMESTAMP	Fecha y hora del evento	Índice DESC para consultas rápidas
event_type	VARCHAR(50)	NOT NULL	Ninguno	Tipo de evento de seguridad	LOGIN_*, REGISTER_*, OTP_*, PASSWORD_*
username	VARCHAR(100)	NULLABLE	NULL	Usuario relacionado con evento	Email del usuario
ip_address	VARCHAR(50)	NULLABLE	NULL	IP del cliente	IPv4 o IPv6
success	BOOLEAN	NOT NULL	TRUE	Resultado del evento	TRUE = exitoso, FALSE = fallo
message	TEXT	NULLABLE	NULL	Mensaje descriptivo del evento	Detalles del evento
level	VARCHAR(10)	NOT NULL	INFO	Nivel de severidad	INFO, WARNING, ERROR

Tabla 19: Descripción de la tabla “security_audit_log” (autoría propia)

Consideraciones de Seguridad

- Passwords: Todas las contraseñas se hashean con bcrypt. Nunca se almacenan en texto plano.
- OTP: Códigos de 6 dígitos con expiración de 5 minutos desde emisión.
- Verificación IPN: Solo emails @ipn.mx (investigadores) o @alumno.ipn.mx (estudiantes) pueden registrarse.
- Auditoría: Todos los eventos de autenticación se registran en security_audit_log con timestamp e IP.
- Roles: Sistema de 3 roles (admin, investigador, estudiante) con acceso diferenciado.

5.3 Casos de uso

5.3.1 Casos de uso del prototipo

El diagrama representa el funcionamiento general del sistema, mostrando la interacción de cuatro actores principales: Estudiante, Investigador, Administrador y Sandino (superusuario), así como la participación de sistemas externos como el Motor de Análisis IA y la Base de Datos.

Los actores Estudiante e Investigador pueden iniciar sesión (CU1) y generar análisis (CU2), proceso que incluye obligatoriamente el procesamiento mediante el Motor de Análisis IA (CU7) y la consulta de reportes de análisis (CU3) como parte del flujo. Además, ambos actores pueden consultar reportes

de análisis (CU3), su historial personal (CU4) y realizar comparaciones (CU8). El Investigador cuenta adicionalmente con la capacidad de consultar el historial de estudiantes (CU5).

Por su parte, el Administrador únicamente puede iniciar sesión (CU1), consultar su historial (CU4) y gestionar cuentas (CU6), sin permisos para ejecutar análisis.

Finalmente, el actor Sandino (superusuario) posee acceso total al sistema, incluyendo todos los casos de uso anteriores, además del caso de uso especializado de acceso total (CU14), el cual extiende la gestión de cuentas (CU6) y permite interacción directa y auditable con la Base de Datos.




Ilustración 40: “Caso de uso del prototipo [autoría propia]”

5.3.2 Diagramas de secuencia

La ilustración 42 muestra el proceso de registro tanto de investigador como de administrador en la aplicación. Ambos pasan por el mismo proceso de registro con sus datos registrados y una vez todos los campos hayan sido completados y validados, se enviará un correo de confirmación al correo electrónico registrado.

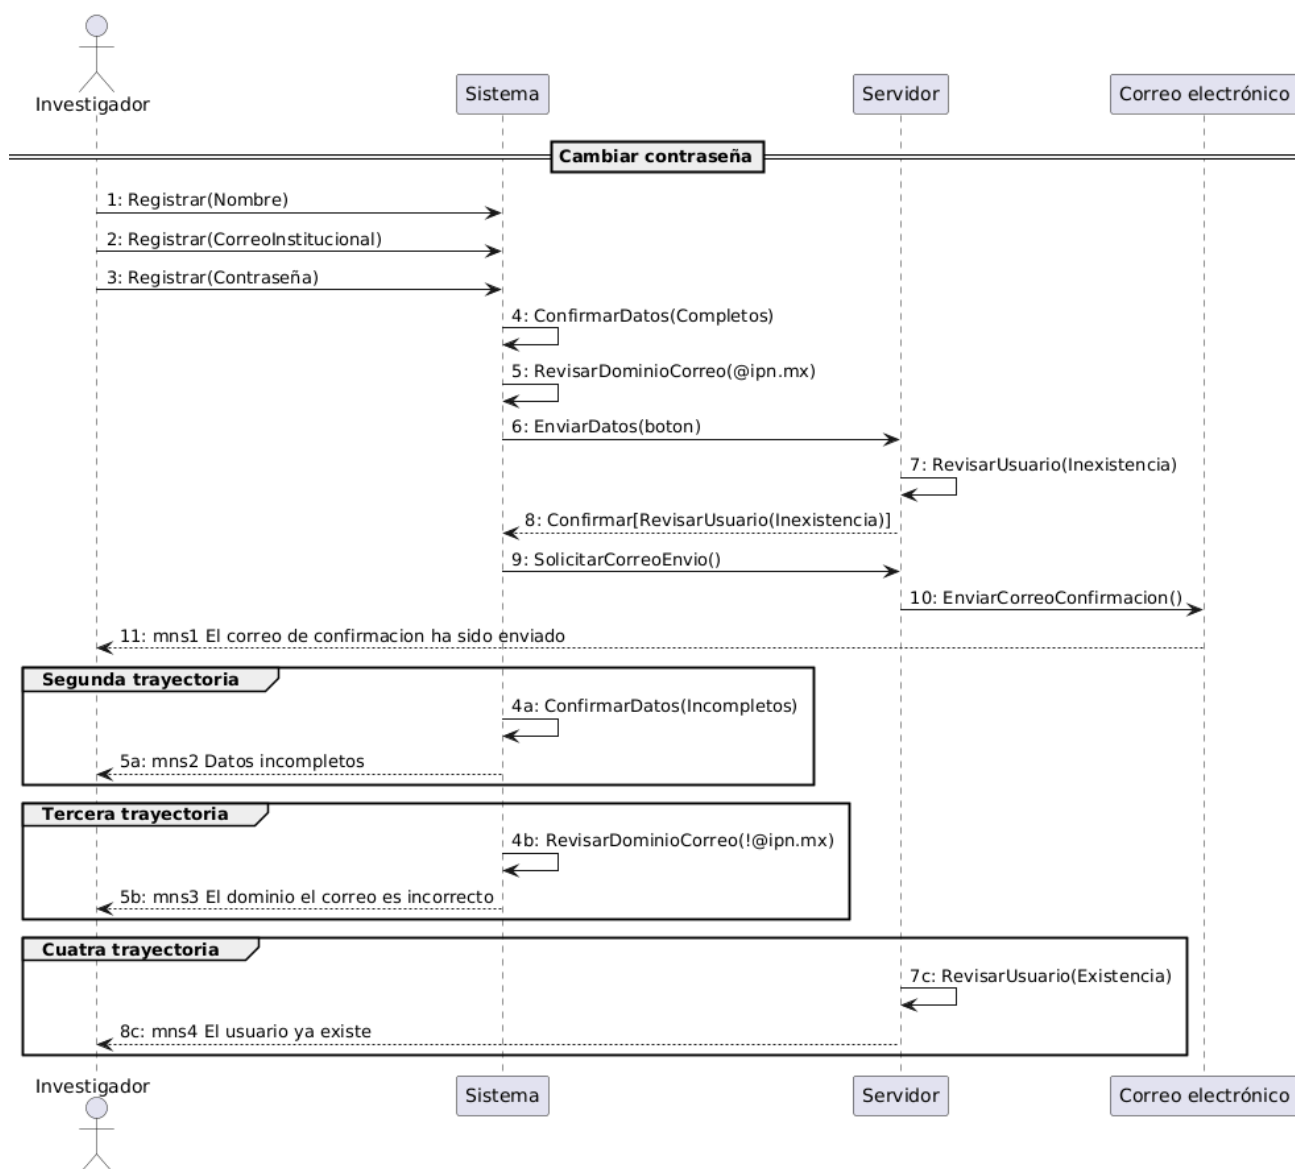


Ilustración 41: “Diagramas de secuencia [autoría propia]”

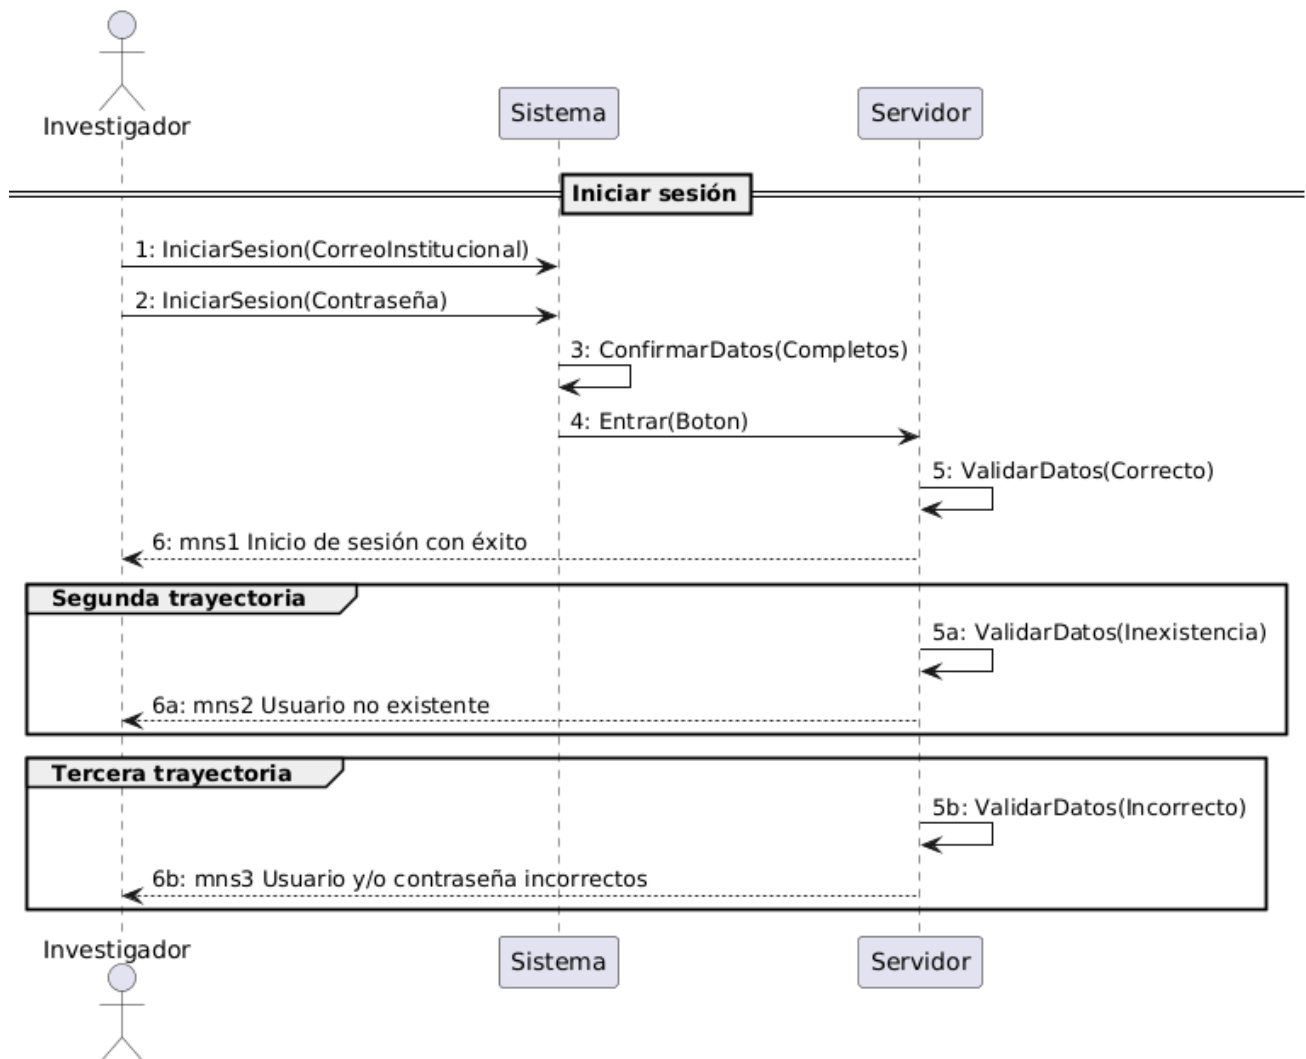


Ilustración 42: "Proceso de inicio de sesión del investigador [autoría propia]"

Las ilustraciones 43 y 44 muestran el proceso de inicio de sesión tanto para investigador y administrador. Incluso tomando en cuenta los casos de usuario no existente y datos incorrectos.




Ilustración 43: “Proceso de inicio de sesión del administrador [autoría propia]”

Las ilustraciones 45 y 46 muestran el cambio de contraseña para investigador y administrador. Se contempla el caso de usuario inexistente.

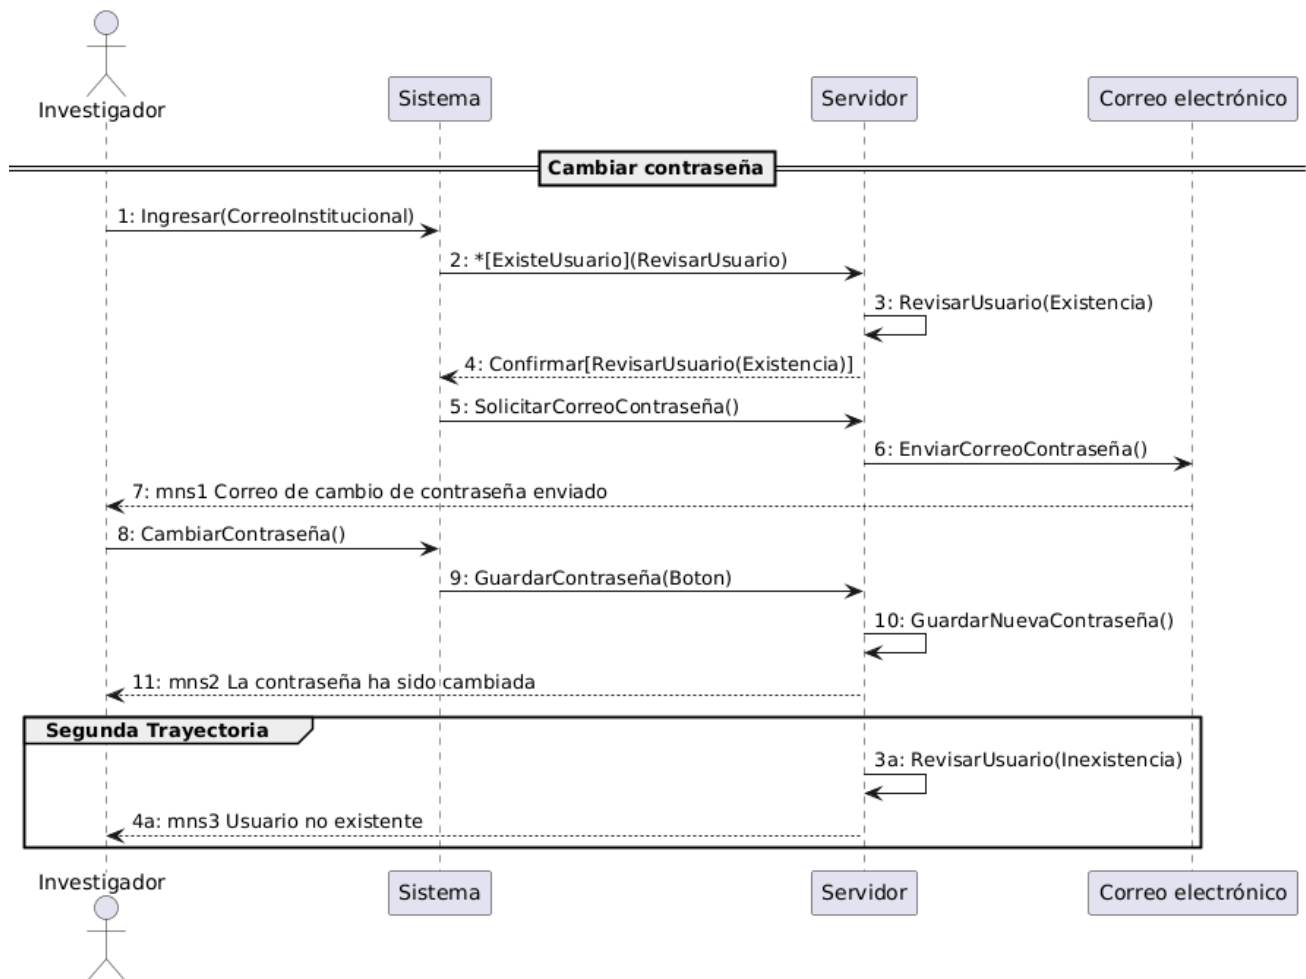


Ilustración 44: “Proceso de cambio de contraseña del investigador [autoría propia]”

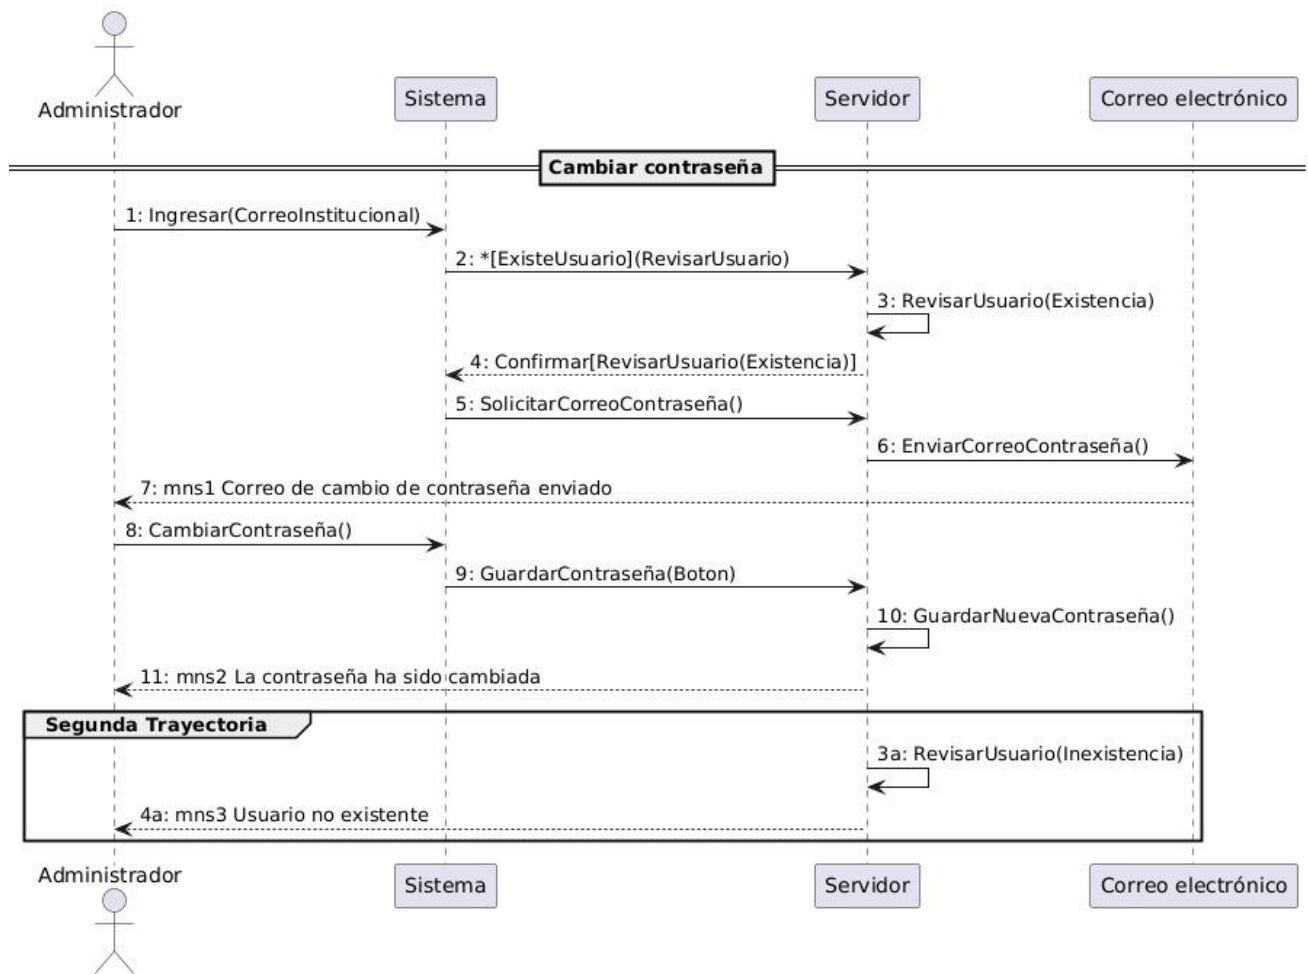


Ilustración 45: “Proceso de cambio de contraseña del administrador [autoría propia]”




Ilustración 46: “Manejo de usuarios [autoría propia]”

Las ilustraciones 48 y 49 muestra la configuración de perfil. Solo se muestra el cambio de nombre. El cambio de contraseña es en la pantalla principal.




Ilustración 47: Configuración de Perfil [autoría propia]




Ilustración 48: “Configurar Perfil Administrador [autoría propia]”

En las ilustraciones 50 y 51 se explica el proceso de cerrar sesión para investigador y administrador.




Ilustración 49: “Cerrar Sesión [autoría propia]”




Ilustración 50: “Cerrar sesión Administrador [autoría propia]”

En la ilustración 52, se representa el diagrama para ver notificaciones tanto para investigador y administrador. Sin embargo, el proceso de mandar notificaciones es exclusivo del administrador que puede mandar notificaciones generales o personalizadas a determinada cantidad de investigadores. El administrador escribe una notificación y, al mandarla, se confirma que la notificación no esté vacía. Si la notificación no está vacía, se pregunta al administrador si desea que la notificación sea general o personalizada. En caso de ser notificación general, se guarda la notificación en el servidor y el servidor manda la notificación a todos los investigadores e incluso el administrador. En caso de que la notificación sea personalizada, el prototipo pedirá al administrador que se elija al o a los investigadores a los que se desee enviar la notificación. Una vez el o los investigadores sean seleccionados, el prototipo mandará la notificación al servidor y el servidor la guardará. Al último, el prototipo muestra la notificación personalizada a los investigadores seleccionados previamente por el administrador.




Ilustración 51 “Prototipo de notificaciones [autoría propia]”

En las ilustraciones 53, 54 y 55, se representan los procesos de nuevo análisis, consultar reportes y consultar comparaciones. Si el investigador o administrador elijen hacer un nuevo análisis, se le pedirá que suban un vídeo en formato .mp4 o .mov, después se pedirá delimitar el tiempo y área, siendo los parámetros del mismo vídeo para un mejor análisis. Por último, se pedirá que se elija el tipo de experimento llevado a cabo (sin medicar, placebo, tratamiento).

Una vez se han establecido las bases, el módulo de preprocesamiento empieza a analizar del vídeo extrayendo tiempos de presencia en los brazos, tiempos de inmovilización, tiempos de eventos especiales, contadores de eventos especiales, entre otros. Una vez obtenida la información inicial, el módulo de modelado de conductas toma en cuenta los contadores de eventos especiales ocurridos en ambos brazos. Luego el módulo de análisis estadísticos toma todos los tiempos tomados en cualquier evento que haya ocurrido. Al último, el proceso de análisis termina y se envía un mensaje al usuario de que el evento ha terminado.

Desde ese punto, el investigador tiene la opción de ver los resultados del análisis ya sea los gráficos, datos estáticos, dashboard e incluso el reporte completo, mismo que puede descargar en formato PDF. Se le pregunta al investigador si desea guardar los datos analizados para futuras comparaciones, independientemente de la respuesta el usuario puede acceder al módulo de comparación para ver gráficos de comparaciones, consultar comparaciones o hacer una nueva comparación que pediría dos grupos de datos analizados y guardados para su posterior comparación. Después de elegir un tipo de análisis (test o ANOVA), el usuario puede ver el reporte completo o descargarlo en PDF.




Ilustración 52: “Procesos de generación de análisis [autoría propia]”

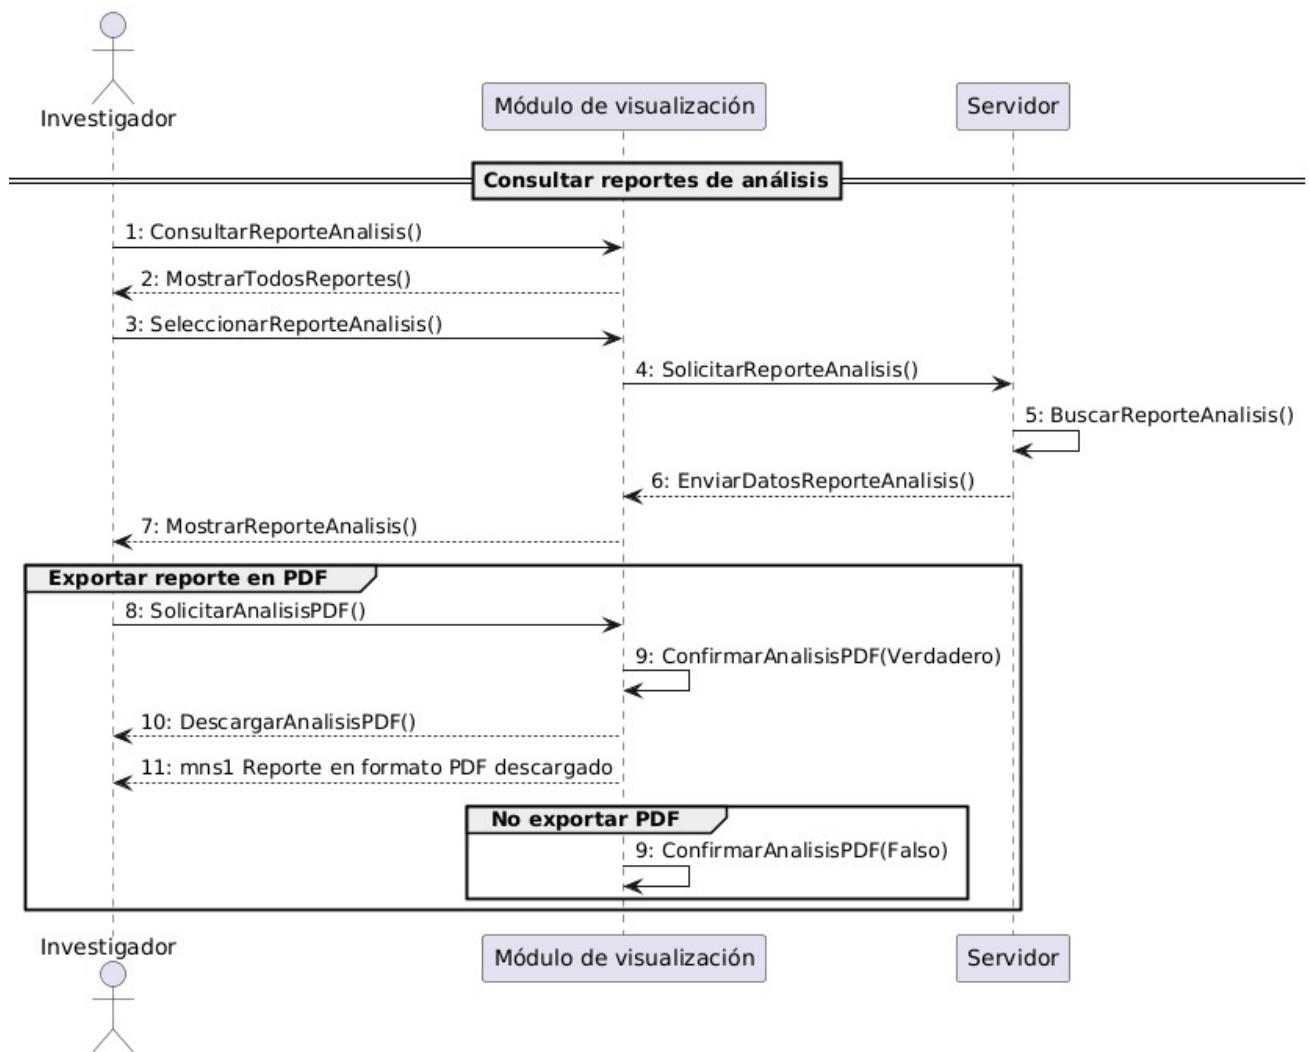


Ilustración 53: “Consulta de reportes de análisis [autoría propia]”




Ilustración 54: “Consulta y generación de comparaciones [autoría propia]”

5.3.3 Diagrama de clases

En la ilustración 56, se presenta el diagrama de clases que representa la estructura interna y funcional del prototipo, mostrando las clases principales, sus atributos, métodos y las interacciones entre ellas. La clase `Administrador` contiene los atributos `AdministradorID`, `Nombre`, `CorreoInstitucional` y `Contraseña`, y define operaciones como `Registrarse()`, `IniciarSesión()`, `CambiarContraseña()`, `ManejarUsuarios()` y `MandarNotificaciones()`, lo que le permite gestionar usuarios y enviar notificaciones dentro del prototipo. La clase `Usuario`, con atributos `UsuarioID`, `Nombre`,

CorreoInstitucional y Rol, incluye métodos como Registrarse (), IniciarSesión () y CambiarContraseña (), y se comunica con el prototipo para realizar análisis, comparaciones o consultar reportes. El Prototipo, asociado a los usuarios, posee operaciones como NuevoAnálisis (), ConsultarReportes (), ConfigurarComparaciones (), VerNotificaciones () y CerrarSesión (), gestionando así la interacción general entre módulos.

Existen clases de apoyo como Registro y Contraseña, que permiten registrar nuevos datos y realizar cambios de credenciales respectivamente. Las clases ManejaUsuarios y MandarNotificaciones representan las funcionalidades administrativas, donde la primera permite agregar, modificar o eliminar usuarios, mientras que la segunda gestiona el envío y registro de notificaciones generales o personalizadas.

El proceso de análisis está compuesto por varios módulos especializados. El MóduloPreprocesamiento gestiona datos de video mediante atributos como VideoID, TiempoVideo, ÁreaVideo y TipoExperimento, y métodos para confirmar el tipo de experimento, obtener contadores de presencia o eventos, y guardar datos iniciales. Estos datos se transfieren al MóduloModeladoConductas, encargado de registrar contadores de presencia y eventos y guardar los datos modelados. Posteriormente, el MóduloAnálisisEstadístico procesa estos resultados calculando tiempos generales y de eventos, generando estadísticas mediante métodos como ObtenerTiempoBAC () o GuardarDatosMAE ().

El flujo continúa con el MóduloVisualización, que permite observar los resultados analíticos y generar reportes o dashboards, y con el MóduloComparación, que posibilita comparar distintos análisis o experimentos, guardar resultados y exportarlos en formato PDF. Finalmente, el Servidor centraliza la comunicación entre los módulos y clases, almacenando los datos procesados y gestionando funciones como el envío de correos, revisión de contraseñas, guardado de reportes y confirmaciones de análisis o comparaciones.




Ilustración 55: “Diagrama de clases [autoría propia]”

Capítulo 6. Desarrollo

En este capítulo se documenta el proceso de **diseño y desarrollo del prototipo**, abarcando desde la definición de su estructura general hasta la elaboración de los elementos visuales y funcionales que lo componen.

6.1 Mockups del prototipo

6.1.1 Vista previa del inicio de sesión.

En la ilustración 57, representa el boceto hecho del inicio del prototipo. El investigador tiene la opción de ingresar sus datos, cambiar contraseña o registrarse.




The image shows a web browser window displaying a login interface. At the top, a teal banner contains the text: "PROTOTIPO PARA ANÁLISIS AUTOMATIZADO Y VISUALIZACIÓN DE COMPORTAMIENTO DE ESPECÍMENES EN MODELOS DE ANSIEDAD". Below this, a white login form is centered. The form has a title "INICIO DE SESIÓN". It includes two input fields: "Correo Electrónico" with the placeholder "tucorreo@ipn.mx" and "Contraseña" with the placeholder "Contraseña". A teal "Iniciar Sesión" button is positioned below the password field. At the bottom of the form, there are two links: "Registrarse" and "Cambiar Contraseña".

Ilustración 56: “Vista previa de inicio de sesión [autoría propia]”

6.1.2 Vista previa de registro.

En la ilustración 58 se muestra la pantalla del registro que pide al investigador dar su nombre completo, correo institucional y contraseña. Después de enviar los datos, el investigador recibirá un correo electrónico de confirmación.



The image shows a web browser window with a registration form. In the top left corner of the browser, there is a link that says "← Volver atrás". The form itself is centered and has a title "REGISTRO" in bold. Below the title, there are three input fields: "Nombre Completo" with the example text "Ej. Juan Andrés Pérez García", "Correo Electrónico" with the example text "tucorreo@ipn.mx", and "Contraseña" with the placeholder text "Contraseña". At the bottom of the form is a green button labeled "Enviar Datos".

Ilustración 57: “Vista previa del registro [autoría propia]”

6.1.3 Vista previa de cambio de contraseña.

En la ilustración 59, el investigador solo necesita ingresar su correo electrónico para recibir un correo de cambio de contraseña.



CAMBIAR CONTRASEÑA

Ingresa tu correo electrónico para recibir las instrucciones de recuperación.

Correo Electrónico

Solicitar correo de recuperación

Ilustración 58: “Cambiar contraseña [autoría propia]”

6.1.4 Vista previa de inicio del prototipo

En la ilustración 60, se ve la vista de investigador después de iniciar sesión. En un apartado, se muestran las diferentes opciones de realizar un nuevo análisis, consultar reportes y consultar comparaciones. En la parte superior derecha se encuentra la parte de configurar perfil, ver notificaciones y cerrar sesión.




Ilustración 59: “Vista previa del inicio del prototipo [autoría propia]”

Mientras tanto, la ilustración 61 muestra la vista de administrador con todas las funciones de la pantalla de inicio del prototipo para el usuario a excepción de dos botones extras en la parte superior derecha acerca de manejo de perfiles y mandar notificaciones.




Ilustración 60 “Vista previa del administrador [autoría propia]”

6.2 Pantallas del prototipo

6.2.1 Pantalla de bienvenida




Ilustración 62 “Vista de pantalla de bienvenida parte superior [autoría propia]”




Ilustración 63 “Vista de pantalla de bienvenida parte media [autoría propia]”

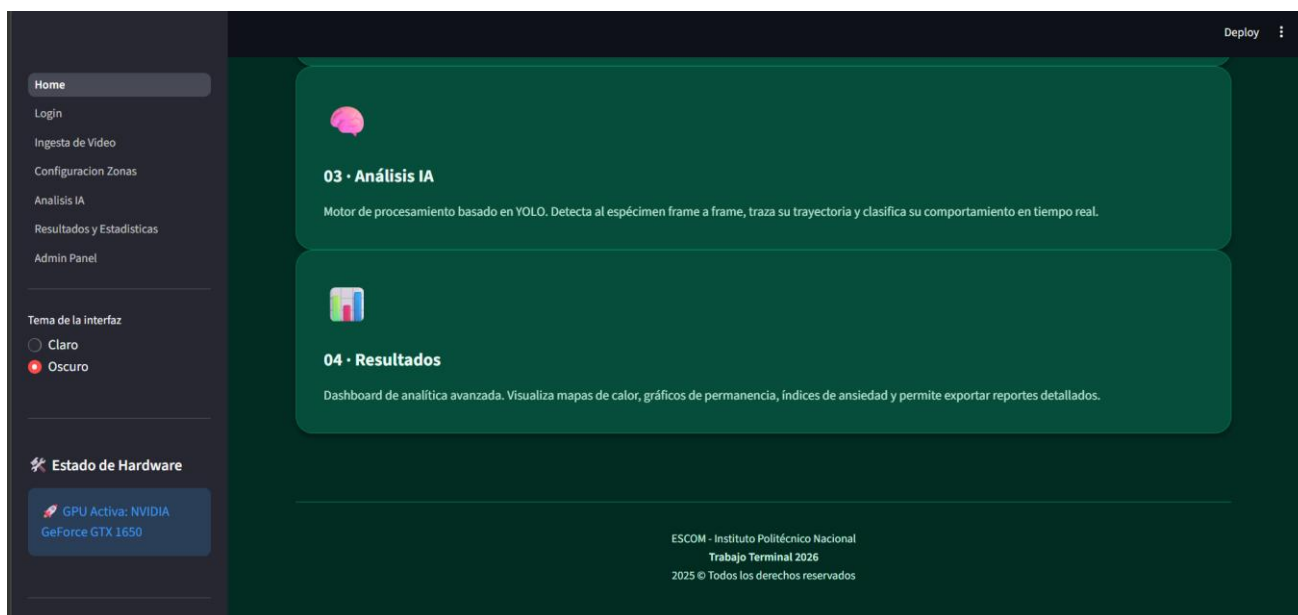


Ilustración 64 “Vista de pantalla de bienvenida parte inferior [autoría propia]

6.2.2 Pantalla de inicio de sesión




Ilustración 66 “Vista de pantalla de inicio de sesión (sesión iniciada) [autoría propia]

6.2.3 Pantalla de ingesta de video

Home
Login
Ingesta de Video
Configuración Zonas
Análisis IA
Resultados y Estadísticas
Admin Panel

Tema de la interfaz
☐ Claro
☒ Oscuro

Ingesta de Video Experimental
Carga el video del experimento en el laberinto en cruz elevado y selecciona el rango a analizar.

ID del Especimen: TEST-060326
Fecha del Experimento: 2026/03/06
ID del Tratamiento: test
Responsable: Equipo TT

Cargar Video (MP4 / MOV / AVI)
Drag and drop file here
Limit 4GB per file • MP4, MOV, AVI, MPEG4
Browse files
R5B20_01mar24.mp4 301.1MB
Cargar Video

Ilustración 67 “Vista de ingesta de video donde se ingresa la información [autoría propia]”

Home
Login
Ingesta de Video
Configuración Zonas
Análisis IA
Resultados y Estadísticas
Admin Panel

Tema de la interfaz
☐ Claro
☒ Oscuro

Edición del video: TEST-060326

Inicio (mm:ss): 01:30
Fin (mm:ss): 01:41

Video player showing a mouse in a blue cross-shaped maze.

Ilustración 68 “Vista de ingesta de video donde se ingresa la información [autoría propia]”

6.2.4 Pantalla de Configuración de Zonas




Ilustración 69 “Vista de configuración de zonas parte superior y añadir zonas [autoría propia]”




Ilustración 70 “Vista de ingesta de video y modificar zonas [autoría propia]”

6.3 Optimización de la infraestructura de cómputo y aceleración por hardware

Como respuesta directa a la alta demanda computacional detectada en las etapas iniciales del proyecto, donde el procesamiento basado exclusivamente en la unidad central de procesamiento (CPU) constituía un cuello de botella crítico para la viabilidad del sistema, se realizó una migración estratégica hacia arquitecturas de alto desempeño fundamentadas en el procesamiento gráfico. La integración de hardware dedicado, específicamente mediante el uso de la tarjeta NVIDIA RTX 5070 Ti, permitió una delegación matricial eficiente de las tareas de inferencia, logrando una reducción drástica en los tiempos de respuesta del pipeline integrado. Los resultados experimentales documentados demuestran

que el tiempo de procesamiento por iteración descendió de un promedio de 6.0 segundos en configuraciones convencionales a un rango operativo de 1.63 segundos bajo aceleración por GPU.

Este avance técnico se complementó con la implementación de métodos heurísticos aplicados sobre instrucciones de bajo nivel mediante el uso de `ptxas.exe`, lo que permitió que el sistema alcanzara una rapidez de extracción de rasgos de hasta 3.3 iteraciones por segundo. Esta capacidad operativa resulta fundamental para satisfacer la demanda de procesamiento por lotes masivo que requiere la investigación científica biomédica moderna, asegurando que el flujo de trabajo no se vea interrumpido por limitaciones de hardware. La segregación de entornos virtualizados bajo Python 3.10.11, con soporte nativo para CUDA 11.x, garantizó la estabilidad del motor de inferencia al separar la lógica de la interfaz gráfica de los procesos intensivos de visión artificial. Esta arquitectura permitió que librerías críticas como TensorFlow 2.10.0 y PyTorch 2.7.1 operaran con la máxima eficiencia de memoria VRAM disponible durante el análisis de secuencias de video extensas.

La robustez de la infraestructura seleccionada permitió además sostener ciclos de entrenamiento masivo de larga duración, algunos de los cuales superaron las 36 horas de ejecución continua sin presentar degradación en el rendimiento del motor YOLOv11. Esta configuración de hardware asegura que el ciclo de desarrollo en espiral de Boehm mantenga una progresión verificable y escalable, alineándose con los requerimientos de fiabilidad RNF-03 y los estándares de seguridad institucional. Para el entrenamiento específico del modelo de detección, se empleó una estación equipada con una GPU NVIDIA GeForce RTX 5060 de 8 GB, optimizada para tareas de detección "píxel por píxel". Este nodo de trabajo permitió procesar datasets de gran escala, incluyendo el entrenamiento final que integró la totalidad de los videos del repositorio institucional. Finalmente, la disposición de múltiples estaciones de trabajo asegura que el desarrollo mantenga una progresión constante sin interrupciones técnicas, facilitando ciclos cortos de retroalimentación.

6.3.1 Análisis crítico de la resolución espacial e integridad de datos etológicos

En el marco de la verificación del cumplimiento de la Regla de Negocio RN3, se ejecutaron protocolos de pruebas de estrés para validar el impacto de la resolución de video en la fiabilidad de las métricas obtenidas. El equipo planteó originalmente la hipótesis de que una reducción en la resolución espacial podría optimizar los tiempos de inferencia sin comprometer la calidad del dato; sin embargo, los hallazgos demostraron que la integridad de los resultados se ve comprometida de manera irreversible bajo configuraciones de bajo muestreo. Mediante el análisis comparativo del clip experimental R5B20, se determinó que el procesamiento en una resolución nativa de 720p (1280x720) es un recurso técnico no negociable para la robustez del sistema de análisis de posturas.

La experimentación reveló que el submuestreo de la imagen al 50% (640x360) induce un fenómeno técnico de jitter de coordenadas o inestabilidad espacial, el cual desvirtúa el seguimiento preciso de los puntos anatómicos del espécimen. Este ruido en la trayectoria es interpretado erróneamente por los clasificadores de Random Forest de SimBA, lo que conduce a diagnósticos conductuales equivocados. La gravedad de esta pérdida de integridad se evidenció al observar que la tasa de detección de conductas de acicalamiento (grooming) se elevó de un valor real de 0.8% a un 9.1% artificial debido a la vibración de las coordenadas ruidosas. En consecuencia, el sistema generó una cantidad masiva de falsos positivos (848 cuadros erróneos) que invalidaron estadísticamente la sesión de prueba.

Para mitigar el riesgo de inconsistencia, se estableció que el sistema debe operar exclusivamente bajo el estándar de 720p, lo que asegura que cada etograma mantenga una concordancia superior al 95% con las observaciones manuales. El análisis del jitter también reveló que la pérdida de detalle espacial afecta la estimación de postura en DeepLabCut, resultando en detecciones inestables cuando el animal se desplaza hacia zonas de bajo contraste. Asimismo, se detectó que el uso de umbrales de activación restrictivos (0.50 por defecto) en resoluciones nativas podía anular la detección de conductas sutiles como la tigmotaxis. Fue necesario realizar un descenso analítico del umbral a 0.35 para capturar incidentes válidos, lo que subraya la necesidad de un equilibrio preciso entre la calidad del video y la configuración del clasificador.

Se determinó que el sacrificio de resolución invalida la precisión del modelo etológico, por lo que la optimización de velocidad debe buscarse estrictamente a través de la potencia del hardware y no mediante la degradación del material visual. El sistema ahora garantiza que las trayectorias de los puntos anatómicos sean estables, permitiendo un conteo milimétrico de los tiempos de permanencia en brazos abiertos y cerrados. Este rigor en la integridad de los datos es lo que permite que el prototipo sea considerado una herramienta operativa fiable para la ciencia biomédica. Esta decisión técnica asegura el cumplimiento de la RN2 sobre validaciones automáticas de integridad y consistencia del tratamiento.

6.3.2 Evolución de los modelos de IA y entrenamiento de alta fidelidad

La consolidación del motor de detección y seguimiento transitó por un proceso de refinamiento cualitativo que permitió superar el sobreajuste ambiental (overfitting) detectado en las fases iniciales del desarrollo. Inicialmente, el entrenamiento con un dataset reducido de 600 imágenes mostró inconstancia ante variaciones lumínicas, fallando especialmente en el tránsito de cajas oscuras a laberintos azules. El equipo reaccionó escalando el volumen de datos a 1,200 etiquetas en un ciclo de 36 horas, pero los resultados en pruebas a ciegas continuaron reportando sensibilidades inaceptables ante distractores visuales externos. Durante estas pruebas, se observó que el sistema presentaba una tasa de "no detección" de hasta el 91% en ciertos escenarios críticos.

El análisis detallado permitió identificar que el modelo confundía al personal de laboratorio con el espécimen, un error que inflaba artificialmente los falsos positivos y generaba micro-detecciones erráticas. El avance cualitativo definitivo se alcanzó con el desarrollo de la tercera versión del modelo (V3), fundamentado en un dataset especializado de 2,265 imágenes anotadas con alta precisión. Este conjunto de datos fue diseñado específicamente para neutralizar el fenómeno de domain shift provocado por el contraste del pelaje albino de los roedores sobre los fondos claros y superficies reflectantes del laboratorio. Gracias a esta especialización cualitativa del dato, el modelo YOLOv11 V3 logró una robustez sin precedentes, eliminando la confusión con sombras y garantizando una trayectoria de rastreo limpia.

Las métricas de desempeño obtenidas tras este entrenamiento consolidado reflejan la madurez técnica del sistema, reportando una Precisión del 99.5%, una Sensibilidad (Recall) del 98.7% y un mAP50 del 99.4%. Estos valores confirman que el prototipo ha superado la fase de inestabilidad, permitiendo la identificación ininterrumpida del espécimen incluso durante desplazamientos veloces o cambios bruscos de orientación postural. Al cierre de este informe, se mantiene un proceso de mejora continua con un entrenamiento adicional que utiliza 453 imágenes, acumulando más de 18 horas de ejecución

continúa para validar subconjuntos de datos específicos. Esta metodología de reentrenamiento híbrido asegura que el motor de IA se mantenga resiliente frente a variaciones ambientales a largo plazo.

El éxito del modelo V3 también radica en la aplicación de una configuración de análisis exhaustivo, procesando la información visual con un alto grado de detalle espacial. El robustecimiento del modelo permitió cumplir finalmente con el requerimiento de efectividad proyectado, posicionando al detector como el pilar central del análisis automatizado. La eliminación de errores sistemáticos asegura que los informes exportados sean veraces y comparables entre diferentes grupos experimentales, como los tratados con diazepam o placebo. El modelo YOLOv11 V3 se consolida así como la versión operativa definitiva del prototipo.

6.3.3 Refinamiento de la arquitectura modular y continuidad temporal

Para asegurar la estabilidad temporal de las predicciones etológicas y erradicar el problema de las micro-detecciones erróneas o parpadeos (flickering), se formalizó una división estricta de tareas técnicas dentro del ecosistema del software. El refinamiento del script principal, `generar_video_prediccion.py`, permitió establecer una arquitectura donde cada componente de IA se especializa en un dominio de datos único, evitando la propagación de ruidos espaciales entre las distintas fases del análisis. Bajo esta nueva configuración modular, YOLOv11 asume la responsabilidad exclusiva del rastreo visual —representado gráficamente por un Punto Rojo dinámico— y del conteo automatizado de los tiempos de permanencia por brazo.

Por otro lado, la herramienta DeepLabCut (DLC) se dedica estrictamente a la estimación de postura (pose estimation) de las extremidades y la nariz, mientras que SimBA ejecuta la clasificación final de comportamientos patológicos como la tigmotaxis. Esta segregación funcional asegura que el jitter de coordenadas no contamine las series temporales de conducta, cumpliendo con los estándares de calidad del sistema. La importancia de esta estructura se validó tras diagnosticar que las micro-detecciones de apenas ~0.2 segundos observadas en etapas previas eran producto de una inestabilidad en el umbral de probabilidad de la red CNN-LSTM. Al estabilizar la entrada de coordenadas mediante el nuevo rastreador V3 y ajustar el umbral de probabilidad RN4 a un valor estable de ≥ 0.6 , el sistema logró mantener clasificaciones coherentes que respetan la duración biológica real de las conductas de ansiedad.

Esta modularidad también responde a los requerimientos no funcionales de mantenibilidad (RNF-06) y trazabilidad (RNF-08), permitiendo actualizaciones independientes sin afectar la integridad del flujo de trabajo. El refinamiento arquitectónico eliminó el fenómeno del parpadeo que invalidaba el análisis etológico al cortar abruptamente las predicciones mientras la conducta aún persistía. Al asegurar trayectorias limpias, el clasificador puede ahora distinguir con precisión entre movimientos rítmicos genuinos y simples vibraciones técnicas de las coordenadas. Finalmente, la arquitectura consolidada garantiza que el ruido espacial no se propague entre cuadros independientes, dejando el sistema preparado para el procesamiento por lotes masivo de la videoteca de tesis.

Cada modificación en el pipeline se ha registrado en el repositorio de GitHub con descripciones claras de los requerimientos que satisfacen, asegurando una auditoría documental completa. El uso de campos de texto de alta precisión para delimitar el tiempo de análisis sustituyó a los controles deslizantes previos, mejorando la usabilidad técnica del sistema. Esta evolución hacia una arquitectura de división

de tareas es el pilar que garantiza la entrega de estadísticas precisas y replicables exigidas por el Comité de Evaluación.

6.3.4 Herramientas de usabilidad y visualización HUD avanzada

En cumplimiento con el requerimiento de usabilidad RNF-02, se integraron módulos de interacción avanzada que otorgan al investigador un control milimétrico sobre el proceso analítico sin requerir conocimientos informáticos profundos. Uno de los hitos principales fue la creación de un Selector de ROIs Interactivo, el cual permite delimitar manualmente los rectángulos exactos de los brazos Norte, Sur, Este, Oeste y Centro al inicio de cada análisis. Esta función otorga adaptabilidad total ante cambios accidentales en la perspectiva de la cámara, asegurando un conteo de segundos milimétrico y ofreciendo opciones de corrección dinámica (Undo) durante la selección.

El sistema de visualización, denominado Head-Up Display (HUD), fue rediseñado bajo criterios de rigor científico para maximizar la legibilidad de la información en tiempo real. Se implementó un esquema de Split HUD con una opacidad del 90%, donde la información de comportamientos se ubica en la parte superior derecha y el cronómetro acumulado por zonas se despliega en la parte inferior derecha. Esta disposición permite supervisar la validez del análisis sin que los elementos gráficos obstruyan la visibilidad del espécimen, facilitando la validación visual inmediata mediante un sistema de punto dinámico que cambia de color según la zona ocupada. El punto adquiere tonalidades Coral para brazos abiertos, Cyan para cerrados y Naranja para el centro, permitiendo al usuario confirmar el estado del análisis con un solo vistazo.

Además de estas mejoras visuales, la interfaz de usuario se fortaleció con la sustitución de controles deslizantes imprecisos por campos de entrada de texto que permiten especificar el segundo exacto (mm:ss) para iniciar el registro automatizado. Esta funcionalidad satisface la necesidad crítica de omitir los instantes iniciales de estabilización del animal o de retiro del operario humano del campo visual. Asimismo, el Commit 1bc3ba5 introdujo la capacidad de transformar ROIs moviendo sus esquinas libremente sin necesidad de recargar el sistema completo, optimizando significativamente la experiencia de usuario. Estas herramientas transforman al prototipo en una plataforma profesional, intuitiva y ajustada a las demandas reales del entorno de investigación farmacológica.

La gestión de datos se optimizó mediante un selector de tratamientos con persistencia de sesión, el cual utiliza sugerencias históricas de la base de datos para evitar la creación de registros duplicados en la tabla experiments. Esta actualización garantiza que cada análisis esté vinculado correctamente a sus metadatos (fecha, tratamiento, espécimen), cumpliendo con la regla de negocio RN6 sobre trazabilidad. Finalmente, la exportación estructurada en formatos Excel y PDF habilita la ejecución de pruebas estadísticas avanzadas como ANOVA y T-Test requeridas para la validación científica final.

6.3.5 Validación de escenario ciego y gestión de factores de riesgo

La capacidad de generalización del sistema se verificó mediante la ejecución de una "prueba a ciegas" sobre el clip experimental DZP-R1_THIGMO_TEST_CIEGO, exponiendo al modelo a un escenario inédito bajo tratamiento con diazepam. El prototipo logró identificar satisfactoriamente un acumulado de tigmotaxis de 6.1 segundos, representando un 1.6% de la sesión total al minuto 06:10. No obstante, este test sirvió para detectar un riesgo crítico relacionado con la interferencia visual humana en el

cuadro de grabación, identificando que la presencia física del investigador genera ruidos espaciales que confunden al detector YOLOv11.

Este error de identificación, que dispara falsos positivos y provoca parpadeos en el clasificador al intentar extraer puntos anatómicos en objetos no deseados, subrayó la importancia imperativa de cumplir con la Regla de Negocio RN11. Se concluyó que es fundamental recortar o seleccionar el video en secciones donde el personal de laboratorio no sea visible para alcanzar el estándar de concordancia $\kappa \geq 0.8$ exigido científicamente. El diagnóstico de la prueba ciego también permitió identificar una falla de continuidad temporal, donde el clasificador "parpadeó" en 4 eventos de apenas ~ 0.2 segundos debido a la inestabilidad de la trayectoria ante ruidos visuales. Estos hallazgos motivaron el posterior entrenamiento masivo del modelo V3 para estabilizar el umbral de probabilidad y garantizar una trayectoria limpia.

Para mitigar los riesgos de saturación por datos de baja calidad (R09) y sobreajuste (R11), el equipo implementó técnicas de regularización y una depuración cualitativa del dataset. El hito de las 2,265 imágenes anotadas resolvió con éxito el riesgo de datos no representativos que afectó las pruebas iniciales. Al cierre de este ciclo, se registra un entrenamiento de validación adicional en curso que acumula más de 18 horas de ejecución continua utilizando 453 imágenes para sub-análisis específicos. Este esfuerzo asegura que el prototipo no solo sea robusto frente a las condiciones actuales, sino que mantenga su precisión frente a nuevas variaciones ambientales, posicionándose en un estado operativo definitivo y estable.

Tras solventar estas contingencias y verificar la integridad de las trayectorias mediante el HUD dinámico, el prototipo se considera preparado para el procesamiento masivo de la videoteca de tesis. La eliminación definitiva del ruido espacial permite que el equipo proceda con la exportación estructurada de datos para realizar las pruebas estadísticas requeridas para la validación final del Trabajo Terminal. El sistema representa hoy una solución sólida y verificada para la interpretación automatizada de conductas de ansiedad en modelos animales, cumpliendo con los objetivos generales planteados en la propuesta original.

6.4 Validación experimental y refinamiento de la estimación de postura

El desarrollo alcanzado durante el ciclo de trabajo actual se ha consolidado mediante la validación operativa del sistema en escenarios reales, tomando como referencia los resultados en una prueba que se hizo la mañana con fecha del 13 de marzo de 2026. Este informe registra un análisis exhaustivo de una sesión experimental con una duración total de 933.1 segundos, donde el prototipo logró extraer de forma autónoma indicadores clave de desempeño (KPIs) de alta relevancia científica. Los datos arrojaron una permanencia de 316.4 segundos (33.9%) en los brazos abiertos del laberinto, frente a 477.6 segundos en los brazos cerrados, registrando un total de 11 entradas o transiciones, lo que permitió al sistema concluir que el espécimen mostraba una alta exploración indicativa de un posible efecto ansiolítico.

La madurez del módulo de visualización se evidencia en la capacidad de generar de forma automática etogramas temporales de posición, gráficas de preferencia de zona mediante diagramas de dona y mapas de calor (heatmaps*) de mayor permanencia. Estas herramientas permiten una síntesis de datos espaciales y temporales que satisface las necesidades de interpretación objetiva planteadas

originalmente por los investigadores de la Escuela Nacional de Medicina y Homeopatía (ENMyH), cumpliendo con el objetivo de reducir el margen de error humano y la subjetividad en la observación manual. La precisión en la delimitación de las áreas de interés (ROI) ha permitido que estas métricas sean trazables y coherentes con el comportamiento observado en los videos experimentales.

En paralelo a la validación de resultados, el equipo se encuentra actualmente ejecutando el etiquetado manual de un nuevo dataset especializado de 311 imágenes para fortalecer el motor de Pose Estimation. Este proceso requiere una intervención técnica detallada en la que, por cada cuadro, se definen y localizan ocho puntos anatómicos específicos del ratón: nariz, oreja izquierda, oreja derecha, pata izquierda, pata derecha, torso, base de la cola y punta de la cola. El propósito de esta tarea es generar un conjunto de datos de entrenamiento robusto que permita a la red neuronal profunda (DeepLabCut) identificar con precisión milimétrica la orientación y los movimientos finos del animal, incluso ante variaciones de iluminación o cambios de postura abruptos.




Ilustración 70 “Interfaz de RoboFlow, etiquetado de las partes del ratón [autoría propia]”

La integración de estas nuevas imágenes anotadas busca mitigar definitivamente los riesgos de sobreajuste ambiental (overfitting) que fueron diagnosticados en versiones previas del modelo, donde la red presentaba inconstancia al cambiar de escenarios controlados a entornos experimentales novedosos. Al proporcionar coordenadas precisas de extremidades y puntos clave de la cola, el sistema podrá realizar análisis cinemáticos y biomecánicos más avanzados, lo cual es fundamental para distinguir conductas sutiles como el acicalamiento o la evaluación de riesgo (stretch-attend posture) que requieren una resolución temporal y espacial superior. Este entrenamiento es una pieza clave para asegurar que el sistema no pierda la trayectoria del espécimen y mantenga la estabilidad del rastreador en los brazos cerrados del laberinto.

Asimismo, durante la mañana del 13 de marzo de 2026, se llevó a cabo una reunión de validación presencial con el Dr. César Augusto Sandino, en la cual se realizaron múltiples pruebas pequeñas en tiempo real para demostrar el funcionamiento actual del sistema. Estos ensayos permitieron contrastar las capacidades del prototipo frente a las expectativas del investigador, validando funciones críticas como la selección interactiva de zonas (ROI), el ajuste manual del segundo exacto de inicio del análisis

y la fluidez de la interfaz tipo dashboard. La retroalimentación obtenida confirma que, aunque aún se deben hacer ajustes y realizar el manual de usuario, el sistema es intuitivo y satisface los requerimientos de usabilidad para personal sin formación técnica avanzada en computación.

Finalmente, el éxito de estas demostraciones y la solidez de los reportes generados posicionan al prototipo en un estado operativo definitivo, listo para el procesamiento masivo de la videoteca experimental. La combinación de una detección visual estabilizada mediante YOLOv11 V3 y el inminente reentrenamiento del modelo de postura con las 365 imágenes adicionales asegura que el producto final cumpla con el estándar de concordancia del 90% al 95% solicitado por el laboratorio. Con este avance, el proyecto se encamina hacia la exportación estructurada de datos para el análisis estadístico final, garantizando una herramienta de alta precisión para la validación de tratamientos farmacológicos.

6.5 Refinamiento del pipeline de inferencia, integración de SimBA y optimización de la trazabilidad conductual

El desarrollo tecnológico del sistema ha alcanzado un hito crítico con la consolidación funcional del pipeline de inferencia, logrando la integración fluida entre los módulos de detección, estimación de postura y clasificación conductual. A través del Commit c33446e, se implementaron mejoras sustanciales en el flujo de trabajo de SimBA, destacando la eliminación definitiva del submuestreo o downscaling en el procesamiento de DeepLabCut (DLC). Esta decisión técnica responde a los hallazgos de las pruebas de estrés previas, las cuales demostraron que el sacrificio de resolución inducía un jitter de coordenadas irrecuperable que invalidaba la precisión del modelo etológico. Al operar bajo esta nueva configuración, el sistema garantiza el cumplimiento de la norma RN3, procesando los fotogramas en su resolución nativa de 720p para preservar la integridad de los metadatos espaciales.

Para fortalecer la robustez del rastreo anatómico, el Commit 917b66d introdujo una restricción algorítmica que vincula las cajas delimitadoras (bounding boxes) de YOLO con los puntos clave (keypoints) de DLC. Esta optimización asegura que las inferencias de postura se mantengan dentro de los límites espaciales del espécimen detectado, mitigando significativamente la generación de falsos positivos y errores de triangulación en zonas de bajo contraste. Asimismo, se ha validado la implementación de filtros avanzados sobre los keypoints procesados, lo que permite obtener trayectorias dinámicas más limpias y coherentes con la biomecánica real del roedor. Estos avances permiten que el sistema realice un seguimiento ininterrumpido incluso en los brazos cerrados del laberinto, donde las oclusiones solían degradar el rendimiento del modelo.

En el ámbito de la clasificación supervisada, se han ejecutado pruebas de video utilizando algoritmos de Random Forest entrenados para identificar patrones complejos de conducta. Un avance fundamental en esta fase ha sido la finalización del etiquetado manual para las categorías de acicalamiento (grooming) y contacto con la pared, expandiendo la biblioteca de predicción híbrida del prototipo. Aunque los resultados en videos de "prueba a ciegas" (escenarios inéditos) aún presentan áreas de oportunidad en términos de generalización, el uso de muestras anotadas de diversos entornos experimentales está permitiendo estabilizar el umbral de probabilidad para evitar las micro-detecciones o "parpadeos" del clasificador.

La trazabilidad y gestión del proyecto se han visto fortalecidas mediante el Commit 7ea46b6, el cual actualizó de forma integral el pipeline de análisis, la documentación técnica y la integración con SimBA. Como parte de este esfuerzo de estandarización, se realizaron correcciones exhaustivas en los diagramas de casos de uso para asegurar que la documentación refleje con precisión la arquitectura funcional y lógica del software actual. Estas modificaciones garantizan que los procesos de inicio de sesión, configuración de zonas (ROI) y generación de reportes coincidan estrictamente con la interfaz interactiva desplegada para los investigadores.

Finalmente, la efectividad del sistema para la toma de decisiones farmacológicas se ha verificado mediante la generación de reportes estructurados que extraen indicadores clave de desempeño (KPIs). Los análisis recientes, como el documentado en el reporte 1304.pdf, muestran una capacidad superior para cuantificar tiempos de permanencia y transiciones entre zonas, entregando resultados con un nivel de concordancia que se aproxima al estándar solicitado por los expertos. El sistema se encuentra ahora en una fase de optimización final, donde el refinamiento de los clasificadores supervisados permitirá alcanzar la estabilidad operativa necesaria para el procesamiento masivo de la videoteca experimental de la tesis.

6.6 Optimización de la arquitectura de software, estandarización de identidad institucional y refinamiento del flujo de datos

Dentro de la progresión cíclica de la metodología espiral de Boehm, la presente fase de desarrollo se ha centrado en alcanzar la madurez operativa necesaria para la portabilidad del sistema entre diversas plataformas de hardware. Este hito técnico ha priorizado la transición desde un entorno de desarrollo rígido hacia una arquitectura de configuración centralizada, eliminando sistemáticamente el uso de rutas absolutas en el código fuente. Dicha refactorización asegura que el prototipo pueda ser desplegado e iniciado en cualquier estación de trabajo del Instituto Politécnico Nacional sin requerir reconfiguraciones manuales de los directorios de archivos, cumpliendo así con los estándares de mantenibilidad y modularidad definidos en el requerimiento RNF-06.

El robustecimiento del núcleo del sistema incluyó una corrección crítica en el módulo `full_pipeline` mediante la implementación estratégica de la instrucción `sys.path.insert`. Esta modificación técnica permite que el pipeline de análisis sea ejecutado como un script aislado, garantizando que el intérprete de Python localice correctamente los módulos internos de visión artificial y minería de datos independientemente del punto de ejecución. Esta mejora en la lógica de importación resuelve problemas de resolución de dependencias detectados en iteraciones previas, facilitando la integración de nuevas funcionalidades de aprendizaje profundo sin comprometer la estabilidad de los procesos de inferencia ya verificados.

En el ámbito de la integridad de los metadatos etológicos, se desarrolló una funcionalidad de Auto-Padding para los frames contenidos en los archivos CSV exportados desde DeepLabCut. Esta solución técnica previene las advertencias (warnings) recurrentes de SimBA relacionadas con la discrepancia en el conteo de cuadros, asegurando que la serie temporal de coordenadas coincida milimétricamente con la duración del video original. Al garantizar que el clasificador reciba secuencias de datos completas y alineadas, se fortalece la validez estadística de los etogramas generados, eliminando sesgos temporales que podrían afectar la interpretación de conductas patológicas como la tigmotaxis o el acicalamiento.

Como parte del esfuerzo continuo de enriquecimiento de los modelos de inteligencia artificial, el equipo de ingeniería ha mantenido una actividad intensiva de etiquetado manual a través de la plataforma RoboFlow. En este ciclo, se ha priorizado la anotación precisa de los puntos clave (keypoints) de los especímenes, capturando la variabilidad postural en diferentes cuadrantes del Laberinto en Cruz Elevada (EPM). Estas nuevas muestras etiquetadas alimentarán los procesos de reentrenamiento híbrido del modelo YOLOv11 V3 y del módulo de estimación de postura, incrementando la resiliencia del rastreador ante oclusiones y variaciones lumínicas críticas en el entorno de laboratorio.

Paralelamente a las mejoras funcionales, se realizó un rediseño integral de la identidad visual del prototipo para alinearla con los valores y la estética del Instituto Politécnico Nacional. La nueva interfaz interactiva incorpora ahora una colorimetría y simbología concordantes con el manual de identidad institucional, utilizando tonos guinda y blanco que refuerzan el carácter oficial del sistema en entornos académicos. Este rediseño no es meramente estético, sino que mejora la experiencia de usuario (RNF-02) al emplear una paleta de colores de alto contraste que facilita la lectura de los indicadores clave de ansiedad y las trayectorias dinámicas en las pantallas de visualización HUD.

La consolidación de estos avances permite que el prototipo no solo sea una herramienta de alta precisión técnica, sino también un software profesional listo para su validación ante el Comité de Evaluación del Trabajo Terminal. La eliminación de errores de ruta y la implementación del padding automático de frames posicionan al pipeline de análisis en un estado de "Producción Listo", minimizando los riesgos de falla operativa durante el procesamiento masivo de la videoteca experimental. Con este hito, el sistema garantiza que los reportes estructurados para la ENMyH mantengan una trazabilidad total y una presentación acorde a la excelencia académica del IPN.

6.7 Fortalecimiento de la seguridad de acceso, depuración de dependencias de bajo nivel y optimización de recursos de cómputo

El desarrollo tecnológico durante el presente ciclo se ha enfocado en robustecer los mecanismos de seguridad y la eficiencia operativa del software, asegurando la integridad del flujo de trabajo institucional. Un avance crítico en la gestión de accesos consistió en la implementación de un control de sesión restrictivo; actualmente, en ausencia de un usuario con sesión activa, la interfaz limita la navegación exclusivamente a las secciones de inicio (Home) y autenticación (Login). Esta medida fuerza al personal a realizar el registro o ingreso formal en línea antes de interactuar con los módulos de análisis, garantizando la trazabilidad de los datos conforme a la regla de negocio RN6.

Complementariamente, se ha refinado el sistema de Roles y Permisos, de modo que los usuarios registrados con perfil de investigador queden estrictamente excluidos del panel de administración, cumpliendo así con los estándares de seguridad y jerarquía definidos para el prototipo.

En el ámbito de la visión por computadora de bajo nivel, se resolvió un obstáculo técnico persistente relacionado con la extracción de puntos clave (keypoints) anatómicos de los especímenes. Tras identificar que la ausencia de la librería especializada ptxas impedía la correcta comunicación entre los modelos de aprendizaje profundo y el hardware de aceleración gráfica, se procedió a su integración exitosa en el entorno de ejecución. Esta corrección técnica ha permitido que la extracción de coordenadas espaciales se realice ahora sin interrupciones, asegurando que el pipeline de estimación

de postura mantenga la precisión métrica necesaria para la generación de etogramas temporales y mapas de calor precisos, como los observados en los reportes de análisis recientes.

Para optimizar la gestión de dependencias y evitar conflictos entre librerías, se realizó la segregación del entorno de ejecución mediante la creación del ambiente virtualizado especializado `venv311`. Este entorno ha sido configurado específicamente para gestionar todas las funciones del prototipo que operan fuera del marco de análisis de DeepLabCut (DLC), permitiendo una ejecución más ligera y controlada de los módulos de minería de datos y visualización interactiva. Esta decisión arquitectónica mejora significativamente la mantenibilidad del software (RNF-06), al aislar los requisitos técnicos de las diferentes etapas del pipeline de inferencia y facilitar la actualización independiente de los modelos de inteligencia artificial sin comprometer la estabilidad global del sistema.

Un hito fundamental en la optimización del código fuente fue la identificación y eliminación de tres bloques extensos de código duplicado que comprometían la eficiencia del procesamiento. Se detectó que estas redundancias provocaban una llamada recursiva involuntaria al sistema, lo que resultaba en una doble ejecución de procesos analíticos y un gasto innecesario de recursos de hardware (CPU/GPU) por cada solicitud de usuario. Al simplificar esta lógica de ejecución, se ha logrado una respuesta más ágil de la interfaz y se ha garantizado que el procesamiento de videos experimentales se realice de manera lineal, optimizando la capacidad de cómputo necesaria para las tareas de inferencia matricial exhaustiva.

En cuanto al enriquecimiento del dataset de entrenamiento, el equipo ha mantenido una actividad constante a través de la plataforma RoboFlow, continuando con el etiquetado manual de fotogramas clave para mejorar la detección de los puntos anatómicos de los especímenes. Estos esfuerzos de anotación son esenciales para fortalecer la robustez del modelo ante oclusiones y para asegurar que la clasificación de comportamientos sutiles, como el acicalamiento o el contacto con la pared, alcance los umbrales de precisión científica requeridos. La incorporación de estos nuevos datos etiquetados busca mitigar los problemas de generalización detectados en fases previas de "prueba a ciegas", donde la inconstancia en la detección dificultaba la obtención de trayectorias limpias.

Finalmente, se han estado ejecutando pruebas de validación integrales para confirmar que las mejoras en la seguridad y la arquitectura no afecten la exactitud de los resultados etoestadísticos.

6.8 Escalamiento del dataset para la detección de microconductas y validación de la robustez del sistema

En el marco de la metodología espiral de Boehm, que rige el progreso cíclico y verificable de este Trabajo Terminal, la presente fase de desarrollo se ha orientado hacia un robustecimiento masivo de la base de conocimientos del sistema para alcanzar la detección precisa de microconductas. Durante el transcurso de la semana 42, se ha priorizado la expansión cuantitativa del repositorio de entrenamiento mediante la incorporación de un nuevo conjunto de 4,170 imágenes, las cuales han comenzado a ser etiquetadas manualmente y se encuentran actualmente en proceso de procesamiento. Este esfuerzo busca complementar la especialización cualitativa lograda en versiones previas, proporcionando a la red neuronal la diversidad visual necesaria para generalizar en escenarios experimentales complejos y dinámicos.

El objetivo técnico de integrar estas 4,170 nuevas muestras es dotar al pipeline de análisis de la "inteligencia" requerida para distinguir eventos de microconducta. A medida que avance este proceso y se incremente el volumen de datos etiquetados frame por frame, se busca que el clasificador supervisado SimBA y el motor de estimación de postura DeepLabCut superen los problemas de inconstancia detectados en las "pruebas a ciegas" previas, donde las conductas de corta duración solían ser fragmentadas o mal interpretadas como ruido espacial. Esta gran escala de datos, una vez consolidada, permitirá que el sistema aprenda representaciones abstractas de la forma del cuerpo del animal en diversas orientaciones, lo cual es fundamental para el análisis etológico riguroso exigido por la Escuela Nacional de Medicina y Homeopatía.

En concordancia con los hallazgos críticos de las semanas 35 y 36, se ha mantenido un protocolo estricto de etiquetado en resolución nativa de 720p para evitar la inducción de jitter de coordenadas, asegurando que cada una de las nuevas 4,170 imágenes preserve la integridad de los metadatos espaciales. Este proceso de anotación intensiva, que se está llevando a cabo de manera progresiva, es indispensable para mitigar los riesgos de sobreajuste ambiental (overfitting) y saturación por datos de baja calidad que fueron identificados como obstáculos críticos en fases anteriores del desarrollo. Al diversificar el dataset con muestras que capturan diferentes condiciones de iluminación y contrastes, se garantiza que el rastreador mantenga una trayectoria limpia incluso en los brazos cerrados del laberinto, donde las oclusiones suelen ser más frecuentes.

Paralelamente a las tareas de etiquetado masivo que se encuentran en marcha, el equipo ha continuado realizando pruebas de validación funcional para verificar la estabilidad de la integración YOLO-DLC-SimBA bajo las nuevas configuraciones de hardware y software. Estas sesiones de prueba permiten monitorear que las mejoras arquitectónicas implementadas recientemente, como la eliminación de rutas absolutas y la corrección de librerías de bajo nivel (ptxas), no hayan afectado la precisión en la generación de etogramas temporales y reportes de indicadores clave (KPIs). De esta manera, se asegura que el sistema evolucione hacia una solución operativa madura y estable, capaz de entregar estadísticas precisas y replicables para el análisis final de la investigación científica.

6.9 Estandarización de identidad institucional, optimización de inferencia y refinamiento de criterios de anotación de puntos clave

El avance más notable en la interfaz de usuario consistió en un rediseño integral del entorno gráfico, aplicando estrictamente la paleta de colores oficial del Instituto Politécnico Nacional, con tonos guinda y blanco en sus valores específicos. Esta actualización no solo cumple con el requerimiento de usabilidad RNF-02, sino que alinea el prototipo con los estándares de identidad institucional de la ESCOM y la ENMyH, proporcionando una plataforma con un rigor estético profesional adecuado para su despliegue en laboratorios de investigación del instituto.

En cuanto al enriquecimiento del motor de inteligencia artificial, se mantuvo una actividad intensiva de etiquetado sobre el dataset masivo de 4,170 imágenes introducido en ciclos previos. Al alcanzar un hito de 2,027 imágenes completamente anotadas, se procedió a una fase de entrenamiento y descarga del modelo desde la plataforma RoboFlow para su integración en el pipeline de inferencia. Los resultados de esta iteración mostraron un desempeño moderado en términos de precisión cualitativa, pero sobresaliente en velocidad de ejecución, lo que permitió validar la viabilidad técnica de realizar análisis complejos en tiempos reducidos.

Desde una perspectiva técnica de implementación, se identificó un conflicto de versionamiento en la exportación de modelos desde YOLO; se observó que al importar el nuevo modelo entrenado, la etiqueta de "occlusion" es omitida por el motor de inferencia, tratando todos los puntos como visibles independientemente de su estado real. Ante esta limitación tecnológica, se adoptó la política de mantener los keypoints de las patas "recortados" o limitados espacialmente en las anotaciones, postergando su marcado definitivo únicamente cuando existe una visibilidad confirmada del 100% de la extremidad. Esta medida garantiza que el entrenamiento del modelo de postura DeepLabCut mantenga la pureza de datos necesaria para la clasificación etológica posterior en SimBA.




Ilustración 71: Ejemplo de etiquetado en el software RoboFlow [Autoría Propia]

La optimización de estos criterios de detección y la integración refinada de YOLOv11 al pipeline han resultado en una mejora sustancial del rendimiento computacional. Actualmente, el sistema es capaz de completar un análisis de video exhaustivo en un tiempo aproximado de 3 minutos, manteniendo resultados de detección decentes y estables. Esta rapidez operativa facilita ciclos de retroalimentación

mucho más ágiles para los investigadores, cumpliendo con la necesidad de eficiencia planteada originalmente por el Dr. Sandino en las fases de análisis de requerimientos.

Finalmente, ante la estabilidad alcanzada en la velocidad de inferencia, los esfuerzos se han redirigido a fortalecer la detección de microconductas específicas. Se ha continuado con el etiquetado masivo enfocado primordialmente en eventos de grooming y thigmotaxis, categorías esenciales para la validación de efectos ansiolíticos en ensayos farmacológicos. Este robustecimiento cualitativo del dataset busca asegurar que el sistema evolucione hacia una herramienta de grado científico capaz de reportar estadísticas precisas y replicables.

6.10 Consolidación analítica de grupos experimentales, refinamiento de microconductas vía LSTM y estrategia de escalamiento masivo

En el marco de la fase de cierre de la metodología espiral de Boehm, que rige la progresión de este Trabajo Terminal para asegurar la gestión de riesgos y la madurez del software, en la semana 45 los esfuerzos de ingeniería se concentraron en tres pilares: la implementación de un módulo de comparación estadística robusto, el refinamiento del pipeline de postura mediante técnicas de "rescate" por redes recurrentes y la planificación de los hitos finales de entrega.

6.10.1 Implementación del módulo de comparación estadística y control de grupos

Se ha integrado un módulo avanzado diseñado para la comparación controlada de grupos experimentales, cumpliendo con los requerimientos analíticos solicitados por la ENMyH. Este componente inicializa configuraciones de sesión y controles de acceso basados en roles almacenados en `st.session_state`, garantizando que solo usuarios autorizados operen sobre los datos, conforme a las reglas de seguridad institucional. La extracción de información se realiza mediante una conexión optimizada a la base de datos relacional (`get_db_engine`), integrando experimentos finalizados y enriqueciéndolos con etiquetas únicas generadas a partir de metadatos experimentales.

La interfaz permite al investigador definir dos grupos de estudio (entre 6 y 8 especímenes por grupo de igual tamaño para asegurar validez estadística), consolidando los datos en un DataFrame de pandas con variables categóricas. El sistema no solo calcula estadísticas descriptivas vectorizadas (N, media, desviación estándar, error estándar, mínimos y máximos), sino que incorpora el cálculo del tamaño del efecto mediante el *d* de Cohen, permitiendo una interpretación profunda de la potencia farmacológica de las sustancias evaluadas. La exportación de estos resultados se ha estandarizado en archivos Excel multihoja y CSV, facilitando el re-graficado en software especializado solicitado por los expertos.

6.10.2 Refinamiento del pipeline: YOLO Pose v4 y rrquitectura de rescate LSTM

Para elevar la precisión del rastreo anatómico, se ha integrado la versión v4 de YOLO Pose, manteniendo un sistema de tracking basado en el torso del espécimen para mitigar las pérdidas de trayectoria observadas en iteraciones previas. Este avance se complementa con la corrección en la selección de modelos SimBA para el backend de YOLO, asegurando que la clasificación conductual no se vea afectada por inconsistencias en la arquitectura de datos de origen.

Un avance crítico de este ciclo es la implementación de una arquitectura de rescate basada en LSTM para la detección de la conducta de acicalamiento (grooming). Esta funcionalidad integra inferencia y entrenamiento de redes neuronales recurrentes diseñadas para procesar secuencias temporales que los

modelos tradicionales de Random Forest podrían fragmentar. Mediante el uso de umbrales calibrados y diagnósticos de validación en los clips R5C y R6C, el sistema ha logrado estabilizar la detección de microconductas, reduciendo el "parpadeo" o flickering que invalidaba la interpretación etológica en fases tempranas del proyecto.

6.10.3 Optimización administrativa, UX y persistencia de resultados

El sistema de gestión de experimentos ha sido optimizado mediante el ordenamiento lógico del historial y la adición de una funcionalidad de borrado administrativo, permitiendo una depuración controlada del repositorio de análisis. En términos de usabilidad (RNF-02), se ha reforzado la persistencia de resultados y se incorporó un campo de registro de observaciones que se mantiene activo durante la sesión, facilitando la documentación cualitativa del investigador en tiempo real. Estas mejoras aseguran que el prototipo sea una herramienta ergonómica y eficiente para el personal médico del laboratorio.

6.10.4 Estrategia de escalamiento del dataset e hitos de conclusión

Como parte de la estrategia de mejora continua, se ha mantenido un ritmo intensivo de etiquetado manual de imágenes a través de RoboFlow, superando los conjuntos de datos previos de 2,265 y 4,170 muestras. El equipo de ingeniería ha establecido como meta alcanzar un repositorio de 8,000 imágenes anotadas para la extracción de keypoints. Se proyecta que este volumen masivo de datos proporcionará una precisión mayor y una robustez definitiva ante oclusiones y variaciones lumínicas, alcanzando el estándar de concordancia del 95% requerido para la validación científica final.

Finalmente, en coordinación con la dirección del proyecto, se han definido las fechas críticas para la entrega de la versión operativa final del programa y la conclusión del reporte técnico del Trabajo Terminal. Estas definiciones aseguran que el prototipo transite de su fase de validación experimental a su implementación definitiva como una solución tecnológica estable y verificada para el Instituto Politécnico Nacional.

Capítulo 7. Ciclo de desarrollo

El desarrollo del presente proyecto se estructuró siguiendo los principios de la metodología espiral de Boehm, lo que permitió una gestión sistémica de los riesgos y un progreso gradual a través de la elaboración de prototipos funcionales. A diferencia de los modelos lineales tradicionales, este enfoque cíclico facilitó la integración constante de retroalimentación técnica y científica, asegurando que el producto final cumpliera con los estándares de calidad y rendimiento definidos por las normas internacionales de ingeniería de software.

En este apartado se detallan las actividades ejecutadas, los hitos alcanzados y la evolución técnica del sistema a través de sus cuatro iteraciones principales, las cuales abarcaron desde la planeación inicial hasta la validación de indicadores clave de desempeño en escenarios reales.

7.1 Iteración 1

En la primera fase del proyecto se realizaron las primeras acciones de investigación y análisis requeridas para sentar las bases firmes para el desarrollo del sistema. Principalmente, este periodo se centró en recopilar, examinar y estructurar datos vinculados al problema propuesto, además de

entender los términos científicos y técnicos que forman parte del proyecto. El protocolo, los capítulos 1 y 3 del presente documento, que tratan sobre el estado del arte y el marco teórico, respectivamente, fueron desarrollados como resultado de este proceso. Ambos documentos ayudaron a establecer el contexto del estudio y a identificar los fundamentos conceptuales requeridos para respaldar las decisiones que se tomaron en la evolución futura del sistema.

En el capítulo sobre estado del arte, se llevó a cabo una revisión de diversas investigaciones, metodologías y herramientas vinculadas al análisis automatizado de conductas en modelos animales. Se enfatizó en los estudios enfocados en la ansiedad, como las pruebas del Elevated Plus Maze (EPM). También se revisaron diversos métodos tecnológicos empleados en labores similares, como el procesamiento de video, técnicas de visión por computadora, aprendizaje automático y sistemas para rastrear movimiento. Esta revisión permitió el reconocimiento de las áreas de oportunidad, las limitaciones y los principales beneficios que presentan las soluciones existentes. Esto ayudó a establecer una propuesta que se ajusta a lo que requiere el proyecto TT 2026-A155.

Por otro lado, el desarrollo del marco teórico hizo posible que se afianzaran las ideas esenciales para entender cómo funciona y cuál es el alcance del sistema propuesto. Se discutieron en esta sección temas vinculados con el comportamiento de los animales, los modelos experimentales de ansiedad, la extracción de características, las bases de datos, además de las herramientas informáticas y las metodologías utilizadas a lo largo del desarrollo. Asimismo, se examinaron los principios relacionados con la aplicación de inteligencia artificial y métodos computacionales en el estudio del comportamiento, lo que permitió definir criterios técnicos precisos para las etapas siguientes del proyecto.

7.2 Iteración 2

7.2.1 Validación Leave-One-Out

La validación cruzada Leave-One-Out (LOO) constituye una de las metodologías más utilizadas para evaluar la capacidad de generalización de modelos de aprendizaje automático cuando se dispone de conjuntos de datos relativamente pequeños. Kohavi describe este método como un procedimiento donde el modelo es entrenado utilizando todas las muestras disponibles excepto una, la cual es reservada exclusivamente para evaluación; posteriormente, el proceso se repite hasta que cada muestra haya sido utilizada una vez como conjunto de prueba [87]. Esta estrategia permite estimar de manera más realista el comportamiento esperado del modelo frente a datos no observados previamente, reduciendo el sesgo asociado a evaluaciones realizadas únicamente sobre datos conocidos por el sistema.

En el presente proyecto, la validación Leave-One-Out fue seleccionada debido a que el objetivo principal no consiste únicamente en determinar si el modelo aprendió correctamente los videos presentes en el conjunto de entrenamiento, sino en evaluar qué tan adecuadamente puede generalizar frente a un nuevo video o sujeto experimental no visto anteriormente. Bishop explica que los métodos de validación cruzada permiten aproximar el rendimiento esperado del sistema bajo condiciones reales de operación, particularmente en aplicaciones biomédicas y de visión computacional donde la disponibilidad de datos suele ser limitada [22].

Si se dispone de 26 videos etiquetados manualmente, el procedimiento LOO se realiza dejando fuera un video distinto en cada iteración. El modelo es entrenado utilizando los 25 videos restantes y posteriormente evaluado sobre el video excluido. Después de obtener las métricas correspondientes, el proceso se repite hasta completar las 26 iteraciones. De esta manera, cada video es evaluado exactamente una vez como un caso completamente nuevo para el sistema, garantizando una validación ciega donde el modelo nunca tiene acceso al video de prueba durante el entrenamiento [87].

Por ejemplo, en la primera iteración el modelo es entrenado utilizando los videos 2 al 26 y evaluado sobre el video 1. En la segunda iteración se entrena con los videos 1 y 3 al 26, dejando fuera el video 2 para evaluación. Este procedimiento continúa sucesivamente hasta completar todas las combinaciones posibles. Hastie, Tibshirani y Friedman mencionan que esta metodología resulta especialmente útil cuando el número de muestras es reducido, ya que maximiza la cantidad de datos disponibles para entrenamiento sin perder rigurosidad estadística durante la evaluación [33].

7.2.2 Métricas de evaluación

Durante cada iteración de validación, el sistema genera métricas de desempeño por conducta y por modelo entrenado. Para ello, las predicciones realizadas por la inteligencia artificial son comparadas frame por frame contra las etiquetas humanas consideradas como referencia o ground truth. Sokolova y Lapalme señalan que las métricas derivadas de la matriz de confusión representan uno de los mecanismos más robustos para evaluar clasificadores binarios y multiclase, particularmente en problemas con distribuciones desbalanceadas [88].

La matriz de confusión se compone de cuatro categorías fundamentales:

- **Verdadero Positivo (TP):** el observador humano indica la presencia de la conducta y el modelo también la detecta correctamente.
- **Falso Positivo (FP):** el modelo detecta la conducta, pero la etiqueta humana indica que realmente no estaba presente.
- **Falso Negativo (FN):** la conducta se encuentra presente según la anotación humana, pero el modelo no logra detectarla.
- **Verdadero Negativo (TN):** tanto el modelo como el observador humano coinciden en la ausencia de la conducta.

Aunque los valores TN forman parte de la evaluación estadística tradicional, en este proyecto las métricas principales se centran en TP, FP y FN debido a que las conductas analizadas, como Grooming y Thigmotaxis, representan únicamente una pequeña proporción del total de frames del video. Powers explica que, en problemas altamente desbalanceados, la exactitud global puede resultar engañosa debido a la enorme cantidad de negativos correctos, generando evaluaciones artificialmente elevadas aun cuando el modelo falle en detectar los eventos de interés [89].

7.2.3 Limitaciones de exactitud como métrica principal

La métrica “accuracy” o exactitud representa la proporción total de predicciones correctas realizadas por el modelo respecto al número total de muestras evaluadas. Sin embargo, Sokolova y Lapalme

destacan que esta métrica pierde confiabilidad cuando las clases positivas son considerablemente menos frecuentes que las negativas [88]. De forma similar, Powers menciona que un clasificador puede obtener valores elevados de accuracy aun siendo incapaz de detectar correctamente la clase minoritaria [89].

En el contexto de este proyecto, las conductas Grooming y Thigmotaxis ocupan únicamente un pequeño porcentaje de los frames presentes en cada video experimental. En consecuencia, un modelo que predijera constantemente la ausencia de conducta podría alcanzar porcentajes de exactitud superiores al 90%, aun siendo incapaz de detectar correctamente los eventos conductuales relevantes. Por ejemplo, si Grooming ocurre únicamente en el 8.5% de los frames, un clasificador que siempre responda “no Grooming” obtendría aproximadamente un 91.5% de accuracy, pese a no detectar absolutamente ningún caso positivo.




Ilustración 76: Desbalance de clases [autoría propia]

Debido a esta problemática, se emplean métricas derivadas de la matriz de confusión que permiten evaluar el equilibrio entre sensibilidad y precisión del modelo. De acuerdo con la documentación oficial de Scikit-learn [90], Precisión representa la proporción de predicciones positivas correctas realizadas por el sistema:

$$P = \frac{TP}{(TP + FP)}$$

Los desarrolladores de Scikit-learn [90] describen Recall como la capacidad del modelo para detectar correctamente los casos positivos reales:

$$R = \frac{TP}{(TP + FN)}$$

Finalmente, Goodfellow, Bengio y Courville explican que el F1-score corresponde a la media armónica entre Precision y Recall, permitiendo balancear ambas métricas dentro de una única medida cuantitativa de desempeño [21]:

$$F1 = 2 \cdot \frac{P \cdot R}{P + R}$$

Goodfellow, Bengio y Courville [21] señalan que el F1-score resulta particularmente útil en problemas de clasificación desbalanceada debido a que penaliza simultáneamente falsos positivos y falsos negativos, proporcionando una evaluación más representativa del comportamiento real del modelo que la exactitud convencional.

7.2.4 Interpretación de precision, recall y F1-Score

Las métricas Precision, Recall y F1-score permiten interpretar el desempeño del modelo desde distintas perspectivas relacionadas con la detección correcta de conductas. Sokolova y Lapalme señalan que estas métricas constituyen una de las herramientas más importantes para evaluar clasificadores binarios y multiclase, especialmente en problemas con clases desbalanceadas donde la exactitud tradicional puede resultar engañosa [88]. Asimismo, Powers explica que este tipo de métricas permite analizar simultáneamente la capacidad del modelo para detectar eventos positivos reales y evitar falsas detecciones [89].

La métrica Precision responde a la siguiente pregunta: de todos los eventos que el modelo clasificó como conducta positiva, ¿cuántos correspondían realmente a dicha conducta? De acuerdo con la documentación oficial de Scikit-learn [90], una precisión elevada implica que el sistema genera pocos falsos positivos, es decir, pocas detecciones incorrectas de conducta inexistente. En términos prácticos, un valor alto de Precision indica que el modelo evita “inventar” eventos conductuales cuando estos realmente no ocurren.

Por otro lado, Recall evalúa qué proporción de la conducta real fue detectada correctamente por el sistema. Los desarrolladores de Scikit-learn [90] describen esta métrica como una medida de sensibilidad del modelo frente a eventos positivos verdaderos. Un Recall elevado implica una baja cantidad de falsos negativos, es decir, pocos casos reales omitidos por el sistema durante la clasificación. En aplicaciones conductuales, esto resulta particularmente importante debido a que ciertos eventos pueden ser de corta duración o manifestarse mediante movimientos muy sutiles.

Finalmente, el F1-score corresponde a la media armónica entre Precision y Recall, permitiendo resumir ambas métricas en un único indicador cuantitativo. Goodfellow, Bengio y Courville mencionan que esta métrica resulta especialmente útil en tareas de clasificación desbalanceada debido a que penaliza simultáneamente falsos positivos y falsos negativos [21]. De manera complementaria, Powers [89] explica que un F1-score cercano a 1 representa un desempeño altamente consistente, mientras que valores cercanos a 0 indican un desempeño deficiente, ya sea por incapacidad para detectar la conducta o por generación excesiva de ruido y falsas alarmas.

Precisión vs Exhaustividad en validación LOO ciega (SimBA RF, n=5 videos con resultado detallado)




Ilustración 75: Precisión y exhaustividad en grooming y thigmotaxis utilizando SimBA [autoría propia]

7.2.5 Funcionamiento de la validación

El proceso completo de validación Leave-One-Out fue automatizado mediante el script principal denominado:

`src/scripts/loo_full_bsoid.py`

La lógica general del pipeline consiste en seleccionar un video como conjunto de prueba o held-out, excluyéndolo completamente del entrenamiento antes de iniciar el proceso de validación. Posteriormente, el sistema realiza un respaldo temporal de los modelos productivos existentes para evitar modificaciones permanentes sobre los clasificadores principales del proyecto.

Después de ello, el script elimina temporalmente las etiquetas correspondientes al video evaluado dentro del conjunto de entrenamiento ubicado en `targets_inserted`. Una vez removidos dichos datos, se procede a reentrenar tanto el clasificador SimBA como el modelo B-SOiD utilizando únicamente los videos restantes. Posteriormente, ambos modelos generan predicciones sobre el video excluido y dichas predicciones son comparadas frame por frame contra las etiquetas humanas consideradas como ground truth.

Hastie, Tibshirani y Friedman destacan que uno de los principales riesgos durante la evaluación de modelos de aprendizaje automático es la fuga de información o data leakage, fenómeno que ocurre cuando datos de prueba participan indirectamente durante el entrenamiento [33]. Por esta razón, el sistema implementa una separación estricta entre entrenamiento y evaluación. Finalmente, el pipeline calcula automáticamente métricas de desempeño como Precision, Recall, F1-score, TP, FP y FN, para después restaurar los modelos y archivos originales del proyecto.

El procesamiento completo de los 26 videos experimentales es ejecutado mediante el script:

`src/scripts/run_loo_batch.py`

Este script automatiza todas las iteraciones Leave-One-Out y consolida los resultados finales dentro del archivo:

reportes/figuras/loo_resultados_n26.csv

Dicho archivo CSV constituye la fuente principal utilizada para generar las gráficas y tablas estadísticas presentadas dentro de la tesis.

7.2.6 Modelos evaluados y estrategias comparadas

Para la conducta Grooming se evaluaron múltiples estrategias de clasificación con el objetivo de comparar diferentes aproximaciones de análisis conductual automático.

El primer modelo corresponde a SimBA, el cual emplea un clasificador supervisado Random Forest basado en características geométricas derivadas de pose y movimiento. Breiman describe Random Forest como un método de aprendizaje basado en conjuntos de árboles de decisión capaz de reducir el sobreajuste y mejorar la capacidad de generalización del modelo [32]. De manera complementaria, Hastie, Tibshirani y Friedman [33] explican que los métodos ensemble basados en árboles resultan particularmente robustos frente a datos complejos y variables altamente correlacionadas.

El segundo enfoque corresponde a B-SOiD, sistema orientado al descubrimiento y clasificación de motivos conductuales a partir de patrones de postura y movimiento derivados de pose estimation. Sun et al. mencionan que los sistemas modernos de análisis conductual basados en pose permiten modelar relaciones espaciales y temporales complejas entre distintas regiones corporales del animal [45].

Además de evaluar ambos sistemas de manera individual, se implementaron estrategias híbridas tipo ensemble. La primera estrategia denominada Ensemble OR considera que existe Grooming si cualquiera de los dos modelos detecta la conducta. Por otra parte, la estrategia Conditional utiliza SimBA como clasificador principal y activa B-SOiD únicamente cuando las predicciones de SimBA presentan señales de degradación o colapso estadístico. Finalmente, la estrategia Dynamic implementa un comportamiento adaptativo basado en la distribución temporal de predicciones generadas por ambos modelos.

Para la conducta Thigmotaxis, SimBA presentó consistentemente un mejor desempeño debido a que dicha conducta depende principalmente de variables espaciales y geométricas relacionadas con la posición del animal dentro del laberinto. Pereira y Moita explican que las conductas altamente espaciales suelen ser más fáciles de modelar mediante características geométricas derivadas de visión computacional [16]. Asimismo, Mobbs et al. relacionan este comportamiento con mecanismos naturales de evitación y proximidad defensiva a bordes o zonas protegidas [40].

7.2.7 Resultados principales del experimento

Los resultados consolidados del experimento Leave-One-Out con $N = 26$ videos muestran diferencias importantes entre las estrategias evaluadas. Para Grooming, el modelo SimBA obtuvo un F1-score aproximado de 0.400, mientras que B-SOiD alcanzó un valor cercano a 0.357. La estrategia Ensemble

OR incrementó el desempeño hasta aproximadamente 0.502, mientras que el mejor resultado fue obtenido mediante el enfoque Conditional, alcanzando un F1-score cercano a 0.523.

En contraste, para la conducta Thigmotaxis el mejor desempeño fue obtenido directamente por SimBA con un F1-score aproximado de 0.636. B-SOiD mostró un desempeño considerablemente inferior, cercano a 0.318, mientras que Ensemble OR obtuvo aproximadamente 0.332.

La interpretación general de estos resultados indica que las estrategias híbridas y ensembles aportan beneficios importantes para la detección de Grooming debido a la complejidad y variabilidad de dicha conducta. Según Brandão [42], las conductas defensivas y de autocuidado presentan patrones motores altamente variables entre individuos. De forma similar, Klaassen et al. [43] señalan que las respuestas conductuales relacionadas con estrés y ansiedad pueden cambiar significativamente dependiendo del contexto experimental y del sujeto evaluado.




Ilustración 72: Desempeño de detección de grooming por SimBA, B-SOiD y Ensemble OR [autoría propia]

7.2.8 Uso de F1-score

Durante el análisis estadístico se identificó que algunos videos experimentales no contenían frames positivos correspondientes a determinadas conductas. Por ejemplo, ciertos videos podían no contener episodios reales de Grooming. Powers explica que, bajo condiciones altamente desbalanceadas, algunas métricas pueden producir valores artificialmente bajos incluso cuando el modelo no presenta errores reales de clasificación [89].

Debido a esta situación, se reportaron dos variantes distintas de promedio estadístico:

1. F1-score promedio general: incluye todos los videos evaluados.
2. F1-score promedio justo: excluye videos donde no existían ejemplos positivos reales de la conducta.

El uso de F1-score justo permite evaluar únicamente escenarios donde efectivamente existía conducta que detectar, proporcionando una interpretación más representativa del desempeño real del sistema. Esta estrategia evita penalizaciones artificiales derivadas de la ausencia total de eventos positivos dentro de ciertos videos experimentales.





Figura 73: Distribución del F1 de grooming por método sobre 13 vídeos [autoría propia]

7.2.9 Interpretación de los resultados

Los resultados obtenidos sugieren que el principal cuello de botella del sistema no corresponde al seguimiento espacial del animal, sino a la interpretación semántica de conductas complejas. Redmon et al. describen YOLO como una arquitectura capaz de realizar detección de objetos en tiempo real con alta precisión espacial [13]. De manera similar, Sharma et al. reportan desempeños elevados de arquitecturas YOLO modernas en tareas de detección animal y reconocimiento visual [55]. En este proyecto, el sistema de pose estimation basado en YOLO presentó un desempeño elevado con valores de mAP50 cercanos a 0.995, indicando una localización altamente precisa del ratón y sus keypoints corporales.

No obstante, la clasificación conductual presentó mayor dificultad, particularmente para Grooming. Pereira y Moita explican que las conductas complejas y sutiles representan uno de los principales desafíos en etología computacional debido a la gran variabilidad motora existente entre animales [16]. Además, Grooming involucra movimientos de baja amplitud, microajustes corporales y múltiples regiones anatómicas, incluyendo cara, vibrisas, patas delanteras y cuerpo.

En contraste, Thigmotaxis representa una conducta predominantemente geométrica y espacial, relacionada con la cercanía del animal respecto a paredes y bordes del laberinto. Ball y Gunaydin describen este comportamiento como un patrón clásico asociado a respuestas de ansiedad y evitación defensiva [41]. Debido a ello, resulta considerablemente más sencillo de modelar mediante características espaciales derivadas de visión computacional [16][39].



7.2.10 Casos de estudio representativos

El caso correspondiente al video R6B20 mostró un comportamiento particularmente relevante durante la evaluación experimental. En este caso, SimBA obtuvo un F1-score igual a 0.000 para Grooming, mientras que la estrategia Conditional logró incrementar el desempeño hasta aproximadamente 0.346. Para Thigmotaxis, SimBA alcanzó un F1-score cercano a 0.751. Este resultado demuestra que algunos animales pueden generar patrones conductuales suficientemente distintos como para provocar colapsos en clasificadores individuales, mientras que las estrategias híbridas logran rescatar parcialmente la capacidad de detección.




Ilustración 77: Ensemble condicional y otras alternativas en comparación [autoría propia]

Por otro lado, el caso R6C mostró un escenario diferente. Tanto SimBA como Conditional alcanzaron un F1-score cercano a 0.668 para Grooming, mientras que SimBA obtuvo aproximadamente 0.638 en Thigmotaxis. Este comportamiento evidencia que la estrategia Conditional no perjudica el desempeño cuando SimBA ya presenta una clasificación adecuada.

7.2.11 Ground Truth y anotaciones humanas

Las anotaciones humanas utilizadas como ground truth se encuentran integradas directamente dentro de los archivos CSV almacenados en:

`data/simba_projects/grooming_thigmotaxis_yolo/project_folder/csv/targets_inserted/`

En total, se confirmó la existencia de 52 archivos CSV, correspondientes a 26 videos reales y 26 versiones aumentadas mediante espejado horizontal (mirror augmentation). Cada archivo contiene simultáneamente las características calculadas por SimBA y YOLO, incluyendo coordenadas corporales, distancias, movimiento, zonas espaciales y proximidad a paredes, así como las etiquetas humanas correspondientes a Grooming y Thigmotaxis.

Cada fila representa un frame individual del video experimental. Las columnas finales denominadas Grooming y Thigmotaxis contienen las etiquetas binarias utilizadas como referencia experimental:

0 = ausencia de conducta.

1 = presencia de conducta.

Kohavi explica que en esquemas Leave-One-Out es fundamental garantizar que las muestras de prueba permanezcan completamente separadas del entrenamiento para evitar sesgos en la evaluación estadística [87]. Por esta razón, durante el proceso Leave-One-Out el script elimina temporalmente el archivo CSV correspondiente al video evaluado del directorio `targets_inserted`, evitando que SimBA

utilice sus etiquetas humanas durante el entrenamiento. Posteriormente, el sistema predice sobre dicho video y compara las predicciones generadas contra las columnas originales de ground truth únicamente durante la fase de evaluación. Este procedimiento fortalece la validez experimental y estadística del sistema [33][87].

7.3 Iteración 3

Durante la tercera iteración, se hicieron múltiples cambios para análisis conductual automatizado. Estos cambios se representan de la siguiente forma:

7.3.1 Adquisición y normalización de video

Esta capa recibe los videos experimentales y ejecuta un proceso de normalización espacial y temporal. Todos los videos son convertidos y procesados en resolución mínima de 1280×720 píxeles (720p), manteniendo una frecuencia constante de cuadros por segundo.

La decisión de establecer 720p como resolución mínima responde a criterios técnicos derivados de la detección de puntos clave corporales. Modelos de estimación de pose como YOLO Pose dependen directamente de la resolución espacial para localizar estructuras anatómicas pequeñas, tales como hocico, orejas, base de cola y extremidades. Redmon et al. señalan que la precisión de detección decrece significativamente cuando la resolución reduce el número de píxeles disponibles para representar objetos pequeños [91]. De manera complementaria, la documentación oficial de Ultralytics establece que la detección robusta depende de conservar suficiente detalle espacial para evitar pérdida de información contextual durante el escalamiento de entrada [92].

En el contexto etológico, comportamientos como grooming involucran micro-movimientos de amplitud reducida, mientras que la tigmotaxis requiere precisión posicional respecto al perímetro del laberinto. Una resolución inferior introduce solapamiento espacial y pérdida de detalle, afectando la localización precisa del sujeto experimental. Bovet y Benhamou demostraron que la precisión espacial resulta crítica para la cuantificación confiable de trayectorias locomotoras en paradigmas de ansiedad [93].

7.3.2 Extracción de pose

Se consolidó el uso de YOLO Pose v4 como backend principal para la estimación corporal.

Esta capa transforma cada frame en un vector estructurado de coordenadas:

$$P_t = (x_1, y_1)(x_2, y_2), \dots, (x_n, y_n)$$

donde:

P_t : conjunto de puntos clave en el instante (t).

n: número total de keypoints anatómicos.

La reducción del tiempo de procesamiento de aproximadamente 5 horas a 3 minutos por video fue consecuencia directa de la optimización GPU y del procesamiento paralelo, consistente con las mejoras reportadas para detectores de una sola etapa considerando que se utiliza una RTX 5070 Ti [91].

Este enfoque permite detectar al sujeto experimental en tiempo real, estimar su posición espacial dentro del laberinto y generar las trayectorias necesarias para el posterior análisis conductual [21].

Cada fotograma de entrada corresponde a una imagen con resolución original de:

$$I \ni R^{720 \cdot 1080 \cdot 3}$$

donde:

- 720: número de píxeles verticales.
- 1280: número de píxeles horizontales.
- 3: canales de RGB.

Cada píxel tiene una representación matemática:

$$p_{ij} = (r_{ij}, g_{ij}, b_{ij})$$

donde cada variable constituye las intensidades discretas de color.

Para normalizar la información y favorecer la estabilidad numérica durante el entrenamiento, los valores son reescalados:

$$p'_{ij} = \frac{p_{ij}}{255}$$

de forma que:

$$p'_{ij} \in [0,1]$$

Este proceso reduce variaciones numéricas extremas y mejora la convergencia del descenso por gradiente. Posteriormente, la imagen se redimensiona a:

$$I' \ni R^{640 \cdot 640 \cdot 3}$$

Dentro de esa redimensión, cada píxel pasa por el siguiente proceso:

$$x' = x \cdot \frac{640}{1280}$$

$$y' = y \cdot \frac{640}{720}$$

donde:

- x, y : coordenadas originales del fotograma (frame).
- x', y' : coordenadas transformadas.

Este mapeo constituye una transformación afín que preserva la correspondencia relativa entre posiciones espaciales. La elección de una resolución cuadrada responde a la necesidad de compatibilidad con la arquitectura convolucional y permite un balance adecuado entre precisión espacial y eficiencia computacional [21].

El núcleo matemático de YOLO está compuesto por capas convolucionales sucesivas.

Cada convolución se define como:

$$F_{i,j}^{(l)} = \sum_{u=-k}^k \sum_{v=-k}^k W_{u,v}^{(l)} X_{i+u,j+v}^{(l-1)} + b^{(l)}$$

donde:

- $X^{(l-1)}$: entrada a la capa por la capa anterior.
- $W^{(l)}$: kernel convolucional.
- $b^{(l)}$: sesgo.

$F_{i,j}^{(l)}$ es la activación de la salida del píxel en su respectiva coordenada que contiene el conjunto de representación del objeto por buscar, así como contornos, bordes, figuras, orientación y posturas. $W_{u,v}^{(l)}$ es el filtro convolucional en donde se hace una matriz donde se determinan los pesos del filtro convolucional, lo anterior detecta bordes, contornos y esquinas. $X_{i+u,j+v}^{(l-1)}$ representa el valor de entrada de la capa anterior con sus respectivos desplazamientos verticales y horizontales. Mientras tanto, la doble sumatoria es el recorrido de todos los elementos del filtro considerando el valor k . Finalmente, se hace la sumatoria de las multiplicaciones de cada píxel por su peso.

Después, se utiliza una función de activación no lineal que transforma la salida del píxel en su respectiva coordenada a la siguiente capa.

$$A_{i,j}^{(l)} = \sigma(F_{i,j}^{(l)})$$

También se emplea la función SiLu que permite transiciones suaves y pérdida de gradientes:

$$\sigma(x) = x \cdot \frac{1}{1 + e^{-x}}$$

donde:

- x : la entrada de la función.
- $\frac{1}{1+e^{-x}}$: sigmoide donde los valores van de 0 a 1.

A medida que la imagen atraviesa las capas convolucionales de la red, su resolución espacial disminuye progresivamente mediante operaciones de pooling (agrupamiento) y convoluciones con desplazamiento (stride). Esta reducción se expresa como:

$$H_l = \frac{H_{l-1}}{s}$$

$$W_l = \frac{W_{l-1}}{s}$$

donde:

- H_l : altura de la capa.
- W_l : ancho de la capa.
- H_{l-1} : altura de la capa anterior.
- W_{l-1} : ancho de la capa anterior.
- s : desplazamiento del filtro.

El parámetro s determina cuántos píxeles avanza el filtro en cada operación convolucional. Cuando $s > 1$, se reduce la resolución espacial, lo que permite disminuir el costo computacional y concentrar la información más relevante [21].

Esta reducción incrementa simultáneamente el campo receptivo efectivo:

$$R_l = R_{l-1} + (k - 1) \prod_{m=1}^{l-1} s_m$$

donde:

- R_l : campo receptivo en la capa.
- R_{l-1} : campo receptivo de la capa anterior.
- k : tamaño del kernel convolucional.
- s_m : desplazamiento aplicado a la capa previa.

El campo receptivo representa la región original de la imagen que influye en una activación específica. Su incremento permite que el modelo integre información contextual más amplia del entorno experimental, facilitando la identificación de configuraciones espaciales complejas asociadas a patrones conductuales [21].

Una vez procesada la imagen, se divide el espacio visual en una cuadrícula de tal forma que:

$$S \times S$$

donde S representa el número de divisiones por eje.

Para una configuración experimental cada celda posee un cierto número de dimensiones que se representa como: La ecuación completa constituye lo siguiente:

$$g_{ij} = \left[\frac{iW}{S}, \frac{(i+1)W}{S} \right] \cdot \left[\frac{jH}{S}, \frac{(j+1)H}{S} \right]$$

donde:

- W : ancho total de la imagen.
- H : altura total de la imagen.
- i : índice horizontal.
- j : índice vertical.

Finalmente, para asignar formalmente la detección del ratón, se usa esta ecuación donde:

$$(x_c, y_c) \in g_{ij}$$

- (x_c, y_c) : coordenadas del centro geométrico del objeto.

Hay que tomar en cuenta que cada celda predice una caja delimitadora definida como:

$$B = (x, y, w, h, c)$$

donde:

- x : coordenada horizontal.
- y : coordenada vertical.
- w : ancho de la caja.
- h : altura de la caja.
- c : confianza de detección.

Las coordenadas se normalizan respecto al tamaño de la celda:

$$x, y \in [0,1]$$

$$w, h \in [0,1]$$

Para reconstruir la localización absoluta, se utilizan las siguientes operaciones:

$$x_{abs} = x_{cell} + x \cdot cell_w$$

$$y_{abs} = y_{cell} + y \cdot cell_h$$

$$w_{abs} = w \cdot W$$

$$h_{abs} = h \cdot H$$

donde:

- x_{cell}, y_{cell} : coordenadas de la celda.
- $cell_w, cell_h$: dimensiones de la celda.
- W, H : dimensiones de la imagen.

Estas transformaciones permiten localizar con precisión al sujeto dentro del fotograma original. Sin embargo, queda pendiente el porcentaje de confianza. La confianza de detección se define como:

$$c = P(Object) \cdot IoU$$

donde:

- $P(Object)$: probabilidad de presencia del objeto.
- IoU : coincidencia espacial entre predicción y referencia.

La probabilidad se calcula mediante función logística de la siguiente forma:

$$P(Object) = \sigma(z)$$

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

donde:

- z : activación previa de la neurona.
- $\sigma(z)$: probabilidad transformada.

Esta función convierte valores reales arbitrarios en probabilidades dentro del intervalo [0,1]. Sin embargo, para obtener z , YOLO ejecuta la siguiente fórmula:

$$z = \sum_{r=1}^n w_r A_r + b$$

donde:

- w_r : pesos adquiridos.
- A_r : activaciones de neuronas.
- b : sesgo.

Otra de las cosas para obtener el porcentaje de confianza es el IoU (intersección sobre la unión) es por la métrica de superposición espacial:

$$IoU = \frac{|B_p \cap B_r|}{|B_p \cup B_r|}$$

donde:

- B_p : caja predicha.
- B_r : caja real.

$$IoU = \frac{A_{intersección}}{A_p + A_r - A_{intersección}}$$

donde:

- $A_{intersección}$: área compartida.
- A_p : área predicha.
- A_r : área real.

El IoU cuantifica la precisión espacial de la localización del objeto y sirve para obtener el porcentaje de confianza.

Una vez detectado el objeto, el modelo calcula:

$$P(c_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

donde:

- $P(c_i)$: probabilidad de pertenencia a la clase requerida.
- z_i : activación logit, valor bruto que produce una neurona.
- K : número total de clases.

Esta función garantiza interpretar la salida como distribución probabilística:

$$\sum_{i=1}^K P(c_i) = 1$$

Sin embargo, también se tiene una función de pérdida global donde el entrenamiento optimiza:

$$L = L_{loc} + L_{size} + L_{conf} + L_{cls}$$

donde:

- L_{loc} : error de localización.
- L_{size} : error de tamaño.
- L_{conf} : error de confianza.
- L_{cls} : error de clasificación.

Con las siguientes operaciones de error de localización se penalizaron los errores de posicionamiento inicial:

$$L_{loc} = \lambda_{coord} \sum [(x - \hat{x})^2 + (y - \hat{y})^2]$$

donde:

- x, y : coordenadas reales.

- $\hat{x}, \hat{y}$: coordenadas predichas.
- λ_{coord} : factor de ponderación.

El error de tamaño reduce sensibilidad a errores en cajas grandes

$$L_{size} = \lambda_{coord} \sum \left[(\sqrt{w} - \sqrt{\hat{w}})^2 + (\sqrt{h} - \sqrt{\hat{h}})^2 \right]$$

donde:

- w, h : anchura y altura reales.
- $\hat{w}, \hat{h}$: anchura y altura predichas.

El error de confianza determina si un objeto, en esencia, está en una celda:

$$L_{conf} = \sum (c - \hat{c})^2$$

donde:

- c : confianza real.
- $\hat{c}$: confianza predicha.

La pérdida de clasificación, mejor conocida como entropía cruzada, sirve para medir qué tan bien las clases son detectadas:

$$L_{cls} = - \sum y_i \log(\hat{y}_i)$$

donde:

- y_i : etiqueta real.
- $\hat{y}_i$: etiqueta predicha.

Este procedimiento minimiza el error global durante el análisis. También es la forma en la cual el modelo aprende. Los parámetros se actualizan mediante descenso de gradiente:

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L(\theta_t)$$

donde:

- θ_t : parámetros actuales.
- θ_{t+1} : parámetros actualizados.
- η : tasa de aprendizaje.

- $\nabla_{\theta} L$: gradiente de la pérdida.

La supresión no máxima es una etapa que se ejecuta después del proceso para evitar duplicado de cajas. Dado un conjunto de predicciones (cajas):

$$B_1, B_2, \dots, B_n$$

se selecciona:

$$B^* = \arg \max Score(B_i)$$

donde:

- $Score(B_i)$: puntuación de confianza.

Las cajas se ordenan de forma descendente por nivel de confianza y se aplica una métrica de superposición especial. Posteriormente se descartan cajas si:

$$IoU(B_i, B^*) > \tau$$

donde:

- τ : umbral de supresión.

Finalmente, la posición del objeto en cada instante es detectada por trayectorias temporales:

$$(x_t, y_t)$$

donde:

- x_t : coordenada horizontal en el tiempo.
- y_t : coordenada vertical en el tiempo.

La trayectoria total de una secuencia de posiciones del mismo objeto es:

$$T = (x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

A partir de esta secuencia se calcula la velocidad:

$$v_t = \frac{\sqrt{(x_t - x_{t-1})^2 + (y_t - y_{t-1})^2}}{\Delta t}$$

donde:

- v_t : velocidad instantánea.
- Δt : intervalo temporal.

Asimismo, el tiempo de permanencia regional se calcula como:

$$Time(R) = \sum_{t=1}^n 1[(x_t, y_t) \in R]$$

donde:

- R : región espacial.
- $1[(x_t, y_t) \in R]$: función indicadora.

Estas variables permiten cuantificar dinámicas espaciales y temporales relevantes para la clasificación conductual final donde se puede determinar por qué parte del píxel ha pasado un objeto.

7.3.3 Capa de clasificación primaria

Sobre los vectores pose-estimativos se ejecuta un clasificador Random Forest, inspirado en la arquitectura implementada por SimBA. Breiman demuestra que Random Forest ofrece alta robustez frente a ruido y buena capacidad de generalización en clasificación multivariada [94].

El clasificador produce una predicción binaria para cada conducta:

$$\hat{y}_t \in 0,1$$

7.3.4 Capa de rescate temporal basada en LSTM

Para resolver el fenómeno de flickering (detecciones intermitentes en secuencias cortas), se integró una arquitectura recurrente LSTM que procesa ventanas temporales de 45 frames. Hochreiter y Schmidhuber demostraron que las LSTM son capaces de modelar dependencias temporales largas y mantener memoria contextual [95].

La operación interna puede expresarse como:

$$h_t = LSTM(x_t, h_{t-1})$$

donde:

x_t : secuencia de entrada.

h_t : estado oculto temporal.

Esto permite rescatar eventos breves que un clasificador frame por frame podría perder.

7.3.5 Determinación del tamaño de muestra

Con base en principios de cobertura distribucional en aprendizaje supervisado [21], así como en metodologías de curvas de aprendizaje para evaluación de convergencia [104], se plantea una expansión progresiva del conjunto de entrenamiento. El tamaño final no se fija como una constante absoluta, sino que se determinará empíricamente mediante incrementos sucesivos del corpus, evaluando en cada etapa la estabilización del F1-score bajo validación Leave-One-Out [87].

Este criterio permite identificar el punto en el cual la incorporación de nuevos videos produce mejoras marginales mínimas, indicando una cobertura suficiente de la variabilidad biológica, espacial y

contextual de las conductas analizadas [96]. Como meta inicial, se estima que un rango de 60 a 80 videos reales podría aproximar dicha condición de saturación.

Con base en principios de cobertura distribucional en aprendizaje supervisado [21], así como en metodologías de curvas de aprendizaje para evaluación de convergencia [104], se plantea una expansión progresiva del conjunto de entrenamiento.

Sea N_k el número acumulado de videos incorporados en la iteración k y $F_1(N_k)$ el desempeño del clasificador medido mediante validación Leave-One-Out. La evolución del sistema puede modelarse mediante una función de aprendizaje:

$$F_1 = f(N)$$

donde:

N : tamaño de la muestra o corpus.

F_1 : desempeño obtenido para dicho tamaño muestral.

Con base en el capítulo 7.2.3, se obtienen los resultados para precision, recall y F1-Score. El tamaño final del conjunto no se fija como una constante absoluta, sino que se determinará empíricamente mediante incrementos sucesivos de los corpus definidos como:

$$N_k = N_0 + k\Delta N$$

donde:

N_0 : tamaño inicial del conjunto.

ΔN : número de videos añadidos por iteración.

k : índice de expansión.

En cada incremento, se evaluará la mejora marginal del desempeño mediante:

$$\Delta F_1^{(k)} = F_1^{(k)} - F_1^{(k-1)}$$

Este criterio permite identificar el punto de saturación distribucional cuando:

$$\left| \Delta F_1^{(k)} \right| < \varepsilon$$

durante múltiples iteraciones consecutivas, donde ε representa un umbral mínimo de mejora aceptable. Esta condición indica que la incorporación de nuevos videos produce ganancias marginales despreciables, señalando una cobertura suficiente de la variabilidad biológica, espacial y contextual de las conductas analizadas [96][104].

Desde una perspectiva teórica, esta convergencia puede aproximarse mediante un comportamiento asintótico:

$$F_1(N) = F_{1,max}(1 - e^{-\lambda N})$$

donde:

$F_{1,max}$: representa el desempeño máximo alcanzable.

λ : tasa de convergencia del aprendizaje.

Bajo este marco, el tamaño óptimo del conjunto se define como:

$$N^* = \min \left\{ N: \frac{dF_1}{dN} < \varepsilon \right\}$$

Esto significa el número de vídeos necesarios para alcanzar un desempeño aceptable.

A partir del cálculo del F1-score acumulativo mediante micro-promedio para las clases Grooming y Thigmotaxis, se observó que la secuencia de desempeño presenta un comportamiento no monótono. En particular, se identificó un valor máximo local de $F_1 = 0.525$ para Grooming con 14 videos, mientras que el valor final obtenido al incorporar los 26 videos disponibles descendió a $F_1 = 0.460$. Este comportamiento sugiere la existencia de una alta variabilidad entre muestras y evidencia que el conjunto actual aún no garantiza estabilidad estadística del aprendizaje.

Para modelar la evolución esperada del desempeño al incrementar el tamaño del conjunto de entrenamiento, se empleó un modelo exponencial saturante descrito por:

$$F_1(N) = F_{1,max}(1 - e^{-\lambda N})$$

Considerando un valor estimado de $F_{1,max} = 0.55$ y una tasa ($\lambda=0.03$), obtenida a partir de la pendiente media observada durante las primeras iteraciones, se proyecta una mejora progresiva del desempeño hasta alcanzar valores cercanos al límite superior conforme aumenta el número de muestras.

Bajo este ajuste, los valores proyectados indican que para 100 videos el F1-score esperado sería aproximadamente 0.546, mientras que para 120 videos alcanzaría 0.551. La diferencia entre ambos escenarios corresponde a una mejora marginal de apenas 0.005, lo que sugiere una aproximación al régimen de saturación.

El criterio de saturación adoptado se definió mediante un umbral de mejora marginal:

$$\varepsilon = 0.00$$

y un requisito de persistencia durante tres iteraciones consecutivas:

$$r = 3$$

De acuerdo con este criterio, la saturación se considera alcanzada cuando la mejora incremental del F1-score permanece por debajo del 0.5 % durante al menos tres incorporaciones sucesivas de nuevos videos. La aplicación de este criterio al modelo proyectado indica que esta condición se satisface a partir de aproximadamente 110 videos.

De manera complementaria, se analizó la convergencia asintótica de la curva mediante su derivada:

$$\frac{dF_1}{dN} = F_{1,\max} \lambda e^{-\lambda N}$$

Estableciendo como condición de convergencia una pendiente inferior a 5×10^{-4} , se obtuvo una solución aproximada de:

$$N > 116.5$$

lo que indica que, a partir de 117 videos, la tasa de mejora se vuelve prácticamente despreciable, reflejando una estabilización efectiva del aprendizaje.

Por lo tanto, se concluye que el corpus actual de 26 videos resulta insuficiente para garantizar saturación distribucional, justificándose formalmente la expansión progresiva del conjunto experimental hasta una horquilla comprendida en 117 vídeos.

7.3.6 Módulo de comparación estadística

Este módulo recibe los tiempos conductuales acumulados y calcula estadísticos descriptivos e inferenciales para comparar grupos experimentales. Dichos tiempos conductuales acumulados son:

- Brazos abiertos.
- Brazos cerrados.
- Centro.
- Grooming.
- Tigmotaxis.

El criterio mínimo operativo para comparación estadística se estableció en:

$$n = 6 \text{ a } 8 \text{ videos por grupo}$$

con dos grupos:

$$N_{total} = 12 \text{ a } 16$$

Esto es consistente con tamaños muestrales frecuentemente empleados en estudios conductuales de laberinto elevado [97].

Cada comparación utiliza grupos balanceados:

$$n_1 = n_2$$

con:

$$n \in 6,7,8$$

No se permiten comparaciones desbalanceadas porque introducen heterocedasticidad y sesgo en pruebas paramétricas [100]. En todo caso, esto significa que, por ejemplo; no se puede comparar un grupo con 6 vídeos mientras que otro grupo tiene una cantidad de vídeos diferentes a 6.

La media para representar tiempo promedio conductual en todos los brazos, así como en el centro y los momentos de las poses de grooming y thigmotaxis [101]. Con esto, se representa el tiempo promedio de permanencia en las zonas. La fórmula para la media consiste en:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

donde:

n : número de videos del grupo.

x_i : tiempo registrado en el video i .

La desviación estándar cuantifica cuánto varían los tiempos individuales respecto al promedio [101].

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

donde:

$x_i - \bar{x}$: desviación individual respecto a la media.

$n - 1$: corrección de Bessel para estimación muestra.

Una desviación baja sugiere una consistencia conductual en especímenes mientras que una desviación alta indica variación de conductas.

El error estándar de la media estima la precisión de la media como estimador poblacional [101].

$$SEM = \frac{s}{\sqrt{n}}$$

donde:

s : desviación estándar de un grupo.

n : número de vídeos del grupo.

Esto indica la incertidumbre asociada a la estimación del promedio conductual.

Los valores mínimo y máximo definen los límites observados del comportamiento registrado:

$$x_{min} = \min(x_i)$$

$$x_{max} = \max(x_i)$$

Para una comparación entre grupos, se utilizan diferentes pruebas.

La prueba t de Student se utiliza para comparar resultados entre dos grupos con el fin de evaluar diferencia significativa entre medias [102].

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

donde:

$\overline{x_1}, \overline{x_2}$: medias de los grupos.

s_1^2, s_2^2 : varianzas.

n_1, n_2 : número de videos de los grupos.

ANOVA se usa con el fin de comparar múltiples grupos con el fin de evaluar si existe un tratamiento global [102].

$$F = \frac{MS_{between}}{MS_{within}}$$

donde:

$MS_{between}$: variabilidad entre grupos.

MS_{within} : variabilidad interna.

La prueba de d de Cohen cuantifica la magnitud del efecto:

$$d = \frac{\overline{x_1} - \overline{x_2}}{s_p}$$

donde:

d : tamaño del efecto.

$\overline{x_1}, \overline{x_2}$: medias de los grupos.

s_p : derivación estándar combinada.

con la desviación estándar combinada cuya función es normalizar la diferencia entre medias considerando la variabilidad conjunta de ambos grupos [102].

$$s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$$

donde:

n_1, n_2 : número de vídeos de los grupos.

s_1^2, s_2^2 : varianzas.

La interpretación de la d de Cohen puede dar los siguientes resultados [103]:

- 0.2: existe una diferencia cuya magnitud no es ampliada.
- 0.5: existe una diferencia significativa cuya magnitud sugiere un efecto conductual apreciable.
- 0.8: existe una gran diferencia cuya magnitud sugiere un efecto conductual bastante detectable.

7.3.7 Paso 1 – Acceso al sistema

El usuario accede a la aplicación Streamlit a través de un navegador web en la dirección de red local donde está desplegado el servidor. Introduce sus credenciales en la página de inicio de sesión. Si la

autenticación de dos factores está habilitada, recibirá un código OTP en su correo institucional que deberá ingresar para completar el acceso.

En el caso donde solo se inicie sesión con las credenciales correctas (correo institucional y contraseña) y estas sean correctas, el acceso al sistema será otorgado.

Ilustración de un formulario de inicio de sesión. El formulario está centrado en una pantalla con fondo gris claro. Tiene un título "Correo Electrónico Institucional" en gris. Debajo hay un campo de texto con un icono de correo y el texto "@alumno.ipn.mx". Abajo de eso, el texto "Contraseña" precede a un campo de texto con puntos grises para ocultar la contraseña. A la derecha del campo de contraseña hay un icono de ojo. En la parte inferior del formulario hay un botón rectangular con el texto "ENTRAR DE FORMA SEGURA" en letras mayúsculas y color rojo oscuro.

Ilustración 78: Ejemplo de inicio de sesión básico [autoría propia]

Si las credenciales son correctas, un mensaje en verde con la leyenda “identificación exitosa” aparecerá antes de mostrar la sección general del sistema.




Ilustración 79: Mensaje de inicio de sesión exitoso [autoría propia]




Ilustración 80: Vista general del sistema [autoría propia]

En caso de que el correo institucional ingresado o la contraseña sean incorrectos, el acceso será denegado y un mensaje en rojo con la leyenda “credenciales incorrectas o cuenta inactiva” aparecerá. También el mismo mensaje puede aparecer si la cuenta ha sido inhabilitada.

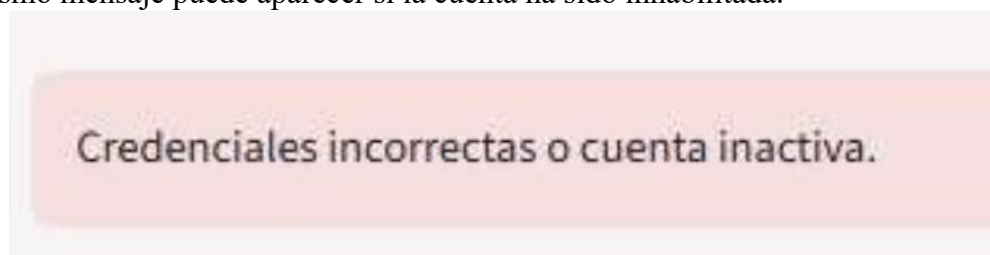


Ilustración 81: Mensaje de inicio de sesión con error [autoría propia]

7.3.8 Paso 2 – Ingesta del video

En la página de ingesta, el usuario:

- Ingresa a la sección de “Ingesta de vídeo”.



Ilustración 82: Botón para acceder a la sección de ingesta de vídeo [autoría propia]

Modulo 01: Ingesta de Video

Cargue el registro experimental en formato de video para iniciar el proceso de análisis conductual. Defina los parametros basicos del espécimen y el tratamiento administrado.

Parametros del Registro

ID del Especimen: Fecha del Experimento:

ID del Tratamiento: Responsable:

[➤ Añadir Nuevo Tratamiento](#)

Carga Video (MP4 / MOV / AVI)

Drag and drop file here
Limit 4GB per file • MP4, MOV, AVI, MPEG4

[Browse files](#)

[PREPARAR VIDEO Y RECORRAR](#)

UPV - Unidad de Investigación de Comportamiento Animal 2026

Ilustración 83: Vista general la sección de ingesta de video [autoría propia]

b. Selecciona el archivo de video desde su equipo local.




Ilustración 84: Espacio para seleccionar archivo .mp4, .mov o .avi [autoría propia]




Ilustración 85: Selección de archivo de vídeo [autoría propia]




Ilustración 86: Carga de vídeo [autoría propia]

- c. Registra los datos del experimento (identificador del animal, fecha).

Parametros del Registro

ID del Especimen	Fecha del Experimento
R5DZ_01mar24	2024/05/23
ID del Tratamiento	Responsable
Control	Gabrielito Lázaro Viver
➤ Añadir Nuevo Tratamiento	

Ilustración 87: Registro de datos del experimento [autoría propia]



Ilustración 88: Botón de preparación de vídeo [autoría propia]

- d. Revisa la duración del vídeo.




Ilustración 89: Duración del vídeo [autoría propia]

e. Confirma la ingesta para continuar.



Ilustración 90: Botón de guardado de parámetros del vídeo [autoría propia]




Ilustración 91: Botón de guardado de continuar al módulo de keypoints [autoría propia]

7.3.9 Paso 3 – Extracción de keypoints

El usuario inicia el proceso de extracción desde la página de Keypoints. El sistema lanza YOLO Pose en segundo plano y muestra los logs de avance en tiempo real. En las pruebas internas, esta etapa se redujo de un orden de horas con DeepLabCut a un orden de minutos con YOLO Pose. Una vez finalizado, el sistema notifica al usuario y habilita la continuación al siguiente paso.

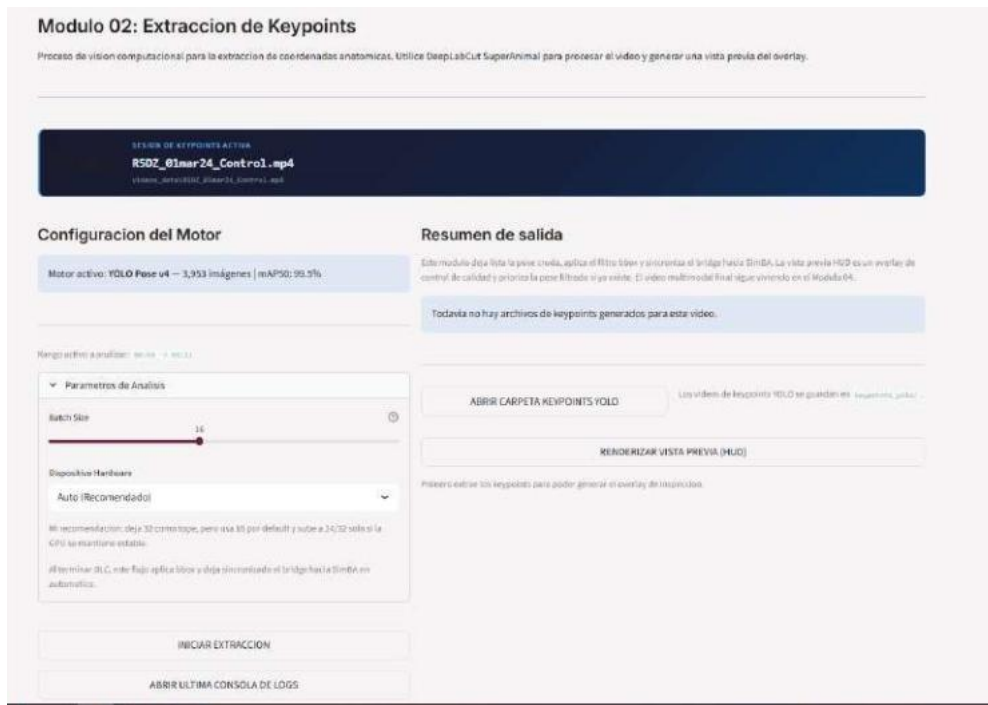


Ilustración 92: Vista general del módulo de keypoints [autoría propia]




Ilustración 93: Botón de inicio de extracción de keypoints [autoría propia]

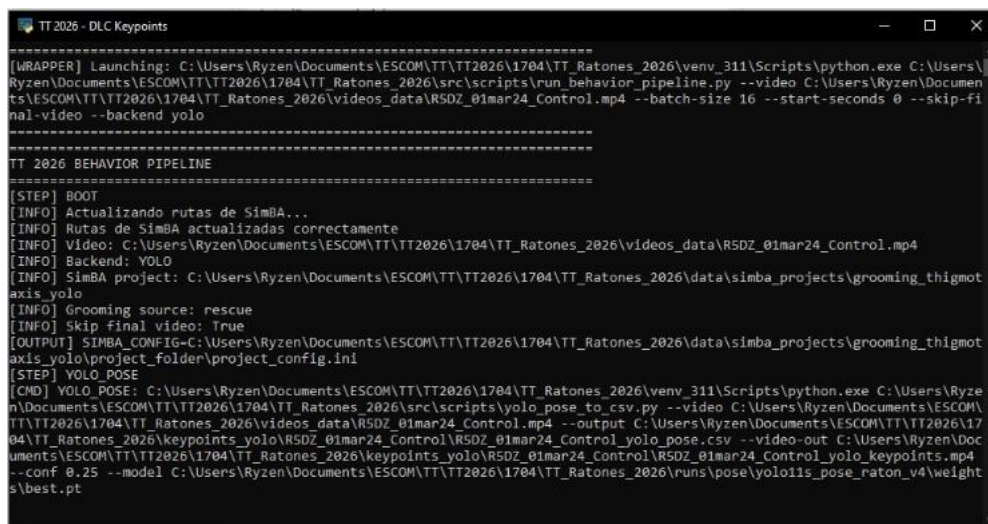


Ilustración 94: Consola de comandos abierta al iniciar la extracción de keypoints [autoría propia]



Ilustración 95: Pantalla de carga mostrada durante la extracción de keypoints con advertencias del proceso [autoría propia]

```
Extrayendo keypoints con YOLO Pose...

=====
[WRAPPER] Launching: C:\Users\Ryzen\Documents\ESCOM\TT\TT2026\1704\TT_Ratones_2026\venv_311\Scripts\python.exe C:\Users\Ryzen\Documents\ESCOM\TT\TT2026\1704\
=====

TT_2026 BEHAVIOR PIPELINE

[STEP] BOOT
[INFO] Actualizando rutas de SimBA...
[INFO] Rutas de SimBA actualizadas correctamente
[INFO] Video: C:\Users\Ryzen\Documents\ESCOM\TT\TT2026\1704\TT_Ratones_2026\videos_data\830Z_03mar28_Control1.mp4
[INFO] Backend: YOLO
[INFO] SimBA project: C:\Users\Ryzen\Documents\ESCOM\TT\TT2026\1704\TT_Ratones_2026\data\simba_projects\grooming_thigmotaxis_yolo
[INFO] Grooming source: rescue
[INFO] Skip final video: true
[OUTPUT] SIMBA_CONF26=C:\Users\Ryzen\Documents\ESCOM\TT\TT2026\1704\TT_Ratones_2026\data\simba_projects\grooming_thigmotaxis_yolo\project_folder\project_conf
[STEP] YOLO_POSE
[END] YOLO_POSE: C:\Users\Ryzen\Documents\ESCOM\TT\TT2026\1704\TT_Ratones_2026\venv_311\Scripts\python.exe C:\Users\Ryzen\Documents\ESCOM\TT\TT2026\1704\TT_R
```

Ilustración 96: Consola de comandos mostrada en el sistema durante la extracción de keypoints [autoría propia]

```
=====
SUCCESS: Keypoints prep pipeline complete.
=====

[WRAPPER] Child exit code: 0
```

Ilustración 97: Consola de comandos mostrando salida con éxito después de la extracción de keypoints [autoría propia]

7.3.10 Paso 4 – Configuración de zonas del EPM

El usuario ajusta las coordenadas de las zonas del EPM para el video. El sistema ofrece una configuración predeterminada basada en plantillas, que el usuario puede modificar mediante controles en la interfaz. Las zonas se guardan y sincronizan automáticamente con el proyecto SimBA activo.



Ilustración 98: Acceso al módulo de configuración de zonas [autoría propia]

Módulo 03: Configuración de Zonas (ROI)

Defina los límites anatómicos del laberinto sobre el video experimental. Las coordenadas se escalarán automáticamente a la resolución original del video.

Aquí defines las 6 paredes que después se sincronizan a SimbA. Las demás zonas de interés se conservan para el módulo de resultado final.

Herramientas de Dibujo

Clasificación de ROI:

- ☒ Brazo Abierto
- ☐ Brazo Cerrado
- ☐ Centro
- ☐ Muro / Pared

Modo de Interacción:

- ☒ Dibujar rectángulos
- ☐ Mover / Editar

CARGAR PLANTILLA (EPM)

LIMPIAR LIENZO

Lienzo de Configuración

(Dibuje rectángulos de interés sobre el fotograma del video)



Ilustración 99: Vista general del módulo de configuración de zonas [autoría propia]

Herramientas de Dibujo

Clasificación de ROI:

- ☒ Brazo Abierto
- ☐ Brazo Cerrado
- ☐ Centro
- ☐ Muro / Pared

Modo de Interacción:

- ☒ Dibujar rectángulos
- ☐ Mover / Editar

Ilustración 100: Apartado de herramientas de definición de zonas [autoría propia]



Ilustración 101: Apartado de lienzo. Los brazos abiertos (morado), brazos cerrados (gris), centro (gris claro) y muro (naranja) deben ser dibujados [autoría propia]

Zonas Detectadas

Las coordenadas mostradas abajo se quedarán convertidas a la resolución real del vídeo.

Nombre Zona	Tipo	Geometría	left	top	width	height	x1	y1	x2	y2
Brazo Abierto 1	Brazo Abierto	Rectángulo	606	14	69	293	None	None	None	None
Brazo Abierto 2	Brazo Abierto	Rectángulo	602	365	72	299	None	None	None	None
Brazo Cerrado 1	Brazo Cerrado	Rectángulo	218	282	382	106	None	None	None	None
Brazo Cerrado 2	Brazo Cerrado	Rectángulo	675	290	363	88	None	None	None	None
Centro	Centro	Rectángulo	598	301	75	74	None	None	None	None
Pared 1	Muro / Pared	Línea	None	None	None	None	221	293	579	298
Pared 2	Muro / Pared	Línea	None	None	None	None	222	293	221	306
Pared 3	Muro / Pared	Línea	None	None	None	None	222	874	587	329
Pared 4	Muro / Pared	Línea	None	None	None	None	682	296	1005	301
Pared 5	Muro / Pared	Línea	None	None	None	None	1006	299	1009	323

Ilustración 102: Tabla de características de zonas detectadas [autoría propia]



Ilustración 103: Botón de guardado de configuración del experimento [autoría propia]

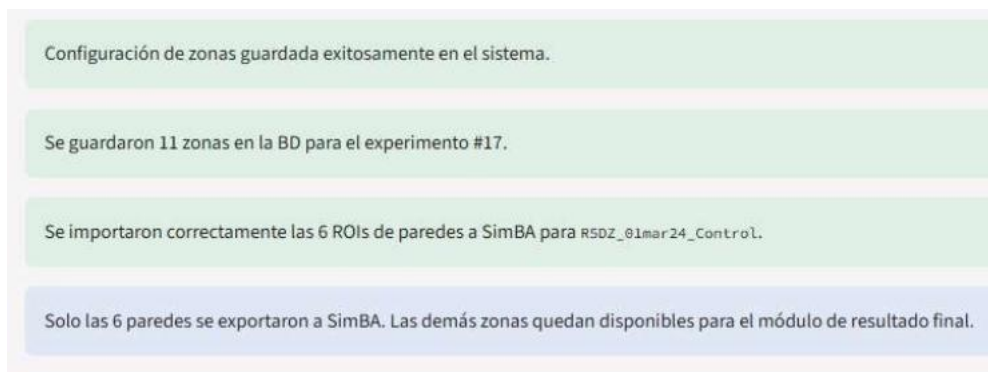


Ilustración 104: Mensaje de guardado exitoso de configuración del experimento [autoría propia]

7.3.11 Paso 5 – Análisis final

El usuario lanza el análisis final desde la página correspondiente. El sistema ejecuta las etapas de conversión YOLO–SimBA, cómputo de características e inferencia conductual de forma automática y secuencial. Al finalizar, el video multimodal y las métricas quedan disponibles en la base de datos.



Ilustración 105: Acceso al módulo de análisis final [autoría propia]

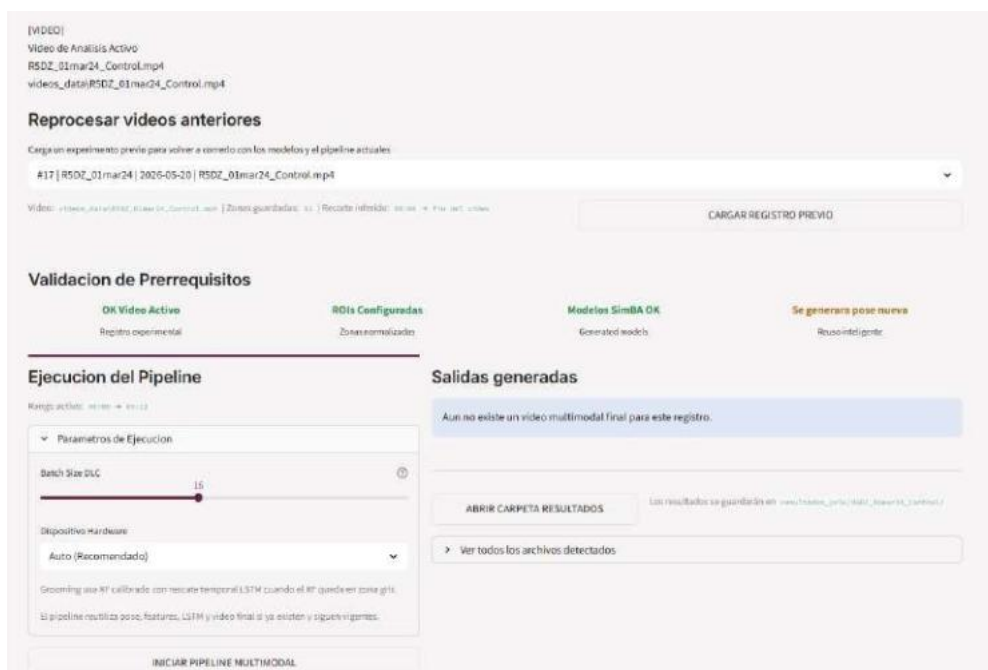


Ilustración 106: Vista general del módulo de análisis final [autoría propia]



Ilustración 107: Configuración del batch de análisis final [autoría propia]




Ilustración 108: Botón para iniciar análisis final [autoría propia]

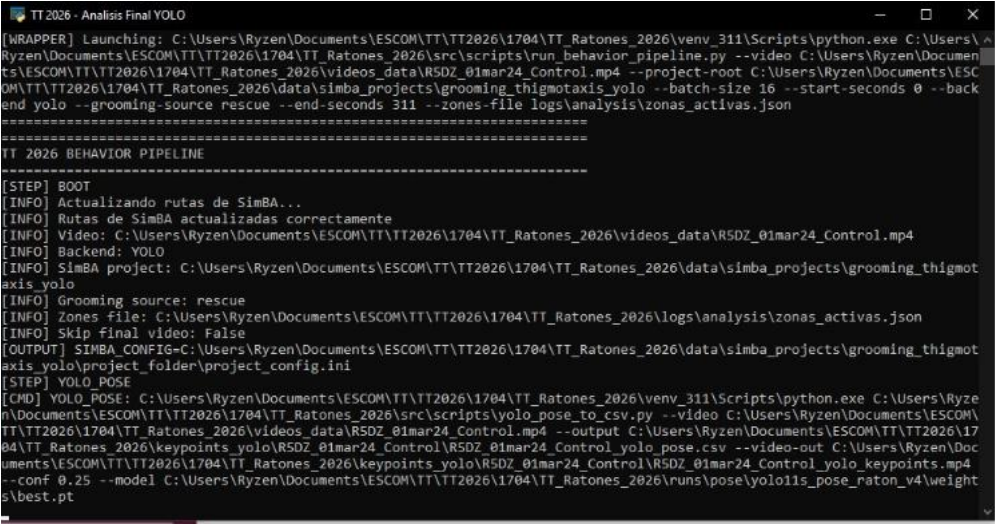


Ilustración 109: Consola de comandos abierta al iniciar el análisis final [autoría propia]



Ilustración 110: Pantalla de carga mostrada durante el análisis final con advertencias del proceso [autoría propia]



Ilustración 111: Consola de comandos mostrada en el sistema durante el análisis final [autoría propia]



Ilustración 112: Consola de comandos mostrando salida con éxito después de haber ejecutado el análisis final [autoría propia]

7.3.12 Paso 6 – Consulta de resultados

El usuario accede al dashboard de resultados para revisar las métricas cuantitativas del experimento, visualizar el video multimodal y descargar los archivos de timelogs conductuales para análisis estadístico posterior. Si cuenta con permisos de administrador o investigador propietario del experimento, puede activar el modo de edición para corregir los tiempos agregados de brazos abiertos, brazos cerrados, grooming y thigmotaxis. El sistema exige un motivo de edición, actualiza las métricas persistentes y conserva el historial completo para auditoría y reversión.




Ilustración 113: Acceso al módulo de resultados y estadísticas [autoría propia]

Vista del historial

Todos

Total experimentos: 16 Último registro: 2026-05-20 Prom. abiertos: 186.2s Prom. grooming: 32.0s

Filtra registros y luego selecciona uno para ver detalles y graficas.

Buscar sujeto o responsable: Filtrar por tratamiento: Todos Estado: Todos

☐ Mostrar solo mis experimentos (para poder editarlos)

Hay experimentos de otros investigadores en la vista actual. Filtra para ver solo tus experimentos y poder editarlos. (Tienes 2 experimento(s) propio(s) en esta vista)

Señal	ID	Sujeto	Tratamiento	Fecha	Responsable	Abiertos (s)	Cerrados (s)	Grooming (s)	Thigmotaxis (s)	Estado
☐	17	RSDZ_01mar24	Control	2026-05-20	Gabriela Lizano Villar	272.2	28.1	5.6	3.8	completed
☐	16	MOUSE-015-1185	Control	2026-05-11	Ernesto Javier Márquez Palacios	269.2	28.1	5.1	4.6	completed
☐	15	VH-R1	Diazepam Smg.	2026-05-09	Habid Portocarrero Rodriguez	178.4	101.9	13.1	14.9	completed
☐	14	MOUSE-013-0705	Control	2026-05-08	Gabriela Lizano Villar	180.4	103.0	13.0	14.0	completed
☐	12	MOUSE-012-PV26	Control	2026-04-27	Habid Portocarrero Rodriguez	230.0	25.0	147.0	1.0	completed
☐	11	MOUSE-011-PV25	Control	2026-04-27	Habid Portocarrero Rodriguez	160.4	87.4	25.2	4.8	completed
☐	10	MOUSE-010-PV25	Control	2026-04-27	Habid Portocarrero Rodriguez	103.9	160.5	61.0	1.4	completed
☐	9	MOUSE-009-PV26	Control	2026-04-27	Habid Portocarrero Rodriguez	226.1	67.9	56.1	7.0	completed
☐	8	MOUSE-008-PV26	Control	2026-04-27	Habid Portocarrero Rodriguez	222.4	54.4	56.0	1.4	completed
☐	7	MOUSE-007-PV25	Diazepam Smg.	2026-04-27	Habid Portocarrero Rodriguez	132.4	89.2	26.3	4.6	completed

Mueve a una o varias casillas para visualizar comparativas y detalles.

Selecciona al menos un experimento en la tabla para ver sus graficas y detalles.

Ilustración 114: Vista general del módulo de resultados y estadísticas [autoría propia]

Señal	ID	Sujeto	Tratamiento	Fecha	Responsable	Abiertos (s)	Cerrados (s)	Grooming (s)	Thigmotaxis (s)	Estado
☐	17	RSDZ_01mar24	Control	2026-05-20	Gabriela Lizano Villar	272.2	28.1	5.6	3.8	completed
☐	16	MOUSE-015-1185	Control	2026-05-11	Ernesto Javier Márquez Palacios	269.2	28.1	5.1	4.6	completed
☐	15	VH-R1	Diazepam Smg.	2026-05-09	Habid Portocarrero Rodriguez	178.4	101.9	13.1	14.9	completed
☐	14	MOUSE-013-0705	Control	2026-05-08	Gabriela Lizano Villar	180.4	103.0	13.0	14.0	completed
☐	12	MOUSE-012-PV26	Control	2026-04-27	Habid Portocarrero Rodriguez	230.0	25.0	147.0	1.0	completed
☐	11	MOUSE-011-PV25	Control	2026-04-27	Habid Portocarrero Rodriguez	160.4	87.4	25.2	4.8	completed
☐	10	MOUSE-010-PV25	Control	2026-04-27	Habid Portocarrero Rodriguez	103.9	160.5	61.0	1.4	completed
☐	9	MOUSE-009-PV26	Control	2026-04-27	Habid Portocarrero Rodriguez	226.1	67.9	56.1	7.0	completed
☐	8	MOUSE-008-PV26	Control	2026-04-27	Habid Portocarrero Rodriguez	222.4	54.4	56.0	1.4	completed
☐	7	MOUSE-007-PV25	Diazepam Smg.	2026-04-27	Habid Portocarrero Rodriguez	132.4	89.2	26.3	4.6	completed

Ilustración 115: Tabla general de experimentos y sus resultados [autoría propia]

Buscar sujeto o responsable: Filtrar por tratamiento: Todos Estado: Todos

☐ Mostrar solo mis experimentos (para poder editarlos)

Ilustración 116: Clasificación de experimentos por responsable, tratamiento y estado [autoría propia]

☒ 12 MOUSE-012-PV26

Ilustración 117: Selección singular de un experimento [autoría propia]



Ilustración 118: Información de un experimento [autoría propia]



Ilustración 119: Información gráfica de un experimento [autoría propia]



Ilustración 120: Mapa de calor de un experimento [autoría propia]

Descargar Reportes

CSV

JSON

PDF

Datos tabulares compatibles con Excel

Formato estructurado para APIs

Reporte profesional imprimible

Ilustración 121: Apartado de descarga de reportes en diferentes formatos [autoría propia]




Ilustración 122: Múltiples reportes en diferentes formatos descargados [autoría propia]

☒	12	MOUSE-012-PV26
☒	11	MOUSE-011-PV26
☒	10	MOUSE-010-PV26

Ilustración 123: Selección de múltiples experimentos [autoría propia]




Ilustración 124: Comparación rápida de múltiples experimentos [autoría propia]

☐ Confirmando que deseo borrar los experimentos seleccionados que me pertenecen.

BORRAR MIS EXPERIMENTOS SELECCIONADOS

Ilustración 125: Borrado de experimentos pertenecientes al usuario [autoría propia]

7.3.13 Paso 7 – Comparación de resultados

El usuario puede acceder al módulo de comparación para comparar dos grupos de experimentos con 6 a 8 experimentos por grupos. La comparación puede ser realizada por estudiantes, investigadores y administradores sin restricción. Se pueden obtener representaciones gráficas y datos crudos así como en respectivos reportes para descargar.



Ilustración 126: Acceso del módulo de comparación [autoría propia]

Módulo 06: Comparación de Grupos Experimentales

Genera tablas consolidadas con estadísticas descriptivas por grupo de tratamiento. Exporta datos formateados para análisis estadístico (ANOVA, prueba t, etc.). Recomendadas 6-8 ratas por grupo para validez estadística.

Selección Manual de Experimentos para Comparación

Instrucciones:

1. Selecciona el tratamiento para cada grupo
2. Selecciona los experimentos específicos que desees incluir de cada tratamiento
3. Cada grupo debe tener entre 6 y 8 experimentos (válido para análisis estadísticos)
4. Ambos grupos deben tener la misma cantidad de experimentos
5. Presiona el botón Comparar para generar el análisis

Grupo 1	Grupo 2
Tratamiento para Grupo 1: Control	Tratamiento para Grupo 2: Diazepam 5mg
Experimentos disponibles: 9	Experimentos disponibles: 7
Selecciona experimentos para Grupo 1: Choose options	Selecciona experimentos para Grupo 2: Choose options
Selecciona entre 6 y 8 experimentos	Selecciona entre 6 y 8 experimentos

Debes seleccionar experimentos en ambos grupos antes de comparar.

Ilustración 127: Vista general del módulo de comparación [autoría propia]

Grupo 1	Grupo 2
Tratamiento para Grupo 1: Control	Tratamiento para Grupo 2: Diazepam 5mg
Experimentos disponibles: 9	Experimentos disponibles: 7
Selecciona experimentos para Grupo 1: Choose options	Selecciona experimentos para Grupo 2: Choose options
Selecciona entre 6 y 8 experimentos	Selecciona entre 6 y 8 experimentos

Ilustración 128: Selección de grupos de experimentos y sus experimentos [autoría propia]

Selecciona experimentos para Grupo 1: Experimento 1 Experimento 2 Experimento 3 Experimento 4 Experimento 5 Experimento 6 Experimento 7 Experimento 8	Selecciona experimentos para Grupo 2: Experimento 1 Experimento 2 Experimento 3 Experimento 4 Experimento 5 Experimento 6 Experimento 7 Experimento 8
Experimentos seleccionados: 6 ✓	Experimentos seleccionados: 5 (mínimo requerido: 6)
Grupo 2: Se requieren entre 6 y 8 experimentos (actualmente: 5)	

Ilustración 129: Validación de experimentos seleccionados [autoría propia]

Selecciona experimentos para Grupo 1: Experimento 1 Experimento 2 Experimento 3 Experimento 4 Experimento 5 Experimento 6 Experimento 7 Experimento 8	Selecciona experimentos para Grupo 2: Experimento 1 Experimento 2 Experimento 3 Experimento 4 Experimento 5 Experimento 6 Experimento 7 Experimento 8
Experimentos seleccionados: 6 ✓	Experimentos seleccionados: 6 ✓
✓ Validación exitosa: Ambos grupos tienen 6 experimento(s) seleccionado(s)	
Comparar Grupos	
Presiona el botón "Comparar Grupos" para generar el análisis estadístico.	

Ilustración 130: Validación de experimentos exitosa [autoría propia]

Comparar Grupos

Ilustración 131: Botón de comparación de grupos [autoría propia]

Datos Individuales por Sujeto Nueva Comparación

Resumen de Experimentos Seleccionados

Grupo	ID Ratón	Tratamiento	Fecha	T. Abiertos (s)	T. Cerrados (s)	T. Centro (s)	Grooming (s)	Tigrotaxis (s)
Grupo 1	R502_01mar24	Control	2026-05-20	272.136431	26.064631	6.760880	5.599588	1.632808
Grupo 1	MOUSE-615-1105	Control	2026-05-11	269.211399	26.064631	11.595138	5.064303	4.632001
Grupo 1	MOUSE-613-6705	Control	2026-05-08	186.429040	103.800900	27.596344	11.890300	14.623001
Grupo 1	MOUSE-608-PV26	Control	2026-04-27	222.391756	14.387963	18.220614	16.000000	1.366616
Grupo 1	MOUSE-609-PV26	Control	2026-04-27	226.086360	67.862715	17.765643	16.096784	6.995096
Grupo 1	MOUSE-610-PV26	Control	2026-04-27	183.897456	160.462743	22.466217	61.000000	1.433298
Grupo 2	VH-R1	Diazepam 5mg	2026-05-09	178.395775	163.864254	26.695697	13.099600	14.866315
Grupo 2	MOUSE-604-PV26	Diazepam 5mg	2026-04-27	141.527913	153.360335	5.099787	18.260986	8.866304
Grupo 2	MOUSE-605-PV26	Diazepam 5mg	2026-04-27	194.153717	92.860473	12.032531	10.290313	4.166380
Grupo 2	MOUSE-606-PV26	Diazepam 5mg	2026-04-27	140.196029	133.036336	16.065889	9.612884	1.902000

Ilustración 132: Tabla de datos individuales por experimento que incluye tiempo en brazos, grooming y tigrotaxis [autoría propia]

Estadísticas Descriptivas por Grupo

Tabla consolidada para análisis estadístico (ANOVA, prueba t)

Variable	Grupo	Tratamiento	N	Media	Desv. Est.	Error Est.	Mínimo	Máximo
Tiempo Brazos Abiertos (s)	Grupo 1	Control	6	212.37	63.06	25.74	108.9	272.18
Tiempo Brazos Abiertos (s)	Grupo 2	Diazepam 5mg	6	186.17	46.25	18.88	141.53	267.75
Tiempo Brazos Cerrados (s)	Grupo 1	Control	6	73.64	50.91	20.78	28.06	160.46
Tiempo Brazos Cerrados (s)	Grupo 2	Diazepam 5mg	6	96.93	43.56	17.78	25.23	151.36
Tiempo Centro (s)	Grupo 1	Control	6	16.68	7.31	2.99	9.77	27.7
Tiempo Centro (s)	Grupo 2	Diazepam 5mg	6	12.4	9.13	3.81	3.1	29.7
Grooming (s)	Grupo 1	Control	6	32.79	27.49	11.22	5.07	61
Grooming (s)	Grupo 2	Diazepam 5mg	6	16.07	8.57	3.5	5.03	26.27
Tigrotaxis (s)	Grupo 1	Control	6	5.38	4.74	1.93	1.37	14.63
Tigrotaxis (s)	Grupo 2	Diazepam 5mg	6	5.61	5.43	2.21	0.33	14.87

Ilustración 133: Tabla de datos estadísticos por grupo que incluye media, desviación estándar, error estándar, máximo y mínimo por categoría de tiempo [autoría propia]



Ilustración 134: Comparación visual por grupos con respecto a tiempos [autoría propia]



Ilustración 135: Sección de descarga de reportes en diferentes formatos [autoría propia]




Ilustración 136: Reportes en diferentes formatos descargados [autoría propia]

Conclusiones

Este proyecto fue una oportunidad para demostrar que la tecnología puede ser un puente entre la ciencia y la empatía. No se trató solo de diseñar un prototipo, sino de comprender cómo la automatización puede aportar valor a la investigación y a la interpretación del comportamiento. Cada línea de código y cada iteración reflejan el esfuerzo colectivo de un equipo que aprendió a resolver problemas reales con una visión ética, científica y humana.

Además, el trabajo realizado abre un horizonte de posibilidades para el futuro. Su estructura escalable y adaptable permite que este prototipo evolucione y se integre en otros proyectos de investigación, ampliando su alcance más allá de los modelos de ansiedad. En ese camino, también se generarán

nuevos aprendizajes, retos y descubrimientos que fortalecerán no solo la herramienta, sino también la formación profesional y humana de quienes la desarrollan.

En suma, este proyecto no solo representa un logro técnico, sino el inicio de una línea de trabajo prometedora, donde la innovación y la curiosidad seguirán guiando cada paso hacia soluciones más precisas, accesibles y con impacto real en la ciencia.

Trabajo a futuro

El desarrollo de este proyecto se concibe como un proceso en constante evolución, donde cada iteración permitirá refinar los objetivos, validar resultados y fortalecer la integración entre los distintos actores involucrados. Siguiendo el **modelo de Espiral de Boehm aplicado a la Ciencia de Datos**, el trabajo futuro estará orientado a consolidar las fases de análisis, diseño, desarrollo, validación y retroalimentación, garantizando la mejora continua del prototipo.

Durante las siguientes etapas, se prevé realizar **ajustes y correcciones al documento técnico**, integrando observaciones académicas y resultados experimentales que surjan durante las pruebas con los modelos de ansiedad. Estas revisiones permitirán mantener una documentación actualizada, precisa y alineada con las normas de calidad del ciclo de vida del software.

Asimismo, se fortalecerá la **comunicación entre la Escuela Superior de Cómputo (ESCOM) y la Escuela Nacional de Medicina y Homeopatía (ENMyH)**, mediante reuniones periódicas, validaciones conjuntas y revisión de resultados experimentales. Esta colaboración continua será esencial para asegurar que el prototipo responda adecuadamente a las necesidades reales del ámbito biomédico y mantenga coherencia con los protocolos experimentales.


Cada iteración incluirá la **identificación de riesgos técnicos y operativos**, así como la **planificación de estrategias de mitigación**, en aspectos como la calidad de video, procesamiento de datos, capacidad de cómputo y validez estadística. Dichos riesgos serán evaluados y documentados al inicio de cada ciclo, permitiendo decisiones informadas y oportunas para el desarrollo.

Finalmente, el proyecto continuará evolucionando hacia versiones más robustas, escalables y especializadas. Se contempla la ampliación del prototipo hacia otros modelos conductuales, la integración de procesamiento en tiempo real y la posibilidad de implementar arquitecturas en la nube que permitan un análisis colaborativo entre instituciones. Este trabajo futuro consolidará la visión del proyecto como una herramienta de apoyo científico, adaptable y en constante crecimiento.

Primer intento de migración e instalación del sistema en entorno Linux:

En el primer intento de migrar e instalar el sistema en Linux, realizado el miércoles 13 de mayo del año 2026, se encontraron varios problemas de compatibilidad, sobre todo con los controladores NVIDIA y la detección de las GPUs Tesla K80 que estaban disponibles en el servidor. Además, surgieron discrepancias entre las versiones de CUDA y PyTorch, así como con varias dependencias empleadas por SimBA y Streamlit. Estas incompatibilidades mostraron que el método de instalación propuesto originalmente necesitaba más ajustes para adaptarse apropiadamente al entorno Rocky Linux 9.7 y obstaculizaron el uso correcto de la aceleración por GPU.

Los resultados de este primer intento llevaron a replantear la estrategia de instalación. Se decidió dividir las dependencias y componentes del sistema en varios entornos virtuales Conda para reducir los conflictos de compatibilidad y conseguir que la instalación del sistema fuera funcional.



```
Windows PowerShell
Copyright (C) Microsoft Corporation. Todos los derechos reservados.

Instale la versión más reciente de PowerShell para obtener nuevas características y mejoras. https://aka.ms/PSWindows

PS C:\WINDOWS\system32> ssh luis@148.204.63.158
The authenticity of host '148.204.63.158 (148.204.63.158)' can't be established.
ED25519 key fingerprint is SHA256:mLoGynBsLOSGHS6j4ZumVtFRq5TUHKN5HuTzN5BRV0o.
This key is not known by any other names.
Are you sure you want to continue connecting (yes/no/[fingerprint])? yes
Warning: Permanently added '148.204.63.158' (ED25519) to the list of known hosts.
luis@148.204.63.158's password:
Activate the web console with: systemctl enable --now cockpit.socket

Last login: Wed May 13 12:52:05 2026 from 148.204.64.94
(base) [luis@ibh1 ~]$ df -h
```

Ilustración 137: Acceso al clúster en consola [autoría propia]

```
luis@ibh1:~  
(base) [luis@ibh1 ~]$ conda create -n 2026A155 python=3.11  
2 channel Terms of Service accepted  
Channels:  
- conda-forge  
- defaults  
Platform: linux-64  
Collecting package metadata (repodata.json): done  
Solving environment: done  
  
==> WARNING: A newer version of conda exists. <==  
current version: 26.1.1  
latest version: 26.3.2  
  
Please update conda by running  
  
$ conda update -n base -c conda-forge conda  
  
## Package Plan ##  
  
environment location: /home/luis/miniconda3/envs/2026A155  
  
added / updated specs:  
- python=3.11  
  
The following packages will be downloaded:  
  
package | build | size | channel  
-----|-----|-----|-----  
_openmp_mutex-4.5 | 20_gnu | 28 KB | conda-forge  
ld_impl_linux-64-2.45.1 | default_hbd61a6d_102 | 711 KB | conda-forge  
libexpat-2.8.0 | hecca717_0 | 75 KB | conda-forge  
libgcc-15.2.0 | he0feb66_19 | 1017 KB | conda-forge
```

Ilustración 138: Creación del entorno virtual [autoría propia]

```
(base) [luis@ibh1 ~]$ conda env list

# conda environments:
#
# * -> active
# + -> frozen
base                * /home/luis/miniconda3
2026A155            /home/luis/miniconda3/envs/2026A155
cv                  /home/luis/miniconda3/envs/cv
llm-k80             /home/luis/miniconda3/envs/llm-k80
mi_env              /home/luis/miniconda3/envs/mi_env
tf-cpu              /home/luis/miniconda3/envs/tf-cpu
torch-k80           /home/luis/miniconda3/envs/torch-k80

(base) [luis@ibh1 ~]$ conda activate 2026A155
(2026A155) [luis@ibh1 ~]$ pip
```

Ilustración 139: Confirmación de creación y entrada del entorno virtual [autoría propia]

```
luis@ibh1:~
(2026A155) [luis@ibh1 ~]$ sudo dnf update -y
[sudo] password for luis:
Last metadata expiration check: 1:37:02 ago on Wed 13 May 2026 04:52:51 PM C
ST.
Dependencies resolved.
=====
Package                        Arch    Version                                Repo    Size
=====
Installing:
kernel                         x86_64  5.14.0-611.54.1.el9_7                baseos  1.1 M
Upgrading:
NetworkManager                 x86_64  1:1.54.0-4.el9_7                     baseos  2.3 M
```

Ilustración 140: Actualización y habilitación de repositorios [autoría propia]

```
Complete!
(2026A155) [luis@ibh1 ~]$ sudo dnf install epel-release -y
[sudo] password for luis:
Last metadata expiration check: 1:54:41 ago on Wed 13 May 2026 04:52:51 PM C
ST.
Package epel-release-9-10.el9.noarch is already installed.
Dependencies resolved.
Nothing to do.
Complete!
(2026A155) [luis@ibh1 ~]$ sudo dnf config-manager --enable crb
(2026A155) [luis@ibh1 ~]$
```

Ilustración 141: Habilitación EPEL y CodeReady (CRB) para dependencias de instalación [autoría propia]

```
(2026A155) [luis@ibh1 ~]$ sudo dnf groupinstall "Development Tools" -y
Rocky Linux 9 - BaseOS                6.1 kB/s | 3.9 kB      00:00
Rocky Linux 9 - AppStream              8.0 kB/s | 4.3 kB      00:00
Rocky Linux 9 - CRB                   7.5 kB/s | 4.3 kB      00:00
Dependencies resolved.
=====
Package                Architecture      Version           Repository        Size
=====
Installing Groups:
Development Tools

Transaction Summary
=====
Complete!
```

Ilustración 142: Instalación de herramientas de desarrollo: grupo “Development Tools” [autoría propia]

```
(2026A155) [luis@ibh1 ~]$ sudo dnf install kernel-devel-matched kernel-headers -y
Last metadata expiration check: 0:00:34 ago on Wed 13 May 2026 06:49:30 PM C
ST.
Package kernel-headers-5.14.0-611.54.1.el9_7.x86_64 is already installed.
Dependencies resolved.
=====
Package                Arch      Version           Repository        Size
=====
Installing:
kernel-devel-matched    x86_64    5.14.0-611.54.1.el9_7    appstream        1.1 M

Transaction Summary
=====
Install 1 Package

Total download size: 1.1 M
Installed size: 0
Downloading Packages:
kernel-devel-matched-5.14.0-611.54.1.el9_7. 2.8 MB/s | 1.1 MB      00:00
-----
Total                                1.7 MB/s | 1.1 MB      00:00
Running transaction check
Transaction check succeeded.
Running transaction test
Transaction test succeeded.
Running transaction
  Preparing      :                                1/1
  Installing     : kernel-devel-matched-5.14.0-611.54.1.el9_7.x86_6 1/1
  Verifying      : kernel-devel-matched-5.14.0-611.54.1.el9_7.x86_6 1/1

Installed:
kernel-devel-matched-5.14.0-611.54.1.el9_7.x86_64

Complete!
```

Ilustración 143: Instalación de herramientas de desarrollo: paquetes de cabeceras del kernel [28:L630-L638] [autoría propia]

```
(2026A155) [luis@ibh1 ~]$ sudo dnf install git wget bzip2 -y
Last metadata expiration check: 0:02:31 ago on Wed 13 May 2026 06:49:30 PM C
ST.
Package git-2.47.3-1.el9_6.x86_64 is already installed.
Package wget-1.21.1-8.el9_4.x86_64 is already installed.
Package bzip2-1.0.8-10.el9_5.x86_64 is already installed.
Dependencies resolved.
Nothing to do.
Complete!
```

Ilustración 144: Instalación de utilidades adicionales para manejo de archivos [autoría propia]

```
(2026A155) [luis@ibh1 ~]$ sudo dnf install ffmpeg -y
Last metadata expiration check: 0:02:41 ago on Wed 13 May 2026 06:49:30 PM C
ST.
No match for argument: ffmpeg
Error: Unable to find a match: ffmpeg
```

Ilustración 145: Primer intento de instalación de la herramienta ffmpeg con error [autoría propia]

```
(2026A155) [luis@ibh1 ~]$ sudo dnf install \
https://download1.rpmfusion.org/free/el/rpmfusion-free-release-9.noarch.rpm
-y
[sudo] password for luis:
Sorry, try again.
[sudo] password for luis:
Last metadata expiration check: 0:07:55 ago on Wed 13 May 2026 06:49:30 PM C
ST.
rpmfusion-free-release-9.noarch.rpm          15 kB/s | 10 kB      00:00
Dependencies resolved.
=====
Package                                Arch      Version      Repository      Size
=====
Installing:
rpmfusion-free-release                 noarch    9-1          @commandline    10 k

Transaction Summary
=====
Install 1 Package

Total size: 10 k
Installed size: 3.8 k
Downloading Packages:
Running transaction check
Transaction check succeeded.
Running transaction test
Transaction test succeeded.
Running transaction
  Preparing      :                                1/1
  Installing     : rpmfusion-free-release-9-1.noarch 1/1
  Verifying      : rpmfusion-free-release-9-1.noarch 1/1

Installed:
rpmfusion-free-release-9-1.noarch

Complete!
```

Ilustración 146: Instalación de RPM Fusion [autoría propia]

```
(2026A155) [luis@ibh1 ~]$ sudo dnf makecache
Extra Packages for Enterprise Linux 9 - x86_64 95 kB/s | 33 kB 00:00
Extra Packages for Enterprise Linux 9 - x86_64 8.4 MB/s | 21 MB 00:02
Extra Packages for Enterprise Linux 9 openh 4.4 kB/s | 993 B 00:00
Rocky Linux 9 - BaseOS 6.6 kB/s | 4.3 kB 00:00
Rocky Linux 9 - BaseOS 5.2 MB/s | 21 MB 00:03
Rocky Linux 9 - AppStream 8.0 kB/s | 4.3 kB 00:00
Rocky Linux 9 - CRB 8.4 kB/s | 4.3 kB 00:00
Rocky Linux 9 - Extras 4.9 kB/s | 3.1 kB 00:00
RPM Fusion for EL 9 - Free - Updates 196 kB/s | 229 kB 00:01
Metadata cache created.
(2026A155) [luis@ibh1 ~]$ sudo dnf install ffmpeg ffmpeg-devel -y
Last metadata expiration check: 0:00:15 ago on Wed 13 May 2026 06:58:00 PM C
ST.
Dependencies resolved.
=====
Package Arch Version Repository Size
=====
Installing:
ffmpeg x86_64 5.1.9-1.el9 rpmfusion-free-updates 1.7 M
ffmpeg-devel x86_64 5.1.9-1.el9 rpmfusion-free-updates 801 k
```

Ilustración 147: Actualización de metadata [autoría propia]

```
(2026A155) [luis@ibh1 ~]$ sudo dnf install ffmpeg ffmpeg-devel -y
Last metadata expiration check: 0:00:15 ago on Wed 13 May 2026 06:58:00 PM C
ST.
Dependencies resolved.
=====
Package Arch Version Repository Size
=====
Installing:
ffmpeg x86_64 5.1.9-1.el9 rpmfusion-free-updates 1.7 M
```

Ilustración 148: Segundo intento de instalación de la herramienta ffmpeg con éxito [autoría propia]

```
(2026A155) [luis@ibh1 ~]$ sudo dnf config-manager --add-repo \
http://developer.download.nvidia.com/compute/cuda/repos/rhel9/$(uname -m)/cu
da-rhel9.repo
Adding repo from: http://developer.download.nvidia.com/compute/cuda/repos/rh
el9/x86_64/cuda-rhel9.repo
(2026A155) [luis@ibh1 ~]$ sudo dnf clean expire-cache
Cache was expired
0 files removed
```

Ilustración 149: Instalación de drivers primera parte [autoría propia]

```
(2026A155) [luis@ibh1 ~]$ sudo dnf install cuda-drivers -y
cuda-rhel9-x86_64 2.4 MB/s | 4.4 MB 00:01
Last metadata expiration check: 0:00:01 ago on Wed 13 May 2026 07:03:19 PM C
ST.
All matches were filtered out by modular filtering for argument: cuda-driver
s
Error: Unable to find a match: cuda-drivers
```

Ilustración 150: Instalación de drivers segunda parte [autoría propia]

```
(2026A155) [luis@ibh1 ~]$ sudo dnf module disable nvidia-driver -y
Last metadata expiration check: 0:01:07 ago on Wed 13 May 2026 07:03:19 PM C
ST.
Dependencies resolved.
=====
Package                Architecture      Version           Repository        Size
=====
Disabling modules:
nvidia-driver

Transaction Summary
=====
Complete!
```

Ilustración 151: Deshabilitación del módulo del drive [autoría propia]

```
(2026A155) [luis@ibh1 ~]$ sudo dnf clean all
sudo dnf makecache
65 files removed
cuda-rhel9-x86_64                3.5 MB/s | 4.4 MB      00:01
Extra Packages for Enterprise Linux 9 - x86 11 MB/s | 21 MB      00:01
Extra Packages for Enterprise Linux 9 openh 2.5 kB/s | 2.5 kB      00:00
Rocky Linux 9 - BaseOS           13 MB/s | 21 MB      00:01
Rocky Linux 9 - AppStream        13 MB/s | 19 MB      00:01
Rocky Linux 9 - CRB              4.1 MB/s | 4.5 MB      00:01
Rocky Linux 9 - Extras           30 kB/s | 17 kB      00:00
RPM Fusion for EL 9 - Free - Updates 304 kB/s | 229 kB     00:00
Metadata cache created.
```

Ilustración 152: Limpieza de caché de drivers [autoría propia]

```
WARNING: You do not appear to have an NVIDIA GPU supported by the
470.256.02 NVIDIA Linux graphics driver installed in this
system. For further details, please see the appendix SUPPORTED
NVIDIA GRAPHICS CHIPS in the README available on the Linux
driver download page at www.nvidia.com.
```



Ilustración 153: Mensaje de falta de detección de una GPU [autoría propia]

La advertencia mostrada durante la instalación confirmó que la versión del controlador NVIDIA instalada inicialmente no ofrecía soporte adecuado para las GPUs Tesla K80 presentes en el servidor. Como consecuencia, el sistema no logró reconocer correctamente el hardware gráfico disponible, impidiendo el uso funcional de CUDA y de bibliotecas dependientes de aceleración por GPU. Este problema permitió identificar uno de los principales factores de incompatibilidad del sistema en Linux y justificó la necesidad de replantear el procedimiento de instalación para el segundo intento.

Segundo intento de migración e instalación del sistema en Linux (exitoso):

La advertencia que se mostró durante la instalación corroboró que la versión inicial del controlador NVIDIA no era suficiente para las GPUs Tesla K80 que existían en el servidor. Por lo tanto, el sistema no pudo identificar adecuadamente el hardware gráfico disponible, lo que interfirió con la utilización funcional de CUDA y de las bibliotecas que dependen del aceleramiento por GPU. Este

inconveniente permitió reconocer uno de los factores de incongruencia más relevantes del sistema en Linux y fundamentó la necesidad de reconsiderar el método de instalación para el segundo intento.

```
(base) [josue@ibng2 ~]$ conda create -n TTRatatouille python=3.11 -y
2 channel Terms of Service accepted
Retrieving notices: done
Channels:
- defaults
Platform: linux-64
Collecting package metadata (repodata.json): done
Solving environment: done
```

Ilustración 154: Creación del entorno virtual [autoría propia]

```
Downloading and Extracting Packages:
Preparing transaction: done
Verifying transaction: done
Executing transaction: done
#
# To activate this environment, use
#
#     $ conda activate TTRatatouille
#
# To deactivate an active environment, use
#
#     $ conda deactivate
#
(base) [josue@ibng2 ~]$ conda activate TTRatatouille
(TTRatatouille) [josue@ibng2 ~]$ conda deactivate
(base) [josue@ibng2 ~]$
```

Ilustración 155: Confirmación de creación y entrada del entorno virtual [autoría propia]

En un principio, se creó y activó un entorno virtual Conda para evitar que las dependencias del sistema causaran conflictos con otras instalaciones de Python en el servidor Linux.

```
(TTRatatouille) [josue@ibng2 ~]$ sudo dnf update -y
```

We trust you have received the usual lecture from the local System Administrator. It usually boils down to these three things:

- #1) Respect the privacy of others.
- #2) Think before you type.
- #3) With great power comes great responsibility.

```
[sudo] password for josue:
Last metadata expiration check: 1:08:35 ago on Mon 18 May 2026 05:04:30 PM CST.
Dependencies resolved.
```

Package	Arch	Version	Repository	Size
Installing:				
kernel	x86_64	5.14.0-611.55.1.el9_7	baseos	1.1 M
kernel-devel	x86_64	5.14.0-611.55.1.el9_7	appstream	18 M
Upgrading:				
NetworkManager	x86_64	1:1.54.0-4.el9_7	baseos	2.3 M
NetworkManager-libnm	x86_64	1:1.54.0-4.el9_7	baseos	1.9 M
NetworkManager-team	x86_64	1:1.54.0-4.el9_7	baseos	35 k
NetworkManager-tui	x86_64	1:1.54.0-4.el9_7	baseos	246 k
PackageKit	x86_64	1.2.6-2.el9_7	appstream	617 k
PackageKit-glib	x86_64	1.2.6-2.el9_7	appstream	156 k
cifs-utils	x86_64	7.5-1.el9	baseos	113 k

Ilustración 156: Actualización y habilitación de repositorios [autoría propia]

```
(TTRatatouille) [josue@ibng2 ~]$ sudo dnf install epel-release -y
Last metadata expiration check: 1:28:24 ago on Mon 18 May 2026 05:04:30 PM CST.
Package epel-release-9-10.el9.noarch is already installed.
Dependencies resolved.
Nothing to do.
Complete!
(TTRatatouille) [josue@ibng2 ~]$ sudo dnf config-manager --enable crb
(TTRatatouille) [josue@ibng2 ~]$
```

Ilustración 157: Habilitación EPEL y CodeReady (CRB) para dependencias de instalación [autoría propia]

```
(TTRatatouille) [josue@ibng2 ~]$ sudo dnf groupinstall "Development Tools" -y
Rocky Linux 9 - BaseOS          9.9 kB/s | 4.3 kB    00:00
Rocky Linux 9 - AppStream       17 kB/s | 4.8 kB    00:00
Rocky Linux 9 - CRB             21 kB/s | 4.8 kB    00:00
Dependencies resolved.
```

Package	Architecture	Version	Repository	Size
Installing Groups:				
Development Tools				
Transaction Summary				
Complete!				

Ilustración 158: Instalación de herramientas de desarrollo: grupo "Development Tools" [autoría propia]

```
(TTRatatouille) [josue@ibng2 ~]$ sudo dnf install kernel-devel-matched kernel-headers -y
Last metadata expiration check: 0:00:51 ago on Mon 18 May 2026 06:34:35 PM CST.
Package kernel-devel-matched-5.14.0-611.55.1.el9_7.x86_64 is already installed.
Package kernel-headers-5.14.0-611.55.1.el9_7.x86_64 is already installed.
Dependencies resolved.
Nothing to do.
Complete!
```

Ilustración 159: Instalación de herramientas de desarrollo: paquetes de cabeceras del kernel [28:L630-L638] [autoría propia]

```
(TTRatatouille) [josue@ibng2 ~]$ sudo dnf install git wget bzip2 -y
Last metadata expiration check: 0:01:19 ago on Mon 18 May 2026 06:34:35 PM CST.
Package git-2.47.3-1.el9_6.x86_64 is already installed.
Package wget-1.21.1-8.el9_4.x86_64 is already installed.
Package bzip2-1.0.8-10.el9_5.x86_64 is already installed.
Dependencies resolved.
Nothing to do.
Complete!
```

Ilustración 160: Instalación de utilidades adicionales para manejo de archivos [autoría propia]

Más tarde, el sistema Rocky Linux fue configurado a través de la actualización de repositorios y la instalación de utilidades de compilación requeridas por varios paquetes y controladores del sistema.

```
(TTRatatouille) [josue@ibng2 ~]$ sudo dnf install ffmpeg -y
Last metadata expiration check: 0:01:41 ago on Mon 18 May 2026 06:34:35 PM CST.
No match for argument: ffmpeg
Error: Unable to find a match: ffmpeg
```

Ilustración 161: Primer intento de instalación de la herramienta ffmpeg con error [autoría propia]

```
(TTRatatouille) [josue@ibng2 ~]$ sudo dnf install \
https://download1.rpmfusion.org/free/el/rpmfusion-free-release-9.noarch.rpm -y
Last metadata expiration check: 0:05:59 ago on Mon 18 May 2026 06:34:35 PM CST.
rpmfusion-free-release-9.noarch.rpm 18 kB/s | 10 kB 00:00
Dependencies resolved.
=====
Package Architecture Version Repository Size
=====
Installing:
rpmfusion-free-release noarch 9-1 @commandline 10 k
Transaction Summary
=====
Install 1 Package

Total size: 10 k
Installed size: 3.8 k
Downloading Packages:
Running transaction check
Transaction check succeeded.
Running transaction test
Transaction test succeeded.
Running transaction
  Preparing : 1/1
  Installing : rpmfusion-free-release-9-1.noarch 1/1
  Verifying : rpmfusion-free-release-9-1.noarch 1/1

Installed:
rpmfusion-free-release-9-1.noarch

Complete!
```

Ilustración 162: Instalación de RPM Fusion [autoría propia]

```
(TTRatatouille) [josue@ibng2 ~]$ sudo dnf makecache
cuda-rhel9-x86_64 2.2 kB/s | 3.5 kB 00:01
ELRepo.org Community Enterprise Linux Repository - el9 7.5 kB/s | 3.0 kB 00:00
Extra Packages for Enterprise Linux 9 - x86_64 128 kB/s | 32 kB 00:00
Extra Packages for Enterprise Linux 9 openh264 (From Cisco) - x86_64 4.5 kB/s | 993 B 00:00
Rocky Linux 9 - BaseOS 11 kB/s | 4.3 kB 00:00
Rocky Linux 9 - AppStream 17 kB/s | 4.8 kB 00:00
Rocky Linux 9 - CRB 18 kB/s | 4.8 kB 00:00
Rocky Linux 9 - Extras 12 kB/s | 3.1 kB 00:00
RPM Fusion for EL 9 - Free - Updates 331 kB/s | 229 kB 00:00
Metadata cache created.
```

Ilustración 163: Actualización de metadata [autoría propia]

```
(TTRatatouille) [josue@ibng2 ~]$ sudo dnf install ffmpeg ffmpeg-devel -y
Last metadata expiration check: 0:01:09 ago on Mon 18 May 2026 06:41:27 PM CST.
Dependencies resolved.
=====
Package                Arch      Version              Repository            Size
=====
Installing:
ffmpeg                 x86_64    5.1.9-1.el9          rpmfusion-free-updates 1.7 M
ffmpeg-devel           x86_64    5.1.9-1.el9          rpmfusion-free-updates 801 k
Installing dependencies:
SDL2                   x86_64    2.26.0-1.el9         appstream              683 k
```

Ilustración 164: Segundo intento de instalación de la herramienta ffmpeg con éxito [autoría propia]

A causa de dificultades en la instalación inicial de FFmpeg, se hicieron necesarios repositorios adicionales a través de RPM Fusion para solucionar las dependencias multimedia que SimBA y las herramientas de tratamiento de video necesitaban.

```
(TTRatatouille) [josue@ibng2 ~]$ sudo dnf install cuda-drivers -y
cuda-rhel9-x86_64                                6.3 MB/s | 4.4 MB    00:00
ELRepo.org Community Enterprise Linux Repository - el9 208 kB/s | 227 kB    00:01
Extra Packages for Enterprise Linux 9 - x86_64      20 MB/s | 21 MB     00:01
Extra Packages for Enterprise Linux 9 openh264 (From Cisco) - x86_64 2.8 kB/s | 2.5 kB    00:00
Rocky Linux 9 - BaseOS                             14 MB/s | 23 MB     00:01
Rocky Linux 9 - AppStream                           7.5 MB/s | 20 MB     00:02
Rocky Linux 9 - CRB                                 4.8 MB/s | 4.9 MB    00:01
Rocky Linux 9 - Extras                              36 kB/s | 17 kB     00:00
RPM Fusion for EL 9 - Free - Updates               282 kB/s | 229 kB    00:00
Package nvidia-x11-drv-470xx-470.256.02-8.el9_7.elrepo.x86_64 is already installed.
Dependencies resolved.
Nothing to do.
Complete!
```

Ilustración 165: Instalación de drivers NVIDIA [autoría propia]

```
(TTRatatouille) [josue@ibng2 ~]$ nvidia-smi
Mon May 18 18:56:29 2026

+-----+
| NVIDIA-SMI 470.256.02   Driver Version: 470.256.02   CUDA Version: 11.4   |
+-----+
| GPU   Name               Persistence-M| Bus-Id        Disp.A | Volatile Uncorr. ECC |
| Fan  Temp  Perf    Pwr:Usage/Cap|      Memory-Usage | GPU-Util  Compute M. |
|                               |                      | GPU-Util  Compute M. |
|=====-+-----+
|   0   Tesla K80           On         | 00000000:0D:00.0 Off |             0        |
| N/A   23C    P8      26W / 149W | 0MiB / 11441MiB |      0%    Default  |
|                               |                      | N/A       N/A       |
+-----+
|   1   Tesla K80           On         | 00000000:0E:00.0 Off |             0        |
| N/A   29C    P8      30W / 149W | 0MiB / 11441MiB |      0%    Default  |
|                               |                      | N/A       N/A       |
+-----+
|   2   Tesla K80           On         | 00000000:83:00.0 Off |             0        |
| N/A   26C    P8      25W / 149W | 0MiB / 11441MiB |      0%    Default  |
|                               |                      | N/A       N/A       |
+-----+
|   3   Tesla K80           On         | 00000000:84:00.0 Off |             0        |
| N/A   34C    P8      30W / 149W | 0MiB / 11441MiB |      0%    Default  |
|                               |                      | N/A       N/A       |
+-----+

+-----+
| Processes: |
| GPU   GI   CI        PID   Type   Process name                      GPU Memory |
|       ID   ID                 |              | Usage     |
|=====-+-----+
|   No running processes found   |
+-----+
```

Ilustración 166: Reinicio del sistema para que los cambios tomen efecto [autoría propia]

A continuación, se implementaron los controladores NVIDIA necesarios para detectar las GPUs Tesla K80 que se encuentran en el servidor.

```
(TTRatatouille) [josue@ibng2 ~]$ sudo dnf config-manager --add-repo https://download.docker.com/linux/rhel/docker-ce.repo
Adding repo from: https://download.docker.com/linux/rhel/docker-ce.repo
(TTRatatouille) [josue@ibng2 ~]$ sudo dnf -y install docker-ce docker-ce-cli containerd.io docker-buildx-plugin docker-compose-plugin
Docker CE Stable - x86_64 355 kB/s | 52 kB 00:00
Dependencies resolved.
=====
Package Architecture Version Repository Size
=====
Installing:
containerd.io x86_64 2.2.3-1.el9 docker-ce-stable 35 M
=====
```

Ilustración 167: Instalación de Docker Engine [autoría propia]

```
(TTRatatouille) [josue@ibng2 ~]$ sudo systemctl enable --now docker # Inicia y habilita Docker[26:L602-L608]
Created symlink /etc/systemd/system/multi-user.target.wants/docker.service → /usr/lib/systemd/system/docker.service.
```

Ilustración 168: Inicio y habilitación de Docker [autoría propia]

```
(TTRatatouille) [josue@ibng2 ~]$ sudo docker run -d --name tt_db -e POSTGRES_USER=postgres -e POSTGRES_PASSWORD=escom12345678 -e POSTGRES_DB=ratones_tt2026 -p 5432:5432 postgres
Unable to find image 'postgres:latest' locally
latest: Pulling from library/postgres
a7ee000e310e: Pull complete
57fb71246055: Pull complete
de11576bde87: Pull complete
93fccb407618: Pull complete
864ac3ce35b1: Pull complete
33948d124eb7: Pull complete
c2c802328ad4: Pull complete
18066de916e4: Pull complete
1ca95f4e0c8d: Pull complete
afff1a729121: Pull complete
7a97a7bd35bb: Pull complete
1a15b8bfb205: Pull complete
19d3ada5fe0c: Pull complete
617b42f8fae5: Download complete
b6f664f9310b: Download complete
Digest: sha256:f7ce845ee6873dd84be93c9828fe0d1fab0f9707dc9ac569694657398b290bce
Status: Downloaded newer image for postgres:latest
0980a3db8a8d5f639b2938b63ca69d89433ff16f07a7966b4211ddf62db0b097
```

Ilustración 169: Inicio del contenedor de Docker con credenciales seguras [autoría propia]

```
[root@ibng2 josue]# docker ps
CONTAINER ID IMAGE COMMAND NAMES CREATED STATUS PORTS
0980a3db8a8d postgres "docker-entrypoint.s..." About a minute ago Up About a minute 0.0.0.0:5432->5432/tcp, [::]:5432->5432/tcp tt_db
```

Ilustración 170: Comprobación de ejecución del contenedor [autoría propia]

Luego se estableció Docker Engine y se implementó un contenedor PostgreSQL con el fin de almacenar los datos que el sistema emplea.

```
[root@ibng2 josue]# cd ~
[root@ibng2 ~]# git clone https://github.com/Morpheoo/TT_Ratones_2026 TT_Ratones_2026
Cloning into 'TT_Ratones_2026'...
remote: Enumerating objects: 1000, done.
remote: Counting objects: 100% (75/75), done.
remote: Compressing objects: 100% (9/9), done.
remote: Total 1000 (delta 69), reused 66 (delta 66), pack-reused 925 (from 1)
Receiving objects: 100% (1000/1000), 89.20 MiB | 33.26 MiB/s, done.
Resolving deltas: 100% (500/500), done.
[root@ibng2 ~]# cd TT_Ratones_2026
[root@ibng2 TT_Ratones_2026]#
```

Ilustración 171: Descarga del repositorio del sistema usando Git [autoría propia]

```
[root@ibng2 TT_Ratones_2026]# nano .env
```

Ilustración 172: Creación del archivo .env con la configuración del proyecto [autoría propia]

```
PROJECT_ROOT=.

DATA_DIR=data
VIDEOS_DIR=videos_data
MODELS_DIR=data/models
SIMBA_PROJECT_DIR=data/simba_projects/New folder/thigmotaxis_optimizado

GROOMING_MODEL=data/simba_projects/New folder/thigmotaxis_optimizado/models/generated_models/Grooming.s
THIGMOTAXIS_MODEL=data/simba_projects/New folder/thigmotaxis_optimizado/models/Thigmotaxis.sav

YOLO_MODEL=yolo_tracker.pt

FFMPEG_PATH=

# Base de datos
POSTGRES_USER=postgres
POSTGRES_PASSWORD=escom12345678
POSTGRES_DB=ratones_tt2026
DB_HOST=127.0.0.1
DB_PORT=5432

# Correo
GMAIL_SENDER_EMAIL=chavid04@gmail.com
GMAIL_APP_PASSWORD=bnomelegydqzqpyoS
```

Ilustración 173: Archivo .env configurado [autoría propia]

Tras establecer Docker, se bajó el repositorio del proyecto y se generó el archivo requerido de variables de entorno para enlazarse con la base de datos PostgreSQL.

```
[root@ibng2 TT_Ratones_2026]# cd ~
wget https://repo.anaconda.com/miniconda/Miniconda3-latest-Linux-x86_64.sh -O Miniconda3.sh
bash Miniconda3.sh
--2026-05-18 19:23:08-- https://repo.anaconda.com/miniconda/Miniconda3-latest-Linux-x86_64.sh
Resolving repo.anaconda.com (repo.anaconda.com)... 104.16.32.241, 104.16.191.158, 2606:4700::6810:bf9e,
...
Connecting to repo.anaconda.com (repo.anaconda.com)|104.16.32.241|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 163179296 (156M) [application/octet-stream]
Saving to: 'Miniconda3.sh'
```

Ilustración 174: Instalación de Miniconda para gestionar Python y dependencias [autoría propia]

```
(TTRatatouille) [josue@ibng2 ~]$ conda --version
conda 26.3.2
```

Ilustración 175: Verificación de instalación de Conda [autoría propia]

Para administrar varios entornos de Python y prevenir problemas con las dependencias, se instaló Miniconda en el sistema Linux.

```
(TTRatatouille) [josue@ibng2 ~]$ conda create -n venv_310 python=3.10 -y
2 channel Terms of Service accepted
Retrieving notices: done
Channels:
- defaults
Platform: linux-64
Collecting package metadata (repodata.json): done
Solving environment: done
```

Ilustración 176: Creación del entorno venv_310 [autoría propia]

```
(TTRatatouille) [josue@ibng2 ~]$ conda activate venv_310
(venv_310) [josue@ibng2 ~]$ |
```

Ilustración 177: Activación del entorno venv_310 [autoría propia]

```
(TTRatatouille) [josue@ibng2 ~]$ conda activate venv_310
(venv_310) [josue@ibng2 ~]$ python -m pip install --upgrade pip setuptools wheel
Requirement already satisfied: pip in ./miniconda3/envs/venv_310/lib/python3.10/site-packages (26.0.1)
Collecting pip
  Using cached pip-26.1.1-py3-none-any.whl.metadata (4.6 kB)
Requirement already satisfied: setuptools in ./miniconda3/envs/venv_310/lib/python3.10/site-packages (82.0.1)
WARNING: Cache entry deserialization failed, entry ignored
Requirement already satisfied: wheel in ./miniconda3/envs/venv_310/lib/python3.10/site-packages (0.46.3)
Collecting wheel
  Downloading wheel-0.47.0-py3-none-any.whl.metadata (2.3 kB)
Requirement already satisfied: packaging>=24.0 in ./miniconda3/envs/venv_310/lib/python3.10/site-packages (from wheel) (26.0)
Using cached pip-26.1.1-py3-none-any.whl (1.8 MB)
Downloading wheel-0.47.0-py3-none-any.whl (32 kB)
Installing collected packages: wheel, pip
  Attempting uninstall: wheel
    Found existing installation: wheel 0.46.3
    Uninstalling wheel-0.46.3:
      Successfully uninstalled wheel-0.46.3
  Attempting uninstall: pip
    Found existing installation: pip 26.0.1
    Uninstalling pip-26.0.1:
      Successfully uninstalled pip-26.0.1
Successfully installed pip-26.1.1 wheel-0.47.0
(venv_310) [josue@ibng2 ~]$ |
```

Ilustración 178: Actualización de herramientas base de pip [autoría propia]

```

Successfully installed pip-20.1.1 wheel-0.34.2
(venv_310) [josue@ibng2 ~]$ pip install \
torch==2.7.1+cpu \
torchvision==0.22.1+cpu \
--extra-index-url https://download.pytorch.org/whl/cpu
Looking in indexes: https://pypi.org/simple, https://download.pytorch.org/whl/cpu
WARNING: Cache entry deserialization failed, entry ignored
Collecting torch==2.7.1+cpu
  Downloading torch-2.7.1%2Bcpu-cp310-cp310-manylinux_2_28_x86_64.whl.metadata (27 kB)
WARNING: Cache entry deserialization failed, entry ignored
Collecting torchvision==0.22.1+cpu

```

Ilustración 179: Instalación de PyTorch CPU-only [autoría propia]

```

(venv_310) [josue@ibng2 ~]$ pip install \
tensorflow==2.10.0 \
keras==2.10.0
Collecting tensorflow==2.10.0
  Downloading tensorflow-2.10.0-cp310-cp310-manylinux_2_17_x86_64.manylinux2014_x86_64.whl.metadata (3.1 kB)
Collecting keras==2.10.0

```

Ilustración 180: Instalación de TensorFlow/Keras 2.10 [autoría propia]

```

(venv_310) [josue@ibng2 ~]$ pip install "simba-uw-tf-dev>=1.95.5"
Collecting simba-uw-tf-dev>=1.95.5
  Downloading simba_uw_tf_dev-5.3.5-py3-none-any.whl.metadata (11 kB)
Collecting eli5==0.10.1 (from simba-uw-tf-dev>=1.95.5)
  Using cached eli5-0.10.1-py2.py3-none-any.whl.metadata (17 kB)
Collecting graphviz==0.11 (from simba-uw-tf-dev>=1.95.5)
  Using cached graphviz-0.11-py2.py3-none-any.whl.metadata (6.3 kB)

```

Ilustración 181: Instalación de SimBA [autoría propia]

```

(venv_310) [josue@ibng2 ~]$ pip install \
"numpy<2.0" \
scipy \
pandas \
scikit-learn \
matplotlib \
opencv-python \
pillow \
PyYAML \
tqdm \
imageio \
imageio-ffmpeg \
python-dotenv
Requirement already satisfied: numpy<2.0 in ./miniconda3/envs/venv_310/lib/python3.10/site-packages (1.26.4)
Requirement already satisfied: scipy in ./miniconda3/envs/venv_310/lib/python3.10/site-packages (1.10.1)
Requirement already satisfied: pandas in ./miniconda3/envs/venv_310/lib/python3.10/site-packages (1.4.2)
Requirement already satisfied: scikit-learn in ./miniconda3/envs/venv_310/lib/python3.10/site-packages (1.2.2)
Requirement already satisfied: matplotlib in ./miniconda3/envs/venv_310/lib/python3.10/site-packages (3.5.3)
Requirement already satisfied: opencv-python in ./miniconda3/envs/venv_310/lib/python3.10/site-packages (4.8.1.72)
Requirement already satisfied: pillow in ./miniconda3/envs/venv_310/lib/python3.10/site-packages (9.4.0)
Requirement already satisfied: PyYAML in ./miniconda3/envs/venv_310/lib/python3.10/site-packages (6.0.1)
Requirement already satisfied: tqdm in ./miniconda3/envs/venv_310/lib/python3.10/site-packages (4.64.1)
Requirement already satisfied: imageio in ./miniconda3/envs/venv_310/lib/python3.10/site-packages (2.21.0)
Requirement already satisfied: imageio-ffmpeg in ./miniconda3/envs/venv_310/lib/python3.10/site-packages (0.4.7)
Requirement already satisfied: python-dotenv in ./miniconda3/envs/venv_310/lib/python3.10/site-packages (0.21.0)

```

Ilustración 182: Instalación de librerías numéricas y de IO [autoría propia]


```

(venv_310) [josue@ibng2 ~]$ pip install setuptools==69.5.1
WARNING: Cache entry deserialization failed, entry ignored
Collecting setuptools==69.5.1
  Downloading setuptools-69.5.1-py3-none-any.whl.metadata (6.2 kB)
  Downloading setuptools-69.5.1-py3-none-any.whl (894 kB)
    894.6/894.6 kB 6.7 MB/s 0:00:00
Installing collected packages: setuptools
  Attempting uninstall: setuptools
    Found existing installation: setuptools 82.0.1
    Uninstalling setuptools-82.0.1:
      Successfully uninstalled setuptools-82.0.1
Successfully installed setuptools-69.5.1
(venv_310) [josue@ibng2 ~]$ python -c "import torch, tensorflow, simba; print('OK')"
2026-05-20 18:22:05.251592: I tensorflow/core/platform/cpu_feature_guard.cc:193] This TensorFlow binary is optimized with oneAPI Deep Neural Network Library (oneDNN) to use the following CPU instructions in performance-critical operations: AVX2 FMA
To enable them in other operations, rebuild TensorFlow with the appropriate compiler flags.
2026-05-20 18:22:05.402471: E tensorflow/stream_executor/cuda/cuda_blas.cc:2981] Unable to register cuBLAS factory: Attempting to register factory for plugin cuBLAS when one has already been registered
2026-05-20 18:22:06.052524: W tensorflow/stream_executor/platform/default/dso_loader.cc:64] Could not load dynamic library 'libnvinfer.so.7'; dle
2026-05-20 18:22:06.052626: W tensorflow/stream_executor/platform/default/dso_loader.cc:64] Could not load dynamic library 'libnvinfer_plugin.so.7'; dle
2026-05-20 18:22:06.052641: W tensorflow/compiler/tf2tensorrt/utils/py_utils.cc:38] TF-TRT Warning: Cannot dlopen some TensorRT libraries. If you would like to use Nvidia GPU with TensorRT, please make sure the missing libraries mentioned above are installed properly.
OK

```

Ilustración 183: Verificación de que la instalación de las librerías es correcta [autoría propia]

El entorno venv_310 fue destinado principalmente a las dependencias asociadas con SimBA y TensorFlow/Keras, utilizando una configuración CPU-only para PyTorch debido a incompatibilidades detectadas con CUDA y los controladores disponibles para las GPUs Tesla K80.

```

(TTRatatouille) [josue@ibng2 ~]$ conda create -n venv_311 python=3.11 -y
2 channel Terms of Service accepted
Channels:
 - defaults
Platform: linux-64
Collecting package metadata (repodata.json): done
Solving environment: done

```

Ilustración 184: Creación del entorno venv_311 [autoría propia]

```

(TTRatatouille) [josue@ibng2 ~]$ conda activate venv_311
(venv_311) [josue@ibng2 ~]$ |

```

Ilustración 185: Activación del entorno venv_311 [autoría propia]

```

(venv_311) [josue@ibng2 ~]$ python -m pip install --upgrade pip setuptools wheel
Requirement already satisfied: pip in ./miniconda3/envs/venv_311/lib/python3.11/site-packages (26.0.1)
Collecting pip
  Using cached pip-26.1.1-py3-none-any.whl.metadata (4.6 kB)
Requirement already satisfied: setuptools in ./miniconda3/envs/venv_311/lib/python3.11/site-packages (82.0.1)
WARNING: Cache entry deserialization failed, entry ignored
Requirement already satisfied: wheel in ./miniconda3/envs/venv_311/lib/python3.11/site-packages (0.46.3)
Collecting wheel
  Using cached wheel-0.47.0-py3-none-any.whl.metadata (2.3 kB)
Requirement already satisfied: packaging>=24.0 in ./miniconda3/envs/venv_311/lib/python3.11/site-packages (from wheel) (26.0)
Using cached pip-26.1.1-py3-none-any.whl (1.8 MB)
Using cached wheel-0.47.0-py3-none-any.whl (32 kB)
Installing collected packages: wheel, pip
  Attempting uninstall: wheel
    Found existing installation: wheel 0.46.3
    Uninstalling wheel-0.46.3:
      Successfully uninstalled wheel-0.46.3
  Attempting uninstall: pip
    Found existing installation: pip 26.0.1
    Uninstalling pip-26.0.1:
      Successfully uninstalled pip-26.0.1
Successfully installed pip-26.1.1 wheel-0.47.0
(venv_311) [josue@ibng2 ~]$

```

Ilustración 186: Actualización de pip/setuptools/wheel [autoría propia]

```

(venv_311) [josue@ibng2 ~]$ pip install \
torch==2.0.1 \
torchvision==0.15.2 \
--index-url https://download.pytorch.org/whl/cu118
Looking in indexes: https://download.pytorch.org/whl/cu118
Collecting torch==2.0.1

```

Ilustración 187: Instalación de PyTorch: NVIDIA (CUDA 12.8) [autoría propia]

```

(venv_311) [josue@ibng2 ~]$ pip install \
torch==2.7.1+cpu \
torchvision==0.22.1+cpu \
--extra-index-url https://download.pytorch.org/whl/cpu
Looking in indexes: https://pypi.org/simple, https://download.pytorch.org/whl/cpu
Collecting torch==2.7.1+cpu
  Downloading torch-2.7.1%2Bcpu-cp311-cp311-manylinux_2_28_x86_64.whl.metadata (27 kB)

```

Ilustración 188: Instalación de PyTorch: CPU-only [autoría propia]

```
(venv_311) [josue@ibng2 ~]$ pip install \
altair==6.0.0 \
attrs==25.4.0 \
bcrypt==4.1.2 \
blinker==1.9.0 \
cachetools==6.2.2 \
certifi==2025.11.12 \
charset-normalizer==3.4.4 \
click==8.3.1 \
colorama==0.4.6 \
contourpy==1.3.3 \
cyclor==0.12.1 \
decorator==4.4.2 \
filelock==3.20.0 \
fonttools==4.61.0 \
fsspec==2025.12.0 \
gitdb==4.0.12 \
GitPython==3.1.45 \
greenlet==3.3.0 \
idna==3.11 \
imageio==2.37.2 \
imageio-ffmpeg==0.6.0 \
Jinja2==3.1.6 \
joblib==1.5.2 \
jsonschema==4.25.1 \
jsonschema-specifications==2025.9.1 \
keyboard==0.13.5 \
kiwisolver==1.4.9 \
MarkupSafe==3.0.3 \
matplotlib==3.10.7 \
moviepy==1.0.3 \
mpmath==1.3.0 \
narwhals==2.13.0 \
networkx==3.6 \
numpy==2.3.5 \
opencv-python==4.11.0.86 \
packaging==25.0 \
pandas==2.3.3 \
pillow==11.3.0 \
plotly==6.5.0 \
polars==1.36.1 \
watchdog==6.0.0\==2.0.18 \\\ix==0.9.8 \
WARNING: Cache entry deserialization failed, entry ignored
Collecting altair==6.0.0
```

Ilustración 189: Instalación de dependencias principales [autoría propia]

```
(venv_311) [josue@ibng2 ~]$ python -c "import torch, ultralytics, streamlit; print(
torch.__version__); print(torch.cuda.is_available())"
2.0.1+cu118
True
```

Ilustración 190: Verificación de que la instalación de las librerías es correcta [autoría propia]

Durante la configuración del entorno venv_311 se realizaron pruebas con versiones de PyTorch compatibles con CUDA. Sin embargo, debido a incompatibilidades entre la versión de CUDA requerida y los controladores soportados por las GPUs Tesla K80, fue necesario utilizar nuevamente una instalación CPU-only para garantizar la estabilidad del sistema.

```
(TTRatatouille) [josue@ibng2 ~]$ cd ~
git clone https://github.com/Morpheoo/TT_Ratones_2026
Cloning into 'TT_Ratones_2026'...
remote: Enumerating objects: 1000, done.
remote: Counting objects: 100% (26/26), done.
remote: Compressing objects: 100% (7/7), done.
remote: Total 1000 (delta 21), reused 19 (delta 19), pack-reused 974 (from 1)
Receiving objects: 100% (1000/1000), 89.19 MiB | 28.85 MiB/s, done.
Resolving deltas: 100% (501/501), done.
(TTRatatouille) [josue@ibng2 ~]$ cd TT_Ratones_2026
(TTRatatouille) [josue@ibng2 TT_Ratones_2026]$ ls
_02_Configuracion_Zonas.py      quick_diag.py
```

Ilustración 191: Entrada a la carpeta del proyecto dentro del entorno TTRatatouille [autoría propia]

```
(TTRatatouille) [josue@ibng2 scripts]$ python fix_simba_paths.py
[INFO] Reescribiendo 4 ruta(s) en /home/josue/TT_Ratones_2026/data/simba_projects/g
rooming_thigmotaxis_yolo/project_folder/project_config.ini:
  project_path
    antes : C:\Users\Ryzen\Documents\ESCOM\TT\TT2026\1704\TT_Ratones_2026\data\simb
a_projects\grooming_thigmotaxis_yolo\project_folder
    ahora : /home/josue/TT_Ratones_2026/data/simba_projects/grooming_thigmotaxis_yo
lo/project_folder
  model_dir
    antes : C:\Users\Ryzen\Documents\ESCOM\TT\TT2026\1704\TT_Ratones_2026\data\simb
a_projects\grooming_thigmotaxis_yolo\models
    ahora : /home/josue/TT_Ratones_2026/data/simba_projects/grooming_thigmotaxis_yo
lo/models
  model_path_1
    antes : C:\Users\Ryzen\Documents\ESCOM\TT\TT2026\1704\TT_Ratones_2026\data\simb
a_projects\grooming_thigmotaxis_yolo\models\generated_models\Thigmotaxis.sav
    ahora : /home/josue/TT_Ratones_2026/data/simba_projects/grooming_thigmotaxis_yo
lo/models/generated_models/Thigmotaxis.sav
  model_path_2
    antes : C:\Users\Ryzen\Documents\ESCOM\TT\TT2026\1704\TT_Ratones_2026\data\simb
a_projects\grooming_thigmotaxis_yolo\models\generated_models\Grooming.sav
    ahora : /home/josue/TT_Ratones_2026/data/simba_projects/grooming_thigmotaxis_yo
lo/models/generated_models/Grooming.sav
[OK] project_config.ini actualizado.
(TTRatatouille) [josue@ibng2 scripts]$
```

Ilustración 192: Ejecución del script para actualizar rutas de SimBA [autoría propia]

Para garantizar que el sistema funcione adecuadamente dentro del entorno Linux configurado, se hicieron finalmente modificaciones internas de rutas y ajustes necesarios para SimBA.

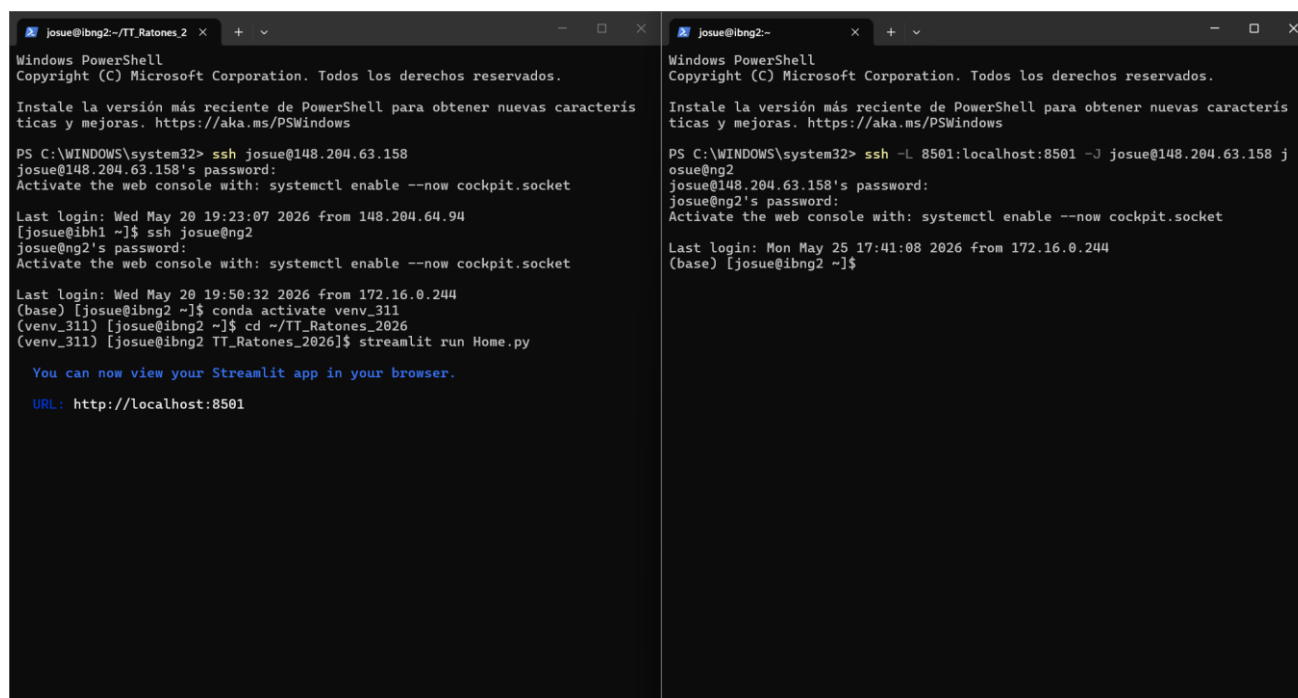
Debido a un cambio en las versiones del software y tras identificar que los entornos virtuales se encontraban al mismo nivel jerárquico dentro del equipo de cómputo, es decir, que los entornos `venv_310` y `venv_311` no estaban contenidos dentro del entorno `RatatouilleTT`, se decidió eliminar el entorno denominado `RatatouilleTT` y conservar únicamente los entornos `venv_310` y `venv_311`, cada uno con sus respectivas dependencias y librerías actualizadas.

En este caso, para ejecutar el sistema en Linux se requieren dos terminales SSH debido a la arquitectura de red del servidor y al funcionamiento interno de Streamlit.

En la primera terminal se establece una conexión SSH al servidor intermedio (148.204.63.158) y posteriormente al servidor interno (ng2), donde se encuentran el repositorio del proyecto, los entornos Conda y las dependencias necesarias. Dentro de este servidor se activa el entorno virtual

venv_311 y se ejecuta la aplicación mediante streamlit run Home.py. Esto inicia un servidor web local asociado al puerto 8501 del propio servidor ng2.

Sin embargo, dicho puerto únicamente es accesible desde la máquina remota, ya que ng2 pertenece a una red interna y no expone directamente sus servicios a Internet. Por esta razón, en una segunda terminal se crea un túnel SSH utilizando port forwarding:



The image shows two terminal windows side-by-side. The left window is titled 'josue@ibng2:~/TT_Ratones_2' and shows a Windows PowerShell session where a user connects to 'josue@148.204.63.158' via SSH. After logging in, the user runs 'conda activate venv_311', 'cd ~/TT_Ratones_2026', and 'streamlit run Home.py'. The output shows the Streamlit app is running and provides a URL: 'http://localhost:8501'. The right window is titled 'josue@ibng2:~' and shows a PowerShell session where a user runs 'ssh -L 8501:localhost:8501 -J josue@148.204.63.158 josue@ng2'. This establishes an SSH tunnel from the local machine's port 8501 to the remote machine's port 8501.

```
Windows PowerShell
Copyright (C) Microsoft Corporation. Todos los derechos reservados.

Instale la versión más reciente de PowerShell para obtener nuevas características y mejoras. https://aka.ms/PSWindows

PS C:\WINDOWS\system32> ssh josue@148.204.63.158
josue@148.204.63.158's password:
Activate the web console with: systemctl enable --now cockpit.socket

Last login: Wed May 20 19:23:07 2026 from 148.204.64.94
[josue@ibh1 ~]$ ssh josue@ng2
josue@ng2's password:
Activate the web console with: systemctl enable --now cockpit.socket

Last login: Wed May 20 19:50:32 2026 from 172.16.0.244
(base) [josue@ibng2 ~]$ conda activate venv_311
(venv_311) [josue@ibng2 ~]$ cd ~/TT_Ratones_2026
(venv_311) [josue@ibng2 TT_Ratones_2026]$ streamlit run Home.py

You can now view your Streamlit app in your browser.

URL: http://localhost:8501

Windows PowerShell
Copyright (C) Microsoft Corporation. Todos los derechos reservados.

Instale la versión más reciente de PowerShell para obtener nuevas características y mejoras. https://aka.ms/PSWindows

PS C:\WINDOWS\system32> ssh -L 8501:localhost:8501 -J josue@148.204.63.158 josue@ng2
josue@148.204.63.158's password:
josue@ng2's password:
Activate the web console with: systemctl enable --now cockpit.socket

Last login: Mon May 25 17:41:08 2026 from 172.16.0.244
(base) [josue@ibng2 ~]$
```

Ilustración 193: Ambas terminales corriendo [autoría propia]

Este túnel redirige el puerto local 8501 de la computadora cliente hacia el puerto 8501 del servidor remoto, permitiendo acceder a la interfaz de Streamlit desde un navegador local mediante `http://localhost:8501`.

De esta manera, la primera terminal mantiene en ejecución la aplicación, mientras que la segunda mantiene activo el canal seguro de comunicación entre el navegador local y el servidor remoto.




Ilustración 194: Pantalla principal del programa corriendo en el nodo con Linux [autoría propia]

Tras cargar el video de prueba y avanzar a la etapa de extracción de keypoints, se presentó el primer error crítico de ejecución del pipeline. El sistema intentó acceder al ejecutable de Python del entorno venv_310 utilizando una ruta con formato de Windows (Scripts/python.exe), incompatible con la estructura de directorios de Linux. Esto provocó una excepción FileNotFoundError, impidiendo la continuación del proceso.



Ilustración 195: Error de rutas de Pyhton [autoría propia]

A partir de este resultado se identificó la necesidad de adaptar las rutas internas del sistema al formato utilizado por Conda en Linux (bin/python) para garantizar la compatibilidad del proyecto en el nuevo entorno de ejecución.

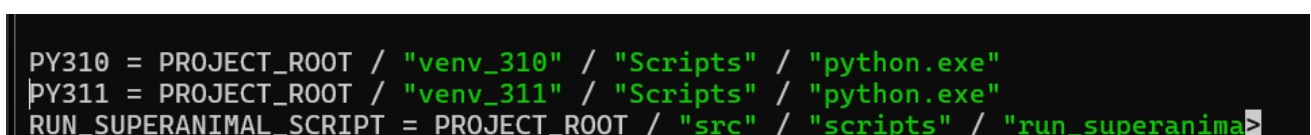


Ilustración 196: Archivo run_behavior_pipeline como estaba originalmente [autoría propia]


```
PY310 = Path("/home/josue/miniconda3/envs/venv_310/bin/python")
PY311 = Path("/home/josue/miniconda3/envs/venv_311/bin/python")|
RUN_SUPERANIMAL_SCRIPT = PROJECT_ROOT / "src" / "scripts" / "run_supera
```

Ilustración 197: Corrección aplicada al archivo run_behavior_pipeline [autoría propia]

El segundo error apareció por la falta de los modelos

Estado y Logs

La extracción de keypoints termino con error.

```
=====
[WRAPPER] Launching: /home/josue/miniconda3/envs/venv_311/bin/python /home/josue/TT_Ratones_2026/src/scripts/run_behavior_pipeline.py --video /home/josue/TT_
=====
[STEP] ERROR
[ERROR] Grooming model not found: /home/josue/TT_Ratones_2026/data/simba_projects/grooming_thigmotaxis_yolo/models/generated_models/Grooming.sav
Traceback (most recent call last):
  File "/home/josue/TT_Ratones_2026/src/scripts/run_behavior_pipeline.py", line 474, in main
    ensure_path(grooming_model, "Grooming model")
  File "/home/josue/TT_Ratones_2026/src/scripts/run_behavior_pipeline.py", line 49, in ensure_path
    raise FileNotFoundError(f"{description} not found: {path}")
FileNotFoundError: Grooming model not found: /home/josue/TT_Ratones_2026/data/simba_projects/grooming_thigmotaxis_yolo/models/generated_models/Grooming.sav
[WRAPPER] Child exit code: 1
```

Ilustración 198: Error por falta de modelos [autoría propia]

Debido al tamaño de los modelos utilizados por el sistema (aproximadamente 3.3 GB), estos no fueron incluidos dentro del repositorio de GitHub. Por esta razón, una vez finalizada la instalación de dependencias y la configuración de los entornos virtuales, se procedió a copiar manualmente los archivos de modelos preentrenados desde un dispositivo USB hacia la raíz del proyecto. Entre los archivos transferidos se incluyen modelos YOLO Pose, modelos LSTM para detección de grooming, clasificadores Random Forest de SimBA y artefactos opcionales de B-SOiD. La estructura de carpetas contenida en el dispositivo externo replica la estructura interna del proyecto, permitiendo fusionar automáticamente los archivos con las rutas esperadas por el sistema.

Debido a que Linux no cuenta una opción para copiar/fusionar carpetas directamente, se hizo el copiado de los archivos en 2 pasos.

```
PS C:\WINDOWS\system32> scp -r -J josue@148.204.63.158 "C:\Users\Gaby\Downloads\TT_Ratones_2026_modelos-20260526T001553Z-3-001\TT_Ratones_2026_modelos"
josue@ng2: /home/josue/
josue@148.204.63.158's password:
josue@ng2's password:
grooming_lstm.keras          100% 2539KB   1.1MB/s   00:02
metadata.json               100%  11KB   749.1KB/s   00:00
scaler.pkl                  100%  15KB   217.2KB/s   00:00
Grooming.sav                100% 269MB   1.0MB/s   04:22
Thigmotaxis.sav             100% 286MB   1.1MB/s   04:31
LEEME_PRIMERO.txt           100% 3214    448.4KB/s   00:00
best.pt                     100%  19MB   992.6KB/s   00:19
yolo_tracker.pt             100% 5343KB   1.1MB/s   00:04
```

Ilustración 199: Comando para copiar los modelos descargados desde el equipo Windows a una carpeta temporal [autoría propia]

```
(base) [josue@ibng2 ~]$ rsync -av /home/josue/TT_Ratones_2026_modelos/ /home
/josue/TT_Ratones_2026/
sending incremental file list
./
LEEME_PRIMERO.txt
yolo_tracker.pt
data/
data/models/
data/models/lstm_grooming_yolo/
data/models/lstm_grooming_yolo/grooming_lstm.keras
data/models/lstm_grooming_yolo/metadata.json
data/models/lstm_grooming_yolo/scaler.pkl
data/simba_projects/
data/simba_projects/grooming_thigmotaxis_yolo/
data/simba_projects/grooming_thigmotaxis_yolo/models/
data/simba_projects/grooming_thigmotaxis_yolo/models/generated_models/
data/simba_projects/grooming_thigmotaxis_yolo/models/generated_models/Groomi
ng.sav
data/simba_projects/grooming_thigmotaxis_yolo/models/generated_models/Thigmo
taxis.sav
runs/
runs/pose/
runs/pose/yolo11s_pose_ratón_v4/
runs/pose/yolo11s_pose_ratón_v4/weights/
runs/pose/yolo11s_pose_ratón_v4/weights/best.pt

sent 609,949,327 bytes  received 231 bytes  406,633,038.67 bytes/sec
total size is 609,799,408  speedup is 1.00
(base) [josue@ibng2 ~]$
```

Ilustración 200: Uso del comando rsync para fusionar las carpetas [autoría propia]

Posteriormente, se verificó que los modelos quedaran almacenados en las ubicaciones correctas para garantizar el funcionamiento adecuado de los distintos módulos de inferencia y análisis conductual. Para este caso, los modelos correspondientes a B-SOiD fueron omitidos temporalmente durante la instalación, debido a que su descarga y transferencia representaban un tiempo considerable bajo las limitaciones de velocidad y estabilidad de la red disponible, especialmente considerando el proceso adicional de copia hacia el nodo Linux remoto. Dichos modelos corresponden a un componente opcional del sistema, utilizado únicamente bajo configuraciones específicas del pipeline de grooming, por lo que su ausencia no impide la ejecución general del sistema en el modo de funcionamiento predeterminado.

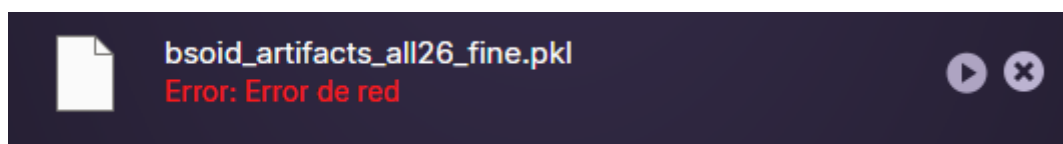


Ilustración 201: Error de descarga del archivo de los modelos B-SOiD [autoría propia]

Tras otro intento se recibió un error con la versión de numpy instalada en el equipo de cómputo, pues el entorno `venv_311` cuenta con NumPy 2.3.5 pero varias librerías de PyTorch/Ultralytics fueron compiladas todavía para NumPy 1.x., por lo que a continuación bajamos la versión a la 1.26.4.


```
(venv_311) [josue@ibng2 TT_Ratones_2026]$ pip uninstall -y numpy
Found existing installation: numpy 2.3.5
Uninstalling numpy-2.3.5:
  Successfully uninstalled numpy-2.3.5
(venv_311) [josue@ibng2 TT_Ratones_2026]$ pip install "numpy<2"
Collecting numpy<2
  Downloading numpy-1.26.4-cp311-cp311-manylinux_2_17_x86_64.manylinux2014_x86_64.whl.metadata (61 kB)
  Downloading numpy-1.26.4-cp311-cp311-manylinux_2_17_x86_64.manylinux2014_x86_64.whl (18.3 MB)
  18.3/18.3 MB 207.7 kB/s 0:01:27
Installing collected packages: numpy
Successfully installed numpy-1.26.4
(venv_311) [josue@ibng2 TT_Ratones_2026]$ |
```

ImportError: Missing optional dependency 'pytables'. Use pip or conda to install pytables.

```
File "/home/josue/TT_Ratones_2026/pages/03_Configuracion_Zonas.py", line 431, in <module>
    roi_sync = _sync_wall_rois_to_simba(normalized_zones)
    ^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^

File "/home/josue/TT_Ratones_2026/pages/03_Configuracion_Zonas.py", line 240, in _sync_wall_rois_to_simba
    roi_sync_result = sync_streamlit_rois_to_simba(
    ^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^

File "/home/josue/TT_Ratones_2026/src/simba_roi_bridge.py", line 491, in sync_streamlit_rois_to_simba
    with pd.HDFStore(roi_path, mode="w") as store:
    ^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^

File "/home/josue/miniconda3/envs/venv_311/lib/python3.11/site-packages/pandas/io/pytables.py", line 579, in __init__
    tables = import_optional_dependency("tables")
    ^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^

File "/home/josue/miniconda3/envs/venv_311/lib/python3.11/site-packages/pandas/compat/_optional.py", line 138, in import_optional_dependency
    raise ImportError(msg)
```

Ilustración 203: Error de librería faltante [autoría propia]

```
(venv_311) [josue@ibng2 keypoints_yolo]$ conda install pytables -y
2 channel Terms of Service accepted
Channels:
  - defaults
Platform: linux-64
Collecting package metadata (repodata.json): done
Solving environment: done
```

Brazo Cerrado 1	Brazo Cerrado	Rectangulo	218	288	384	98	None	None	None	None
Brazo Cerrado 2	Brazo Cerrado	Rectangulo	672	285	368	82	None	None	None	None
Centro	Centro	Rectangulo	597	294	75	77	None	None	None	None
Pared 1	Muro / Pared	Linea	None	None	None	None	595	299	216	302
Pared 2	Muro / Pared	Linea	None	None	None	None	598	376	214	376
Pared 3	Muro / Pared	Linea	None	None	None	None	312	299	312	376
Pared 4	Muro / Pared	Linea	None	None	None	None	674	301	954	301
Pared 5	Muro / Pared	Linea	None	None	None	None	955	363	952	282
Pared 6	Muro / Pared	Linea	None	None	None	None	677	368	1043	366

GUARDAR CONFIGURACIÓN EXPERIMENTAL

Configuración de zonas guardada exitosamente en el sistema.

Se guardaron 11 zonas en la BD para el experimento #1.

Se importaron correctamente las 6 ROIs de paredes a SimBA para TEST-200526_Control.

Solo las 6 paredes se exportaron a SimBA. Las demás zonas quedan disponibles para el módulo de resultado final.

Ilustración 205: Guardado exitoso de la configuración de zonas [autoría propia]

El pipeline termino con error. Revisa los logs.

```

=====
[WRAPPER] Launching: /home/josue/miniconda3/envs/venv_311/bin/python /home/josue/TT_Ratones_2026/src/scripts/run_behavior_pipeline.py --video /home/josue/TT_
=====
TT 2026 BEHAVIOR PIPELINE
=====
[STEP] BOOT
[INFO] Video: /home/josue/TT_Ratones_2026/videos_data/TEST-200526_Control.mp4
[INFO] Backend: YOLO
[INFO] SimBA project: /home/josue/TT_Ratones_2026/data/simba_projects/grooming_thigmotaxis_yolo
[INFO] Grooming source: rescue
[INFO] Zones file: /home/josue/TT_Ratones_2026/logs/analysis/zonas_activas.json
[INFO] Skip final video: False
[OUTPUT] SIMBA_CONFIG=/home/josue/TT_Ratones_2026/data/simba_projects/grooming_thigmotaxis_yolo/project_folder/project_config.ini
[STEP] YOLO_POSE
[CMD] YOLO_POSE: /home/josue/miniconda3/envs/venv_311/bin/python /home/josue/TT_Ratones_2026/src/scripts/yolo_pose_to_csv.py --video /home/josue/TT_Ratones_2
Creating new Ultralytics Settings v0.0.6 file
View Ultralytics Settings with 'yolo settings' or at '/home/josue/.config/Ultralytics/settings.json'
Update Settings with 'yolo settings key=value', i.e. 'yolo settings runs_dir=path/to/dir'. For help see https://docs.ultralytics.com/quickstart/#ultralytics-
[YOLO] Video: TEST-200526_Control.mp4 | 1280x720 @ 30.0fps | 9341 frames
[YOLO] Modelo: /home/josue/TT_Ratones_2026/runs/pose/yolo11s_pose_raton_v4/weights/best.pt
[YOLO] CSV de salida: /home/josue/TT_Ratones_2026/keypoints_yolo/TEST-200526_Control/TEST-200526_Control_yolo_pose.csv
[YOLO] Video de salida: /home/josue/TT_Ratones_2026/keypoints_yolo/TEST-200526_Control/TEST-200526_Control_yolo_keypoints.mp4
Traceback (most recent call last):
  File "/home/josue/TT_Ratones_2026/src/scripts/yolo_pose_to_csv.py", line 162, in <module>
    run(args.video, args.output, args.conf, args.video_out)
  File "/home/josue/TT_Ratones_2026/src/scripts/yolo_pose_to_csv.py", line 116, in run
    results = model(frame, conf=conf, verbose=False)[0]
    ^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^
  File "/home/josue/miniconda3/envs/venv_311/lib/python3.11/site-packages/ultralytics/engine/model.py", line 177, in __call__

```

Ilustración 206: Error en Análisis Final [autoría propia]

Durante la ejecución del módulo de Análisis Final se presentó un conflicto de compatibilidad entre las versiones instaladas de NumPy, PyTorch y las librerías asociadas al framework Ultralytics. El entorno había quedado parcialmente inconsistente tras la actualización de dependencias, provocando errores de tipado interno durante la conversión de arreglos NumPy hacia tensores de PyTorch. Para resolver el problema fue necesario reinstalar las librerías principales del entorno virtual (numpy, torch, torchvision, torchaudio, ultralytics y opencv-python) asegurando compatibilidad entre versiones. Posteriormente, se verificó el correcto funcionamiento del pipeline ejecutando

nuevamente la etapa de inferencia YOLO Pose sobre un video de prueba, confirmando la generación adecuada de los archivos de keypoints y video procesado.

```
(venv_311) [josue@ibng2 TT_Ratones_2026]$ pip install torch torchvision torchaudio
Collecting torch
  Downloading torch-2.12.0-cp311-cp311-manylinux_2_28_x86_64.whl.metadata (31 kB)
Collecting torchvision
  Downloading torchvision-0.27.0-cp311-cp311-manylinux_2_28_x86_64.whl.metadata (5.5 kB)
WARNING: Cache entry deserialization failed, entry ignored
Collecting torchaudio
```

Ilustración 207: Reinstalación de las librerías de PyTorch [autoría propia]

```
(base) [josue@ibng2 ~]$ conda activate venv_311
(venv_311) [josue@ibng2 ~]$ pip install opencv-python
Collecting opencv-python
  Using cached opencv_python-4.13.0.92-cp37-abi3-manylinux_2_28_x86_64.whl.metadata (19 kB)
Collecting numpy>=2 (from opencv-python)
  Using cached numpy-2.4.6-cp311-cp311-manylinux_2_27_x86_64.whl.metadata (6.6 kB)
Downloading opencv_python-4.13.0.92-cp37-abi3-manylinux_2_28_x86_64.whl (72.9 MB)
72.9/72.9 MB 55.7 MB/s 0:00:01
Downloading numpy-2.4.6-cp311-cp311-manylinux_2_27_x86_64.whl (16.9 MB)
```

Ilustración 208: Instalación de OpenCV [autoría propia]

```
(venv_311) [josue@ibng2 ~]$ pip install torch torchvision torchaudio --index-url https://download.pytorch.org/whl/cu121
Looking in indexes: https://download.pytorch.org/whl/cu121
Collecting torch
  Downloading torch-2.5.1%2Bcu121-cp311-cp311-linux_x86_64.whl (780.5 MB)
780.5/780.5 MB 29.4 MB/s 0:00:13
Collecting torchvision
  Downloading torchvision-0.20.1%2Bcu121-cp311-cp311-linux_x86_64.whl (7.3 MB)
```

Ilustración 209: Reinstalación de PyTorch para CUDA [autoría propia]

Referencias

- [1] M. Khatri, S. K. Rai, R. Ranblor, K. Kishore y M. Tiwari, “Synthesis and Pharmacological Evaluation of [(4-Arylpiperazin-1-yl)-alkyl]-carbamic Acid Ethyl Ester Derivatives as Potential Anxiolytic Agents,” *Arch. Pharmal. Res.*, vol. 35, no. 7, pp. 1143–1150, 2011.
- [2] Sin autor, “NORMA Oficial Mexicana NOM-062-ZOO-1999, Especificaciones técnicas para la producción, cuidado y uso de los animales de laboratorio,” *Secretaría de Agricultura, Ganadería, Desarrollo Rural, Pesca y Alimentación*, Ciudad de México, Gov. Rep., Tomo DLXXV No.16, 2001.
- [3] A. P. Carobrez y L. J. Bertoglio, “Ethological and Temporal Analyses of Anxiety-like Behavior: The Elevated Plus-Maze Model 20 Years On,” *Neurosci. Biobehav. Rev.*, vol. 29, no. 8, pp. 1193–1205, 2005.

- [4] F. G. Graeff, C. F. Netto y H. Zangrossi Jr, “The Elevated T-Maze as an Experimental Model of Anxiety,” *Neurosci. Biobehav. Rev.*, vol. 23, no. 2, pp. 237–246, 1998.
- [5], Z. T. Pennington et al., “EzTrack-A step-by-step guide to behavior tracking”, *Curr. Protoc.*, vol. 1, Num. 10, p. e255, 2021.
- [6] **ISO/IEC/IEEE 12207:2017, Systems and Software Engineering — Software Life Cycle Processes**, International Organization for Standardization, Geneva, Switzerland, 2017. [En línea]. Disponible en: <https://www.iso.org/standard/63712.html>
- [7] **ISO/IEC/IEEE 15288:2023, Systems and Software Engineering — System Life Cycle Processes**, International Organization for Standardization, Geneva, Switzerland, 2023. [En línea]. Disponible en: <https://www.iso.org/standard/63711.html>
- [8] **ISO/IEC 25010:2023, Systems and Software Engineering — Systems and Software Quality Requirements and Evaluation (SQuaRE): System and Software Quality Models**, International Organization for Standardization, Geneva, Switzerland, 2023. [En línea]. Disponible en: <https://www.iso.org/standard/78176.html>
- [9] S. Olson y L. Barton, “Artificial Intelligence in Veterinary Medicine: Enhancing Animal Health and Welfare,” *Vet. Clin. North Am. Small Anim. Pract.*, vol. 53, no. 1, pp. 1–14, 2023.
- [10] M. J. Bailey, J. S. Capozzi, y P. J. Lowry, “The Translational Relevance of Rodent Models in Neurobehavioral Research,” *Front. Behav. Neurosci.*, vol. 17, pp. 112–128, 2023.
- [11] I. Sandino, Comunicación personal, Escuela Nacional de Medicina y Homeopatía, Instituto Politécnico Nacional, 2025.
- [12] M. Mathis, A. B. Mamidanna, K. M. Cury et al., “DeepLabCut: Markerless Pose Estimation of User-Defined Body Parts with Deep Learning,” *Nat. Neurosci.*, vol. 21, no. 9, pp. 1281–1289, 2018.
- [13] J. Redmon, S. Divvala, R. Girshick y A. Farhadi, “You Only Look Once: Unified, Real-Time Object Detection,” *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, pp. 779–788, 2016.
- [14] G. Quintana-Diez, “Integración de inteligencia artificial en la medicina del comportamiento animal,” *Rev. Med. Vet. Cienc. Anim.*, vol. 12, no. 2, pp. 85–94, 2022.
- [15] National Centre for the Replacement, Refinement and Reduction of Animals in Research (NC3Rs), “The 3Rs,” 2023. [En línea]. Disponible en: <https://www.nc3rs.org.uk>
- [16] A. Pereira y R. Moita, “The Role of Computer Vision in Ethology: A Review,” *Anim. Behav.*, vol. 190, pp. 1–14, 2022.
- [17] C. Wiltschko et al., “Mapping Sub-Second Structure in Mouse Behavior,” *Neuron*, vol. 88, no. 6, pp. 1121–1135, 2015.
- [18] S. Hochreiter and J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997. [En línea]. Disponible en: https://www.researchgate.net/publication/13853244_Long_Short-Term_Memory
- [19] C. Olah, “Understanding LSTM Networks,” colah’s blog, 2015. [En línea]. Disponible en: <https://colah.github.io/posts/2015-08-Understanding-LSTMs>
- [20] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention Is All You Need,” in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017.

- [21] I. Goodfellow, Y. Bengio and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016. [Online]. Disponible en: <https://www.deeplearningbook.org/>
- [22] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer, 2006.
- [23] Z. Cao, G. Hidalgo, T. Simon, S.-E. Wei, and Y. Sheikh, “OpenPose: Realtime Multi-Person 2D Pose Estimation Using Part Affinity Fields,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 43, no. 1, pp. 172–186, 2021. [Online]. Disponible en: <https://arxiv.org/abs/1812.08008>
- [24] G. Bradski, “Computer Vision Face Tracking for Use in a Perceptual User Interface,” Intel Research, 1998. [Online]. Disponible en: https://opencv.jp/opencv-1.0.0_org/docs/papers/camshift.pdf
- [25] D. Comaniciu, V. Ramesh y P. Meer, “Kernel-Based Object Tracking,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 25, no. 5, pp. 564–577, 2003. [Online]. Disponible en: <https://comaniciu.net/Papers/KernelTracking.pdf>
- [26] Open-Source Computer Vision Library (OpenCV), “MeanShift and CAMShift,” tutorial OpenCV docs (v4.x). [Online]. Disponible en: https://docs.opencv.org/4.x/d7/d00/tutorial_meanshift.html
- [27] J. Cohen, “A Coefficient of Agreement for Nominal Scales,” *Educ. Psychol. Meas.*, vol. 20, no. 1, pp. 37–46, 1960. Available: <https://journals.sagepub.com/doi/10.1177/001316446002000104>
- [28] M. L. McHugh, “Interrater Reliability: The Kappa Statistic,” *Biochem. Med.*, vol. 22, no. 3, pp. 276–282, 2012. Available: <https://www.biochemia-medica.com/en/journal/22/3/10.11613/BM.2012.031>
- [29] J. L. Fleiss, B. Levin and M. C. Paik, *Statistical Methods for Rates and Proportions*, 3rd ed. New York, NY, USA: Wiley, 2003. Disponible en: <https://onlinelibrary.wiley.com/doi/book/10.1002/0471445428>
- [30] J. MacQueen, “Some Methods for Classification and Analysis of Multivariate Observations,” *Proc. 5th Berkeley Symp. Math. Stat. Probab.*, vol. 1, pp. 281–297, 1967. Disponible en: <https://projecteuclid.org/journals/proceedings-of-the-berkeley-symposium/volume-5/issue-1>
- [31] J. Shlens, “A Tutorial on Principal Component Analysis,” *arXiv preprint arXiv:1404.1100*, Apr. 2014. [Online]. Available: <https://arxiv.org/pdf/1404.1100>
- [32] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001. Disponible: <https://link.springer.com/article/10.1023/A:1010933404324>
- [33] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2nd ed. New York, NY, USA: Springer, 2009. Disponible en: <https://hastie.su.domains/ElemStatLearn/>
- [34] S. A. Rahman, “Illustration of random forest trees,” ResearchGate, 2021. Disponible en: https://www.researchgate.net/figure/Illustration-of-random-forest-trees_fig4_354354484

- [35] A. K. Bhowan, “Diagram of ensemble methods: Bagging, Boosting, and Stacking,” ResearchGate, 2019. Disponible en: https://www.researchgate.net/figure/Diagram-of-ensemble-methods-A-Bagging-B-Boosting-C-Stacking-DT-decision-tree_fig1_331562581
- [36] C. J. C. Burges, “A Tutorial on Support Vector Machines for Pattern Recognition,” *Data Mining and Knowledge Discovery*, vol. 2, pp. 121–167, 1998. [Online]. Disponible en: <https://link.springer.com/article/10.1023/A%3A1009715923555>.
- [37] Scikit-learn developers, “Support Vector Machines — User Guide,” [scikit-learn.org](https://scikit-learn.org/stable/modules/svm.html), sección 1.4. [Online]. Disponible en: <https://scikit-learn.org/stable/modules/svm.html>.
- [38] I. T. Jolliffe y J. Cadima, “Principal component analysis: a review and recent developments,” *Philos. Trans. R. Soc. A*, vol. 374, no. 2065, 2016. DOI: 10.1098/rsta.2015.0202.
- [39] A.-M. Krypotos, M. Effting, M. Kindt y T. Beckers, “Avoidance learning: a review of theoretical models and recent developments,” *Front. Behav. Neurosci.*, vol. 9, p. 189, jul. 2015. [En línea]. Disponible: <https://pmc.ncbi.nlm.nih.gov/articles/PMC4508580/>.
- [40] D. Mobbs, C. Hagan, T. Dalgleish, B. Silston y C. Prévost, “The ecology of human fear: survival optimization and the nervous system,” *Front. Neurosci.*, 2015. [En línea]. Disponible: <https://pmc.ncbi.nlm.nih.gov/articles/PMC4364301/>.
- [41] T. M. Ball y L. A. Gunaydin, “Measuring maladaptive avoidance: from animal models to clinical anxiety,” *Neuropsychopharmacology*, vol. 47, pp. 978–986, 2022. [En línea]. Disponible: <https://www.nature.com/articles/s41386-021-01263-4>.
- [42] M. L. Brandão, “Different patterns of freezing behavior organized in the defensive continuum,” *Prog. Neuro-psychopharmacol. Biol. Psychiatry*, vol. 32, no. 8, pp. 1665–1670, 2008. doi: 10.1016/j.pnpbp.2007.12.002.
- [43] F. H. Klaassen, L. Held, B. Figner et al., “Defensive freezing and its relation to approach–avoidance decision-making under threat,” *Sci. Rep.*, vol. 11, Article number 12030, 2021. <https://doi.org/10.1038/s41598-021-90968-z>.
- [44] V. J. Jiménez-Planet and S. Hernández-Villegas, “REPISALUD (REPositorio Institucional de SALUD) del Instituto de Salud Carlos III (ISCIII) y sus Fundaciones: análisis de la puesta en marcha y evolución del proyecto,” Repisalud, Madrid, España. [Online]. Disponible en: <https://repisalud.isciii.es/rest/api/core/bitstreams/cdba37dc-a63b-43ff-a004-ec1762a6116e/content>.
- [45] G. Sun, C. Lyu, R. Cai, C. Yu, H. Sun, K. E. Schriver, L. Gao and X. Li, “DeepBhvTracking: A Novel Behavior Tracking Method for Laboratory Animals Based on Deep Learning,” *Frontiers in Behavioral Neuroscience*, vol. 15, Oct. 2021. [Online]. Disponible en: <https://www.frontiersin.org/journals/behavioral-neuroscience/articles/10.3389/fnbeh.2021.750894/full>

- [46] L. P. J. J. Noldus, A. J. Spink, R. A. J. Tegelenbosch, “EthoVision: A versatile video tracking system for automation of behavioral experiments,” *Behavior Research Methods, Instruments, & Computers*, vol. 33, no. 3, pp. 398-414, 2001. <https://link.springer.com/content/pdf/10.3758/BF03195394.pdf>
- [47] J. M. Lim, B. Platt, S. K. Janhunen, G. Riedel. “Comparison of automated video tracking systems in the open field test: ANY-Maze versus Ethovision XT,” *Journal of Neuroscience Methods*, vol. 397, pág. 109940, agosto de 2023, doi: 10.1016/j.jneumeth.2023.109940.
- [48] ML4Devs, “Why machine learning projects fail,” ML4Devs, 2023. [Online]. Disponible en: <https://ml4devs.com/why-machine-learning-projects-fail/>
- [49] RheoData, “AI Failures Statistics: Why Today’s Machine Learning Systems Fail,” RheoData, 2024. [Online]. Disponible en: <https://rheodata.com/ai-failure-statistics/>
- [50] M. Berthold, “Why Most Machine Learning Models Never Get Deployed,” KDnuggets, 2022. [Online]. Disponible en: <https://www.kdnuggets.com/2022/03/why-ml-models-rarely-get-deployed.html>
- [51] myosh, “What is a Risk Assessment Matrix?” myosh Safety Systems, 2024. [Online]. Disponible en: <https://myosh.com/blog/2024/04/24/what-is-a-risk-assessment-matrix/>
- [52] Beazley Group, “Guide to Risk Assessment,” Cyber Customer Centre – Risk Management Tools, 2024. [Online]. Disponible en: <https://www.beazley.com/en-US/cyber-customer-centre/cyber-risk-management-tools/guide-to-risk-assessment/>
- [53] ISO, ISO 31000:2018 — Risk management — Guidelines, International Organization for Standardization, 2018.
- [54] National Institute of Standards and Technology, Guide for Conducting Risk Assessments (NIST SP 800-30 Rev.1), Gaithersburg, MD, USA, 2012.
- [55] Sharma, Akhilesh & Kumar, Vipin & Longchamps, Louis. (2024). Comparative performance of YOLOv8, YOLOv9, YOLOv10, YOLOv11 and Faster R-CNN models for detection of multiple weed species. *Smart Agricultural Technology*. 9. 100648. 10.1016/j.atech.2024.100648.
- [56] Ke, W., Liu, T., & Cui, X. (2025). IECA-YOLOv7: A Lightweight Model with Enhanced Attention and Loss for Aerial Wildlife Detection. *Animals*, 15(18), 2743. <https://doi.org/10.3390/ani15182743>
- [57] Adhikari, B., Li, J., Michel, E. S., Dykes, J., Tseng, T, P., Tagert, M. L., Chen, D. “A Comprehensive Evaluation of YOLO-based Deer Detection Performance on Edge Devices,” Elsevier, 2025. [Online]. Disponible en: <https://arxiv.org/pdf/2509.20318v2>
- [58] Mathis, M. W., Mathis, A. “Deep learning tools for the measurement of animal behavior in neuroscience”, Harvard University. [Online]. Disponible en: <https://ar5iv.labs.arxiv.org/html/1909.13868#:~:text=Deeper%20networks%20are%20slower%2C%20but,Other%20networks%20recently%20added>

- [59] S. Ye et al., “SuperAnimal pretrained pose estimation models for behavioral analysis,” *Nature Communications*, vol. 15, no. 1, p. 5165, Jun. 2024, doi: 10.1038/s41467-024-48792-2
- [60] J. Lauer *et al.*, “multi-animal pose estimation, identification and tracking with DeepLabCut,” *Nature Methods*, vol. 19, no. 4, pp. 496–504, Apr. 2022, doi: 10.1038/s41592-022-01443-0
- [61] Vonstad, E. K., Su, X., Vereijken, B., Bach, K., & Nilsen, J. H. (2020). “Comparison of a Deep Learning-Based Pose Estimation System to Marker-Based and Kinect Systems in Exergaming for Balance Training.” *Sensors (Basel, Switzerland)*, 20(23), 6940. <https://doi.org/10.3390/s20236940>
- [62] Udell, A. “Mean Shift and Cam Shift Object Tracking,” towards data science, 2021. [Online] Disponible en: <https://towardsdatascience.com/mean-shift-and-cam-shift-object-tracking-f1c2c515b6bc/>
- [63] Subramaniam, A. “Understanding Object Tracking: From Classical Filters to Deep Learning,” Medium, 2025. [Online]. Disponible en: <https://medium.com/ai-simplified-in-plain-english/understanding-object-tracking-from-classical-filters-to-deep-learning-1d950c449610>
- [64] Yurushkin, M. “A Complete Review of the OpenCV Object Tracking Algorithms,” broutonlab. [Online.] Disponible en: <https://broutonlab.com/blog/opencv-object-tracking/>
- [65] F. A. Team, “CNNs vs. Transformers: Image Recognition Models Explained,” Flypix, Feb. 10, 2025. <https://flypix.ai/es/image-recognition-models-cnns/>
- [66] L. Alzubaidi et al., “Review of deep learning: concepts, CNN architectures, challenges, applications, future directions,” *Journal of Big Data*, vol. 8, no. 1, p. 53, Mar. 2021, doi: 10.1186/s40537-021-00444-8.
- [67] C. Stryker, “Red neuronal recurrente (RNN),” IBM, Feb. 05, 2025. <https://www.ibm.com/es-es/think/topics/recurrent-neural-networks>
- [68] “¿Cuáles son las ventajas y desafíos de usar LSTM o GRU para dependencias a largo plazo en series temporales?,” Sep. 01, 2023. <https://www.linkedin.com/advice/1/what-advantages-challenges-using-lstm-gru-long-term?lang=es>
- [69] A. M. Calero, A. Rasheed, and A. Lekkas, “Chronoshap: Revealing Temporal Patterns from Transformers and Ltsf-Linear Models in Time Series Forecasting,” *SSRN Electronic Journal*, Jan. 2025, doi: 10.2139/ssrn.5403215.
- [70] L. Ramírez, “Algoritmo k-means: ¿Qué es y cómo funciona?” *Thinking for Innovation*, Oct. 30, 2024. <https://www.iebschool.com/hub/algoritmo-k-means-que-es-y-como-funciona-big-data/>
- [71] J. Rew, S. Park, Y. Cho, S. Jung, and E. Hwang, “Animal movement prediction based on predictive recurrent neural network,” *Sensors*, vol. 19, no. 20, p. 4411, Oct. 2019, doi: 10.3390/s19204411.
- [72] R. Mosquera, O. D. Castrillón, and L. Parra, “Máquinas de Soporte Vectorial, Clasificador Naïve Bayes y Algoritmos Genéticos para la Predicción de Riesgos Psicosociales en Docentes de Colegios Públicos Colombianos Información Tecnológica, vol. 29, no. 6, pp. 153–162, Dec. 2018, doi: 10.4067/s0718-07642018000600153.

- [73] ISO, “ISO 14064-1: Greenhouse gases — Part 1: Specification with guidance at the organization level,” 2018.
- [74] Green Software Foundation, “Principles of Sustainable Software Engineering,” IEEE Software, 2022.
- [75] M. K. Patterson, “Power and Energy Consumption in IT Systems,” IEEE Computer Society Technical Report, 2022.
- [76] S. Balaji et al., “Energy Behavior of Cloud-Based ML Execution Environments,” IEEE Transactions on Cloud Computing, 2023.
- [77] International Energy Agency, “Emission Factors for Mexico,” cited in IEEE Energy and Environment Proceedings, 2024.
- [78] J. Rojas et al., “Urban Mobility and Carbon Emissions in Latin American Megacities,” IEEE Transactions on Intelligent Transportation Systems, 2023.
- [79] A. Mittal et al., “Energy Efficiency of Machine Learning Models in Edge Devices,” IEEE Transactions on Sustainable Computing, vol. 8, no. 2, 2023.
- [80] ISO, “ISO 26000: Guidance on Social Responsibility,” 2010.
- [81] T. J. McCabe, “A Complexity Measure,” IEEE Transactions on Software Engineering, vol. SE-2, no. 4, 1976.
- [82] ISO/IEC, “25010: System and Software Quality Models,” 2011.
- [83] Microsoft, “Especificaciones y requisitos del sistema de Windows 11 | Microsoft Windows,” Windows. <https://www.microsoft.com/es-es/windows/windows-11-specifications>
- [84] “The Python tutorial,” Python Documentation. <https://docs.python.org/3/tutorial/index.html>
- [85] Transformative Mobility Lab / Factsheet, Mexico City — Modal split and public transport overview, 2021 (public data fact sheet; modal share: public transport $\approx$ 50%). TUMI
- [86] World Bank / Operational Evaluation & related analyses, Cost effectiveness of CO₂ reduction with hybrid and electric buses — example estimates for Mexico (electric bus $\approx$ 1 kWh/km $\rightarrow$ $\sim$ 0.6 kg CO₂/veh-km in Mexican grid)-
- [87] R. Kohavi, “A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection,” en Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI), Montreal, Canada, 1995, pp. 1137–1143.
- [88] M. Sokolova y G. Lapalme, “A systematic analysis of performance measures for classification tasks,” Information Processing & Management, vol. 45, no. 4, pp. 427–437, 2009.
- [89] D. M. W. Powers, “Evaluation: From Precision, Recall and F-Measure to ROC, Informedness, Markedness and Correlation,” Journal of Machine Learning Technologies, vol. 2, no. 1, pp. 37–63, 2011.

- [90] Scikit-learn Developers, “Classification metrics,” Scikit-learn Documentation. [En línea]. Disponible en: https://scikit-learn.org/stable/modules/model_evaluation.html. [Accedido: 27-may-2026].
- [91] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You Only Look Once: Unified, Real-Time Object Detection,” Proc. CVPR, 2016.
- [92] Ultralytics, “YOLO Documentation,” 2025.
- [93] P. Bovet y S. Benhamou, “Spatial analysis of animals’ movements,” *Journal of Theoretical Biology*, vol. 131, no. 4, pp. 419–433, 1988.
- [94] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [95] S. Hochreiter y J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [96] S. R. Datta et al., “Computational neuroethology,” *Nature*, vol. 562, pp. 361–370, 2018.
- [97] S. Pellow et al., “Validation of open arm entries in an elevated plus-maze,” *Journal of Neuroscience Methods*, vol. 14, pp. 149–167, 1985.
- [98] J. Cohen, “A coefficient of agreement for nominal scales,” *Educational and Psychological Measurement*, vol. 20, pp. 37–46, 1960.
- [99] J. R. Landis y G. G. Koch, “The measurement of observer agreement for categorical data,” *Biometrics*, vol. 33, no. 1, pp. 159–174, 1977.
- [100] G. E. P. Box, “Some theorems on quadratic forms,” *Annals of Mathematical Statistics*, vol. 25, no. 2, pp. 290–302, 1954.
- [101] D. C. Montgomery y G. C. Runger, *Applied Statistics and Probability for Engineers*, 7th ed. Wiley, 2018.
- [102] R. A. Fisher, *Statistical Methods for Research Workers*, 14th ed. Oliver and Boyd, 1970.
- [103] J. Cohen, *Statistical Power Analysis for the Behavioral Sciences*, 2nd ed. Routledge, 1988.
- [104] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2nd ed. Springer, 2009.
- [105] A. Ng, *Machine Learning Yearning*. Deeplearning.ai, 2018.

Apéndice

El cronograma completo del proyecto de los tres integrantes del equipo se encuentra disponible en el siguiente enlace, en un formato digital:

<https://smurl.es/2026-A155-Cronograma>

Prototipo I. Durante la primera etapa de desarrollo, alrededor de finales de junio y principios de julio, construimos un primer prototipo funcional para el análisis automatizado del comportamiento de roedores en el laberinto en cruz elevada. Este prototipo marcó un punto de partida importante: permitió comprobar la viabilidad del sistema, validar nuestras ideas iniciales y reconocer, con evidencia, las limitaciones técnicas que debíamos resolver para iteraciones posteriores.




Ilustración 61 "Ilustración del modelo [auditoria propia]"

1. Modelo inicial apenas entrenado. En esta primera fase, el modelo con el que trabajábamos estaba apenas en construcción: contábamos con muy pocas imágenes de entrenamiento y todavía no existía un dataset sólido ni estandarizado. Por esta razón, el desempeño inicial era limitado; el sistema lograba detectar al ratón, pero lo hacía con poca precisión y de manera inconstante. Fallaba especialmente cuando el animal cambiaba de orientación, se desplazaba rápido, entraba a zonas con sombra o cruzaba hacia los brazos cerrados. Aun con estas carencias, este primer modelo nos permitió comprobar que el enfoque era viable y que la base del proyecto funcionaba, aunque de manera rudimentaria.

2. Ejecución completamente en local. En esta segunda etapa, todo el sistema se ejecutaba únicamente en la computadora local, lo que significaba depender por completo del hardware personal disponible. Esto nos permitió tener un primer acercamiento práctico al flujo de trabajo, pero también nos enfrentó rápidamente a varias limitaciones importantes. El procesamiento de los videos resultaba muy lento debido a la ausencia de una GPU dedicada, y el equipo se sobrecalentaba con facilidad durante las corridas más largas. Además, trabajar solo con CPU hacía prácticamente imposible entrenar modelos más grandes o experimentar con arquitecturas complejas, lo que restringía nuestras opciones técnicas. Cada análisis requería bastante tiempo, ya que el modelo inicial tenía un bajo nivel de entrenamiento y el preprocesamiento cuadro por cuadro demandaba más recursos de los que la máquina podía ofrecer.

3. Primeras herramientas en Python y OpenCV. En esta etapa inicial, el desarrollo del sistema se apoyó completamente en Python y en un conjunto reducido de herramientas de visión por computadora, principalmente OpenCV. Con ellas implementamos las primeras funciones esenciales del flujo de trabajo: extracción de fotogramas, limpieza básica de imagen, delimitación manual de regiones de interés y dibujo de las detecciones sobre el video. Si bien las capacidades eran todavía limitadas, estos módulos nos permitieron construir un pipeline funcional capaz de cargar un video, identificar al espécimen y generar una visualización preliminar de su trayectoria dentro del laberinto. Gracias a estas pruebas, pudimos confirmar que el enfoque elegido era viable y que los componentes iniciales se integraban correctamente entre sí. Aunque el sistema aún no incorporaba técnicas avanzadas como estimación de postura, modelado temporal o minería de datos, este primer conjunto de herramientas fue suficiente para establecer las bases del análisis automatizado y abrir el camino para las siguientes etapas del proyecto.

4. Contador de eventos: funcional, pero aún limitado. El contador de eventos desarrollado en el prototipo inicial permitía registrar aspectos básicos del comportamiento del espécimen, como las entradas y salidas de los brazos, la presencia en zonas específicas y la permanencia aproximada en cada área del laberinto. Aunque cumplía con su propósito fundamental, su precisión y alcance eran todavía reducidos. El sistema dependía exclusivamente del movimiento del cuadro de detección, lo que ocasionaba errores cuando el ratón quedaba parcialmente oculto, se superponía con sombras o se desplazaba cerca de los bordes. Además, este contador no tenía la capacidad de diferenciar posturas ni de identificar eventos conductuales más complejos, como episodios de acicalamiento o periodos prolongados de inmovilidad, elementos esenciales para un análisis etológico más riguroso. A pesar de estas limitaciones, el módulo cumplió su función dentro del prototipo, pues permitió validar la estructura general del análisis y evidenció con claridad las áreas que requerían un desarrollo más profundo en etapas posteriores.

Prototipo II. En el segundo prototipo se logró un avance significativo respecto a la versión inicial, principalmente gracias a la incorporación de un modelo YOLOv11 entrenado con un conjunto sustancialmente mayor de imágenes. En esta iteración se utilizaron **1,954 imágenes cuidadosamente etiquetadas**, lo que permitió obtener un modelo considerablemente más robusto y preciso. Como resultado, la detección del espécimen mostró una mejora notable, alcanzando **aproximadamente un 94% de efectividad** durante la mayor parte del video. Las únicas fallas recurrentes se presentaron en los instantes iniciales, donde el modelo tendía a confundir al investigador con el ratón, un problema esperado que será abordado con más datos y técnicas de depuración en las siguientes iteraciones.




Ilustración 62 "Ilustración del modelo prototipo II [auditoria propia]"

A pesar de este avance en detección, en esta etapa **aún no se había integrado la estimación de postura (pose stimation)**, una funcionalidad que se evaluará más adelante para complementar la clasificación conductual y enriquecer el análisis etológico. Sin embargo, incluso sin esta capa adicional de análisis, el sistema ya mostraba un comportamiento mucho más estable que la versión previa. El **contador de eventos**, por ejemplo, **presentó mejoras significativas**: dejó de desaparecer, mantuvo su consistencia a lo largo de la grabación y reflejó de manera más confiable las entradas y tiempos de permanencia en cada zona del laberinto.

Otro cambio relevante de esta iteración fue la **migración del procesamiento a una GPU en Google Colab**, lo que permitió un rendimiento muy superior al obtenido en ejecución local. La mayor capacidad de cómputo redujo los tiempos de inferencia y facilitó la manipulación de modelos más complejos. No obstante, esta transición trajo consigo ciertas limitaciones técnicas, especialmente relacionadas con la interacción gráfica.

En Colab no fue posible desplegar ventanas para delimitar visualmente las áreas de interés del laberinto, por lo que la marcación de regiones se tuvo que realizar de forma manual introduciendo coordenadas. Aunque este proceso no afectó el funcionamiento general, sí representó un obstáculo

operativamente importante que deberá solucionarse en prototipos futuros para garantizar una experiencia más fluida y automatizada.

Este segundo prototipo representa un progreso considerable: el modelo detecta con mucha mayor precisión, el contador de eventos opera de manera estable y la infraestructura de ejecución es más potente y eficiente. Aun con sus limitaciones, se consolidaron las bases para avanzar hacia una versión más robusta, donde se incorporará pose estimation, más datos de entrenamiento y nuevas evaluaciones del rendimiento general del sistema.

Transcripción de la entrevista realizada al Dr. Sandino el 30 de septiembre de 2025:

1. **¿Cuál sería el principal problema que se espera resolver con la aplicación? ¿Y qué resultado considera exitoso?**

Sandino: El principal problema que tenemos, como reto, es poder interpretar de forma automatizada las diferentes conductas en este modelo. Y lo que lograríamos es estandarizar la interpretación de manera que no dependa del observador la asignación de las diferentes conductas que se le dan a la rata durante el experimento. Ok. Perfecto.

2. **Sobre los datos ¿Qué tipo de videos y anotaciones necesitamos recolectar para que el sistema sea realmente útil?**

Sandino: Se necesita la captura de un video que pueda reflejar con el detalle suficiente todas las conductas que queremos evaluar. Para que entonces podamos hacer una adecuada interpretación de esas conductas.

3. **De las funcionalidades. ¿Qué conductas o métricas considera más importantes que el sistema detecta automáticamente? Por ejemplo, trayectorias, tiempo de movilidad, o zonas de permanencia.**

Sandino: Si bien todas nos dan información diferente que es útil para poder interpretar el efecto que podamos tener en una molécula con fines de utilización como ansiolítico. Los tiempos en brazos abiertos y los tiempos en brazos cerrados son los principales indicadores de que se está teniendo un efecto ansiolítico. A qué nivel y con qué características nos sirve el resto de los parámetros; los tiempos en brazos cerrados y tiempo en brazos abiertos en general son los principales indicadores.

4. **¿Qué visualizaciones les resultan más útiles para la toma de decisiones? Por ejemplo, podemos hacer gráficas, heatmaps (mapas de calor), reportes comparativos o alertas.**

Sandino: Los gráficos son más útiles porque son los que solemos utilizar, pero personalmente a mí me gustan los mapas de calor en el equipo donde me puede extraer el mismo valor que pondríamos en los gráficos, en los parámetros globales. Entonces, si en el mapa de calor se me puede poner en un brazo o en los brazos cerrados el tiempo total, pero yo además puedo ver qué tanto se desplaza en diferentes regiones de ese brazo me sería muy útil.

5. **¿Qué nivel de precisión o concordancia espera que considere aceptable para que la aplicación sea adoptada? Por ejemplo, más del 90% o 95%**

Sandino: Nosotros actualmente lo hacemos con tres personas diferentes que hacen la evaluación de forma independiente, entonces la variación que solemos tener entre esas tres personas suele ser entre el 10% y el 15% del valor medio. Por lo tanto, entre el 90% y el 95% de precisión sería excelente para fines de tomar como verdaderos los datos que nos arroja el análisis.

6. Respecto a usabilidad ¿Qué tan importante es que la aplicación tenga una interfaz sencilla y accesible para las personas sin experiencia técnica?

Sandino: Muy importante. Tengo médicos que se dedican a hacer estos experimentos. Mientras más amigable sea la interfaz pues es más asequible que puedan ellos utilizarla con precisión y que sea adecuado el uso.

Equipo: Lo que teníamos pensado era hacer la aplicación, y nada más que seleccionen el vídeo, recortar dicho vídeo, y definir el área a estudiar.

Sandino: De hecho, algo que tal vez podría funcionar es que automáticamente uno pudiera decir “Empieza a registrar a partir de tal segundo”. De manera que no dependa tanto que la persona que vaya a analizar el vídeo lo recorte o lo tenga que recortar. Porque eso implica por lo menos un programa de edición de vídeo que tienen que aprender a utilizar, pero si en la interfase le podemos poner “Empieza a analizar a partir de tal segundo” ... Y que entonces el conteo empieza a partir de ese segundo, no importa si el vídeo tiene diez segundos que se tienen que omitir o cinco o tres, sino nada más uno lo previsualiza y dice “bueno, a partir del segundo quince es cuando se va a poner, a empezar a tomar, porque ya se salió el operario, ya se estabilizó la imagen y la rata ya se estabiliza también”.

7. Este es sobre la sobriedad de interfaz ¿Prefiere una aplicación web con dashboards interactivos o reportes descargables en PDF o Excel?

Sandino: Yo creo que en Excel porque eso nos permite llevarlo a otros programas. Por ejemplo, hay veces que utilizamos graficadores como Origin nada más por fines de publicación, porque Origin nos permite hacer gráficos (BueR, o, ya los hacemos más en R, pero todavía hay quienes lo hacen en Origin) ya con fines de publicación, donde podemos editar como lo pida la revista, el tamaño de los títulos, de los ejes, o cualquier cosa, ya lo hacemos también en R, con Excel nos puede servir muy bien también R.

Equipo: Entonces serían dos cosas, o sea, un Excel con los datos ya analizados, o digamos en crudo, y además las gráficas que se muestran en el programa, ¿no?

Sandino: Sí. Finalmente, los gráficos nos van a ayudar a ir viendo cómo se comporta el espécimen durante el video, pero esas gráficas seguramente no van a ser las que llevemos a la presentación final de los resultados, seguramente nos servirán los datos analizados o crudos, de donde provienen esas gráficas, pero para Re graficarlo nada más.

8. ¿Desea tener un registro de todos los dashboards y análisis realizados?

Sandino: Dependerá de la capacidad de cómputo y almacenamiento, ya que los videos ocupan mucho espacio. Lo ideal sería conservar únicamente los resultados procesados, no los videos, para evitar requerir demasiado almacenamiento. Con respecto al procesamiento, el laboratorio cuenta con varias opciones: una computadora con buena capacidad, un pequeño clúster y la posibilidad de usar equipos con GPU o incluso servicios en la nube si fuera necesario. Para decidir cuál es la mejor opción, es importante conocer primero los requerimientos óptimos de cómputo del sistema.




Ilustración 64: Diagrama de casos global. [autoría propia]




Ilustración 65: Diagrama de casos de uso de autenticación de usuarios y gestión de acceso. [autoría propia]




Ilustración 66: Diagrama de casos de uso de ingesta de video. [autoría propia]




Ilustración 67: Diagrama de casos de uso de extracción de keypoints . [autoría propia]




Ilustración 68: Diagrama de casos de uso de configuración de regiones de interés. [autoría propia]




Ilustración 69: Diagrama de casos de uso de análisis final conductual. [autoría propia]




Ilustración 70: Diagrama de casos de uso del módulo de resultados y estadísticas. [autoría propia]




Ilustración 71: Diagrama de casos de uso del módulo de comparación. [autoría propia]




Ilustración 72: Diagrama de casos de uso de administración del sistema. [autoría propia]

