



**INSTITUTO POLITÉCNICO NACIONAL**  
**ESCUELA SUPERIOR DE CÓMPUTO**



**ESCOM**

*Trabajo Terminal*

**“Prototipo para análisis automatizado y visualización de comportamiento de especímenes en modelos de ansiedad”**

*2026-A155*

*Presentan*

**Lázaro Vivar Gabrielle**

**Múzquiz Palacios Ernesto Javier**

**Portocarrero Rodríguez Habid**

*Directores*

Ramírez Guzmán Alicia Marcela

Salas Ramírez Israel

Diciembre 2025



INSTITUTO POLITÉCNICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO



SUBDIRECCIÓN ACADÉMICA

No de TT 2026-A155

diciembre de 2025

Documento Técnico

## **“Prototipo para análisis automatizado y visualización de comportamiento de especímenes en modelos de ansiedad”**

*Presentan*

**Lázaro Vivar Gabrielle<sup>1</sup>**

**Múzquiz Palacios Ernesto Javier<sup>2</sup>**

**Portocarrero Rodríguez Habid<sup>3</sup>**

*Directores*

Ramírez Guzmán Alicia Marcela

Salas Ramírez Israel

### **RESUMEN**

El presente proyecto desarrolla un prototipo de software orientado al análisis automatizado del comportamiento animal en modelos experimentales de ansiedad. Su propósito es optimizar los procesos de observación y evaluación que tradicionalmente se realizan de forma manual, reduciendo tiempos y errores humanos. A través de la aplicación de principios de ingeniería de software, se busca ofrecer una herramienta confiable, escalable y eficiente que contribuya al avance de la investigación científica dentro del ámbito biomédico.

<sup>1</sup>glazarov1500@alumno.ipn.mx

<sup>2</sup>emuzquizp1800@alumno.ipn.mx

<sup>3</sup>hportocarreror1700@alumno.ipn.mx

## CARTA RESPONSIVA

Que otorga visto bueno y avala la conclusión de documentación del Trabajo Terminal bajo los lineamientos establecidos por la Comisión Académica de Trabajos Terminales (CATT)

CDMX, diciembre de 2025

**M. EN C. IVAN GIOVANNI MOSSO GARCÍA  
PRESIDENTE DE LA COMISIÓN ACADÉMICA DE TRABAJOS TERMINALES  
P R E S E N T E**

**EN ATENCIÓN A:**

**M. EN A.N. MARÍA MAGDALENA SALDIVAR ALMOREJO  
SECRETARIA EJECUTIVA**

|   |  |
|---|--|
| Por medio de la presente, se informa que el Trabajo Terminal Núm. | 2026-A155  |
| Que lleva por Título:   | Prototipo para análisis automatizado y visualización de comportamiento de especímenes en modelos de ansiedad |

Fue concluido satisfactoriamente por:

Lázaro Vivar Gabrielle  
Múzquiz Palacios Ernesto Javier  
Portocarrero Rodríguez Habid

Se avala que la documentación entregada mediante discos en formato DVD fue **revisada de manera precisa y exhaustiva** con el propósito de asegurar que los avances desarrollados bajo la supervisión de quien o quienes suscriben, hayan cumplido con lo planteado en el protocolo original, así como en lo establecido por el Documento Rector de Operación y Evaluación para los Trabajos Terminales de la ESCOM.

**ATENTAMENTE  
“LA TÉCNICA AL SERVICIO DE LA PATRIA”**

---

(Nombre completo y Firma)  
Director

---

(Nombre completo y Firma)  
Directora

**Palabras clave:**

Modelos de ansiedad, análisis Conductual Animal, ensayos Farmacológicos, visión por computadora (Computer Vision), estimación de Postura, detección de Objetos, inteligencia artificial (IA), aprendizaje automático (Machine Learning), minería de Datos (Data Mining), dashboard interactivo.

## **Advertencia**

*"Este documento contiene información desarrollada por la Escuela Superior de Cómputo del Instituto Politécnico Nacional, a partir de datos y documentos con derecho de propiedad y, por lo tanto, su uso quedará restringido a las aplicaciones que explícitamente se convengan."*

*La aplicación no convenida exime a la escuela su responsabilidad técnica y da lugar a las consecuencias legales que para tal efecto se determinen.*

*Información adicional sobre este reporte técnico podrá obtenerse en:*

*La Subdirección Académica de la Escuela Superior de Cómputo del Instituto Politécnico Nacional, situada en Av. Juan de Dios Bátiz s/n Teléfono: 57296000, extensión 52000.*

## Agradecimientos

El equipo desea expresar su más sincero agradecimiento al **Instituto Politécnico Nacional** y a la **Escuela Superior de Cómputo (ESCOM)** por ser la base de nuestra formación profesional, el apoyo, orientación y por brindarnos los recursos necesarios para la realización de este proyecto.

A nuestros **directores**, la **Dra. Alicia Marcela Ramírez Guzmán** y el **Dr. Israel Salas Ramírez**, por su guía, paciencia y compromiso. Su acompañamiento constante, su exigencia académica y su apoyo humano fueron fundamentales para la consolidación de este trabajo. Gracias por enseñarnos que la investigación y la tecnología deben siempre ir acompañadas de ética, rigor y propósito.

A la **Escuela Nacional de Medicina y Homeopatía (ENMyH)**, por su colaboración y disposición en la etapa experimental del proyecto, y por permitirnos vincular la ingeniería con la ciencia biomédica.

A **nuestras familias**, quienes con amor, comprensión y apoyo incondicional fueron nuestra fortaleza durante todo el proceso. Su confianza nos motivó a superar cada obstáculo y a culminar esta etapa con orgullo.

A nuestros **compañeros, docentes y amigos** que, directa o indirectamente, compartieron su tiempo, conocimiento y entusiasmo, enriqueciendo este proyecto con su colaboración y sus ideas.

# ÍNDICE

## Contenido

|  |                                      |
|--|--------------------------------------|
| Agradecimientos .....  | 6                                    |
| Indice de figuras .....  | <b>¡Error! Marcador no definido.</b> |
| Glosario de términos .....   | <b>¡Error! Marcador no definido.</b> |
| Abreviaturas .....   | 18                                   |
| Capítulo 1. Introducción .....   | 19                                   |
| 1.1 Antecedentes .....   | 19                                   |
| 1.2 Planteamiento del problema.....  | 20                                   |
| 1.3 Propuesta de solución.....   | 20                                   |
| 1.4 Objetivo general.....  | 21                                   |
| 1.4.1 Objetivos específicos .....  | 21                                   |
| 1.5 Justificación .....  | 22                                   |
| 1.6 Alcance del proyecto.....  | 22                                   |
| 1.7 Metodología .....  | 23                                   |
| Capítulo 2. Estado del arte. ....  | 25                                   |
| 2.1 Análisis etológico y temporal del comportamiento similar a la ansiedad: el modelo de EPM elevado 20 años después .....                         | 26                                   |
| 2.2 El laberinto en T elevado como modelo experimental de ansiedad.....  | 26                                   |
| 2.3 El uso del EPM como un ensayo del comportamiento relacionado con la ansiedad en roedores.....  | 26                                   |
| 2.4 Prueba del EPM Combinado con Software de Seguimiento por Video para Investigar el Efecto Ansiolítico de Suplementos Cetogénicos Exógenos ..... | 27                                   |
| 2.5 Prueba del EPM para Evaluar el Comportamiento Similar a la Ansiedad en el Ratón .....  | 28                                   |
| 2.6 El diazepam provoca efectos sedantes más que ansiolíticos en ratones C57BL/6J .....  | 28                                   |
| 2.7 ezTrack: Un flujo de análisis de video de código abierto para la investigación del comportamiento animal .....                                 | 29                                   |
| 2.8 Analixity: Un sistema de análisis de código abierto y bajo costo para la prueba de EPM, basado en técnicas de visión por computadora .....     | 30                                   |
| 2.9 EthoVision .....   | 30                                   |
| 2.10 ANY-maze .....  | 31                                   |

|   |    |
|---|----|
| 2.11 Tabla Comparativa .....  | 31 |
| Capítulo 3. Marco Teórico .....   | 34 |
| 3.1 Visión por computadora para seguimiento de objetos .....                        | 34 |
| 3.1.1 YOLO (You Only Look Once).....  | 34 |
| 3.1.2 DeepLabCut.....   | 36 |
| 3.1.3 Estimación de postura (Pose Estimation).....                                  | 38 |
| 3.1.4 CAMShift y métodos clásicos de seguimiento .....                              | 40 |
| 3.1.5 Redes Neuronales Convolucionales (CNN) aplicadas a visión por computadora ... | 42 |
| 3.2 Machine Learning para Series Temporales .....                                   | 44 |
| 3.2.1 Redes Neuronales Recurrentes (RNN) .....                                      | 44 |
| 3.2.2 LSTM (Long Short-Term Memory).....  | 45 |
| 3.2.3 Transformers .....  | 47 |
| 3.2.4 Coeficiente Kappa de Cohen para validación de concordancia.....               | 49 |
| 3.3. Minería de Datos y Clasificación de Comportamientos .....                      | 51 |
| 3.3.1 K-Means (Clustering).....   | 51 |
| 3.3.2 Random Forest .....   | 53 |
| 3.3.3 Máquinas de Vectores de Soporte (SVM).....                                    | 55 |
| 3.3.4 Reducción de dimensionalidad .....  | 57 |
| 3.4 Modelos experimentales en etología y neurociencia conductual .....              | 59 |
| 3.4.1 Conceptos etológicos del comportamiento ansioso .....                         | 59 |
| 3.4.1.1 Exploración .....   | 59 |
| 3.4.1.2 Evitación .....   | 61 |
| 3.4.1.3 Inmovilidad/congelación .....   | 63 |
| 3.4.2 Laberinto en Cruz Elevada (EPM) .....   | 64 |
| Capítulo 4. Análisis.....   | 67 |
| 4.1 Requerimientos .....  | 67 |
| 4.1.1 Requerimientos Funcionales (RF).....  | 67 |
| 4.1.2 Requerimientos No Funcionales (RNF) .....                                     | 68 |
| 4.1.3 Reglas del negocio .....  | 68 |
| 4.2 Análisis de las herramientas a utilizar.....                                    | 70 |
| 4.2.1 Análisis de técnicas de detección de objetos .....                            | 71 |
| 4.2.2 Análisis de técnicas de estimación de pose con aprendizaje profundo.....      | 71 |

|  |     |
|--|-----|
| 4.2.3 Análisis de técnicas de estimación de pose .....                 | 71  |
| 4.2.4 Análisis de herramientas de seguimiento visual .....             | 72  |
| 4.2.5 Análisis de conceptos etológicos para análisis de ansiedad ..... | 72  |
| 4.3 Análisis de riesgos .....  | 74  |
| 4.3.6 Identificación de requerimientos técnicos .....                  | 79  |
| 4.3.7 Requerimientos del prototipo .....                               | 80  |
| 4.4 Análisis de factibilidad .....                                     | 80  |
| 4.4.1 Factibilidad tecnológica .....                                   | 80  |
| 4.4.1.1 Evaluación de recursos actuales y brechas tecnológicas .....   | 80  |
| 4.4.1.2 Simulación, modelado y pruebas .....                           | 80  |
| 4.4.1.3 Evaluación de compatibilidad e integración .....               | 80  |
| 4.4.2 Factibilidad operativa.....                                      | 81  |
| 4.4.3 Factibilidad económica .....                                     | 82  |
| 4.4.3.1 Costos fijos .....   | 82  |
| 4.4.3.2 Costos variables .....   | 83  |
| 4.4.3.3 Costos totales estimados del desarrollo del proyecto .....     | 84  |
| 4.4.3.4 Conclusión de viabilidad económica .....                       | 84  |
| 4.4.4 Factibilidad legal.....  | 84  |
| 4.4.4.1 Identificación del marco legal aplicable .....                 | 84  |
| 4.5 Análisis de sostenibilidad .....                                   | 85  |
| Capítulo 5. Diseño .....   | 90  |
| 5.1 Arquitectura del prototipo .....                                   | 90  |
| 5.2 Modelo de bases de datos .....                                     | 90  |
| 5.3 Casos de uso.....  | 91  |
| 5.3.1 Casos de uso del prototipo .....                                 | 91  |
| 5.3.2 Diagramas de secuencia .....                                     | 93  |
| 5.3.3 Diagrama de clases.....  | 107 |
| Capítulo 6. Desarrollo .....   | 110 |
| 6.1 Mockups del prototipo .....  | 110 |
| 6.1.1 Vista previa del inicio de sesión.....                           | 110 |
| 6.1.2 Vista previa de registro. ....                                   | 111 |
| 6.1.3 Vista previa de cambio de contraseña. ....                       | 112 |

|   |     |
|---|-----|
| 6.1.4 Vista previa de inicio del prototipo..... | 112 |
| Conclusiones.....                               | 114 |
| Trabajo a futuro .....                          | 114 |
| Referencias.....                                | 115 |
| Apéndice .....                                  | 122 |

## INDICE DE ILUSTRACIONES

|  |    |
|--|----|
| <i>Ilustración 1: OpenAI (2025). Imagen generada por ChatGPT sobre el concepto de metodología de espiral de Boehm [Imagen generada por IA]. ChatGPT (versión 5.1). Archivo creado por el usuario, sin URL.</i> ..... | 25 |
| <i>Ilustración 2: Fases de un sistema de Visión Artificial.....</i>  | 34 |
| <i>Ilustración 3: Pasos para el reconocimiento de patrones.....</i>  | 34 |
| <i>Ilustración 4: Ventana de seguimiento de un objeto en tiempo real.....</i>  | 35 |
| <i>Ilustración 5: Trayectoria de un objeto seguido.....</i>  | 35 |
| <i>Ilustración 6: Esquema del algoritmo de seguimiento de CAMshift .....</i>   | 37 |
| <i>Ilustración 7: Elipse sobre objeto en seguimiento .....</i>   | 38 |
| <i>Ilustración 8: Cuadro inicial y final del video utilizado para el ensayo[4] .....</i>   | 38 |
| <i>Ilustración 9: Representación de keypoints y campos de afinidad para múltiples personas (OpenPose) [23] .....</i>   | 39 |
| <i>Ilustración 10: Estrategias de asociación de partes en DeepLabCut [12] .....</i>  | 39 |
| <i>Ilustración 11: Secuencia de fútbol americano siguiendo al jugador 75 [25].....</i>   | 40 |
| <i>Ilustración 12: Una imagen de video y su probabilidad de piel en la imagen [24] .....</i>   | 41 |
| <i>Ilustración 13: Ilustración 13. Ejemplo de seguimiento de un objeto con cambio de escala [26].....</i>  | 42 |
| <i>Ilustración 14: Arquitectura básica de una CNN .....</i>  | 43 |
| <i>Ilustración 15: Pipeline de detección por CNN .....</i>   | 43 |
| <i>Ilustración 16: Arquitectura básica de una RNN .....</i>  | 44 |
| <i>Ilustración 17: Puerta de olvido .....</i>  | 46 |
| <i>Ilustración 18: Puerta de entrada y valores candidatos.....</i>   | 46 |
| <i>Ilustración 19: Actualización del estado de la celda .....</i>  | 46 |
| <i>Ilustración 20: Puerta de salida y generación del estado oculto.....</i>  | 47 |
| <i>Ilustración 21: Arquitectura general del Transformer.....</i>   | 48 |
| <i>Ilustración 22: Atención escalada por producto punto y multi-head attention .....</i>   | 49 |
| <i>Ilustración 23: Ejemplo de Matriz de confusión temporal.....</i>  | 51 |
| <i>Ilustración 24: Representación gráfica del proceso iterativo (asignación y actualización) .....</i>   | 52 |
| <i>Ilustración 25: Ejemplo de diferentes resultados de clustering con distintas distribuciones.....</i>  | 53 |
| <i>Ilustración 26: Múltiples árboles de decisión en un Random Forest [34] .....</i>  | 54 |
| <i>Ilustración 27: Diagrama esquemático de los métodos de ensamblaje [35] .....</i>  | 54 |
| <i>Ilustración 28: Ejemplo de un problema de clasificación en un espacio bidimensional. Los vectores de soporte marcados con cuadros grises definen el margen mayor de separación entre las 2 clases [36] .....</i>  | 56 |
| <i>Ilustración 29: Otro ejemplo de una SVM lineal que muestra el hiperplano óptimo, sus márgenes y los vectores de soporte que determinan la separación entre clases [37].....</i>                                   | 57 |
| <i>Ilustración 30: Ejemplo conceptual del problema de dimensionalidad en un sistema de una pelota en un resorte observado desde 3 cámaras [31].....</i>  | 58 |
| <i>Ilustración 31: Nube de datos simulados para la cámara A con indicación de varianza de señal y ruido. Adaptada de Shlens [31] .....</i>   | 59 |
| <i>Ilustración 32: Ejemplo de un módulo de seguimiento de ezTrack [5]. .....</i>   | 60 |
| <i>Ilustración 33: Representación de módulos conductuales y transiciones destacando micro movimientos relevantes para la exploración [17] .....</i>  | 61 |
| <i>Ilustración 34: Red de la corteza prefrontal media y su implicación en la evitación defensiva [40] .....</i>  | 62 |
| <i>Ilustración 35: Esquema que muestra como la interacción entre el miedo y la evitación permite identificar los procesos neuroconductuales subyacentes [41] .....</i>   | 63 |
| <i>Ilustración 36: Esquema de la cascada defensiva [42] .....</i>  | 63 |
| <i>Ilustración 37: Esquema del EPM desde vista superior. Los brazos horizontales son abiertos mientras los verticales son cerrados [44]. .....</i>   | 64 |
| <i>Ilustración 3938: Arquitectura general del prototipo [autoría propia]</i> .....   | 90 |

|   |     |
|---|-----|
| 39 .....  | 90  |
| <i>Ilustración 40: "Modelo de base de datos [autoría propia]"</i> .....                           | 91  |
| <i>Ilustración 41: "Casos de uso del prototipo [autoría propia]"</i> .....                        | 92  |
| <i>Ilustración 42: "Diagramas de secuencia [autoría propia]"</i> .....                            | 93  |
| <i>Ilustración 43: "Proceso de inicio de sesión del investigador [autoría propia]"</i> .....      | 94  |
| <i>Ilustración 44: "Proceso de inicio de sesión del administrador [autoría propia]"</i> .....     | 95  |
| <i>Ilustración 45: "Proceso de cambio de contraseña del investigador [autoría propia]"</i> .....  | 96  |
| <i>Ilustración 46: "Proceso de cambio de contraseña del administrador [autoría propia]"</i> ..... | 97  |
| <i>Ilustración 47: "Manejo de usuarios [autoría propia]"</i> .....                                | 98  |
| <i>Ilustración 48: Configuración de Perfil [autoría propia]</i> .....                             | 99  |
| <i>Ilustración 49: "Configurar Perfil Administrador [autoría propia]"</i> .....                   | 100 |
| <i>Ilustración 50: "Cerrar Sesión [autoría propia]"</i> .....                                     | 101 |
| <i>Ilustración 51: "Cerrar sesión Administrador [autoría propia]"</i> .....                       | 101 |
| <i>Ilustración 52 "Prototipo de notificaciones [autoría propia]"</i> .....                        | 103 |
| <i>Ilustración 53: "Procesos de generación de análisis [autoría propia]"</i> .....                | 105 |
| <i>Ilustración 54: "Consulta de reportes de análisis [autoría propia]"</i> .....                  | 106 |
| <i>Ilustración 55: "Consulta y generación de comparaciones [autoría propia]"</i> .....            | 107 |
| <i>Ilustración 56: "Diagrama de clases [autoría propia]"</i> .....                                | 109 |
| <i>Ilustración 57: "Vista previa de inicio de sesión [autoría propia]"</i> .....                  | 110 |
| <i>Ilustración 58: "Vista previa del registro [autoría propia]"</i> .....                         | 111 |
| <i>Ilustración 59: "Cambiar contraseña [autoría propia]"</i> .....                                | 112 |
| <i>Ilustración 60: "Vista previa del inicio del prototipo [autoría propia]"</i> .....             | 113 |
| <i>Ilustración 61 "Vista previa del administrador [autoría propia]"</i> .....                     | 113 |
| <i>Ilustración 62 "Ilustración del modelo [auditoria propia]"</i> .....                           | 122 |
| <i>Ilustración 63 "Ilustración del modelo prototipo II [auditoria propia]"</i> .....              | 124 |

## INDICE DE TABLAS

|  |    |
|--|----|
| <i>Tabla 1: Comparación de trabajos similares [autoría propia]</i> .....   | 33 |
| <i>Tabla 2: Complejidad por capa y longitud de camino para diferentes arquitecturas</i> .....  | 49 |
| <i>Tabla 3: "Requerimientos Funcionales (RF)".....</i>   | 67 |
| <i>Tabla 4: "Requerimientos No Funcionales (RNF)</i> .....   | 68 |
| <i>Tabla 5: "Reglas de Negocio"</i> .....  | 70 |
| <i>Tabla 6: "Tabla de análisis de técnicas de detección de objetos [autoría propia]" .....</i>   | 71 |
| <i>Tabla 7: "Tabla de análisis de técnicas de estimación de pose con aprendizaje profundo [autoría propia]" .....</i>                  | 71 |
| <i>Tabla 8: "Tabla de análisis de técnicas de estimación de pose [autoría propia]" .....</i>   | 72 |
| <i>Tabla 9: "Tabla de análisis de herramientas de seguimiento visual [autoría propia]" .....</i>                                       | 72 |
| <i>Tabla 10: "Tabla de análisis de arquitecturas de redes neuronales profundas para visión por computadora [autoría propia]" .....</i> | 72 |
| <i>Tabla 11: Costos totales estimados del desarrollo del proyecto .....</i>  | 84 |

## Glosario de términos

|                              |   |
|------------------------------|---|
| Acicalamiento                | Conducta natural en roedores que consiste en limpiarse o frotarse el cuerpo. En modelos de ansiedad, su frecuencia puede indicar niveles de tensión o estrés. |
| Algoritmo                    | Conjunto de reglas matemáticas que permiten resolver un problema (ej. clasificar conductas de roedores).  |
| Analgésico                   | Fármaco que disminuye o suprime el dolor.[1]  |
| Anestésico                   | Fármaco que causa la parcial o total ausencia de sensibilidad.[1]   |
| Anotación manual             | Registro de comportamientos realizado por humanos (etólogos) para entrenar o validar sistemas de IA.  |
| Aprendizaje no supervisado   | Método de machine learning que agrupa o estructura datos sin etiquetas previas, útil para descubrir patrones ocultos (ej. clustering).                        |
| Aprendizaje supervisado      | Tipo de aprendizaje automático donde el modelo se entrena con datos etiquetados para reconocer patrones y hacer predicciones.                                 |
| Back-end                     | Parte del sistema que gestiona la lógica interna, almacenamiento y procesamiento de datos. No es visible para el usuario final.                               |
| Base de datos relacional     | Estructura de almacenamiento de datos organizada en tablas con relaciones entre sí. Permite consultar, filtrar y gestionar información de forma eficiente.    |
| Big Data                     | Procesamiento de grandes volúmenes de datos (ej. videos de varios minutos de experimentos) que requieren herramientas computacionales avanzadas.              |
| Clustering                   | Técnica de minería de datos que agrupa elementos con características similares (ej. patrones conductuales según fármaco).                                     |
| Red Neuronal Convolutacional | Tipo de IA para analizar imágenes/videos, identificando patrones espaciales (ej. posturas de roedores).   |
| Coeficiente de concordancia  | Métrica estadística usada para evaluar el grado de acuerdo entre evaluadores o modelos, como el coeficiente Kappa.  |
| Computer Vision              | Visión por computadora. Área de la IA dedicada a interpretar imágenes y videos mediante algoritmos (detección, seguimiento, análisis de postura, etc.)        |

|                                    |   |
|------------------------------------|---|
| CONBIOÉTICA                        | Normativa mexicana que regula el uso ético de animales en investigación.  |
| Dashboard                          | Panel visual interactivo que muestra resultados clave (ej. Gráficas de actividad en tiempo real)  |
| Deep Learning                      | Subcampo del aprendizaje automático basado en redes neuronales profundas capaces de aprender patrones complejos.                                  |
| DeepLabCut                         | Sistema de código abierto basado en deep learning para estimación precisa de postura en animales.   |
| Laberinto en Cruz elevada          | Prueba para medir ansiedad en roedores, donde el tiempo en brazos abiertos vs. cerrados indica niveles de estrés.                                 |
| Feature                            | Característica. Variable numérica o descriptor extraído de los datos (ej. distancia recorrida, tiempo en brazos abiertos).                        |
| Fármaco                            | Cualquier sustancia que no sea alimento, y que se use para prevenir, diagnosticar, tratar o aliviar los síntomas de una enfermedad o afección.[7] |
| Heatmap (Mapa de calor)            | Mapa de calor. Visualización gráfica donde los colores representan la intensidad de visitas o actividad en zonas del laberinto.                   |
| IA                                 | Inteligencia Artificial. Sistemas que imitan aprendizaje humano para realizar tareas complejas (ej. reconocer patrones de conducta).              |
| Inferencia                         | Proceso mediante el cual un modelo entrenado realiza predicciones sobre nuevos datos.   |
| K-Means                            | Algoritmo de clustering que agrupa datos en k categorías basadas en similitud.  |
| Kappa de Cohen ( $\kappa$ )        | Métrica estadística que mide el acuerdo entre evaluadores (ej. humano vs. IA), ajustando el azar.   |
| Red de memoria a corto-largo plazo | Tipo de red neuronal para analizar secuencias temporales (ej. movimientos entre zonas de la cruz elevada)   |
| Machine Learning                   | Aprendizaje Automático. Subcampo de la IA donde los sistemas “aprenden” de datos sin ser programados explícitamente.                              |
| Minimización de ruido              | Proceso que reduce variaciones indeseadas en imágenes o señales para mejorar su análisis.   |
| Modelo experimental                | Estructura o protocolo estandarizado para estudiar un fenómeno biológico (como la ansiedad en roedores).  |
| Normalización de Datos             | Procedimiento de ajustar variables a rangos comparables para evitar sesgos en modelos matemáticos.  |
| Placebo                            | Sustancia sin efecto farmacológico utilizada como control en ensayos experimentales.  |

|                                |  |
|--------------------------------|--|
| Plotly Dash                    | Framework para crear dashboards interactivos en Python.  |
| Pose Estimation                | Estimación de postura. Proceso de identificar puntos corporales (ej. cabeza, hocico, columna) para interpretar posturas y movimientos finos. |
| Preprocesamiento               | Limpieza y preparación de datos (ej. eliminar ruido en videos) antes del análisis.   |
| Random Forest                  | Algoritmo de aprendizaje supervisado basado en múltiples árboles de decisión para clasificar comportamientos.                                |
| Reconocimiento de patrones     | Proceso por el cual un algoritmo identifica regularidades en los datos (ej. detectar grooming o inmovilidad).                                |
| Red neuronal                   | Modelo computacional inspirado en el cerebro humano, compuesto por nodos conectados capaces de aprender de datos.                            |
| Resolución espacial            | Grado de detalle con el que se captura una imagen o video.   |
| Red Neuronal Recurrente        | Tipo de red neuronal diseñada para procesar secuencias temporales, como trayectorias o series de video.                                      |
| Área de interés                | Zona específica del video que se analiza separadamente, como los brazos abiertos o cerrados del EPM.   |
| Simulación                     | Ejecución de pruebas controladas que imitan condiciones reales para validar modelos o sistemas.  |
| Máquina de vectores de soporte | Support Vector Machine. Algoritmo de clasificación que separa datos mediante hiperplanos en un espacio multidimensional.                     |
| Threshold (Umbral)             | Valor numérico a partir del cual se clasifica un evento o comportamiento (ej. inmovilidad si velocidad < X).                                 |
| Tracking (Seguimiento)         | Seguimiento. Proceso mediante el cual el sistema identifica y sigue la posición del animal cuadro por cuadro en un video.                    |
| Tranquilizante                 | Clase de medicamentos psicotrópicos que se emplean para reducir la tensión y la ansiedad.[8]   |
| Tuberculina                    | Extracto proteico obtenido de Mycobacterium tuberculosis.  |
| Tuberculinizado                | Animal al que se le aplica mediante administración intradérmica unidades de tuberculina en un periodo de tiempo.                             |
| Interfaz de usuario            | Parte visual de un software con la que interactúa el usuario (botones, paneles, gráficos).   |

|  |  |
|--|--|
| Vectorización                                  | Conversión de movimientos en coordenadas numéricas (ej. [x, y, t]) para análisis cuantitativo.                     |
| You Only Look Once (Solo puedes mirar una vez) | Modelo de detección de objetos en tiempo real que localiza rápidamente instancias de interés en imágenes o videos. |
| Overfitting (Sobreajuste)                      | ocurre cuando un modelo de aprendizaje automático se ajusta demasiado a los datos de entrenamiento.                |

## Abreviaturas

|      |   |
|------|---|
| CNN  | Convolutional Neural Networks (Red Neuronal Convolucional). |
| EPM  | Elevated Plus Maze (Laberinto en Cruz elevada).             |
| IA   | Inteligencia Artificial.                                    |
| LSTM | Long Short-Term Memory (Red de memoria a corto-largo plazo) |
| PDI  | Procesamiento digital de imágenes                           |
| RNN  | Red Neuronal Recurrente.                                    |
| ROI  | Region of Interest (Área de interés).                       |
| SVM  | Support Vector Machine (máquina de vectores de soporte).    |
| UI   | User Interface (Interfaz de usuario).                       |
| YOLO | You Only Look Once. (Solo miras una vez).                   |

# Capítulo 1. Introducción

## 1.1 Antecedentes

El análisis del comportamiento animal utilizando inteligencia artificial (IA) ha cobrado gran relevancia en la última década debido a su potencial para aumentar la precisión, eficiencia y reproducibilidad en los estudios biomédicos. La integración de técnicas de visión por computadora y aprendizaje automático ha permitido automatizar tareas tradicionalmente realizadas de manera manual, como la observación de posturas, trayectorias y tiempos de permanencia, lo que reduce la subjetividad y el margen de error humano en los experimentos de comportamiento [1], [9].

En el ámbito de la farmacología experimental, los roedores —especialmente las ratas y los ratones— constituyen los modelos biológicos más utilizados para el estudio de los trastornos de ansiedad y el desarrollo de nuevos fármacos ansiolíticos. Esto se debe a que presentan una fisiología, genética y neuroanatomía altamente comparables con las del ser humano, particularmente en la organización del sistema nervioso central y las respuestas neuroendocrinas al estrés [2], [10]. Además, su tamaño, bajo costo, facilidad de manejo y rápida reproducción los hacen ideales para la experimentación controlada en laboratorio.

De acuerdo con el posgrado de la **Escuela Nacional de Medicina y Homeopatía (ENMyH)** del **Instituto Politécnico Nacional**, los ensayos con roedores permiten evaluar el efecto de nuevas moléculas con potencial ansiolítico. Los experimentos se estructuran generalmente en tres grupos: un grupo control que recibe placebo, un grupo tratado con **diazepam** (fármaco ansiolítico de referencia), y uno o más grupos experimentales que reciben las moléculas en evaluación. Esta comparación posibilita identificar tanto los efectos terapéuticos como los mecanismos de acción de las sustancias probadas [11]. La metodología incluye pruebas conductuales como el **Laberinto en Cruz Elevada (EPM)** o el **Laberinto en T Elevado**, ampliamente utilizadas para medir conductas asociadas a la ansiedad, como la evitación, exploración y tiempo de inmovilidad [3], [4].

El uso de animales de laboratorio está regulado en México por la **Norma Oficial Mexicana NOM-062-ZOO-1999**, que establece las especificaciones éticas, sanitarias y de bienestar animal aplicables a su cuidado y uso experimental. Esta norma asegura el bienestar de los especímenes y permite que los procedimientos se lleven a cabo bajo condiciones controladas, reduciendo al mínimo el sufrimiento de los especímenes.[5].

La inteligencia artificial ha potenciado el análisis conductual de estos modelos experimentales en años recientes, lo cual ha posibilitado la identificación automatizada de patrones de conducta a través de instrumentos como **YOLO** [13], **DeepLabCut** [12], o sistemas de seguimiento de código abierto (como **ezTrack** [5]). Estos últimos proporcionan precisión cuantitativa y reproductibilidad al evaluar las respuestas ansiolíticas. Esta sinergia entre la neurociencia conductual y la ingeniería computacional representa un avance significativo para acortar el tiempo necesario para validar nuevas sustancias y personalizar los tratamientos farmacológicos [14].

## 1.2 Planteamiento del problema

Para validar tratamientos experimentales en modelos de ansiedad, el análisis conductual en investigaciones farmacológicas constituye un paso crucial. Esta tarea, de manera tradicional, se lleva a cabo manualmente con la observación humana meticulosa de videos. En estos, los asistentes del laboratorio documentan visualmente cada movimiento, postura y desplazamiento del espécimen. No obstante, este método, a pesar de ser riguroso, es poco eficaz: el análisis de un único video puede demandar entre una y dos semanas de trabajo repartido entre tres asistentes. Estos tienen la tarea de determinar minuciosamente los eventos relevantes y luego procesar manualmente los datos con el fin de producir gráficas que puedan interpretarse. Este procedimiento, además de ser exigente en términos de tiempo, introduce una alta cantidad de subjetividad y variabilidad entre los evaluadores, lo cual pone en riesgo la capacidad para reproducir y la consistencia de los hallazgos experimentales.

## 1.3 Propuesta de solución

En vista de esta circunstancia, se hace necesario crear una herramienta tecnológica que estandarice y automatice la evaluación del comportamiento de nuestro espécimen, eliminando los sesgos humanos y acortando de manera significativa el tiempo de análisis. Este prototipo pretende combinar diferentes métodos de inteligencia artificial, visión por computadora y minería de datos a partir de videos grabados con anterioridad durante ensayos farmacológicos para convertir el proceso convencional de observación manual en un flujo automatizado, reproducible y de alta precisión.

La solución se centrará en un prototipo de inteligencia artificial y visión por computadora, con la capacidad de identificar, rastrear y describir el movimiento de roedores en contextos controlados.

Este prototipo integrará tres componentes principales:

1. **Detección de objetos mediante redes neuronales convolucionales (CNN) tipo YOLOv11**, entrenadas específicamente para identificar y localizar con alta precisión a los roedores dentro del entorno experimental.
2. **Análisis de secuencias temporales con redes LSTM (Long Short-Term Memory)**, que procesarán las trayectorias obtenidas para reconocer patrones conductuales asociados con diferentes respuestas de ansiedad.
3. **Estimación de postura mediante técnicas de pose estimation** (MediaPipe o DeepLabCut), para extraer coordenadas clave del cuerpo y mejorar la caracterización del comportamiento (posición, orientación, movimientos finos).

Una vez procesada la información, los datos vectorizados serán sometidos a **minería de datos mediante algoritmos como K-Means**, con el fin de agrupar patrones de actividad y detectar conductas recurrentes o anómalas.

Los resultados se visualizarán a través de **mapas de calor (heatmaps)**, **trayectorias dinámicas**, **gráficas comparativas** y **tablas de métricas conductuales**, que permitirán evaluar de forma clara cómo los tratamientos farmacológicos influyen en la conducta de los especímenes.

Finalmente, el prototipo contará con una **interfaz interactiva tipo dashboard**, que mostrará métricas de precisión, coeficientes de concordancia ( $\kappa$  de Cohen) y visualizaciones gráficas en tiempo real, facilitando la interpretación por parte de los investigadores biomédicos.

## 1.4 Objetivo general

Desarrollar un prototipo de análisis automatizado para analizar y representar patrones conductuales de especímenes en modelos experimentales de ansiedad a partir de vídeos, utilizando técnicas de minería de datos (clustering, clasificación y reducción de dimensionalidad), aprendizaje automático (redes neuronales CNN-LSTM, detección visual YOLO y estimación de postura), e inteligencia artificial (reconocimiento automático y validación estadística), generando visualizaciones gráficas e informes comparativos que permitan evaluar tratamientos farmacológicos.

### 1.4.1 Objetivos específicos

1. **Recolectar y estructurar datos conductuales de especímenes**, tales como la **movilidad entre brazos abiertos y cerrados, tiempo de permanencia en cada zona del laberinto, frecuencia de acicalamiento, tiempo de inmovilidad y contacto con las paredes**, a fin de generar una base de datos estructurada para el análisis automatizado posterior. Utilizados en modelos experimentales de ansiedad, mediante grabaciones individuales en video. En cada sesión se observará un espécimen único sometido a distintos tratamientos farmacológicos, incluyendo **un grupo control con placebo, un grupo tratado con diazepam** (fármaco ansiolítico de referencia) y **uno o más grupos experimentales con nuevas moléculas en evaluación**.
2. **Identificar técnicas de visión por computadora** aplicables al análisis conductual de especímenes en el modelo del **laberinto en cruz elevada (EPM)**, considerando algoritmos como **CNN-LSTM, YOLO y estimación de postura**, con el propósito de determinar cuáles permiten una extracción automatizada y vectorización precisa de los movimientos, trayectorias y posturas relevantes para la detección de conductas asociadas a la ansiedad.
3. **Desarrollar el módulo de clasificación y minería de datos**, que agrupe patrones de comportamiento según los tratamientos aplicados (placebo, diazepam o fármaco experimental), utilizando algoritmos como K-Means, Random Forest y SVM.
4. **Desarrollar el módulo de visualización interactiva**, encargado de generar dashboards con trayectorias, mapas de calor, tiempos de permanencia y gráficos comparativos de conducta en función de los tratamientos ansiolíticos.
5. **Desarrollar el módulo de validación experimental**, que evalúe la precisión de los resultados mediante validación cruzada ( $k$ -fold) y el coeficiente Kappa de Cohen ( $\kappa \geq 0.8$ ), contrastando las detecciones del prototipo con las anotaciones de expertos.
6. **Desarrollar el módulo de almacenamiento y gestión de resultados**, que organice los datos procesados, informes y visualizaciones en una base estructurada para consulta y análisis posteriores.

## 1.5 Justificación

La necesidad que da origen a este proyecto es contar con una herramienta tecnológica que **automatice el análisis conductual de especímenes utilizados en modelos experimentales** de ansiedad, mediante la identificación precisa de actividades anómalas como la movilidad de brazos, tiempos de permanencia en distintas zonas del laberinto, conteo de eventos (transiciones entre brazos, acicalamiento, inmovilidad, contacto con paredes, entre otros).

El modelo del **laberinto en cruz elevada (EPM)** permite analizar comportamientos ansiosos mediante parámetros etológicos como el tiempo de permanencia y la frecuencia de acicalamiento (Carobrez & Bertoglio, 2005). La observación manual de estos comportamientos implica un proceso **lento, subjetivo y propenso a errores humanos**, lo cual dificulta la obtención de datos reproducibles y comparables entre tratamientos. En la investigación farmacológica, donde es crucial contar con una precisión tanto temporal como espacial del comportamiento de los animales para poder evaluar el efecto de compuestos ansiolíticos, esta circunstancia supone un obstáculo importante. Por esta razón, el posgrado de la Escuela Nacional de Medicina y Homeopatía (ENMyH) del Instituto Politécnico Nacional (IPN) ha expresado la necesidad de contar con una herramienta automatizada que posibilite identificar, documentar y examinar de manera objetiva las reacciones conductuales a partir de videos experimentales. Este prototipo, que utiliza inteligencia artificial, minería de datos y visión por computadora, posibilitará la producción de visualizaciones gráficas y mediciones cuantitativas confiables. De esta manera se mejorará el tiempo de análisis y se asegurarán resultados más exactos y reproducibles. Así, el proyecto satisface a una necesidad específica a nivel científico y operativo: optimizar la objetividad, eficacia y calidad del análisis conductual en investigaciones sobre ansiedad, para así robustecer la capacidad de investigación de la ENMyH y el IPN en el ámbito biomédico.

## 1.6 Alcance del proyecto

Es importante crear un prototipo automatizado para estudiar el comportamiento animal, ya que esto ayuda a establecer prácticas de experimentación más objetivas y cuantitativas, y que estén en línea con los estándares de la investigación biomédica. La incorporación de tecnologías fundamentadas en inteligencia artificial mejora la calidad científica y la consistencia metodológica de las investigaciones sobre conducta en lugares como la ENMyH donde el estudio preclínico en modelos de ansiedad es una línea importante de investigación. La automatización basada en visión por computadora ha mostrado, en varias investigaciones, que aumenta de manera notable la reproducibilidad y la precisión en ensayos etológicos, disminuyendo la variabilidad vinculada a la evaluación hecha por humanos [9], [12].

De igual manera, la implementación de estas tecnologías está en consonancia con las directrices normativas y éticas sobre el empleo de animales de laboratorio. La NOM-062-ZOO-1999 enfatiza la relevancia del bienestar de los animales y la exigencia de llevar a cabo procedimientos en condiciones controladas que maximicen cada prueba [2]. La implementación de sistemas automatizados posibilita el uso óptimo de los datos adquiridos de cada muestra y reduce la repetición de pruebas, lo que ayuda a cumplir con el principio de las 3R (Reducción, Refinamiento y Reemplazo). Esto no solo optimiza la eficacia científica, sino que también refuerza la responsabilidad ética en el manejo de animales, lo cual es consistente con las tendencias internacionales de investigación responsable [5].

Se eligen tecnologías como YOLO, DeepLabCut y métodos de estimación de postura debido a su exactitud comprobada en tareas de rastreo y detección en modelos de animales. Estas herramientas se han validado extensamente en entornos biomédicos y posibilitan la extracción de patrones complejos que sobrepasan las capacidades de observación manual, como trayectorias tridimensionales, micro conductas y alteraciones sutiles en la postura corporal [12], [13]. Su empleo asegura datos cuantitativos de alta resolución que tienen la posibilidad de ser estudiados a través de métodos de minería de datos y aprendizaje automático; esto mejora la capacidad analítica de los investigadores y hace más sencillo detectar efectos farmacológicos.

La puesta en marcha de una plataforma con paneles interactivos y visualizaciones dinámicas ofrece a los investigadores y a los usuarios un entendimiento más profundo y accesible del comportamiento animal. Los instrumentos de análisis visual, como trayectorias dinámicas, mapas de calor y gráficos comparativos, hacen posible la síntesis de grandes cantidades de datos y su conversión en información clara y útil para la toma de decisiones experimentales [14]. Esto beneficia también los procesos de formación académica pues tanto estudiantes como residentes tienen la posibilidad de comprender el comportamiento animal desde un punto de vista basado en evidencia y perspectiva cuantitativa.

Por último, el alcance del proyecto incluye la creación de un prototipo modular y flexible, diseñado para integrar nuevas metodologías o expandirse a otros paradigmas experimentales. Esta perspectiva flexible posibilita que la plataforma no solo satisfaga las demandas presentes, sino que también progrese con los desarrollos en neurociencia conductual, IA y farmacología. En esta línea, el proyecto actúa como una base tecnológica que permitirá llevar a cabo líneas de investigación en el futuro tanto dentro de la ENMyH y el IPN como en otras entidades enfocadas en el estudio del comportamiento animal.

## 1.7 Metodología

Para el desarrollo del proyecto se adopta la metodología espiral de Boehm, adaptada a las particularidades de los proyectos de ciencia de datos. Barry W. Boehm, quien lo propuso en 1986 y lo formalizó en 1988 en “A Spiral Model of Software Development and Enhancement”, es el autor de este modelo que se distingue por ser sistemático a la hora de gestionar riesgos desde etapas tempranas, por su carácter cíclico y por su avance progresivo [15].

El modelo en espiral, a diferencia de los modelos secuenciales tradicionales, concibe el desarrollo como una serie de ciclos donde el producto se transforma gradualmente mediante revisiones y prototipos. Cada iteración culmina con un entregable validado que se utiliza como fundamento para el ciclo siguiente, lo cual permite una retroalimentación constante y un control de calidad [16], [17].

En el campo de la ciencia de datos, donde los proyectos presentan incertidumbre en cuanto a los datos, un alto nivel de complejidad técnica y validación experimental, el modelo en espiral brinda un entorno perfecto para iterar a través de prototipos, monitorear riesgos de calidad y garantizar una progresión verificable del modelo analítico [16], [18].

La versión empleada en este proyecto contempla cinco actividades esenciales en cada iteración, que aseguran la integración gradual de resultados parciales hasta llegar a una solución madura:

**1. Definición de objetivos y planificación.** En esta fase se definen las metas de negocio y técnicas, el alcance del ciclo y las métricas para medir el éxito. Se establecen los recursos, las fuentes de datos y los entregables que se anticipan. En proyectos de ciencia de datos, esta etapa se refiere a comprender los datos iniciales y el problema en cuestión, siguiendo los procesos del ciclo de vida que la norma ISO/IEC/IEEE 12207:2017 [6] establece.

**2. Análisis de riesgos y viabilidad.** Los riesgos técnicos, de datos, éticos o de implementación son idénticos al evaluar la viabilidad operativa y técnica del proyecto. Esta actividad se basa en el principio fundamental del modelo de Boehm: prever los riesgos y reducirlos antes de involucrar más recursos [15], [7].

**3. Desarrollo de prototipo.** Se pone en práctica un prototipo funcional o exploratorio que posibilita la verificación de hipótesis, la evaluación de la calidad de los datos y la validación de enfoques analíticos iniciales. Este prototipo es el fundamento para la evaluación del rendimiento en cada iteración, fusionando prácticas de análisis de datos e Ingeniería de Software [16], [18].

**4. Evaluación y validación.** Los resultados del prototipo se comparan con los objetivos establecidos para confirmar si se cumplen los estándares de calidad y rendimiento definidos. En esta etapa se examina la fortaleza, la capacidad de interpretación y el potencial sesgo de los modelos, siguiendo las pautas de calidad que establece la norma ISO/IEC 25010:2023 [8].

**5. Retroalimentación y ajuste.** Con la base de la validación, se recoge el feedback, se modifican los objetivos y se organiza la iteración posterior. Esta etapa asegura que el proceso mejore de forma constante y se ajuste a cambios imprevistos en los datos o en las especificaciones del proyecto.

Cada ciclo de la espiral termina en un producto entregable concreto, lo que posibilita el progreso desde un prototipo elemental hasta una solución sólida, establecida y verificada.



*Ilustración 1: OpenAI (2025). Imagen generada por ChatGPT sobre el concepto de metodología de espiral de Boehm [Imagen generada por IA]. ChatGPT (versión 5.1). Archivo creado por el usuario, sin URL.*

En situaciones donde son fundamentales el descubrimiento iterativo, la evaluación empírica y la experimentación, el modelo en espiral es particularmente relevante. Posibilita incluir modificaciones durante el proceso, gracias a su sistema de retroalimentación, lo cual evita la inflexibilidad de los modelos lineales. Asimismo, su estructura enfocada en el riesgo favorece la detección anticipada de eventuales errores de diseño, calidad de datos o alineación con los objetivos comerciales, lo que incrementa las posibilidades de que el proyecto sea exitoso [16], [17].

## Capítulo 2. Estado del arte.

El análisis y la investigación de la conducta relacionada con la ansiedad en los animales ha progresado significativamente en las últimas décadas, gracias a que ha surgido la necesidad de entender los procesos neurobiológicos subyacentes y a que han mejorado los tratamientos farmacológicos. El EPM es uno de los modelos experimentales más comúnmente empleados en este ámbito, pues posibilita la evaluación de las reacciones conductuales que surgen del conflicto entre la tendencia innata de los roedores a explorar y su repulsión hacia lugares elevados y abiertos.

Dado que este mismo modelo constituye la base experimental de los videos proporcionados por la Escuela Nacional de Medicina y Homeopatía (ENMyH), que serán analizados en el presente proyecto, resulta fundamental revisar los antecedentes científicos que han consolidado su validez y las distintas metodologías asociadas a su aplicación. Por lo tanto, en este capítulo se exponen los estudios y progresos más importantes realizados recientemente en el empleo del EPM como instrumento de investigación sobre la ansiedad, destacando sus contribuciones, restricciones y el posible uso conjunto con tecnologías emergentes de visión por computadora e inteligencia artificial.

## 2.1 Análisis etológico y temporal del comportamiento similar a la ansiedad: el modelo de EPM elevado 20 años después

En este artículo se enfatiza que el uso del EPM constituye un recurso esencial para investigar conductas vinculadas con la ansiedad en roedores. Pese a que en un principio fue desarrollado como un procedimiento para analizar los efectos ansiolíticos de medicamentos, su practicidad se ha extendido a examinar elementos como la memoria, el aprendizaje, el dolor, las hormonas, la adicción y los subtipos de desórdenes de ansiedad, como la fobia, el trastorno de estrés postraumático (TEPT) y el trastorno de ansiedad generalizada.

Se hace mención de que el EPM es popular por su simplicidad, velocidad y coste bajo. También se destaca que no se requiere un largo entrenamiento ni la aplicación de estímulos aversivos como privar de comida o aplicar descargas eléctricas. Sin embargo, su uso varía significativamente entre laboratorios, lo que ha llevado a una falta de estandarización en los protocolos. Esta revisión se centra en cómo mejorar la validez del EPM mediante la consideración de factores como la medición de patrones defensivos, el análisis minuto a minuto del comportamiento y el uso de protocolos de prueba/reprueba.

## 2.2 El laberinto en T elevado como modelo experimental de ansiedad

El artículo presenta el laberinto elevado en T como un modelo animal diseñado para diferenciar entre dos tipos de ansiedad: el miedo condicionado, asociado al trastorno de ansiedad generalizada (TAG), y el miedo no condicionado, relacionado con el trastorno de pánico (TP). Este modelo es una variante del laberinto elevado en cruz, pero con una modificación clave: uno de los brazos cerrados se sella, dejando tres brazos quedando de tal forma, uno cerrado y dos abiertos. En este laberinto, se miden dos comportamientos principales: la evitación inhibitoria, que representa el miedo condicionado, y el escape unidireccional, que refleja el miedo no condicionado.

En la validación conductual, se demostró que la experiencia en los brazos abiertos es el factor crítico que motiva la evitación inhibitoria, no el manejo por parte del experimentador. Los roedores evitan los brazos abiertos debido a su aversión innata a las alturas y los espacios abiertos, y este miedo no disminuye con la habituación, lo que sugiere que es un comportamiento persistente con un alto valor de supervivencia. Por otro lado, el escape unidireccional, que ocurre cuando el roedor escapa de un brazo abierto hacia el cerrado, refleja una respuesta innata de miedo.

## 2.3 El uso del EPM como un ensayo del comportamiento relacionado con la ansiedad en roedores

En este artículo se enfatiza que el EPM no solamente es un instrumento para evaluar la ansiedad, sino que brinda además una ventana muy interesante a la biología del comportamiento. Esta prueba no solo evalúa la ansiedad, sino que además puede proporcionar datos acerca de la memoria y el aprendizaje, esto es porque se ha comprobado que los roedores son capaces de retener recuerdos de experiencias pasadas en el laberinto, lo cual tiene un impacto en su conducta durante pruebas posteriores.

Una faceta poco conocida del EPM es que se utiliza en investigaciones de neurobiología, al ser empleada por los investigadores con el fin de descubrir las áreas cerebrales que están implicadas en la

ansiedad. Se ha comprobado, por ejemplo, que la amígdala, una zona crucial para procesar el miedo, se encuentra muy activa cuando los roedores evitan los brazos abiertos. Asimismo, el hipocampo, vinculado a la memoria espacial, tiene un rol relevante en el modo en que los animales se orientan y rememoran el laberinto. Estos descubrimientos han contribuido a que los investigadores comprendan de manera más eficaz cómo el cerebro controla la ansiedad y el miedo.

Además, el EPM se ha ajustado para analizar otros elementos del comportamiento, tal como la sociabilidad y la reacción ante el estrés social. En ciertos experimentos, los roedores son sometidos a situaciones sociales que les causan estrés antes de ser introducidos en el laberinto, estos animales tienden a mostrar más comportamientos de inmovilidad y a evitar los brazos abiertos cuando la ansiedad aumenta. Esto indica que la ansiedad puede ser fuertemente influenciada por el estrés social, lo cual es importante para comprender trastornos también en seres humanos como el de estrés postraumático o la depresión.

Un dato interesante es que el EPM se ha empleado además para investigar como los sonidos y la música afectan la ansiedad. La música relajante, según se menciona en el artículo, tiene la capacidad de disminuir la ansiedad en roedores al incrementar el tiempo que permanecen en los brazos abiertos. En contraste, los ruidos fuertes o los sonidos estridentes producen el efecto inverso, intensificando la evitación de los brazos abiertos. No solo desde la perspectiva científica estos hallazgos son interesantes, sino que además poseen implicaciones prácticas, como el empleo de música para disminuir el estrés en animales de laboratorio.

## 2.4 Prueba del EPM Combinado con Software de Seguimiento por Video para Investigar el Efecto Ansiolítico de Suplementos Cetogénicos Exógenos

El artículo describe la metodología del laberinto elevado en cruz (EPM) combinado con un software de seguimiento por video para evaluar el efecto de tratamientos potencialmente ansiolíticos en modelos de roedores de laboratorio.

El estudio se centra en evaluar el efecto de suplementos exógenos de cetonas en ratas Sprague Dawley (SPD). Los suplementos de cetonas se administraron de forma crónica durante 7 días antes de realizar la prueba del EPM. Los datos de comportamiento se recopilaron utilizando un sistema de seguimiento por video, y los resultados mostraron que el EPM es un método efectivo para detectar el efecto ansiolítico inducido por los suplementos de cetonas. Esto sugiere que el EPM es una herramienta sensible para evaluar cambios en el comportamiento relacionado con la ansiedad asociados con terapias basadas en fármacos o modificaciones metabólicas.

La relevancia de estandarizar las condiciones experimentales para asegurar la validez de los resultados también es enfatizada en este artículo. Esto abarca la adaptación de los animales al ambiente experimental, el manejo constante de roedores y la realización de pruebas bajo condiciones controladas de ruido e iluminación. Además, se sugiere limpiar el laberinto tras cada ensayo para quitar cualquier indicio de olor que pudiera alterar la conducta de los animales que sigan.

## 2.5 Prueba del EPM para Evaluar el Comportamiento Similar a la Ansiedad en el Ratón

Los datos representativos muestran que los efectos de los fármacos ansiolíticos y ansiogénicos pueden detectarse claramente en este modelo, aunque es importante ajustar las dosis para distinguir entre efectos emocionales y locomotores. Finalmente, se ofrecen notas complementarias acerca de aspectos relevantes, como la utilización de ratones macho para prevenir alteraciones vinculadas con el ciclo estral, lo necesario que es acostumbrar a los animales al entorno experimental y la relevancia de conservar una iluminación constante para no generar sesgos de conducta.

Este protocolo ha sido adaptado de estudios previos y ha demostrado ser efectivo para detectar tanto efectos ansiogénicos como ansiolíticos en ratones.

## 2.6 El diazepam provoca efectos sedantes más que ansiolíticos en ratones C57BL/6J

El estudio investigó los efectos del diazepam y la paroxetina en ratones C57BL/6J, tanto hembras como machos, utilizando pruebas de comportamiento como el EPM y el campo abierto. Los resultados mostraron que el diazepam no aumentó el número de entradas ni el tiempo pasado en los brazos abiertos, lo que sugiere que no tuvo un efecto ansiolítico en los ratones, sino que más bien causó efectos sedantes, evidenciados por una disminución en la actividad locomotora y en el comportamiento de evaluación de riesgo, medido como una reducción en el tiempo pasado en posturas de estiramiento y exploración. Estos efectos se observaron tanto en ratones no sometidos a estrés como en aquellos que fueron sometidos a una hora de restricción antes de la prueba. En contraste, la paroxetina, un antidepresivo inhibidor selectivo de la recaptación de serotonina, mostró efectos ansiolíticos claros en ambos sexos, aumentando el tiempo pasado en los brazos abiertos del EPM y el comportamiento de evaluación de riesgo.

Además, el estudio subrayó que el diazepam no solamente redujo la actividad locomotora, sino que también acortó el tiempo en que los ratones permanecieron en la parte central del campo abierto; este comportamiento suele estar relacionado con la ansiedad. Esto apoya el concepto de que, en este modelo de ratón, el diazepam funciona fundamentalmente como sedante y no como ansiolítico. Por otra parte, la paroxetina no solo prolongó el tiempo que pasó en los brazos abiertos del EPM, sino que además aumentó la conducta de evaluación de riesgo. Esto indica que este medicamento podría ser más eficaz para disminuir la ansiedad en ratones C57BL/6J.

Los hallazgos también indicaron que el estrés previo no modificó de manera significativa los efectos del diazepam, porque los ratones que fueron sometidos a una hora de limitación antes del ensayo presentaron comportamientos parecidos a los que no tuvieron estrés. Esto sugiere que el efecto sedante del diazepam es consistente independientemente del estado de estrés del animal. Sin embargo, la paroxetina mostró un efecto ansiolítico más pronunciado en los ratones no sometidos a estrés, lo que podría indicar que el estrés previo podría modular la eficacia de este fármaco en ciertos contextos.

## 2.7 ezTrack: Un flujo de análisis de video de código abierto para la investigación del comportamiento animal

ezTrack es una herramienta de análisis de comportamiento de código abierto y multiplataforma que permite a investigadores sin experiencia en programación realizar análisis de video de manera sencilla. EzTrack se compone de dos módulos fundamentales: uno para examinar la posición y el movimiento de un animal específico, y otro para medir la conducta de congelación, que se usa frecuentemente en investigaciones sobre miedo y ansiedad. En conjunto los dos módulos presentan visualizaciones interactivas, procesamiento por lotes y la posibilidad de modificar parámetros para asegurar resultados más exactos.

El módulo de seguimiento de ubicación de ezTrack monitorea el centro de masa de un animal en cada cuadro del video, lo que posibilita calcular el tiempo y la distancia recorrida en las áreas de interés (ROI) establecidas por el usuario. Se dice que este módulo ha sido validado en diversas pruebas conductuales, incluyendo la prueba de oscuridad-luz, el laberinto de agua de Morris, la preferencia por un lugar condicionado, y finalmente el EPM. Los resultados logrados evidenciaron una fuerte correlación con los análisis manuales, lo que demostró su exactitud. Además, ezTrack es resistente a las variaciones de luz y a la presencia de objetos en el campo visual, lo que lo vuelve apto para una extensa variedad pruebas.

El módulo de análisis de congelación de ezTrack determina el desplazamiento del animal al calcular la cantidad de pixeles que varían entre fotogramas sucesivos. Se considera que un animal está en estado de congelación cuando su movimiento desciende por debajo de un umbral establecido por el usuario durante un periodo de tiempo determinado. Este módulo también ofrece instrumentos de calibración para modificar los límites de movimiento y congelación, además de posibilitar el recorte de los fotogramas con el fin de suprimir la intervención de cables conectados al animal. Los resultados de ezTrack mostraron una fuerte correlación con los análisis manuales en ensayos de condicionamiento del miedo, lo que confirma su precisión a la hora de detectar este tipo de comportamiento.

La sencillez para utilizar ezTrack es una de sus principales ventajas, pues está concebido para ser accesible incluso para quienes no tienen experiencia en programación. Además, ezTrack tiene la capacidad de adaptarse a diversas configuraciones experimentales, ya que es compatible con una variedad extensa de formatos de video y múltiples sistemas operativos (Windows, macOS y Linux). Es relevante también subrayar la transparencia y la reproducibilidad de ezTrack. Ya que se hace uso de Jupyter Notebook, se almacenan en un archivo HTML o PDF todos los pasos y parámetros que se emplearon para procesar la información, lo que simplifica la revisión y reproducción de los análisis. Esto se opone al software comercial, donde los parámetros elegidos no siempre son registrados de forma accesible.

A pesar de que ezTrack presenta ciertas limitaciones, entre ellas su dependencia del centro de masa para establecer la posición y su enfoque en el seguimiento de un solo animal, su simplicidad y versatilidad lo hacen una herramienta útil para un extenso espectro de aplicaciones en neurociencias y análisis conductuales. Además, por ser de código abierto, ezTrack tiene la posibilidad de ser mejorado y cambiado por la comunidad científica, lo que posibilita incluir nuevas funciones más adelante.

## 2.8 Analixity: Un sistema de análisis de código abierto y bajo costo para la prueba de EPM, basado en técnicas de visión por computadora

Analixity es un software en un sistema multiplataforma de código abierto para procesamiento de video, diseñado específicamente para realizar pruebas de EPM.

Este software produce un archivo de Excel con los parámetros de comportamiento cuantificados, incluyendo el tiempo transcurrido en los brazos abiertos y cerrados, el tiempo de la zona central, la cantidad de veces que se ingresó a cada área y la distancia total recorrida durante el examen. Con el fin de validar su efectividad, los resultados logrados con Analixity se contrastaron con los que se lograron por medio del software comercial ANY-maze y mediante análisis manual. No hubo discrepancias estadísticamente relevantes entre las metodologías, lo que avala que Analixity es igual de efectivo y fiable que un software comercial, pero con el beneficio de ser adaptable a distintas condiciones de laboratorio y ser de código abierto.

En la actualidad, hay diferentes programas comerciales para analizar el comportamiento animal, incluyendo LABORAS, Ethovision y ANY-maze. Además, muchos de estos programas funcionan como "cajas negras", donde los investigadores no tienen acceso a los procedimientos internos utilizados para la cuantificación de parámetros. En contraste, Analixity es un software de código abierto desarrollado en Python con bibliotecas OpenCV, lo que permite a los investigadores conocer y modificar los procesos internos según sus necesidades. Además, es compatible con Windows, MacOS y Linux, lo que lo hace accesible para una amplia gama de usuarios.

En el estudio de validación, se compararon los resultados obtenidos con Analixity con los obtenidos mediante análisis manual y con ANY-maze. Se analizaron videos de ratas Wistar y ratones C57BL/6 J en diferentes condiciones de iluminación, y se cuantificaron parámetros como el tiempo pasado en los brazos abiertos y cerrados, el tiempo en la zona central y el número de entradas a cada zona. Los resultados mostraron que Analixity redujo significativamente el tiempo de análisis, de 30 minutos a solo 2.5 minutos por video, sin comprometer la precisión.

Aunque el software se menciona en diversos artículos y se indica que es de código abierto, no se encontró un medio disponible para su descarga. Por ello, no fue posible incluirlo en las pruebas de comparación con el sistema desarrollado por el equipo.

## 2.9 EthoVision

Iniciado como un sistema de rastreo de comportamiento animal cuyo funcionamiento parte de la identificación cuadro por cuadro de los objetos que aparecen en la escena separando siempre el cuerpo del animal del fondo mediante variaciones en brillo, matices de gris y combinaciones de tono y saturación lo que permite que el algoritmo distinga entre animales y el fondo del frame.

A partir de esta detección obtiene coordenadas área superficial para cada instante del experimento siguiendo de manera constante el movimiento en cualquier tipo de arena definida por el usuario.

El investigador puede organizar espacios de trabajo experimentos perfiles de adquisición y un conjunto amplio de variables independientes como tratamiento fecha configuración genética o temperatura junto

con variables dependientes como coordenadas x, coordenadas y, superficie, distancia recorrida, velocidad y tiempo en zonas que se almacenan en pistas.

El módulo de diseño experimental permite programar series completas de pruebas incluyendo qué animal se evalúa, en qué orden y con qué ajustes el módulo de adquisición procesa la imagen con tres métodos distintos de detección por umbrales de gris por sustracción del fondo o por color usando el modelo HSI. También puede rastrear hasta dos animales en paralelo cada uno con su color o tamaño particular y aplicar filtros para eliminar colas, sombras, ruido o barras de jaulas

El módulo de visualización permite reproducir los recorridos superpuestos al video o sobre la arena esquemática para analizar la exploración patrones de búsqueda o comportamiento. Finalmente, el módulo analítico transforma todas las coordenadas en datos cuantitativos como distancias, velocidades, cambios de dirección, permanencia en regiones o estados como movimiento e inmovilidad proporcionando estadísticas exportables a otros programas.

## 2.10 ANY-maze

ANY-Maze es un sistema de análisis automatizado de detección de conducta que funciona tomando un vídeo del experimento y procesándolo frame por frame para identificar al animal dentro del entorno por medio de un análisis de imagen por imagen con cada píxel siendo comparado para detectar diferencias con otras imágenes.

Para lograr la detección de movimiento, también utiliza métricas como la distancia recorrida, los patrones de movimiento y la permanencia en zonas, que se definen antes de iniciar la prueba y, que sirven para evaluar conductas como exploración o ansiedad. También cuenta con herramientas para configurar el experimento de manera flexible permitiendo delimitar áreas de interés para registrar eventos específicos ofreciendo un sistema que integra el seguimiento automático y la recolección de datos en una sola interfaz.

Una vez que el rastreo está en marcha, el programa genera estadísticas y gráficos que resumen variables como velocidad, entradas a zonas, tiempo de inmovilidad o patrones de exploración. Estas mediciones pueden exportarse para análisis posteriores; también incluye mecanismos para reducir la variabilidad del análisis como filtros de ruido, ajustes de sensibilidad y parámetros que permiten corregir trayectorias perdidas asegurando que el seguimiento se mantenga incluso en condiciones de baja iluminación o cuando el animal se superpone con elementos del entorno

El propósito del sistema es ofrecer una plataforma fácil de usar que automatice tareas que normalmente se harían manualmente lo que disminuye errores humanos y aumenta la reproducibilidad del experimento siendo una herramienta utilizada ampliamente en pruebas como laberintos elevados, laberintos en cruz, campo abierto o tareas de preferencia de lugar donde la posición y el movimiento del animal son indicadores centrales de la conducta evaluada.

## 2.11 Tabla Comparativa

Se presenta una tabla comparativa de trabajos similares que han abordado el análisis del comportamiento de especímenes en modelos de ansiedad, incluyendo metodologías tradicionales y herramientas automatizadas.

"Ethological and Temporal Analyses of Anxiety-like Behavior: The Elevated Plus-Maze Model 20 Years On" este artículo es una revisión que resalta la evolución del laberinto en cruz elevada como modelo de evaluación etológica de la ansiedad en roedores, destacando la necesidad de un análisis más profundo del comportamiento más allá de métricas tradicionales.[3]

"The Elevated T-Maze as an Experimental Model of Anxiety" propone un modelo alternativo que permite discriminar entre diferentes tipos de ansiedad a través del estudio de evitación y escape en un laberinto en T elevado.[4]

"ezTrack" es un software de código abierto que permite el seguimiento automatizado del comportamiento animal mediante análisis de video, sin necesidad de experiencia en programación, siendo una herramienta accesible y reproducible.[5]

Estos proyectos permiten contextualizar el desarrollo de nuestra propuesta.

| Característica   | DeepLabCut                       | ANY-maze                               | Ethovision   | ezTrack [5]                       | Nuestro Prototipo (TT-2026-A155)                         |
|--|----------------------------------|--|--|-----------------------------------|--|
| <b>Costo</b>   | Gratis<br>(requiere GPU potente) | Muy costoso                            | Muy costoso  | Gratis                            | Gratis / costo muy bajo                                  |
| <b>Facilidad de uso</b>  | Difícil, requiere programación   | Muy intuitivo                          | Intermedio   | Intermedio                        | Muy intuitivo  |
| <b>Estimación de postura</b>   | ✓ Postura avanzada               | ✗ No especializado                     | ✓ Postura avanzada   | ✗ No incluye postura real         | ✓ Postura completa (MediaPipe / DeepPose)                |
| <b>Clasificación de conductas</b>  | ✗ Requiere código adicional      | ✗ Limitado a trayectorias              | ✓ Reconocimiento automático de comportamiento  | ✗ No clasifica                    | ✓ CNN-LSTM con clasificación automática                  |
| <b>Detección de micro-conductas (acicalamiento, inmovilidad, contacto)</b> | ✓ Si se programa, no por defecto | ✗ No detecta acicalamiento             | ✓ Si detecta microconductas  | ✗ No detecta microconductas       | ✓ Sí detecta microconductas                              |
| <b>Seguimiento del animal</b>  | Muy preciso, basado en keypoints | Bueno, basado en tracking clásico      | Bueno: tracking robusto, incluso en video de baja resolución                                       | Básico (centro de masa)           | Preciso: YOLO + postura                                  |
| <b>Instalación</b>   | Compleja, setups largos          | Fácil, instalación guiada              | Fácil, instalación guiada  | Fácil-intermedia                  | Fácil, interfaz web local directa                        |
| <b>Reproducibilidad científica</b>   | Alta, depende del usuario        | Media                                  | Alta   | Media-alta                        | Alta con k-fold + $\kappa \geq 0.8$                      |
| <b>Dashboards y visualizaciones</b>  | ✗ No incluidos                   | Básicos                                | ✓ Incluye visualización de trayectorias y gráficos de actividad/movimiento                         | Básicos                           | ✓ Dashboards interactivos y comparativos                 |
| <b>Flexibilidad / modificación</b>   | Muy alta (open source)           | Muy baja (cerrado)                     | Muy baja (cerrado, software comercial)   | Alta (open source)                | Alta (modular y expandible)                              |
| <b>Usuarios objetivo</b>   | Programadores / expertos en IA   | Investigadores sin experiencia técnica | Investigadores de comportamiento / neurociencias / farmacología que necesitan una solución robusta | Laboratorios con recursos básicos | Investigadores biomédicos, estudiantes y desarrolladores |

Tabla 1: Comparación de trabajos similares [autoría propia]

## Capítulo 3. Marco Teórico

### 3.1 Visión por computadora para seguimiento de objetos

La visión por computadora es una rama que permite a las máquinas para interpretar y entender el mundo visual. Para detectar y seguir el movimiento de los animales en videos, se emplean algoritmos sofisticados en el marco del seguimiento de objetos. Entre los algoritmos que más se usan se encuentran los siguientes:

#### 3.1.1 YOLO (You Only Look Once)

Un algoritmo de detección de objetos en tiempo real. A diferencia de los métodos tradicionales que procesan la imagen por etapas separadas como extracción de características, generación de propuestas o clasificación independiente, YOLO realiza todo el proceso de detección en un solo paso, aplicando una sola red neuronal convolucional directamente sobre la imagen completa. Esta idea rompe con la lógica secuencial clásica mostrada en sistemas de visión artificial (descritos en las Ilustraciones 2 y 3), al tratar el reconocimiento y localización como un problema único y unificado[3].

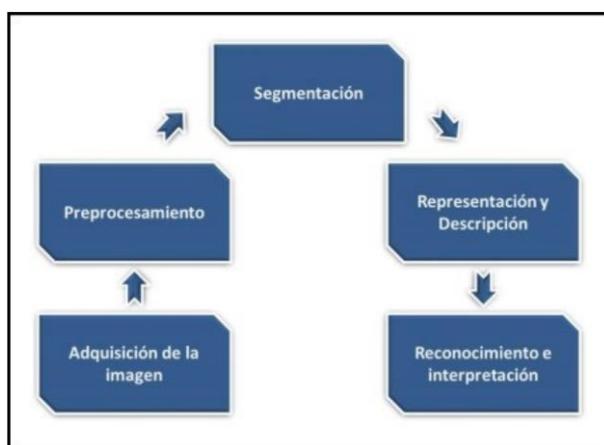


Ilustración 2: Fases de un sistema de Visión Artificial

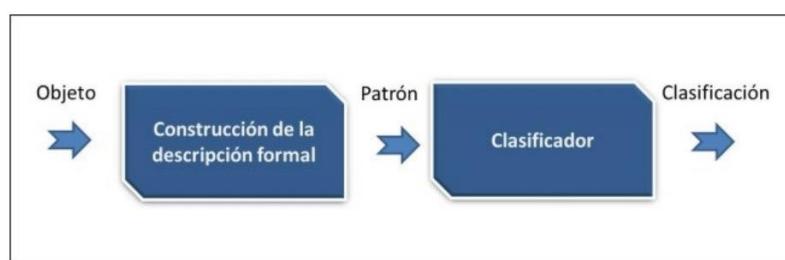
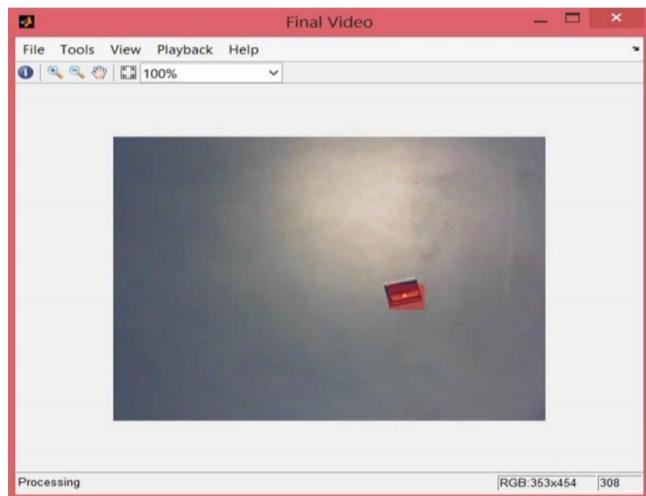


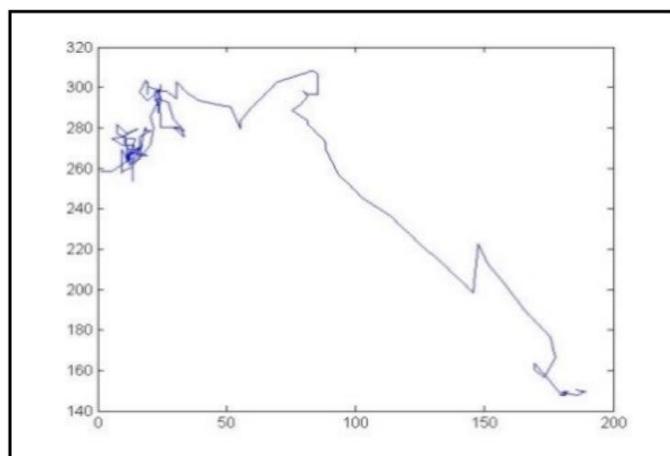
Ilustración 3: Pasos para el reconocimiento de patrones

La clave de YOLO radica en dividir la imagen en una cuadrícula: cada celda tiene la tarea de pronosticar si existe un objeto dentro de su área, produciendo coordenadas de un bounding box, así como una probabilidad de que esté presente y otra posibilidad para cada clase. Esta predicción directa convierte al algoritmo en uno de los más rápidos en visión por computador, ideal para aplicaciones donde la detección debe ocurrir en tiempo real, como aquellas que requieren seguimiento continuo del objeto, similar a la siguiente figura.



*Ilustración 4: Ventana de seguimiento de un objeto en tiempo real*

Al procesar toda la imagen de una sola vez, YOLO adquiere una comprensión global del contexto visual, así reduciendo los errores por confusión entre objetos y mejora la coherencia espacial de sus decisiones, lo que es especialmente valioso en escenas complejas o con múltiples instancias. No obstante, aunque YOLO es altamente eficiente, puede enfrentar dificultades en escenas donde hay occlusiones, pérdida temporal del objeto dentro del cuadro o variaciones bruscas de iluminación, condiciones que complican la detección continua y precisa, con una pérdida progresiva del objeto real, como se ejemplifica en la Ilustración 5



*Ilustración 5: Trayectoria de un objeto seguido*

### 3.1.2 DeepLabCut

Una herramienta de análisis de comportamiento desarrollada para realizar seguimiento basado en aprendizaje profundo sin necesidad de marcadores físicos. A diferencia de métodos clásicos como CAMShift o enfoques basados en histogramas de color, DeepLabCut utiliza arquitecturas de redes neuronales convolucionales (CNN) para identificar con alta precisión puntos anatómicos previamente definidos sobre animales u otros sujetos en movimiento. Esta metodología permite automatizar el análisis del comportamiento aun cuando existen variaciones en iluminación, perspectiva o apariencia del objeto, las cuales suelen afectar de forma significativa a los enfoques tradicionales de seguimiento.

Generalmente, su flujo de trabajo inicia con la selección de fotogramas representativos del video, los cuales posteriormente se etiquetan manualmente marcando las posiciones corporales relevantes para el estudio. Estos datos anotados alimentan el proceso de entrenamiento, durante el cual el modelo ajusta sus pesos para aprender la posición de los puntos clave. Una vez entrenado, el sistema puede predecir automáticamente la ubicación de dichos puntos en cada fotograma del video original o de nuevos videos, generando trayectorias temporales precisas que pueden utilizarse para análisis conductuales, cinemáticos o espaciales, tal como se ejemplifica en la Ilustración 6.

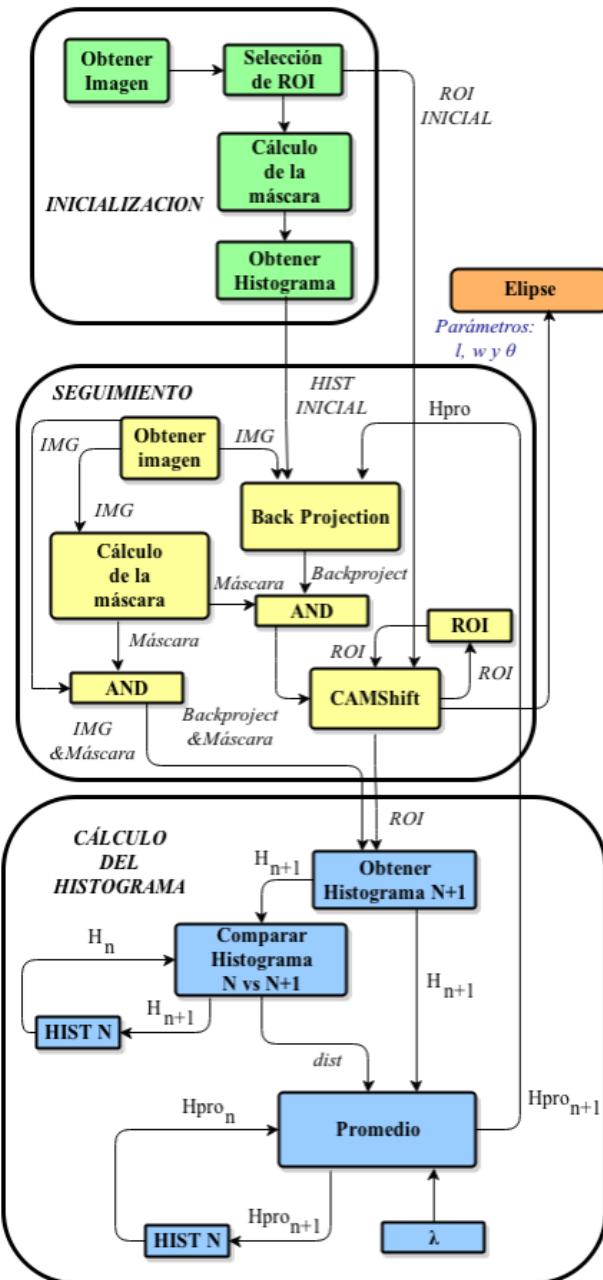


Ilustración 6: Esquema del algoritmo de seguimiento de CAMshift

La salida final de DeepLabCut no es una ventana adaptativa como en CAMShift, mostrada usualmente como una elipse de seguimiento (como en la Ilustración 7), sino un conjunto de coordenadas precisas para cada punto corporal entrenado. Esto permite análisis biomecánicos avanzados, cálculo de ángulos, trayectorias y patrones conductuales sin depender de contornos ni de la segmentación tradicional basada en color. Además, dado que cada frame se analiza independientemente mediante el modelo entrenado, no se acumula error histórico ni se generan divergencias de histograma como las que tu documento soluciona mediante promedio ponderado (ecuaciones 2–3).



Ilustración 7: Elipse sobre objeto en seguimiento

Cuando se observan resultados de un modelo entrenado para diferentes momentos del video, el comportamiento es comparable a las diferencias presentadas en la Ilustración 8, pero con la ventaja de que DeepLabCut mantiene precisión incluso si el animal cambia de forma, tamaño, pose o iluminación. Mientras CAMShift depende de mantener coherencia visual en color y dimensión para no perder el objeto, DeepLabCut aprende representaciones abstractas del cuerpo, lo que lo hace mucho más robusto, especialmente en ciencia del comportamiento, neurociencia y análisis de movimiento.

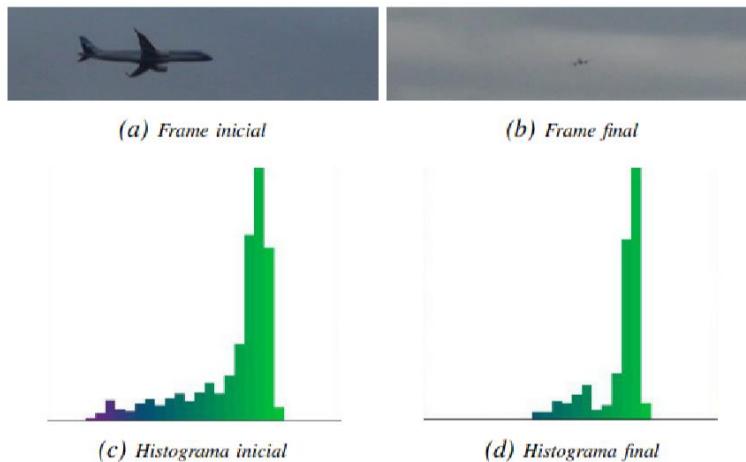


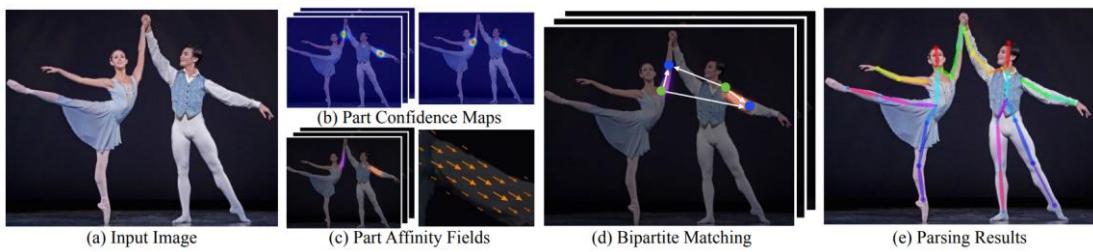
Ilustración 8: Cuadro inicial y final del video utilizado para el ensayo [4]

### 3.1.3 Estimación de postura (Pose Estimation)

Según Mathis et al. en su artículo "DeepLabCut: "Markerless Pose Estimation of User-Defined Body Parts with Deep Learning": el Pose Estimation es un método de visión por computadora que posibilita deducir la ubicación espacial de segmentos corporales, a menudo articulaciones o puntos clave, usando imágenes o videos [12]. Esta técnica es esencial para rastrear objetos, ya que no solo identifica la existencia de un organismo, sino que también proporciona una descripción de su forma corporal en tiempo real, lo cual permite realizar análisis detallados sobre movimiento y conducta. Los modelos de estimación de postura, a través de redes neuronales convolucionales u otras

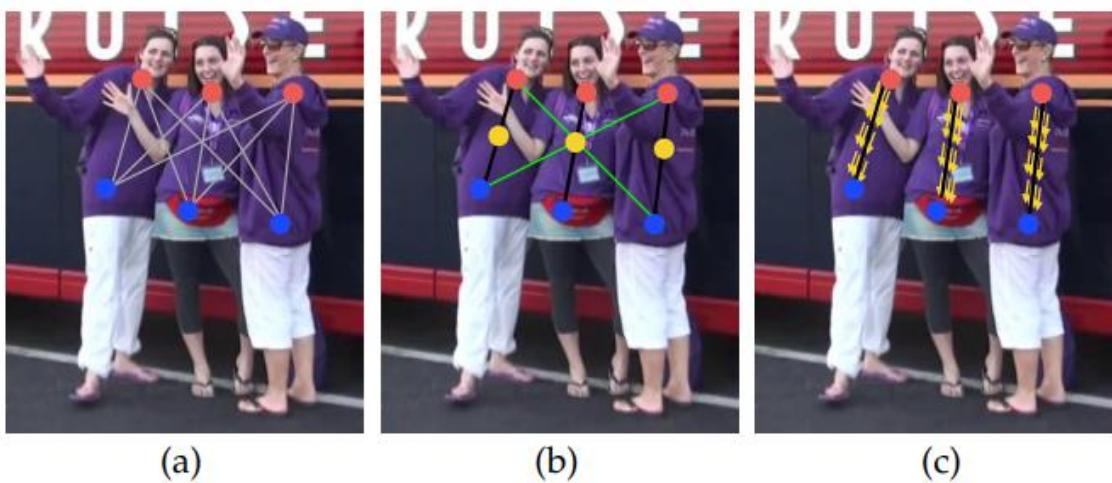
arquitecturas de aprendizaje profundo, desarrollan la habilidad para convertir píxeles en coordenadas anatómicas.

De acuerdo con Cao et al., los escritores de "OpenPose: Estimación de poses 2D en tiempo real para múltiples personas a través de campos de afinidad por partes", las estrategias contemporáneas se categorizan en procedimientos de una fase y procedimientos de dos fases. Los métodos de una etapa, que calculan directamente las articulaciones a partir de la imagen sin necesidad de detectar antes el cuerpo entero, son más veloces, pero algo menos exactos. Los métodos de dos etapas, en cambio, primero identifican al sujeto y después hacen inferencias sobre su postura dentro de esa área. Los Part Affinity Fields (PAF), que fueron introducidos por OpenPose, hacen posible la asociación de varias articulaciones en situaciones donde hay más de una persona, lo cual soluciona la ambigüedad del ensamblaje de las articulaciones cuando existen varios individuos en la escena [23].



*Ilustración 9: Representación de keypoints y campos de afinidad para múltiples personas (OpenPose) [23]*

Según el artículo de Mathis et al., la estimación de postura sin marcadores se ha convertido en algo fundamental en la investigación biomédica y del comportamiento animal, ya que se requieren sistemas no invasivos con una precisión alta [12]. DeepLabCut, por citar un caso, posibilita la definición de puntos anatómicos concretos y el entrenamiento de modelos a medida con una cantidad de datos relativamente reducida, empleando para ello aprendizaje profundo y transferencia del aprendizaje. Esta herramienta es especialmente beneficiosa en contextos con variación postural significativa, fondos intrincados y movimientos veloces, y se emplea mucho en el análisis del movimiento, la neurociencia y la etología.



*Ilustración 10: Estrategias de asociación de partes en DeepLabCut [12]*

Incorporar la estimación de postura a los sistemas de seguimiento de objetos brinda un beneficio importante en comparación con los procedimientos que se basan solamente en cajas delimitadoras. De acuerdo con Pereira y Moita en "El papel de la visión por computadora en la etología: Un análisis de postura", la Pose Estimation permite medir ángulos articulares, trayectorias de extremidades, patrones de locomoción y micro comportamientos [16]. Esto es esencial para el estudio del comportamiento espontáneo, de las tareas motoras, de la evaluación del dolor o de los trastornos neuromotores, e incluso para la interacción social en animales de laboratorio. Asimismo, los datos producidos, al ser series temporales multivariadas, tienen la posibilidad de combinarse con modelos de aprendizaje automático como LSTM o Transformers para clasificar comportamientos o anticipar patrones en el futuro.

### 3.1.4 CAMShift y métodos clásicos de seguimiento

CAMShift (Continuously Adaptive Mean Shift), de acuerdo con Bradski, es una ampliación del algoritmo Mean-Shift que posibilita el seguimiento de objetos en videos en tiempo real. Esta técnica hace posible la modificación dinámica del tamaño y la orientación de la ventana de búsqueda a medida que cambia el aspecto del objeto [24].



Ilustración 11: Secuencia de fútbol americano siguiendo al jugador 75 [25]

Comaniciu, Ramesh y Meer explican que los métodos en función del kernel modelan el objeto a través de histogramas que son ponderados de manera espacial, lo cual asegura solidez frente a ruidos y distorsiones. La actualización ininterrumpida del modelo disminuye la deriva del rastreador a medida que la apariencia del objeto cambia progresivamente, y el procedimiento iterativo del algoritmo Mean-Shift permite encontrar el modo de la distribución de probabilidad del objeto [25].



Ilustración 12: Una imagen de video y su probabilidad de piel en la imagen [24]

De acuerdo con el tutorial de OpenCV, CAMShift y Mean-Shift son considerados algoritmos de seguimiento por apariencia; estos son veloces y apropiados para aplicaciones en tiempo real, aunque su sensibilidad a los fondos con colores parecidos y a las occlusiones es una limitante. Otros métodos tradicionales son el seguimiento de puntos locales (Lucas-Kanade), los filtros de Kalman o los filtros de partículas (predicción frente a occlusiones) y el template matching (eficaz, aunque limitado en situaciones de rotación y escala cambiantes) [26].

CAMShift es más eficaz en situaciones donde la información de color tiene capacidad de discriminación y las dinámicas del objeto son, por lo general, predecibles, según señala Bradski. Por lo tanto, se sugiere que el rendimiento sea evaluado a través de métricas como la tasa de pérdida (failure rate), la precisión del bounding box (IoU) y la deriva acumulada, empleando secuencias que contengan occlusiones, rotación y cambios de escala [24][26].



Ilustración 13: Ilustración 13. Ejemplo de seguimiento de un objeto con cambio de escala [26]

### 3.1.5 Redes Neuronales Convolucionales (CNN) aplicadas a visión por computadora

Según Bengio, Courville y Goodfellow, las Redes Neuronales Convolucionales (CNN) son la arquitectura básica para el análisis de imágenes, porque pueden aprender jerarquías de propiedades a partir de patrones sencillos, como texturas o bordes, hasta alcanzar representaciones complejas de objetos enteros [21]. Esta característica hace que las CNN sean especialmente beneficiosas en visión por computadora, donde es necesario entender con precisión la escena para detectar y ubicar elementos dentro de cada cuadro.

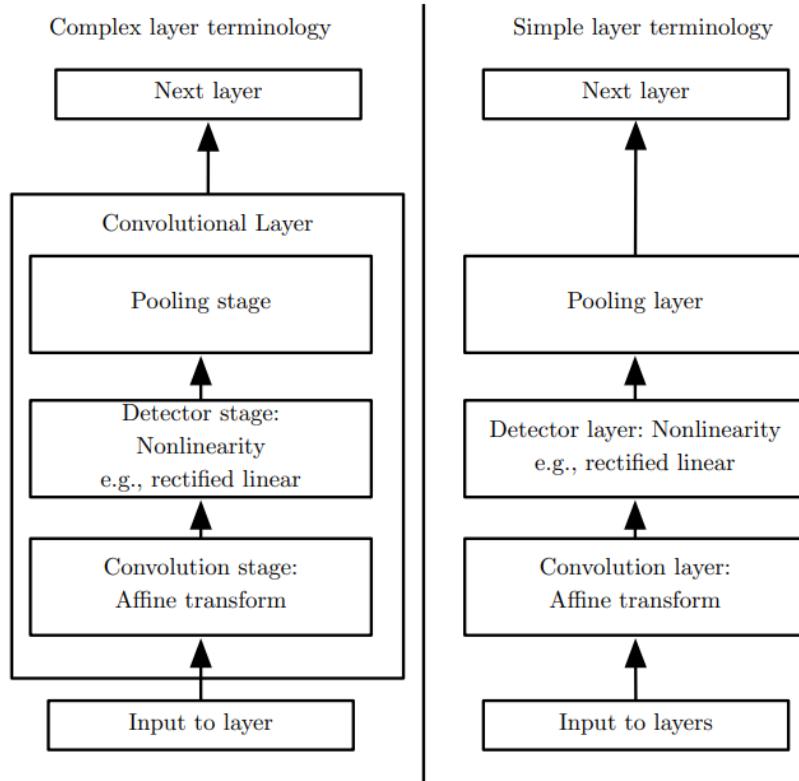


Ilustración 14: Arquitectura básica de una CNN

De acuerdo con Goodfellow et al., una CNN convencional está constituida por capas de pooling, capas convolucionales y capas completamente conectadas. Las capas convolucionales utilizan filtros con el fin de obtener propiedades locales de la imagen, a la vez que las capas de pooling disminuyen la dimensionalidad y mantienen la información más importante. Este proceso jerárquico favorece la generalización efectiva de la red, ya que es resistente ante cambios en la posición, escala y orientación de los objetos [21].

Según Redmon et al., YOLO (You Only Look Once) es el primer modelo de detección de objetos en tiempo real que empleó las CNNs de forma exhaustiva. Este modelo (como ya se mencionó con anterioridad) realiza una única pasada para procesar la imagen completa y, así, prever simultáneamente las cajas delimitadoras y las probabilidades de clase [13]. Esta perspectiva posibilita el establecimiento de sistemas de seguimiento que se basan en detecciones certeras y veloces, los cuales son compatibles con aplicaciones en tiempo real.



Ilustración 15: Pipeline de detección por CNN

Goodfellow et al. subrayan la relevancia de transfer learning en el ámbito del entrenamiento, que implica la reutilización de redes previamente entrenadas en extensas bases de datos como ImageNet y su adaptación a dominios particulares. Para optimizar la robustez y prevenir el sobreajuste, se hacen uso de métodos de normalización, regularización y aumento de datos. Las métricas de rendimiento más habituales incluyen la capacidad de la CNN para conservar su consistencia ante variaciones en la luz, obstrucciones parciales y desplazamientos de los objetos, así como la precisión media (mAP) para detección [21].

## 3.2 Machine Learning para Series Temporales

Para realizar el análisis computacional del comportamiento de los animales, no es suficiente con identificar lo que sucede en cada fotograma; también es necesario entender cómo dicho comportamiento se desarrolla con el tiempo. Para lograr esto, los modelos de aprendizaje automático que se especializan en series temporales posibilitan la captura de relaciones, patrones dinámicos y dependencias que solo se manifiestan cuando las observaciones se analizan como secuencias. En este campo, sobresalen las arquitecturas que se han creado para procesar datos históricos y simular alteraciones progresivas o repentina en el desplazamiento de los animales, por ejemplo, las LSTM, las RNN, los Transformers y los métodos de validación estadística que se utilizan para medir su exactitud.

### 3.2.1 Redes Neuronales Recurrentes (RNN)

Los modelos de RNN estás creados para manejar datos secuenciales, incluyendo dependencias temporales a través de un estado oculto que se actualiza en cada iteración. Según Goodfellow et al. (2016), su rasgo más característico es la existencia de conexiones recurrentes que posibilitan que datos de etapas anteriores incidan en el procesamiento actual, lo cual resulta fundamental para tareas con series temporales.

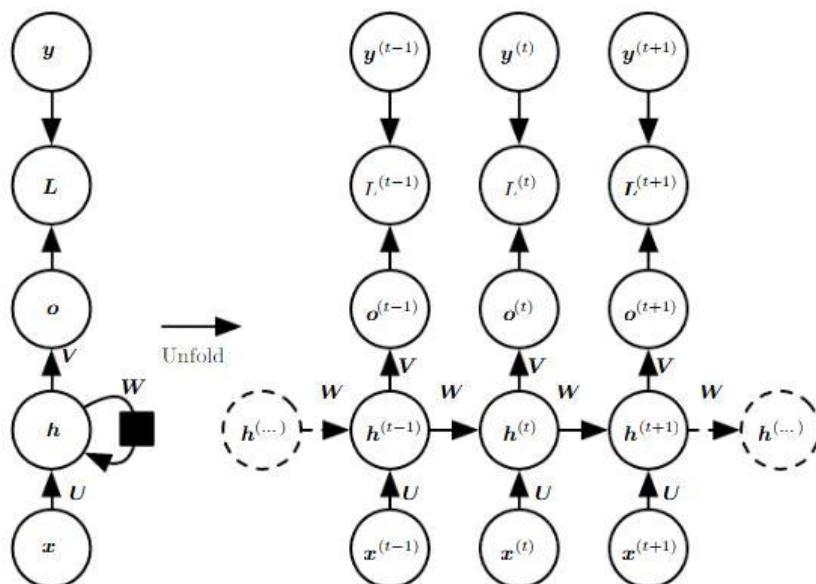


Ilustración 16: Arquitectura básica de una RNN

Matemáticamente, una RNN calcula su estado interno de este modo

$$h_t = f(W_{xh}x_t + W_{hh}h_{t-1} + b_n),$$

En la que  $h_t$  resume tanto la información actual como la que proviene del pasado cercano. Como Bishop (2006) señala, este estado encubierto se puede observar con mayor claridad al "desplegar" la red a través del tiempo, demostrando cómo cada paso depende del previo.

Debido a su estructura repetitiva, las RNN son particularmente beneficiosas en series temporales; la razón es que posibilitan la captura de cambios dinámicos, patrones a nivel local y dependencias de corto alcance sin requerir ventanas manuales de datos. Goodfellow y sus colegas (2016) muestran, además, un diagrama conceptual del flujo de información que ilustra el modo en que el estado oculto funciona como un resumen del pasado pertinente para hacer predicciones en cada momento.

### 3.2.2 LSTM (Long Short-Term Memory)

Esta es una arquitectura de redes neuronales recurrentes (RNN) diseñada específicamente para modelar dependencias a largo plazo en series temporales. De forma tradicional, las RNN tienen a "olvidar" información conforme las secuencias se vuelven largas debido al desvanecimiento o explosión del gradiente. Este problema, identificado desde la década de los noventa, llevó al desarrollo de la arquitectura LSTM por Hochreiter y Schmidhuber en 1997 [18]. A diferencia de la RNN estándar, las LSTM integran una estructura interna conocida como celda de memoria, cuya función es conservar información útil a lo largo del tiempo sin que esta se degrade conforme crece la longitud de la secuencia.

Una LSTM, en términos operativos, controla los datos que pasan por su celda de memoria con un grupo de puertas que funcionan como filtros. Esta dinámica interna posibilita determinar qué recordar, qué olvidar y qué mostrar como salida, solucionando de manera efectiva el problema de las dependencias a largo plazo. De acuerdo con la explicación clásica de Olah [19], el proceso se puede entender mediante cuatro pasos esenciales:

1. Forget gate (puerta de olvido)

Tal como se muestra en la Ilustración 9 del artículo de Ola "Understanding LSTM Networks" [19], la primera operación que se lleva a cabo dentro de la celda, y establece qué fracción del estado anterior  $C_{t-1}$  debe ser desechar. Basado en la combinación del estado oculto previo  $h_{t-1}$  con la entrada vigente  $x_t$ , un vector es producido por una capa sigmoide  $f_t \in [0,1]$  que señala qué información se retiene y cuál se descarta.

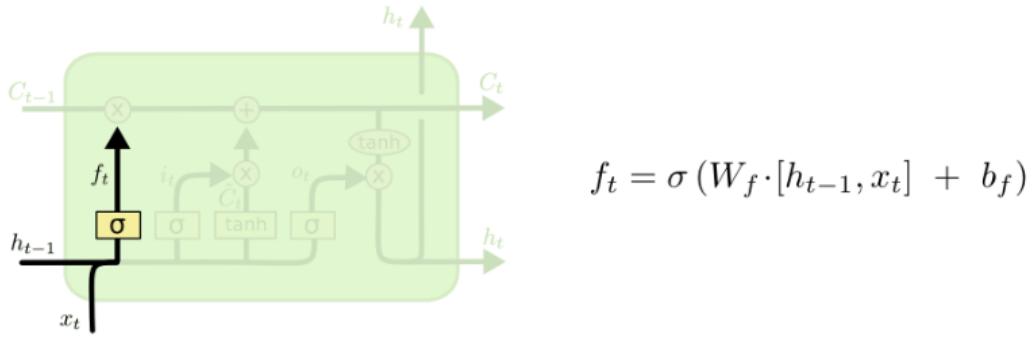


Ilustración 17: Puerta de olvido

## 2. Puerta de entrada y valores candidatos

En la Ilustración 10 de Olah [19] se observa el funcionamiento de la puerta de entrada. Aquí el modelo determina qué información reciente integrar en el estado interno. Para lograr esto, una segunda capa sigmoide produce  $i_t$ , que determina qué componentes serán actualizados, mientras que la capa  $\text{tanh}(h)$  calcula un vector candidato  $\tilde{C}_t$  con los valores que podrían añadirse.

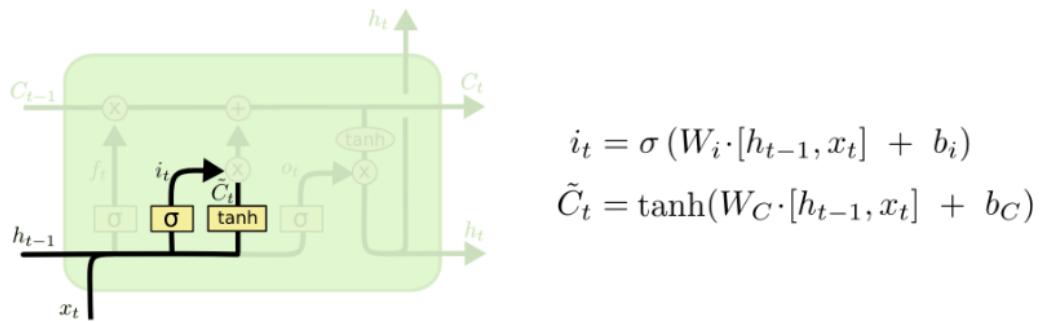


Ilustración 18: Puerta de entrada y valores candidatos

## 3. Actualización del estado de la celda

La Ilustración 11 sintetiza la actualización del estado de la celda. El estado recién creado  $C_t$  se origina de la combinación de lo que se mantiene y lo que se añade:

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

Este mecanismo es fundamental para la estabilidad del comportamiento de las LSTM, ya que hace posible mantener información relevante durante largos períodos sin que esta se deteriore.

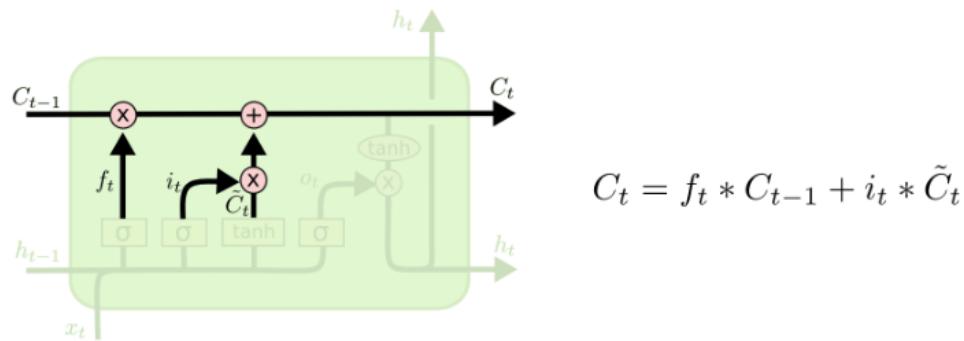
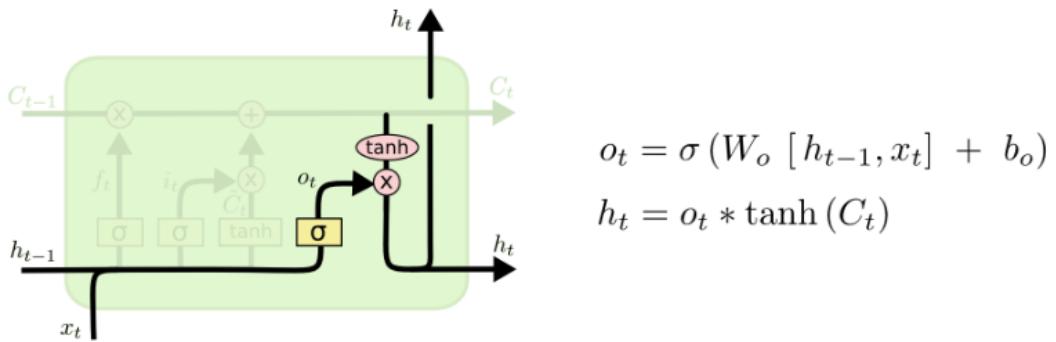


Ilustración 19: Actualización del estado de la celda

#### 4. Puerta de salida y generación del estado oculto

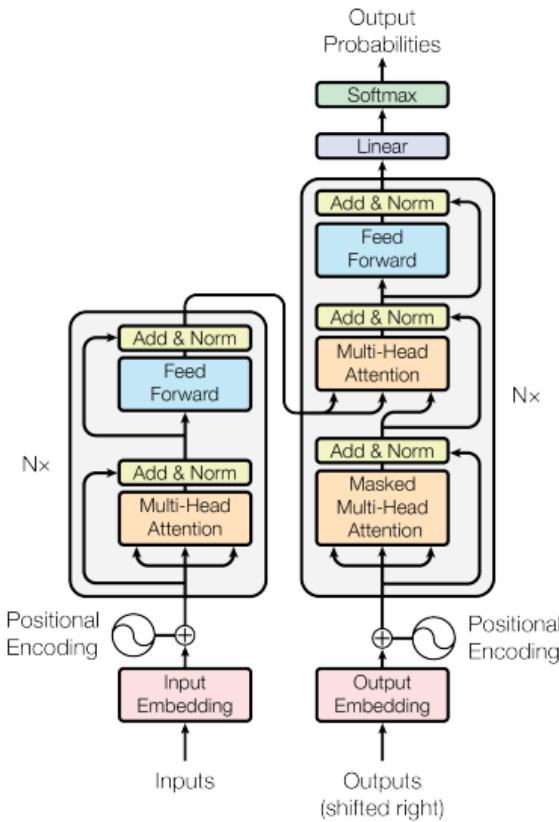
Finalmente, la Ilustración 12 de Olah [19] muestra como una tercera compuerta sigmoide establece qué fracción del estado  $C_t$  será presentada como solución. Después la celda aplica una función  $\tan(h)$  a  $C_t$  y la ajusta a través del vector  $o_t$ , generando de este modo el estado oculto  $h_t$ , que nutre la fase temporal siguiente.



### 3.2.3 Transformers

Son una arquitectura de deep learning que reemplaza totalmente la utilización de redes recurrentes y convolucionales, empleando solamente mecanismos de atención propia para el procesamiento de secuencias. A pesar de que se introdujo en un principio para la traducción automática, sus características posibilitan su adaptación eficaz al modelado de series temporales, en las que es necesario captar relaciones a largo plazo entre posiciones dentro de la secuencia.

A diferencia de modelos recurrentes como LSTM y RNN, los Transformers posibilitan que el procesamiento de la secuencia total se realice en paralelo, lo que disminuye significativamente el tiempo de entrenamiento. La atención escalada por producto punto (scaled dot-product attention) facilita la conexión de cualquier momento temporal con otro utilizando una única operación computacional, lo que es extremadamente útil para series en las que las relaciones no tienen que ser necesariamente locales o próximas en el tiempo.



*Ilustración 21: Arquitectura general del Transformer*

Para el modelado de series temporales, el encoder lleva a cabo el procesamiento de la secuencia histórica (como los últimos  $n$  pasos), lo que produce representaciones internas que capturan las dependencias globales. El decodificador puede emplearse para hacer predicciones autorregresivas de manera secuencial, usando la set-attention enmascarada con el fin de evitar que el modelo “visualice el futuro”. Esta característica reproduce la conducta autorregresiva clásica de las series temporales, pero con el beneficio de que la atención posibilita que se exploten relaciones complejas a lo largo de toda la ventana temporal.

Para llevar a cabo esta operación, el Transformer utiliza el mecanismo de atención que se muestra en la Ilustración 14, en la cual cada instante de tiempo es representado como una consulta ( $Q$ ), una clave ( $K$ ) y un valor ( $V$ ). Esto posibilita evaluar la importancia de cada momento de la serie en comparación con los otros.

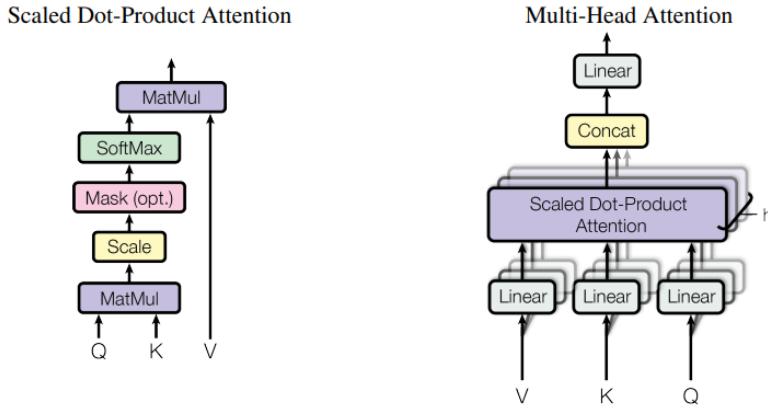


Ilustración 22: Atención escalada por producto punto y multi-head attention

En la práctica, gracias a la multi-head attention, el modelo puede trabajar con varios patrones temporales al mismo tiempo: correlaciones entre variables, efectos rezagados, estacionalidades y tendencias, entre otros. Cada “cabeza” aprende una forma diferente de dependencia temporal.

El positional encoding es otro elemento fundamental para las series temporales; permite compensar la falta de recurrencia e introduce información acerca del orden temporal. La codificación sinusoidal que Vaswani, Shaazer y el equipo de desarrollo del Transformer propusieron específicamente posibilita que el modelo se generalice a horizontes temporales más extensos que los contemplados durante la fase de entrenamiento.

En la Tabla 2 se presenta un resumen de la superioridad estructural de los Transformers en comparación con las arquitecturas recurrentes y convolucionales, que consiste en su capacidad para atrapar dependencias globales a través de rutas computacionales más breves y en su menor complejidad secuencial.

| Layer Type                  | Complexity per Layer     | Sequential Operations | Maximum Path Length |
|-----------------------------|--------------------------|-----------------------|---------------------|
| Self-Attention              | $O(n^2 \cdot d)$         | $O(1)$                | $O(1)$              |
| Recurrent                   | $O(n \cdot d^2)$         | $O(n)$                | $O(n)$              |
| Convolutional               | $O(k \cdot n \cdot d^2)$ | $O(1)$                | $O(\log_k(n))$      |
| Self-Attention (restricted) | $O(r \cdot n \cdot d)$   | $O(1)$                | $O(n/r)$            |

Tabla 2: Complejidad por capa y longitud de camino para diferentes arquitecturas

### 3.2.4 Coeficiente Kappa de Cohen para validación de concordancia

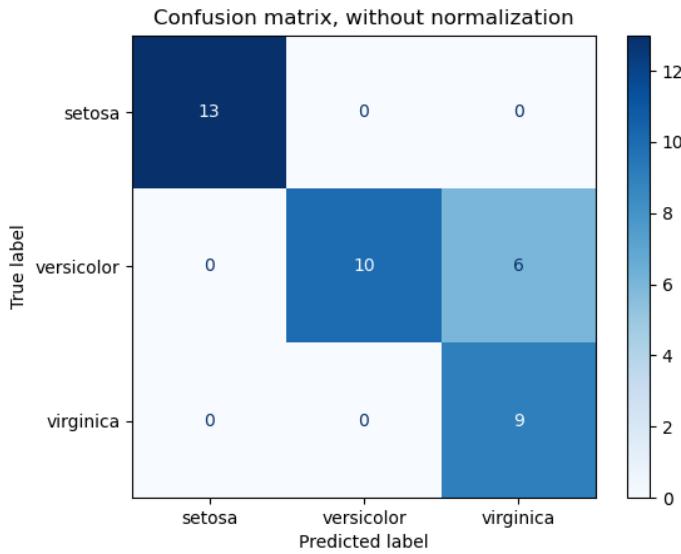
Según Cohen, el coeficiente Kappa de Cohen es una medida creada para calcular la concordancia entre dos clasificadores nominales, corrigiendo el acuerdo esperado por azar. Se utiliza con frecuencia como estándar para evaluar acuerdos interanotador y la validez de sistemas de clasificación automática. Esta característica lo vuelve particularmente valioso en problemas de Machine Learning para series temporales, en los que las etiquetas pueden ser ruidosas, ordinales o

desbalanceadas. En esas situaciones, si no se ajusta por la probabilidad de coincidencia aleatoria, el porcentaje de aciertos simple puede llevar a resultados engañosos [27].

De acuerdo con McHugh, la interpretación de Kappa se basa en una escala práctica: los valores que están cerca de 1 indican una concordancia casi perfecta; los que rondan el 0 muestran un acuerdo equivalente al azar, mientras que los negativos evidencian desacuerdo sistemático. El coeficiente Kappa proporciona un marco uniforme que posibilita la comparación de la fortaleza de los modelos ante la variabilidad humana en la anotación, para el análisis comparativo de arquitecturas de series temporales, como los modelos basados en Long Short-Term Memory (LSTM) de Hochreiter y Schmidhuber o los modelos Transformer sugeridos por Vaswani et al. Kappa es útil para determinar si un modelo está aprendiendo patrones reales o simplemente repitiendo la distribución marginal de clases cuando las anotaciones humanas son consideradas como "verdaderas" (standard gold) [28]; su implementación es aconsejable no solo para validar a los anotadores, sino también para informar sobre la confiabilidad del modelo.

La fórmula tradicional para calcular el coeficiente es  $k = \frac{(p_o - p_e)}{1 - p_e}$  en donde  $p_o$  indica la proporción y acuerdo que se ha observado y  $p_e$  la probabilidad de acuerdo esperada por azar. Fleiss et al. analizan a fondo las propiedades y generalizaciones estadísticas del coeficiente, y también tratan sobre versiones ponderadas que son beneficiosas cuando los desacuerdos no tienen la misma gravedad o cuando las clases poseen una relación ordinal (por ejemplo, un error adyacente en una escala ordinal debería ser penalizado menos que un error lejano) [29]. En series temporales de tipo biomédico o etológico, es necesario informar sobre  $p_o$ ,  $p_e$  y  $k$  junto con intervalos de confianza es un buen método para proporcionar claridad acerca de la estabilidad estadística del indicador.

En investigaciones de estimación de postura y comportamiento en las cuales se emplean instrumentos como OpenPose (Cao et al.) o DeepLabCut (Mathis et al.), es habitual cotejar etiqueta por etiqueta las etiquetas automáticas con las humanas y reportar Kappa, además de matrices de confusión temporales y análisis de error por intervalos (por ejemplo, cuando hay transiciones entre estados). DeepLabCut y OpenPose posibilitan el etiquetado de frames a gran escala; sin embargo, en concordancia con Mathis et al., es fundamental la validación human-in-the-loop y el uso de métricas como Kappa para asegurar que los resultados sean creíbles y reproducibles [12]. Por ello, incluye visualizaciones temporales junto con los valores de Kappa para mostrar dónde suceden las discrepancias y si se agrupan en transiciones rápidas entre estados o en eventos poco comunes.



*Ilustración 23: Ejemplo de Matriz de confusión temporal*

### 3.3. Minería de Datos y Clasificación de Comportamientos

Para el análisis cuantitativo del comportamiento, se requieren métodos que tengan la capacidad de ordenar grandes cantidades de datos provenientes de trayectorias, posiciones y señales temporales. Este marco es proporcionado por la minería de datos, porque posibilita el hallazgo de estructuras internas, la disminución de la complejidad de las observaciones y la creación de categorías que simplifican la interpretación neuroconductual o etológica. En este marco, los algoritmos de agrupamiento, clasificación supervisada y reducción de dimensionalidad son fundamentales para detectar patrones repetitivos, diferenciar conjuntos de comportamientos y elegir las características más significativas en sistemas con una gran cantidad de variables que suelen ser ruidosas. Las siguientes subsecciones detallan las metodologías más utilizadas en este ámbito y explican su relevancia para el análisis computacional del comportamiento animal.

#### 3.3.1 K-Means (Clustering)

El algoritmo K-Means, que fue presentado por primera vez en el trabajo de MacQueen "Some Methods for Classification and Analysis of Multivariate Observations" (1967) [30], es un método esencial para la agrupación no supervisada. Se emplea para identificar patrones y estructuras ocultas en conjuntos de datos con alta dimensionalidad. Este procedimiento, de acuerdo con el libro clásico de Bishop "Machine Learning and Pattern Recognition" [22], divide los datos en K grupos al minimizar la distancia entre cada punto y el centroide del clúster que le corresponde. Según Bishop, esta estrategia es especialmente efectiva cuando se persiguen "regiones compactas y casi esféricas" en los datos. Por lo tanto, es adecuada para usarse en minería de datos aplicada al estudio de la conducta animal, la identificación de patrones motores y el análisis etológico.

K-Means es un procedimiento para identificar patrones de conducta que se repiten con el tiempo, en el contexto de minería de datos y clasificación conductual. El algoritmo permite la agrupación de

segmentos de conducta semejantes sin requerir etiquetas previas en investigaciones que rastrean animales y donde se recogen variables como trayectorias espaciales, velocidad o ángulos corporales. Esta perspectiva, según Bishop [22], es efectiva para disminuir la dimensionalidad conceptual del comportamiento, ya que facilita la identificación de categorías que posteriormente pueden asociarse con fenómenos neuroconductuales o etológicos. Cuando se completa esta estructura con sistemas de visión computacional como EzTrack [5] o DeepLabCut [12], es particularmente beneficiosa, ya que ambos producen datos cuantitativos que tienen la capacidad de ser introducidos directamente en el algoritmo.

El proceso computacional se compone de cuatro etapas fundamentales: el establecimiento inicial de K centroides, la asignación a cada punto del centroide más próximo, el recálculo de los centroides y la repetición hasta que se alcance la convergencia. Según MacQueen [30], este ciclo es sencillo y eficiente, lo que posibilita la utilización de K-Means en grandes cantidades de información con un coste computacional reducido. En investigaciones sobre el comportamiento de los animales, esta eficacia permite analizar millones de fotogramas.

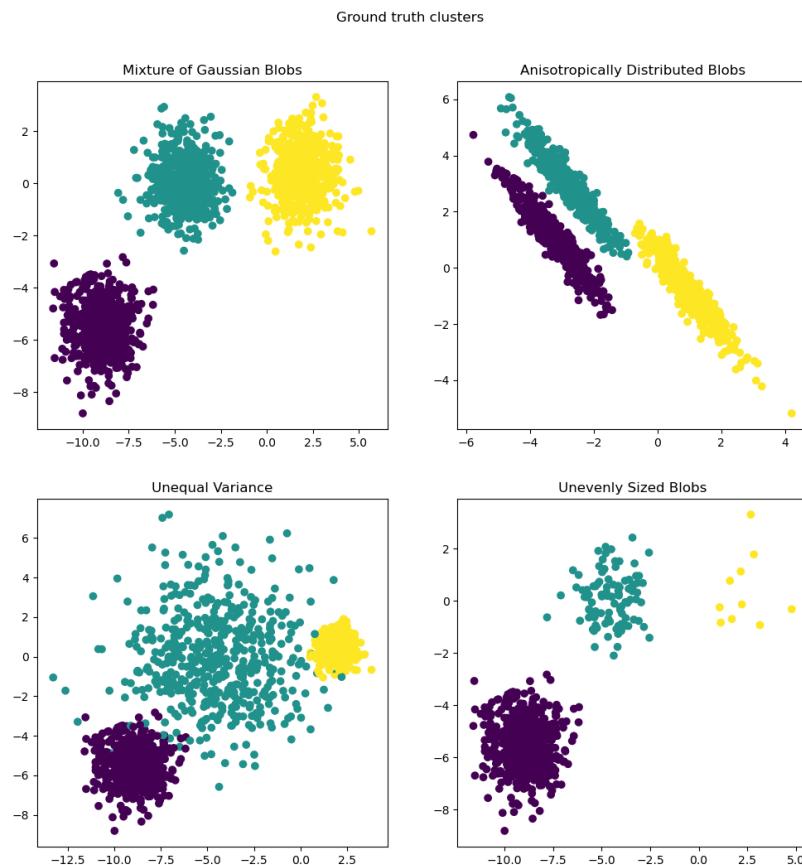
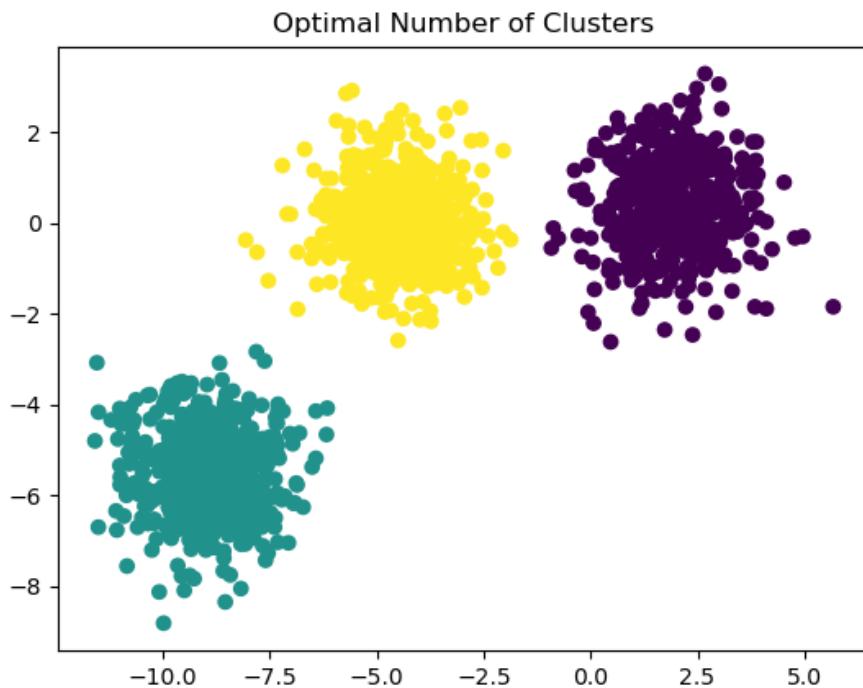


Ilustración 24: Representación gráfica del proceso iterativo (asignación y actualización)

K-Means tiene serias limitaciones a pesar de su utilidad. De acuerdo con Bishop [22], el método es sensible a la inicialización, tiene la capacidad de converger a soluciones locales y no opera adecuadamente si los clústeres son significativamente desiguales en tamaño o si no tienen una forma aproximadamente esférica. Por lo tanto, en las aplicaciones de análisis conductual, se aconseja que se revisen varias inicializaciones ( $k$ -means++) y que se valide a los clusters utilizando índices como Dunn o Silhouette.



*Ilustración 25: Ejemplo de diferentes resultados de clustering con distintas distribuciones*

### 3.3.2 Random Forest

El algoritmo Random Forest es parte de la familia de estrategias de ensamblaje que fusionan varios árboles de decisión con el propósito de optimizar la habilidad predictiva de los modelos. Según Breiman, que formalmente presentó esta técnica en 2001 [32], el procedimiento consiste en crear múltiples árboles que se entrena sobre subconjuntos aleatorios de datos y variables. Esta estrategia, en el contexto de la minería de datos aplicada a la evaluación de comportamientos, disminuye la variabilidad que los modelos individuales tienen por su propia naturaleza y posibilita identificar patrones complejos sin caer fácilmente en el sobreajuste. Bishop sostiene que al combinar predicciones independientes de los modelos base, los métodos de ensamble aumentan la habilidad de generalización de manera constante [22].

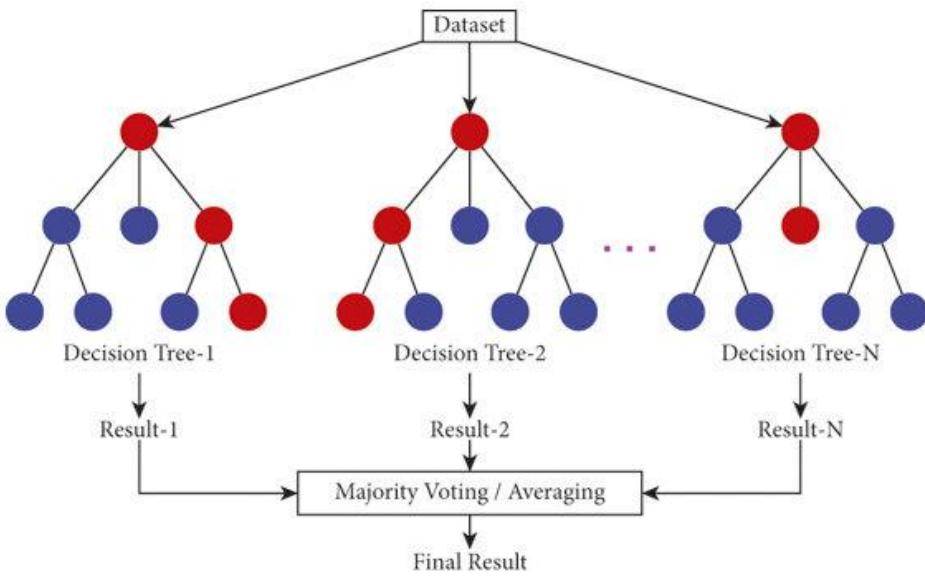


Ilustración 26: Múltiples árboles de decisión en un Random Forest [34]

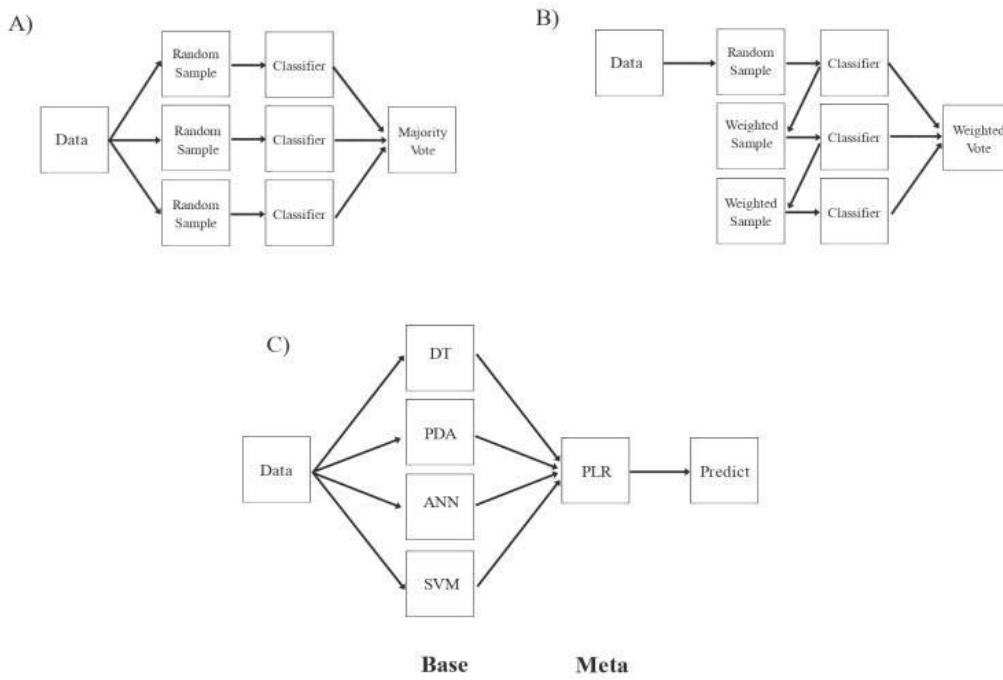


Ilustración 27: Diagrama esquemático de los métodos de ensamblaje [35]

En contextos en los que se examinan comportamientos humanos o animales a través de métodos de visión por computadora, es frecuente que los conjuntos de datos sean incompletos, tengan un alto número de dimensiones o estén llenos de ruido. Quintana-Diez afirma que la inclusión de inteligencia

artificial en el análisis del comportamiento animal ha posibilitado el tratamiento de grandes cantidades de datos con mayor exactitud y consistencia [14]. De acuerdo con Bailey y su equipo, los modelos computacionales contribuyen a relacionar patrones de comportamiento con parámetros fisiológicos, incluso cuando la información tiene variaciones entre individuos [10], este algoritmo es perfecto para este tipo de situaciones, ya que gestiona correctamente datos heterogéneos y posibilita determinar cuáles rasgos tienen mayor incidencia en una clasificación mediante medidas de la importancia de las variables.

DeepLabCut de Mathis et al. [12] y OpenPose de Cao et al. [23], que son herramientas modernas, también producen descriptores temporales y espaciales de alta resolución acerca del movimiento o la postura. Estos rasgos se utilizan como insumo para modelos de clasificación que emplean Random Forest, los cuales tienen la capacidad de identificar comportamientos, detectar anomalías o dividir grupos experimentales. Pereira y Moita, en sus investigaciones etológicas, afirman que la visión artificial ha transformado radicalmente el modo de cuantificar la conducta, posibilitando así la creación de bases de datos confiables y ampliables para realizar minería de datos [16]. En esa línea, el hecho de que el bosque aleatorio tenga la habilidad de trabajar con cientos de descriptores lo hace un candidato apropiado para los sistemas de análisis automatizado.

Asimismo, Random Forest se caracteriza por su capacidad para ser interpretado. De acuerdo con Hastie, Tibshirani y Friedman [33], en The Elements of Statistical Learning, los bosques posibilitan la estimación de la importancia de cada variable a través de métricas como el decrecimiento de impureza o la disminución en precisión al permutar características. Cuando se intenta entender qué elementos explican una conducta, sobre todo en la investigación veterinaria o biomédica, esta información es fundamental. Según Barton y Olson, para que los sistemas inteligentes sean integrables en la toma de decisiones clínicas, deben ser transparentes y precisos a la vez [9].

### 3.3.3 Máquinas de Vectores de Soporte (SVM)

Según Burges en "A Tutorial on Support Vector Machines for Pattern Recognition" [36], las máquinas de soporte vectorial (SVM) son un clasificador supervisado que se propone encontrar el hiperplano óptimo que divide dos clases, con el objetivo de maximizar el margen entre los vectores de soporte. Que el clasificador dependa solo de los vectores de soporte pone de relieve su eficiencia en la memoria y su habilidad para generalizar.

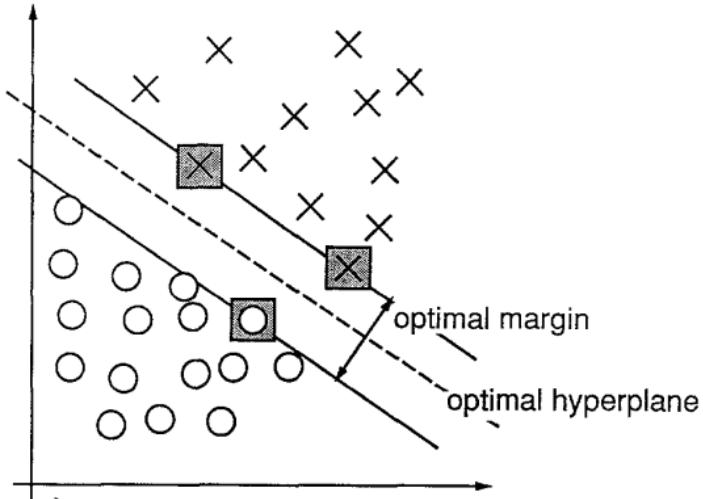
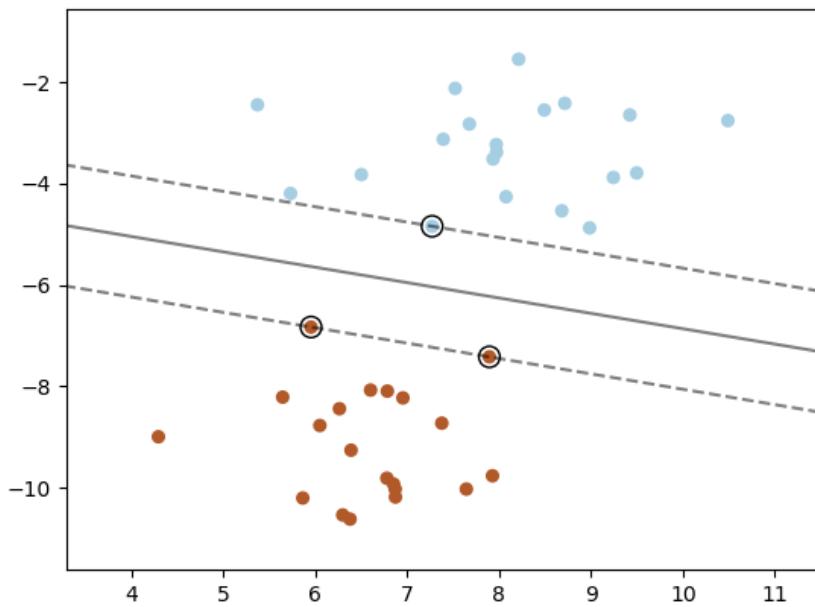


Ilustración 28: Ejemplo de un problema de clasificación en un espacio bidimensional. Los vectores de soporte marcados con cuadros grises definen el margen mayor de separación entre las 2 clases [36]

Las SVM son efectivas en espacios con alta dimensionalidad y se pueden utilizar cuando la cantidad de dimensiones sobrepasa la cantidad de muestras, de acuerdo con el manual de uso de scikit learn. [37] En concreto, el algoritmo contiene la selección de un parámetro de regularización C, que regula el balance entre la adaptación a los datos del entrenamiento y la capacidad de generalizar. Además, se trata el problema de los datos que no pueden separarse de manera no lineal al emplear funciones kernel (como la polinómica, la RBF o la lineal) para hacer un mapeo implícito a espacios de dimensiones superiores, sin tener que calcular explícitamente dicho mapeo.

De acuerdo con Burges [36], la formulación de la SVM se presenta como un problema de optimización cuadrática convexa, acompañado de restricciones que aseguran la clasificación correcta (en el caso separable) o permiten violaciones controladas (margen blando). Esta formulación asegura la existencia de un mínimo global, a diferencia de otros métodos como redes neuronales que pueden quedar atrapados en mínimos locales. Para el dominio de la clasificación de comportamientos tales como reconocimiento de gestos, detección de patrones de conducta o análisis de secuencias temporales, esta propiedad brinda robustez frente al ruido y estabilidad en la frontera de decisión.

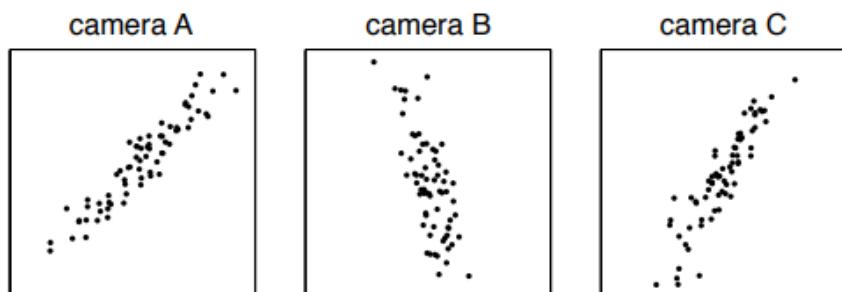
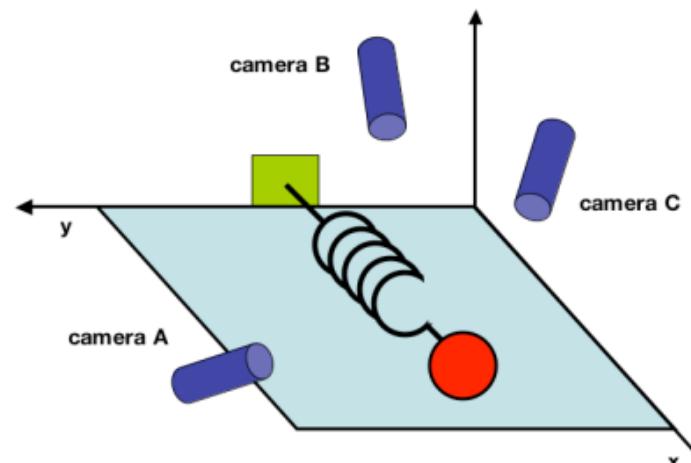


*Ilustración 29: Otro ejemplo de una SVM lineal que muestra el hiperplano óptimo, sus márgenes y los vectores de soporte que determinan la separación entre clases [37]*

Según Burges [36], la formulación de la SVM es un problema de optimización cuadrática convexa, que incluye restricciones para garantizar una clasificación adecuada (en el caso separable) o para permitir infracciones controladas (margen blando). Esta formulación garantiza que haya un mínimo global, lo cual contrasta con otros métodos como las redes neuronales, que pueden quedar estancadas en mínimos locales. Esta propiedad proporciona estabilidad en la frontera de decisión y solidez frente al ruido en el ámbito de detección de patrones conductuales y clasificación de comportamientos.

### 3.3.4 Reducción de dimensionalidad

La reducción de dimensionalidad es una serie de métodos que buscan convertir datos de alta dimensión en representaciones más compactas, pero sin que la estructura fundamental del problema se vea afectada. Este procedimiento posibilita la eliminación de redundancias, ruido y variables que no tienen relevancia, según Pattern Recognition and Machine Learning de Christopher Bishop [22]. Esto es particularmente ventajoso en minería de datos, donde el número de atributos puede obstaculizar tanto el rendimiento computacional como la interpretación de los modelos. La reducción de la dimensionalidad, en este contexto, permite identificar patrones más generales y aumenta la habilidad de los algoritmos para clasificar las conductas complejas tanto en individuos como en animales.



*Ilustración 30: Ejemplo conceptual del problema de dimensionalidad en un sistema de una pelota en un resorte observado desde 3 cámaras [31]*

El PCA (Análisis de Componentes Principales) es un método muy utilizado. De acuerdo con lo que plantean Hastie, Tibshirani y Friedman en *The Elements of Statistical Learning* [33], el PCA proyecta los datos en nuevas direcciones ortogonales denominadas "componentes principales", las cuales capturan la mayor varianza posible del conjunto de datos original. Esto posibilita que la representación se simplifique sin que la estructura estadística predominante se vea afectada. La Ilustración 31 presenta una nube de puntos donde la dirección principal no coincide con los ejes originales, sino con una dirección inclinada que captura la señal principal, en otras palabras, muestra visualmente cómo PCA determina el rumbo de mayor varianza para describir los datos de manera más precisa.

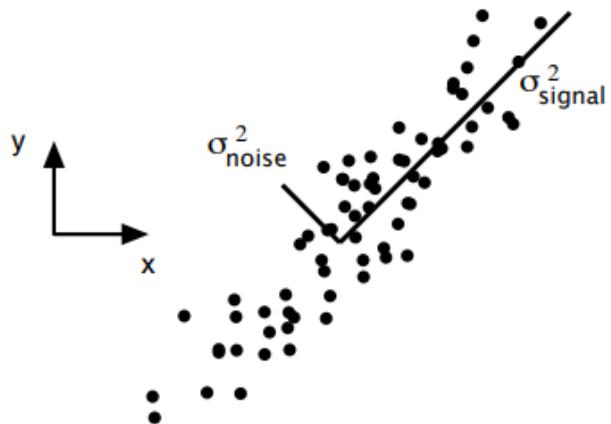


Ilustración 31: Nube de datos simulados para la cámara A con indicación de varianza de señal y ruido. Adaptada de Shlens [31]

Bishop [22] también sostiene que los métodos no lineales, como Isomap y t-SNE, son capaces de mantener relaciones topológicas más complejas en los datos. Cuando las conductas tienen patrones muy correlacionados o dinámicas delicadas que no se pueden captar de manera apropiada a través de transformaciones lineales, estas técnicas resultan ser especialmente eficaces.

### 3.4 Modelos experimentales en etología y neurociencia conductual

El estudio experimental de la conducta ansiosa requiere modelos que integren principios etológicos con fundamentos neurobiológicos para permitir una interpretación cuantitativa y reproducible del comportamiento. Estos modelos, ampliamente empleados en neurociencia conductual, se basan en situaciones controladas que evocan respuestas defensivas naturales y facilitan la medición de variables como exploración, evitación e inmovilidad. Su diseño permite vincular patrones observables con procesos subyacentes (sensoriales, cognitivos y emocionales) y establecer puentes entre el comportamiento espontáneo de los animales y los mecanismos neurales que lo regulan. Las subsecciones siguientes describen los constructos etológicos relevantes y los paradigmas experimentales más utilizados en la caracterización del comportamiento ansioso.

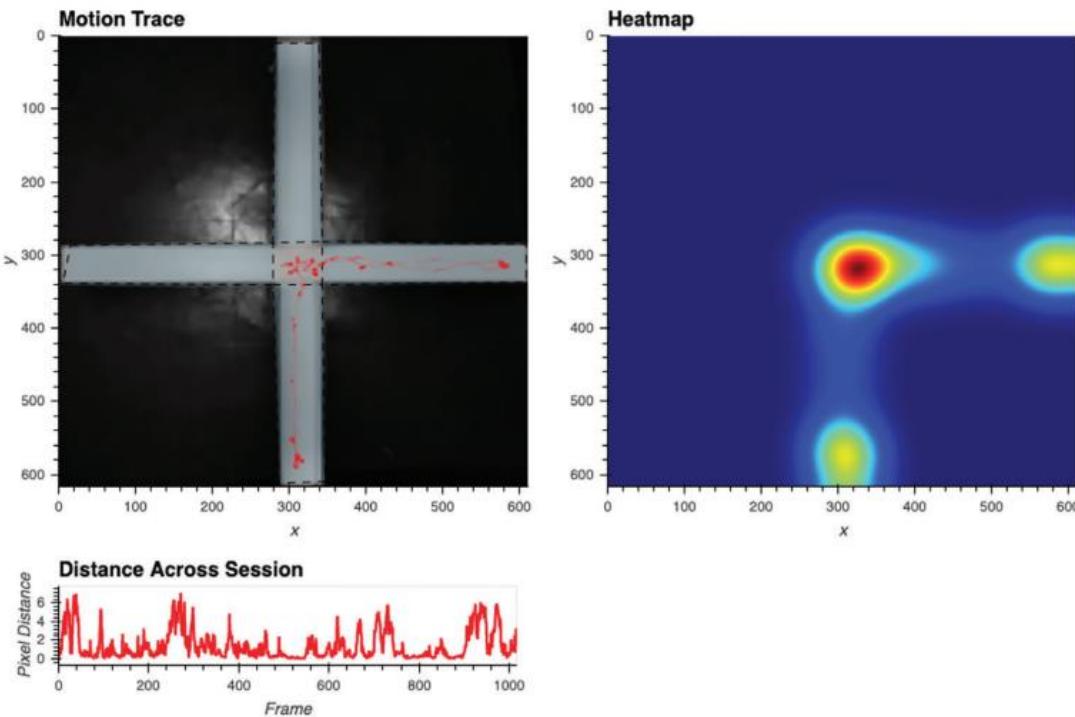
#### 3.4.1 Conceptos etológicos del comportamiento ansioso

El análisis del comportamiento ansioso en modelos animales se apoya en paradigmas experimentales que evocan respuestas defensivas naturales y permiten medirlas de forma objetiva. Estos modelos combinan principios etológicos y neurobiológicos para vincular acciones observables con los mecanismos que las generan. A continuación, se presentan los principales constructos conductuales y los métodos más empleados para su estudio.

##### 3.4.1.1 Exploración

Según Carobrez y Bertoglio, la exploración se define como una serie de acciones encaminadas a obtener información sobre el entorno, que incluyen movimientos intencionados, rearings (alzadas),

olfateo dirigido y contacto con objetos [3]. Estas conductas posibilitan la evaluación de la interacción entre el deseo de investigar y la valoración del ambiente, y deben distinguirse del comportamiento motor general, puesto que solo el análisis combinado de frecuencia, tiempo y tipo de conducta proporciona una medida válida de la propensión a explorar [10].



*Ilustración 32: Ejemplo de un módulo de seguimiento de ezTrack [5].*

La operacionalización de la exploración en laboratorio, conforme a lo que indican Pennington y su equipo, necesita una etograma exhaustivo y sistemas de registro automatizados. Estos últimos posibilitan medir tanto sucesos discretos (por ejemplo "sniffing" o "head dips") como variables continuas (como trayectorias o tiempo en áreas). El análisis posicional y la extracción de series temporales de conducta son simplificados por herramientas como EzTrack, lo cual permite que la medición sea más exacta y reproducible [5]. También se aconseja incorporar sesiones de habituación antes para diferenciar la respuesta inicial a lo nuevo de la motivación exploratoria sostenida.

Según Pereira y Moita, unir una etograma con análisis multivariantes (como el agrupamiento de módulos conductuales o componentes principales) posibilita disociar, desde una perspectiva estadística, la exploración de otros elementos comportamentales. Esto permite aumentar la validez de las investigaciones y simplificar la comparación entre especies y protocolos [16]. Wiltschko et al. han mostrado, además, que el análisis de la estructura sub-segundo del comportamiento en roedores brinda una resolución temporal más precisa y permite descubrir micro-movimientos significativos que no se recogen en el análisis global [17].

Mathis y sus coautores han demostrado que, mediante DeepLabCut, se puede estimar la pose sin marcadores y cuantificar automáticamente posturas y movimientos particulares (por ejemplo, rearings

y head-dips) de modo reproducible. Esto mejora la exactitud de la medición de la exploración [12]. Así, es posible obtener información pormenorizada acerca de la motricidad y la disposición exploratoria sin perturbar el comportamiento natural de los animales.

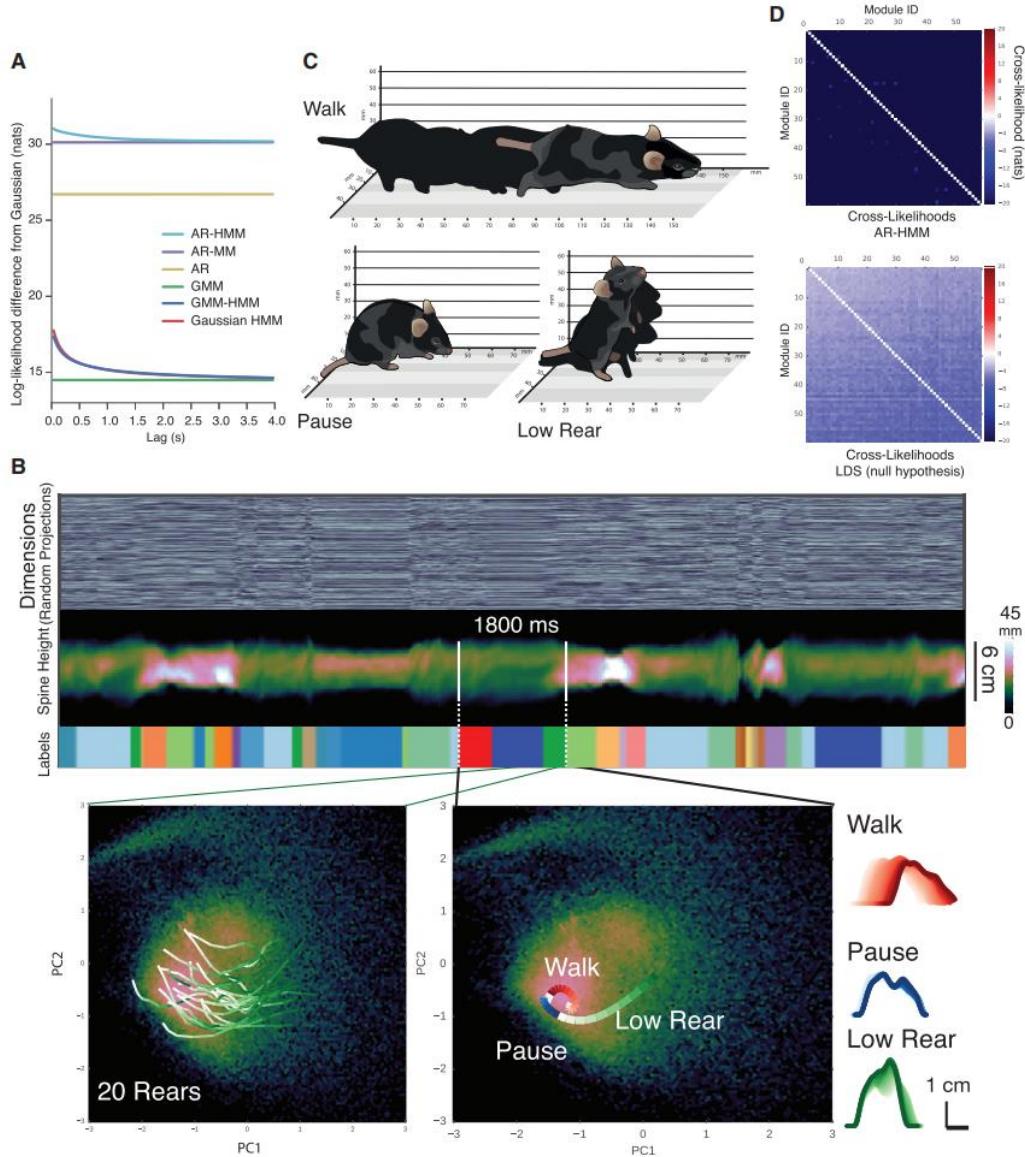


Ilustración 33: Representación de módulos conductuales y transiciones destacando micro movimientos relevantes para la exploración [17]

### 3.4.1.2 Evitación

De acuerdo con Kryptos, Effting, Kindt y Beckers, la evitación es una táctica defensiva adaptativa que busca disminuir las posibilidades de enfrentarse a situaciones o estímulos aversivos. Sin embargo, si se vuelve generalizada o persiste sin una contingencia real, se convierte en mal adaptativa y ayuda a que los trastornos de ansiedad continúen. Kryptos et al. indican que la evitación puede ser adquirida por diversos medios, como procesos habituales y tendencias de rasgo, lo cual requiere paradigmas experimentales que dividan esos procesos. Además, describen los mecanismos de aprendizaje

involucrados (los factores pavlovianos e instrumentales, la influencia de las instrucciones y el aprendizaje vicario). (Según Krypotos et al.). [39]

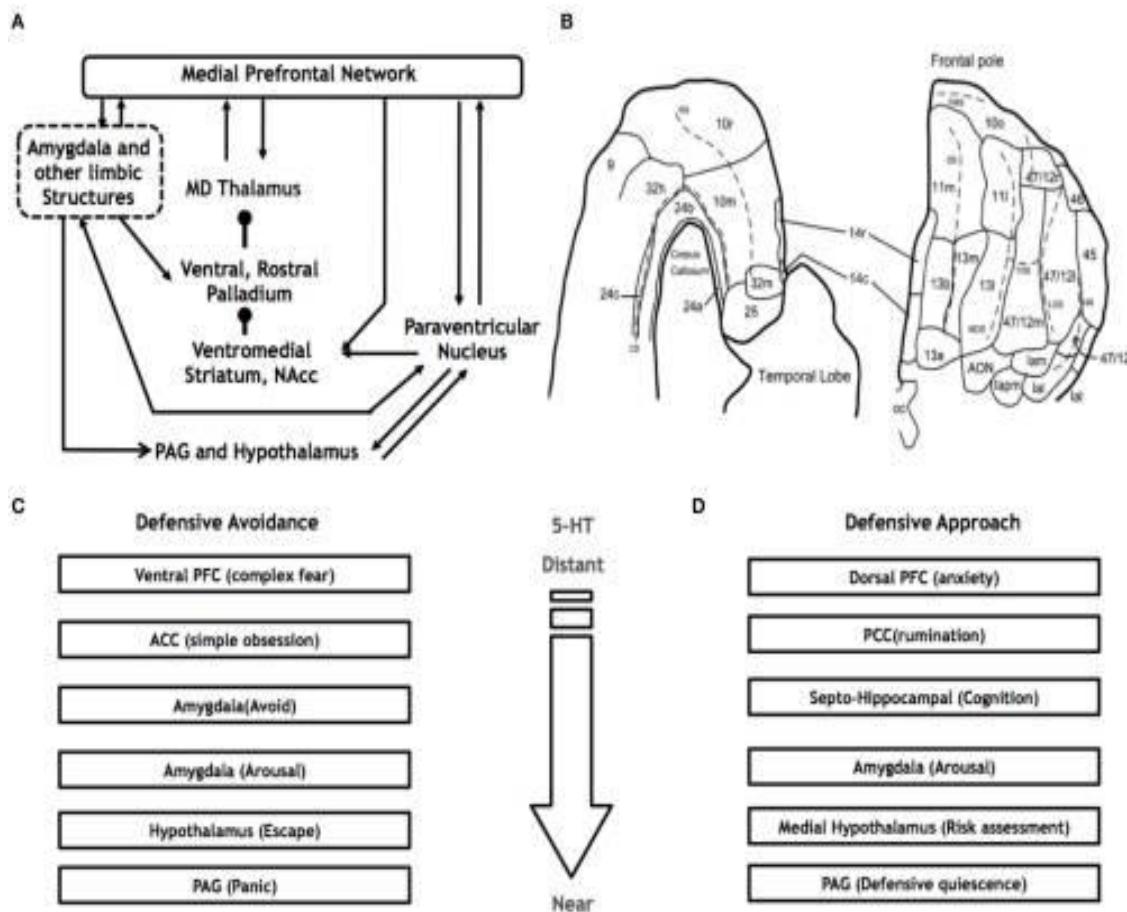


Ilustración 34: Red de la corteza prefrontal media y su implicación en la evitación defensiva [40]

Según la visión neuro etológica, Mobbs y su equipo sugieren que la evitación es parte de un sistema integrado de optimización de la supervivencia (SOS, por sus siglas en inglés), donde se coordinan circuitos que abarcan a la corteza prefrontal medial, al estriado, a la amígdala y a regiones mesencefálicas como el PAG. En este sistema están involucradas las siguientes funciones: evaluar amenazas, prever/prevenir y elegir estrategias como las respuestas circa-strike, el escape dirigido post encuentro y la evitación pre encuentro. Según Mobbs et al., la evitación preventiva (evitar el encuentro) se basa en procesos de predicción/simulación y en redes frontoestriatales que facilitan un cambio de respuestas motivadas por miedo a respuestas más automáticas o instrumentales. (De acuerdo con Mobbs et al.). [40]

Ball y Gunaydin examinan cómo diferenciar la evitación adaptativa de evitación mal adaptativa, además de proponer un marco neuroconductual que divide tres procesos subyacentes: (i) evaluación exagerada del peligro, (ii) evitación regular (involuntaria, insensible al resultado) y (iii) tendencia a evitar como rasgo. Esto indica, en términos experimentales, que se deben medir no solo la expresión de evitación, sino también proxies del miedo (como las medidas autonómicas), la resistencia a la

extinción y la generalización. De esta manera, se podrá determinar si el comportamiento de evitar es causado por un rasgo, un hábito o miedo. Según Ball y Gunaydin. [41]

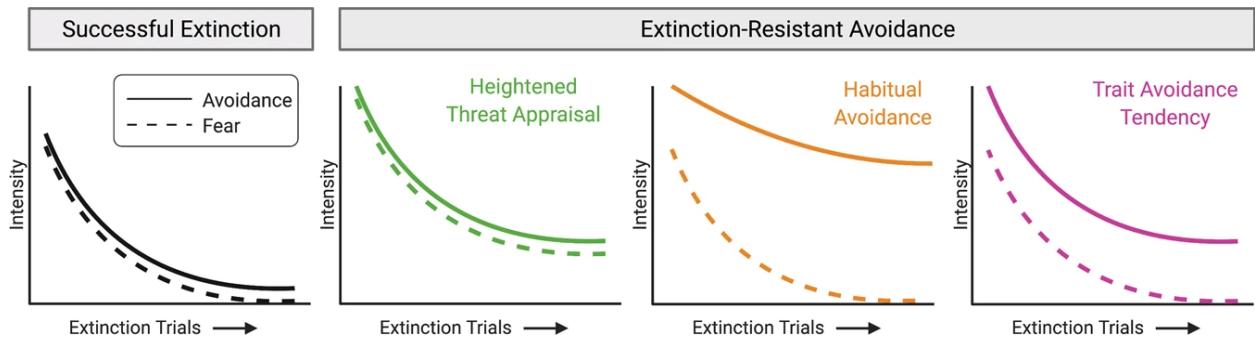
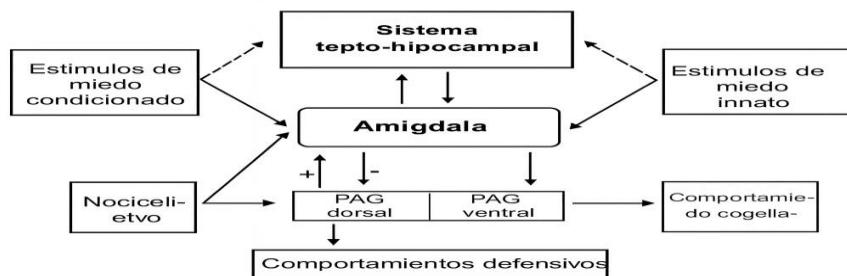


Ilustración 35: Esquema que muestra como la interacción entre el miedo y la evitación permite identificar los procesos neuroconductuales subyacentes [41]

### 3.4.1.3 Inmovilidad/congelación

Desde el punto de vista etológico, la respuesta defensiva conocida como "freezing" o inmovilidad es una reacción frente a amenazas que, Según Brandão et al. [42], consiste en una repentina inhibición motora, acompañada de bradicardia, tras la identificación de un peligro inminente; esto posibilita que el individuo mejore la evaluación de riesgos y disminuya las posibilidades de ser descubierto por un depredador. Este fenómeno se encuentra en el continuo de inminencia depredadora ("predatory imminence continuum"), donde la táctica de defensa va cambiando a medida que la amenaza se aproxima, pasando por exploración, congelación y, finalmente, huida o lucha. [42]



**Fig. 1.** Activación de sustratos neuronales distintos en función de la naturaleza de los estímulos amenazadores. Los estímulos condicionados de peligro (potenciales o distales) elicitán comportamiento condicionado de congelación a través de la activación del sistema de inhibición conductual (sistema tepto-hipocampal), mientras que los estímulos innatos de peligro (proximales o nociceptivos) elicitán formas activas de comportamiento defensivo a través de la activación del eje amigdala-PAG dorsal. La activación del circuito PAG dorsal-amigdala por estímulos nociceptivos también activa mecanismos inhibitorios a través de las proyecciones de la amigdala-PAG dorsal, lo que podría subyacer a la llamada analgesia inducida por el miedo, o la propuesta de que la ansiedad inhibe el pánico, o la propuesta de que la ansiedad innibe el pánico.

Ilustración 36: Esquema de la cascada defensiva [42]

La inmovilidad defensiva, desde la perspectiva neurobiológica, comprende proyecciones que van del núcleo central de la amígdala al gris periacueductal (PAG) en el tronco encefálico; este último regula la bradicardia vagal y la inhibición motora. Según Klaassen et al. [43], este mecanismo posibilita la preparación para actuar, incluso cuando el sujeto parece estar inmóvil. Asimismo, se ha relacionado en seres humanos la magnitud de la congelación con decisiones de aproximación-evitación ante una amenaza, lo que indica su importancia no solo en modelos animales, sino también en el análisis de la ansiedad clínica [43].

Desde el punto de vista etológico, la congelación es distinta de otros estados defensivos, como la inmovilidad tónica ("tonic immobility"), no solo en su función adaptativa, sino también en su desencadenante. La congelación ocurre cuando todavía hay una oportunidad de cambiar la estrategia defensiva, mientras que la inmovilidad tónica suele activarse cuando el sujeto no puede huir ni luchar, y toma una actitud parecida a la "muerte aparente", esta diferenciación es beneficiosa para los modelos experimentales en neurociencia conductual, ya que posibilita el análisis de la manera en que los animales escogen sus respuestas ante diferentes grados de amenaza; esto tiene consecuencias para la investigación sobre características de ansiedad y susceptibilidad a trastornos de ansiedad [42].

### 3.4.2 Laberinto en Cruz Elevada (EPM)

El laberinto en cruz elevado (Elevated Plus-Maze, EPM) es un aparato experimental que se creó con el objetivo de analizar la conducta ansiosa en roedores. Según Carobrez y Bertoglio, el EPM es una plataforma que se encuentra a unos 50 cm del suelo y cuenta con cuatro brazos organizados en forma de cruz: dos de ellos están abiertos, mientras que los otros dos están cerrados por medio de paredes laterales [3]. Este tipo de configuración crea un entorno que mezcla áreas aversivas y seguras, lo cual posibilita la observación de cómo el animal toma decisiones cuando se enfrenta a la disyuntiva entre evitar y explorar.

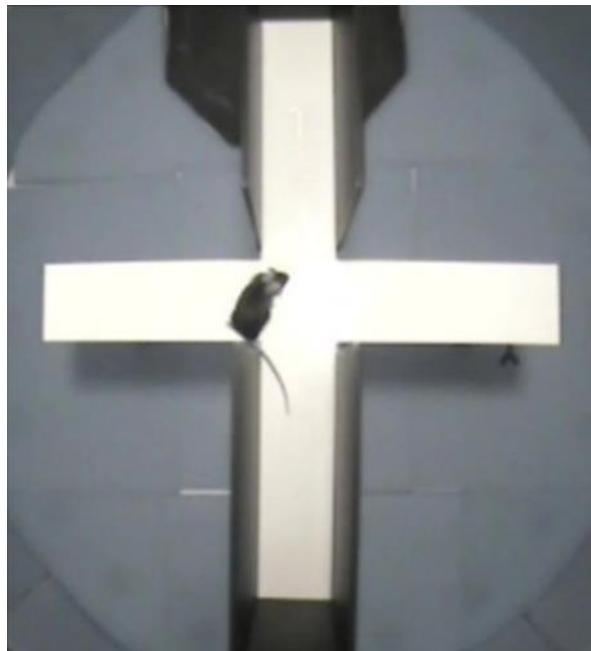


Ilustración 37: Esquema del EPM desde vista superior. Los brazos horizontales son abiertos mientras los verticales son cerrados [44].

De acuerdo con lo que dicen Netto, Zangrossi y Graeff, la lógica del EPM se fundamenta en el temor natural que tienen los roedores a los espacios abiertos y altos [4]. Los brazos abiertos indican peligro, mientras que los cerrados sugieren una zona segura. El nivel de ansiedad del animal se refleja en la selección que hace entre estos espacios, lo cual representa un modelo etológico de aproximación y evitación.

Carobrez y Bertoglio [3] indican que el EPM tiene una estructura habitual con brazos de 50 cm de largo por 10 cm de ancho, que poseen paredes con una altura de 40 cm en los tramos cerrados. La parte central de la cruz es un pequeño soporte que une los cuatro brazos. Esta estandarización garantiza que los resultados sean comparables entre diferentes laboratorios.

El EPM opera de la siguiente manera: se ubica el animal en el centro de la cruz y se monitorea su conducta durante un lapso de 5 a 10 minutos. Los parámetros más frecuentes comprenden el tiempo de latencia para explorar, la cantidad de entradas a cada brazo y el tiempo que se permanece en brazos abiertos y cerrados [3].

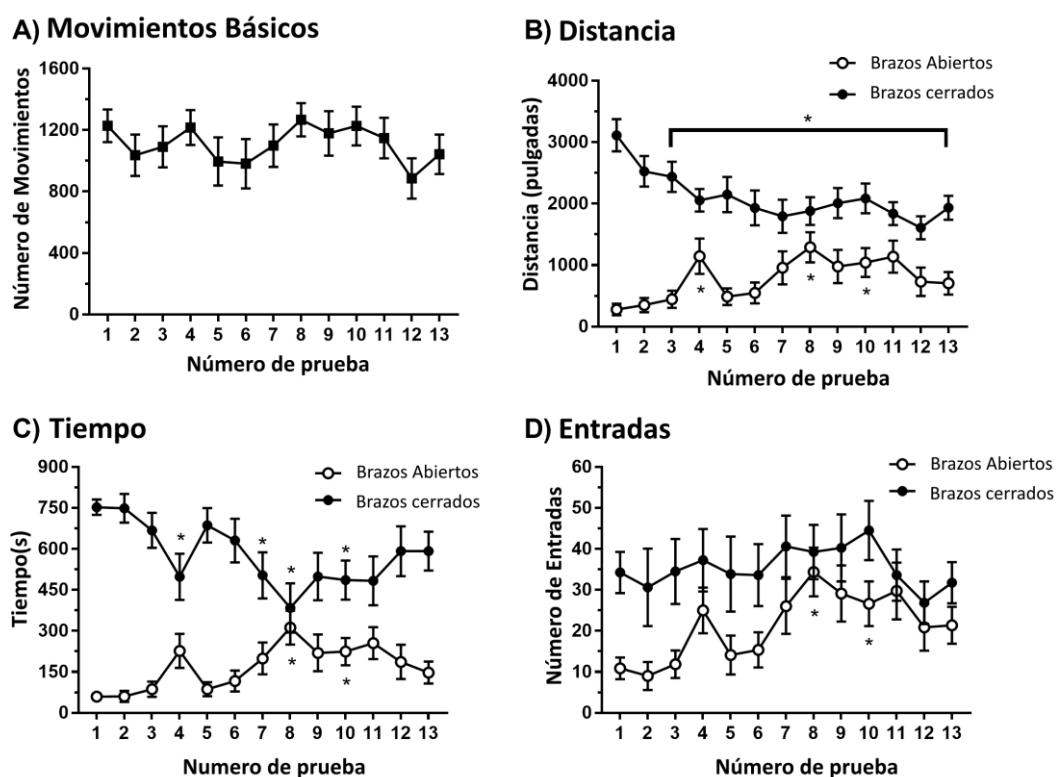


Ilustración 38. Seguimiento del comportamiento individual de ratas mediante pruebas repetidas de EPM [45].

Según Khatri et al., la validación farmacológica del EPM se llevó a cabo con benzodiacepinas, las cuales incrementan la exploración de los brazos abiertos, lo que demuestra que el modelo es sensible a compuestos ansiolíticos [1]. Por lo tanto, el EPM es visto como un estándar fiable para evaluar la ansiedad en animales de laboratorio.

Se examinan conductas particulares como el "head-dipping" (cuando alguien se asoma por el borde de los brazos abiertos) y la "stretch-attend posture" (una postura en que se estira y retrocede), además de las medidas básicas. Estos comportamientos, de acuerdo con Carobrez y Bertoglio, enriquecen la interpretación del modelo [3] y muestran estrategias para evaluar el riesgo.

Pennington et al. indican que los sistemas automatizados, como EzTrack, tienen la capacidad de reemplazar el registro manual. Estos sistemas posibilitan seguir el recorrido del animal y estimar métricas con mayor exactitud [5]. Esto ha permitido una disminución del sesgo observador y una mejora de la reproducibilidad, convirtiéndose en un instrumento accesible y reproducible [5].

Mathis et al. subrayan que tecnologías como DeepLabCut posibilitan la estimación de la postura del animal sin requerir marcadores [12]. Esto extiende el análisis del EPM a aspectos más detallados de la conducta, como los micro movimientos y los patrones de exploración.

Mobbs et al. [40] describen que la amígdala, el hipocampo y la corteza prefrontal intervienen en el control de la ansiedad, pues se activan ante circunstancias de peligro. El EPM ha posibilitado el reconocimiento de la interrelación entre estos sistemas de defensa y exploración, proporcionando pruebas sobre la neurobiología de la ansiedad, y de acuerdo con Bailey, Capozzi y Lowry, el EPM es un modelo traslacional, ya que los patrones de ansiedad detectados en roedores están vinculados a trastornos en seres humanos [10].

Su diseño simple, parámetros definidos y validación farmacológica lo hacen un modelo sólido para investigar la ansiedad al medir directamente la conducta de aproximación-evitación en un ambiente controlado.

### 3.5 Sistema operativo

El sistema operativo (SO) es el software que se ejecuta en una computadora, actuando como un intermediario entre el hardware y el software. El SO decide qué proceso recibirá acceso a la CPU y por cuánto tiempo, gestiona la memoria RAM asignando espacio a cada aplicación y protegiendo ese espacio. También administra el disco duro para que se puedan guardar y recuperar archivos.

#### 3.5.1 Windows 10/11

Windows es un sistema operativo creado por Microsoft. Este software se compone de un grupo de programas que permiten gestionar y controlar el funcionamiento de varias partes de un ordenador, como la memoria, el disco duro y los dispositivos periféricos [83].

### 3.6 Lenguaje de programación

Un lenguaje de programación es un conjunto de reglas, símbolos y palabras clave que permiten la creación de instrucciones. Estas instrucciones se combinan para formar un programa que una computadora puede ejecutar y así llevar a cabo tareas específicas. La principal función de un lenguaje de programación es facilitar a los desarrolladores la escritura de algoritmos de manera lógica y estructurada.

#### 3.6.1 Python

Python se erige como un lenguaje de programación robusto y de fácil asimilación. Su diseño incorpora estructuras de datos de alto nivel notablemente eficientes, complementadas por una metodología de programación orientada a objetos. La funcionalidad del intérprete de Python es extensible mediante la incorporación de nuevas funciones y tipos de datos implementados en lenguajes de bajo nivel como C o C++. Esto, a su vez, posiciona a Python como un lenguaje de extensión óptimo para la personalización de aplicaciones preexistentes [84].

## Capítulo 4. Análisis

### 4.1 Requerimientos

#### 4.1.1 Requerimientos Funcionales (RF)

| ID    | Requerimiento funcional                | Descripción   |
|-------|--|---|
| RF-01 | <b>Adquisición de datos</b>            | El prototipo debe permitir cargar videos experimentales en formato MP4, almacenándolos en una base de datos con su respectivo metadato (fecha, tratamiento, espécimen, prueba). |
| RF-02 | <b>Preprocesamiento de video</b>       | El prototipo debe extraer y limpiar frames utilizando OpenCV y FFmpeg para generar secuencias listas para análisis.   |
| RF-03 | <b>Detección y seguimiento</b>         | El prototipo debe detectar automáticamente la posición del espécimen mediante YOLO y estimación de postura (MediaPipe).   |
| RF-04 | <b>Clasificación conductual</b>        | El prototipo debe reconocer patrones de comportamiento utilizando modelos CNN-LSTM entrenados con anotaciones expertas.   |
| RF-05 | <b>Visualización de resultados</b>     | El prototipo debe mostrar trayectorias, mapas de calor y métricas de desempeño en un dashboard interactivo.   |
| RF-06 | <b>Gestión de usuarios</b>             | El prototipo debe incluir autenticación y roles (administrador, investigador) con acceso controlado a los datos.  |
| RF-07 | <b>Exportación de reportes</b>         | El prototipo debe generar reportes PDF con métricas, gráficas y análisis comparativos de tratamientos.  |
| RF-08 | <b>Generación de archivos de Excel</b> | El prototipo debe generar archivos XLSX que contengan tablas estructuradas con métricas conductuales.   |

Tabla 3: "Requerimientos Funcionales (RF)"

#### 4.1.2 Requerimientos No Funcionales (RNF)

| ID     | Categoría                              | Requerimiento No Funcional   | Descripción Detallada   |
|--------|--|--|---|
| RNF-01 | Rendimiento y eficiencia               | Tiempo máximo de procesamiento por video menor a 5 horas en GPU Colab. | El prototipo deberá ejecutar las fases de extracción, detección y clasificación en menos de 5 horas por video, optimizando el uso de GPU y memoria. Los procesos deberán paralelizarse cuando sea posible para evitar cuellos de botella. |
| RNF-02 | Usabilidad y experiencia de usuario    | Interfaz web intuitiva, accesible y coherente.                         | La interfaz deberá ser clara, visual y fácil de operar incluso para usuarios sin experiencia en programación. Se emplearán dashboards interactivos con colores contrastantes, menús descriptivos y mensajes de error interpretables.      |
| RNF-03 | Fiabilidad y disponibilidad            | Continuidad del servicio y manejo de fallos.                           | El prototipo deberá garantizar la integridad de los datos y permitir la reanudación automática de procesos interrumpidos. Cualquier error crítico deberá registrarse en logs y notificarse al usuario sin pérdida de información.         |
| RNF-04 | Escalabilidad y capacidad de expansión | Capacidad para escalar horizontal o verticalmente.                     | La arquitectura deberá permitir añadir más recursos (CPU/GPU) o instancias en la nube sin necesidad de modificar el código fuente, posibilitando el procesamiento de mayores volúmenes de video y datos en futuras iteraciones.           |
| RNF-05 | Seguridad y confidencialidad           | Protección de credenciales y datos experimentales.                     | Todas las comunicaciones deberán realizarse bajo protocolo HTTPS, con autenticación por token y cifrado SHA-256 para contraseñas.   |
| RNF-06 | Mantenibilidad y modularidad           | Código modular, documentado y versionado.                              | El código fuente debe organizarse en módulos independientes (procesamiento, modelado, visualización), con documentación en cada función y control de versiones mediante Git y GitHub Issues para facilitar actualizaciones futuras.       |
| RNF-07 | Portabilidad y compatibilidad          | Ejecución multiplataforma.   | El prototipo deberá ejecutarse correctamente en sistemas operativos como Windows 10 o superior, utilizando dependencias fácilmente instalables mediante entornos virtuales (Conda o pip).   |
| RNF-08 | Trazabilidad y control de versiones    | Registro y seguimiento de todos los cambios.                           | Cada modificación en el código, dataset o modelo entrenado deberá asociarse a una versión del repositorio en GitHub. Los commits deberán incluir descripciones claras y referencias a los requerimientos que satisfacen.                  |

Tabla 4: "Requerimientos No Funcionales (RNF)

#### 4.1.3 Reglas del negocio

Las reglas del negocio constituyen los **principios rectores** que orientan la planificación, ejecución y validación de cada iteración dentro de la **metodología espiral de Boehm**. Estas reglas establecen los límites, prioridades y criterios de éxito del proyecto, asegurando que el desarrollo mantenga su enfoque académico, ético y técnico en todo momento. Cada iteración de la espiral tiene que ser planificada, llevada a cabo y evaluada según las pautas que se describen a continuación.

Las reglas del negocio permiten:

- **Estandarizar las decisiones y acciones**, evitando ambigüedad en los procesos.

- **Garantizar cumplimiento** con políticas académicas, técnicas y éticas.
- **Reducir riesgos y errores**, al establecer con claridad las condiciones y los límites del flujo de trabajo.
- **Alinear la planificación y validación** del prototipo conforme a los criterios de éxito definidos.

Estas reglas tienen que redactarse en un lenguaje que sea claro, comprobable y medible. En este proyecto, las normas de la empresa garantizarán que:

- Cada iteración cumpla con los estándares éticos y metodológicos del IPN.
- Los resultados de IA y minería de datos deben ser trazables y validados.
- Las decisiones acerca de los ajustes o mejoras de modelo se toman utilizando en métricas objetivas.

Cada iteración de la espiral debe planificarse, ejecutarse y evaluarse conforme a estas reglas, garantizando un desarrollo controlado, reproducible y alineado con los objetivos científicos y académicos del Trabajo Terminal.

A continuación, se detallan las reglas de negocio que rigen la operación, validación y mantenimiento del prototipo de análisis automatizado de comportamiento en modelos de ansiedad.

Cada regla está formulada de manera verificable, clara y orientada a buenas prácticas de ingeniería de software:

| RN#  | Descripción  | Caso de cumplimiento  | Caso de no cumplimiento   |
|------|--|---|---|
| RN1  | Todo usuario debe autenticarse mediante credenciales válidas, con contraseña. Solo personal autorizado puede acceder a datos experimentales.             | El usuario ingresa con credenciales correctas y el prototipo muestra únicamente las funciones permitidas. | Se impide el acceso y se muestra mensaje: "Credenciales inválidas o usuario no autorizado". |
| RN2  | Todo archivo cargado (videos, datos) debe cumplir validaciones automáticas de integridad: formato, tamaño, duración y consistencia con tratamiento.      | El archivo pasa todas las validaciones y se registra correctamente.                                       | La carga es rechazada con el mensaje: "El archivo no cumple las validaciones".              |
| RN3  | Los videos deberán tener resolución mínima de <b>720p</b> para garantizar confiabilidad en detección de posturas.  | El video es $\geq 720p$ y el prototipo permite el análisis.   | El prototipo bloquea el análisis y muestra: "Resolución insuficiente (mínimo 720p)".        |
| RN4  | El modelo CNN-LSTM clasificará comportamiento en: activo, inmóvil, exploratorio, ansioso. Se guarda probabilidad, fecha e ID del video.                  | Si la probabilidad $\geq 0.6$ , se registra la clasificación correspondiente.                             | Si la probabilidad $< 0.6$ , el segmento se marca como "indeterminado".                     |
| RN5  | Cada resultado debe tener trazabilidad: video fuente, modelo, usuario, fecha y parámetros.   | El prototipo genera automáticamente el registro completo de trazabilidad.                                 | No se permite guardar el resultado y se muestra: "Información de trazabilidad incompleta".  |
| RN6  | Toda modificación del modelo o reglas deberá registrarse bajo control de versiones (GitHub) con commits identificados.                                   | El cambio se registra en el repositorio con etiqueta de versión (vX.X).                                   | El cambio no se acepta si no se documenta con commit y descripción.                         |
| RN7  | Todo cambio en métricas, reglas o umbrales deberá documentarse, justificarse y aprobarse; el prototipo actualizará umbrales vía interfaz administrativa. | Se registra el cambio, se aprueba y se notifica al responsable técnico.                                   | No se aplican cambios y se muestra: "Modificación no autorizada".                           |
| RN8  | Cada regla deberá tener al menos un caso de prueba unitario registrado.  | La prueba se ejecuta, pasa correctamente y queda documentada.   | No se permite cerrar iteración sin caso de prueba correspondiente.                          |
| RN9  | Todas las reglas deben cumplir estándares ISO/IEC 25010 y 12207: calidad, mantenibilidad y fiabilidad.   | Auditoría de iteración $\geq 80\%$ de cumplimiento.   | La auditoría exige correcciones antes de aprobar la iteración.                              |
| RN10 | Todas las reglas deben estar en el SRS y reflejarse en los diagramas UML. Se mantendrá bitácora de decisiones.   | La documentación está actualizada, con UML y bitácora completa.   | No se aprueba avance si falta sincronización documental.                                    |
| RN11 | El prototipo debe cumplir ética y confidencialidad según NOM-062-ZOO-1999 e IPN. Ningún dato puede compartirse sin autorización.                         | Los datos se mantienen internos y accesibles solo a personal autorizado.                                  | El prototipo bloquea cualquier acceso o exportación no autorizada.                          |
| RN12 | Toda terminología (espécimen, iteración, métrica, etc.) debe estar definida en un diccionario de negocio único.  | Los documentos y el prototipo utilizan la misma terminología.   | El sistema exige definir el término antes de continuar.                                     |

Tabla 5: "Reglas de Negocio"

## 4.2 Análisis de las herramientas a utilizar

Las herramientas por utilizar en este prototipo se dividen de la siguiente manera:

- Técnicas de visión por computadora.
- Arquitectura de aprendizaje profundo (Deep Learning).
- Algoritmos de clasificación (Clustering).
- Herramientas estadísticas.
- Conceptos etológicos para análisis de ansiedad.

#### 4.2.1 Análisis de técnicas de detección de objetos

Se analizaron las siguientes técnicas de detección de objetos:

| Herramienta  | Tiempo real | Maneja múltiples objetos | Precisión | Fácil de entrenar | Ligero |
|--------------|-------------|--------------------------|-----------|-------------------|--------|
| YOLO         | ✓           | ✓                        | ✓         | ✓                 | ✓      |
| Faster R-CNN | ✗           | ✓                        | ✓         | ✗                 | ✗      |
| SSD          | ✓           | ✓                        | ✗         | ✓                 | ✓      |
| Retina Net   | ✗           | ✓                        | ✓         | ✗                 | ✗      |
| EfficientDet | ✗           | ✓                        | ✓         | ✗                 | ✓      |

Tabla 6: "Tabla de análisis de técnicas de detección de objetos [autoría propia]"

Se optó por utilizar YOLO (You Only Look Once) sobre otras herramientas debido a que su tiempo de inferencia fue menor que varias implementaciones de Faster R-CNN con solo un tiempo de 13.5 milisegundos [55]. También suele ser más preciso que Retina Net y EfficientDet por márgenes de más de 40% [56]. Por otra parte, Adhikari et al sostienen que YOLO equilibra mejores factores como la precisión, velocidad, robustez y facilidad de uso [57].

#### 4.2.2 Análisis de técnicas de estimación de pose con aprendizaje profundo

Se analizaron las siguientes técnicas de estimación de pose con aprendizaje profundo:

| Herramienta                    | Precisión | No requiere marcadores | Adaptable | Facilita extracción de características | Requiere de alto cóputo |
|--------------------------------|-----------|------------------------|-----------|--|-------------------------|
| DeepLabCut                     | ✓         | ✓                      | ✓         | ✓                                      | ✓                       |
| DeepPoseKit                    | ✓         | ✓                      | ✓         | ✓                                      | ✓                       |
| LEAP                           | ✓         | ✓                      | ✗         | ✓                                      | ✗                       |
| OpenPose (adaptado a animales) | ✗         | ✓                      | ✗         | ✓                                      | ✓                       |
| SLEAP                          | ✓         | ✓                      | ✓         | ✓                                      | ✓                       |

Tabla 7: "Tabla de análisis de técnicas de estimación de pose con aprendizaje profundo [autoría propia]"

A pesar de que DLC (DeepLabCut), DPK (DeepPoseKit) y SLEAP poseen características similares entre sí. DLC ofrece una mejor precisión a diferencia de DPK y SLEAP, dicha precisión de DLC puede ser comparada con la precisión humana. DLC es más robusto que LEAP y SLEAP para manejar occlusiones [58]. DLC puede ser entrenado para ser preciso con datasets pequeños de 100 a 200 imágenes, en comparación con otras herramientas que utilizan mayores cantidades de datos y no alcanzan una precisión como la de DLC [59].

#### 4.2.3 Análisis de técnicas de estimación de pose

Se analizaron las siguientes técnicas de estimación de pose:

| Herramienta        | Seguimiento de puntos | Adaptable | Robustez | Tiempo real | Escalable |
|--------------------|-----------------------|-----------|----------|-------------|-----------|
| Pose Estimation    | ✓                     | ✓         | ✓        | ✓           | ✓         |
| Kinect Skeleton    | ✓                     | X         | X        | ✓           | ✓         |
| Marker-based Vicon | ✓                     | X         | ✓        | ✓           | X         |
| OpenPose           | ✓                     | ✓         | X        | X           | ✓         |
| SLEAP              | ✓                     | ✓         | ✓        | ✓           | ✓         |

Tabla 8: "Tabla de análisis de técnicas de estimación de pose [autoría propia]"

Según Lauer et al, Pose Estimation basada en DLC suele ser precisa sin necesidad de un marcador además de que es adaptable a varias especies de animales [60]. Mientras tanto, Kinect Skeleton y Vicon requieren de marcadores y es limitado en entornos naturales [61].

#### 4.2.4 Análisis de herramientas de seguimiento visual

Se analizaron las siguientes herramientas de seguimiento visual:

| Herramienta  | Tiempo real | Ligero | Sensible a cambios | Robusto | Manejo de movimiento rápido |
|--------------|-------------|--------|--------------------|---------|-----------------------------|
| CamShift     | ✓           | ✓      | ✓                  | X       | X                           |
| MeanShift    | ✓           | ✓      | X                  | X       | X                           |
| Optical Flow | ✓           | ✓      | X                  | X       | ✓                           |
| KLT Tracker  | ✓           | ✓      | X                  | X       | ✓                           |
| CSRT Tracker | ✓           | X      | ✓                  | ✓       | ✓                           |

Tabla 9: "Tabla de análisis de herramientas de seguimiento visual [autoría propia]"

Se eligió CAMShift gracias a su simplicidad y eficiencia. CAMShift es basado en color y es útil en entornos controlados [62]. En cambio, MeanShift se pierde fácilmente con cambios de escala [63]. CAMShift no requiere una carga significativa de recursos computacionales a diferencia de CSRT y KLT que, no solo requieren más recursos, sino que también no funciona bien con occlusiones [64].

#### 4.2.5 Análisis de arquitecturas de redes neuronales profundas para visión por computadora

| Herramienta  | Datos espaciales | Extracción de características visuales | Eficiencia en parámetros | Manejo de secuencias | Procesamiento en paralelo | Requerimientos computacionales |
|--------------|------------------|--|--------------------------|----------------------|---------------------------|--------------------------------|
| CNN          | ✓                | ✓                                      | ✓                        | ✓                    | ✓                         | ✓                              |
| MLP          | X                | X                                      | X                        | X                    | ✓                         | ✓                              |
| RNN          | X                | X                                      | X                        | ✓                    | X                         | ✓                              |
| LSTM         | X                | X                                      | X                        | ✓                    | X                         | X                              |
| Transformers | ✓                | ✓                                      | X                        | ✓                    | ✓                         | X                              |

Tabla 10: "Tabla de análisis de arquitecturas de redes neuronales profundas para visión por computadora [autoría propia]"

Se optó por usar CNN como arquitectura para visión por computadora debido a que, a diferencia de MLP, CNN aplica filtros para detectar patrones jerárquicos, desde bordes hasta objetos. En cambio,

MLP trata a la imagen como un vector plano ignorando relaciones especiales [65]. Según Rajagukguk et al, CNN tiene una aplicación exitosa en la supervisión de animales [66].

#### 4.2.6 Análisis de arquitecturas de aprendizaje profundo para series temporales

De forma conjunta, se optó por utilizar las siguientes arquitecturas:

- RNN (Red Neuronal Recurrente).
- LSTM (Long Short-Term Memory).
- Transformers.

Según Cole, RNN incorpora cada nueva secuencia y la salida depende de las secuencias ingresadas con anterioridad, además de que maneja entradas y salidas de longitud variable [67]. Por otra parte, las LSTM retienen información por largos períodos de tiempos capturando tendencias de largo plazo [68]. Mientras tanto, los Transformers suelen examinar las secuencias de entrada simultáneamente en vez de paso a paso [69].

#### 4.2.7 Análisis de técnicas de minería de datos

Se optó por utilizar K-Means ya que reduce la complejidad de una imagen ya que se puede utilizar como herramienta de apoyo para segmentar poblaciones [70]. Por otra parte, Random Forest ayuda a clasificar el comportamiento animal a partir de datos de postura o movimiento, según Rew et al [71]. Las Máquinas de Soporte Vectorial (SVM) son una opción robusta para clasificar comportamientos de animales cuando se cuentan con datos de etiquetado para el entrenamiento, según Mosquera et al [72].

#### 4.2.8 Análisis de sistemas operativos

Se analizaron los siguientes sistemas operativos:

| Sistema operativo | Compatibilidad | Soporte para herramientas de Deep Learning | Facilidad de uso | Soporte técnico comercial |
|-------------------|----------------|--|------------------|---------------------------|
| Windows           | ✓              | ✓  | ✓                | ✓                         |
| Linux             | X              | X  | X                | X                         |
| macOS             | ✓              | X  | ✓                | ✓                         |

Se optó por usar Windows como sistema operativo del prototipo debido a su compatibilidad con herramientas de Deep Learning además de que hay soporte técnico comercial que evita incompatibilidades entre herramientas.

#### 4.2.9 Análisis de los lenguajes de programación

Se analizaron los siguientes lenguajes de programación:

| Lenguaje de programación | Facilidad de aprendizaje | Velocidad de desarrollo | Rendimiento | Soporte técnico |
|--------------------------|--------------------------|-------------------------|-------------|-----------------|
| Python                   | ✓                        | ✓                       | ✓           | ✓               |
| Java                     | X                        | X                       | X           | X               |
| C++                      | X                        | X                       | ✓           | ✓               |

Se optó por utilizar el lenguaje de programación Python debido a su velocidad de desarrollo y rendimiento en tareas de Machine Learning.

### 4.3 Análisis de riesgos

En concordancia con la metodología espiral de Boehm, se determina un proceso sistemático para detectar, evaluar y manejar los riesgos relacionados con el desarrollo del prototipo. Este procedimiento es un elemento fundamental de la planificación porque posibilita prever eventos que tienen el potencial de afectar la calidad del sistema, su continuidad operativa o la fiabilidad de los resultados experimentales. El manejo adecuado de estos riesgos tiene como objetivo preservar la estabilidad del equipo laboral, garantizar la disponibilidad e integridad de los datos y asegurar que se alcancen dentro del plazo y de manera apropiada las metas científicas e institucionales del proyecto.

Para comenzar con el análisis, se detectaron varios factores de riesgo en función de su tipo y se agrupan de acuerdo con su naturaleza, y cómo se relacionan con el ciclo de vida del proyecto:

- Económico: Eventos que afectan los costos del proyecto, como sobrecosto en infraestructura o recursos.
- Operativo: Situaciones que afectan la continuidad operativa o la ejecución diaria del proyecto.
- Temporal: Factores que pueden provocar retrasos debido a la complejidad de tareas, procesos lentos o dependencias entre componentes.
- Técnico: Riesgos relacionados con el funcionamiento del software, modelos de IA, datos, hardware o infraestructura tecnológica.
- Recursos: Limitaciones o falta de disponibilidad de hardware, software, personal o herramientas necesarias para avanzar.
- Organizacional: Fallas internas relacionadas con procesos administrativos, alineación de objetivos o estructura del equipo.
- Falta de claridad: Problemas derivados de comunicación deficiente, roles indefinidos o instrucciones ambiguas entre los integrantes del equipo.
- Externo: Factores fuera del control del equipo, como contingencias institucionales, sociales o fallas de servicios externos.
- Personal: Problemas interpersonales o de comunicación que afectan el flujo de trabajo y la comprensión de objetivos.

Para clasificar cada riesgo el equipo definió criterios y rangos porcentuales en una tabla auxiliar llamada “Tabla de Evaluación de Impacto”, en donde se establece el nivel de severidad que tendría un riesgo si este llegara a presentarse, expresado mediante valores porcentuales asociados a afectación menor, compromiso de entregables o impacto crítico para el proyecto

| Nivel        | Valor Numérico (%) | Descripción del impacto                            |
|--------------|--------------------|--|
| <b>Bajo</b>  | <30%               | Afectación menor sin alterar entregables           |
| <b>Medio</b> | 30-65%             | Compromete entregables, calidad o datos            |
| <b>Alto</b>  | 66-85%             | Impacto crítico que detiene o invalida el proyecto |

Tabla 6. Tabla de Evaluación de Impacto [autoría propia]

Tras establecer los grados de impacto, se calculó el riesgo total vinculado a cada evento usando la siguiente fórmula:

$$RE \text{ (Riesgo)} = P \text{ (Probabilidad)} \times I \text{ (Impacto)}$$

Esta expresión se refiere al modelo que la literatura acepta en gran medida para medir el nivel de riesgo. En esta, RE significa exposición total al riesgo, P es la probabilidad de ocurrencia expresada como porcentaje e I es la severidad del impacto también en porcentaje.

La fórmula se fundamenta en la definición oficial de riesgo de la norma internacional ISO 31000, que lo describe como la combinación entre la probabilidad de un evento y sus consecuencias [53]. Asimismo, coincide con la definición presentada por el National Institute of Standards and Technology (NIST) específicamente en la “NIST Special Publication 800-30”, una guía de 95 páginas para la evaluación de riesgos, en la cual el riesgo se define como el producto de la probabilidad de que un evento ocurra y el impacto que genera dentro del sistema evaluado [54]. Dada la publicación de Beazley Group [52], esta misma relación matemática se utiliza en guías aplicadas para el análisis de riesgo, las cuales son empleadas en el sector de la ciberseguridad y tecnológico, por lo que su aplicación es completamente coherente con proyectos relacionados con ingeniería y software.

Finalmente, se presenta la Tabla de Clasificación de Riesgos, que permite identificar y categorizar cada riesgo según su nivel de impacto real, facilitando la evaluación objetiva de su severidad y la priorización de las medidas de mitigación correspondientes

| Nivel           | Rango de Probabilidad (%) | Rango de Probabilidad (%)       |
|-----------------|---------------------------|---------------------------------|
| <b>Bajo</b>     | <20%                      | Afectación mínima               |
| <b>Moderado</b> | 20-50%                    | Retraso o reproceso moderado    |
| <b>Alto</b>     | 51-80%                    | Compromete entregables o datos  |
| <b>Extremo</b>  | >80%                      | Con impacto crítico al proyecto |

Tabla 7. Tabla de Clasificación de Riesgos [autoría propia]

A partir de esta metodología, se elaboró la Matriz de Riesgos del Proyecto, que muestra los riesgos generales detectados, su categoría, probabilidad de ocurrencia, gravedad del impacto, nivel alcanzado según el tipo y las acciones de mitigación pertinentes que están en línea con los principios de gestión de Boehm. Esta matriz posibilita que se concentren recursos en los lugares que más lo necesitan, que se prioricen esfuerzos y, además, que haya una vigilancia constante sobre aquellos factores críticos que podrían afectar el éxito del prototipo.

| ID  | Riesgo              | Descripción   | Categoría             | Probabilidad de ocurrencia (P%) | Severidad del impacto (I%) | Nivel (según P) | Gestión del riesgo  |
|-----|---------------------|---|-----------------------|---------------------------------|----------------------------|-----------------|---|
|     |                     |   |                       |                                 |                            |                 |   |
| R01 | Costes elevados     | Incremento en el gasto de infraestructura en la nube o licencias para almacenamiento y entrenamiento.           | Económico / Operativo | 40%                             | 50%                        | 20% (Moderado)  | Aprovechar servicios gratuitos o educativos de Google Cloud; programar sesiones de entrenamiento fuera de picos de carga. |
| R02 | Factor tiempo       | Retrasos por complejidad técnica o dependencia entre iteraciones (entrenamiento, validación, dashboard).        | Temporal / Técnico    | 80% [48]                        | 80%                        | 64% (Alto)      | Dividir entregables en sprints semanales, aplicar seguimiento ágil y establecer márgenes de contingencia.                 |
| R03 | Escasez de recursos | Limitación de hardware (GPU, RAM) o falta temporal de integrantes para pruebas o validación.                    | Recursos              | 50%                             | 80%                        | 40% (Moderado)  | Distribuir tareas, usar recursos compartidos (Colab, VM ESCOM), implementar cronograma de disponibilidad.                 |
| R04 | Cambios operativos  | Actualización o incompatibilidad de librerías (TensorFlow, MediaPipe) o errores por versiones distintas.        | Operativo / Técnico   | 15%                             | 50%                        | 7.5% (Bajo)     | Documentar dependencias, fijar versiones en requirements.txt, revisar entorno antes de cada iteración.                    |
| R05 | Falta de claridad   | Malentendidos en la comunicación del equipo o con los directores que afecten decisiones técnicas o prioridades. | Organizacional        | 15%                             | 50%                        | 7.5% (Bajo)     | Reuniones de seguimiento semanales, bitácora compartida de decisiones y acuerdos, control de documentación en GitHub.     |

|     |                                   |   |                   |          |     |                |  |
|-----|-----------------------------------|---|-------------------|----------|-----|----------------|--|
| R06 | <b>Pérdida de código</b>          | Eliminación accidental o corrupción del repositorio   | Técnico           | 5%       | 90% | 4.5% (Bajo)    | Implementar control de versiones y realizar respaldos periódicos en repositorios y almacenamiento en la nube.          |
| R07 | <b>Falla de librería</b>          | Errores o incompatibilidades en dependencias          | Técnico           | 10%      | 85% | 8.5% (Bajo)    | Reinstalar la librería afectada y verificar su compatibilidad con el entorno de desarrollo.                            |
| R08 | <b>Falla de hardware</b>          | Fallo de GPU, disco o equipo durante el desarrollo    | Técnico           | 10%      | 90% | 9% (Bajo)      | Mantener respaldos actualizados en repositorios y nube, así como documentar cualquier cambio en el entorno de trabajo. |
| R09 | <b>Sesgo en los datos</b>         | Dataset no representativo o con distribución desigual | Técnico           | 75% [49] | 80% | 60% (Alto)     | Realizar auditorías manuales o automáticas para detectar y corregir sesgos en el dataset.                              |
| R10 | <b>Baja calidad de datos</b>      | Datos incompletos, ruidosos o mal etiquetados         | Técnico           | 85% [50] | 80% | 68% (Alto)     | Implementar validaciones automáticas y procedimientos de preprocesamiento para estandarizar los datos.                 |
| R11 | <b>Sobreajuste</b>                | Modelo memoriza patrones y falla al generalizar       | Técnico           | 30%      | 80% | 24% (Moderado) | Aplicar técnicas de regularización y validación cruzada de manera iterativa.   |
| R12 | <b>Problemas de escalabilidad</b> | Falta de capacidad para procesar más datos o usuarios | Técnico           | 10%      | 80% | 8% (Bajo)      | Ajustar los requisitos del prototipo y utilizar infraestructura con mayor capacidad cuando sea necesario.              |
| R13 | <b>Falta de habilidades</b>       | Dominio insuficiente de herramientas o frameworks     | Falta de claridad | 20%      | 50% | 10% (Bajo)     | Fomentar la capacitación continua mediante cursos y documentación técnica.   |
| R14 | <b>Conflictos de rol</b>          | Funciones poco claras o tareas mal asignadas          | Falta de claridad | 30%      | 50% | 15% (Bajo)     | Definir claramente los roles y estructurar el flujo de trabajo del equipo.   |
| R15 | <b>Falta de alineación</b>        | Diferencias en prioridades u objetivos                | Organizacional    | 45%      | 50% | 22.5% (Bajo)   | Emplear herramientas de gestión colaborativa y reuniones periódicas de seguimiento.                                    |

|     |                                      |   |                           |     |     |                  |   |
|-----|--------------------------------------|---|---------------------------|-----|-----|------------------|---|
| R16 | <b>Expectativas excesivas</b>        | Estimaciones o promesas no realistas          | Organizacional            | 25% | 50% | 12.5% (Bajo)     | Establecer reportes de progreso semanales y revisar los compromisos adquiridos.   |
| R17 | <b>Factores externos</b>             | Huelgas, recortes, cierres o eventos sociales | Externo / Temporal        | 25% | 20% | 5% (Bajo)        | Esperar la resolución del conflicto y reprogramar las actividades afectadas.  |
| R18 | <b>Cambios en requerimientos</b>     | Modificaciones al alcance del prototipo       | Organizacional / Técnico  | 55% | 70% | 38.5% (Moderado) | Definir el alcance desde la primera iteración; registrar cambios mediante control de versiones y aprobación por los directores. |
| R19 | <b>Precisión insuficiente</b>        | Modelo ML no alcanza $\kappa < 0.80$          | Técnico                   | 30% | 80% | 24% (Moderado)   | Ajustar hiperparámetros, ampliar dataset validado y aplicar técnicas de regularización y validación cruzada.                    |
| R20 | <b>Sobrecosto nube</b>               | Uso excesivo de GPU, VMs o almacenamiento     | Económico / Operativo     | 40% | 50% | 20% (Moderado)   | Monitorear consumo mensual; aprovechar créditos educativos y optimizar entrenamientos en sesiones programadas.                  |
| R21 | <b>Retraso por dependencias</b>      | Desfase entre módulos que impide avanzar      | Temporal / Organizacional | 80% | 80% | 64% (Alto)       | Planificar con márgenes de contingencia; dividir iteraciones en tareas cortas con seguimiento semanal.                          |
| R22 | <b>Falta temporal de recursos</b>    | Escasez de hardware o personal disponible     | Operativo / Recursos      | 50% | 60% | 30% (Moderado)   | Compartir recursos mediante entornos colaborativos (Colab, servidores ESCOM) y redistribuir cargas de trabajo.                  |
| R23 | <b>Incompatibilidad de librerías</b> | Cambios imprevistos en TensorFlow/MediaPipe   | Técnico                   | 45% | 50% | 22.5% (Moderado) | Documentar versiones en requirements.txt; validar compatibilidad antes de actualizar y mantener respaldo de entorno virtual.    |
| R24 | <b>Confusión comunicativa</b>        | Malentendidos internos sobre objetivos        | Organizacional / Personal | 65% | 50% | 32.5% (Moderado) | Establecer reuniones semanales, bitácora compartida y control de tareas mediante GitHub Projects o Asana.                       |

Tabla 8. Matriz de Riesgos [autoría propia]

#### 4.3.6 Identificación de requerimientos técnicos

Se han definido los recursos esenciales necesarios para el funcionamiento óptimo del prototipo, tanto en hardware como en software, considerando la naturaleza del procesamiento de datos audiovisuales y el entrenamiento de modelos de aprendizaje profundo.

- Hardware:**

- Cámaras de alta resolución y alta tasa de fotogramas por segundo (fps).
- (*Opcional*) Equipos o sensores específicos según los requerimientos del experimento, en caso de necesitar mediciones complementarias fuera del análisis visual.
- Servidores o GPUs potentes para el entrenamiento del modelo de IA (por ejemplo, NVIDIA RTX 3090 o equivalentes)

- Software:**

- Librerías de visión por computadora como **OpenCV** y **DeepLabCut**.

- Frameworks de aprendizaje automático como **TensorFlow** y **PyTorch**.
- Entornos y lenguajes de análisis de datos como **Python**, **R** y **MATLAB**.

#### 4.3.7 Requerimientos del prototipo

Los requerimientos del prototipo no se definen de manera rígida al inicio, sino que se **refinan progresivamente en cada iteración**, conforme se obtienen nuevos resultados de validación y retroalimentación de los usuarios expertos de la **Escuela Nacional de Medicina y Homeopatía (ENMyH)**.

El prototipo propuesto —un prototipo para el análisis automatizado de comportamiento en modelos de ansiedad— integra procesos de **visión por computadora**, **aprendizaje profundo**, **minería de datos** y **visualización interactiva**, por lo que sus requerimientos se dividen en **funcionales (RF)** y **no funcionales (RNF)**.

### 4.4 Análisis de factibilidad

#### 4.4.1 Factibilidad tecnológica

La factibilidad tecnológica consiste en evaluar si el proyecto puede desarrollarse con la infraestructura técnica, el conocimiento especializado y los recursos disponibles. Su propósito es determinar si las tecnologías actuales, los equipos y el personal capacitado son suficientes para implementar el prototipo de manera eficiente y sostenible.

En el marco del modelo espiral de Boehm, este análisis se realiza de manera **iterativa**, verificando en cada ciclo la capacidad técnica del prototipo para cumplir con los objetivos planteados y ajustando los recursos conforme a las necesidades de desarrollo, entrenamiento y validación del prototipo.

El proceso de evaluación tecnológica del presente proyecto considera los siguientes aspectos:

##### 4.4.1.1 Evaluación de recursos actuales y brechas tecnológicas

Se analizó la infraestructura disponible y las capacidades técnicas actuales, identificando posibles **brechas tecnológicas** entre los requerimientos del proyecto y los recursos existentes. Este análisis posibilita prever requerimientos de inversión, compra de partes o formación técnica extra para asegurar la compatibilidad y el desempeño del prototipo.

##### 4.4.1.2 Simulación, modelado y pruebas

Se van a utilizar herramientas de simulación y experimentales para anticipar el comportamiento del prototipo y mejorar el desempeño de los modelos. Estas simulaciones posibilitan la validación de la eficiencia de los algoritmos y la capacidad del hardware antes de su implementación definitiva, lo que disminuye los costos y los riesgos técnicos.

##### 4.4.1.3 Evaluación de compatibilidad e integración

El prototipo tiene una arquitectura modular que simplifica la incorporación con otros entornos laborales y programas científicos. Se toman en cuenta los elementos como la adecuación a sistemas ya existentes, el cumplimiento de las regulaciones técnicas y las limitaciones físicas y temporales del ambiente donde se desplegará el prototipo.

#### 4.4.2 Factibilidad operativa

El objetivo de la factibilidad operativa del proyecto es establecer si el sistema propuesto tiene la capacidad de ser empleado adecuadamente en el ámbito académico y experimental para el que se pidió. En este caso, el proyecto no se origina como una iniciativa independiente, sino como una reacción directa a un requerimiento expuesto por el mismo solicitante: el Dr. César Augusto Sandino Reyes López, investigador del posgrado de la Escuela Nacional de Medicina y Homeopatía (ENMyH), quien propuso la necesidad de automatizar la interpretación de comportamientos en el modelo del EPM.

Para respaldar esta viabilidad, se utilizó un instrumento formal de recolección de datos dirigido al Dr. Sandino, investigador del posgrado de la Escuela Nacional de Medicina y Homeopatía (ENMyH). La aplicación se realizó a través de una entrevista estructurada que contenía ocho preguntas abiertas. El propósito de esta creación fue obtener datos reales sobre la demanda del sistema, los indicadores más relevantes, la factibilidad técnica del prototipo y las condiciones reales de operación en el laboratorio. El instrumento se utilizó en una reunión programada con el investigador en persona. El instrumento completo estará incluido en la sección de anexos.

Los datos obtenidos posibilitaron el análisis minucioso e individual de cada pregunta, funcionando como eje para perfeccionar requisitos y verificar las aptitudes operativas del sistema. Los cambios en la interfaz, la organización de los datos, las funciones automáticas de análisis y el modo en que se deben mostrar los resultados al usuario final fueron guiados por la información recabada.

El problema principal detectado en la entrevista fue que había que estandarizar la evaluación para que esta no dependiera del observador humano, y así poder interpretar las conductas de forma automatizada. El Dr. Sandino sostiene que el resultado exitoso es aquel en el que el sistema asigna las conductas de manera objetiva y consistente, disminuyendo así la variación común entre los evaluadores.

En relación con los datos necesarios, se determinó que los videos deben grabar las conductas de interés con un nivel de detalle suficiente para facilitar su identificación precisa. El sistema tiene que ser capaz de entender estos materiales sin requerir que el usuario los preprocese de manera compleja. En realidad, se destacó la relevancia de que la interfaz haga posible elegir el punto preciso en el que comienza el análisis, para no obligar al personal a manejar programas externos de edición para cortar los videos.

En el campo funcional, los períodos de tiempo en brazos abiertos y cerrados se indicaron como los indicadores primordiales para identificar efectos ansiolíticos. Estas dos categorías son el eje interpretativo del modelo, a pesar de que otras variables como la movilidad, las trayectorias o las áreas de permanencia ofrecen información importante. Asimismo, se destacó la conveniencia de observar los resultados en gráficos comunes y mapas de calor precisos que exhiban no solamente los valores globales, sino también la manera en que se distribuye el movimiento en el espacio.

Se concluyó que, en términos de precisión, el sistema tiene que obtener un nivel de concordancia entre el 90% y el 95% con respecto al análisis llevado a cabo por humanos, porque este rango es equivalente a la variación común entre tres observadores independientes en el laboratorio. Este aspecto fue crucial para determinar el umbral mínimo necesario para implementar el sistema como un instrumento de operación fiable.

El Dr. Sandino también subrayó que es fundamental que la plataforma sea accesible a los usuarios sin formación técnica, en especial a los investigadores y médicos que llevan a cabo los experimentos.

Si la interfaz es simple, con opciones claras y sin requerir conocimientos informáticos avanzados, se incrementará notablemente el uso del sistema. Se determinó que, en lo que concierne al formato de exportación de los resultados, la información tiene que ser descargable en Excel. Esto se debe a que el formato Excel posibilita la elaboración y re-graficado de los resultados en softwares especializados como R u Origin, dependiendo de las exigencias de publicación.

La sugerencia es mantener solamente los resultados procesados, no los videos originales, porque estos últimos ocupan mucho espacio de almacenamiento y registro histórico. El laboratorio tiene una variedad de opciones de computación, que van desde estaciones de trabajo hasta clústeres pequeños y sistemas con GPU. Por tanto, la elección definitiva estará determinada por las necesidades óptimas del sistema.

La viabilidad operativa general del prototipo, más allá de estos elementos particulares, se basa en contar con personal calificado, infraestructura tecnológica apropiada y una colaboración eficaz entre los desarrolladores y los investigadores participantes. La aplicación del modelo espiral de Boehm posibilitó incorporar en cada iteración una retroalimentación directa, modificando los requisitos a medida que el desarrollo progresaba.

El prototipo ofrecerá ventajas operativas concretas: disminución de errores humanos, reducción del tiempo de análisis de varias horas a minutos (dentro de un margen cercano al 85%), incremento en la reproducibilidad científica y ahorro financiero indirecto. La habilidad del prototipo para expandirse a otros modelos o especies, además de evitar licencias comerciales caras como EthoVision XT o ANY-maze, hace que su aceptación operativa sea aún mayor.

#### 4.4.3 Factibilidad económica

En concordancia con el modelo **espiral de Boehm**, la **factibilidad económica** del proyecto no se concibe como un cálculo estático, sino como un **proceso iterativo** que evoluciona a lo largo de los ciclos de desarrollo. En cada iteración de la espiral se evalúan los costos asociados a recursos computacionales, humanos y tecnológicos, con el fin de identificar riesgos financieros y optimizar el uso de los recursos disponibles.

Los costos se dividen en dos categorías principales: **costos fijos** y **costos variables**, proyectados para un periodo de un año académico (48 semanas).

##### 4.4.3.1 Costos fijos

Incluyen los recursos que permanecen constantes durante todo el ciclo de desarrollo:

- **Equipos de cómputo:** laptops o estaciones con GPU NVIDIA (mínimo RTX 3060) para el entrenamiento de modelos (~\$35,000 MXN por equipo).
- **Software y licencias:** herramientas de desarrollo (Google Colab Pro, o entornos de nube con GPU dedicadas) — costo anual estimado \$5,000 MXN.
- **Gastos administrativos y de infraestructura:** conexión a internet, electricidad y mantenimiento de red — \$3,500 MXN.
- **Costos de documentación e impresión:** generación de informes, anexos y documentación técnica — \$1,500 MXN.

**Total, costos fijos aproximados: \$45,000 MXN.**

#### 4.4.3.2 Costos variables

Estos costos dependen del avance de cada iteración del modelo espiral:

- **Servicios en la nube:** ejecución de experimentos y almacenamiento de datasets en Google Cloud o Kaggle (~\$1,000 MXN por iteración; total \$5,000 MXN).
- **Material experimental:** mantenimiento y manejo de especímenes de laboratorio proporcionados por ENMyH — estimado \$2,000 MXN.
- **Material audiovisual:** cámaras y soporte para grabaciones, cables HDMI y almacenamiento externo — \$3,000 MXN.
- **Capacitación técnica:** cursos o talleres de IA/visión por computadora (~\$2,000 MXN).

**Total, costos variables estimados: \$12,000 MXN.**

**Costo total proyectado del proyecto: ≈ \$57,000 MXN.**

#### 4.4.3.3 Costos totales estimados del desarrollo del proyecto

| Categoría        | Concepto   | Costo estimado<br>(MXN) | Descripción  |
|------------------|--|-------------------------|--|
| Costos fijos     | Equipos de cómputo con GPU (RTX 3060 o superior)                     | \$35,000                | Estación de trabajo para entrenamiento de modelos CNN-LSTM y YOLO. |
|                  | Licencias y entornos de desarrollo (Colab Pro, VS Code, GitHub, GCP) | \$5,000                 | Accesos premium y servicios de nube.                               |
|                  | Gastos administrativos (electricidad, internet, mantenimiento)       | \$3,500                 | Operación durante el periodo de desarrollo.                        |
|                  | Documentación, reportes e impresión                                  | \$1,500                 | Material de apoyo y entregables físicos.                           |
| Costos variables | Servicios en la nube y almacenamiento de datasets                    | \$5,000                 | Ejecución y respaldo de modelos durante las iteraciones.           |
|                  | Material experimental y mantenimiento de especímenes                 | \$2,000                 | Uso en colaboración con la ENMyH.                                  |
|                  | Cámaras y materiales audiovisuales                                   | \$3,000                 | Grabación y vectorización de video.                                |
|                  | Capacitación técnica especializada                                   | \$2,000                 | Cursos o talleres de IA y visión por computadora.                  |
| Total            | —  | \$57,000                | Inversión total proyectada para 48 semanas.                        |

Tabla : Costos totales estimados del desarrollo del proyecto

#### 4.4.3.4 Conclusión de viabilidad económica

El proyecto es **económicamente viable**, ya que los beneficios derivados del ahorro de tiempo, la precisión en los resultados y la optimización de los recursos superan ampliamente los costos de implementación.

El uso de **metodologías iterativas basadas en el modelo espiral** permite ajustar los recursos económicos conforme avanza el desarrollo y **minimizando riesgos financieros**.

#### 4.4.4 Factibilidad legal

##### PONER UNA TABLA DE FACTIBILIDAD LEGAL

El proyecto “**Prototipo para análisis automatizado y visualización de comportamiento de especímenes en modelos de ansiedad**” se desarrolla en un entorno académico e institucional bajo los lineamientos del **Instituto Politécnico Nacional (IPN)**, en colaboración con la **Escuela Nacional de Medicina y Homeopatía (ENMyH)** y la **Escuela Superior de Cómputo (ESCOM)**, garantizando que todas las actividades estén sujetas a las políticas éticas y normativas vigentes del Instituto.

##### 4.4.4.1 Identificación del marco legal aplicable

###### 1. Protección de datos personales

El prototipo no procesa información personal de individuos, sino datos derivados de observaciones experimentales con especímenes animales.

No obstante, se cumplen los principios establecidos en la Ley Federal de Protección de Datos Personales en Posesión de los Particulares (LFPDPPP), asegurando la confidencialidad de cualquier información técnica o académica generada por los investigadores y colaboradores.

## **2. Normativa sobre el uso de animales de laboratorio**

El manejo experimental de los especímenes se apega a la Norma Oficial Mexicana NOM-062-ZOO-1999, que regula la producción, cuidado y uso de animales de laboratorio.

Esta norma establece especificaciones éticas y sanitarias que deben seguirse en todos los procedimientos experimentales, las cuales son observadas por la ENMyH-IPN.

## **3. Propiedad intelectual y licencias de software**

Todo el desarrollo del código, documentación y modelos de IA es de autoría del equipo desarrollador y se encuentra protegido por la Ley Federal del Derecho de Autor (LFDA).

El proyecto utiliza herramientas y librerías de código abierto bajo licencias compatibles (MIT, Apache 2.0 y GPL v3), lo cual no infringe derechos de terceros y permite la libre distribución y modificación del software con fines académicos.

## **4. Cumplimiento institucional y uso educativo**

El prototipo se enmarca en las políticas de investigación del IPN y cumple con los Lineamientos de Propiedad Intelectual y Transferencia de Conocimiento (2023) del Instituto.

Además, su uso está destinado exclusivamente a fines científicos, educativos y de investigación, sin propósito comercial directo.

### **4.5 Análisis de sostenibilidad**

El análisis de sostenibilidad es un componente clave en el desarrollo de sistemas tecnológicos porque posibilita la detección y la mitigación de los efectos sociales, técnicos y ambientales que se producen durante todo el ciclo vital del software. Según las directrices establecidas en ISO 14064-1 y en las pautas muy usadas en ingeniería de software sostenible, un proyecto tiene que incluir una valoración del consumo de energía, las emisiones relacionadas, la disminución de los impactos operacionales y estrategias para disminuir el daño al medio ambiente [73], [74].

#### **4.5.1 Evaluación del consumo energético del proyecto**

Para estimar el consumo energético se emplea la relación estándar:

$$E = P \cdot t$$

donde P es la potencia promedio del equipo empleado y t el tiempo de ejecución. Patterson indica que los servidores ligeros y las estaciones de trabajo empleados para cargas intensivas de cómputo tienen un consumo típico que oscila entre 40 y 70 W [75]. En consecuencia, se establece un valor intermedio de 50 W para el ordenador personal empleado en las pruebas.

## Tiempos reales de ejecución

Los datos siguientes fueron recolectados a lo largo de la experimentación del proyecto:

Computadora A: Procesados 5 minutos de video (aproximadamente 7200 fotogramas) en un tiempo de alrededor de 35 minutos.

Computadora B: Procesamiento de 3000 fotogramas en un lapso de alrededor de 49 minutos.

Para mantener consistencia, se toma el tiempo promedio observado para la ejecución completa del video:

$$t_{local} = 42 \text{ min} = 0.7h$$

El consumo energético en la computadora local es entonces:

$$E_{local} = 50W \cdot 0.7 = 35Wh$$

## Consumo energético en Google Colab

Google Colab utiliza la infraestructura compartida de los centros de datos. Según una investigación reciente del IEEE, los nodos de computación virtualizados que se utilizan para cargas de trabajo moderadas tienen un consumo medio de entre 100 y 150 W, tomando en cuenta el segmento del servidor atribuido a un notebook virtualizado [76]. Se adopta el valor conservador de 100 W.

Si la mitad del procesamiento se delega a Colab:

$$t_{colab} = 0.7h$$

$$E_{colab} = 100W \cdot 0.7h = 70Wh$$

## Consumo total del análisis

$$E_{total} + E_{local} + E_{colab} = 35Wh + 7'0Wh = 105Wh$$

### 4.5.2 Evaluación de huella de carbono (ISO 14064-1)

La huella de carbono se calcula conforme el modelo definido en ISO 14064-1, donde:

$$CO_2 = E \cdot FE$$

La International Energy Agency reportó y los estudios energéticos del IEEE citan que el factor de emisión eléctrica para México en 2025 será de 0.434 kg CO<sub>2</sub>/kWh [77].

$$105Wh = 0.105kWh$$

$$CO_2 = 0.105 \cdot 0.434 = 0.04557kgCO_2$$

Esto equivale a aproximadamente a 45 gramos de CO<sub>2</sub> por procesamiento completo de un video de 5 minutos.

Esta emisión es considerablemente más baja en comparación con la que está asociada al transporte físico de personal al laboratorio para hacer análisis manuales, el cual se desarrollará más adelante.

#### 4.5.3 Impacto ambiental del proceso tradicional vs. el prototipo

El método tradicional de análisis requiere la presencia de:

- Al menos 1 laboratorista o investigador
- Al menos 3 asistentes encargados de la observación manual,
- En ocasiones un supervisor o validador adicional

Cada miembro debe desplazarse a las instalaciones educativas o de investigación, lo que produce un efecto ambiental vinculado con la movilidad urbana. Según cálculos que se han consolidado en inventarios urbanos y que se encuentran en investigaciones de transporte del IEEE [78], el índice de emisión promedio para coches en la Ciudad de México es 0.192 kg CO<sub>2</sub>/km.

En el entorno particular de la Ciudad de México la distribución modal registrada en la Ciudad de México, aproximadamente el 50% de los desplazamientos urbanos son realizados en transporte público [85] mientras que el resto utilizan transporte privado. Por lo tanto, se estima que al menos la mitad de los miembros emplea transporte público para ir al laboratorio, mientras que el resto hace uso del transporte privado.

Para calcular el impacto ecológico del transporte público, se usa también un valor técnico de uso frecuente en evaluaciones urbanas, especialmente en investigaciones sobre la electrificación de flotas y la eficacia energética. Este establece que el consumo por vehículo-kilómetro para los autobuses estándar es de cerca de 0.6 kg CO<sub>2</sub>, tomando como referencia el promedio de emisión del sistema eléctrico mexicano [86]. Se debe dividir este valor entre la ocupación del vehículo para convertirlo a emisiones por pasajero-kilómetro, y se presentan diferentes escenarios lógicos que posibilitan calcular el rango posible de acuerdo con las condiciones auténticas del transporte urbano en hora pico o en operación normal.

Cálculo de emisiones del método tradicional (2 personas)

Distancia promedio diaria (ida + vuelta): 16 km  
Factor de emisión: 0.192 kg CO<sub>2</sub>/km

$$CO_{privper} = 16\text{ km} \cdot 0.192 \frac{\text{kg}}{\text{km}} = 3.072\text{ kg CO}_2$$

Para 2 personas:

$$CO_{privtotal} = 2 \cdot 3.072 = 6.144\text{ kg CO}_2$$

Emisiones del transporte público (2 personas)

Se convierte el valor de 0.6 kg CO<sub>2</sub>/veh-km a emisiones por pasajero-kilómetro considerando diferentes niveles de ocupación:

**Escenario A: Ocupación alta (135 pasajeros, BRT/Metrobús en hora pico)**

Valores documentados de ocupación pico en corredores tipo BRT.

$$EFpas = 0.6/35 = 0.00444\text{ kg CO}_2 / \text{pas} \cdot \text{cdotpkm}$$

$$CO_{pubper} = 0.16km \cdot 0.00444 = 0.0711kgCO_2$$

Para 2 personas:

$$CO_{pubA} = 0.1422kgCO2$$

### **Escenario B: Ocupación media (40 pasajeros)**

Valor representativo típico de ocupación urbana consolidado en estudios comparativos.

$$EF_{pas} = \frac{0.6}{40} = 0.015$$

Para 2 personas:

$$CO_{pubB} = 0.048kgCO_2$$

### **Escenario C: Ocupación baja (20 pasajeros)**

Escenario conservador de baja demanda.

$$EF_{pas} = 0.6/20 = 0.03 \text{ kg CO}_2 / \text{pas} \cdot \text{cdotpkm}$$

$$CO_{pubper} = 16km \cdot 0.03 = 0.48kgCO_2$$

Para 2 personas:

Escenario A:

$$CO_{totalA} = 6.144 + 0.1422 = 6.2862kgCO_2$$

Escenario B:

$$CO_{totalB} = 6.144 + 0.48 = 6.624kgCO_2$$

Escenario C:

$$CO_{totalC} = 6.144 + 0.96 = 7.104kgCO_2$$

#### **3.5.4 Comparación con el prototipo**

Como se estableció previamente, el prototipo genera.

$$CO_{prototipo} = 0.04557kgCO_2 \text{ por análisis completo}$$

Comparación porcentual:

Escenario A  $\approx 99.33\%$

Escenario B:  $\approx 99.31\%$

Escenario C:  $\approx 99.35\%$

Aun al tomar en cuenta escenarios conservadores para el transporte público y aplicar la realidad de que más de la mitad del equipo emplea este modo de transporte, el efecto medioambiental del método

tradicional continúa siendo de 6.2 a 7.1 kg CO<sub>2</sub> por jornada; en cambio, el prototipo solamente genera 0.0379 kg CO<sub>2</sub> por procesamiento completo.

La disminución resultante varía entre el 99.33% y el 99.35%, lo que indica que el prototipo erradica casi por completo la huella vinculada al traslado del personal, convirtiéndose así en una opción significativamente más responsable con el medio ambiente, eficiente y sostenible.

## Capítulo 5. Diseño

### 5.1 Arquitectura del prototipo

La arquitectura del prototipo refleja los procesos más importantes del desarrollo este prototipo, el cual realizará mediante minería de datos, IA y machine learning para la evaluación de tratamientos farmacológicos en modelos de ansiedad. Además, contará con un sistema de inicio de sesión, vectorización de video y validación del comportamiento de los especímenes en pruebas específicas. En la ilustración 38, se puede observar la arquitectura del prototipo de forma general para entender visualmente el funcionamiento de esta. La arquitectura describe los diferentes módulos dentro del prototipo por el cual pasa un archivo audiovisual (vídeo) siendo preprocesado antes de que se obtengan datos que son útiles para los módulos de modelado de conductas y análisis estadístico. El módulo de visualización presenta los datos al usuario y estos son guardados posteriormente para una comparación usando tesis o ANOVA en este.

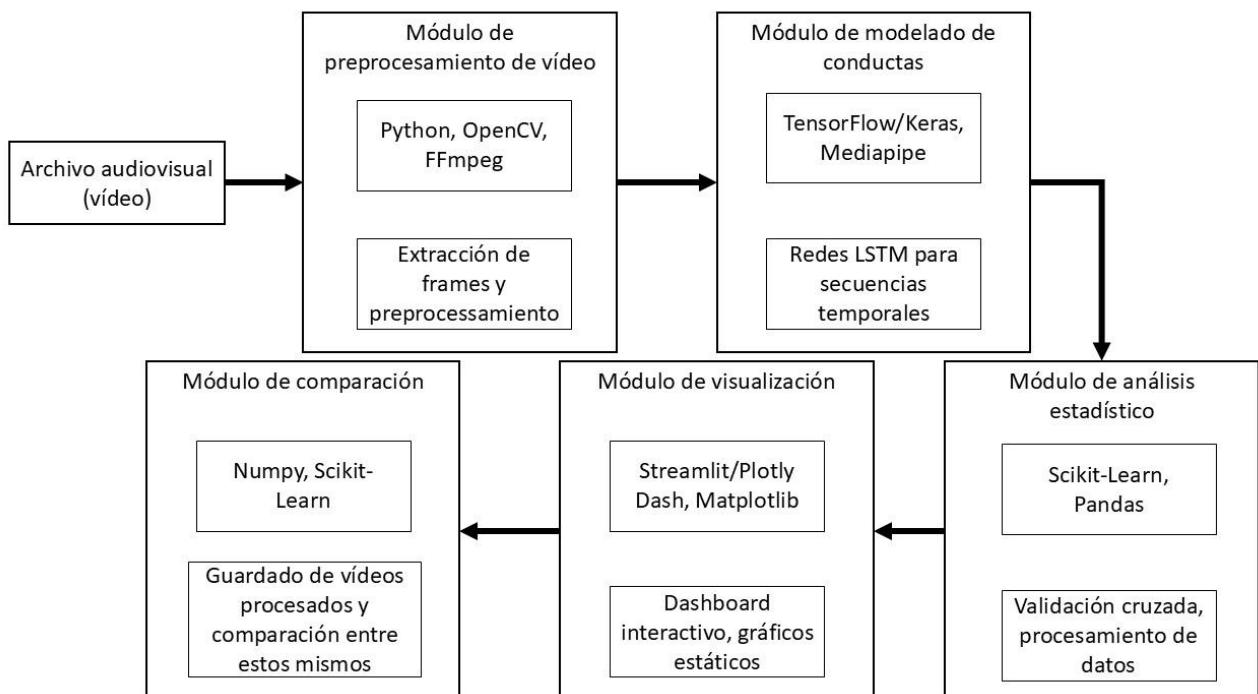


Ilustración 3938: Arquitectura general del prototipo [autoría propia]

### 5.2 Modelo de bases de datos

El diagrama entidad-relación representa un sistema donde los administradores gestionan usuarios y supervisan sus actividades relacionadas con análisis y comparaciones. En la figura [ilustración 40], la entidad Administrador contiene los atributos AdministratorID, Nombre, CorreoInstitucional y Contraseña, y tiene la función de manejar usuarios, enviar notificaciones y realizar acciones sobre análisis y comparaciones. La entidad Usuario, con atributos UserID, Nombre, CorreoInstitucional y Contraseña, puede realizar análisis y recibir notificaciones. La relación Maneja une a administradores y usuarios, registrando mediante los atributos IDManeja, AccionManeja y FechaManeja las acciones

que un administrador realiza sobre un usuario. La entidad Notificación, con atributos IDNotificacion, ContenidoNotificacion y FechaNotificacion, permite la comunicación entre administradores y usuarios a través de las relaciones Envía y Recibe. Los Análisis, definidos por AnalisisID, ContenidoAnalisis, FechaAnalisis, Video y TipoExperimento, pueden ser realizados por usuarios mediante la relación Posee y están vinculados a Reportes de Análisis, representados por ReporteAnalisisID, ContenidoReporteAnalisis y FechaReporteAnalisis, a través de una relación uno a uno. De forma similar, las Comparaciones, que incluyen ComparacionID, FechaComparacion y ContenidoComparacion, son efectuadas por los usuarios y generan Reportes de Comparación, con atributos ReporteComparacionID, ContenidoReporteComparacion y FechaReporteComparacion, relacionados también en una correspondencia uno a uno.

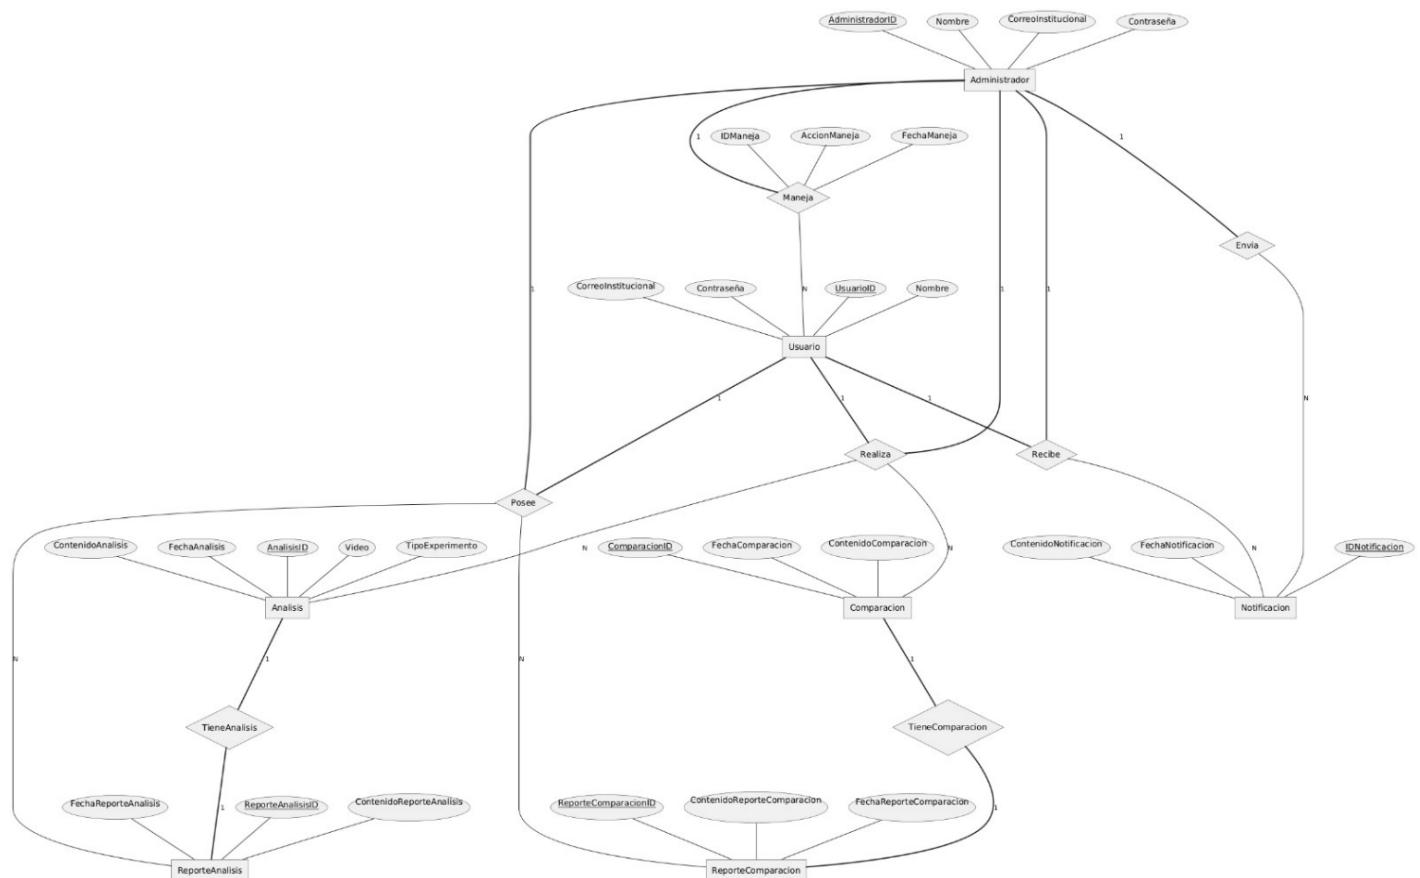


Ilustración 40: "Modelo de base de datos [autoría propia]"

## 5.3 Casos de uso

### 5.3.1 Casos de uso del prototipo

El diagrama representa el funcionamiento general del prototipo, mostrando cómo interactúan dos actores principales: usuario y administrador, con los distintos casos de uso del prototipo. El usuario puede generar análisis (CU1), proceso que requiere obligatoriamente establecer parámetros (CU7) y posteriormente confirmar el resultado del análisis (CU8), ambos incluidos como pasos internos del flujo principal. Además, el Usuario puede consultar reportes tanto de análisis (CU2) como de

comparaciones (CU3), siendo este último un caso de uso que extiende a generar comparaciones (CU6) cuando el usuario necesita producir una nueva comparación a partir de análisis previos. Por su parte, el administrador posee funcionalidades adicionales orientadas a la gestión del prototipo, incluyendo manejar usuarios (CU4) y manejar notificaciones (CU5).

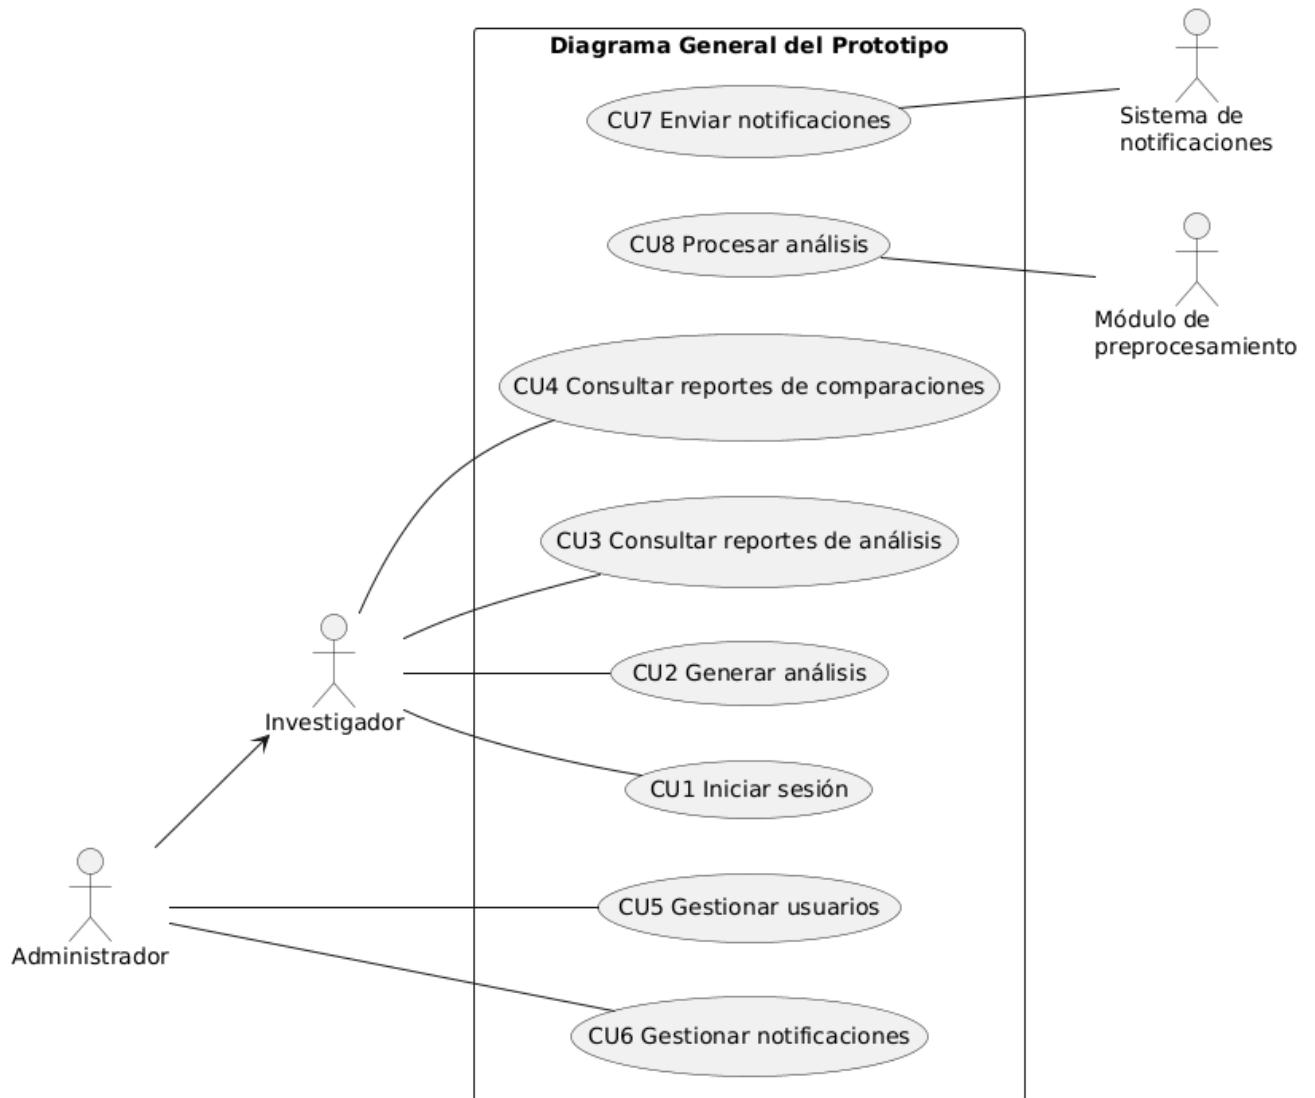


Ilustración 41: “Casos de uso del prototipo [autoría propia]”

### 5.3.2 Diagramas de secuencia

La ilustración 42 muestra el proceso de registro tanto de investigador como de administrador en la aplicación. Ambos pasan por el mismo proceso de registro con sus datos registrados y una vez todos los campos hayan sido completados y validados, se enviará un correo de confirmación al correo electrónico registrado.

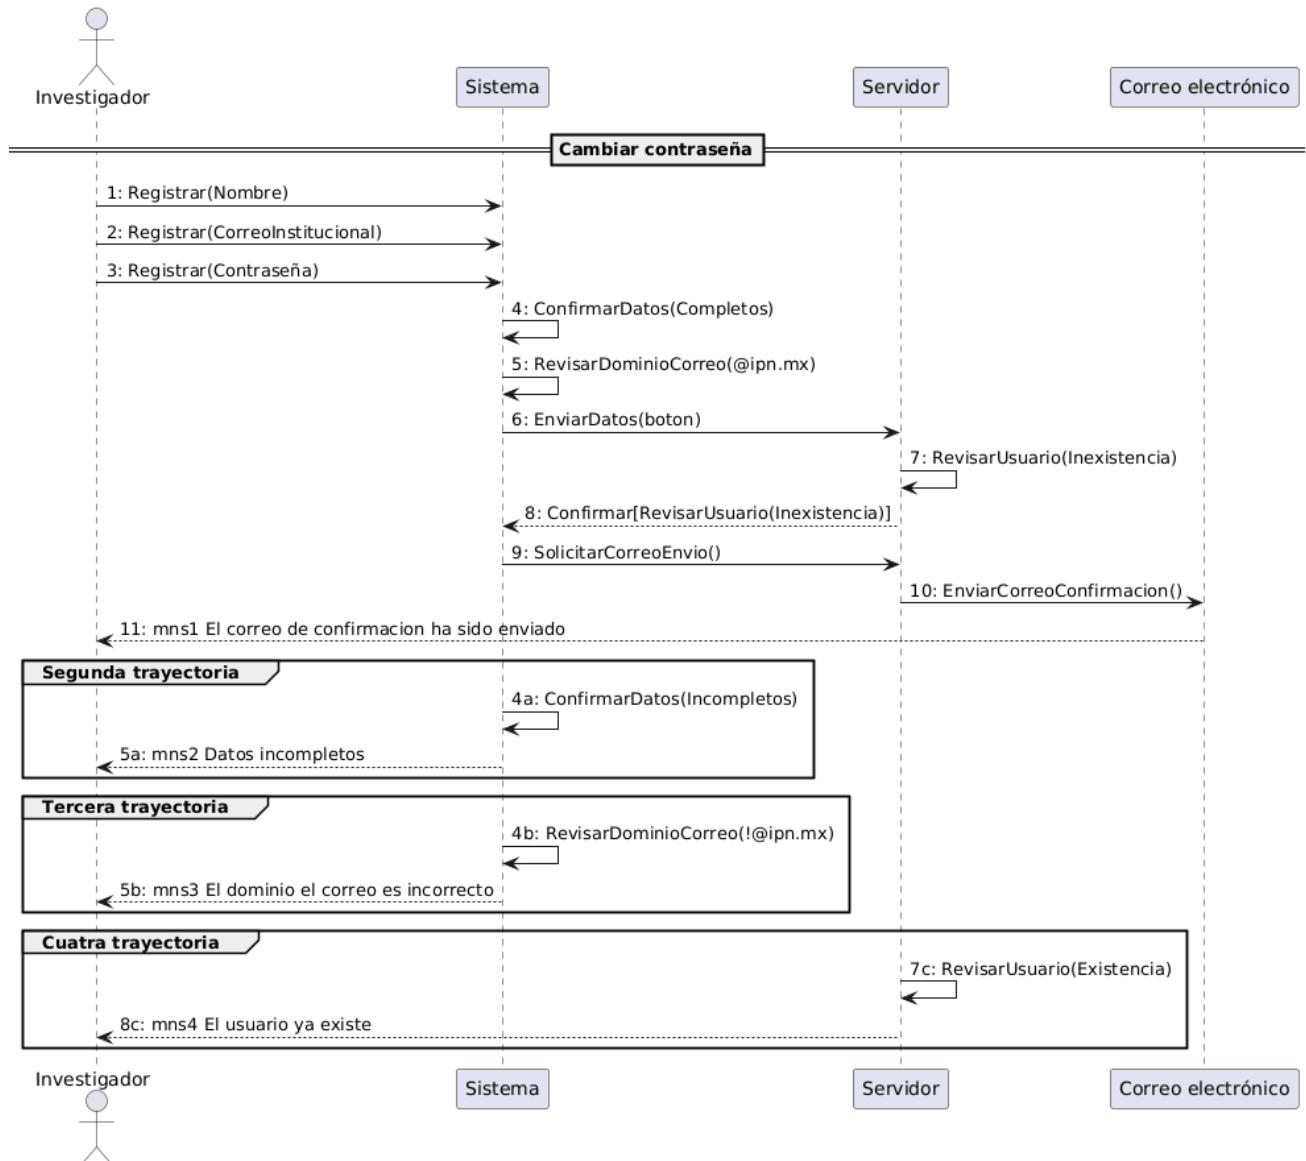


Ilustración 42: “Diagramas de secuencia [autoría propia]”

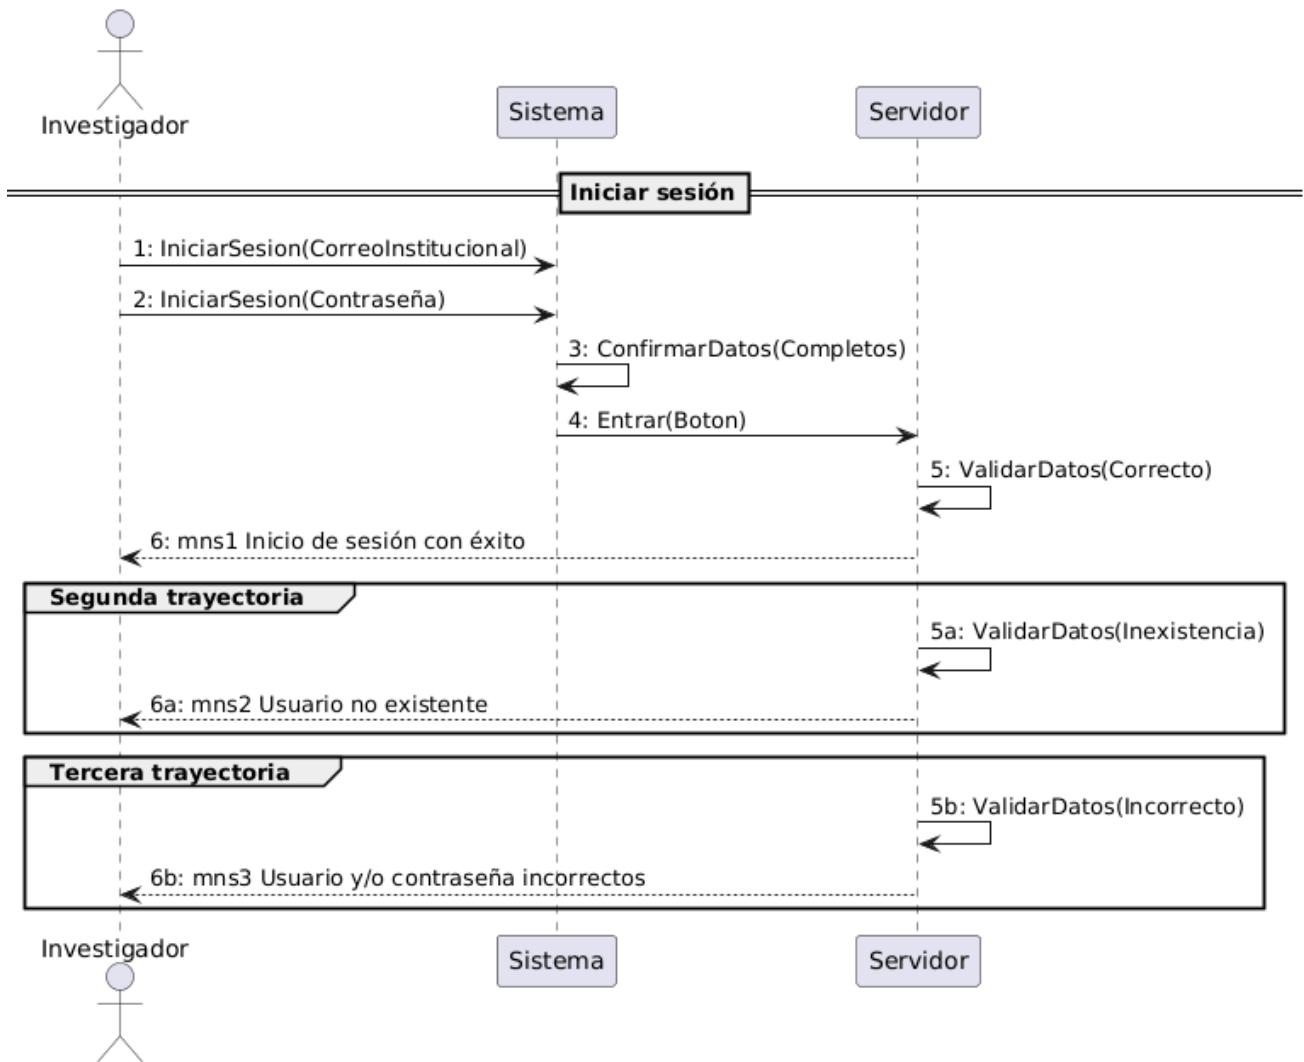


Ilustración 43: “Proceso de inicio de sesión del investigador [autoría propia]”

Las ilustraciones 43 y 44 muestran el proceso de inicio de sesión tanto para investigador y administrador. Incluso tomando en cuenta los casos de usuario no existente y datos incorrectos.

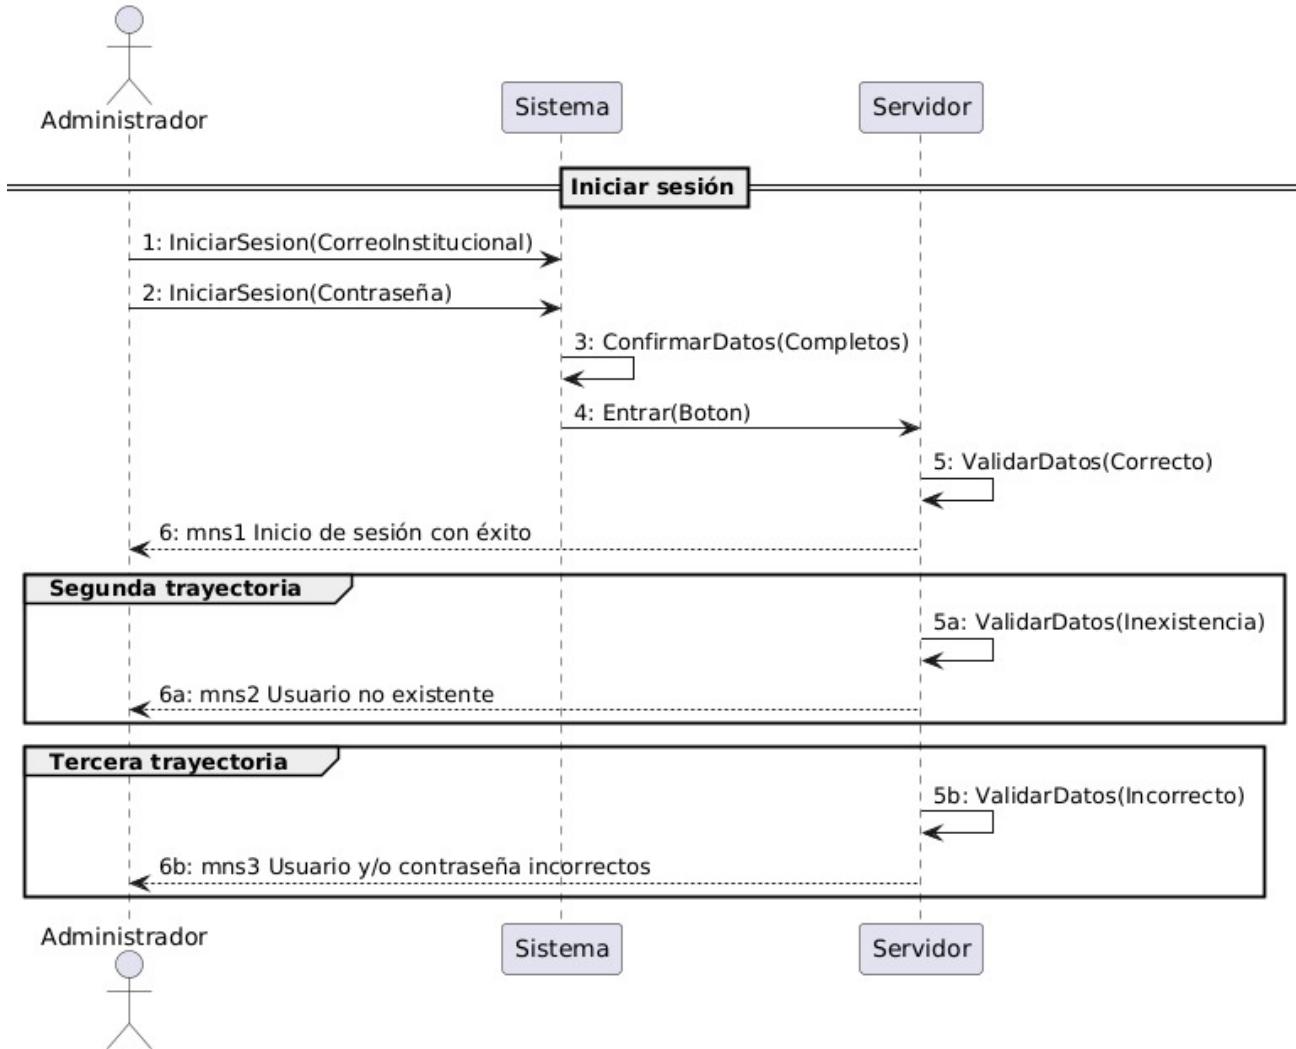


Ilustración 44: “Proceso de inicio de sesión del administrador [autoría propia]”

Las ilustraciones 45 y 46 muestran el cambio de contraseña para investigador y administrador. Se contempla el caso de usuario inexistente.

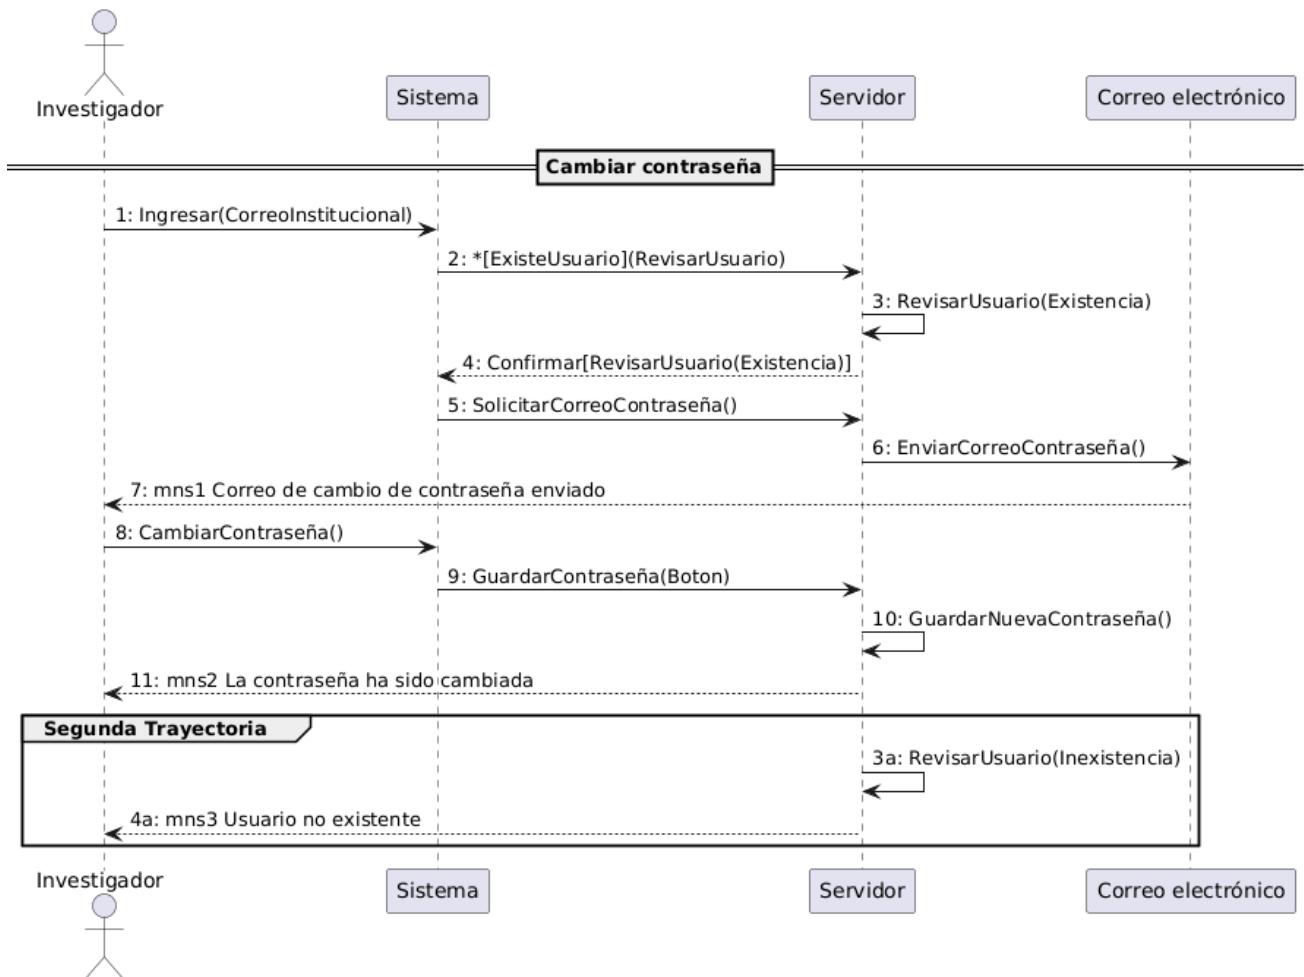


Ilustración 45: “Proceso de cambio de contraseña del investigador [autoría propia]”

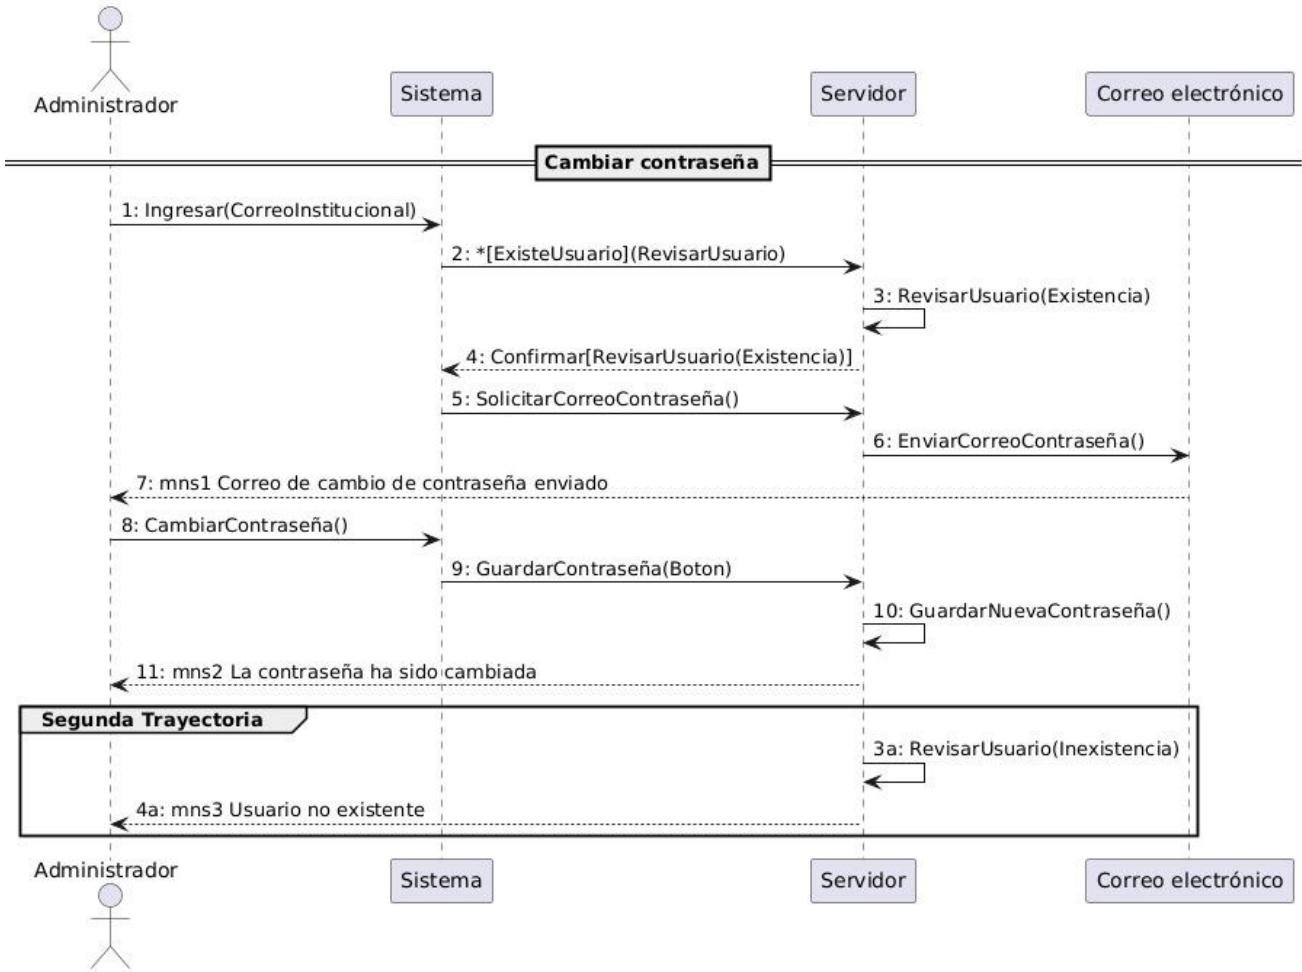


Ilustración 46: “Proceso de cambio de contraseña del administrador [autoría propia]”

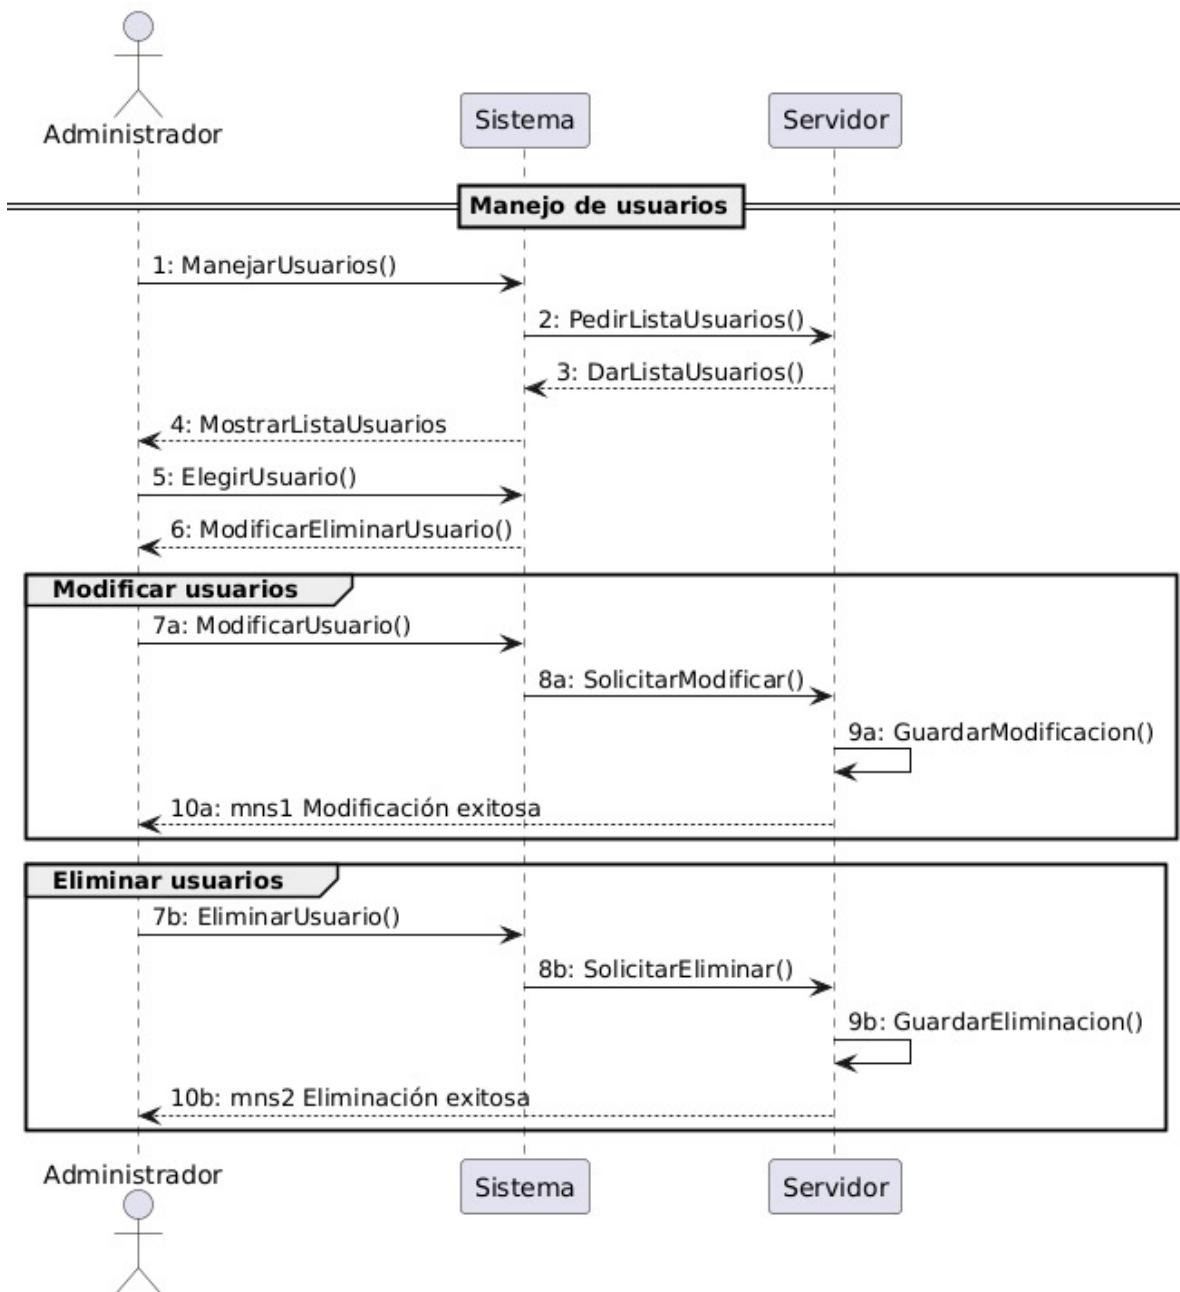


Ilustración 47: “Manejo de usuarios [autoría propia]”

Las ilustraciones 48 y 49 muestra la configuración de perfil. Solo se muestra el cambio de nombre. El cambio de contraseña es en la pantalla principal.

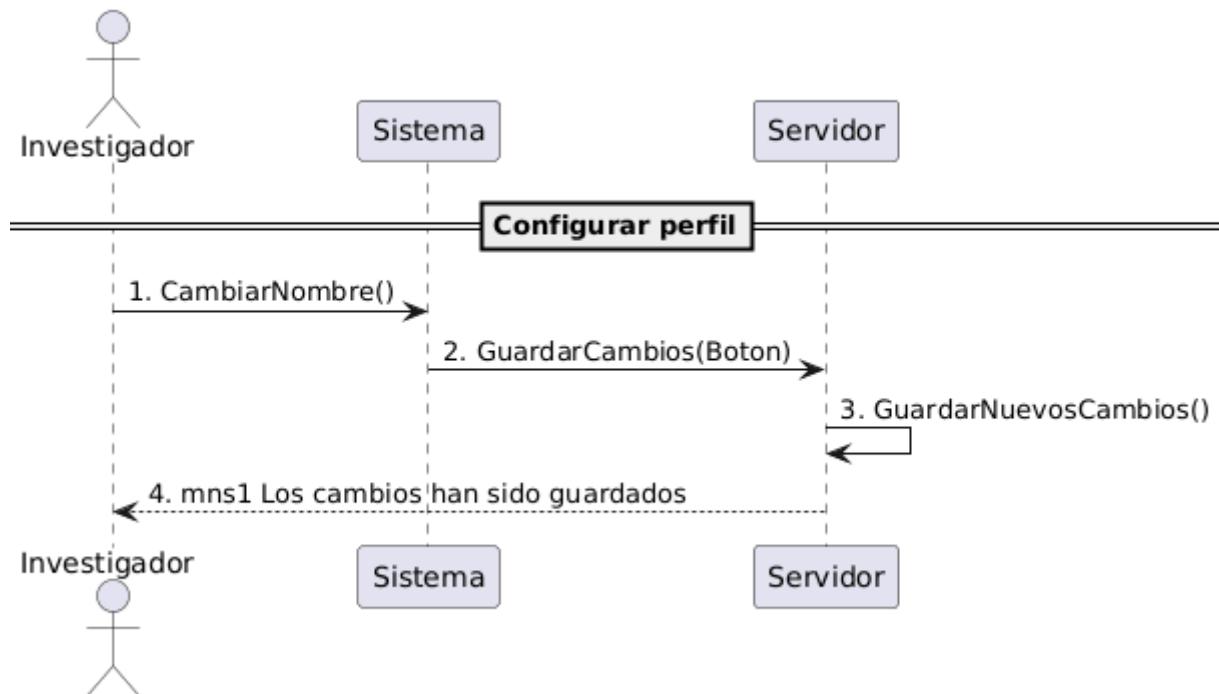


Ilustración 48: Configuración de Perfil [autoría propia]

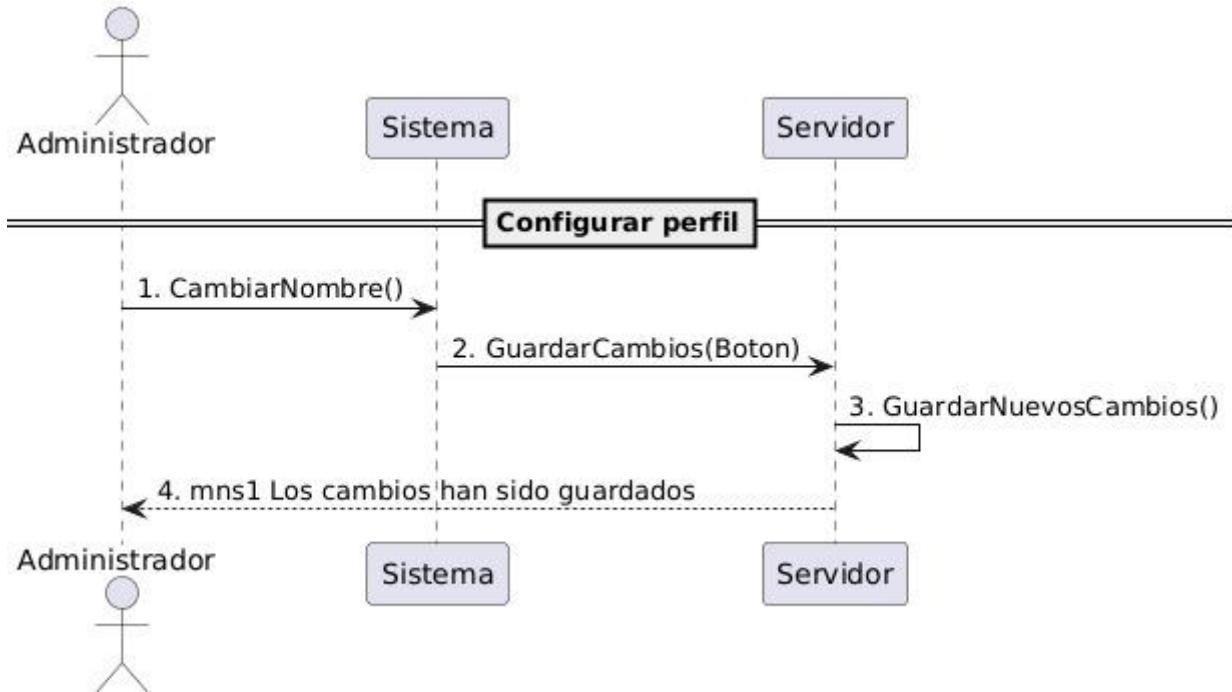


Ilustración 49: "Configurar Perfil Administrador [autoría propia]"

En las ilustraciones 50 y 51 se explica el proceso de cerrar sesión para investigador y administrador.

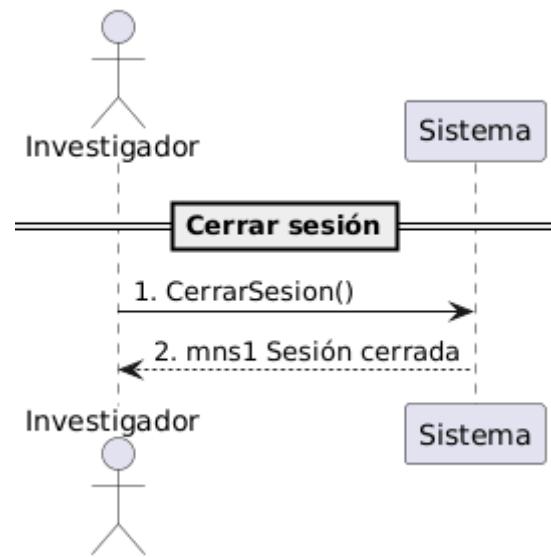


Ilustración 50: “Cerrar Sesión [autoría propia]”

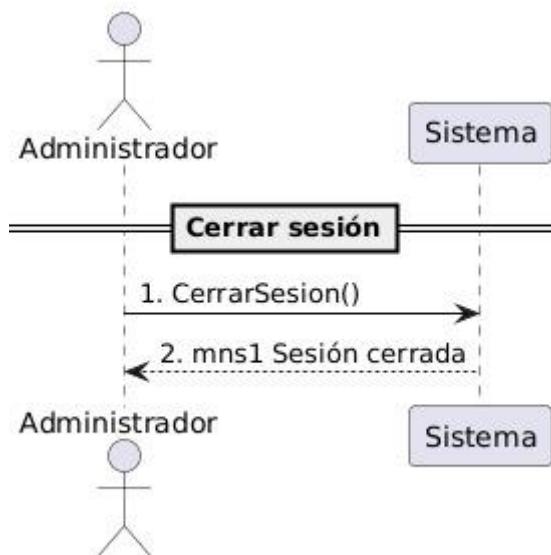


Ilustración 51: “Cerrar sesión Administrador [autoría propia]”

En la ilustración 52, se representa el diagrama para ver notificaciones tanto para investigador y administrador. Sin embargo, el proceso de mandar notificaciones es exclusivo del administrador que puede mandar notificaciones generales o personalizadas a determinada cantidad de investigadores. El administrador escribe una notificación y, al mandarla, se confirma que la notificación no esté vacía. Si la notificación no está vacía, se pregunta al administrador si desea que la notificación sea general o personalizada. En caso de ser notificación general, se guarda la notificación en el servidor y el servidor manda la notificación a todos los investigadores e incluso el administrador. En caso de que la notificación sea personalizada, el prototipo pedirá al administrador que se elija al o a los investigadores a los que se desee enviar la notificación. Una vez el o los investigadores sean seleccionados, el prototipo mandará la notificación al servidor y el servidor la guardará. Al último, el prototipo muestra la notificación personalizada a los investigadores seleccionados previamente por el administrador.

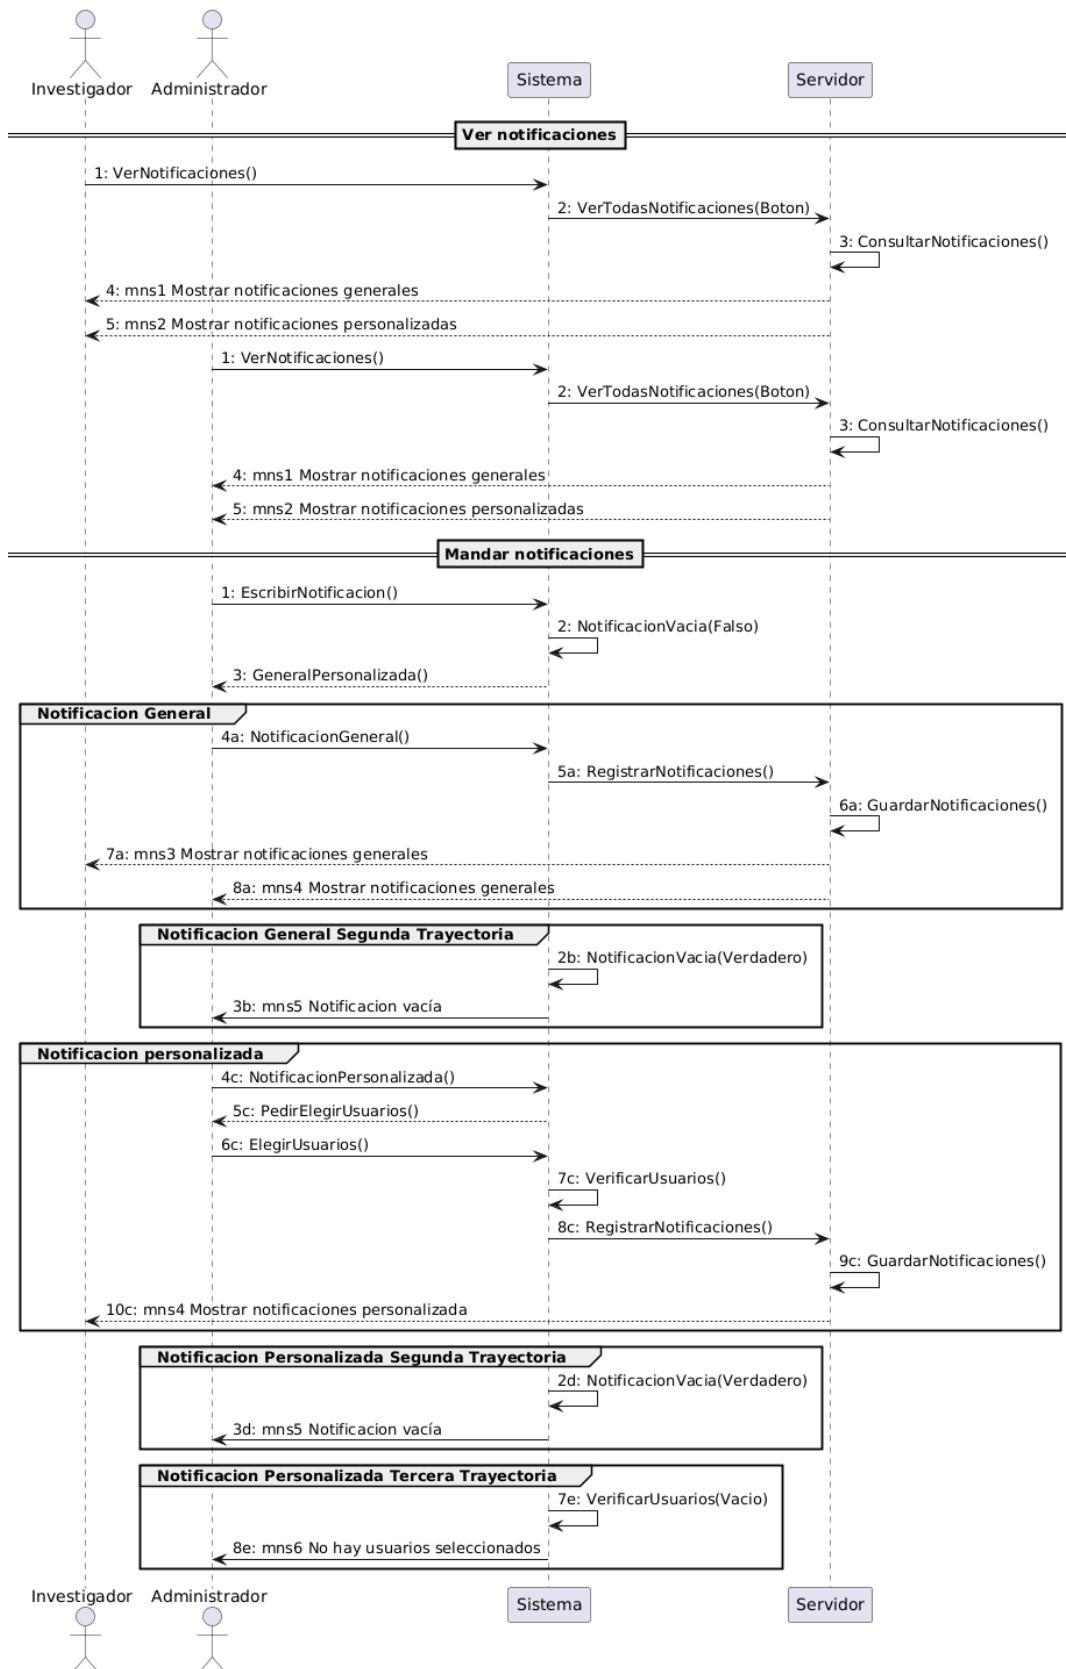


Ilustración 52 “Prototipo de notificaciones [autoría propia]”

En las ilustraciones 53, 54 y 55, se representan los procesos de nuevo análisis, consultar reportes y consultar comparaciones. Si el investigador o administrador elijen hacer un nuevo análisis, se le pedirá que suban un vídeo en formato .mp4 o .mov, después se pedirá delimitar el tiempo y área, siendo los parámetros del mismo vídeo para un mejor análisis. Por último, se pedirá que se elija el tipo de experimento llevado a cabo (sin medicar, placebo, tratamiento).

Una vez se han establecido las bases, el módulo de preprocesamiento empieza a analizar del vídeo extrayendo tiempos de presencia en los brazos, tiempos de inmovilización, tiempos de eventos especiales, contadores de eventos especiales, entre otros. Una vez obtenida la información inicial, el módulo de modelado de conductas toma en cuenta los contadores de eventos especiales ocurridos en ambos brazos. Luego el módulo de análisis estadísticos toma todos los tiempos tomados en cualquier evento que haya ocurrido. Al último, el proceso de análisis termina y se envía un mensaje al usuario de que el evento ha terminado.

Desde ese punto, el investigador tiene la opción de ver los resultados del análisis ya sea los gráficos, datos estáticos, dashboard e incluso el reporte completo, mismo que puede descargar en formato PDF. Se le pregunta al investigador si desea guardar los datos analizados para futuras comparaciones, independientemente de la respuesta el usuario puede acceder al módulo de comparación para ver gráficos de comparaciones, consultar comparaciones o hacer una nueva comparación que pediría dos grupos de datos analizados y guardados para su posterior comparación. Después de elegir un tipo de análisis (test o ANOVA), el usuario puede ver el reporte completo o descargarlo en PDF.

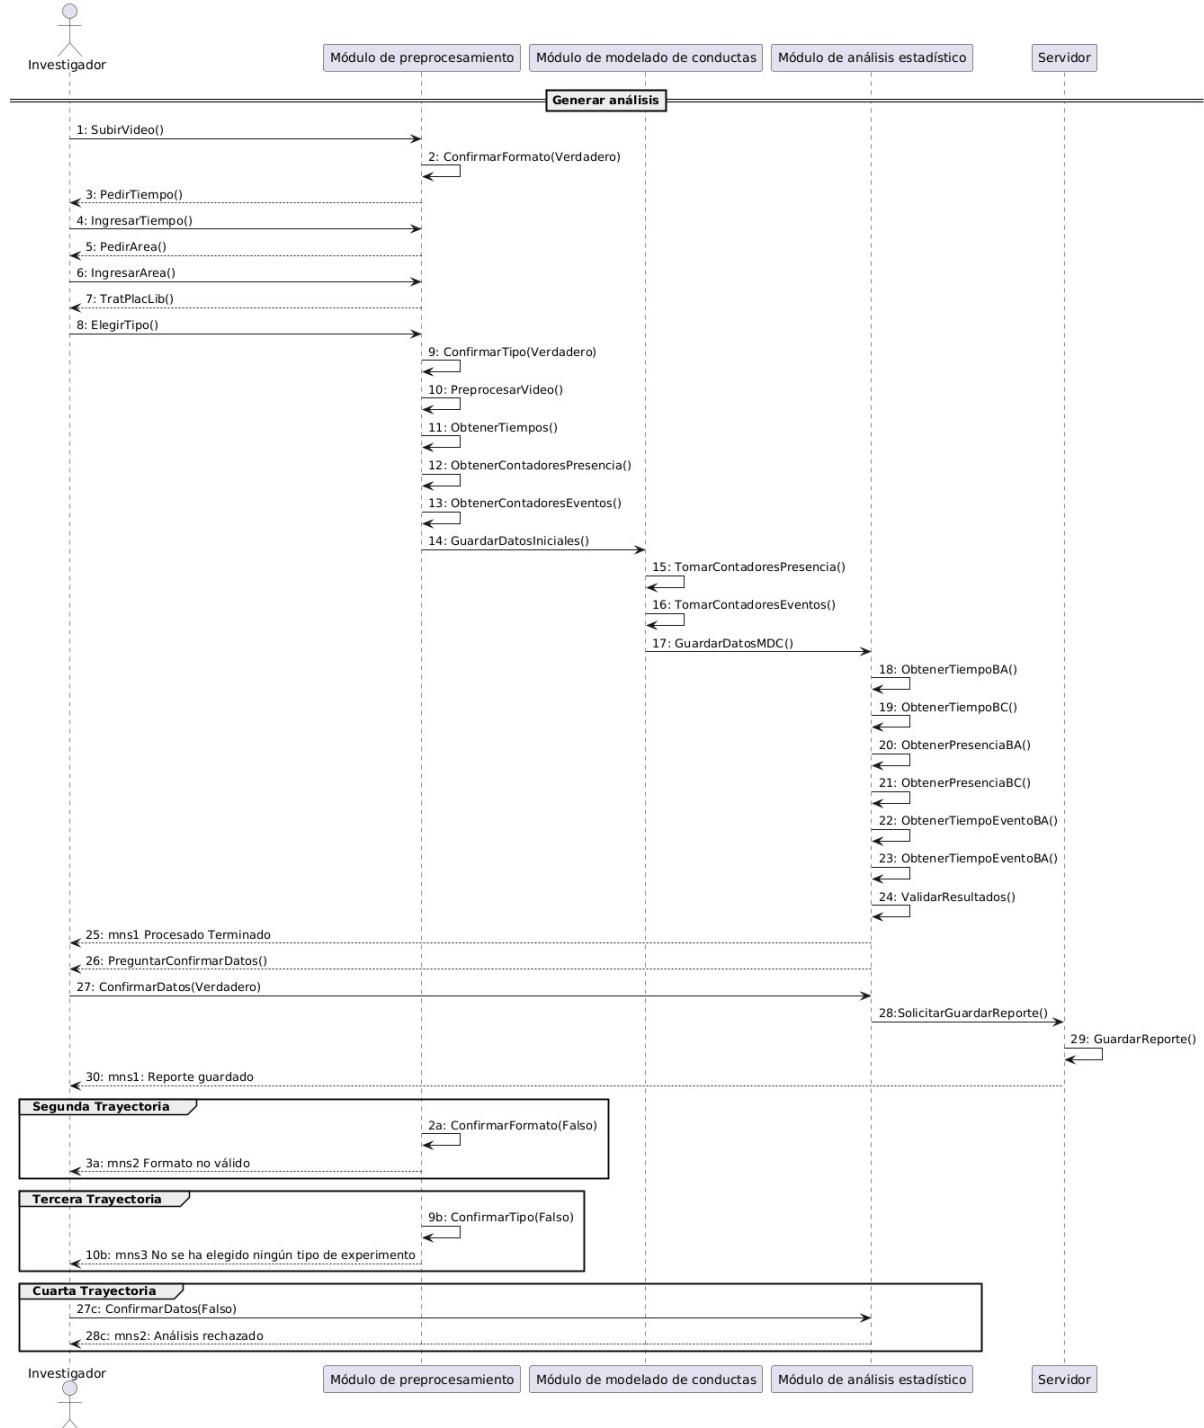


Ilustración 53: “Procesos de generación de análisis [autoría propia]”

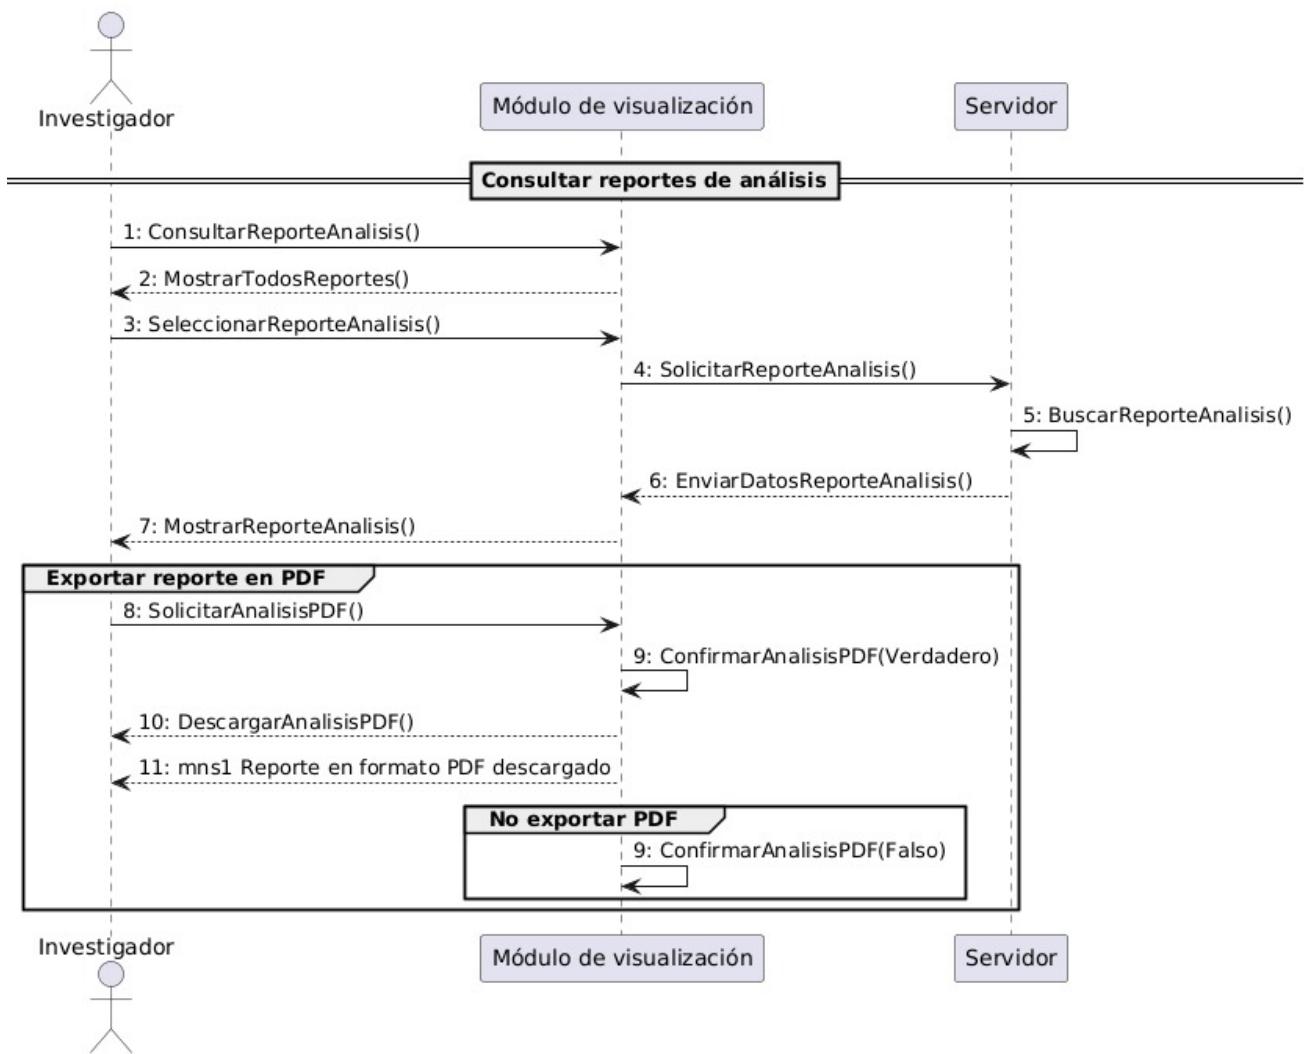


Ilustración 54: “Consulta de reportes de análisis [autoría propia]”

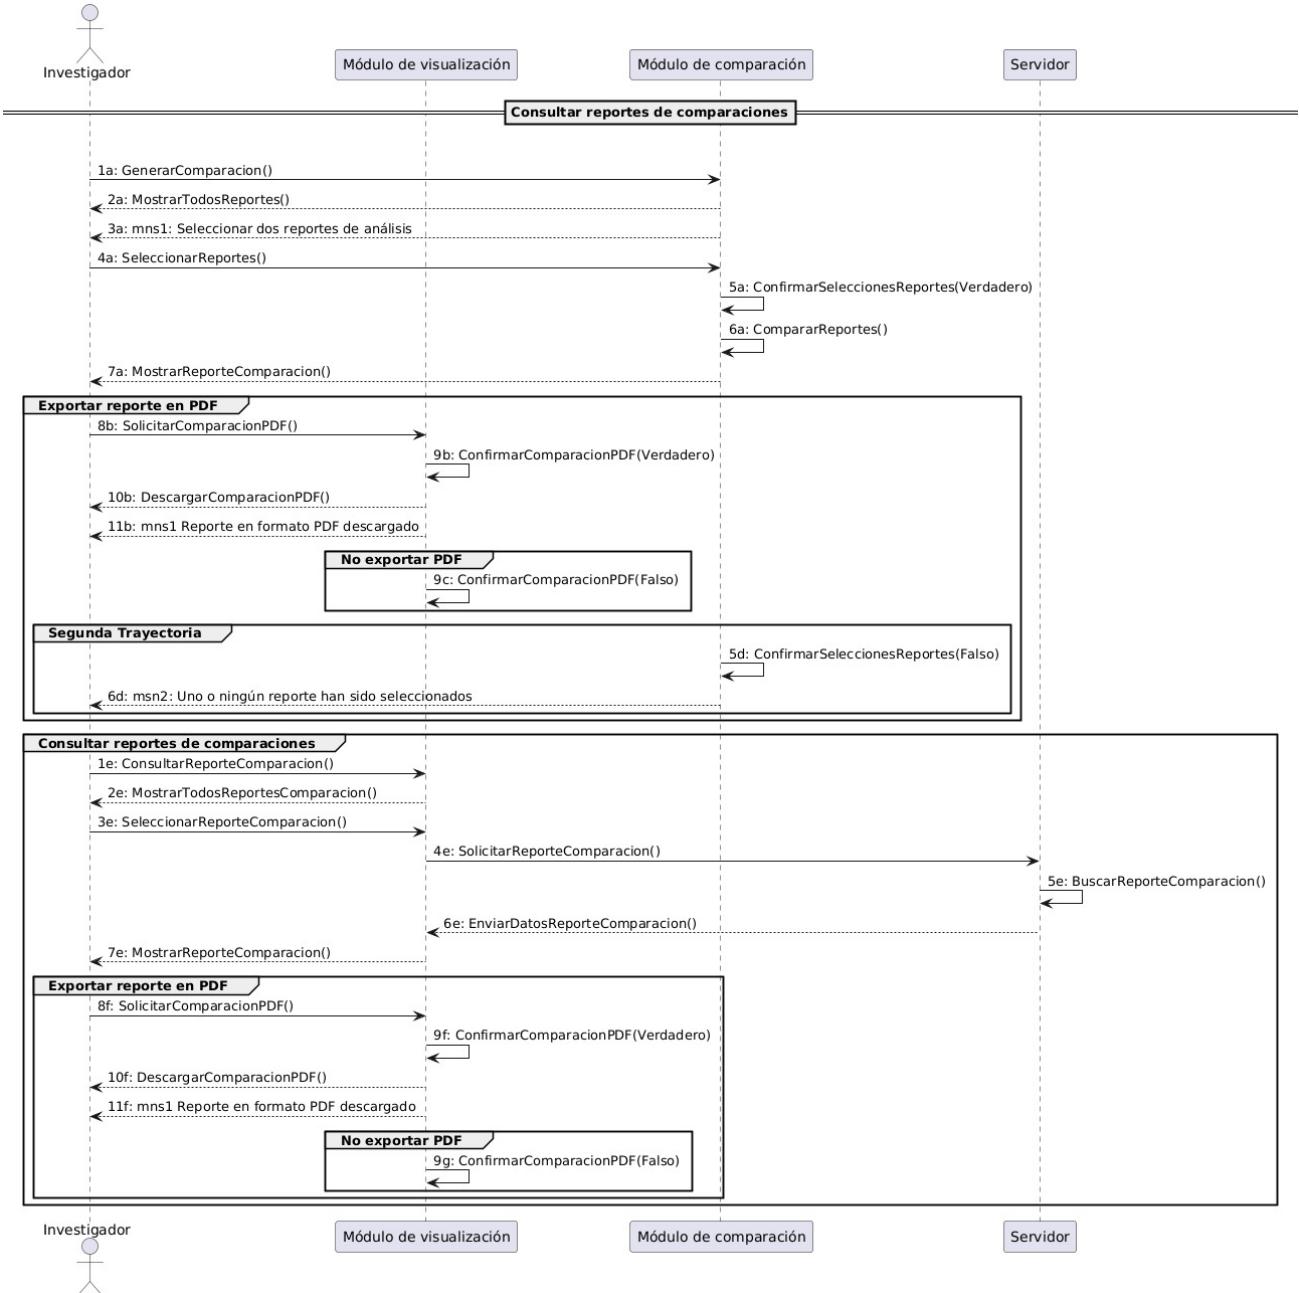


Ilustración 55: “Consulta y generación de comparaciones [autoría propia]”

### 5.3.3 Diagrama de clases

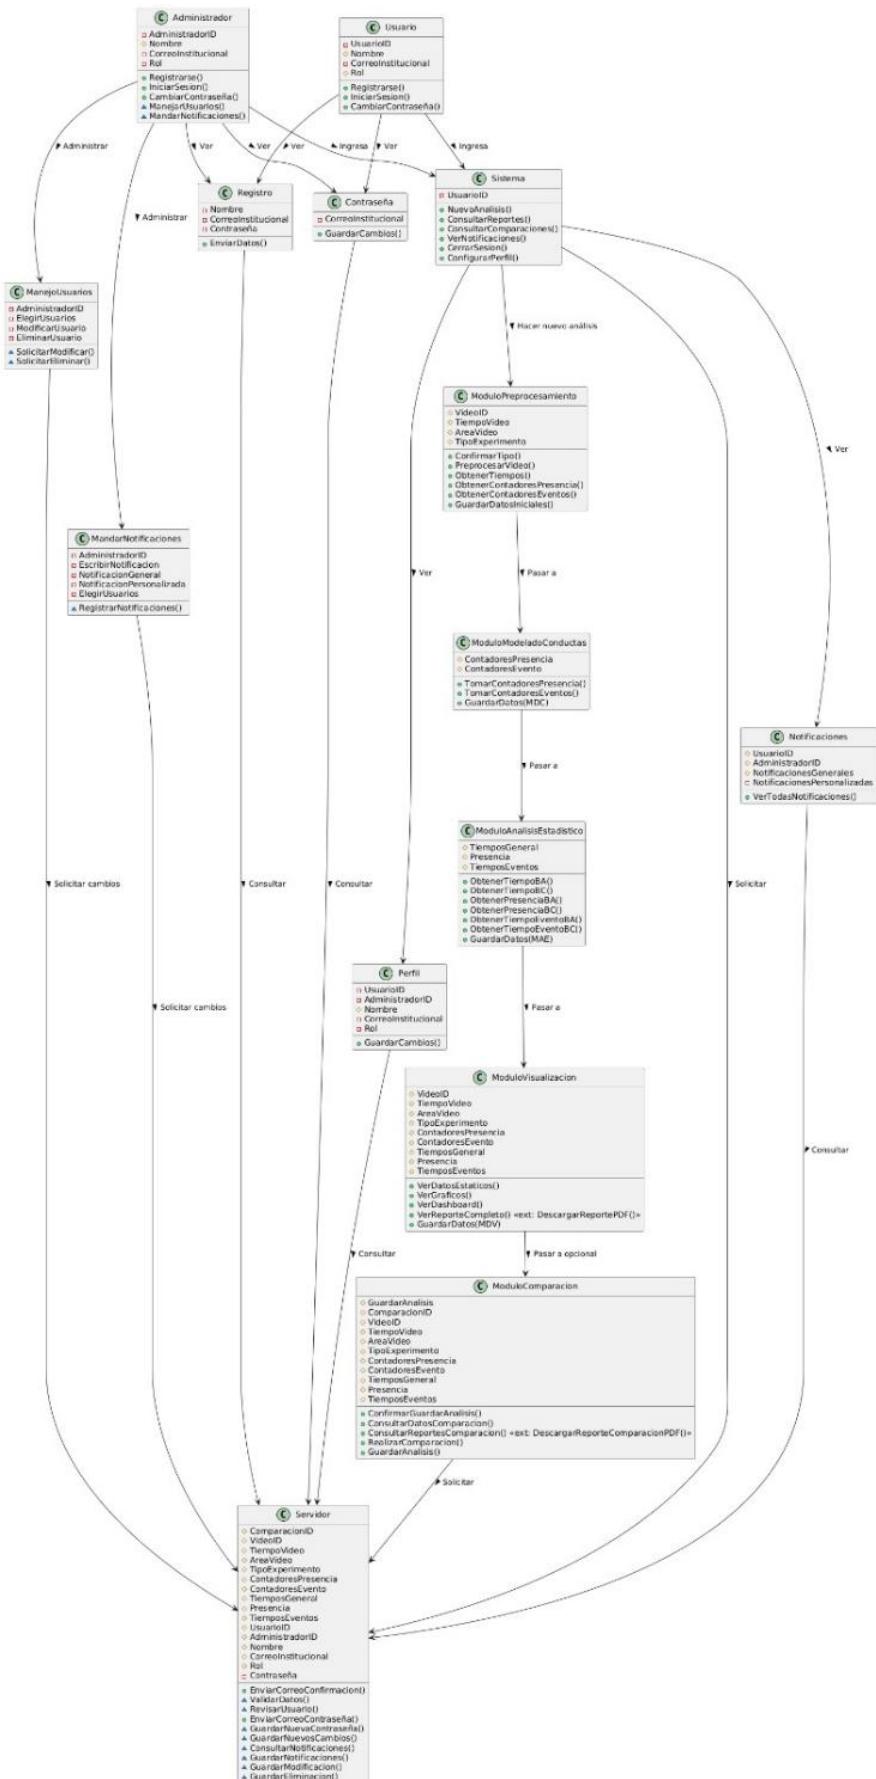
En la ilustración 56, se presenta el diagrama de clases que representa la estructura interna y funcional del prototipo, mostrando las clases principales, sus atributos, métodos y las interacciones entre ellas. La clase Administrador contiene los atributos AdministradorID, Nombre, CorreoInstitucional y Contraseña, y define operaciones como Registrarse (), IniciarSesión (), CambiarContraseña (), ManejarUsuarios () y MandarNotificaciones (), lo que le permite gestionar usuarios y enviar notificaciones dentro del prototipo. La clase Usuario, con atributos UsuarioID, Nombre, CorreoInstitucional y Rol, incluye métodos como Registrarse (), IniciarSesión () y CambiarContraseña ()

()), y se comunica con el prototipo para realizar análisis, comparaciones o consultar reportes. El Prototipo, asociado a los usuarios, posee operaciones como NuevoAnálisis (), ConsultarReportes (), ConfigurarComparaciones (), VerNotificaciones () y CerrarSesión (), gestionando así la interacción general entre módulos.

Existen clases de apoyo como Registro y Contraseña, que permiten registrar nuevos datos y realizar cambios de credenciales respectivamente. Las clases ManejaUsuarios y MandarNotificaciones representan las funcionalidades administrativas, donde la primera permite agregar, modificar o eliminar usuarios, mientras que la segunda gestiona el envío y registro de notificaciones generales o personalizadas.

El proceso de análisis está compuesto por varios módulos especializados. El MóduloPreprocesamiento gestiona datos de video mediante atributos como VideoID, TiempoVideo, ÁreaVideo y TipoExperimento, y métodos para confirmar el tipo de experimento, obtener contadores de presencia o eventos, y guardar datos iniciales. Estos datos se transfieren al MóduloModeladoConductas, encargado de registrar contadores de presencia y eventos y guardar los datos modelados. Posteriormente, el MóduloAnálisisEstadístico procesa estos resultados calculando tiempos generales y de eventos, generando estadísticas mediante métodos como ObtenerTiempoBAC () o GuardarDatosMAE ().

El flujo continúa con el MóduloVisualización, que permite observar los resultados analíticos y generar reportes o dashboards, y con el MóduloComparación, que posibilita comparar distintos análisis o experimentos, guardar resultados y exportarlos en formato PDF. Finalmente, el Servidor centraliza la comunicación entre los módulos y clases, almacenando los datos procesados y gestionando funciones como el envío de correos, revisión de contraseñas, guardado de reportes y confirmaciones de análisis o comparaciones.



*Ilustración 56: “Diagrama de clases [autoría propia]”*

## Capítulo 6. Desarrollo

En este capítulo se documenta el proceso de **diseño y desarrollo del prototipo**, abarcando desde la definición de su estructura general hasta la elaboración de los elementos visuales y funcionales que lo componen.

### 6.1 Mockups del prototipo

#### 6.1.1 Vista previa del inicio de sesión.

En la ilustración 57, representa el boceto hecho del inicio del prototipo. El investigador tiene la opción de ingresar sus datos, cambiar contraseña o registrarse.

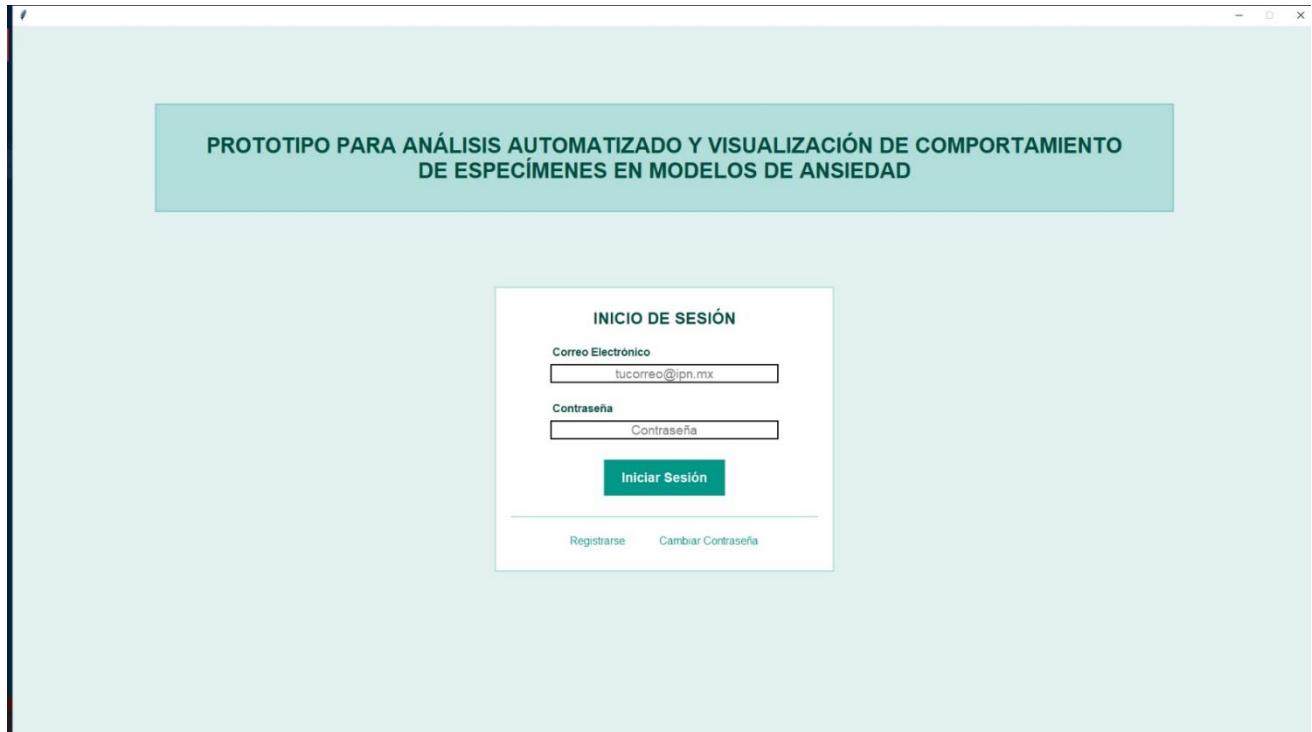


Ilustración 57: "Vista previa de inicio de sesión [autoría propia]"

## 6.1.2 Vista previa de registro.

En la ilustración 58 se muestra la pantalla del registro que pide al investigador dar su nombre completo, correo institucional y contraseña. Después de enviar los datos, el investigador recibirá un correo electrónico de confirmación.

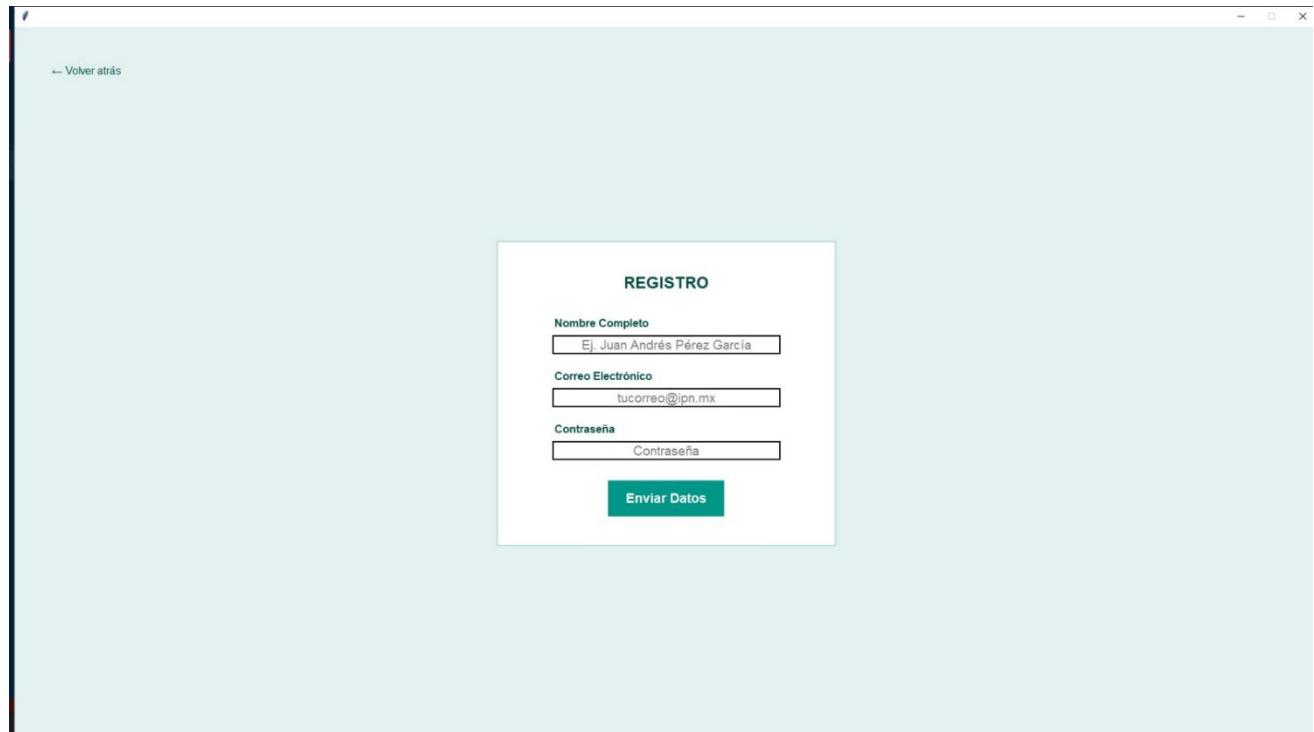


Ilustración 58: “Vista previa del registro [autoría propia]”

### 6.1.3 Vista previa de cambio de contraseña.

En la ilustración 59, el investigador solo necesita ingresar su correo electrónico para recibir un correo de cambio de contraseña.

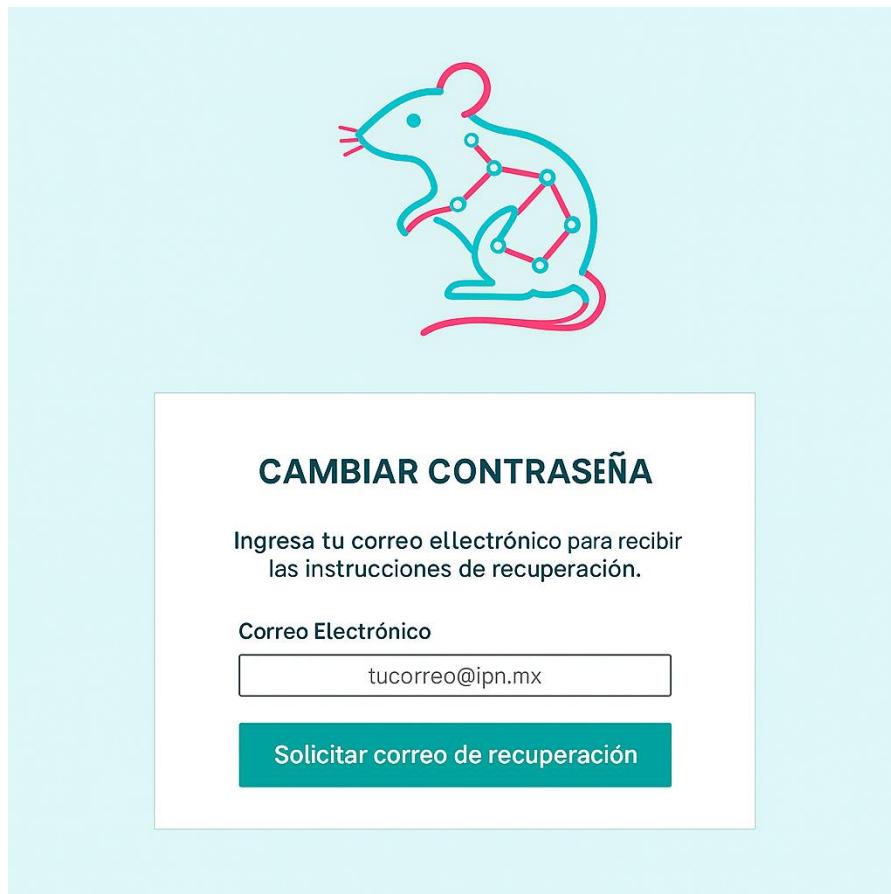


Ilustración 59: “Cambiar contraseña [autoría propia]”

### 6.1.4 Vista previa de inicio del prototipo

En la ilustración 60, se ve la vista de investigador después de iniciar sesión. En un apartado, se muestran las diferentes opciones de realizar un nuevo análisis, consultar reportes y consultar comparaciones. En la parte superior derecha se encuentra la parte de configurar perfil, ver notificaciones y cerrar sesión.

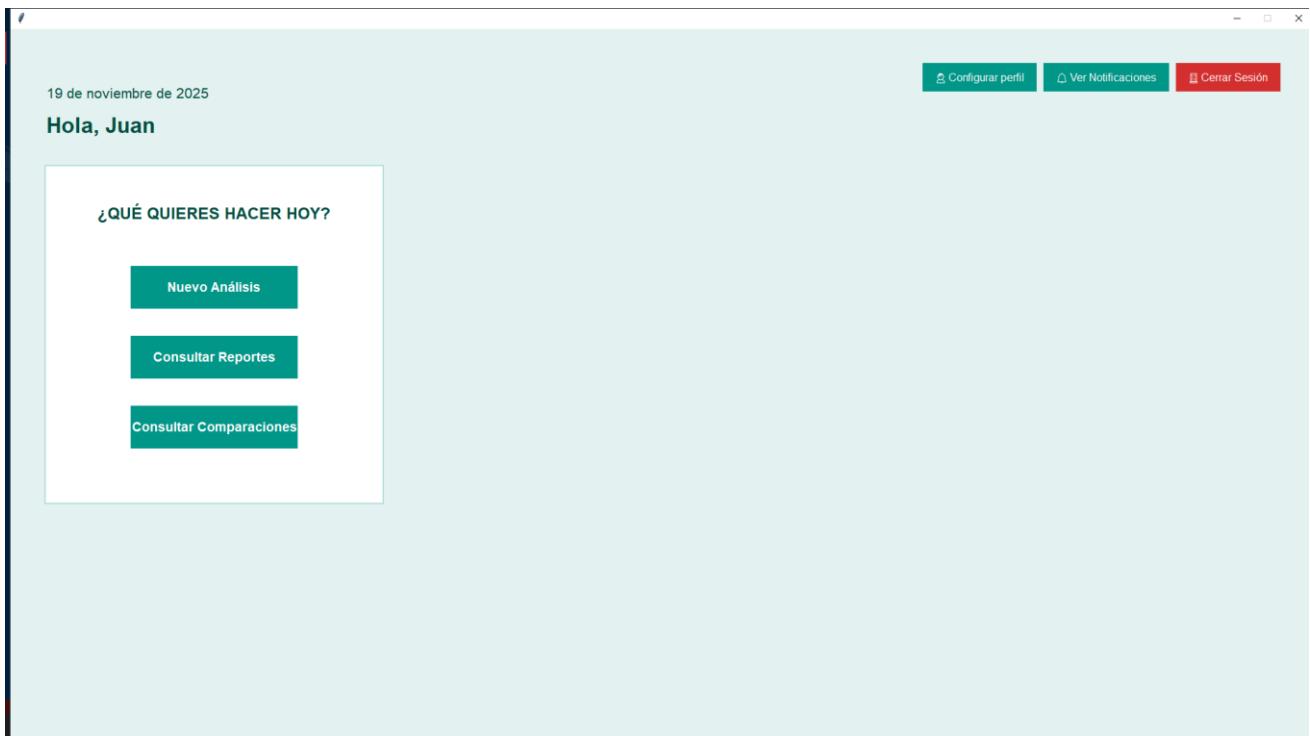


Ilustración 60: “Vista previa del inicio del prototipo [autoría propia]”

Mientras tanto, la ilustración 61 muestra la vista de administrador con todas las funciones de la pantalla de inicio del prototipo para el usuario a excepción de dos botones extras en la parte superior derecha acerca de manejo de perfiles y mandar notificaciones.

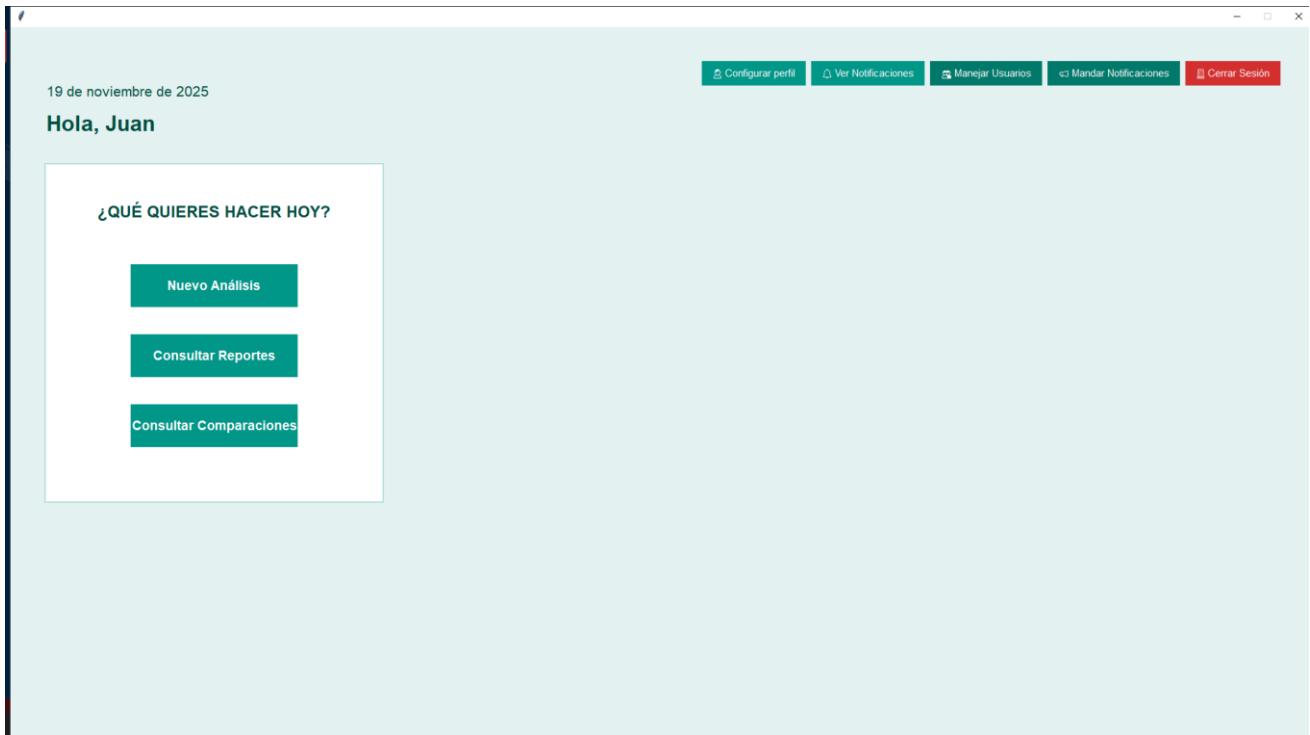


Ilustración 61 “Vista previa del administrador [autoría propia]”

## Conclusiones

Este proyecto fue una oportunidad para demostrar que la tecnología puede ser un puente entre la ciencia y la empatía. No se trató solo de diseñar un prototipo, sino de comprender cómo la automatización puede aportar valor a la investigación y a la interpretación del comportamiento. Cada línea de código y cada iteración reflejan el esfuerzo colectivo de un equipo que aprendió a resolver problemas reales con una visión ética, científica y humana.

Además, el trabajo realizado abre un horizonte de posibilidades para el futuro. Su estructura escalable y adaptable permite que este prototipo evolucione y se integre en otros proyectos de investigación, ampliando su alcance más allá de los modelos de ansiedad. En ese camino, también se generarán nuevos aprendizajes, retos y descubrimientos que fortalecerán no solo la herramienta, sino también la formación profesional y humana de quienes la desarrollan.

En suma, este proyecto no solo representa un logro técnico, sino el inicio de una línea de trabajo prometedora, donde la innovación y la curiosidad seguirán guiando cada paso hacia soluciones más precisas, accesibles y con impacto real en la ciencia.

## Trabajo a futuro

El desarrollo de este proyecto se concibe como un proceso en constante evolución, donde cada iteración permitirá refinar los objetivos, validar resultados y fortalecer la integración entre los distintos actores involucrados. Siguiendo el **modelo de Espiral de Boehm aplicado a la Ciencia de Datos**, el trabajo futuro estará orientado a consolidar las fases de análisis, diseño, desarrollo, validación y retroalimentación, garantizando la mejora continua del prototipo.

Durante las siguientes etapas, se prevé realizar **ajustes y correcciones al documento técnico**, integrando observaciones académicas y resultados experimentales que surjan durante las pruebas con los modelos de ansiedad. Estas revisiones permitirán mantener una documentación actualizada, precisa y alineada con las normas de calidad del ciclo de vida del software.

Asimismo, se fortalecerá la **comunicación entre la Escuela Superior de Cómputo (ESCOM) y la Escuela Nacional de Medicina y Homeopatía (ENMyH)**, mediante reuniones periódicas, validaciones conjuntas y revisión de resultados experimentales. Esta colaboración continua será esencial para asegurar que el prototipo responda adecuadamente a las necesidades reales del ámbito biomédico y mantenga coherencia con los protocolos experimentales.

Cada iteración incluirá la **identificación de riesgos técnicos y operativos**, así como la **planificación de estrategias de mitigación**, en aspectos como la calidad de video, procesamiento de datos, capacidad de cómputo y validez estadística. Dichos riesgos serán evaluados y documentados al inicio de cada ciclo, permitiendo decisiones informadas y oportunas para el desarrollo.

Finalmente, el proyecto continuará evolucionando hacia versiones más robustas, escalables y especializadas. Se contempla la ampliación del prototipo hacia otros modelos conductuales, la integración de procesamiento en tiempo real y la posibilidad de implementar arquitecturas en la nube

que permitan un análisis colaborativo entre instituciones. Este trabajo futuro consolidará la visión del proyecto como una herramienta de apoyo científico, adaptable y en constante crecimiento.

## Referencias

- [1] M. Khatri, S. K. Rai, R. Ranblor, K. Kishore y M. Tiwari, “Synthesis and Pharmacological Evaluation of [(4-Arylpiperazin-1-yl)-alkyl]-carbamic Acid Ethyl Ester Derivatives as Potential Anxiolytic Agents,” *Arch. Pharmal. Res.*, vol. 35, no. 7, pp. 1143–1150, 2011.
- [2] Sin autor, “NORMA Oficial Mexicana NOM-062-ZOO-1999, Especificaciones técnicas para la producción, cuidado y uso de los animales de laboratorio,” *Secretaría de Agricultura, Ganadería, Desarrollo Rural, Pesca y Alimentación*, Ciudad de México, Gov. Rep., Tomo DLXXV No.16, 2001.
- [3] A. P. Carobrez y L. J. Bertoglio, “Ethological and Temporal Analyses of Anxiety-like Behavior: The Elevated Plus-Maze Model 20 Years On,” *Neurosci. Biobehav. Rev.*, vol. 29, no. 8, pp. 1193–1205, 2005.
- [4] F. G. Graeff, C. F. Netto y H. Zangrossi Jr, “The Elevated T-Maze as an Experimental Model of Anxiety,” *Neurosci. Biobehav. Rev.*, vol. 23, no. 2, pp. 237–246, 1998.
- [5], Z. T. Pennington et al., “EzTrack-A step-by-step guide to behavior tracking”, *Curr. Protoc.*, vol. 1, Num. 10, p. e255, 2021.
- [6] **ISO/IEC/IEEE 12207:2017, Systems and Software Engineering — Software Life Cycle Processes**, International Organization for Standardization, Geneva, Switzerland, 2017. [En línea]. Disponible en: <https://www.iso.org/standard/63712.html>
- [7] **ISO/IEC/IEEE 15288:2023, Systems and Software Engineering — System Life Cycle Processes**, International Organization for Standardization, Geneva, Switzerland, 2023. [En línea]. Disponible en: <https://www.iso.org/standard/63711.html>
- [8] **ISO/IEC 25010:2023, Systems and Software Engineering — Systems and Software Quality Requirements and Evaluation (SQuaRE): System and Software Quality Models**, International Organization for Standardization, Geneva, Switzerland, 2023. [En línea]. Disponible en: <https://www.iso.org/standard/78176.html>
- [9] S. Olson y L. Barton, “Artificial Intelligence in Veterinary Medicine: Enhancing Animal Health and Welfare,” *Vet. Clin. North Am. Small Anim. Pract.*, vol. 53, no. 1, pp. 1–14, 2023.
- [10] M. J. Bailey, J. S. Capozzi, y P. J. Lowry, “The Translational Relevance of Rodent Models in Neurobehavioral Research,” *Front. Behav. Neurosci.*, vol. 17, pp. 112–128, 2023.
- [11] I. Sandino, Comunicación personal, Escuela Nacional de Medicina y Homeopatía, Instituto Politécnico Nacional, 2025.
- [12] M. Mathis, A. B. Mamidanna, K. M. Cury et al., “DeepLabCut: Markerless Pose Estimation of User-Defined Body Parts with Deep Learning,” *Nat. Neurosci.*, vol. 21, no. 9, pp. 1281–1289, 2018.
- [13] J. Redmon, S. Divvala, R. Girshick y A. Farhadi, “You Only Look Once: Unified, Real-Time Object Detection,” *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, pp. 779–788, 2016.
- [14] G. Quintana-Diez, “Integración de inteligencia artificial en la medicina del comportamiento animal,” *Rev. Med. Vet. Cienc. Anim.*, vol. 12, no. 2, pp. 85–94, 2022.

- [15] National Centre for the Replacement, Refinement and Reduction of Animals in Research (NC3Rs), “The 3Rs,” 2023. [En línea]. Disponible en: <https://www.nc3rs.org.uk>
- [16] A. Pereira y R. Moita, “The Role of Computer Vision in Ethology: A Review,” *Anim. Behav.*, vol. 190, pp. 1–14, 2022.
- [17] C. Wiltschko et al., “Mapping Sub-Second Structure in Mouse Behavior,” *Neuron*, vol. 88, no. 6, pp. 1121–1135, 2015.
- [18] S. Hochreiter and J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997. [En línea]. Disponible en: [https://www.researchgate.net/publication/13853244\\_Long\\_Short-Term\\_Memory](https://www.researchgate.net/publication/13853244_Long_Short-Term_Memory)
- [19] C. Olah, “Understanding LSTM Networks,” colah’s blog, 2015. [En línea]. Disponible en: <https://colah.github.io/posts/2015-08-Understanding-LSTMs>
- [20] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention Is All You Need,” in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017.
- [21] I. Goodfellow, Y. Bengio and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016. [Online]. Disponible en: <https://www.deeplearningbook.org/>
- [22] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer, 2006.
- [23] Z. Cao, G. Hidalgo, T. Simon, S.-E. Wei, and Y. Sheikh, “OpenPose: Realtime Multi-Person 2D Pose Estimation Using Part Affinity Fields,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 43, no. 1, pp. 172–186, 2021. [Online]. Disponible en: <https://arxiv.org/abs/1812.08008>
- [24] G. Bradski, “Computer Vision Face Tracking for Use in a Perceptual User Interface,” Intel Research, 1998. [Online]. Disponible en: [https://opencv.jp/opencv-1.0.0\\_org/docs/papers/camshift.pdf](https://opencv.jp/opencv-1.0.0_org/docs/papers/camshift.pdf)
- [25] D. Comaniciu, V. Ramesh y P. Meer, “Kernel-Based Object Tracking,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 25, no. 5, pp. 564–577, 2003. [Online]. Disponible en: <https://comaniciu.net/Papers/KernelTracking.pdf>
- [26] Open-Source Computer Vision Library (OpenCV), “MeanShift and CAMShift,” tutorial OpenCV docs (v4.x). [Online]. Disponible en: [https://docs.opencv.org/4.x/d7/d00/tutorial\\_meanshift.html](https://docs.opencv.org/4.x/d7/d00/tutorial_meanshift.html)
- [27] J. Cohen, “A Coefficient of Agreement for Nominal Scales,” *Educ. Psychol. Meas.*, vol. 20, no. 1, pp. 37–46, 1960. Available: <https://journals.sagepub.com/doi/10.1177/001316446002000104>
- [28] M. L. McHugh, “Interrater Reliability: The Kappa Statistic,” *Biochem. Med.*, vol. 22, no. 3, pp. 276–282, 2012. Available: <https://www.biochemia-medica.com/en/journal/22/3/10.11613/BM.2012.031>
- [29] J. L. Fleiss, B. Levin and M. C. Paik, *Statistical Methods for Rates and Proportions*, 3rd ed. New York, NY, USA: Wiley, 2003. Disponible en: <https://onlinelibrary.wiley.com/doi/book/10.1002/0471445428>

- [30] J. MacQueen, “Some Methods for Classification and Analysis of Multivariate Observations,” Proc. 5th Berkeley Symp. Math. Stat. Probab., vol. 1, pp. 281–297, 1967. Disponible en: <https://projecteuclid.org/journals/proceedings-of-the-berkeley-symposium/volume-5/issue-1>
- [31] J. Shlens, “A Tutorial on Principal Component Analysis,” *arXiv preprint arXiv:1404.1100*, Apr. 2014. [Online]. Available: <https://arxiv.org/pdf/1404.1100.pdf>
- [32] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001. Disponible: <https://link.springer.com/article/10.1023/A:1010933404324>
- [33] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2nd ed. New York, NY, USA: Springer, 2009. Disponible en: <https://hastie.su.domains/ElemStatLearn/>
- [34] S. A. Rahman, “Illustration of random forest trees,” ResearchGate, 2021. Disponible en: [https://www.researchgate.net/figure/Illustration-of-random-forest-trees\\_fig4\\_354354484](https://www.researchgate.net/figure/Illustration-of-random-forest-trees_fig4_354354484)
- [35] A. K. Bhowan, “Diagram of ensemble methods: Bagging, Boosting, and Stacking,” ResearchGate, 2019. Disponible en: [https://www.researchgate.net/figure/Diagram-of-ensemble-methods-A-Bagging-B-Boosting-C-Stacking-DT-decision-tree\\_fig1\\_331562581](https://www.researchgate.net/figure/Diagram-of-ensemble-methods-A-Bagging-B-Boosting-C-Stacking-DT-decision-tree_fig1_331562581)
- [36] C. J. C. Burges, “A Tutorial on Support Vector Machines for Pattern Recognition,” *Data Mining and Knowledge Discovery*, vol. 2, pp. 121–167, 1998. [Online]. Disponible en: <https://link.springer.com/article/10.1023/A:1009715923555>.
- [37] Scikit-learn developers, “Support Vector Machines — User Guide,” scikit-learn.org, sección 1.4. [Online]. Disponible en: <https://scikit-learn.org/stable/modules/svm.html>.
- [38] I. T. Jolliffe y J. Cadima, “Principal component analysis: a review and recent developments,” *Philos. Trans. R. Soc. A*, vol. 374, no. 2065, 2016. DOI: 10.1098/rsta.2015.0202.
- [39] A.-M. Krypotos, M. Effting, M. Kindt y T. Beckers, “Avoidance learning: a review of theoretical models and recent developments,” *Front. Behav. Neurosci.*, vol. 9, p. 189, jul. 2015. [En línea]. Disponible: <https://pmc.ncbi.nlm.nih.gov/articles/PMC4508580/>.
- [40] D. Mobbs, C. Hagan, T. Dalgleish, B. Silston y C. Prévost, “The ecology of human fear: survival optimization and the nervous system,” *Front. Neurosci.*, 2015. [En línea]. Disponible: <https://pmc.ncbi.nlm.nih.gov/articles/PMC4364301/>.
- [41] T. M. Ball y L. A. Gunaydin, “Measuring maladaptive avoidance: from animal models to clinical anxiety,” *Neuropsychopharmacology*, vol. 47, pp. 978–986, 2022. [En línea]. Disponible: <https://www.nature.com/articles/s41386-021-01263-4>.
- [42] M. L. Brandão, “Different patterns of freezing behavior organized in the defensive continuum,” *Prog. Neuro-psychopharmacol. Biol. Psychiatry*, vol. 32, no. 8, pp. 1665–1670, 2008. doi: 10.1016/j.pnpbp.2007.12.002.

- [43] F. H. Klaassen, L. Held, B. Figner et al., “Defensive freezing and its relation to approach-avoidance decision-making under threat,” *Sci. Rep.*, vol. 11, Article number 12030, 2021. <https://doi.org/10.1038/s41598-021-90968-z>.
- [44] V. J. Jiménez-Planet and S. Hernández-Villegas, “REPISALUD (REPositorio Institucional de SALUD) del Instituto de Salud Carlos III (ISCIII) y sus Fundaciones: análisis de la puesta en marcha y evolución del proyecto,” Repisalud, Madrid, España. [Online]. Disponible en: <https://repisalud.isciii.es/rest/api/core/bitstreams/cdba37dc-a63b-43ff-a004-ec1762a6116e/content>.
- [45] G. Sun, C. Lyu, R. Cai, C. Yu, H. Sun, K. E. Schriver, L. Gao and X. Li, “DeepBhvTracking: A Novel Behavior Tracking Method for Laboratory Animals Based on Deep Learning,” *Frontiers in Behavioral Neuroscience*, vol. 15, Oct. 2021. [Online]. Disponible en: <https://www.frontiersin.org/journals/behavioral-neuroscience/articles/10.3389/fnbeh.2021.750894/full>
- [46] L. P. J. J. Noldus, A. J. Spink, R. A. J. Tegelenbosch, “EthoVision: A versatile video tracking system for automation of behavioral experiments,” *Behavior Research Methods, Instruments, & Computers*, vol. 33, no. 3, pp. 398-414, 2001. <https://link.springer.com/content/pdf/10.3758/BF03195394.pdf>
- [47] J. M. Lim, B. Platt, S. K. Janhunen, G. Riedel. “Comparison of automated video tracking systems in the open field test: ANY-Maze versus Ethovision XT,” *Journal of Neuroscience Methods*, vol. 397, pág. 109940, agosto de 2023, doi: 10.1016/j.jneumeth.2023.109940.
- [48] ML4Devs, “Why machine learning projects fail,” ML4Devs, 2023. [Online]. Disponible en: <https://ml4devs.com/why-machine-learning-projects-fail/>
- [49] RheoData, “AI Failures Statistics: Why Today’s Machine Learning Systems Fail,” RheoData, 2024. [Online]. Disponible en: <https://rheodata.com/ai-failure-statistics/>
- [50] M. Berthold, “Why Most Machine Learning Models Never Get Deployed,” KDnuggets, 2022. [Online]. Disponible en: <https://www.kdnuggets.com/2022/03/why-ml-models-rarely-get-deployed.html>
- [51] myosh, “What is a Risk Assessment Matrix?” myosh Safety Systems, 2024. [Online]. Disponible en: <https://myosh.com/blog/2024/04/24/what-is-a-risk-assessment-matrix/>
- [52] Beazley Group, “Guide to Risk Assessment,” Cyber Customer Centre – Risk Management Tools, 2024. [Online]. Disponible en: <https://www.beazley.com/en-US/cyber-customer-centre/cyber-risk-management-tools/guide-to-risk-assessment/>
- [53] ISO, ISO 31000:2018 — Risk management — Guidelines, International Organization for Standardization, 2018.
- [54] National Institute of Standards and Technology, Guide for Conducting Risk Assessments (NIST SP 800-30 Rev.1), Gaithersburg, MD, USA, 2012.

- [55] Sharma, Akhilesh & Kumar, Vipan & Longchamps, Louis. (2024). Comparative performance of YOLOv8, YOLOv9, YOLOv10, YOLOv11 and Faster R-CNN models for detection of multiple weed species. *Smart Agricultural Technology*. 9. 100648. 10.1016/j.atech.2024.100648.
- [56] Ke, W., Liu, T., & Cui, X. (2025). IECA-YOLOv7: A Lightweight Model with Enhanced Attention and Loss for Aerial Wildlife Detection. *Animals*, 15(18), 2743. <https://doi.org/10.3390/ani15182743>
- [57] Adhikari, B., Li, J., Michel, E. S., Dykes, J., Tseng, T. P., Tagert, M. L., Chen, D. “A Comprehensive Evaluation of YOLO-based Deer Detection Performance on Edge Devices,” Elsevier, 2025. [Online]. Disponible en: <https://arxiv.org/pdf/2509.20318v2>
- [58] Mathis, M. W., Mathis, A. “Deep learning tools for the measurement of animal behavior in neuroscience”, Harvard University. [Online]. Disponible en: <https://arxiv.labs.arxiv.org/html/1909.13868#:~:text=Deeper%20networks%20are%20slower%2C%20but,Other%20networks%20recently%20added>
- [59] S. Ye et al., “SuperAnimal pretrained pose estimation models for behavioral analysis,” *Nature Communications*, vol. 15, no. 1, p. 5165, Jun. 2024, doi: 10.1038/s41467-024-48792-2
- [60] J. Lauer *et al.*, “multi-animal pose estimation, identification and tracking with DeepLabCut,” *Nature Methods*, vol. 19, no. 4, pp. 496–504, Apr. 2022, doi: 10.1038/s41592-022-01443-0
- [61] Vonstad, E. K., Su, X., Vereijken, B., Bach, K., & Nilsen, J. H. (2020). “Comparison of a Deep Learning-Based Pose Estimation System to Marker-Based and Kinect Systems in Exergaming for Balance Training.” *Sensors* (Basel, Switzerland), 20(23), 6940. <https://doi.org/10.3390/s20236940>
- [62] Udell, A. “Mean Shift and Cam Shift Object Tracking,” towards data science, 2021. [Online] Disponible en: <https://towardsdatascience.com/mean-shift-and-cam-shift-object-tracking-f1c2c515b6bc/>
- [63] Subramaniam, A. “Understanding Object Tracking: From Classical Filters to Deep Learning,” Medium, 2025. [Online]. Disponible en: <https://medium.com/ai-simplified-in-plain-english/understanding-object-tracking-from-classical-filters-to-deep-learning-1d950c449610>
- [64] Yurushkin, M. “A Complete Review of the OpenCV Object Tracking Algorithms,” broutonlab. [Online.] Disponible en: <https://broutonlab.com/blog/opencv-object-tracking/>
- [65] F. A. Team, “CNNs vs. Transformers: Image Recognition Models Explained,” Flypix, Feb. 10, 2025. <https://flypix.ai/es/image-recognition-models-cnns/>
- [66] L. Alzubaidi et al., “Review of deep learning: concepts, CNN architectures, challenges, applications, future directions,” *Journal of Big Data*, vol. 8, no. 1, p. 53, Mar. 2021, doi: 10.1186/s40537-021-00444-8.
- [67] C. Stryker, “Red neuronal recurrente (RNN),” IBM, Feb. 05, 2025. <https://www.ibm.com/es-es/think/topics/recurrent-neural-networks>

- [68] “¿Cuáles son las ventajas y desafíos de usar LSTM o GRU para dependencias a largo plazo en series temporales?,” Sep. 01, 2023. <https://www.linkedin.com/advice/1/what-advantages-challenges-using-lstm-gru-long-term?lang=es>
- [69] A. M. Calero, A. Rasheed, and A. Lekkas, “Chronoshap: Revealing Temporal Patterns from Transformers and Ltsf-Linear Models in Time Series Forecasting,” SSRN Electronic Journal, Jan. 2025, doi: 10.2139/ssrn.5403215.
- [70] L. Ramírez, “Algoritmo k-means: ¿Qué es y cómo funciona?” Thinking for Innovation, Oct. 30, 2024. <https://www.iebschool.com/hub/algoritmo-k-means-que-es-y-como-funciona-big-data/>
- [71] J. Rew, S. Park, Y. Cho, S. Jung, and E. Hwang, “Animal movement prediction based on predictive recurrent neural network,” Sensors, vol. 19, no. 20, p. 4411, Oct. 2019, doi: 10.3390/s19204411.
- [72] R. Mosquera, O. D. Castrillón, and L. Parra, “Máquinas de Soporte Vectorial, Clasificador Naïve Bayes y Algoritmos Genéticos para la Predicción de Riesgos Psicosociales en Docentes de Colegios Públicos Colombianos Información Tecnológica, vol. 29, no. 6, pp. 153–162, Dec. 2018, doi: 10.4067/s0718-07642018000600153.
- [73] ISO, “ISO 14064-1: Greenhouse gases — Part 1: Specification with guidance at the organization level,” 2018.
- [74] Green Software Foundation, “Principles of Sustainable Software Engineering,” IEEE Software, 2022.
- [75] M. K. Patterson, “Power and Energy Consumption in IT Systems,” IEEE Computer Society Technical Report, 2022.
- [76] S. Balaji et al., “Energy Behavior of Cloud-Based ML Execution Environments,” IEEE Transactions on Cloud Computing, 2023.
- [77] International Energy Agency, “Emission Factors for Mexico,” cited in IEEE Energy and Environment Proceedings, 2024.
- [78] J. Rojas et al., “Urban Mobility and Carbon Emissions in Latin American Megacities,” IEEE Transactions on Intelligent Transportation Systems, 2023.
- [79] A. Mittal et al., “Energy Efficiency of Machine Learning Models in Edge Devices,” IEEE Transactions on Sustainable Computing, vol. 8, no. 2, 2023.
- [80] ISO, “ISO 26000: Guidance on Social Responsibility,” 2010.
- [81] T. J. McCabe, “A Complexity Measure,” IEEE Transactions on Software Engineering, vol. SE-2, no. 4, 1976.
- [82] ISO/IEC, “25010: System and Software Quality Models,” 2011.
- [83] Microsoft, “Especificaciones y requisitos del sistema de Windows 11 | Microsoft Windows,” Windows. <https://www.microsoft.com/es-es/windows/windows-11-specifications>
- [84] “The Python tutorial,” Python Documentation. <https://docs.python.org/3/tutorial/index.html>

[85] Transformative Mobility Lab / Factsheet, Mexico City — Modal split and public transport overview, 2021 (public data fact sheet; modal share: public transport  $\approx$  50%). TUMI

[86] World Bank / Operational Evaluation & related analyses, Cost effectiveness of CO<sub>2</sub> reduction with hybrid and electric buses — example estimates for Mexico (electric bus  $\approx$  1 kWh/km  $\rightarrow$   $\sim$ 0.6 kg CO<sub>2</sub>/veh-km in Mexican grid)-

## Apéndice

El cronograma completo del proyecto de los tres integrantes del equipo se encuentra disponible en el siguiente enlace, en un formato digital:

<https://smurl.es/2026-A155-Cronograma>

**Prototipo I.** Durante la primera etapa de desarrollo, alrededor de finales de junio y principios de julio, construimos un primer prototipo funcional para el análisis automatizado del comportamiento de roedores en el laberinto en cruz elevada. Este prototipo marcó un punto de partida importante: permitió comprobar la viabilidad del sistema, validar nuestras ideas iniciales y reconocer, con evidencia, las limitaciones técnicas que debíamos resolver para iteraciones posteriores.

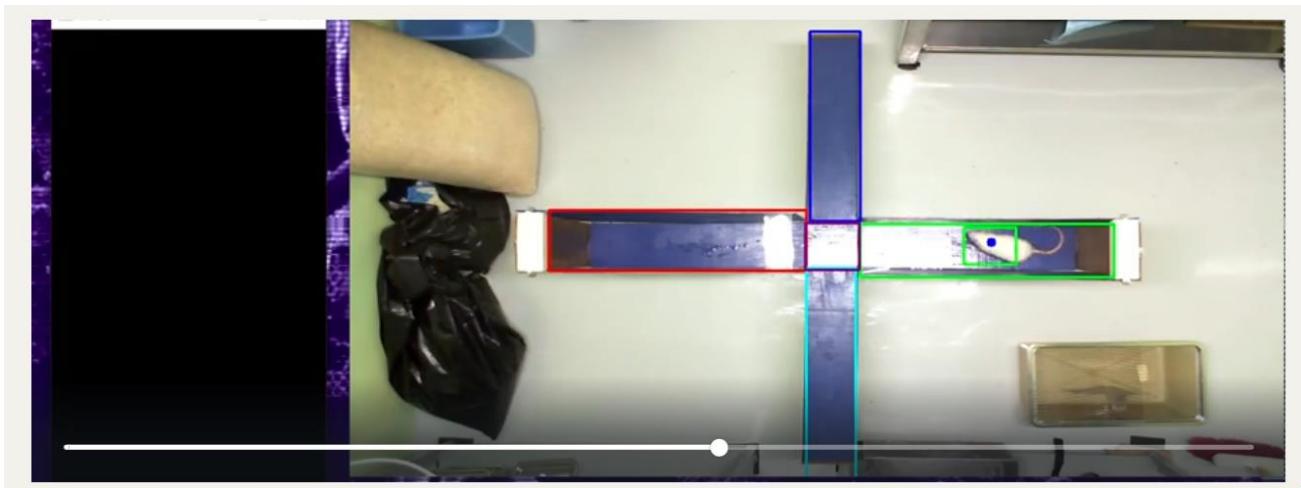


Ilustración 62 "Ilustración del modelo [auditoria propia]"

**1. Modelo inicial apenas entrenado.** En esta primera fase, el modelo con el que trabajábamos estaba apenas en construcción: contábamos con muy pocas imágenes de entrenamiento y todavía no existía un dataset sólido ni estandarizado. Por esta razón, el desempeño inicial era limitado; el sistema lograba detectar al ratón, pero lo hacía con poca precisión y de manera inconstante. Fallaba especialmente cuando el animal cambiaba de orientación, se desplazaba rápido, entraba a zonas con sombra o cruzaba hacia los brazos cerrados. Aun con estas carencias, este primer modelo nos permitió comprobar que el enfoque era viable y que la base del proyecto funcionaba, aunque de manera rudimentaria.

**2. Ejecución completamente en local.** En esta segunda etapa, todo el sistema se ejecutaba únicamente en la computadora local, lo que significaba depender por completo del hardware personal disponible. Esto nos permitió tener un primer acercamiento práctico al flujo de trabajo, pero también nos enfrentó rápidamente a varias limitaciones importantes. El procesamiento de los videos resultaba muy lento debido a la ausencia de una GPU dedicada, y el equipo se sobrecalentaba con facilidad durante las corridas más largas. Además, trabajar solo con CPU hacía prácticamente imposible entrenar modelos más grandes o experimentar con arquitecturas complejas, lo que restringía nuestras opciones técnicas. Cada análisis requería bastante tiempo, ya que el modelo inicial tenía un bajo nivel de entrenamiento y el preprocesamiento cuadro por cuadro demandaba más recursos de los que la máquina podía ofrecer.

**3. Primeras herramientas en Python y OpenCV.** En esta etapa inicial, el desarrollo del sistema se apoyó completamente en Python y en un conjunto reducido de herramientas de visión por computadora, principalmente OpenCV. Con ellas implementamos las primeras funciones esenciales del flujo de trabajo: extracción de fotogramas, limpieza básica de imagen, delimitación manual de regiones de interés y dibujo de las detecciones sobre el video. Si bien las capacidades eran todavía limitadas, estos módulos nos permitieron construir un pipeline funcional capaz de cargar un video, identificar al espécimen y generar una visualización preliminar de su trayectoria dentro del laberinto. Gracias a estas pruebas, pudimos confirmar que el enfoque elegido era viable y que los componentes iniciales se integraban correctamente entre sí. Aunque el sistema aún no incorporaba técnicas avanzadas como estimación de postura, modelado temporal o minería de datos, este primer conjunto de herramientas fue suficiente para establecer las bases del análisis automatizado y abrir el camino para las siguientes etapas del proyecto.

**4. Contador de eventos: funcional, pero aún limitado.** El contador de eventos desarrollado en el prototipo inicial permitía registrar aspectos básicos del comportamiento del espécimen, como las entradas y salidas de los brazos, la presencia en zonas específicas y la permanencia aproximada en cada área del laberinto. Aunque cumplía con su propósito fundamental, su precisión y alcance eran todavía reducidos. El sistema dependía exclusivamente del movimiento del cuadro de detección, lo que ocasionaba errores cuando el ratón quedaba parcialmente oculto, se superponía con sombras o se desplazaba cerca de los bordes. Además, este contador no tenía la capacidad de diferenciar posturas ni de identificar eventos conductuales más complejos, como episodios de acicalamiento o períodos prolongados de inmovilidad, elementos esenciales para un análisis etológico más riguroso. A pesar de estas limitaciones, el módulo cumplió su función dentro del prototipo, pues permitió validar la estructura general del análisis y evidenció con claridad las áreas que requerían un desarrollo más profundo en etapas posteriores.

**Prototipo II.** En el segundo prototipo se logró un avance significativo respecto a la versión inicial, principalmente gracias a la incorporación de un modelo YOLOv11 entrenado con un conjunto sustancialmente mayor de imágenes. En esta iteración se utilizaron **1,954 imágenes cuidadosamente etiquetadas**, lo que permitió obtener un modelo considerablemente más robusto y preciso. Como resultado, la detección del espécimen mostró una mejora notable, alcanzando **aproximadamente un 94% de efectividad** durante la mayor parte del video. Las únicas fallas recurrentes se presentaron en los instantes iniciales, donde el modelo tendía a confundir al investigador con el ratón, un problema esperado que será abordado con más datos y técnicas de depuración en las siguientes iteraciones.

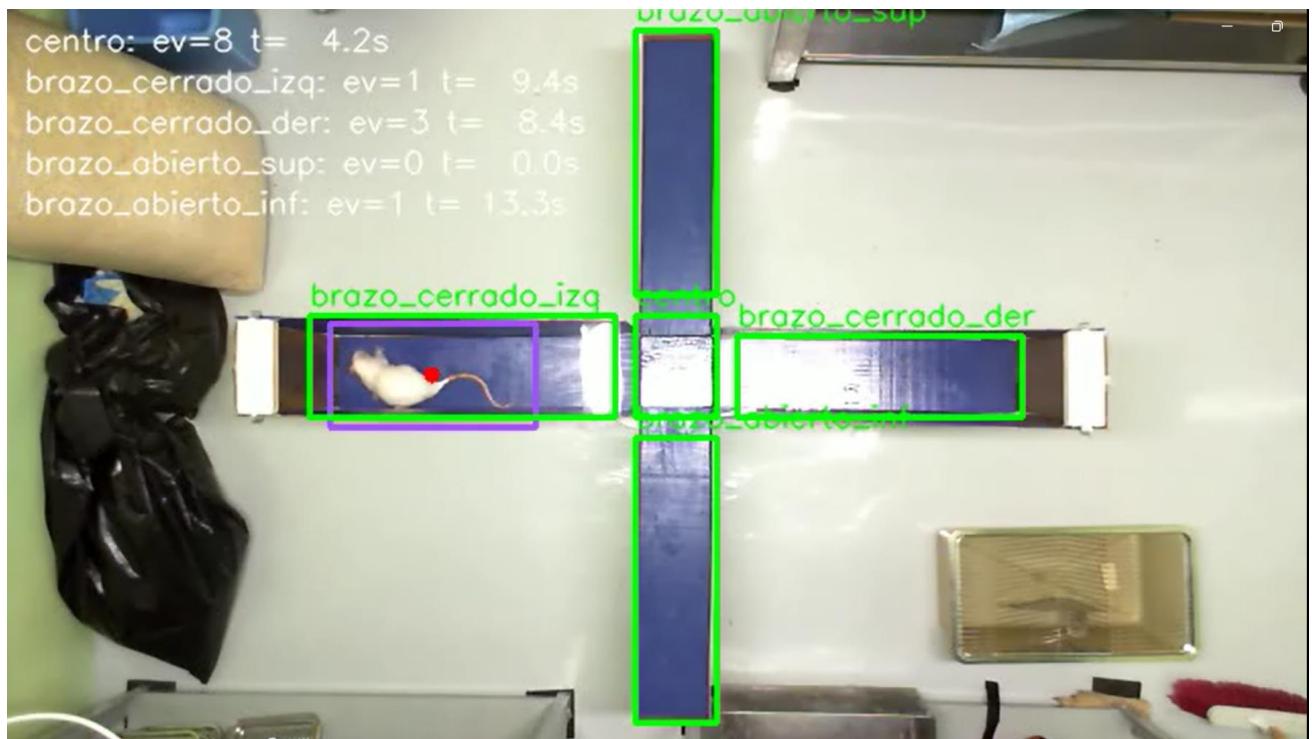


Ilustración 63 "Ilustración del modelo prototipo II [auditoria propia]"

A pesar de este avance en detección, en esta etapa **aún no se había integrado la estimación de postura (pose estimation)**, una funcionalidad que se evaluará más adelante para complementar la clasificación conductual y enriquecer el análisis etológico. Sin embargo, incluso sin esta capa adicional de análisis, el sistema ya mostraba un comportamiento mucho más estable que la versión previa. El **contador de eventos**, por ejemplo, **presentó mejoras significativas**: dejó de desaparecer, mantuvo su consistencia a lo largo de la grabación y reflejó de manera más confiable las entradas y tiempos de permanencia en cada zona del laberinto.

Otro cambio relevante de esta iteración fue la **migración del procesamiento a una GPU en Google Colab**, lo que permitió un rendimiento muy superior al obtenido en ejecución local. La mayor capacidad de cómputo redujo los tiempos de inferencia y facilitó la manipulación de modelos más complejos. No obstante, esta transición trajo consigo ciertas limitaciones técnicas, especialmente relacionadas con la interacción gráfica.

En Colab no fue posible desplegar ventanas para delimitar visualmente las áreas de interés del laberinto, por lo que la marcación de regiones se tuvo que realizar de forma manual introduciendo coordenadas. Aunque este proceso no afectó el funcionamiento general, sí representó un obstáculo operativamente importante que deberá solucionarse en prototipos futuros para garantizar una experiencia más fluida y automatizada.

Este segundo prototipo representa un progreso considerable: el modelo detecta con mucha mayor precisión, el contador de eventos opera de manera estable y la infraestructura de ejecución es más potente y eficiente. Aun con sus limitaciones, se consolidaron las bases para avanzar hacia una versión más robusta, donde se incorporará pose estimation, más datos de entrenamiento y nuevas evaluaciones del rendimiento general del sistema.

**Transcripción de la entrevista realizada al Dr. Sandino el 30 de septiembre de 2025:**

1. **¿Cuál sería el principal problema que se espera resolver con la aplicación? ¿Y qué resultado considera exitoso?**

**Sandino:** El principal problema que tenemos, como reto, es poder interpretar de forma automatizada las diferentes conductas en este modelo. Y lo que lograríamos es estandarizar la interpretación de manera que no dependa del observador la asignación de las diferentes conductas que se le dan a la rata durante el experimento. Ok. Perfecto.

2. **Sobre los datos ¿Qué tipo de videos y anotaciones necesitamos recolectar para que el sistema sea realmente útil?**

**Sandino:** Se necesita la captura de un video que pueda reflejar con el detalle suficiente todas las conductas que queremos evaluar. Para que entonces podamos hacer una adecuada interpretación de esas conductas.

3. **De las funcionalidades. ¿Qué conductas o métricas considera más importantes que el sistema detecta automáticamente? Por ejemplo, trayectorias, tiempo de movilidad, o zonas de permanencia.**

**Sandino:** Si bien todas nos dan información diferente que es útil para poder interpretar el efecto que podamos tener en una molécula con fines de utilización como ansiolítico. Los tiempos en brazos abiertos y los tiempos en brazos cerrados son los principales indicadores de que se está teniendo un efecto ansiolítico. A qué nivel y con qué características nos sirve el resto de los parámetros; los tiempos en brazos cerrados y tiempo en brazos abiertos en general son los principales indicadores.

4. **¿Qué visualizaciones les resultan más útiles para la toma de decisiones? Por ejemplo, podemos hacer gráficas, heatmaps (mapas de calor), reportes comparativos o alertas.**

**Sandino:** Los gráficos son más útiles porque son los que solemos utilizar, pero personalmente a mí me gustan los mapas de calor en el equipo donde me puede extraer el mismo valor que pondríamos en los gráficos, en los parámetros globales. Entonces, si en el mapa de calor se me puede poner en un brazo o en los brazos cerrados el tiempo total, pero yo además puedo ver qué tanto se desplaza en diferentes regiones de ese brazo me sería muy útil.

**5. ¿Qué nivel de precisión o concordancia espera que considere aceptable para que la aplicación sea adoptada? Por ejemplo, más del 90% o 95%**

**Sandino:** Nosotros actualmente lo hacemos con tres personas diferentes que hacen la evaluación de forma independiente, entonces la variación que solemos tener entre esas tres personas suele ser entre el 10% y el 15% del valor medio. Por lo tanto, entre el 90% y el 95% de precisión sería excelente para fines de tomar como verdaderos los datos que nos arroja el análisis.

**6. Respecto a usabilidad ¿Qué tan importante es que la aplicación tenga una interfaz sencilla y accesible para las personas sin experiencia técnica?**

**Sandino:** Muy importante. Tengo médicos que se dedican a hacer estos experimentos. Mientras más amigable sea la interfaz pues es más asequible que puedan ellos utilizarla con precisión y que sea adecuado el uso.

**Equipo:** Lo que teníamos pensado era hacer la aplicación, y nada más que seleccionen el vídeo, recortar dicho vídeo, y definir el área a estudiar.

**Sandino:** De hecho, algo que tal vez podría funcionar es que automáticamente uno pudiera decir “Empieza a registrar a partir de tal segundo”. De manera que no dependa tanto que la persona que vaya a analizar el vídeo lo recorte o lo tenga que recortar. Porque eso implica por lo menos un programa de edición de vídeo que tienen que aprender a utilizar, pero si en la interfase le podemos poner “Empieza a analizar a partir de tal segundo” ... Y que entonces el conteo empieza a partir de ese segundo, no importa si el vídeo tiene diez segundos que se tienen que omitir o cinco o tres, sino nada más uno lo previsualiza y dice “bueno, a partir del segundo quince es cuando se va a poner, a empezar a tomar, porque ya se salió el operario, ya se estabilizó la imagen y la rata ya se estabiliza también”.

**7. Este es sobre la sobriedad de interfaz ¿Prefiere una aplicación web con dashboards interactivos o reportes descargables en PDF o Excel?**

**Sandino:** Yo creo que en Excel porque eso nos permite llevarlo a otros programas. Por ejemplo, hay veces que utilizamos graficadores como Origin nada más por fines de publicación, porque Origin nos permite hacer gráficos (BueR, o, ya los hacemos más en R, pero todavía hay quienes lo hacen en Origin) ya con fines de publicación, donde podemos editar como lo pida la revista, el tamaño de los títulos, de los ejes, o cualquier cosa, ya lo hacemos también en R, con Excel nos puede servir muy bien también R.

**Equipo:** Entonces serían dos cosas, o sea, un Excel con los datos ya analizados, o digamos en crudo, y además las gráficas que se muestran en el programa, ¿no?

**Sandino:** Sí. Finalmente, los gráficos nos van a ayudar a ir viendo cómo se comporta el espécimen durante el video, pero esas gráficas seguramente no van a ser las que llevemos a la presentación final de los resultados, seguramente nos servirán los datos analizados o crudos, de donde provienen esas gráficas, pero para Re graficarlo nada más.

## 8. ¿Desea tener un registro de todos los dashboards y análisis realizados?

**Sandino:** Dependerá de la capacidad de cómputo y almacenamiento, ya que los videos ocupan mucho espacio. Lo ideal sería conservar únicamente los resultados procesados, no los videos, para evitar requerir demasiado almacenamiento. Con respecto al procesamiento, el laboratorio cuenta con varias opciones: una computadora con buena capacidad, un pequeño clúster y la posibilidad de usar equipos con GPU o incluso servicios en la nube si fuera necesario. Para decidir cuál es la mejor opción, es importante conocer primero los requerimientos óptimos de cómputo del sistema.

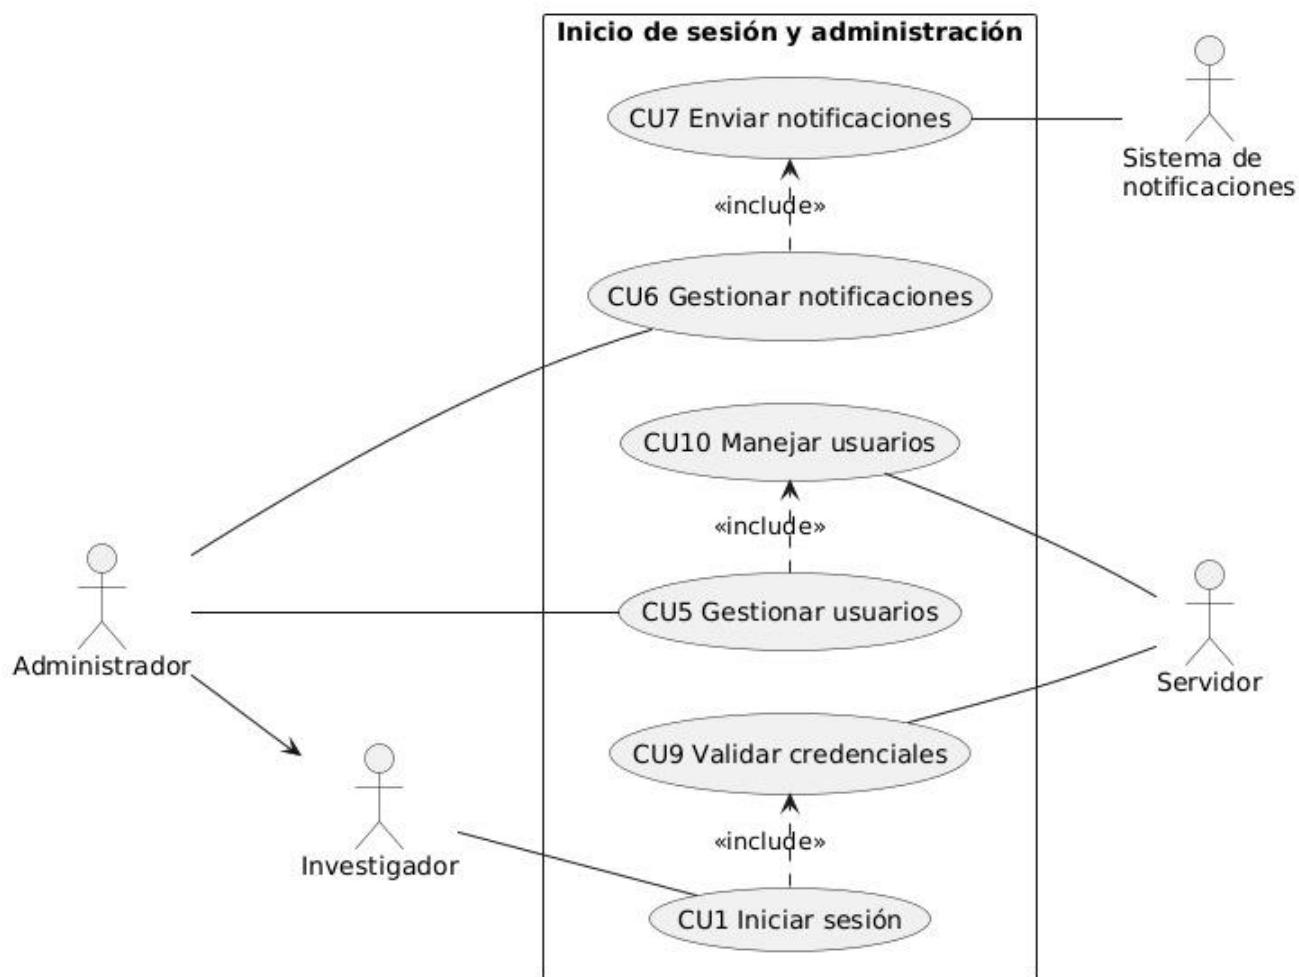


Ilustración 64: Diagrama de casos de uso para inicio de sesión [autoría propia]

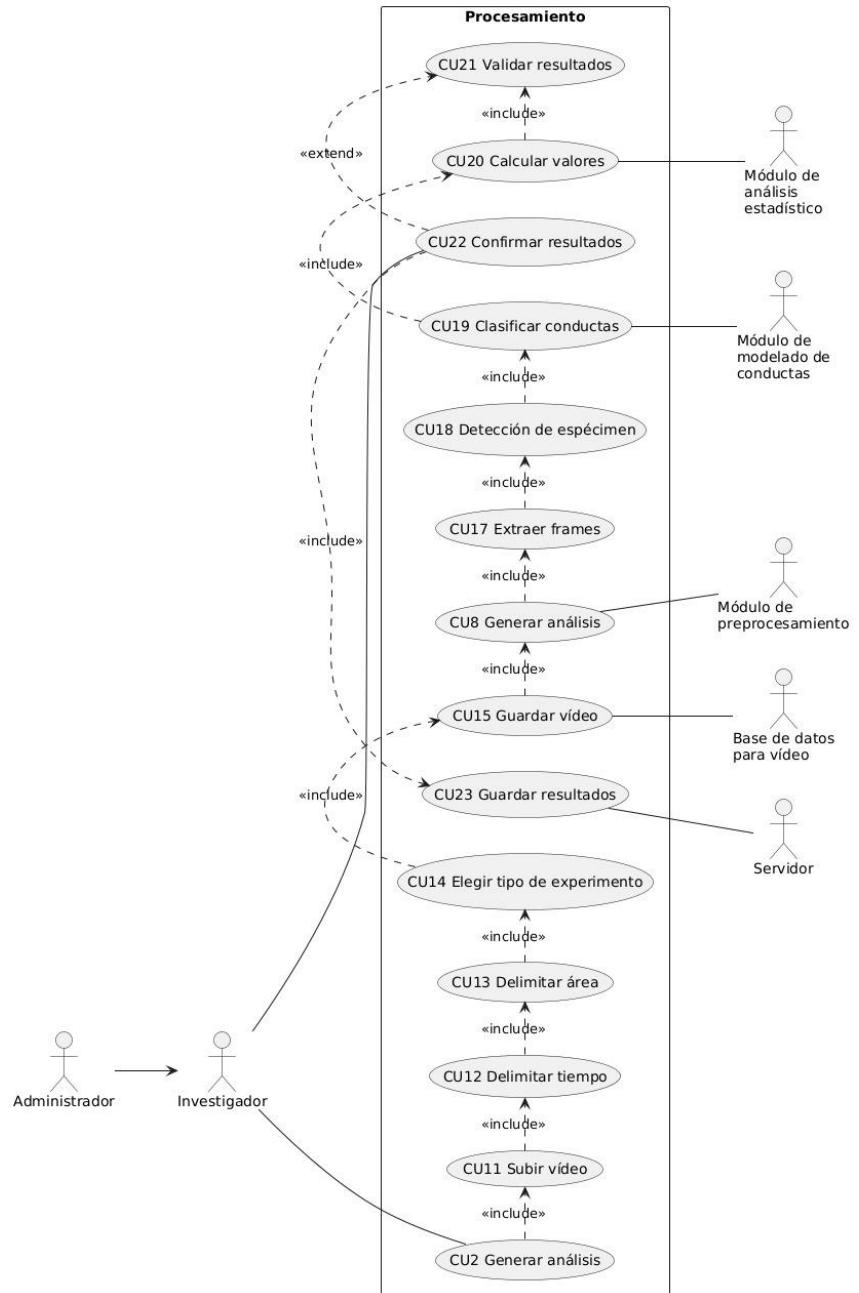


Ilustración 65: Diagrama de casos de uso para procesamiento [autoría propia]

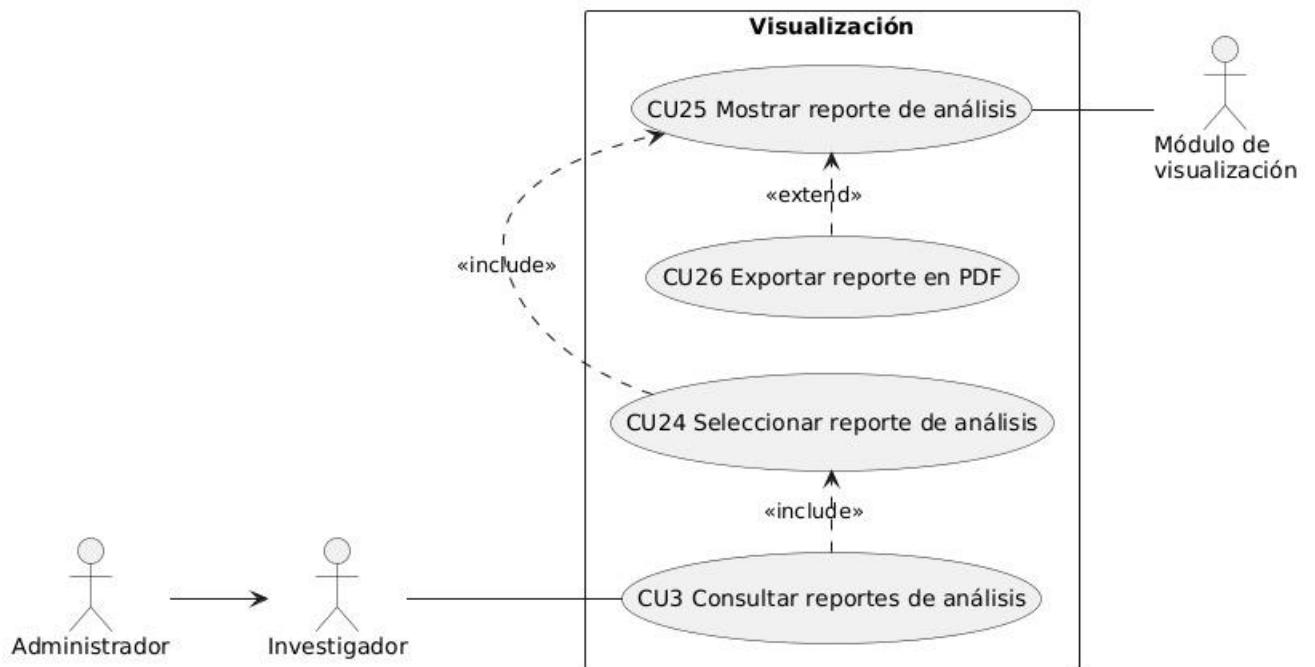


Ilustración 66: Diagramas de casos de uso para visualización [autoría propia]

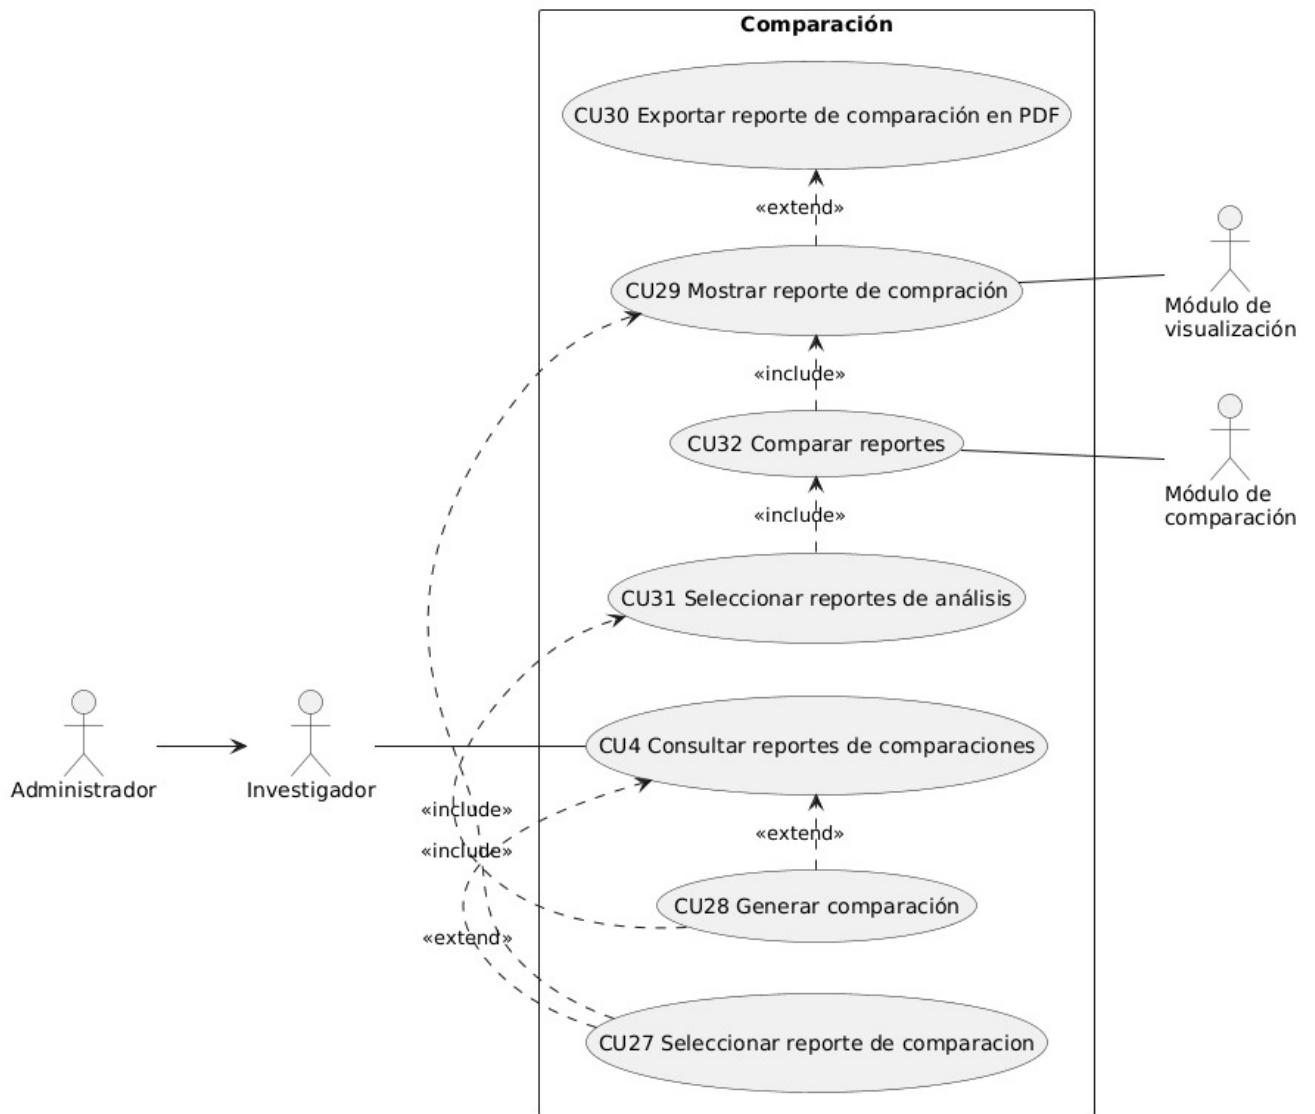


Ilustración 67: Diagrama de casos de uso para comparación [autoría propia]

